



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE
DEPARTAMENTO DE INGENIERÍA INDUSTRIAL Y DE SISTEMAS
ICS2563 ECONOMETRÍA APLICADA - 2025'2
Profesor: PATRICIO DOMÍNGUEZ
Ayudantes: GONZALO AGUILAR (GONZALO.AGUILAR@UC.CL) Y CATALINA ALEGRÍA
(CALEGRIAK@UC.CL)

Ayudantía 7

POF y RCT

3 de octubre de 2025

Potential Outcome Framework

Esta metodología corresponde en realidad a establecer la terminología a utilizar durante todo el capítulo de causalidad. Para ello, suponemos que queremos obtener cómo un tratamiento afecta a cierta situación, que corresponde a la variable dependiente. Así, suponiendo que tratamos con n unidades experimentales, tenemos la siguiente notación para $i \in \{1, \dots, n\}$.

- $D_i := \{0, 1\}$: Corresponde a una variable binaria, que indica si la unidad experimental i obtuvo el tratamiento.
- Y_i : Corresponde a la variable dependiente, que en nuestra nueva notación llamaremos *outcome*, de la unidad experimental i .
- Y_{1i} e Y_{0i} : Corresponde al *outcome* del individuo i , pero esta vez considera si fue tratado Y_{1i} o si no fue tratado Y_{0i} . Una notación equivalente es $Y_{1i} = Y_i(1)$ y $Y_{0i} = Y_i(0)$. **Nótese que nunca ocurrirá en la realidad que el individuo sea tratado y a la vez no sea tratado.**
- $\tau_i = Y_{1i} - Y_{0i} = Y_i(1) - Y_i(0)$: Corresponde al efecto del tratamiento D_i , en el individuo i . **Nótese que como nunca se observará Y_{0i} e Y_{1i} a la vez, nunca se podrá observar τ_i .**

Por lo tanto, bajo la notación anterior, y como en la realidad un individuo no puede estar tratado y no tratado a la vez, se puede escribir el *outcome* que nos interesa, y que es el observado:

$$Y_i = Y_{0i} + (Y_{1i} - Y_{0i})D_i \quad \forall i \in \{1, \dots, n\} \quad (1)$$

Toda la notación anterior es conocida como notación de Neyman-Rubin, y particularmente la ecuación (1) corresponde a cómo se escribiría la variable dependiente en esta notación.

Finalmente, dado un tratamiento D_i , lo que podemos conocer es:

$$\begin{aligned}
 \underbrace{\mathbb{E}[Y_{1i} | D_i = 1] - \mathbb{E}[Y_{0i} | D_i = 0]}_{\text{Diferencia observada}} &= \mathbb{E}[Y_{1i} | D_i = 1] + \underbrace{\mathbb{E}[Y_{0i} | D_i = 1] - \mathbb{E}[Y_{0i} | D_i = 1]}_{\text{Equivalente a sumar 0}} - \mathbb{E}[Y_{0i} | D_i = 0] \\
 &= \underbrace{\mathbb{E}[Y_{1i} | D_i = 1] - \mathbb{E}[Y_{0i} | D_i = 1]}_{\text{ATT}} + \underbrace{\mathbb{E}[Y_{0i} | D_i = 1] - \mathbb{E}[Y_{0i} | D_i = 0]}_{\text{Sesgo de selección}} \quad (2)
 \end{aligned}$$

De la ecuación (2) se puede desprender el *Average Treatment on the Treated* (ATT), o efecto promedio sobre los tratados, así como el sesgo de selección. Particularmente, se puede notar que

$$\text{ATT} = \mathbb{E}[Y_{1i} | D_i = 1] - \mathbb{E}[Y_{0i} | D_i = 1] = \mathbb{E}[Y_{1i} - Y_{0i} | D_i = 1] = \mathbb{E}[\tau_i | D_i = 1]$$

Pero ya vimos que el τ_i no es observable. Nos interesa entonces estimar el valor esperado de τ_i , aún sin condicionar por tratados y no tratados, es decir, nos interesa el *Average Treatment Effect* (ATE), o efecto promedio del tratamiento, y se define según:

$$\text{ATE} = \mathbb{E}[\tau_i] = \mathbb{E}[Y_{1i} - Y_{0i}]$$

¿Cómo podemos obtenerlo, si sabemos que no podemos observar τ ?

Grupos de tratamiento, control, y contrafactuales

Antes de obtener la respuesta a la pregunta anterior, vale la pena definir a la unidades experimentales desde cierta perspectiva. Consideraremos **grupo de tratamiento** a todas aquellas unidades experimentales que hayan sido efectivamente tratadas, es decir, Y_{1i} sea observable. Por otra parte, definiremos **grupo de control** a todas aquellas unidades experimentales que no hayan sido tratadas en la realidad, es decir, Y_{0i} sea observable.

Ahora bien, un contrafactual corresponde al *qué pasaría si*, es decir, aún sabiendo que una unidad pertenece al grupo de tratamiento o control, el contrafactual es exactamente la misma unidad experimental, pero considerada en el grupo al que no pertenece. Así:

- Si Y_i está en el grupo de tratamiento, entonces sabemos que Y_{1i} es observable. Llamaremos **contrafactual** de esta unidad a Y_{0i} , que no es observable y pertenece al grupo de control.
- Si Y_i está en el grupo de control, entonces sabemos que Y_{0i} es observable. Llamaremos **contrafactual** de esta unidad a Y_{1i} , que no es observable y pertenece al grupo de tratamiento.

Randomized Controlled Trials

Ahora si podemos responder a la pregunta previa. Para ello, definimos la metodología RCT. RCT hace referencia a la sigla en inglés de *Randomized Controlled Trials*, o Ensayo Clínico

Aleatorizado, y corresponde a una metodología que permite recuperar el efecto causal en un estudio. Su fundamento de basa en el mismo problema presentado anteriormente, donde tenemos un *outcome* y un tratamiento que asignar. La clave, es que en RCT el tratamiento es asignado de manera aleatoria, es decir, no nos interesa cuál de los individuos fue tratado y cual no.

Bajo RCT, y la notación de Neyman-Rubin, notemos que D_i es asignado de manera aleatoria, por lo tanto no depende de i , lo que permite establecer la siguiente igualdad:

$$\mathbb{E}[Y_{0i} | D_i = 0] = \mathbb{E}[Y_{0i} | D_i = 1] \wedge \mathbb{E}[Y_{1i} | D_i = 0] = \mathbb{E}[Y_{1i} | D_i = 1]$$

De esta manera, el grupo de control es un válido contrafactual del grupo de tratamiento y viceversa. Por lo tanto, en nuestra definición de ATT, se puede notar que bajo RCT se tiene

$$ATT = \mathbb{E}[Y_{1i} - Y_{0i} | D_i = 1] = \mathbb{E}[\tau_i | D_i = 0] = \mathbb{E}[\tau_i] = \mathbb{E}[Y_{1i} - Y_{0i}] = ATE$$

y por la propiedad lineal del operador esperanza, se tiene que

$$ATE = \mathbb{E}[Y_{1i}] - \mathbb{E}[Y_{0i}]$$

que ahora si puede estimarse, porque los grupos de control y tratamiento son, entre sí, contrafactuales.

Tablas de balance

Una tabla de balance es útil para comprender cómo se relacionan los grupos de tratamiento y control en distintas variables. En términos prácticos, una tabla de balance presenta la siguiente estructura:

Variable	Tratamiento	Control	Valor-p para la diferencia
Nombre variable 1	Promedio de la variable 1 en el grupo de tratamiento	Promedio de la variable 1 en el grupo de control	Valor-p que indica la diferencia entre medias
$\vdots$	$\vdots$	$\vdots$	$\vdots$

La tabla de balance pretende presentar el promedio entre los grupos de tratamiento y control, y a partir del valor-p, hacer notar que la diferencia de media entre las variables es o no significativa. Así, el valor-p es para el siguiente test de hipótesis:

$$H_0 : promedio(variable_i)_{tratamiento} = promedio(variable_i)_{control}$$

$$v/s$$

$$H_a : promedio(variable_i)_{tratamiento} \neq promedio(variable_i)_{control}$$

Por lo tanto, para un nivel de significancia α , rechazamos H_0 si $valor - p < \alpha$.

Pregunta 1: POF

Un investigador quiere estimar el efecto causal de asistir a la universidad sobre el salario esperado. Para ello cuenta con la siguiente información de 5 individuos, incluyendo sus salarios potenciales (en miles de pesos) y su decisión real de estudiar o no. Sin embargo, un colega sospecha que uno de los datos podría estar equivocado o incompleto.

Individuo (i)	Salario Universitario (Y_{1i})	Salario No Universitario (Y_{0i})	Estudio Universitario (D_i)
1	660	600	1
2	590	540	1
3	600	620	0
4	550	530	0
5	620	580	1

- a) Suponiendo que todos los datos son correctos, calcule el efecto promedio del tratamiento (ATE) de ir a la universidad.

Solución: Como tenemos los resultados potenciales, calculamos el ATE como:

$$ATE = \mathbb{E}(\tau_i) = \frac{1}{5} \sum_{i=1}^5 (Y_{1i} - Y_{0i}) = \frac{60 + 50 - 20 + 20 + 40}{5} = 30$$

- b) Ahora suponga que el investigador no puede observar los contrafactuales, solo los salarios efectivamente realizados. Calcule la diferencia de medias entre quienes asistieron y quienes no asistieron a la universidad.

Solución: Ahora no tenemos los contrafactuales de cada observación. La media de salarios de quienes efectivamente asistieron a la universidad sería:

$$\bar{Y}_{D=1} = \mathbb{E}(Y_{1i} | D_i = 1) = \frac{660 + 590 + 620}{3} = 623,333$$

Y para los que no asistieron a la universidad:

$$\bar{Y}_{D=0} = \mathbb{E}(Y_{0i} | D_i = 0) = \frac{620 + 530}{2} = 575$$

Entonces la diferencia de medias sería:

$$\bar{Y}_{D=1} - \bar{Y}_{D=0} = 48,333$$

- c) Compare ambos resultados y explique el rol del sesgo de selección. ¿En qué casos la diferencia de medias coincide con el ATE?, ¿Qué puede decir sobre la sospecha del dato equivocado?

Solución: A primera vista, hay una clara diferencia entre el ATE estimado (30) y la diferencia de medias (48,333). Este último sobreestima el efecto promedio de ir a la universidad en el salario. Como sabemos:

$$\underbrace{\mathbb{E}[Y_{1i} | D_i = 1] - \mathbb{E}[Y_{0i} | D_i = 0]}_{\text{Diferencia observada}} = \underbrace{\mathbb{E}[Y_{1i} | D_i = 1] - \mathbb{E}[Y_{0i} | D_i = 1]}_{\text{TOT}} + \underbrace{\mathbb{E}[Y_{0i} | D_i = 1] - \mathbb{E}[Y_{0i} | D_i = 0]}_{\text{Sesgo de selección}}$$

Calculando el ATT o TOT y el sesgo obtenemos:

$$\begin{aligned} \text{TOT} &= \frac{60 + 50 + 40}{3} = 50 \\ \mathbb{E}(Y_0 | D = 1) &= \frac{600 + 540 + 580}{3} = 573,333, \quad \mathbb{E}(Y_0 | D = 0) = 575 \\ \text{sesgo} &= [\mathbb{E}(Y_0 | D = 1) - \mathbb{E}(Y_0 | D = 0)] = -1,666 \end{aligned}$$

Por lo tanto, en este caso la diferencia de medias equivale más al TOT que al ATE. Para que la diferencia de medias coincidiera con el ATE en primer lugar debería haber asignación aleatoria, ya que los individuos se autoseleccionan para estudiar o no. Esto se puede ver en el sesgo, que es distinto de 0. Además, las personas que decidieron estudiar es porque tenían un mayor beneficio al hacerlo que los que decidieron no estudiar. En relación a esto, el dato del que se sospecha podría ser el individuo 3, ya que se tiene un mayor salario no estudiando, lo que no coincide con las otras observaciones. Lo anterior denota otro supuesto clave: que los efectos deben ser homogéneos para todos.

- d) Compare los estimadores ATE y TOT y discuta en qué situaciones pueden diferir.

Solución: Recordemos que $ATE = 30$ y $TOT = 50$. Como se habló anteriormente, en esta situación los que fueron tratados (estudiaron) eran los que tenían mayor beneficio de hacerlo. Por lo tanto, hay un sesgo de selección que no permite que el TOT sea equivalente al ATE, e incluso lo sobreestima. Por lo que el TOT no es un estimador representativo de la población promedio, si no que probablemente de un grupo con ciertas características en común y con efectos heterogéneos al tratamiento.

Pregunta 2: RCT y covariables

El Ministerio de Transporte quiere evaluar el impacto de un programa de pases gratuitos de transporte público sobre la empleabilidad de jóvenes recién egresados.

Para ello, se entrega aleatoriamente el pase a algunos jóvenes, y se observa el resultado en términos de salarios. La base de datos contiene: `salario_base`, `treat`, `edad`, `educ_padres`, `distancia`.

-
- a) Estime el efecto del pase gratuito sobre los salarios utilizando únicamente la variable de tratamiento y el outcome (`salario_base`). Realice una simulación con 500 iteraciones y muestras de 80 observaciones, y grafique la **densidad de kernel** de los coeficientes.
 - b) Repita el análisis incorporando la covariable `educ_padres`. Discuta si la **precisión** de los coeficientes cambia en comparación con (a).
 - c) Incorpore ahora `educ_padres` y `distancia`. ¿Cómo afecta esta variable adicional al estimador? ¿Por qué es irrelevante en este DGP?
 - d) Compare los resultados de (a), (b) y (c). ¿Qué concluye respecto al efecto de incluir covariables relevantes e irrelevantes en un RCT?
 - e) Suponga ahora que la asignación **no fue completamente aleatoria**: los jóvenes que vivían más lejos tenían más probabilidad de recibir el pase (`treat_sesgado`). El nuevo outcome es `salario_sesgado`, que además depende negativamente de la distancia.
 - I) Estime el efecto del programa con una regresión simple.
 - II) Estime el efecto del programa con una regresión que incluya covariables (`educ_padres`, `distancia`).

Compare las densidades de ambos estimadores y discuta el rol del **sesgo de selección**.

Solución: El Script de R se encuentra subido, ahí se grafican las densidades con los que se discuten las preguntas.

- a) Gráfico en R.
- b) Al agregar esta covariable la precisión de los estimadores cambia, ya que en comparación al gráfico de la regresión simple, en este hay menos varianza. Visualmente, se reconoce porque la curva es menos “chata”. Entonces, agregar esta variable mejora la precisión. Sin embargo, vemos que no es una variable relevante omitida, ya que en ese caso la media se movería por el eje x.
- c) Al agregar como covariable nivel educativo de los padres y distancia a la regresión, la curva es muy parecida a la regresión con covariable solo educación de los padres. Esto quiere decir que, al agregar distancia, la densidad de los datos no cambia mucho. Por lo que, no mejora la precisión y es una variable irrelevante.
- d) Vemos que ahora la densidad de la regresión simple tiene mucha varianza y no parece estar centrada en un valor específico. Sin embargo, cuando controlamos agregando las covariables, la varianza se reduce mucho y parece estar centrada en un valor. Cuando no controlamos por variables relevantes que explican el sesgo, estamos estimando un coeficiente con sesgo, en donde puede haber mucho error y variabilidad. Si controlamos por una variable relevante que explica el sesgo, estamos recuperando el efecto del tratamiento.

Pregunta 3: Tablas de balance

Como investigador desconfiado, quiere verificar si la asignación de los pases fue efectivamente aleatoria.

- a) Usando la asignación aleatoria (`treat`), construya una **tabla de balance** para `edad`, `educ_padres` y `distancia`. ¿Se observan diferencias significativas entre los grupos tratado y control?

Solución: No se observan mayores diferencias entre grupos a primera vista. Fijandonos en los valores p, ninguno da significativo, por lo que los dos grupos en términos de covariables son comparables.

- b) Repita el ejercicio usando la asignación sesgada (`treat_sesgado`). ¿Qué variable muestra desbalance evidente entre tratados y controles?

Solución: Se observa que la covariable de distancia es evidentemente distinta entre el grupo de tratado y de control.

- c) Explique qué implicancias tienen estas diferencias para la **validez interna** del experimento. Relacione con la idea de contrafactual válido.

Solución: Si las covariables están desbalanceadas, los grupos tratado y control no son comparables y la estimación pierde validez interna. El grupo control ya no representa un contrafactual válido, porque las diferencias en el resultado pueden deberse tanto al tratamiento como a la covariable desbalanceada.