



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE  
DEPARTAMENTO DE INGENIERÍA INDUSTRIAL Y DE SISTEMAS  
ICS2563 ECONOMETRÍA APLICADA - 2025'2  
**Profesor:** PATRICIO DOMÍNGUEZ  
**Ayudantes:** ANTONIO LÓPEZ (ANTONIO.LOPEZ.MAS@UC.CL)  
LUZ MARÍA INFANTE (LINFANTEK@UC.CL)

## Ayudantía 9

### Repaso I2

15 de octubre de 2025

### Pregunta 1: DD, DDD y RCT

Se quiere evaluar el impacto de una política que incentiva la pesca en la región de Valparaíso. Esta política fue implementada el 1 de enero de 2025 en la comuna de Viña del Mar. A continuación se tiene la siguiente información sobre las toneladas de pesca por año y comuna <sup>1</sup>:

| Año  | Valparaíso | Viña | Concón |
|------|------------|------|--------|
| 2023 | 110        | 145  | 50     |
| 2024 | 150        | 146  | 51     |
| 2025 | 190        | 160  | 52     |

#### Preguntas:

- (a) Plantee el modelo de DD

$$\text{Pesca}_{it} = \beta_0 + \beta_1 \text{Tratado}_i + \beta_2 \text{Post}_t + \beta_3 (\text{Tratado}_i \cdot \text{Post}_t) + \varepsilon_{it}$$

Donde  $\text{Pesca}_{it}$  es el outcome a medir (toneladas de pescado al año) de la comuna  $i$  en el año  $t$ ,  $\text{Tratado}_i$  indica si la comuna  $i$  recibió este incentivo y  $\text{Post}_t$  indica si el año  $t$  es posterior a la implementación de este piloto.

- (b) Elija una comuna para utilizar como contrafactual y justifique su respuesta. Para esto puede apoyarse en gráficos.

En un marco de DD el supuesto central es el de tendencias paralelas. Este supuesto indica que las comunas a comparar en este caso no necesariamente deben tener un número similar de toneladas de pesca al año, pero si deberían haber presentado una

---

<sup>1</sup>Información no es basada en hechos reales

tendencia similar en caso de no haberse asignado el tratamiento. Si bien este supuesto no se puede probar (es imposible saber qué hubiera pasado en ese caso) se puede analizar la tendencia hacia atrás de las comunas. En el caso de que con anterioridad hayan presentado una tendencia similar, no es descabellado pensar que se hubieran mantenido con la misma tendencia si no hubiese ocurrido el tratamiento. Graficando los datos de la tabla se obtiene:




Figura 1: Toneladas de pesca según comuna y año

En el gráfico es fácil ver como las comunas de Valparaíso y Viña del mar tenían niveles de pesca muy parecidos los años 2023 y 2024 (o al menos mucho más similares a los de Concón). Sin embargo, si se observa la **tendencia** de las comunas en este periodo, se aprecia que la comuna de Valparaíso tenía una tendencia bastante pronunciada al alza en este periodo, mientras que la pesca en Viña se mantuvo relativamente estable. Debido a esto, Concón presenta un contrafactual mejor, ya que sus niveles de pesca también se mantuvieron con la misma tendencia.

(c) Calcule el estimador de DD entre 2024 y 2025

Calculamos el estimador:

- $\Delta$  Viña:  $160 - 146 = 14$
- $\Delta$  Concón:  $52 - 51 = 1$

---

De este modo el estimador será  $14 - 1 = 13$

- (d) Interprete causalmente el coeficiente de DD y discuta su validez.

Asumiendo que se cumple el supuesto de tendencias paralelas podemos decir que la política de incentivo de pesca aumenta en 13 toneladas la producción anual de pescado en la comuna una vez implementada.

Dicho esto, es importante recordar que además de este supuesto, existe el supuesto de SUTVA (Stable Unit Treatment Value Assumption), el cual nos pide que todos los individuos tratados reciban el mismo tratamiento y que el tratamiento no afecte indirectamente al grupo control (el outcome de la comuna  $i$  no puede depender del tratamiento de una comuna  $j$ ). Este supuesto es más difícil de probar, sobre todo en este caso que se trata de pesca en comunas aledañas. Es plausible considerar que el hecho de exista un incentivo en Viña disminuya la pesca en Concón, ya que la cantidad de peces en el mar es limitada. Si esto sucede entonces no se estaría cumpliendo el supuesto SUTVA y nuestro grupo control no sería un contrafactual válido, por lo que el experimento pierde validez.

- (e) Asuma ahora que al gobierno le gustó su análisis y cree que el supuesto de SUTVA sí se cumple. Al gobierno le gustaría saber si este programa favorecerá más a los pescadores artesanales o a la pesca industrial. Para esto usted tiene la siguiente información<sup>2</sup>:

| Comuna | Tipo de pesca | Año  | Captura (toneladas) |
|--------|---------------|------|---------------------|
| Viña   | Artesanal     | 2024 | 50                  |
| Viña   | Artesanal     | 2025 | 70                  |
| Viña   | Industrial    | 2024 | 40                  |
| Viña   | Industrial    | 2025 | 42                  |
| Concón | Artesanal     | 2024 | 48                  |
| Concón | Artesanal     | 2025 | 50                  |
| Concón | Industrial    | 2024 | 42                  |
| Concón | Industrial    | 2025 | 43                  |

Indique el instrumento que utilizaría para medir el efecto deseado, cuál sería el coeficiente de interés y obtenga el resultado.

Para obtener el efecto diferencial del tratamiento en la pesca artesanal podemos utilizar triples diferencias. En este caso la regresión sería:

$$\begin{aligned} \text{Toneladas}_{it} = & \beta_0 + \beta_1 \text{Viña}_i + \beta_2 \text{PescaArtesanal}_p + \beta_3 \text{Post}_t \\ & + \beta_4 (\text{Viña}_i \times \text{PescaArtesanal}_p) + \beta_5 (\text{Viña}_i \times \text{Post}_t) \\ & + \beta_6 (\text{PescaArtesanal}_p \times \text{Post}_t) + \beta_7 (\text{Viña}_i \times \text{PescaArtesanal}_p \times \text{Post}_t) + \varepsilon_{itp} \end{aligned}$$

---

<sup>2</sup>Esta tabla contiene información no relacionada con la anterior. Se eligieron estos números de forma arbitraria con fines pedagógicos.

---

Donde el coeficiente de interés sería  $\beta_7$ , ya que presenta la interacción triple entre Viña (tratado), post y artesanal.

Para obtener el coeficiente, primero obtenemos los  $\Delta$  antes y después en cada sub grupo:

$$\begin{aligned}\text{Viña, Artesanal: } & 70 - 50 = 20 \\ \text{Viña, Industrial: } & 42 - 40 = 2 \\ \text{Concón, Artesanal: } & 50 - 48 = 2 \\ \text{Concón, Industrial: } & 43 - 42 = 1\end{aligned}$$

Después obtenemos la DD por tipo de pesca:

$$\begin{aligned}\text{DiD (Artesanal)} &= (20) - (2) = 18 \\ \text{DiD (Industrial)} &= (2) - (1) = 1\end{aligned}$$

Por último, obtenemos la triple diferencia:

$$\text{DDD} = \text{DiD(Artesanal)} - \text{DiD(Industrial)} = 18 - 1 = 17$$

Esto se interpreta como que el programa benefició en 17 toneladas adicionales a los pescadores artesanales vs a los pescadores industriales. (Asumiendo que se cumplan los supuestos discutidos previamente)

- (f) Compare la validez causal y la asignación de tratamiento para las estrategias de experimentos controlados aleatorios y de diferencia en diferencia utilizando el marco de resultados potenciales.

El marco de resultados potenciales indica que para cada unidad existen dos resultados potenciales.  $Y_i(1)$  donde la unidad recibe tratamiento y  $Y_i(0)$  donde la unidad no recibe tratamiento.

Por otro lado, el efecto causal por individuo es la diferencia del resultado al ser tratado y no ser tratado. Lo que no puede ser observado por el investigador.

En un ensayo aleatorio, la asignación del tratamiento se realiza al azar. Esto quiere decir que el tratamiento es independiente de los resultados potenciales, matemáticamente esto se expresa:

$$D_i \perp (Y_1, Y_0)$$

Por lo tanto en un RCT se cumplirá que:

$$ATE = E[Y_i | D_i = 1] - E[Y_i | D_i = 0]$$

El grupo de control es un buen contrafactual para el grupo de tratamiento. La media observada en el grupo tratado menos la del grupo control es una estimación insesgada del efecto causal promedio.

---

¿Que pasaría si en el caso donde aplique DD comparamos directamente la media entre los resultados?

$$\begin{aligned}\text{DiD} &= E[Y_i \mid D_i = 1, t = \text{post}] - E[Y_i \mid D_i = 0, t = \text{post}] \\ &= \delta + \lambda_{\text{post}} + \gamma_T - (\lambda_{\text{post}} + \gamma_C) \\ &= \delta + \gamma_T - \gamma_C\end{aligned}$$

Donde el efecto que nos interesa estimar es  $\delta$ .  $\lambda_t$  representa los efectos temporales, pre o post tratamiento y  $\gamma_i$  representa a los efectos fijos de grupo, Tratamiento o Control. Si solo calculamos la diferencia entre grupos post tratamiento generamos un sesgo de selección ( $\gamma_T - \gamma_C$ ).

Para deshacernos de este sesgo de selección implementamos las Diferencias en Diferencias. Calculamos la diferencia entre el grupo de control antes del tratamiento.

$$\begin{aligned}&= E[Y_i \mid D_i = 1, t = \text{pre}] - E[Y_i \mid D_i = 0, t = \text{pre}] \\ &= \lambda_{\text{pre}} + \gamma_T - (\lambda_{\text{pre}} + \gamma_C) \\ &= \gamma_T - \gamma_C\end{aligned}$$

Y finalmente podemos recuperar el efecto que nos interesa realizando diferencias en diferencias.

$$\begin{aligned}\text{DiD} &= E[Y_i \mid D_i = 1, t = \text{post}] - E[Y_i \mid D_i = 1, t = \text{pre}] \\ &\quad - E[Y_i \mid D_i = 0, t = \text{post}] - E[Y_i \mid D_i = 0, t = \text{pre}] = \delta\end{aligned}$$

Esto es válido solo si se cumple el supuestos de tendencias paralelas y de identificación. Sobre las asignaciones de tratamiento, un RCT tiene asignación completamente aleatoria mientras que DiD tiene asignaciones no aleatorias del tratamiento.

## Pregunta 2: Efectos fijos

Se quiere evaluar el efecto del ejercicio sobre la cantidad de veces al año que alguien se resfría. Estudiamos esto en base a dos individuos. Sospechamos que la genética de cada individuo tiene un impacto en la tendencia a resfriarse de cada persona. Esta variable es no observable, así que la controlaremos mediante efectos fijos.

| Individuo | Año  | Ejercicio (hrs/sem) | Resfríos (al año) |
|-----------|------|---------------------|-------------------|
| A         | 2019 | 5                   | 2                 |
| A         | 2020 | 7                   | 1                 |
| B         | 2019 | 4                   | 4                 |
| B         | 2020 | 3                   | 5                 |

**Preguntas:**

- (a) Utilizando los datos de la tabla, estime el coeficiente within.

Partimos del modelo

$$y_{it} = \beta x_{it} + c_i + u_{it},$$

donde  $c_i$  capta heterogeneidad inobservable constante en el tiempo (p. ej., “genética”). La transformación *within* resta a cada variable su media individual:

$$\tilde{y}_{it} \equiv y_{it} - \bar{y}_i, \quad \tilde{x}_{it} \equiv x_{it} - \bar{x}_i,$$

Esto elimina  $c_i$  porque no varía en  $t$ , y permite estimar  $\beta$  por MCO usando sólo variación temporal dentro de cada individuo. Con  $T = 2$ , el estimador *within* coincide con primeras diferencias:

$$\Delta y_i = y_{i2} - y_{i1} = \beta_{within} (x_{i2} - x_{i1}) + (u_{i2} - u_{i1}).$$

Entonces, con los datos de la tabla podemos calcular  $\tilde{y}_{it}$ ,  $\bar{y}_i$ ,  $\tilde{x}_{it}$  y  $\bar{x}_i$ , Y luego estimamos

| Individuo | Año  | Ejercicio | Media(Ej.) | Within(Ej.) | Resfríos | Media(Resf.) | Within(Resf.) |
|-----------|------|-----------|------------|-------------|----------|--------------|---------------|
| A         | 2019 | 5         | 6.0        | -1.0        | 2        | 1.5          | 0.5           |
| A         | 2020 | 7         | 6.0        | 1.0         | 1        | 1.5          | -0.5          |
| B         | 2019 | 4         | 3.5        | 0.5         | 4        | 4.5          | -0.5          |
| B         | 2020 | 3         | 3.5        | -0.5        | 5        | 4.5          | 0.5           |

$\beta_{within}$ :

$$\hat{\beta}_{FE} = \frac{\sum_{i,t} \tilde{x}_{it} \tilde{y}_{it}}{\sum_{i,t} \tilde{x}_{it}^2} = \frac{(-1)(0,5) + (1)(-0,5) + (0,5)(-0,5) + (-0,5)(0,5)}{(-1)^2 + (1)^2 + (0,5)^2 + (-0,5)^2} = \frac{-1,5}{2,5} = -0,6.$$

**Interpretación:** con características fijas controladas, +1 hora de ejercicio a la semana se asocia con **0,6** resfríos menos al año.

- (b) Calcule el coeficiente  $\beta_{between}$  y compárelo con  $\beta_{within}$ .

El estimador *between* se calcula en base a las medias de los individuos sobre el tiempo. Es decir, calculamos el promedio de  $x$ ,  $y$  y  $\epsilon$  entre todos los datos de un mismo individuo a través del tiempo.

$$\bar{y}_i = \alpha + \beta_{between} \bar{x}_i + \bar{\epsilon}_i$$

$$\hat{\beta}_{between} = \frac{\text{Cov}(\bar{x}_i, \bar{y}_i)}{\text{Var}(\bar{x}_i)}.$$

Ya calculamos las medias por individuo:

$$[\bar{x}_A, \bar{y}_A] = [6,0, 1,5]$$

---


$$[\bar{x}_B, \bar{y}_B] = [3,5, 4,5]$$

Luego el promedio entre todas las observaciones para x e y es:

$$[\bar{x}, \bar{y}] = [4,75, 3,0]$$

Las desviaciones para cada individuo son:

$$A: [\bar{x}_i - \bar{x}, \bar{y}_i - \bar{y}] = [1,25, -1,5]$$

Entonces la covarianza es:

$$\sum_i (\bar{x}_i - \bar{x})(\bar{y}_i - \bar{y}) = 1,25(-1,5) + (-1,25)(1,5) = -3,75.$$

Y la varianza:

$$\sum_i (\bar{x}_i - \bar{x})^2 = 1,25^2 + (-1,25)^2 = 3,125.$$

Finalmente, el coeficiente between es:

$$\hat{\beta}_{\text{between}} = \frac{-3,75}{3,125} = -1,2.$$

El estimador *between* usa diferencias entre individuos y, por tanto, mezcla el efecto del ejercicio con heterogeneidad fija (p.ej., genética o hábitos no observados). Si esos rasgos se correlacionan con el ejercicio, el estimador *between* es sesgado para el efecto causal.

El estimador *within* usa variación temporal dentro de cada individuo, eliminando cualquier factor fijo. Bajo los supuestos de efectos fijos (exogeneidad condicional en  $c_i$ ),  $\hat{\beta}_{\text{FE}}$  identifica el efecto del ejercicio, mientras que  $\hat{\beta}_{\text{between}}$  no necesariamente. En este ejemplo,  $\hat{\beta}_{\text{between}}$  es más extremo ( $-1,2$  vs.  $-0,6$ ) porque las diferencias fijas entre individuos amplifican la pendiente.

- (c) Recupere el valor de los efectos fijos de cada persona

Los efectos fijos de cada individuo se pueden obtener utilizando el promedio de cada individuo y el estimador within calculado.

$$\hat{c}_i = \bar{y}_i - \hat{\beta}_{\text{within}} \bar{x}_i.$$

A:

$$\hat{c}_{\text{Tú}} = 1,5 - (-0,6) \cdot 6 = 1,5 + 3,6 = 5,1.$$

B:

$$\hat{c}_{\text{Yo}} = 4,5 - (-0,6) \cdot 3,5 = 4,5 + 2,1 = 6,6.$$

---

### Pregunta 3: Estimadores *whitin* y *between*

Se dispone de un conjunto de datos agrupados en varias categorías o grupos, y se desea estimar la relación entre una variable dependiente  $y$  y una variable independiente  $x$ . Existen tres formas alternativas de formular el modelo de regresión, cada una basada en un enfoque diferente:

$$y_{it} = \alpha + \beta_{total}x_{it} + \epsilon_{it} \quad (1)$$

$$(y_{it} - \bar{y}_i) = \beta_{whitin}(x_{it} - \bar{x}_i) + \epsilon_{it} + \bar{\epsilon}_i \quad (2)$$

$$\bar{y}_i = \alpha + \beta_{between}\bar{x}_i + \bar{\epsilon}_i \quad (3)$$

- a) Demuestre algebraicamente que los estimadores obtenidos de cada uno de estos modelos están relacionados entre sí.

**Solución:** Los tres son modelos de regresión, y en principio, los tres pueden ser estimados mediante MCO (note que (3) sólo utiliza  $n$  observaciones, las medias de los grupos). Consideremos, entonces, las matrices de sumas de cuadrados y productos cruzados que se utilizarían en cada caso, donde nos centraremos solo en la estimación de  $\beta_{total}$ . En (1), los momentos serían sobre las medias totales,  $\bar{y}$  y  $\bar{x}$ , y utilizaríamos las sumas totales de cuadrados y productos cruzados,

$$S_{xx}^{total} = \sum_{i=1}^n \sum_{t=1}^T (x_{it} - \bar{x})(x_{it} - \bar{x})'$$

$$S_{xy}^{total} = \sum_{i=1}^n \sum_{t=1}^T (x_{it} - \bar{x})(y_{it} - \bar{y})$$

Para (2), como los datos están ya en desviaciones, las medias de  $(y_{it} - \bar{y}_i)$  y  $(x_{it} - \bar{x}_i)$  son cero. Las matrices de momentos son sumas de cuadrados y productos cruzados *within* (es decir, desviaciones de las medias de los grupos),

$$S_{xx}^w = \sum_{i=1}^n \sum_{t=1}^T (x_{it} - \bar{x}_i)(x_{it} - \bar{x}_i)'$$

$$S_{xy}^w = \sum_{i=1}^n \sum_{t=1}^T (x_{it} - \bar{x}_i)(y_{it} - \bar{y}_i)$$

Finalmente, para (3), la media de las medias de los grupos es la media total. Las matrices de momentos son las sumas de cuadrados y productos cruzados *between*,

$$S_{xx}^b = \sum_{i=1}^n T(\bar{x}_i - \bar{x})(\bar{x}_i - \bar{x})'$$

---


$$S_{xy}^b = \sum_{i=1}^n T(\bar{x}_i - \bar{\bar{x}})(\bar{y}_i - \bar{\bar{y}})$$

Es fácil comprobar que

$$S_{xx}^{total} = S_{xx}^w + S_{xx}^b$$

y

$$S_{xy}^{total} = S_{xy}^w + S_{xy}^b$$

Hay, por tanto, tres posibles estimadores de mínimos cuadrados de  $\beta_{total}$  (por notación, la estimación de  $\beta_{total}$  será  $b'$ ), que corresponden a la descomposición analizada. El estimador de mínimos cuadrados es

$$b' = [S_{xx}^{total}]^{-1} S_{xy}^{total} = [S_{xx}^w + S_{xx}^b]^{-1} [S_{xy}^w + S_{xy}^b] \quad (4)$$

El estimador *within* es

$$b^w = [S_{xx}^w]^{-1} S_{xy}^w$$

Mientras que el *between* es

$$b^b = [S_{xx}^b]^{-1} S_{xy}^b$$

Éste es el estimador de mínimos cuadrados en los  $n$  conjuntos de medias de grupos. De la expresión anterior

$$S_{xy}^w = S_{xx}^w b^w$$

y

$$S_{xy}^b = S_{xx}^b b^b$$

Insertando estos resultados en (4), vemos que el estimador de MCO es un promedio ponderado matricialmente, de los estimadores *within* y *between*:

$$b' = F^w b^w + F^b b^b$$

donde

$$F^w = [S_{xx}^w + S_{xx}^b]^{-1} S_{xx}^w = I - F^b$$

- b) Explique cómo el uso de las desviaciones *within* (2) y *between* (3) afecta la estimación de  $\beta$  en comparación con el *modelo clásico* (1), y discuta bajo qué circunstancias estos estimadores difieren más del estimador clásico.

**Solución:** El uso de las *desviaciones within* en el modelo de efectos fijos centra la estimación de  $\beta$  en las variaciones *dentro de los grupos*, eliminando los efectos no observados constantes entre los grupos. Esto proporciona una estimación más precisa cuando dichos efectos están correlacionados con las variables explicativas, evitando el sesgo que podría presentarse en el *modelo clásico*, que no distingue entre variabilidad intra-grupo y entre-grupos.

---

Por otro lado, el estimador *between*, que se basa únicamente en las diferencias entre las medias de los grupos, puede diferir más del estimador clásico cuando la mayor parte de la variabilidad se encuentra dentro de los grupos y no entre ellos. El estimador clásico combina ambas fuentes de variabilidad, por lo que si los efectos intra-grupo son importantes, tanto los estimadores *within* como *between* se alejarán del resultado del clásico.

## Pregunta 4

Imagine que usted desea evaluar el impacto de un nuevo suplemento deportivo sobre la fatiga muscular posterior al entrenamiento. Para ello, diseñó un experimento en el que una muestra aleatoria de deportistas recibe o no el suplemento (variable binaria  $S_i$ ), y al día siguiente se les mide el nivel de fatiga en una escala continua ( $y_i$ ).

- a) Plantee un modelo que le permita evaluar el efecto causal del suplemento sobre la fatiga muscular. Describa las variables a utilizar y la regresión a estimar.

**Solución:** Para evaluar el efecto causal del suplemento sobre la fatiga muscular, se definen las siguientes variables:

- $S_i = \begin{cases} 1 & \text{si el deportista } i \text{ recibió el suplemento,} \\ 0 & \text{en otro caso,} \end{cases}$
- $y_i = \text{nivel de fatiga muscular reportado por el deportista } i \text{ (escala continua).}$

El modelo a estimar corresponde a una regresión lineal simple:

$$y_i = \alpha + \rho S_i + \varepsilon_i,$$

donde  $\alpha$  representa la fatiga promedio del grupo que no recibió el suplemento,  $\rho$  mide el efecto causal del suplemento sobre la fatiga, y  $\varepsilon_i$  es un término de error con esperanza condicional cero.

- b) Usted observa que el nivel promedio de fatiga reportado entre quienes recibieron el suplemento es  $\bar{y}(1) = 3.1$ , mientras que entre quienes no lo recibieron fue  $\bar{y}(0) = 4.0$ . ¿Podría usted usar esta información para estimar el parámetro de interés de su modelo? Justifique formalmente bajo qué condición sería válido hacerlo.

**Solución:** Si la asignación del suplemento  $S_i$  fue completamente aleatoria, entonces  $S_i$  es independiente de los resultados potenciales  $y_i(1)$  y  $y_i(0)$ . Es decir:

$$S_i \perp (y_i(1), y_i(0)).$$

En ese caso, los grupos tratado y control son comparables y se cumple:

$$\mathbb{E}[y_i(0) \mid S_i = 1] = \mathbb{E}[y_i(0) \mid S_i = 0],$$

---

por lo que la diferencia de medias entre grupos identifica el efecto causal promedio (ATE):

$$\hat{\rho} = \bar{y}(1) - \bar{y}(0) = 3.1 - 4.0 = -0.9.$$

Esto indica que, en promedio, el suplemento reduce el nivel de fatiga muscular en 0.9 puntos en la escala considerada.

- c) Suponga ahora que, durante el experimento, se difundió el rumor de que el suplemento tenía un sabor muy desagradable, por lo que sólo una fracción  $q > 0$  de los deportistas asignados al tratamiento lo consumió efectivamente. Su asistente recolectó información sobre quién lo consumió ( $D_i = 1$  si lo hizo, 0 si no) y propone estimar directamente:

$$y_i = \alpha + \gamma D_i + \varepsilon_i$$

para medir el efecto del consumo. Explique por qué este enfoque podría entregar un estimador sesgado del efecto causal del suplemento.

**Solución:** En este caso,  $D_i$  no es una variable asignada aleatoriamente, sino que depende de decisiones individuales —por ejemplo, del gusto, la motivación o el cansancio inicial—, las cuales también podrían afectar el nivel de fatiga. Es decir,

$$D_i \not\perp (y_i(0), y_i(1)).$$

En tal caso, la estimación de  $\gamma$  incorpora dos componentes:

$$\hat{\gamma} = \underbrace{\mathbb{E}[y_i(1) \mid D_i = 1] - \mathbb{E}[y_i(0) \mid D_i = 1]}_{\text{efecto causal entre consumidores}} + \underbrace{\mathbb{E}[y_i(0) \mid D_i = 1] - \mathbb{E}[y_i(0) \mid D_i = 0]}_{\text{sesgo de selección}}.$$

El segundo término no es necesariamente cero, pues quienes decidieron consumir podrían diferir sistemáticamente de quienes no lo hicieron (por ejemplo, los más fatigados o más disciplinados). En consecuencia, la regresión sobre  $D_i$  estaría sesgada y no recuperaría el efecto causal puro del suplemento.

- d) Un colega le comenta que, además del consumo del suplemento, podría existir otro factor importante que usted no ha considerado en su análisis: la calidad del sueño de los deportistas la noche anterior al experimento. Le sugiere que este factor podría estar afectando tanto la decisión de consumir el suplemento ( $D_i$ ) como el nivel de fatiga reportado ( $y_i$ ). Explique cómo la omisión de esta variable podría sesgar su estimación del efecto causal del suplemento. Especifique la dirección esperada del sesgo y justifique su respuesta con base en la relación entre las variables.

**Solución:** Si la calidad del sueño ( $Q_i$ ) afecta simultáneamente la decisión de consumir el suplemento y el nivel de fatiga, su omisión genera un sesgo de variable omitida. El modelo verdadero sería:

$$y_i = \alpha + \rho D_i + \delta Q_i + u_i.$$

---

Al estimar un modelo sin  $Q_i$ , el estimador  $\hat{\rho}$  capta parcialmente el efecto de  $Q_i$  sobre  $y_i$ , en la medida en que  $D_i$  y  $Q_i$  estén correlacionados:

$$\text{Sesgo}(\hat{\rho}) = \delta \frac{\text{Cov}(D_i, Q_i)}{\text{Var}(D_i)}.$$

Si los deportistas con peor calidad de sueño tienden a consumir más el suplemento (porque se sienten más cansados), y además un mal sueño aumenta la fatiga ( $\delta > 0$ ), entonces  $\text{Cov}((D)_i, Q_i) < 0$  y el sesgo será negativo. En ese caso,  $\hat{\rho}$  subestimará el verdadero efecto del suplemento, haciendo que parezca más efectivo de lo que realmente es.