



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE
DEPARTAMENTO DE INGENIERÍA INDUSTRIAL Y DE SISTEMAS
ICS2563 ECONOMETRÍA APLICADA - 2025'2
Profesor: PATRICIO DOMÍNGUEZ
Ayudantes: CATALINA ALEGRÍA, FERNANDO TORO Y HERNÁN PALACIOS

Ayudantía 10

Variables Instrumentales

24 de octubre de 2025

Resumen

Causales de endogeneidad

Como ya sabemos, uno de los principales problemas de validez interna que se tiene al estimar a través del método MCO, por ejemplo una regresión simple del tipo $Y_i = \alpha + \rho S_i + \epsilon_i$ (1), es el sesgo de endogeneidad, por ejemplo, producido por una variable relevante omitida. Este sesgo se puede generar ya sea por: (i) la variable independiente está correlacionada con alguna variable no observada, y (ii) porque dicha variable no incluida está correlacionada con la variable dependiente. Por lo tanto, la variable no omitida (digamos A) está relacionada con el error, y por ende el supuesto básico del MCO no se cumple ($Cov(X_i, \epsilon_i) \neq 0$).

Variables Instrumentales

El método de variables instrumentales es una alternativa para calcular la regresión $Y_i = \alpha + \delta S_i + \gamma A + \epsilon_i$, donde la variable se sospecha S_i endógena. Para ello, este método utiliza una variable o “instrumento” exógeno, digamos Z .

Para que nuestro δ sea consistente, es necesario que se cumplan los siguientes supuestos:

1. **Relevancia:** $Cov(S_i, Z_i) \neq 0$ Este supuesto implica que dado que queremos utilizar al instrumento Z_i para representar a nuestra variable de interés S_i , dichas variables deben estar fuertemente correlacionadas. Una manera de evaluar si está condiciones se satisface es llevar a cabo una regresión del tipo: $S_i = \alpha + \delta Z_i + \epsilon_i$, y llevar a cabo una prueba de hipótesis (por ejemplo, estadístico F).
2. **Exogeneidad:** $Cov(\epsilon_i, Z_i) = 0$

Implica que nuestro instrumento no está correlacionado con el error ϵ_i , el cual incluye las variables no observadas por lo que es tan bueno como aleatorio.

3. Restricción de exclusión: $Cov(\epsilon_i, Z_i) = 0$

Este supuesto también implica que el instrumento no se correlaciona con la variable dependiente Y_i , es decir, que Z_i no tiene efecto directo sobre Y_i más allá de su efecto a través de S_i

De esta manera, al considerar las condiciones, podemos notar lo siguiente:

Sea

$$y_i = \alpha + \rho S_i + \gamma A_i + \epsilon_i$$

$$\begin{aligned} Cov(y_i, z_i) &= Cov(\alpha + \rho S_i + \gamma A_i + \epsilon_i, z_i) \quad (\text{Por (1)}) \\ &= Cov(\alpha, z_i) + Cov(\rho S_i, z_i) + Cov(\gamma A_i, z_i) + Cov(\epsilon_i, z_i) \\ &= \rho Cov(S_i, z_i) \quad (\text{Por Exclusión}) \end{aligned}$$

De esta manera, podemos tener una ecuación para estimar ρ ! En efecto, utilizando la condición de Relevancia, podemos dividir por $Cov(S_i, z_i)$ en la última línea de la expresión anterior y obtener:

$$\hat{\rho}_{IV} = \frac{Cov(y_i, z_i)}{Cov(S_i, z_i)} \quad (2)$$

Note que, sin variar la identidad (2), podemos multiplicar arriba y abajo por $Var(z_i)$, y obtener:

$$\hat{\rho}_{IV} = \frac{\frac{Cov(y_i, z_i)}{Var(z_i)}}{\frac{Cov(S_i, z_i)}{Var(z_i)}} \quad (3)$$

Pero como hemos visto anteriormente en el curso, $\frac{Cov(S_i, z_i)}{Var(z_i)}$ es el coeficiente de una regresión simple entre S_i y z_i , y $\frac{Cov(y_i, z_i)}{Var(z_i)}$ es el coeficiente de una regresión entre y_i y z_i . ¡Luego $\hat{\rho}_{IV}$ es la razón entre dos coeficientes de dos regresiones! Formalizando, tenemos:

$$S_i = \alpha_1 + \pi z_i + \mu_1 \quad (4)$$

$$y_i = \alpha_2 + \delta z_i + \mu_2 \quad (5)$$

luego $\hat{\rho}_{IV} = \frac{\delta}{\pi}$. A la regresión (4) se le conoce como **primera etapa**, en tanto a la regresión (5) se le conoce como **forma reducida**.

Estimador de Wald

Es el estimador IV más simple, consistiendo de un instrumento binario (dummy) y un regresor endógeno (sin covariables). Suponiendo la regresión $Y_i = \alpha + \rho s_i + \eta_i$ el estimador de Wald es (se demostrará en la ayudantía):

$$\hat{\rho} = \frac{\mathbb{E}[Y_i | Z_i = 1] - \mathbb{E}[Y_i | Z_i = 0]}{\mathbb{E}[S_i | Z_i = 1] - \mathbb{E}[S_i | Z_i = 0]} = \frac{\delta}{\pi}$$

Mínimos cuadrados de dos etapas

Supongamos que ahora queremos calcular un modelo sobreidentificado, esto es, cuyas variables endógenas poseen más de un instrumento (Z_1, Z_2). Para ello, existe una manera de agrupar la información de manera eficiente para producir un solo estimador, el método de 2SLS. Supongamos que queremos estimar una ecuación de la forma $Y = X_1\beta_1 + X_2\beta_2 + U$, donde X_1 es uno o más regresores endógenos y Z uno o más instrumentos que cumplen con los supuestos de relevancia y exclusión.

1. La primera etapa esta relacionada con el supuesto de relevancia. Consiste en utilizar los instrumentos para predecir el valor de la variable de interés X_1 . Acá llamaremos “Matriz de instrumentos expandida” a $\hat{Z} = [X_2', Z']$. La etapa nos pide regresionar $X_1 = \hat{Z}\delta + \epsilon$, para obtener una proyección $\hat{X}_1$ ortogonal a U , que corresponde a la parte de X explicada por los instrumentos y las variables exógenas.
2. La segunda etapa se relaciona con el supuesto de exogeneidad de los instrumentos, para así derivar estimadores insesgados de los coeficientes. Reemplazamos en la ecuación original X_1 por $\hat{X}_1$, regresionando $Y = \hat{X}_1\hat{\beta}_1 + X_2\hat{\beta}_2 + \hat{U}$ obteniendo el estimador β_{2SLS} .

Ojo que este estimador solo se puede obtener cuando la ecuación de interés esté **al menos** exactamente identificada (el número de instrumentos es como mínimo el número de regresores endógenos). En ese caso $\beta_{IV} = \beta_{2SLS} = ((\tilde{Z}X)'X)^{-1}((\tilde{Z}X)'Y)$, donde $\tilde{Z} = P_Z$.

Pregunta 1: Teoría de Variables Instrumentales (ejemplo académico)

Queremos estudiar el efecto de las horas de estudio semanales de un estudiante universitario s_i sobre el promedio de notas Y_i . El modelo que se podría estimar es:

$$Y_i(s) = \alpha + \rho s_i + \epsilon_i$$

Existe una variable no observada A_i , que es la motivación o disciplina que poseen los estudiantes que afecta tanto a s_i como a Y_i .

El modelo del DGP es:

$$Y_i = \alpha + \rho s_i + \gamma A_i + \eta_i, \quad \epsilon_i = \gamma A_i + \eta_i.$$

Suponga dos posibles instrumentos:

$$z_{1i} = \mathbf{1}\{\text{campus con biblioteca 24/7}\}$$

$$z_{2i} = \text{índice de ruido en el hogar (encuesta)}$$

- a) Argumente que los dos instrumentos z_i cumplen las dos condiciones necesarias ($\text{Cov}(z_i, s_i) \neq 0$ y $\text{Cov}(z_i, \epsilon_i) = 0$ y muestre teóricamente que se puede recuperar el efecto de ρ).
- b) Se sospecha que tanto el acceso a la biblioteca como el ruido en la casa podría afectar a la motivación de los estudiantes. De alguna razón de por qué se podría sospechar esto, qué supuesto no se cumple y muestre teóricamente por qué no se puede usar como instrumento.
- c) Compare los dos instrumentos propuestos: ¿Por qué z_{1i} es un instrumento fuerte y z_{2i} uno débil? Muestre teóricamente qué problema práctico genera usar un instrumento débil aunque cumpla los supuestos?
- d) (Motivación) Suponga ahora que el efecto de estudiar horas adicionales no es el mismo para todos los estudiantes (por ejemplo, algunos aprovechan más esas horas que otros). ¿Cómo cambiaría la interpretación de ρ en ese caso?

Pregunta 2: Comparación MCO y IV (R)

Un investigador de ciencia política desea estimar el efecto causal de la participación electoral (*Turnout*) sobre el porcentaje de votos obtenido por el Partido Demócrata (*VShare_Dem*) en una elección.

El modelo (MCO) que se podría plantear es:

$$VShare_Dem_i = \beta_0 + \beta_1 Turnout_i + u_i$$

Donde i representa un distrito electoral.

Sin embargo, sospechamos que $Turnout_i$ es una variable endógena. Factores omitidos (como el entusiasmo por un candidato, la competitividad de la elección o el gasto en campaña) probablemente están en el término de error u_i y, a la vez, correlacionan tanto con la participación como con el resultado electoral. Esto sesgará la estimación $\hat{\beta}_1^{MCO}$.

Para solucionar este problema, se propone utilizar la cantidad de lluvia (en mm) el día de la elección ($Lluvia_i$) como una variable instrumental para la participación ($Turnout_i$).

Se cuenta con los siguientes datos para 10 distritos electorales:

Cuadro 1: Datos Electorales y Meteorológicos para 10 Distritos

Distrito	Y_VShare_Dem (Voto % Dem.)	X_Turnout (Participación %)	Z_Lluvia (Lluvia en mm)
1	39	63	0
2	28	49	5
3	34	59	1
4	31	42	10
5	27	58	0
6	31	54	3
7	45	65	0
8	27	44	8
9	23	52	2
10	32	49	6

- a) Estime por Mínimos Cuadrados Ordinarios (MCO) el modelo de interés:

$$VShare_Dem_i = \beta_0 + \beta_1 Turnout_i + u_i$$

Reporte e interprete el coeficiente $\hat{\beta}_1^{MCO}$ y discuta conceptualmente por qué este coeficiente $\hat{\beta}_1^{MCO}$ está probablemente sesgado.

- b) Se propone usar $Lluvia_i$ como instrumento para $Turnout_i$. Enuncie las dos condiciones (supuestos) que debe cumplir un instrumento válido para este contexto y discuta la plausibilidad de estos dos supuestos.
- c) Dado que aún no hemos cubierto Mínimos Cuadrados en 2 Etapas (MC2E), calcularemos el estimador de VI manualmente usando la razón de coeficientes.

-
- **(Primera Etapa):** Estime la regresión de la variable endógena (X) sobre el instrumento (Z):

$$\text{Turnout}_i = \gamma_0 + \gamma_1 \text{Lluvia}_i + v_i$$

Reporte e interprete $\hat{\gamma}_1$.

- **(Forma Reducida):** Estime la regresión de la variable de resultado (Y) sobre el instrumento (Z):

$$\text{VShare_Dem}_i = \pi_0 + \pi_1 \text{Lluvia}_i + w_i$$

Reporte e interprete $\hat{\pi}_1$.

- **(Estimador VI):** Calcule el estimador de Variables Instrumentales ($\hat{\beta}_1^{IV}$) usando la razón de los coeficientes de la forma reducida y la primera etapa:

$$\hat{\beta}_1^{IV} = \frac{\hat{\pi}_1}{\hat{\gamma}_1}$$

- d) Compare su estimación de MCO ($\hat{\beta}_1^{MCO}$) de la parte a) con su estimación de VI ($\hat{\beta}_1^{IV}$) de la parte c). ¿Cuál de los dos coeficientes representa el efecto causal de la participación sobre el voto? Discuta por qué los valores son tan diferentes, relacionándolo con su respuesta sobre el sesgo en a).