



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE
DEPARTAMENTO DE INGENIERÍA INDUSTRIAL Y DE SISTEMAS
ICS2563 ECONOMETRÍA APLICADA - 2025'2
Profesor: PATRICIO DOMÍNGUEZ
Ayudantes: CATALINA ALEGRÍA, FERNANDO TORO Y HERNÁN PALACIOS

Ayudantía 10

Variables Instrumentales

24 de octubre de 2025

Resumen

Causales de endogeneidad

Como ya sabemos, uno de los principales problemas de validez interna que se tiene al estimar a través del método MCO, por ejemplo una regresión simple del tipo $Y_i = \alpha + \rho S_i + \epsilon_i$ (1), es el sesgo de endogeneidad, por ejemplo, producido por una variable relevante omitida. Este sesgo se puede generar ya sea por: (i) la variable independiente está correlacionada con alguna variable no observada, y (ii) porque dicha variable no incluida está correlacionada con la variable dependiente. Por lo tanto, la variable no omitida (digamos A) está relacionada con el error, y por ende el supuesto básico del MCO no se cumple ($Cov(X_i, \epsilon_i) \neq 0$).

Variables Instrumentales

El método de variables instrumentales es una alternativa para calcular la regresión $Y_i = \alpha + \delta S_i + \gamma A + \epsilon_i$, donde la variable se sospecha S_i endógena. Para ello, este método utiliza una variable o “instrumento” exógeno, digamos Z .

Para que nuestro δ sea consistente, es necesario que se cumplan los siguientes supuestos:

1. **Relevancia:** $Cov(S_i, Z_i) \neq 0$ Este supuesto implica que dado que queremos utilizar al instrumento Z_i para representar a nuestra variable de interés S_i , dichas variables deben estar fuertemente correlacionadas. Una manera de evaluar si está condiciones se satisface es llevar a cabo una regresión del tipo: $S_i = \alpha + \delta Z_i + \epsilon_i$, y llevar a cabo una prueba de hipótesis (por ejemplo, estadístico F).
2. **Exogeneidad:** $Cov(\epsilon_i, Z_i) = 0$

Implica que nuestro instrumento no está correlacionado con el error ϵ_i , el cual incluye las variables no observadas por lo que es tan bueno como aleatorio.

3. Restricción de exclusión: $Cov(\epsilon_i, Z_i) = 0$

Este supuesto también implica que el instrumento no se correlaciona con la variable dependiente Y_i , es decir, que Z_i no tiene efecto directo sobre Y_i más allá de su efecto a través de S_i

De esta manera, al considerar las condiciones, podemos notar lo siguiente:

Sea

$$y_i = \alpha + \rho S_i + \gamma A_i + \epsilon_i$$

$$\begin{aligned} Cov(y_i, z_i) &= Cov(\alpha + \rho S_i + \gamma A_i + \epsilon_i, z_i) \quad (\text{Por (1)}) \\ &= Cov(\alpha, z_i) + Cov(\rho S_i, z_i) + Cov(\gamma A_i, z_i) + Cov(\epsilon_i, z_i) \\ &= \rho Cov(S_i, z_i) \quad (\text{Por Exclusión}) \end{aligned}$$

De esta manera, podemos tener una ecuación para estimar ρ ! En efecto, utilizando la condición de Relevancia, podemos dividir por $Cov(S_i, z_i)$ en la última línea de la expresión anterior y obtener:

$$\hat{\rho}_{IV} = \frac{Cov(y_i, z_i)}{Cov(S_i, z_i)} \quad (2)$$

Note que, sin variar la identidad (2), podemos multiplicar arriba y abajo por $Var(z_i)$, y obtener:

$$\hat{\rho}_{IV} = \frac{\frac{Cov(y_i, z_i)}{Var(z_i)}}{\frac{Cov(S_i, z_i)}{Var(z_i)}} \quad (3)$$

Pero como hemos visto anteriormente en el curso, $\frac{Cov(S_i, z_i)}{Var(z_i)}$ es el coeficiente de una regresión simple entre S_i y z_i , y $\frac{Cov(y_i, z_i)}{Var(z_i)}$ es el coeficiente de una regresión entre y_i y z_i . ¡Luego $\hat{\rho}_{IV}$ es la razón entre dos coeficientes de dos regresiones! Formalizando, tenemos:

$$S_i = \alpha_1 + \pi z_i + \mu_1 \quad (4)$$

$$y_i = \alpha_2 + \delta z_i + \mu_2 \quad (5)$$

luego $\hat{\rho}_{IV} = \frac{\delta}{\pi}$. A la regresión (4) se le conoce como **primera etapa**, en tanto a la regresión (5) se le conoce como **forma reducida**.

Estimador de Wald

Es el estimador IV más simple, consistiendo de un instrumento binario (dummy) y un regresor endógeno (sin covariables). Suponiendo la regresión $Y_i = \alpha + \rho s_i + \eta_i$ el estimador de Wald es (se demostrará en la ayudantía):

$$\hat{\rho} = \frac{\mathbb{E}[Y_i | Z_i = 1] - \mathbb{E}[Y_i | Z_i = 0]}{\mathbb{E}[S_i | Z_i = 1] - \mathbb{E}[S_i | Z_i = 0]} = \frac{\delta}{\pi}$$

Mínimos cuadrados de dos etapas

Supongamos que ahora queremos calcular un modelo sobreidentificado, esto es, cuyas variables endógenas poseen más de un instrumento (Z_1, Z_2). Para ello, existe una manera de agrupar la información de manera eficiente para producir un solo estimador, el método de 2SLS. Supongamos que queremos estimar una ecuación de la forma $Y = X_1\beta_1 + X_2\beta_2 + U$, donde X_1 es uno o más regresores endógenos y Z uno o más instrumentos que cumplen con los supuestos de relevancia y exclusión.

1. La primera etapa esta relacionada con el supuesto de relevancia. Consiste en utilizar los instrumentos para predecir el valor de la variable de interés X_1 . Acá llamaremos “Matriz de instrumentos expandida” a $\hat{Z} = [X_2', Z']$. La etapa nos pide regresionar $X_1 = \hat{Z}\delta + \epsilon$, para obtener una proyección $\hat{X}_1$ ortogonal a U , que corresponde a la parte de X explicada por los instrumentos y las variables exógenas.
2. La segunda etapa se relaciona con el supuesto de exogeneidad de los instrumentos, para así derivar estimadores insesgados de los coeficientes. Reemplazamos en la ecuación original X_1 por $\hat{X}_1$, regresionando $Y = \hat{X}_1\hat{\beta}_1 + X_2\hat{\beta}_2 + \hat{U}$ obteniendo el estimador β_{2SLS} .

Ojo que este estimador solo se puede obtener cuando la ecuación de interés esté **al menos** exactamente identificada (el número de instrumentos es como mínimo el número de regresores endógenos). En ese caso $\beta_{IV} = \beta_{2SLS} = ((\tilde{Z}X)'X)^{-1}((\tilde{Z}X)'Y)$, donde $\tilde{Z} = P_Z$.

Pregunta 1: Teoría de Variables Instrumentales (ejemplo académico)

Queremos estudiar el efecto de las horas de estudio semanales de un estudiante universitario s_i sobre el promedio de notas Y_i . El modelo que se podría estimar es:

$$Y_i(s) = \alpha + \rho s_i + \epsilon_i$$

Existe una variable no observada A_i , que es la motivación o disciplina que poseen los estudiantes que afecta tanto a s_i como a Y_i .

El modelo del DGP es:

$$Y_i = \alpha + \rho s_i + \gamma A_i + \eta_i, \quad \epsilon_i = \gamma A_i + \eta_i.$$

Suponga dos posibles instrumentos:

$$z_{1i} = \mathbf{1}\{\text{campus con biblioteca 24/7}\}$$

$$z_{2i} = \text{índice de ruido en el hogar (encuesta)}$$

- a) Argumente que los dos instrumentos z_i cumplen las dos condiciones necesarias ($\text{Cov}(z_i, s_i) \neq 0$ y $\text{Cov}(z_i, \epsilon_i) = 0$) y muestre teóricamente que se puede recuperar el efecto de ρ .

Ambos instrumentos cumplen las condiciones teóricas: Biblioteca 24/7 podría aumentar las horas de estudio, por lo que $\text{Cov}(z_1, s) > 0$ (relevancia).

El ruido en la casa afecta ligeramente dónde y cuánto estudia un alumno, entonces $\text{Cov}(z_2, s) \neq 0$ (relevancia, pero débil).

Para los dos instrumentos, si asumimos que la motivación y la disciplina son características que son difíciles de cambiar para un individuo i , y que por lo tanto tener acceso a una biblioteca o el nivel de ruido del hogar no afecta su motivación, entonces $\text{Cov}(z_1, \epsilon) = 0$ y $\text{Cov}(z_2, \epsilon) = 0$ (exclusión).

Para mostrar teóricamente que se recupera el efecto causal con algún instrumento, calculamos la covarianza entre Y_i y z_i .

$$\text{Cov}(Y_i, z_i) = \text{Cov}(\alpha + \rho s_i + \epsilon_i, z_i)$$

$$\text{Cov}(Y_i, z_i) = \text{Cov}(\alpha, z_i) + \rho \text{Cov}(s_i, z_i) + \text{Cov}(\epsilon_i, z_i)$$

La covarianza entre α que es una constante y z_i es 0. Por supuesto de exogeneidad, tenemos que $\text{Cov}(\epsilon_i, z_i) = 0$.

$$\text{Cov}(Y_i, z_i) = \rho \text{Cov}(s_i, z_i)$$

Por supuesto de relevancia, tenemos que $\text{Cov}(s_i, z_i) \neq 0$, entonces podemos despejar ρ .

$$\rho = \frac{\text{Cov}(Y_i, z_i)}{\text{Cov}(s_i, z_i)}$$

- b) Se sospecha que tanto el acceso a la biblioteca como el ruido en la casa podría afectar a la motivación de los estudiantes. De alguna razón de por qué se podría sospechar esto, qué supuesto no se cumple y muestre teóricamente por qué no se puede usar como instrumento.

Para la primera pregunta no hay sólo una respuesta correcta. Podría ser que las personas que tienen campus con acceso a la biblioteca estudien en universidades más prestigiosas y tengan más motivación. Por otro lado, las personas con más ruido en sus hogares podrían tener más estrés y afectar también la motivación.

Entonces, si z_i esta relacionada con una variable no observada (en este caso la motivación A_i significa que $\text{Cov}(z_i, A_i) \neq 0$, por lo tanto

$$\text{Cov}(z_i, \epsilon_i) = \text{Cov}(z_i, \gamma A_i + \eta_i) \neq 0$$

Entonces, no se cumple el supuesto de exogeneidad o restricción de exclusión. Por lo tanto, ya no se puede ocupar de instrumento, ya que de lo contrario

$$\begin{aligned} \text{Cov}(Y_i, z_i) &= \text{Cov}(\alpha + \rho s_i + \epsilon_i, z_i) \\ \text{Cov}(Y_i, z_i) &= \rho \text{Cov}(s_i, z_i) + \text{Cov}(\epsilon_i, z_i) \\ \text{Cov}(Y_i, z_i) &= \rho \text{Cov}(s_i, z_i) + \text{Cov}(z_i, \gamma A_i + \eta_i) \\ \text{Cov}(Y_i, z_i) &= \rho \text{Cov}(s_i, z_i) + \gamma \text{Cov}(z_i, A_i) \\ \rho &= \frac{\text{Cov}(Y_i, z_i) - \gamma \text{Cov}(z_i, A_i)}{\text{Cov}(s_i, z_i)} \end{aligned}$$

Que es distinto a lo obtenido en el punto anterior y depende de una variable que no podemos observar A_i y un coeficiente que a priori no podemos estimar γ .

-
- c) Compare los dos instrumentos propuestos: ¿Por qué z_{1i} es un instrumento fuerte y z_{2i} uno débil? Muestre teóricamente qué problema práctico genera usar un instrumento débil aunque cumpla los supuestos?

El acceso a biblioteca 24/7 podría cambiar de manera importante las horas de estudio, por lo que $\text{Cov}(s, z_1)$ es grande. Esto significa que z_1 es un instrumento fuerte.

En cambio, el ruido en el hogar apenas podría modificar el total de horas de estudio, ya que los estudiantes pueden estudiar en otros lugares. Entonces $\text{Cov}(s, z_2)$ es distinto de cero pero muy pequeño, lo que hace que z_2 sea un instrumento débil.

Si el instrumento es débil, el denominador de

$$\rho^{IV} = \frac{\text{Cov}((, Y), z)}{\text{Cov}((, s), z)}$$

es muy pequeño, lo que genera un estimador muy impreciso, ya que con pequeñas desviaciones varía mucho su valor (ruidoso). Eso significa que pequeños errores de muestreo en el numerador o denominador se amplifican. Además, puede estar sesgado hacia el estimador MCO.

- d) (Motivación) Suponga ahora que el efecto de estudiar horas adicionales no es el mismo para todos los estudiantes (por ejemplo, algunos aprovechan más esas horas que otros). ¿Cómo cambiaría la interpretación de ρ en ese caso?

Si el efecto es distinto para cada estudiante, entonces el verdadero modelo sería:

$$Y_i = \alpha + \rho_i s_i + \gamma A_i + \eta_i$$

En ese escenario, ρ ya no representa un efecto único común, sino un promedio de efectos individuales. IV identificaría una medida promedio de estos efectos, poniendo más peso en los estudiantes cuyas horas de estudio están más relacionadas con el instrumento.

Pregunta 2: Comparación MCO y IV (R)

Un investigador de ciencia política desea estimar el efecto causal de la participación electoral (*Turnout*) sobre el porcentaje de votos obtenido por el Partido Demócrata (*VShare_Dem*) en una elección.

El modelo (MCO) que se podría plantear es:

$$\text{VShare_Dem}_i = \beta_0 + \beta_1 \text{Turnout}_i + u_i$$

Donde i representa un distrito electoral.

Sin embargo, sospechamos que Turnout_i es una variable endógena. Factores omitidos (como el entusiasmo por un candidato, la competitividad de la elección o el gasto en campaña) probablemente están en el término de error u_i y, a la vez, correlacionan tanto con la participación como con el resultado electoral. Esto sesgará la estimación $\hat{\beta}_1^{MCO}$.

Para solucionar este problema, se propone utilizar la cantidad de lluvia (en mm) el día de la elección (Lluvia_i) como una variable instrumental para la participación (Turnout_i).

Se cuenta con los siguientes datos para 10 distritos electorales:

Cuadro 1: Datos Electorales y Meteorológicos para 10 Distritos

Distrito	Y.VShare_Dem (Voto % Dem.)	X.Turnout (Participación %)	Z.Lluvia (Lluvia en mm)
1	39	63	0
2	28	49	5
3	34	59	1
4	31	42	10
5	27	58	0
6	31	54	3
7	45	65	0
8	27	44	8
9	23	52	2
10	32	49	6

Explicación general: El objetivo es estimar si una mayor participación electoral (Turnout) causa un mayor voto al Partido Demócrata (VShare_Dem). El problema es que la participación puede estar influida por factores no observados como entusiasmo o gasto en campaña, los cuales también afectan el voto. Esto genera endogeneidad y sesgo en el estimador de MCO. Para aislar el efecto causal, usamos una variable instrumental (IV), en este caso la lluvia: un factor externo que afecta la participación, pero no directamente las preferencias políticas. La lluvia nos entrega una variación “exógena” en participación, permitiendo estimar el efecto causal limpio de Turnout sobre VShare_Dem .

a) Estime por Mínimos Cuadrados Ordinarios (MCO) el modelo de interés:

$$\text{VShare_Dem}_i = \beta_0 + \beta_1 \text{Turnout}_i + u_i$$

Reporte e interprete el coeficiente $\hat{\beta}_1^{MCO}$ y discuta conceptualmente por qué este coeficiente $\hat{\beta}_1^{MCO}$ está probablemente sesgado.

Código en R:

Código R

```
# --- 0. Crear los datos ---

# Creamos los vectores de datos
distrito <- 1:10
Y_VShare_Dem <- c(39, 28, 34, 31, 27, 31, 45, 27, 23, 32)
X_Turnout <- c(63, 49, 59, 42, 58, 54, 65, 44, 52, 49)
Z_Lluvia <- c(0, 5, 1, 10, 0, 3, 0, 8, 2, 6)

# (Opcional) Combinarlos en un data.frame, que es más ordenado
datos <- data.frame(distrito, Y_VShare_Dem, X_Turnout, Z_Lluvia)

# --- 1. Análisis MCO (Naïve) ---
# Modelo:  $Y = \beta_0 + \beta_1 X + u$ 

# Usamos la función lm() para Linear Model
modelo_mco <- lm(Y_VShare_Dem ~ X_Turnout, data = datos)

# Ver los resultados
print("--- 1. Modelo MCO (Naïve) ---")
summary(modelo_mco)

# Extraer el coeficiente beta_1 de MCO
beta_1_mco <- coef(modelo_mco)["X_Turnout"]
print(paste("Beta 1 MCO:", beta_1_mco)) #
```

[Output del código:](#)

Código R

```
> # Ver los resultados
> print("--- 1. Modelo MCO (Naïve) ---")
[1] "--- 1. Modelo MCO (Naïve) ---"
> summary(modelo_mco)

Call:
lm(formula = Y_VShare_Dem ~ X_Turnout, data = datos)

Residuals:
    Min       1Q   Median       3Q      Max
-7.8797 -1.1726 -0.1062  2.5969  7.0108
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	2.4414	11.8954	0.205	0.843
X_Turnout	0.5469	0.2203	2.483	0.038 *

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 5.112 on 8 degrees of freedom

Multiple R-squared: 0.4352, Adjusted R-squared: 0.3646

F-statistic: 6.164 on 1 and 8 DF, p-value: 0.03795

>

> # Extraer el coeficiente beta_1 de MCO

> beta_1_mco <- coef(modelo_mco)["X_Turnout"]

> print(paste("Beta 1 MCO:", beta_1_mco)) # Debería ser aprox. +0.81

[1] "Beta 1 MCO: 0.546889507892294"

La estimación por MCO entrega un coeficiente $\hat{\beta}_1^{MCO} = 0,547$ con un error estándar de 0,220 y un valor- $p = 0,038$, lo que indica que el coeficiente es estadísticamente significativo al 5 %.

Esto significa que, manteniendo todo lo demás constante, un aumento de 1 punto porcentual en la participación electoral se asocia con un incremento promedio de aproximadamente 0,55 puntos porcentuales en el voto por el Partido Demócrata.

El error estándar refleja la variabilidad de la estimación: mientras más pequeño, mayor precisión en el estimador.

Sin embargo, este resultado no necesariamente refleja un efecto causal. La participación electoral puede estar influida por factores no observados (como entusiasmo, gasto en campaña o competitividad electoral) que también afectan el voto demócrata.

Si estos factores están correlacionados con la variable explicativa Turnout, entonces $\text{Cov}(X, u) \neq 0$, y el supuesto de exogeneidad de MCO se viola.

En ese caso, el estimador $\hat{\beta}_1^{MCO}$ estará sesgado, probablemente hacia arriba, porque los distritos con mayor entusiasmo político tienden tanto a participar más como a votar más por el mismo partido.

- b) Se propone usar $Lluvia_i$ como instrumento para $Turnout_i$. Enuncie las dos condiciones (supuestos) que debe cumplir un instrumento válido para este contexto y discuta la plausibilidad de estos dos supuestos.

(1) Relevancia: el instrumento debe estar correlacionado con la variable endógena, es decir, $\text{Cov}(Z, X) \neq 0$. La lluvia afecta la participación porque aumenta el costo de ir a votar, por lo que reduce el turnout.

(2) Exogeneidad o restricción de exclusión: el instrumento no debe afectar el resultado por otros canales distintos de la participación, es decir, $\text{Cov}(Z, u) = 0$. La lluvia del día de la elección no cambia las preferencias políticas, sólo influye en la decisión de asistir a votar.

Posibles amenazas: si las zonas más lluviosas difieren sistemáticamente en preferencias políticas o nivel socioeconómico, podría existir correlación espuria entre lluvia y voto. Esto puede mitigarse controlando por características regionales o comparando variaciones de corto plazo.

En síntesis, la lluvia es un buen candidato a instrumento porque influye en la participación y es razonablemente exógena respecto a los factores políticos.

- c) Dado que aún no hemos cubierto Mínimos Cuadrados en 2 Etapas (MC2E), calcularemos el estimador de VI manualmente usando la razón de coeficientes.

- **(Primera Etapa):** Estime la regresión de la variable endógena (X) sobre el instrumento (Z):

$$\text{Turnout}_i = \gamma_0 + \gamma_1 \text{Lluvia}_i + v_i$$

Reporte e interprete $\hat{\gamma}_1$.

La primera etapa se utiliza para comprobar que el instrumento realmente está relacionado con la variable endógena. En este caso, buscamos ver si la lluvia tiene un efecto sobre la participación electoral. Si la lluvia influye significativamente en el turnout, entonces cumple la condición de relevancia y puede servir como instrumento válido. Por eso, en esta etapa estimamos la relación entre participación y lluvia mediante una regresión simple.

Código en R:

Código R

```
# a) Primera Etapa
# Modelo: X = gamma_0 + gamma_1*Z + v
primera_etapa <- lm(X_Turnout ~ Z_Lluvia, data = datos)

print("--- 3a. Primera Etapa (X ~ Z) ---")
summary(primera_etapa)

# Extraer el coeficiente gamma_1
gamma_1 <- coef(primera_etapa)["Z_Lluvia"]
print(paste("Gamma 1 (Efecto de Z en X):", gamma_1))
```

Output del código:

Código R

```
> # a) Primera Etapa
> # Modelo: X = gamma_0 + gamma_1*Z + v
> primera_etapa <- lm(X_Turnout ~ Z_Lluvia, data = datos)
>
> print("--- 3a. Primera Etapa (X ~ Z) ---")
[1] "--- 3a. Primera Etapa (X ~ Z) ---"
> summary(primer_etapa)

Call:
lm(formula = X_Turnout ~ Z_Lluvia, data = datos)

Residuals:
    Min       1Q   Median       3Q      Max
-4.545 -1.220  0.030  1.415  4.395

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  60.6052     1.2237   49.53 3.06e-11 ***
Z_Lluvia     -2.0300     0.2503   -8.11 3.96e-05 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.702 on 8 degrees of freedom
Multiple R-squared:  0.8916, Adjusted R-squared:  0.878
F-statistic: 65.77 on 1 and 8 DF,  p-value: 3.957e-05

>
> # Extraer el coeficiente gamma_1
> gamma_1 <- coef(primer_etapa)["Z_Lluvia"]
> print(paste("Gamma 1 (Efecto de Z en X):", gamma_1))
[1] "Gamma 1 (Efecto de Z en X): -2.03004291845494"
```

Primera etapa: El coeficiente estimado es $\hat{\gamma}_1 = -2,03$, con un error estándar de 0.25, un valor- $p < 0,001$ y un estadístico $F = 65,77$.

Esto indica que por cada milímetro adicional de lluvia, la participación electoral disminuye en cerca de 2 puntos porcentuales. El error estándar pequeño muestra que la estimación es precisa, el valor- p muy bajo indica que el efecto es estadísticamente significativo, y el estadístico F alto confirma que la lluvia está fuertemente relacionada con la participación.

En conjunto, esto demuestra que la lluvia es un buen instrumento, ya que tiene

un efecto claro y significativo sobre la variable endógena.

- **(Forma Reducida):** Estime la regresión de la variable de resultado (Y) sobre el instrumento (Z):

$$VShare_Dem_i = \pi_0 + \pi_1 Lluvia_i + w_i$$

Reporte e interprete $\hat{\pi}_1$.

La forma reducida se usa para medir el efecto total del instrumento sobre la variable de resultado. En este caso, muestra cómo la lluvia afecta directamente el porcentaje de voto demócrata, sin pasar explícitamente por la participación. Esta relación combina todos los posibles efectos de la lluvia sobre el resultado y nos sirve como paso previo para calcular el estimador instrumental mediante la razón de coeficientes.

Código en R:

Código R

```
# b) Forma Reducida
# Modelo: Y = pi_0 + pi_1*Z + w
forma_reducida <- lm(Y_VShare_Dem ~ Z_Lluvia, data = datos)

print("--- 3b. Forma Reducida (Y ~ Z) ---")
summary(forma_reducida)

# Extraer el coeficiente pi_1
pi_1 <- coef(forma_reducida)["Z_Lluvia"]
print(paste("Pi 1 (Efecto de Z en Y):", pi_1))
```

Output del código:

Código R

```
> print("--- 3b. Forma Reducida (Y ~ Z) ---")
[1] "--- 3b. Forma Reducida (Y ~ Z) ---"
> summary(forma_reducida)

Call:
lm(formula = Y_VShare_Dem ~ Z_Lluvia, data = datos)

Residuals:
    Min       1Q   Median       3Q      Max
-9.7107 -2.4339 -0.2107  3.2560 10.9416

Coefficients:
```

```

              Estimate Std. Error t value Pr(>|t|)
(Intercept)  34.0584      2.8521  11.942 2.23e-06 ***
Z_Lluvia     -0.6738      0.5834  -1.155  0.281
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 6.297 on 8 degrees of freedom
Multiple R-squared:  0.1429, Adjusted R-squared:  0.03579
F-statistic: 1.334 on 1 and 8 DF,  p-value: 0.2814

>
> # Extraer el coeficiente pi_1
> pi_1 <- coef(forma_reducida)["Z_Lluvia"]
> print(paste("Pi 1 (Efecto de Z en Y):", pi_1))
[1] "Pi 1 (Efecto de Z en Y): -0.673819742489271"

```

Forma reducida: El coeficiente estimado es $\hat{\pi}_1 = -0,67$, con un error estándar de 0.58 y un valor- $p = 0,28$.

Esto indica que, en promedio, un milímetro adicional de lluvia se asocia con una disminución de cerca de 0.7 puntos porcentuales en el voto demócrata. El error estándar relativamente grande muestra que la estimación es poco precisa, y el valor- p alto indica que el efecto no es estadísticamente significativo, probablemente por el tamaño pequeño de la muestra.

En conjunto, la dirección del efecto es coherente con la idea de que la lluvia reduce la participación y, a través de eso, también el voto demócrata, aunque la evidencia estadística no es concluyente.

- **(Estimador VI):** Calcule el estimador de Variables Instrumentales ($\hat{\beta}_1^{IV}$) usando la razón de los coeficientes de la forma reducida y la primera etapa:

$$\hat{\beta}_1^{IV} = \frac{\hat{\pi}_1}{\hat{\gamma}_1}$$

El estimador IV o de Wald se calcula como la razón entre el efecto de la lluvia sobre el resultado (forma reducida) y el efecto de la lluvia sobre la participación (primera etapa). Esta razón muestra cuánto cambia el voto demócrata por cada cambio en la participación que es causado solo por la lluvia. De esta forma, obtenemos una medida del efecto causal “limpio” de la participación, aislado de otros factores no observados.

Código en R:

Código R

```
# c) Estimador VI (Cálculo manual)
# beta_1_IV = pi_1 / gamma_1
beta_1_iv <- pi_1 / gamma_1

print("--- 3c. Estimador VI (Manual) ---")
print(paste("Beta 1 IV (pi_1 / gamma_1):", beta_1_iv))
```

Output del código:

Código R

```
> # c) Estimador VI (Cálculo manual)
> # beta_1_IV = pi_1 / gamma_1
> beta_1_iv <- pi_1 / gamma_1
>
> print("--- 3c. Estimador VI (Manual) ---")
[1] "--- 3c. Estimador VI (Manual) ---"
> print(paste("Beta 1 IV (pi_1 / gamma_1):", beta_1_iv))
[1] "Beta 1 IV (pi_1 / gamma_1): 0.331923890063425"
```

Estimador de Variables Instrumentales (VI):

A partir de la forma reducida y la primera etapa:

$$\hat{\beta}_1^{IV} = \frac{\hat{\pi}_1}{\hat{\gamma}_1} = \frac{-0,674}{-2,03} = 0,332$$

Esto indica que un aumento de 1 punto porcentual en la participación electoral, causado por una variación exógena en la lluvia, produce en promedio un aumento de 0.33 puntos porcentuales en el voto al Partido Demócrata.

Este estimador captura el efecto causal de la participación sobre el voto, ya que usa solo la parte de la variación en turnout explicada por la lluvia, es decir, aquella que no está contaminada por factores como entusiasmo o gasto en campaña.

- Compare su estimación de MCO ($\hat{\beta}_1^{MCO}$) de la parte a) con su estimación de VI ($\hat{\beta}_1^{IV}$) de la parte c). ¿Cuál de los dos coeficientes representa el efecto causal de la participación sobre el voto? Discuta por qué los valores son tan diferentes, relacionándolo con su respuesta sobre el sesgo en a).

Código en R:

Código R

```
# --- 4. Conclusión ---  
print("--- 4. Comparación Final ---")  
print(paste("Beta 1 MCO (Sesgado):", beta_1_mco))  
print(paste("Beta 1 IV (Causal):  ", beta_1_iv))
```

Output del código:

Código R

```
> # --- 4. Conclusión ---  
> print("--- 4. Comparación Final ---")  
[1] "--- 4. Comparación Final ---"  
> print(paste("Beta 1 MCO (Sesgado):", beta_1_mco))  
[1] "Beta 1 MCO (Sesgado): 0.546889507892294"  
> print(paste("Beta 1 IV (Causal):  ", beta_1_iv))  
[1] "Beta 1 IV (Causal):   0.331923890063425"  
>
```

Comparación entre MCO e IV:

El modelo MCO entrega un coeficiente de $\hat{\beta}_1^{MCO} = 0,547$, mientras que el estimador de Variables Instrumentales (IV) da $\hat{\beta}_1^{IV} = 0,332$.

El estimador MCO muestra una asociación entre participación y voto, pero no necesariamente un efecto causal, porque la participación puede estar influida por factores no observados, como entusiasmo o gasto en campaña, que también afectan el voto. Esto genera endogeneidad y hace que el coeficiente de MCO esté sesgado al alza, exagerando el efecto real.

En cambio, el estimador IV utiliza solo la parte de la participación explicada por la variación exógena en la lluvia, que no está relacionada con esos factores omitidos. Por eso, $\hat{\beta}_1^{IV}$ refleja el efecto causal de la participación sobre el voto demócrata.

En resumen, el efecto IV es menor que el de MCO, lo que coincide con la idea de que el modelo MCO sobreestima el impacto por la presencia de variables omitidas. El estimador IV es el que mejor representa el efecto causal verdadero bajo los supuestos del instrumento.