



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE
DEPARTAMENTO DE INGENIERÍA INDUSTRIAL Y DE SISTEMAS
ICS2563 ECONOMETRÍA APLICADA - 2025'2

Profesor: PATRICIO DOMÍNGUEZ

Ayudantes: ANTONIO LÓPEZ, GONZALO AGUILAR, CATALINA ALEGRÍA

Ayudantía 11

Variables Instrumentales

7 de noviembre de 2025

Resumen

Causales de endogeneidad

Como ya sabemos, uno de los principales problemas de validez interna que se tiene al estimar a través del método MCO, por ejemplo una regresión simple del tipo $Y_i = \alpha + \rho S_i + \epsilon_i$ (1), es el sesgo de endogeneidad, por ejemplo, producido por una variable relevante omitida. Este sesgo se puede generar ya sea por: (i) la variable independiente está correlacionada con alguna variable no observada, y (ii) porque dicha variable no incluida está correlacionada con la variable dependiente. Por lo tanto, la variable no omitida (digamos A) está relacionada con el error, y por ende el supuesto básico del MCO no se cumple ($Cov(X_i, \epsilon_i) \neq 0$).

Variables Instrumentales

El método de variables instrumentales es una alternativa para calcular la regresión $Y_i = \alpha + \delta S_i + \gamma A + \epsilon_i$, donde la variable se sospecha S_i endógena. Para ello, este método utiliza una variable o “instrumento” exógeno, digamos Z .

Para que nuestro δ sea consistente, es necesario que se cumplan los siguientes supuestos:

1. **Relevancia:** $Cov(S_i, Z_i) \neq 0$ Este supuesto implica que dado que queremos utilizar al instrumento Z_i para representar a nuestra variable de interés S_i , dichas variables deben estar fuertemente correlacionadas. Una manera de evaluar si estas condiciones se satisfacen es llevar a cabo una regresión del tipo: $S_i = \alpha + \delta Z_i + \epsilon_i$, y llevar a cabo una prueba de hipótesis (por ejemplo, estadístico F).
2. **Exogeneidad:** $Cov(\epsilon_i, Z_i) = 0$

Implica que nuestro instrumento no está correlacionado con el error ϵ_i , el cual incluye las variables no observadas por lo que es tan bueno como aleatorio.

3. Restricción de exclusión: $Cov(\epsilon_i, Z_i) = 0$

Este supuesto también implica que el instrumento no se correlaciona con la variable dependiente Y_i , es decir, que Z_i no tiene efecto directo sobre Y_i más allá de su efecto a través de S_i

De esta manera, al considerar las condiciones, podemos notar lo siguiente:

Sea

$$y_i = \alpha + \rho S_i + \gamma A_i + \epsilon_i$$

$$\begin{aligned} Cov(y_i, z_i) &= Cov(\alpha + \rho S_i + \gamma A_i + \epsilon_i, z_i) \quad (\text{Por (1)}) \\ &= Cov(\alpha, z_i) + Cov(\rho S_i, z_i) + Cov(\gamma A_i, z_i) + Cov(\epsilon_i, z_i) \\ &= \rho Cov(S_i, z_i) \quad (\text{Por Exclusión}) \end{aligned}$$

De esta manera, podemos tener una ecuación para estimar ρ ! En efecto, utilizando la condición de Relevancia, podemos dividir por $Cov(S_i, z_i)$ en la última línea de la expresión anterior y obtener:

$$\hat{\rho}_{IV} = \frac{Cov(y_i, z_i)}{Cov(S_i, z_i)} \quad (2)$$

Note que, sin variar la identidad (2), podemos multiplicar arriba y abajo por $Var(z_i)$, y obtener:

$$\hat{\rho}_{IV} = \frac{\frac{Cov(y_i, z_i)}{Var(z_i)}}{\frac{Cov(S_i, z_i)}{Var(z_i)}} \quad (3)$$

Pero como hemos visto anteriormente en el curso, $\frac{Cov(S_i, z_i)}{Var(z_i)}$ es el coeficiente de una regresión simple entre S_i y z_i , y $\frac{Cov(y_i, z_i)}{Var(z_i)}$ es el coeficiente de una regresión entre y_i y z_i . ¡Luego $\hat{\rho}_{IV}$ es la razón entre dos coeficientes de dos regresiones! Formalizando, tenemos:

$$S_i = \alpha_1 + \pi z_i + \mu_1 \quad (4)$$

$$y_i = \alpha_2 + \delta z_i + \mu_2 \quad (5)$$

luego $\hat{\rho}_{IV} = \frac{\delta}{\pi}$. A la regresión (4) se le conoce como **primera etapa**, en tanto a la regresión (5) se le conoce como **forma reducida**.

Estimador de Wald

Es el estimador IV más simple, consistiendo de un instrumento binario (dummy) y un regresor endógeno (sin covariables). Suponiendo la regresión $Y_i = \alpha + \rho s_i + \eta_i$ el estimador de Wald es:

$$\hat{\rho} = \frac{\mathbb{E}[Y_i | Z_i = 1] - \mathbb{E}[Y_i | Z_i = 0]}{\mathbb{E}[S_i | Z_i = 1] - \mathbb{E}[S_i | Z_i = 0]} = \frac{\delta}{\pi}$$

Mínimos cuadrados de dos etapas

Supongamos que ahora queremos calcular un modelo sobreidentificado, esto es, cuyas variables endógenas poseen más de un instrumento (Z_1, Z_2). Para ello, existe una manera de agrupar la información de manera eficiente para producir un solo estimador, el método de 2SLS. Supongamos que queremos estimar una ecuación de la forma $Y = X_1\beta_1 + X_2\beta_2 + U$, donde X_1 es uno o más regresores endógenos y Z uno o más instrumentos que cumplen con los supuestos de relevancia y exclusión.

1. La primera etapa esta relacionada con el supuesto de relevancia. Consiste en utilizar los instrumentos para predecir el valor de la variable de interés X_1 . Acá llamaremos “Matriz de instrumentos expandida” a $\hat{Z} = [X_2', Z']$. La etapa nos pide regresionar $X_1 = \hat{Z}\delta + \epsilon$, para obtener una proyección $\hat{X}_1$ ortogonal a U , que corresponde a la parte de X explicada por los instrumentos y las variables exógenas.
2. La segunda etapa se relaciona con el supuesto de exogeneidad de los instrumentos, para así derivar estimadores insesgados de los coeficientes. Reemplazamos en la ecuación original X_1 por $\hat{X}_1$, regresionando $Y = \hat{X}_1\hat{\beta}_1 + X_2\hat{\beta}_2 + \hat{U}$ obteniendo el estimador β_{2SLS} .

Ojo que este estimador solo se puede obtener cuando la ecuación de interés esté **al menos** exactamente identificada (el número de instrumentos es como mínimo el número de regresores endógenos). En ese caso $\beta_{IV} = \beta_{2SLS} = ((\tilde{Z}X)'X)^{-1}((\tilde{Z}X)'Y)$, donde $\tilde{Z} = P_Z$.

Pregunta 1

El economista Joshua Angrist (1990) propuso utilizar el *Draft #* como un instrumento para el servicio militar, con el fin de estimar el retorno causal de realizar el servicio militar en los salarios.

El *Draft #* fue un número entregado de forma aleatoria a todos los hombres mayores de edad en EEUU durante la guerra de Vietnam. El propósito de este número era utilizarlo para definir quienes son llamados primero a servir por la patria en la guerra. Este número era asignado según la fecha de nacimiento, por lo que se puede considerar tan bueno como si fuera aleatorio.

A continuación se muestran dos gráficos ¹




Figura 1: Servicio militar vs Draft #

¹Estos gráficos fueron fabricados con datos inventados para fines pedagógicos, pero si quieren saber más sobre los resultados del experimento les recomiendo leer "Lifetime Earnings and the Vietnam Era Draft Lottery: Evidence from Social Security Administrative Records"




Figura 2: Sueldos vs Draft #

- a) Explique por qué el *Draft #* puede ser un instrumento válido para el servicio militar en este contexto. Discuta brevemente los dos requisitos fundamentales de validez de un instrumento, aplicándolos en este caso.

Recordemos que los requisitos para la validez de una variable instrumental son:

- Relevancia: El instrumento debe afectar la probabilidad de tratamiento. En este caso *Draft #* afecta la probabilidad de ser llamado. Si el sorteo cambia la probabilidad de servicio entonces hay correlación estadística entre instrumento Z y tratamiento D ($\text{Cov}(Z,D) \neq 0$). Aquí esa correlación surge por el mecanismo del sorteo.
- Exclusión: El instrumento solo debe afectar al outcome a través del tratamiento. En este caso *Draft #* solo afecta el salario Y a través de su efecto sobre D (servir). Esto tiene sentido, ya que es un número aleatorio entregado según la fecha de nacimiento, por lo que no debería afectar a los individuos de ninguna forma, a excepción de aumentar su probabilidad de servir.

- b) En base al gráfico 1, describa qué patrón se observa en la probabilidad de servir en el ejército según el *Draft #* obtenido. ¿Qué nos indica este gráfico sobre la relevancia del instrumento? ¿En qué sentido este gráfico representa la primera etapa de la estimación IV?

En el gráfico se puede ver como a medida que aumenta el *Draft #*, la probabilidad de servir aumenta. Esto sirve para confirmar el primer supuesto mencionado anteriormente, ya que como se puede ver en la línea de tendencia la probabilidad de servir está

fuertemente influenciada por el *Draft #* obtenido.

Este gráfico representa la primera etapa, ya que estima la relación $serve = \pi_0 + Draft\# \cdot \pi_1 + u$. En este caso, la pendiente de la recta azul del gráfico corresponde a π_1 .

- c) Observe el gráfico 2. Qué relación se observa entre el *Draft #* obtenido y los salarios promedio? ¿Cómo se interpreta este gráfico como una forma reducida dentro del modelo IV?

El gráfico muestra cómo cambian los salarios promedio según aumenta el *Draft #*. Si bien por la escala del gráfico es leve, se puede ver como a medida que aumenta el *Draft #*, disminuye el salario promedio.

Esta relación gráfica es la forma reducida (estimación de Y con Z sin usar D). En términos de regresión es $wage = \gamma_0 + \gamma_1 Z + v$ y mide el efecto total del instrumento sobre el outcome. Si γ_1 es distinto de 0, aporta evidencia de que Z transmite efectos a Y .

- d) Explique cómo, combinando los resultados de ambos gráficos, se puede construir el estimador de variable instrumental que mide el impacto de servir en el ejército en los sueldos. Escriba la fórmula general y explique en palabras qué mide el cociente entre el efecto del instrumento sobre el salario y su efecto sobre el servicio militar.

La fórmula del estimador IV es:

$$\beta_{IV} = \frac{Cov(Draft\#_i, Wage_i)}{Cov(Draft\#_i, Served_i)}$$

En este contexto, el numerador mide cómo cambian los salarios en promedio cuando el número de lotería aumenta (la forma reducida), y el denominador mide cómo cambia la educación promedio con el número de lotería (la primera etapa).

El cociente entre ambas pendientes estima el efecto causal de la educación sobre el salario para los individuos cuya decisión educativa se ve afectada por la probabilidad de ser reclutados (los compliers). En otras palabras, se interpreta como el retorno a la educación inducido por variaciones en la probabilidad de servicio militar generadas por la lotería.

Pregunta 2

A continuación se derivará algebraicamente el estimador de Mínimos Cuadrados en Dos Etapas (2SLS) a partir del estimador de proyección lineal sobre los instrumentos. Se asume el modelo estructural:

$$y = \alpha + \rho s + X\gamma + u,$$

donde s es una variable endógena, X corresponde a controles exógenos y Z a un conjunto de instrumentos válidos.

a) Considere la primera etapa del modelo:

$$s = Z\pi_1 + X\pi_2 + v,$$

donde Z y X representan los instrumentos y controles, respectivamente, y v el término de error. Demuestre que los valores ajustados de s , equivalentemente, la proyección de s sobre el espacio generado por Z y X , se pueden escribir como:

$$\hat{s} = P_{[Z,X]}s = P_X s + M_X Z(Z' M_X Z)^{-1} Z' M_X s,$$

donde

$$P_X = X(X'X)^{-1}X', \quad M_X = I - P_X.$$

Solución: Partimos de la primera etapa:

$$s = Z\pi_1 + X\pi_2 + v,$$

donde Z son los instrumentos y X los controles exógenos. Queremos obtener los valores ajustados de s , es decir, $\hat{s}$. Por definición de mínimos cuadrados, los coeficientes estimados π_1 y π_2 satisfacen las ecuaciones normales:

$$\begin{pmatrix} Z'Z & Z'X \\ X'Z & X'X \end{pmatrix} \begin{pmatrix} \pi_1 \\ \pi_2 \end{pmatrix} = \begin{pmatrix} Z's \\ X's \end{pmatrix}.$$

Nuestro objetivo es resolver este sistema para π_1 y π_2 y luego expresar $\hat{s} = Z\pi_1 + X\pi_2$. De la segunda ecuación se obtiene:

$$X'Z\pi_1 + X'X\pi_2 = X's \quad \Rightarrow \quad \pi_2 = (X'X)^{-1}(X's - X'Z\pi_1).$$

Sustituyendo en la primera ecuación:

$$Z'Z\pi_1 + Z'X(X'X)^{-1}(X's - X'Z\pi_1) = Z's.$$

Reordenando términos en π_1 :

$$[Z'Z - Z'X(X'X)^{-1}X'Z]\pi_1 = Z's - Z'X(X'X)^{-1}X's.$$

Definimos las matrices de proyección y de residuales:

$$P_X = X(X'X)^{-1}X', \quad M_X = I - P_X.$$

Entonces se cumple:

$$Z'M_XZ = Z'Z - Z'X(X'X)^{-1}X'Z, \quad Z'M_Xs = Z's - Z'X(X'X)^{-1}X's.$$

Por tanto:

$$(Z'M_XZ)\pi_1 = Z'M_Xs \Rightarrow \pi_1 = (Z'M_XZ)^{-1}Z'M_Xs.$$

A partir de la expresión anterior para π_2 :

$$\pi_2 = (X'X)^{-1}(X's - X'Z\pi_1) = (X'X)^{-1}(X's - X'Z(Z'M_XZ)^{-1}Z'M_Xs).$$

Finalmente, los valores ajustados de s se obtienen reemplazando ambos resultados:

$$\hat{s} = Z\pi_1 + X\pi_2.$$

Sustituyendo:

$$\begin{aligned} \hat{s} &= X(X'X)^{-1}X's + [Z - X(X'X)^{-1}X'Z]\pi_1 \\ &= X(X'X)^{-1}X's + M_XZ\pi_1. \end{aligned}$$

Y reemplazando $\pi_1 = (Z'M_XZ)^{-1}Z'M_Xs$, se obtiene:

$$\hat{s} = X(X'X)^{-1}X's + M_XZ(Z'M_XZ)^{-1}Z'M_Xs.$$

b) Considere ahora la segunda etapa del modelo:

$$y = \alpha + \rho\hat{s} + X\gamma + \varepsilon.$$

Usando el teorema de Frisch–Waugh–Lovell (FWL), pruebe que el estimador 2SLS de ρ puede escribirse como:

$$\hat{\rho}_{2SLS} = \frac{\tilde{s}'P_{\tilde{Z}}\tilde{y}}{\tilde{s}'P_{\tilde{Z}}\tilde{s}},$$

donde

$$\tilde{y} = M_X y, \quad \tilde{s} = M_X s, \quad \tilde{Z} = M_X Z, \quad P_{\tilde{Z}} = \tilde{Z}(\tilde{Z}'\tilde{Z})^{-1}\tilde{Z}'.$$

Solución: Segunda etapa:

$$y = \alpha + \rho \hat{s} + X\gamma + \varepsilon.$$

Por el teorema de Frisch–Waugh–Lovell (FWL), el coeficiente de $\hat{s}$ en la regresión de y sobre $(\hat{s}, X)$ se obtiene regresando los residuales de y y de $\hat{s}$ tras proyectar en X . Entonces, por FWL,

$$\hat{\rho}_{2SLS} = \frac{\tilde{s}'\tilde{y}}{\tilde{s}'\tilde{s}}.$$

Para identificar $\tilde{s}$, usamos el resultado del inciso (a):

$$\hat{s} = P_X s + M_X Z (Z' M_X Z)^{-1} Z' M_X s.$$

Al multiplicar por M_X (recordando que $M_X P_X = 0$ y $M_X^2 = M_X$):

$$\tilde{s} = M_X \hat{s} = M_X Z (Z' M_X Z)^{-1} Z' M_X s = \tilde{Z} (\tilde{Z}'\tilde{Z})^{-1} \tilde{Z}' \tilde{s} = P_{\tilde{Z}} \tilde{s}.$$

Sustituyendo en la fórmula de FWL:

$$\hat{\rho}_{2SLS} = \frac{(P_{\tilde{Z}}\tilde{s})'\tilde{y}}{(P_{\tilde{Z}}\tilde{s})'(P_{\tilde{Z}}\tilde{s})}.$$

Como $P_{\tilde{Z}}$ es un proyector ortogonal (simétrico e idempotente), $(P_{\tilde{Z}}\tilde{s})' = \tilde{s}'P_{\tilde{Z}}$ y $(P_{\tilde{Z}}\tilde{s})'(P_{\tilde{Z}}\tilde{s}) = \tilde{s}'P_{\tilde{Z}}\tilde{s}$. Por tanto,

$$\hat{\rho}_{2SLS} = \frac{\tilde{s}'P_{\tilde{Z}}\tilde{y}}{\tilde{s}'P_{\tilde{Z}}\tilde{s}}.$$

- c) A partir del resultado obtenido en el inciso anterior, derive el caso particular en que existe un solo instrumento z (de dimensión $n \times 1$). Muestre que, al reemplazar Z por z , se obtiene el estimador:

$$\hat{\rho}_{IV} = \frac{\tilde{z}'\tilde{y}}{\tilde{z}'\tilde{s}} = \frac{\text{Cov}(\tilde{y}, \tilde{z})}{\text{Cov}(\tilde{s}, \tilde{z})}.$$

Solución: Sea $z \in \mathbb{R}^{n \times 1}$ el único instrumento. Usando el resultado del inciso (b),

$$\hat{\rho}_{2SLS} = \frac{\tilde{s}'P_{\tilde{z}}\tilde{y}}{\tilde{s}'P_{\tilde{z}}\tilde{s}} = \frac{\tilde{s}'\tilde{z}(\tilde{z}'\tilde{z})^{-1}\tilde{z}'\tilde{y}}{\tilde{s}'\tilde{z}(\tilde{z}'\tilde{z})^{-1}\tilde{z}'\tilde{s}} = \frac{\tilde{z}'\tilde{y}}{\tilde{z}'\tilde{s}}.$$

esto ocurre dado que $\tilde{s}'\tilde{z}(\tilde{z}'\tilde{z})^{-1}$ es un escalar. Si, como es usual, X incluye el vector de unos (intercepto), entonces los residuales $\tilde{y}, \tilde{s}, \tilde{z}$ tienen promedio cero. Esto se debe a que las ecuaciones normales de MCO imponen que los residuos sean ortogonales a

los regresores, y en particular a la constante, por lo que su suma (y su media) debe ser igual a cero.

Dado que las variables $\tilde{y}$, $\tilde{s}$, $\tilde{z}$ están centradas, la covarianza muestral entre dos de ellas se puede escribir como:

$$\text{Cov}(\tilde{a}, \tilde{b}) = \frac{1}{n} \sum_{i=1}^n \tilde{a}_i \tilde{b}_i,$$

de modo que

$$\tilde{a}'\tilde{b} = n \text{ Cov}(\tilde{a}, \tilde{b}) \quad \text{para cualesquiera vectores centrados } \tilde{a}, \tilde{b}.$$

Por lo tanto, la expresión anterior del estimador IV puede escribirse en términos de covarianzas:

$$\hat{\rho}_{IV} = \frac{\tilde{z}'\tilde{y}}{\tilde{z}'\tilde{s}} = \frac{\text{Cov}(\tilde{y}, \tilde{z})}{\text{Cov}(\tilde{s}, \tilde{z})}.$$

Pregunta 3

Se desea estimar el retorno causal de la educación sobre los salarios siguiendo la metodología de Angrist & Krueger (1991). Considere el modelo:

$$y_i = \log(\text{wage}_i), \quad s_i = \text{años de educación}_i,$$

y como instrumento un indicador binario de trimestre de nacimiento:

$$z_i = \mathbf{1}\{\text{nacido en el cuarto trimestre}\},$$

de modo que $z_i = 1$ si el individuo nació en el cuarto trimestre. Como controles utilice dummies de cohorte (año de nacimiento), C_i . Donde s_i es *endógena* (potencialmente correlacionada con u_i). A modo de ilustración, se presenta el siguiente gráfico que muestra la primera etapa y la forma reducida del modelo.




Figure 4.1.1: Graphical depiction of first stage and reduced form for IV estimates of the economic return to schooling using quarter of birth (from Angrist and Krueger 1991).

Figura 3: Representación gráfica de la primera etapa y de la forma reducida para las estimaciones IV del retorno económico de la educación utilizando el trimestre de nacimiento (basado en Angrist y Krueger, 1991).

- Estime el efecto de la educación sobre los salarios mediante el estimador de Wald, controlando por cohorte.
- Estime el mismo efecto utilizando el método de Mínimos Cuadrados en Dos Etapas (2SLS), incluyendo los mismos controles por cohorte. Compare numéricamente los

resultados con el estimador de Wald y comente su equivalencia teórica en el caso de un solo instrumento.

- c) Interprete los resultados anteriores en términos económicos y causales. Discuta brevemente la validez del instrumento utilizado (relevancia y exclusión) y qué representa el efecto estimado.

[Solución en el Script de R.](#)