

Econometría Aplicada

ICS 2563

Patricio Domínguez

Departamento de Ingeniería Industrial y de Sistemas
Universidad Católica de Chile

August 5, 2025



Figure: Fuente: LINK

El Modelo de Regresión Lineal

- **Introducción**
- El modelo de regresión simple (bivariado)
 - Tres maneras simples de estimar coeficientes MCO de una regresión bivariada.
 - Esperanza de una función condicional (CEF)
 - Predicción insesgada
 - Mínimos cuadrados ordinarios (MCO)
- Del modelo simple (bivariado) al modelo múltiple (multivariado)
 - Métodos de momentos (MoM)
 - Máxima verosimilitud (MVE)
 - Mínimos cuadrados ordinarios (MCO)
 - Supuestos MCO
 - Álgebra de MCO
 - Propiedades MCO
- Problemas con los datos

El Modelo de Regresión Lineal

- RL: Herramienta más importante para el econometrista
- *Qué es la econometría?*
- Al imponer una serie de supuestos, una RL nos entrega información muy útil sobre un proceso generador de datos (*Data Generator Process, DGP*)

El Modelo de Regresión Lineal

- Algunas definiciones básicas:
- Variable dependiente (izq): variable **Y** (singular) que depende de otros factores (a especificar)
- Variables independientes (der): variables **X** (plural) también llamadas regresores, covariables o variables explicativas
- Todo esto, para qué? Analizar cómo un cambio en X afecta una variable Y .
Ceteris paribus

El Modelo de Regresión Lineal

- Para qué sirve? (Freedman, D., 2009)
 - Resumir información compleja (multivariable)
 - Predecir el futuro (de una variable)
 - Analizar el resultado de una intervención (inferencia causal)
- Pondremos especial atención en el tercer obj: más interesante y resbaladizo.
- Veamos la notación que usaremos.

El Modelo de Regresión Lineal

Vamos a escribir una regresión de varias maneras posibles. Algunos detalles de la notación.

- Observaciones: $y_i = x_{i1}\beta_1 + x_{i2}\beta_2 + \dots x_{ik}\beta_k + \epsilon_i$
- Vectores columna ($n \times 1$): $y = x_1\beta_1 + x_2\beta_2 + \dots x_k\beta_k + \epsilon$
Alternativamente: $y = \sum_{j=1}^k x_j\beta_j + \epsilon$

• Matrices:
$$\underset{(n \times 1)}{y} = \underset{(n \times k)}{X} \underset{(k \times 1)}{\beta} + \underset{(n \times 1)}{\epsilon}$$

El Modelo de Regresión Lineal

- Introducción
- **El modelo de regresión simple (bivariado)**
 - Tres maneras simples de estimar coeficientes MCO de una regresión bivariada.
 - Esperanza de una función condicional (CEF)
 - Predicción insesgada
 - Mínimos cuadrados ordinarios (MCO)
- Del modelo simple (bivariado) al modelo múltiple (multivariado)
 - Métodos de momentos (MoM)
 - Máxima verosimilitud (MVE)
 - Mínimos cuadrados ordinarios (MCO)
 - Supuestos MCO
 - Álgebra de MCO
 - Propiedades MCO
- Problemas con los datos

El Modelo de Regresión Lineal Simple

Tres maneras simples de estimar coeficientes MCO de una regresión bivariada:

- **Estimar la esperanza de una función condicional lineal:** $\mathbb{E}[Y|X]$
 - Supón que $\mathbb{E}[Y|X] = \alpha + X\beta$.
Luego, sabemos que $\mathbb{E}[Y] = \mathbb{E}[\mathbb{E}[Y|X]] = \mathbb{E}[\alpha + X\beta] = \alpha + \mathbb{E}[X]\beta$. Así,
 - $\text{cov}(Y, X) = \mathbb{E}[YX] - \mathbb{E}[Y]\mathbb{E}[X]$
 $= \mathbb{E}[\mathbb{E}[YX|X]] - (\alpha + \mathbb{E}[X]\beta)\mathbb{E}[X]$
...
 - Y, finalmente, tenemos:
 $\text{cov}(Y, X) = \beta(\mathbb{E}[X^2] - (\mathbb{E}[X])^2) = \beta \text{Var}[X]$
 - Así: $\beta = \frac{\text{cov}(Y, X)}{\text{Var}[X]}$

El Modelo de Regresión Lineal Simple

- **Predicción insesgada.**

- Olvídense por un momento de $\mathbb{E}[Y|X]$. Supón en vez que queremos predecir Y , $\hat{Y}$, con tres propiedades

Definiendo a, b , podemos fácilmente lograr estas propiedades:

- Es lineal en $X \rightarrow \hat{Y} = a + Xb$ para algún a, b .
- El error de predicción, $Y - \hat{Y}$, es cero (promedio): $\mathbb{E}[Y - \hat{Y}] = 0$
- El error de predicción no está correlacionado con X : $\mathbb{E}[(Y - \hat{Y})X] = 0$

Prueba:

El Modelo de Regresión Lineal Simple

- **Mínimos cuadrados.**
- Ahora supón que queremos una predicción lineal $\hat{Y}$ que minimice el cuadrado del error predicho, $\mathbb{E}[(Y - \hat{Y})^2] = \mathbb{E}[(Y - a - Xb)^2]$.
- Condiciones de primer orden:
 - $\frac{\partial}{\partial a} : \mathbb{E}[-2(Y - a - Xb)] = 0$
 - $\frac{\partial}{\partial b} : \mathbb{E}[-2X(Y - a - Xb)] = 0$

El Modelo de Regresión Lineal Simple

- **Mínimos cuadrados.**
- Las dos condiciones previas, se pueden escribir también como:

- $\frac{1}{n} \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0$

- $\frac{1}{n} \sum_{i=1}^n (x_i [y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i]) = 0$

- Qué representa el subíndice i ?
- Por qué $\hat{\beta}$ y no β ?
- Con algo de álgebra, obtenemos:

El Modelo de Regresión Lineal Simple

- **Mínimos cuadrados.**

- $$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\text{Covarianza muestral}(x_i, y_i)}{\text{Varianza muestral}(x_i)}$$

Una vez determinado β_1 (pendiente) es más fácil calcular β_0 (intercepto):

- $$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

El Modelo de Regresión Lineal Simple Múltiple

Figure: Código en de STATA

```
71 **** OUTPUT Regresión
72 // Imaginemos que tenemos info de los salarios de 1000 individuos
73 set seed 1
74 clear
75     set obs 1000
76     // Definiendo variables dependientes
77     g edad = 18+ abs(10* rnormal(,1))
78     g esc = rnormal(12,3)
79     g esfuerzo = rnormal()
80     g u = rnormal(,10)
81
82     g exp = edad-esc-1 //experiencia laboral
83     g MW = 500
84     //definiendo variables independientes
85     g ingresos = MW + 1500*exp + 7000*(esc-12)+15*esfuerzo +u
86
87     g log_ingresos= ln(ingresos)
88     reg log_ingresos exp esc esfuerzo
89
```

por qué logs?

El Modelo de Regresión Lineal Simple Múltiple

Figure: Salida de STATA

. reg log_ingresos exp esc esfuerzo						
Source	SS	df	MS	Number of obs = 891		
Model	545.295791	3	181.765264	F(3, 887)	=	777.70
Residual	207.311965	887	.233722621	Prob > F	=	0.0000
				R-squared	=	0.7245
				Adj R-squared	=	0.7236
Total	752.607756	890	.845626692	Root MSE	=	.48345
log_ingresos	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
exp	.0638733	.0021202	30.13	0.000	.059712	.0680346
esc	.3118498	.00666	46.82	0.000	.2987786	.324921
esfuerzo	.0161511	.0158707	1.02	0.309	-.0149974	.0472996
_cons	5.029305	.104976	47.91	0.000	4.823275	5.235335

El Modelo de Regresión Lineal Simple

Caso: variable independiente binaria, $T \in \{0, 1\}$.

Fíjense que $\mathbb{P}(T = 1) = \mathbb{E}[T]$

- $\mathbb{E}[Y] = \mathbb{E}(\mathbb{E}[Y|T]) = \mathbb{E}[Y|T=0]\mathbb{P}(T=0) + \mathbb{E}[Y|T=1]\mathbb{P}(T=1)$
 $\rightarrow \mathbb{E}[Y] = \mathbb{E}[Y|T=0](1 - \mathbb{E}(T)) + \mathbb{E}[Y|T=1]\mathbb{E}(T)$
- $\mathbb{E}[TY] = \mathbb{E}(\mathbb{E}[TY|T]) =$
 $\mathbb{E}[TY|T=0]\mathbb{P}(T=0) + \mathbb{E}[TY|T=1]\mathbb{P}(T=1) =$
 $= 0 \times (1 - \mathbb{E}(T)) + \mathbb{E}[Y|T=1]\mathbb{E}(T) =$
 $\rightarrow \mathbb{E}[TY] = \mathbb{E}[Y|T=1]\mathbb{E}[T]$
- $\mathbb{V}(T) = \mathbb{E}(T^2) - \mathbb{E}^2(T) = \mathbb{E}(T) - \mathbb{E}^2(T) = \mathbb{E}(T)(1 - \mathbb{E}(T))$

El Modelo de Regresión Lineal Simple

Veamos el caso de una variable independiente binaria, $T \in \{0, 1\}$.

Resumiendo:

- $\mathbb{E}[Y] = \mathbb{E}[Y|T=0](1 - \mathbb{E}[T]) + \mathbb{E}[Y|T=1]\mathbb{E}[T]$
- $\mathbb{E}[TY] = \mathbb{E}[Y|T=1]\mathbb{E}[T]$
- $\mathbb{V}(T) = \mathbb{E}[T](1 - \mathbb{E}[T])$
- $\sigma(T, Y) = \mathbb{E}(TY) - \mathbb{E}[T]\mathbb{E}[Y]$
 $= \mathbb{E}[Y|T=1]\mathbb{E}[T] - \mathbb{E}[T] \times [\mathbb{E}[Y|T=0](1 - \mathbb{E}[T]) + \mathbb{E}[Y|T=1]\mathbb{E}[T]]$
 $= \mathbb{E}[Y|T=1]\mathbb{E}[T](1 - \mathbb{E}[T]) - \mathbb{E}(T)\{\mathbb{E}[Y|T=0](1 - \mathbb{E}[T])\}$
 $= \mathbb{E}[T](1 - \mathbb{E}[T]) \times \{\mathbb{E}[Y|T=1] - \mathbb{E}[Y|T=0]\}$

$$\beta_1 = \frac{\sigma(T, Y)}{\mathbb{V}(T)} = \mathbb{E}[Y|T=1] - \mathbb{E}[Y|T=0] \quad (1)$$

$$\beta_0 = \mathbb{E}(Y) - \beta_1 \times \mathbb{E}(T) = \mathbb{E}(Y|T=0) \quad (2)$$

Otros criterios de ajuste

- La elección de estimadores MCO es arbitraria, pero qué tanto?
- Qué otros criterios podríamos usar?

- Regresiones paramétricas y no-paramétricas (Kernel)

- Minimizar

- Suma de residuos: $\sum_{i=1}^N e_i^2$

- Suma residuos en valor absoluto: $\sum_{i=1}^N |e_i|$

- Valor absoluto de la suma de residuos: $|\sum_{i=1}^N e_i|$

Regresión Lineal

- Introducción
- El modelo de regresión simple (bivariado)
 - Tres maneras simples de estimar coeficientes MCO de una regresión bivariada.
 - Esperanza de una función condicional (CEF)
 - Predicción insesgada
 - Mínimos cuadrados ordinarios (MCO)
- **Del modelo simple (bivariado) al modelo múltiple (multivariado)**
 - Métodos de momentos (MoM)
 - Máxima verosimilitud (MV)
 - Mínimos cuadrados ordinarios (MCO)
 - Supuestos MCO
 - Álgebra de MCO
 - Propiedades MCO
- Problemas con los datos

Hacia el Modelo de Regresión Lineal Múltiple

- Usos/finalidades posibles de una RL: predicción, relación causal, etc
- $y = f(x_1, x_2, \dots, x_k, \epsilon) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots \beta_n x_n + \epsilon$
- $Y = XB + e$
- Nos interesa saber cómo se distribuyen los y_i en relación al vector de variables explicativas X
- Aparte de la estimación MCO, uno puede estimar los parámetros de una RL usando otros métodos.

Métodos de Estimación

Los modelos econométricos tienen parámetros desconocidos. La idea, entonces, es estimar estos parámetros. Necesitamos:

- Modelo que contenga parámetros (Ej: β)
- Datos (Ej: y , X)

Decimos que *si el modelo está bien especificado* describirá el mecanismo del *mundo-real* que generó los datos observados. Veremos, brevemente, dos métodos:

- Método de Momentos
- Método de Máxima Verosimilitud

Estimación vía Método de Momentos

Una forma común de estimar parámetros (desconocidos de un modelo definido) es reemplazar promedios poblacionales por muestrales. (poblacional en sentido metafórico, mejor concepto es proceso generador de datos, DGP)

El supuesto implícito es que la muestra representa la población que se busca describir. En su forma más común, se asume que la media muestral es un estimador de la media *poblacional*.

Pero este método incorpora *otros momentos*, además del promedio. Veamos:

Estimación vía Método de Momentos

Por ejemplo, veamos el caso de una regresión lineal simple:

- $u_i = y_i - \beta_1 - \beta_2 x_i$. Y sabemos que $\mathbb{E}[u_i] = 0$. Como tenemos n observaciones, podemos escribir: $\frac{1}{n} \sum_{i=1}^n u_i = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{\beta}_1 - \hat{\beta}_2 x_i) = 0$
- Qué pasa si imponemos la condición $\beta_2 = 0$?
 - Es fácil ver que obtendrías: $\hat{\beta}_1 = \frac{1}{n} \sum_{i=1}^n y_i$
- Necesitamos, entonces, una segunda condición (dos parámetros):
 $\mathbb{E}[u_i x_i] = \mathbb{E}[\mathbb{E}[u_i x_i | x_i]] = \mathbb{E}[x_i \mathbb{E}[u_i | x_i]] = 0$
Lo que queda como: $\frac{1}{n} \sum_{i=1}^n x_i (y_i - \hat{\beta}_1 - \hat{\beta}_2 x_i) = 0$
- Ambas restricciones se pueden escribir como:
 - $\hat{\beta}_1 + (\frac{1}{n} \sum_{i=1}^n x_i) \hat{\beta}_2 = \frac{1}{n} \sum_{i=1}^n y_i$
 - $(\frac{1}{n} \sum_{i=1}^n x_i) \hat{\beta}_1 + (\frac{1}{n} \sum_{i=1}^n x_i^2) \hat{\beta}_2 = \frac{1}{n} \sum_{i=1}^n x_i y_i$

Estimación vía Método de Momentos

Ambas restricciones se pueden escribir como:

- $n\hat{\beta}_1 + (\sum_{i=1}^n x_i)\hat{\beta}_2 = \sum_{i=1}^n y_i$
- $(\sum_{i=1}^n x_i)\hat{\beta}_1 + (\sum_{i=1}^n x_i^2)\hat{\beta}_2 = \sum_{i=1}^n x_i y_i$

Es fácil ver que ambas ecuaciones son un caso especial del modelo de regresión lineal múltiple, donde X incluye la constante (vector de unos):

- $y = X\beta + u$, donde
- $X'X\beta = X'y$
- $\hat{\beta} = (X'X)^{-1}X'y$

Estimación vía Máxima Verosimilitud


- Procedimiento para derivar estimadores de parámetros de un modelo
- Depende críticamente de especificar la forma funcional de DGP correctamente (modelo paramétrico completamente especificado)
- Pero con especificación correcta, es un método flexible y produce estimadores con propiedades asintóticas muy deseables (MLE).
- Muchos métodos: Logit, probit, poisson, exponencial, etc.
- En simple, estimador MV de un parámetro es aquel valor más probable de observar, dado el set de datos disponibles (observados). La idea es buscar, entre todos los parámetros posibles que satisfacen un determinado modelo (DGP), aquel que hace a los datos los más probable de ser observados. Así, la idea es *maximizar la verosimilitud* de la función generada por una distribución de probabilidad.

Estimación vía Máxima Verosimilitud

Tenemos una variable dependiente y (vector $n \times 1$). Luego, para un vector de parámetros a estimar, θ ($k \times 1$), podemos escribir la función de densidad de probabilidad conjunta (o PDF) como $f(y, \theta)$.

- $f(y, \theta)$ representa la especificación del modelo.
- Idea: Estimar θ para lograr una caracterización completa del DGP.
- Si θ es fijo, $f(y, \theta)$ se puede interpretar como la PDF de y . **Pero**, si $f(y, \theta)$ es evaluada en un vector y encontrado en una base de datos dada, la denominaremos *función de verosimilitud*.
- MV busca la función de verosimilitud que hace más posible ese vector y ($n \times 1$) *hallado*.

Estimación vía Máxima Verosimilitud



Estimación vía Máxima Verosimilitud

Define una función de verosimilitud $f(y|\theta)$ para una base de datos dada. Esta función identifica el proceso generador de datos (DGP) que subyace a los datos observados.

Si asumimos que sucesivas observaciones son independientes $\Rightarrow$ densidad conjunta de toda la muestra es, simplemente, la multiplicación de las densidades de las observaciones individuales.

Digamos, entonces, que $f(y, \theta)$ denota la PDF (*probability density function* o función de densidad de probabilidad) de una observación dada, y_i .

Estimación vía Máxima Verosimilitud

Veamos:

- Función de V: La densidad conjunta de n observaciones *iid* obtenidas de este DGP, es el producto de las densidades individuales:

$$f(y|\theta) = \prod_{i=1}^n f(y_i|\theta) = L(\theta|y) = L(\theta|data)$$

- Log Función de V: $l(\theta|y) = \log f(\theta|y) = \sum_{i=1}^n \log f(\theta|y_i)$

La meta es elegir estimadores de los parámetros que maximicen la probabilidad de obtener los datos observados.

- Primero debemos determinar la función que identifica el proceso generador de datos sobre el cual fue obtenida la muestra observada.
- Una vez identificada la función de verosimilitud, el procedimiento consiste en identificar el set de estimadores de los parámetros que maximizan la *verosimilitud* de los datos observados (y).

Estimación vía Máxima Verosimilitud

- Aplicación: dist.normal con media μ y varianza σ^2 .
- $MV(\theta) = \operatorname{argmax} \log L(\tilde{\theta})$
- En una muestra de una dist.normal con media μ y varianza σ^2 :
 - PDF de y_i es $f(y_i, \theta) = f(y_i, \mu, \sigma) = \frac{1}{\sigma\sqrt{2\pi}} \exp(-\frac{(y_i-\mu)^2}{2\sigma^2})$
 - Bajo muestreo *i.i.d.*, la distribución conjunta de la muestra completa:
$$f(y_1, \dots, y_n, \mu, \sigma) = \prod_{i=1}^n \frac{1}{\sigma\sqrt{2\pi}} \exp(-\frac{(y_i-\mu)^2}{2\sigma^2})$$
 - $\log L(\theta|y) = \sum_{i=1}^n \log f(y_i|\theta) = -\frac{1}{2} \sum_{i=1}^n [\log \sigma^2 + \log(2\pi) + \frac{(y_i-\mu)^2}{\sigma^2}]$
 - $\frac{\partial \log L}{\partial \mu} = \frac{1}{\sigma^2} \sum_{i=1}^n (y_i - \mu) = 0 \rightarrow \hat{\mu}_{MV} = \frac{1}{n} \sum_{i=1}^n (y_i) = \bar{y}$
 - $\frac{\partial \log L}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (y_i - \mu)^2 = 0 \rightarrow \hat{\sigma}_{MV}^2 = \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y}_n)^2$

Estimación vía Máxima Verosimilitud

- En una muestra de una dist.normal donde queremos determinar $\mu(x) = \alpha + \beta X$ y varianza σ^2 tenemos:
 - $\log L(\theta|y, x) = l(\alpha, \beta, \sigma^2|y) = \log K - \frac{N}{2} \log \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \alpha - \beta X_i)^2$
 - Fíjense que implica optimizar el mismo problema de antes (minimizar errores cuadrados).
 - $\beta_{MV} = \beta_{MCO}$

Estimación vía Máxima Verosimilitud

Veamos en detalle la similitud entre $\beta_{MLE} = \beta_{MCO}$. Tenemos: $Y_i = X_i\beta + \epsilon_i$, con $\epsilon_i|X_i \sim N(0, \sigma^2)$. Usando que $\epsilon_i = Y_i - X_i\beta$, podemos escribir la función de verosimilitud como:

- $f(\epsilon_1, \epsilon_2, \dots, \epsilon_N, \beta, \sigma) = \prod_{i=1}^N \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(\epsilon_i)^2}{2\sigma^2}\right) = \prod_{i=1}^N \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(y_i - x_i\beta)^2}{2\sigma^2}\right)$
- $l(y_1, \dots, y_n, x_1, \dots, x_N, \beta, \sigma) = -\frac{N}{2} \ln(2\pi) - \frac{N}{2} \log \sigma^2 - \frac{1}{2\sigma^2} (y - x\beta)'(y - x\beta)$
- Luego, $\max_{\beta, \sigma} l(y_1, \dots, y_n, x_1, \dots, x_N, \beta, \sigma)$
- $\frac{\partial l}{\partial \sigma} = -\frac{N}{\sigma} + \frac{(y_i - x_i\beta)'(y_i - x_i\beta)}{\sigma^3} = 0 \rightarrow \sigma^2 = \frac{1}{N} (y_i - x_i\beta)'(y_i - x_i\beta)$
- Define $l_c = -\frac{N}{2} \log(2\pi) - \frac{N}{2} \left(\frac{1}{N} (y_i - x_i\beta)'(y_i - x_i\beta) \right) - \frac{n}{2}$
- $\frac{\partial l}{\partial \beta} = -N \frac{(y_i - x_i\beta)'(y_i - x_i\beta)}{\sigma^2} = 0 \rightarrow \beta = (X'X)^{-1}(X'Y)$

Estimación vía Máxima Verosimilitud

Propiedades estimadores MV (muestras grandes o propiedades asintóticas)

- Consistente
- Asintóticamente eficiente
- Asintóticamente distribuye normal
- **Ejemplo:** EMV de σ^2 es sesgado. Cómo?
- Sesgo vs varianza
- Pero, por supuesto, todas estas propiedades requieren que la forma funcional esté bien especificada.

Regresión Lineal

- Introducción
- El modelo de regresión simple (bivariado)
 - Tres maneras simples de estimar coeficientes MCO de una regresión bivariada.
 - Esperanza de una función condicional (CEF)
 - Predicción insesgada
 - Mínimos cuadrados ordinarios (MCO)
- Del modelo simple (bivariado) al modelo múltiple (multivariado)
 - Métodos de momentos (MoM)
 - Máxima verosimilitud (MV)
 - **Mínimos cuadrados ordinarios (MCO)**
 - Supuestos MCO
 - Álgebra de MCO
 - Propiedades MCO
- Problemas con los datos

Algunos supuestos

- S1: Linealidad
- S2: Rango completo (identificación)
- S3: Exogeneidad de variables independientes (explicativas) exógenas
- S4: Varianza de errores esférica (homocedasticidad + no autocorrelación)

Por conveniencia, podemos agregar S4 y S5:

- S4: Regresores fijos
- S5: Distribución normal

Algunos supuestos

- S1: Linealidad
 - Supuesto: $y = X\beta + \epsilon$
 - x_k set de variables explicativas para observaciones $i \in (1, \dots, N)$
 - $\mathbb{E}[y|x] = x'\beta = \sum_{j=1}^k x_{ij}\beta_k$
- S2: Rango completo (identificación)
 - Supuesto: X es una matriz $n \times K$ con rango $k < n$
 - Las columnas de X son vectores lineales independientes
 - ... y hay al lo menos k observaciones
- S3: Exogeneidad de variables independientes (explicativas)
 - Supuesto: $\mathbb{E}[\epsilon_i|X] = 0$
 - Importante: Esto es respecto de cualquier observación i ; en otras palabras, condicional en el set de covariables, la información de X no aporta sobre $\mathbb{E}[\epsilon|x_j = x_{j0}]$
 - Los errores son aleatorios en la población $\mathbb{E}[\epsilon_i|\epsilon_1, \epsilon_2, \dots, \epsilon_n] = 0$
 - Otro detalle, también implica que la media incondicional $\mathbb{E}[\epsilon_i]$ también es cero.
Prueba: $\mathbb{E}[\epsilon_i] = \mathbb{E}_X[\mathbb{E}[\epsilon_i|X]] = \mathbb{E}_X[0] = 0$

Algunos supuestos

- S4: Varianza de errores esférica (homocedasticidad + no autocorrelación)
 - Supuesto: $\mathbb{V}[\epsilon_i|X] = \sigma^2, \forall i = 1, \dots, n$ y
 - $\text{Cov}(\epsilon_i, \epsilon_j|X) = 0, \forall i \neq j$ que se pueden resumir en:
 - $\mathbb{E}[\epsilon\epsilon'] = \sigma^2 I$
- S5: Regresores fijos
- S6: Distribución Normal
 - $\epsilon|X \sim N[0, \sigma^2 I]$

S1. Linealidad

Vamos a asumir que la forma funcional que relaciona X 's e y es lineal:

$$y_i = x_1\beta_1 + x_2\beta_2 + \dots + x_k\beta_k + \epsilon$$

Qué tan restrictivo es este supuesto?

Pensemos que tenemos una función de producción Cobb-Douglas: $Q = AK^\alpha L^\beta e^\epsilon$

Podemos tomar *logaritmo* en ambos lados y obtenemos:

$$\ln(Q) = \ln(A) + \alpha \ln(L) + \beta \ln(K) + \epsilon$$

S1. Linealidad

Este supuesto nos permite interpretar los coeficientes de maneras muy convenientes.

Ej: lineal-lineal; log-lineal; log-log.

Cómo se interpretan los coeficientes en cada caso?

S2. Rango Completo

No existe relación lineal perfecta entre las variables independientes (X 's) y disponemos de más observaciones que variables del lado derecho (o coeficientes por determinar β s).

Formalmente, X es una matriz de rango $k < n$

K representa el número de parámetros a estimar (variables independientes más la constante)

n es el total de observaciones.

S3. Exogeneidad estricta

La media condicional de los errores es cero: $\mathbb{E}[\epsilon_i|X] = 0$

O dicho de otro modo, $\mathbb{E}[\epsilon_i|x_1, \dots, x_n] = 0$


Una implicancia es que la media incondicional es también cero.

$$\mathbb{E}[\epsilon_i] = \mathbb{E}[\mathbb{E}[\epsilon_i|X]] = \mathbb{E}[0] = 0$$

Es restrictivo que la media incondicional sea cero?


S3. Exogeneidad estricta

La media condicional de los errores es cero: $\mathbb{E}[\epsilon_i|X] = 0$. Veamos un ejemplo:



S3. Exogeneidad estricta

La media condicional de los errores es cero: $\mathbb{E}[\epsilon_i|X] = 0$. Veamos un ejemplo:



S4. Varianza de errores esféricas

Sobre la varianza y covarianza de los errores ϵ_i :

- Homocedasticidad: $\mathbb{V}[\epsilon_i|X] = \sigma^2, \forall i = 1, \dots, n$ y
- No hay correlación entre obs: $\sigma(\epsilon_i, \epsilon_j|X) = 0, \forall i \neq j$
- Condiciones que se pueden resumir en:
 - $\mathbb{E}[\epsilon\epsilon'] = \sigma^2 I$

S6. Normalidad

Una forma de fortalecer S4 es requerir que:

$$\epsilon|X \sim \mathcal{N}(0, \sigma^2 I_n)$$

Álgebra de Mínimos Cuadrados (MCO)

- La idea es estimar los parámetros desconocidos del modelo poblacional:
- MCO es un ajuste particular, con una valoración puntual (podría haber otras, no?) respecto de cómo definir esos parámetros desconocidos
- Optimicemos...

Álgebra de Mínimos Cuadrados (MCO)

- Queremos estimar (**población**): $y_i = x_i' \beta - \epsilon_i$
y podemos asumir que lo siguiente existe: $\mathbb{E}[y_i|x_i] = x_i' \beta$
- Tenemos (**estimadores muestrales**): $y_i = x_i' b - e_i$
re-escribiendo: $e_i = y_i - x_i' b$
- El problema:
$$\text{Min}_{b_0} S(b_0) = e_0' e_0 = (y - Xb_0)'(y - Xb_0) \text{ donde}$$
$$S(b_0) = y'y - 2y'Xb_0 + b_0'X'Xb_0$$

y b_0 representa una elección puntual de parámetros escogidos.
- FOC: $\frac{\partial S(b_0)}{\partial b_0} = -2X'y + 2X'Xb_0 = 0$

Solución:

$$b_0 = \underset{(k \times 1)}{(X'X)^{-1}} \underset{[(k \times n)(n \times k)][(k \times n)(n \times 1)]}{X'y}$$

Álgebra de Mínimos Cuadrados (MCO)

La condición de primer orden, también sugiere lo siguiente:

$$\begin{aligned}\text{FOC: } \frac{\partial S(b_0)}{\partial b_0} &= -2X'y + 2X'Xb_0 \\ &= X'Xb - X'y \\ &= X'e \\ &= 0\end{aligned}$$

Tres implicancias –siempre y cuando incluyamos la constante en X – **Por qué?:**

- La suma de los residuos es cero ($\sum e_i = 0$).
- El hiperplano de la regresión cruza los puntos medios de los datos.
- La media de los valores predichos ($\bar{\hat{y}}$) es igual a la media de ($\bar{y}$).

Solución:

$$b_0 = \frac{(X'X)^{-1} X'y}{[(k \times 1) \quad [(k \times n)(n \times k)][(k \times n)(n \times 1)]}$$

Álgebra de Mínimos Cuadrados (MCO)

Ej: Si X incluye una constante:

- $X = [1, x_2, \dots, x_k]$, donde 1 representa una columna de *unos*.
- Como $X'e = 0$, $x_1'e = 0$ (residuos suman cero), entonces:
- Columna de unos: $i = [1, \dots, 1]$
- $i'y = \sum_{i=1}^n y_i = n\bar{y}$
- $i'y = i'Xb + i'e = i'Xb$
- con lo que al dividir por n , tenemos: $\bar{y} = \bar{x}'b$

Pregunta: Qué pasa si X no incluye una constante?

Álgebra de Mínimos Cuadrados (MCO)

- Veamos qué condición impone la restricción de segundo orden para que la solución represente un valor mínimo:
- SOC: $\frac{\partial^2 S(b_0)}{\partial b_0 \partial b_0'} = \frac{\partial \left(\frac{\partial (y - Xb_0)'(y - Xb_0)}{\partial b_0} \right)}{\partial b_0'} = 2X'X$
- Si hubiera un vector b_0 único, necesitamos que $X'X$ sea una matriz positiva definida.
- Una matriz C es definida positiva si $a'Ca > 0 \forall a$
- $a'X'Xa = (a'X')(Xa) = (Xa)'(Xa) = v'v = \sum_{n=1}^N v_k^2 > 0$
- Ergo, $b = (X'X)^{-1}X'y$ efectivamente minimiza $e'e$

Published: 11 February 2009

The ostrich effect: Selective attention to information

Niklas Karlsson, [George Loewenstein](#) ✉ & [Duane Seppi](#)

[Journal of Risk and Uncertainty](#) **38**, 95–115 (2009) | [Cite this article](#)

5594 Accesses | **246** Citations | **76** Altmetric | [Metrics](#)

Abstract

We develop and test a model which links information acquisition decisions to the hedonic utility of information. Acquiring and attending to information increases the psychological impact of information (an *impact effect*), increases the speed of adjustment for a utility reference-point (a *reference-point updating effect*), and affects the degree of risk aversion towards randomness in news (a *risk aversion effect*). Given plausible parameter values, the model predicts asymmetric preferences for the timing of resolution of uncertainty: Individuals should monitor and attend to information more actively given preliminary good news but “put their heads in the sand” by avoiding additional information given adverse prior news. We test for such an “ostrich effect” in a finance context, examining the account monitoring behavior of Scandinavian and American investors in two datasets. In both datasets, investors monitor their portfolios more frequently in rising markets than when markets are flat or falling.

El efecto avestruz




Figure: Investors log in to their Vanguard accounts much more frequently in rising rather than in falling markets.

Álgebra de Mínimos Cuadrados (MCO)

De esta manera escribiremos el modelo de regresión lineal como:

$$y = \underset{\text{Proyección}}{Xb} + \underset{\text{Residuo}}{e} = \hat{y} + e \quad (3)$$

Ahora, intentaremos escribirla de la siguiente forma:

$$y = \underset{\text{Proyección}}{Py} + \underset{\text{Residuo}}{My} \quad (4)$$

Hablemos, entonces, de P y M.

Álgebra de Mínimos Cuadrados (MCO)

- Tenemos que proyección: $Xb = X(X'X)^{-1}X'y = Py$
- **Def:** Matriz de proyección: $P_{n \times n} = X(X'X)^{-1}X'$

Por otro lado,

- $e = y - Xb = y - X(X'X)^{-1}X'y = (I - X(X'X)^{-1}X')y = I - P = My$
- **Def:** Matriz de residuos (aniquiladora): $M_{n \times n} = I - X(X'X)^{-1}X'$

Álgebra de Mínimos Cuadrados (MCO)

- Matriz de proyección: $P_{n \times n} = X(X'X)^{-1}X'$
- Matriz de residuos: $M_{n \times n} = I - X(X'X)^{-1}X'$

Algunas propiedades:

- P y M son idempotentes ($M^2 = M$) y simétricas ($M' = M$)
- Es fácil ver que $MX = 0$, $PX = X$ y $My = y - \hat{y} = e$
- Si X es un vector constante, desviaciones c/r promedio: $My = y - \bar{y}$
- **Desafío:** Mostrar que M is idempotente y simétrica.
- Así, podemos descomponer y en dos partes: $y = \hat{y} + e = Py + My$
- $y'y = y'P'Py + y'M'My = \hat{y}'\hat{y} + e'e$

Regresiones particionadas

- $y = X\beta + \epsilon = \underset{(n \times 1)}{X_1} \underset{(n \times s)(s \times 1)}{\beta_1} + \underset{(n \times (k-s))((k-s) \times 1)}{X_2} \underset{((k-s) \times 1)}{\beta_2} + \underset{(n \times 1)}{\epsilon}$
- Por conveniencia: $(X'X)\beta = X'y$
- Dos ecuaciones:
 - $X_1'X_1b_1 + X_1'X_2b_2 = X_1'y$
 - $X_2'X_1b_1 + X_2'X_2b_2 = X_2'y$
- $b_1 = (X_1'X_1)^{-1}X_1'y - (X_1'X_1)^{-1}X_1'X_2b_2 = (X_1'X_1)^{-1}X_1'(y - X_2b_2)$
- Sustituyendo b_1 en la ecuación (2), podemos ver que:
- $b_2 = (X_2^{*'}X_2^*)^{-1}X_2^{*'}y^*$ donde $X_2^* = M_1X_2$

Regresiones particionadas

Teorema de Frisch-Waugh (1933) and Lovell (1963)

- Sustituyendo b_1 es fácil obtener lo siguiente: $b_2 = (X_2' M_1 X_2)^{-1} (X_2' M_1 y)$
- Como sabemos que M_1 es simétrica e idempotente, podemos describir:
 $b_2 = (X_2^{*'} X_2^*)^{-1} (X_2^{*'} y^*)$, donde $X_2^* = M_1 X_2$ y $y^* = M_1 y$
- En palabras: podemos obtener b_2 al correr una regresión de los residuos de y sobre x_1 sobre el set de residuos obtenidos de cada columna de X_2 sobre X_1 .
- Se ve, entonces, por qué tiene sentido hablar de coeficientes de regresión *parciales*.
- **Ejemplo:** Mostrar un ejemplo con binscatter en *R* o STATA.
- Volveremos sobre esto cuando veamos datos de panel y diferencias en diferencias.

Álgebra de Mínimos Cuadrados (MCO)

- Matriz de proyección: $P_{n \times n} = X(X'X)^{-1}X'$
- Matriz de residuos: $M_{n \times n} = I - X(X'X)^{-1}X'$

Algunas propiedades:

- Suma Residuos Cuadrados (SSR): $SSR = e'e = \epsilon'M\epsilon$
- **Def:** R^2 (*uncentered*): $R_{uc}^2 = \frac{\hat{y}'\hat{y}}{y'y} = 1 - \frac{e'e}{y'y}$

Medidas de Ajuste

Cómo podemos juzgar la calidad de ajuste que logramos al intentar resumir una nube de puntos en una recta?

$$R_{UC}^2 = \frac{\hat{y}'\hat{y}}{y'y} = 1 - \frac{e'e}{y'y}$$

Pero, en realidad, nos interesa saber la calidad de ajuste relativo a usar una sola constante:

- **Def:** $A = I_n - (\frac{1}{n})ii'$ donde i es un vector $(n \times 1)$ de unos.
- A transforma un vector en desviaciones respecto a la media: $Ae = e$ y $Ai = 0$
- Usando regresiones particionadas: $y = [i \ X_2][b_1 \ b_2]' + e$ y además: $\times A$:
- $y^* = X_2^*b_2 + e$, o también: $X_2^{*'}y^* = X_2^{*'}X_2^*b_2$

$$\underset{[SST]}{y^{*'}y^*} = \underset{[SSM]}{b_2'X_2^{*'}X_2^*b_2} + \underset{[SSR]}{e'e}$$

Medidas de Ajuste

Cómo podemos juzgar la calidad de ajuste que logramos al intentar resumir una nube de puntos en una recta?

$$R_C^2 = \frac{SSM}{SST} = 1 - \frac{SSR}{SST} = \frac{b_2' X^{*'} X^* b_2}{y^{*'} y^*} = 1 - \frac{\sum_i e_i^2}{\sum_i^n (y_i - \bar{y})^2} = \frac{\sum_i^n (\hat{y}_i - \bar{y})^2}{\sum_i^n (y_i - \bar{y})^2}$$

Algunos ejemplos con los cuales practicar:

- Qué pasa si omites la constante? Qué valores posibles tiene R_C^2 ?
- Qué pasa al agregar variables? Interesante mostrar qué pasa usando simulaciones de MonteCarlo.

Álgebra de Mínimos Cuadrados (MCO)

Coeficiente de determinación (R_c^2)

- **Desafío:** Si el único regresor es una constante ($K = 1$), $b = \bar{y}$, la media muestral.
- Si hay regresores variables, $\sum_i (y_i - \bar{y})^2$ se puede descomponer:

$$\sum_i (y_i - \bar{y})^2 = \sum_i (\hat{y}_i - \bar{y})^2 + \sum_i e_i^2$$

- donde $\bar{y} \equiv \frac{1}{n} \sum_{i=1}^n y_i$
- **Def:**

$$R_c^2 \equiv 1 - \frac{\sum_i e_i^2}{\sum_i (y_i - \bar{y})^2} = \frac{\sum_i (\hat{y}_i - \bar{y})^2}{\sum_i (y_i - \bar{y})^2}$$

Propiedades (de muestra finita) de los MCO

Luego de analizar las propiedades algebraicas de los MCO, queremos ya saber por qué son tan famosos. Veamos entonces algunas proposiciones:

- P1. β es insesgado:
- P2. Varianza de estimadores MCO
- P3. Teorema de Gauss-Markov
- P4. Insesgamiento de s^2
- P5. $Cov(b, e|X) = 0$

Propiedades (de muestra finita) de los MCO

Luego de analizar las propiedades algebraicas de los MCO, queremos ya saber por qué son tan famosos. Veamos entonces algunas proposiciones:

- P1. β es insesgado: Si asumimos linealidad, rango completo y exogeneidad estricta $\rightarrow$ estimador insesgado

- **Pregunta:** Por qué no requiere errores esféricos?

- P2. Varianza de estimadores MCO

$$\begin{aligned} \text{Si asumimos P1 + errores esféricos} &\rightarrow V[b|X] = \sigma^2(X'X)^{-1} \\ &= \underset{k \times n}{B} \underset{n \times n}{\mathbb{E}[\epsilon\epsilon'|X]} \underset{n \times k}{B'} = B\sigma^2 I_n B' = \sigma^2 BB' = \sigma^2(X'X)^{-1} \end{aligned}$$

- P3. Teorema de Gauss-Markov
- P4. Insesgamiento de s^2
- P5. $\text{Cov}(b, e|X) = 0$

Teorema de Gauss (1821) - Markov (1900)

Teorema: Si se cumple: linealidad, rango completo, exogeniedad estricta y errores esfericos, estimador MCO es eficiente respecto de la clase de estimadores lineales insesgados. Esto es, que cualquier estimador insesgado β que es lineal en y , $Var[\hat{\beta}|X] - Var[b|X]$ es una matriz semi positiva definida. Entonces, estimador MCO b_0 es el *mejor* estimador lineal insesgado de β .

En otras palabras, es **B.L.U.E.** (Best Linear Unbiased Estimator).

- Ello implica que $Var[\hat{\beta}] \geq Var[\beta]$
- **Prueba:**

Propiedades (de muestra finita) de los MCO

- **P4. Insesgamiento de s^2 :**
- **Prueba:** Asumir S1- S4 (Greene, 4.6)
- **P5. $Cov(b, e|X) = 0$**
- **Prueba:**

$$\begin{aligned}Cov(b, e|X) &= \mathbb{E}[(b - \mathbb{E}(b|X))(e - \mathbb{E}(e|X))'|X] \\&= \mathbb{E}[(b - \mathbb{E}(b|X))(Me)'|X] \\&= \mathbb{E}[(X'X)^{-1}X'\epsilon\mathbb{E}(Me)'|X] \\&= (X'X)^{-1}X'\mathbb{E}(\epsilon\epsilon'|X)M \\&= 0\end{aligned}\tag{5}$$

Test de Hipótesis

Hasta ahora hemos confiado en estimaciones puntuales, pero cómo juzgar si un coeficiente es igual a otro?

Qué tan lejos es estar lejos?

Usaremos el error muestral y asumiremos una distribución para construir un test estadístico.

- Error muestral: $b - \beta = (X'X)^{-1}X'\epsilon$
- Distribución conjunta de (X, ϵ) ?
- En la práctica, sólo necesitamos estimación puntual y su varianza para el test de hipótesis.
- $\epsilon|X \sim N(0, \sigma^2 I_n)$. Asumiendo S1-S6, podemos escribir:

$$(b - \beta)|X \sim \mathcal{N}(0, \sigma^2(X'X)^{-1})$$

Test de Hipótesis

La hipótesis más común que evaluaremos será:

$$H_0 : \beta_j = \bar{\gamma}$$

$$H_a : \beta_j \neq \bar{\gamma}$$

Bajo H_0 , el error muestral de β_j es: $(b_j - \bar{\gamma})|X \sim \mathcal{N}(0, \sigma^2(X'X)_{jj}^{-1})$

Def:

$$z_j \equiv \frac{b_j - \bar{\gamma}}{\sqrt{\sigma^2(X'X)_{jj}^{-1}}}$$

Ahora, más que σ^2 , lo que podemos conocer es s^2 . Al reemplazar, el estadístico nuevo tiene otra distribución:

$$t_j \equiv \frac{b_j - \bar{\gamma}}{\sqrt{s^2(X'X)_{jj}^{-1}}} \equiv \frac{b_j - \bar{\gamma}}{se(b_j)}$$

Test de Hipótesis: Intervalo de confianza

Cómo hacer un t-test:

Comparamos nuestro valor con el valor crítico bajo el cual rechazamos H_0 .

$$P(-t_{\alpha/2, (n-k)} < t < t_{\alpha/2, (n-k)}) = 1 - \alpha$$

Según nuestra elección de α , podemos rechazar o *fallar el rechazo* de H_0 .

Intervalo de Confianza:

$$-t_{\alpha/2, (n-k)} < \frac{b_j - \bar{\gamma}}{se(b_j)} < t_{\alpha/2, (n-k)}$$

$$b_j - se(b_j) \times t_{\alpha/2, (n-k)} < \bar{\gamma} < b_j + se(b_j) \times t_{\alpha/2, (n-k)}$$

O simplemente: $[b_j - se(b_j) \times t_{\alpha/2, (n-k)}; b_j + se(b_j) \times t_{\alpha/2, (n-k)}]$

Test de Hipótesis: valor-p

El valor de α resulta algo arbitrario. Una opción más general es usar el valor p.

Def: $p = P(t > |t_j|) \times 2$

Esto nos dice cuánta masa de probabilidad está por arriba/debajo de un valor.

Dicho de otro modo, nos dice. a qué nivel de significancia se podría rechazar la H_0 .

Test de Hipótesis: valor-p




Figure 1: The distribution of more than one million z -values from Medline (1976–2019).

Fuente: Van Zwet, Erik W., and Eric A. Cator. "The significance filter, the winner's curse and the need to shrink." *Statistica Neerlandica* (2021)

Regresión Lineal

- Introducción
- El modelo de regresión simple (bivariado)
 - Tres maneras simples de estimar coeficientes MCO de una regresión bivariada.
 - Esperanza de una función condicional (CEF)
 - Predicción insesgada
 - Mínimos cuadrados ordinarios (MCO)
- Del modelo simple (bivariado) al modelo múltiple (multivariado)
 - Métodos de momentos (MoM)
 - Máxima verosimilitud (MVE)
 - Mínimos cuadrados ordinarios (MCO)
 - Supuestos MCO
 - Álgebra de MCO
 - Propiedades MCO
- **Problemas con los datos**


Problemas con los datos

Hasta ahora, hemos asumido que los datos que usamos están bien medidos. Dentro de la serie de problemas posibles, analizaremos algunos que son relevantes y limitan bastante la interpretación de coeficientes de una regresión lineal.

- Falacia ecológica o de composición usando datos agrupados (Falacia de Simpson)
- Error clásico de medida
- Sesgo de división
- Valores perdidos (*missing*)
- Sesgo de selección muestral posterior tratamiento

	(1)	(2)	(3)	(4)	(5)	(6)
Panel A: Log SIMCE Matemáticas						
Prop Estud.Prio	-0.281*** (0.00459)	-0.215*** (0.00719)	-0.278*** (0.0733)	-0.280*** (0.0123)	-0.214*** (0.0133)	-0.278*** (0.0613)
N	5909	5909	5909	20	20	20
R-sq	0.389	0.432	0.432	0.967	0.935	0.935
Panel B: SIMCE Matemáticas estandarizado						
Prop Estud.Prio	-2.525*** (0.0400)	-1.858*** (0.0622)	-2.372*** (0.634)	-2.515*** (0.137)	-1.847*** (0.114)	-2.381*** (0.521)
N	5909	5909	5909	20	20	20
R-sq	0.403	0.452	0.452	0.949	0.935	0.937
Controles	No	Sí	Sí	No	Sí	Sí
X ₁	No	No	Sí	No	No	Sí

Paradoja de Simpson



Paradoja de Simpson

Sesgo en admisiones postgrado en University of California. Berkeley (1973)

- Datos agregados muestran que los hombres tienen una *chance* mayor de ser admitidos, respecto de las mujeres
- Bickel et al. (2012, Science)
- Pero qué ocurre al mirar los datos más cuidadosamente?

Paradoja de Simpson

Table: Admisiones UC Berkeley (1973)

Postulantes	Admitidos	Rechazados	% Admisión
Hombres	3738	4704	44.28%
Mujeres	1494	2827	34.58%

Paradoja de Simpson

Sesgo en admisiones postgrado en University of California. Berkeley (1973)

- Datos agregados muestran que los hombres tienen una *chance* mayor de ser admitidos, respecto de las mujeres
- Bickel et al. (2012, Science)
- Pero qué ocurre al mirar los datos más cuidadosamente?
 - No todos los departamentos son equivalentes en dificultad de acceso
 - "*The proportion of women applicants tends to be high in departments that are hard to get into and low in those that are easy to get into (...)*"
 - "*this phenomenon is more pronounced in departments with large number of applicants*"

Paradoja de Simpson

Table: Admisiones UC Berkeley (1973)

Dept	Todos		Hombres		Mujeres	
	Post	% Adm	Post	% Adm	Post	% Adm
A	933	64%	825	62%	108	82%
B	5855	63%	560	63%	25	68%
C	918	35%	325	37%	593	34%
D	792	34%	417	33%	375	35%
F	584	25%	191	28%	393	24%
F	714	6%	373	6%	341	7%

Paradoja de Simpson

Table: Admisiones UC Berkeley (1973)

Dept	Todos		Hombres		Mujeres	
	Post	% Adm	Post	% Adm	Post	% Adm
A	933	64%	825	62%	108	82%
B	5855	63%	560	63%	25	68%
C	918	35%	325	37%	593	34%
D	792	34%	417	33%	375	35%
F	584	25%	191	28%	393	24%
F	714	6%	373	6%	341	7%

Paradoja de Simpson

Sesgo en admisiones postgrado en University of California. Berkeley (1973)

- Datos agregados muestran que los hombres tienen una *chance* mayor de ser admitidos, respecto de las mujeres
- Bickel et al. (2012, Science)
- Pero qué ocurre al mirar los datos más cuidadosamente?
 - No todos los departamentos son equivalentes en dificultad de acceso
 - *"The proportion of women applicants tends to be high in departments that are hard to get into and low in those that are easy to get into (...)"*
 - *this phenomenon is more pronounced in departments with large number of applicants"*
- *"if the data is properly pooled, taking into account the autonomy of departmental decision making, thus correcting for the tendency of women to apply to graduate departments that are more difficult for applicants of either sex to enter, there is a small but statistically significant bias in favor of women"*

Sesgo de selección muestral post tratamiento

Caso: Discriminación racial en detenciones policiales. (Know, Lowe and Mummolo, 2019 APSR)

Detenciones policiales puede ofrecer un espacio interesante para evaluar discriminación policial

- Policía tiene la facultad de controlar a la población (control de identidad).
- Policía decide detener a una subpoblación controlada.
- Potencial test de discriminación racial: Comparar: $\frac{Detenidos_N}{Controlados_N} = \frac{Detenidos_B}{Controlados_B}$

Qué les parece ese análisis?

Sesgo de selección muestral post tratamiento

Caso: Discriminación racial en detenciones policiales.

Qué datos se usan para el análisis del *outcome test*?

- Todos los controles policiales
- Además, para cada control, imagina que tienes información de la raza del ciudadano detenido entre otros atributos.

Sesgo de selección muestral post tratamiento

Caso: Discriminación racial en detenciones policiales.

Problema: Datos que observa la policía para definir a quien controlar no aparecen en los datos de controles.

Por qué sería eso un problema? Imagina la siguiente situación: Policía detiene a dos tipos de sujetos

- Hombres blancos que son descubiertos cometiendo un delito *in fraganti*.
- Todos los hombres negros que encuentran.

Raza afecta a quién controla la policía, *ergo* quién aparece en la base de datos. La comparación del test, en realidad es entre:

$$\frac{Detenidos_N}{Controlados_N} = \frac{Detenidos_{B\&C}}{Controlados_{B\&C}}$$

Qué significa que esa igualdad se mantenga estadísticamente? Podemos presentarla como evidencia de que la policía no discrimina?

Error clásico de medida

Variable *dependiente* medida con error

Error clásico de medida

Variable *independiente* medida con error

Problemas con los datos

Valores perdidos

- *Missings* aleatorios: Es posible ignorarlos. El mayor costo sería eficiencia. (Griliches, 1986 H.E.)
- Pero existen otros casos, donde el dato *missing* no es aleatorio:
 - Ej: Encuestas telefónicas con tasa de respuesta menor al 15 %.
 - Selección de la muestra (Heckman, 1974).

Dos problemas interesantes

Un aspecto importante a considerar es en qué sentido un modelo propuesto se ajusta a la realidad (DGP). Los desajustes en esta línea tienen consecuencias distintas dependiendo de su causa (cuál es la razón del desajuste?). Veremos dos casos interesantes que nos permitirán evaluar la calidad de un modelo propuesto (teoría).

- Inclusión de una variable irrelevante
- Omisión de una variable relevante

Inclusión de una variable irrelevante

Supongamos que el modelo bien especificado (*verdadero*) es:

$$y = \beta_1 x_1 + \beta_2 x_2 + \dots \beta_k x_k + \gamma w + \epsilon$$

Una manera de abordar esta pregunta es una falla en imponer la restricción: $\gamma = 0$. De hecho, ese sería el valor que estimaríamos para γ ($\text{Cov}(w, y) = 0$) .

Pero qué ocurre en términos de varianza de los demás coeficientes?

Recordemos: **S4.** $\mathbb{E}[\epsilon\epsilon'|X] = \text{Var}[\epsilon|X] = \sigma^2 I$

Ahora, para estimar σ^2 usamos: $b = (X'X)^{-1}X'(X\beta + \epsilon) = \beta + A\epsilon$.

donde $A = (X'X)^{-1}X'$. Así,

$$\text{Var}[b|X] = \mathbb{E}[(b - \beta)(b - \beta)'|X] = \mathbb{E}[A\epsilon\epsilon'A'|X] = A\mathbb{E}[\epsilon\epsilon'|X]A' = \sigma^2(X'X)^{-1}$$

En la práctica, matriz covarianza que incluye w es mayor que la del modelo correctamente especificado, ergo, sobre-especificar un modelo se hace a costa de la (menor) precisión de los parámetros.

El problema de la variable omitida

- Hemos visto que la inclusión de una variable irrelevante no genera problemas en términos de sesgo, pero sí en relación a la precisión de los coeficientes.
- Qué ocurre cuando no incluimos una variable relevante?
 - Modelo a estimar: $y = X\beta + z\gamma + \epsilon$
 - Pero en la práctica observamos: $y = X\beta + \epsilon$
 - Qué impacto tiene esta omisión sobre la estimación de $\beta = (\beta_1, \beta_2, \dots, \beta_k)$?

El problema de la variable omitida

Recuerde que un estimador MCO es insesgado. Es fácil ver aquello:

$$b = (X'X)^{-1}X'y = (X'X)^{-1}X'(X\beta + \epsilon) = \beta + (X'X)^{-1}X'\epsilon$$

Aplicando operador E_x , tenemos

$$\mathbb{E}[b|X] = \mathbb{E}_x[E[b|X]] = \mathbb{E}_x[\beta] = \beta$$

Supón ahora que el modelo correctamente especificado es: $y = X\beta + z\gamma + \epsilon$

Si corremos y sobre X sin incluir una variable relevante z , tenemos:

$$b = (X'X)^{-1}X'y = \beta + (X'X)^{-1}X'(z\gamma) + (X'X)^{-1}X'\epsilon$$

Que en valor esperado es: $\mathbb{E}[b|X, z] = \beta + p_{X,z}\gamma$

y $p_{X,z} = (X'X)^{-1}X'z$, pendiente de la regresión de z sobre X (FWL).

Lo que se traduce en $\mathbb{E}[b_k|X, z] = \beta_k + \gamma \frac{\text{Cov}(z, x_k | \text{all other } x\text{'s})}{\text{Var}[x_k | \text{all other } x\text{'s}]}$

El problema de la variable omitida

Asumamos que quieres conocer β_j que se obtiene a partir del siguiente modelo:

$$y_i = \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_k x_{ik} + \gamma q_i + v_i$$

- Qué pasa si no observamos q_i ?
- Modelo estimable: $y_i = \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_k x_{ik} + \epsilon_i$
- Podemos ver que ϵ_i podría estar correlacionado con x_i si q_i está correlacionado con x_i .
- Es fácil; ver que β ya no es consistente al escribir la siguiente proyección lineal:
- $q_i = \delta_1 x_{i1} + \delta_2 x_{i2} + \dots + \delta_k x_{ik} + \gamma \mu + v_i$
- como $\beta = (X'X)^{-1}X'Y$, tenemos que $b_j = \beta_j + \gamma \frac{\text{Cov}(q_i, X_{ik})}{\text{Var}[X_{ik}]}$

El problema de la variable omitida

Veamos un caso sencillo con dos variables explicativas en el modelo bien especificado:


$$y = \beta_1 x + \beta_2 z + \epsilon$$

Qué pasa si estimas β_1 sin incluir z en la regresión?

$$b_1 = \frac{\text{cov}(x, y)}{\text{Var}[x]} = \frac{\text{cov}(x, a_0 + x b_0 + Z c_0 + \epsilon)}{\text{Var}[x]} = \frac{b_0 \text{Var}[x] + c_0 \text{cov}(x, z)}{\text{Var}[x]} = b_0 + c_0 \frac{\text{cov}(x, z)}{\text{Var}[x]}$$

El problema de la variable omitida

Figure: Simulación de Monte Carlo



Contenidos del curso

Hasta ahora hemos visto lo siguiente:

- Introducción al análisis causal
- Repaso de probabilidades
- Álgebra de MCO
- Propiedades de MCO: Teorema de Gauss-Markov
- Teorema de FWL
- R^2 , medidas de ajuste
- Test de hipótesis, Intervalos de Confianza
- Problemas de especificación: Error de Medida, Atrición, Selección en la Variable Dependiente
- Sesgo de variable omitida: Hoy.

Algunos temas no cubiertos en este curso

... Pero que podrían aprender fácilmente:

- Relajando los supuestos: Homocedasticidad (errores robustos de White), FGLS, correlación serial, estimación eficiente (Ω conocida o desconocida)
- Teoría asintótica (podría ser un curso en sí, o varios más). Teorema del límite central; consistencia asintótica y propiedades de muestras grandes. Idea? Comportamiento de estimadores cuando la muestra crece al infinito. Relevante para comprender algunas propiedades de ciertos estimadores.
- Método Generalizado de Momentos (GMM)
- Estimadores de Máxima Verosimilitud
- Modelos de elección discreta (logit, probit, MNL, etc)
- Series de tiempo
- Estimaciones Bayesianas

Programa del curso

1. Introducción y repaso
2. El modelo de regresión lineal en múltiples variables
3. Causalidad y diseño
4. Diseños que abordan selección vía variables observadas
5. Diseños que abordan selección vía variables no observadas

Contenidos del curso

Hasta ahora hemos visto: Regresión Lineal MCO.

Ahora vamos a ver: Cómo usar regresión lineal para obtener estimadores causales.

Clave: Diseño de investigación/análisis.

- El problema de la endogeneidad: Próxima Clase
- Selección y endogeneidad
- Marco de resultados potenciales (*POF*): Notación Neyman-Rubin
- El experimento ideal (RCT)
- Selección basada en observables vs. no-observables
- Datos de Panel y Efectos Fijos
- Diferencias en diferencias
- Variables instrumentales
- Regresión discontinua

Econometría Aplicada

ICS 2563

Patricio Domínguez

Departamento de Ingeniería Industrial y de Sistemas
Universidad Católica de Chile

August 5, 2025