

Econometría Aplicada

ICS 2563

Patricio Domínguez

Departamento de Ingeniería Industrial y de Sistemas
Universidad Católica de Chile

September 10, 2025

Repaso: El problema de la variable omitida

Supón que el modelo correctamente especificado es: $y = X\beta + z\gamma + \epsilon$

- Si corremos y sobre X sin incluir una variable relevante z , tenemos:
- $b = (X'X)^{-1}X'y = \beta + (X'X)^{-1}X'(z\gamma) + (X'X)^{-1}X'\epsilon$
- Que en valor esperado es: $\mathbb{E}[b|X, z] = \beta + p_{X,z}\gamma$
- y $p_{X,z} = (X'X)^{-1}X'z$, pendiente de la regresión de z sobre X (Frisch-Waugh).

Lo que se traduce en $\mathbb{E}[b_k|X, z] = \beta_k + \gamma \frac{\text{Cov}(z, x_k | \text{all other } x\text{'s})}{\text{Var}[x_k | \text{all other } x\text{'s}]}$

- Recuerden que usando regresiones particionadas obteníamos:

$$\beta_k = (X_1'X_1)^{-1}X_1'y - (X_1'X_1)^{-1}X_1'X_2b_2$$

Repaso: El problema de la variable omitida

Veamos un caso sencillo con dos variables explicativas en el modelo bien especificado:

$$y = \beta_1 x + \beta_2 z + \epsilon$$

Qué pasa si estimas β_1 sin incluir z en la regresión?

$$b_1 = \frac{\text{cov}(x,y)}{\text{Var}[x]} = \frac{\text{cov}(x, a_0 + xb_0 + Zc_0 + \epsilon)}{\text{Var}[x]} = \frac{b_0 \text{Var}[x] + c_0 \text{cov}(x,z)}{\text{Var}[x]} = b_0 + c_0 \frac{\text{cov}(x,z)}{\text{Var}[x]}$$

El problema de la variable omitida

En cierto sentido, toda la segunda parte del curso se centrará en este problema.

- Los estimadores MCO ofrecen una atractiva manera de relacionar variables en contextos multivariantes.
- Pero si lo que nos interesa es analizar el efecto causal de X sobre Y , debemos asegurarnos (cómo?) que la relación entre ambas no está mediada por otra que no observamos (y que puede ser no observable).
- Esto se puede dar de múltiples maneras y para ello resulta clave analizar las limitaciones de datos observacionales.

Contenidos del curso

Hasta ahora hemos visto lo siguiente:

- Introducción a la regresión lineal
- Repaso de probabilidades
- Álgebra de MCO
- Propiedades de MCO: Teorema de Gauss-Markov
- Teorema de FWL
- R^2 , medidas de ajuste
- Test de hipótesis, Intervalos de Confianza
- Problemas de especificación: Error de Medida, Atrición, Selección en la variable Dependiente
- Sesgo de variable omitida: Clase pasada.

Contenidos del curso

Hasta ahora hemos visto: Regresión Lineal MCO.

Ahora vamos a ver: Cómo usar regresión lineal para obtener estimadores causales.

Clave: Diseño de investigación/análisis.

- El problema de la endogeneidad: Clase hoy
- Función Condicional Esperada (CEF)
- Selección y endogeneidad
- Marco de resultados potenciales (*Potential Outcome Framework*): Notación Neyman-Rubin
- El experimento ideal (RCT)
- Selección basada en observables vs. no-observables
- Datos de Panel y Efectos Fijos
- Diferencias en diferencias
- Variables instrumentales
- Regresión discontinua

Nuestro Problema central



- La idea será preguntarnos siempre qué podría ser aquello que no estamos observando que podría afectar nuestra estimación.
- Recuerda que debemos pensar en un sentido amplio (factores observables y no observables (?)).
- A estos problemas nos referiremos bajo el concepto de *sesgo de endogeneidad*.
- En términos analíticos, la endogeneidad señala que el error estimado captura una parte del modelo (DGP) que no estamos incluyendo explícitamente.
- En otras palabras, MCO estima en forma insesgada la relación entre dos variables exógenas (e.g. que no están determinadas por otra variable observable o no en el modelo).

Cómo lidiar con este problema?

- Diseño de investigación (análisis) que haga explícitos los supuestos que nos permitiría identificar la relación causal (estructural) entre x e y .

Sesgo de Endogeneidad

Causalidad reversa: Caso especial de variable relevante omitida.

- Si variable omitida afecta positivamente la variable dependiente y , a su vez, está correlacionada positivamente con la variable de interés (x), ello induce un sesgo hacia arriba en el coeficiente (β) que captura el efecto de x sobre y .
- Simultaneidad genera un problema similar.

Cuál es el efecto de la tasa de encarcelamiento (TE) sobre el crimen?

1. Si los criminales más activos son encarcelados, TE disminuye crimen (efecto incapacitación).
2. Mayor propensión a encarcelar indica que la sociedad castiga a quienes delincan pudiendo disuadir a ciertas personas de delinquir (efecto disuasión general).
3. Experiencia de encarcelamiento puede llevar a individuos a cometer más crímenes futuros (adquisición de capital criminal, erosión de capital H, etc)

Sesgo de Endogeneidad

Veamos un poco más la relación entre tasa encarcelamiento y tasa de crimen:

Cuál es el efecto de la tasa de crimen sobre el encarcelamiento?

1. Ola de crimen puede resultar en muchas personas encarceladas
2. Ola de crimen puede también aumentar preocupación social del delito, impulsando penas más severas y mayor probabilidad de encarcelamiento para ciertos delitos.

Existen varios canales a través de los cuales ambas variables se vinculan.

- El problema de endogeneidad aparece al vincular observacionalmente dos variables que se relacionan mutuamente entre sí, sin separar el efecto de una sobre la otra y viceversa.
- Podemos analizar el efecto *exógeno* de una sobre la otra?

Sesgo de Endogeneidad

La discusión anterior al podemos resumir en dos ecuaciones a estimar:

- $crime_t = \alpha_0 + \alpha_1 prison_t + \epsilon_t$
- $prison_t = \beta_0 + \beta_1 crime_t + \beta_2 X_t + v_t$

Por definición, asumimos que X_t representa un set de atributos que son determinados *afuera* del modelo (*exógenos*). Si $prison_t$ o $crime_t$ tuvieran un efecto sobre X_t , debiéramos incluir una tercera ecuación. Por otro lado, diremos que $prison_t$ y $crime_t$ son *endógenos*.

Qué podemos decir del sesgo en nuestra variable de interés (α_1)?

- $\hat{\alpha}_1 = \frac{Cov(p_t, c_t)}{var[p_t]} = \frac{Cov(p_t, \alpha_0 + \alpha_1 p_t + \epsilon_t)}{Var[p_t]} = \alpha_1 + \frac{Cov(p_t, \epsilon_t)}{Var[p_t]}$
- Al sustituir: $p_t = \beta_0 + \beta_1(\alpha_0 + \alpha_1 p_t + \epsilon_t) + \beta_2 X_t + v_t$
- Es fácil ver que: $Cov(p_t, \epsilon_t) = \frac{\beta_1 Var[\epsilon]}{1 - \beta_1 \alpha_1}$
- Como $\beta_1 > 0$ y posiblemente $\alpha_1 < 0 \rightarrow Cov(p_t, \epsilon_t) > 0$
- Qué podemos decir de la estimación entre α_1 y $\hat{\alpha}_1$?

Crimen y Encarcelamiento

Figure: Buonanno and Raphael (2013, AER)


Incarceration and Incapacitation: Evidence from the 2006 Italian Collective Pardon[†]

By PAOLO BUONANNO AND STEVEN RAPHAEL*

In August 2006, the Italian government released one-third of the nation's prison inmates via a national collective pardon. We test for a discontinuous break in national crime rates corresponding to the mass release. We also test for the effect of the return of the incarceration rate to its predicted steady state level on national crime rates. Finally, we exploit regional variation in prison releases based on the province of residence of pardoned inmates. All three sources of variation yield substantial incapacitation effect estimates and suggest that the crime-preventing effects of incarceration diminish with increases in the incarceration rate. (JEL K42)

Crimen y Encarcelamiento

Figure: Buonanno and Raphael (2013, AER)



**FIGURE 1. SCATTER PLOT OF MONTHLY INCARCERATION RATE
AGAINST MONTH MEASURED RELATIVE TO AUGUST 2006**

Crimen y Encarcelamiento

Figure: Buonanno and Raphael (2013, AER)




FIGURE 2. SCATTER PLOT OF TOTAL MONTHLY CRIMES PER 100,000 ITALIAN RESIDENTS AGAINST MONTH MEASURED RELATIVE TO AUGUST 2006

Sesgo de Endogeneidad

En cierto sentido, toda la segunda parte del curso se centrará en este problema.

- Los estimadores MCO ofrecen una atractiva manera de relacionar variables en contextos multivariantes.
- Pero si lo que nos interesa es analizar el efecto causal de X sobre Y , debemos asegurarnos (cómo?) que la relación entre ambas no está mediada por otra que no observamos (y que puede ser no observable).
- Esto se puede dar de múltiples maneras y para ello resulta clave analizar las limitaciones de datos observacionales.

Sesgo de Endogeneidad

- Pregunta: qué sería aquello que no estamos observando que podría afectar nuestra estimación.
- Factores observables y no observables (?).
- A estos problemas nos referiremos bajo el concepto de *sesgo de endogeneidad*.

Cómo lidiar con este problema?

- Establecer un diseño de investigación (análisis) que haga explícitos los supuestos que nos permitiría identificar la relación causal (estructural) entre x e y .
- Y para analizar eso en detalle, necesitamos definir una notación general.
- **Marco de resultados potenciales** Neyman-Rubin.
- Volvamos el ejemplo del hospital que vimos hace un tiempo:

Nuestro problema central

Table: El *Impacto* en salud de un Hospital

Grupo	Muestra	Promedio Status Salud	St. Error
Hospital	7,774	3.21	0.014
No Hospital	90,049	3.93	0.003


Individuos responden "Cómo calificaría su estado de salud?" (1-5; 1 mal; 5 excelente)

Fuente: NHIS, extraído de Angrist and Pischke (2008).

- Diferencia entre grupos es 0.72 ($t\text{-stat} = 58.9$) a favor de los **no hospitalizados**.

Jerzy Neyman and Donald Rubin

Jerzy Neyman (1894-1981)



Donald Rubin (1943 -)



Modelo causal Neyman-Rubin

Resultados Potenciales o *Potential Outcomes Framework*

Para describir problema, describamos el tratamiento del hospital como una variable binaria $D_i = \{0, 1\}$ y el resultado de interés (salud, por ej) como Y_i de N unidades $i = 1, \dots, N$ que han sido escogidas aleatoriamente de una población.

Podemos imaginar, dos posibles resultados de una persona i :

$$\text{Resultado Potencial} = \begin{cases} Y_{1i}, & \text{si } D_i = 1 \text{ si hubiese ido al H} \\ Y_{0i}, & \text{si } D_i = 0 \text{ si no hubiese ido al H} \end{cases}$$

... independiente de si fue –efectivamente– al Hospital.

Para determinar el efecto del hospital sobre la persona i , quisiéramos saber la diferencia entre ambos estados potenciales: $\tau_i = Y_{1i} - Y_{0i} = Y_i(1) - Y_i(0)$

El resultado observado Y_i se puede escribir en notación Neyman-Rubin como:

$$Y_i = Y_{0i} + (Y_{1i} - Y_{0i})D_i$$

Modelo causal Neyman-Rubin

Qué representa la diferencia de medias *observada* entre ambos grupos?

$$\underbrace{\mathbb{E}[Y_i|D_i = 1] - \mathbb{E}[Y_i|D_i = 0]}_{\text{Dif Obs en salud promedio}} =$$
$$= \underbrace{\mathbb{E}[Y_{1i}|D_i = 1] - \mathbb{E}[Y_{0i}|D_i = 1]}_{\text{Efecto promedio en tratados}} + \underbrace{\mathbb{E}[Y_{0i}|D_i = 1] - \mathbb{E}[Y_{0i}|D_i = 0]}_{\text{Sesgo de selección}}$$

Ojo que $\mathbb{E}[Y_{1i}|D_i = 1] - \mathbb{E}[Y_{0i}|D_i = 1] = \mathbb{E}[Y_{1i} - Y_{0i}|D_i = 1]$, es decir el efecto promedio de hospitalización entre aquellos que fueron hospitalizados. La clave es que compara, para un mismo grupo, con lo que *habría* pasado si no hubieran sido hospitalizados.

Sesgo de selección: compara el status de salud entre aquellos que fueron hospitalizados y quienes no. Como aquellos que están enfermos son más probables de ser hospitalizados, tienen peores valores de $Y_{0i} \rightarrow$ sesgo de selección negativo.

Problema Fundamental de Inferencia Causal

- Es imposible observar simultáneamente $Y_i(1)$ e $Y_i(0)$ para una misma unidad i , por lo tanto es **imposible** observar τ_i , el efecto del tratamiento en Y_i (Holland, 1986).
- Sólo podemos observar $Y_i(0)$ para unidades no tratadas e $Y_i(1)$ para unidades tratadas. Pero sí podemos concebir cantidades contrafactuales: $Y_i(1)$ para controles e $Y_i(0)$ para tratados.
- Esta limitación fundamental está dada por el *tiempo* y su inevitable transcurrir.
- Pero más que el efecto en la unidad i , nos interesa el efecto promedio en una población $\mathbb{E}[\tau_i]$, ATE (Average Treatment Effect).
- ATE: $\mathbb{E}[\tau_i] = \mathbb{E}[Y_i(1) - Y_i(0)] = \mathbb{E}[Y_i(1)] - \mathbb{E}[Y_i(0)]$
- Necesitamos un diseño apropiada que nos permita estimar ese valor.
- Repitamos: "*There is no causation without manipulation*".

Problema Fundamental de Inferencia Causal

- Es imposible observar simultáneamente $Y_i(1)$ e $Y_i(0)$ para una misma unidad i , por lo tanto es **imposible** observar τ_i , el efecto del tratamiento en Y_i (Holland, 1986).
- Sólo podemos observar $Y_i(0)$ para unidades no tratadas e $Y_i(1)$ para unidades tratadas. Pero sí podemos concebir cantidades contrafactuales: $Y_i(1)$ para controles e $Y_i(0)$ para tratados.
- Esta limitación fundamental está dada por el *tiempo* y su inevitable transcurrir.
- Pero más que el efecto en la unidad i , nos interesa el efecto promedio en una población $E[\tau_i]$, ATE (Average Treatment Effect).
- **ATE:** $\mathbb{E}[\tau_i] = \mathbb{E}[Y_i(1) - Y_i(0)] = \mathbb{E}[Y_i(1)] - \mathbb{E}[Y_i(0)]$
- Necesitamos un diseño apropiada que nos permita estimar ese valor.
- Repitamos: "*There is no causation without manipulation*".

Experimentos Aleatorios Controlados

EL problema fundamental de la inferencia causal consiste entonces en encontrar un *contrafactual* válido, i.e... datos que nos permitan inferir *qué habría pasado si* no hubiese ocurrido lo que ocurrió. En concreto, tenemos:



- El hecho que sólo observamos un resultado potencial es sutil pero clave. Aunque sea imposible de observar, sí podemos *concebir* un resultado contrafactual (qué habría pasado si).
- Definamos: $\mathbb{E}[Y_i|D_i = 1] = \mathbb{E}[Y_i(1)|D_i = 1]$ y $\mathbb{E}[Y_i|D_i = 0] = \mathbb{E}[Y_i(0)|D_i = 0]$
- Ojo, en general: $\mathbb{E}[Y_i(0)|D_i = 0] \neq \mathbb{E}[Y_i(0)|D_i = 1]$ y $\mathbb{E}[Y_i(1)|D_i = 1] \neq \mathbb{E}[Y_i(1)|D_i = 0]$, por qué?
- Pero hay un caso donde: $\mathbb{E}[Y_i(0)|D_i = 0] = \mathbb{E}[Y_i(0)|D_i = 1] = \mathbb{E}[Y_i(0)]$ y $\mathbb{E}[Y_i(1)|D_i = 1] = \mathbb{E}[Y_i(1)|D_i = 0] = \mathbb{E}[Y_i(1)]$.
- ... Supón que el tratamiento D_i fue asignado en forma aleatoria.

Experimentos Aleatorios Controlados

Figure: A.Banerjee, E.Duflo y M.Kremer



Experimentos Aleatorios Controlados



Experimentos Aleatorios Controlados

Si D_i fue asignado aleatoriamente:

- D_i es independiente de $Y(0)$ e $Y(1)$. Entonces, distribución condicional de $Y_i(0)$ dado D_i es igual a la distribución *incondicional*. Ergo,
 - $\mathbb{E}[Y_i(0)|D_i = 0] = \mathbb{E}[Y_i(0)|D_i = 1]$
 - (...o que el grupo de control ofrece un válido *contrafactual* de lo que habría ocurrido con el grupo de tratamiento en caso de **no** haber sido tratado).
 - $\mathbb{E}[Y_i(1)|D_i = 1] = \mathbb{E}[Y_i(1)|D_i = 0]$.
 - (...o que el grupo de tratamiento ofrece un válido *contrafactual* de lo que habría ocurrido con el grupo de control... en caso de haber sido tratado).
- Así, el efecto promedio $\hat{\tau} = \mathbb{E}[Y_i(1) - Y_i(0)] = \mathbb{E}[Y_i(1)] - \mathbb{E}[Y_i(0)]$.
- Lo que fácilmente se puede estimar comparando las medias entre grupo de control y tratamiento.

Experimentos Aleatorios Controlados

Por su capacidad de estimar ATE, los RCT son considerados el *estandar de oro* en estimación causal.

- Un estimador sutilmente distinto al ATE es el TOT (Treatment-on-treated)
- $\hat{\tau}_{TOT} = \mathbb{E}[Y_i(1)|D_i = 1] - \mathbb{E}[Y_i(0)|D_i = 1]$

Experimentos Aleatorios Controlados

SUTVA: *Stable Unit Value Treatment Assumption.*

Además, del supuesto de asignación aleatoria de D , hay un supuesto implícito importante.

- Sea D un vector $N \times 1$ que contiene valores tratamiento/control de cada unidad i .
- SUTVA: Si $D_i = D'_i \rightarrow Y_i(D) = Y_i(D')$
- Ojo que $Y_i(D)$ representa el resultado potencial en la unidad i , dado el régimen de tratamiento D (en todas las unidades i).
- Por ello, SUTVA es conocido como supuesto de no-interferencia.
- Ej: Vacunas
- Consistencia del tratamiento: Tratamiento mal definidos (*Poorly defined*). Aunque $D = D'$, no se cumple $Y_i(D) = Y_i(D')$

Experimentos Aleatorios Controlados

Cómo realizar un experimento en la práctica (para determinar el efecto de un causa):

1. Definir unidades que podrían ser *elegibles* para el programa.
2. Asignar *aleatoriamente* a las unidades en el grupo de control y tratamiento.
3. Implementar la intervención sólo en aquellas unidades del grupo de tratamiento.

La definición de estos tres puntos no es trivial y contienen muchos detalles como:

- Cálculo de poder para detectar un efecto esperado.
- Recolección de datos y potencial atrición diferenciada
- Efecto sobre los tratados (TOT) y efecto promedio (ATE). Más sobre esto cuando veamos IV.
- Qué significa estar en el grupo de control.

Experimentos Aleatorios Controlados

Cómo usar una regresión lineal y medir el efecto de un programa (asignado aleatoriamente):

- $Y_i(0) = \alpha + \epsilon$
- $Y_i(1) = Y_i(0) + \beta + \beta_i$
- Bajo el supuesto de efecto constante, asumimos que $\beta_i = 0$ y tenemos que:
- $Y_i(1) = \alpha + \beta D_i + \epsilon_i$
- Ahora, como $(Y_i(1), Y_i(0)) \perp D_i$:
- $Y_i = \alpha + \beta D_i + \epsilon_i$
- Ojo, que si incluimos regresores que afectan Y_i , podemos además aumentar la precisión de $\hat{\beta}$ al estimar:
- $Y_i = \alpha + \beta D_i + \delta h(X_i) + \epsilon_i$ donde $h(X_i) = \mathbb{E}[Y|X_i]$

Experimentos Aleatorios Controlados

Ventajas y desventajas generales:

- Forma transparente de eliminar el sesgo de selección sin necesidad de imponer muchos (heroicos) supuestos.
- Recolección de datos es algo (caro) difícil de realizar.
- En la práctica, resuta mejor medir preguntas acotadas con diseños especialmente hechos para ella.
- Generabilidad? RCT permiten responder una pregunta concreta en un contexto específico.
- RCT no son buenos para abordar preguntas del nivel macro y tienen dificultades para medir preguntas de equilibrio general (excepto en aquellos casos donde la aleatorización se realiza al nivel del sistema).

Experimentos Aleatorios Controlados

Consideraciones éticas:

- Limites. Ej: Stanford prison experiment
 - Zimbardo (1971)



Experimentos Aleatorios Controlados

Consideraciones éticas:

- Limites. Ej: Stanford prison experiment
 - *Male college students needed for psychological study of prison life. \$15 per day for 1–2 weeks, beginning Aug. 14. For further information and applications, come to room 248 Jordan Hall, Stanford University.*
 - Zimbardo (1971): Luego de conseguir permiso de Stanford, reclutó a 24 personas para un experimento: simulación de una prisión por 2 semanas.
 - Asignó aleatoriamente el rol de guardias y presos, asignando vestimenta y celdas de confinamiento para los *presos*. Zimbardo actuó como superintendente.
 - El experimento fue cancelado al 6 día, luego de haber reportado varios episodios de violencia.

Experimentos Aleatorios Controlados

Consideraciones éticas:

- Límites. Ej: Stanford prison experiment
- Belmont report
 - Respeto por las personas: consentimiento informado y especial consideración por grupos que requieren protección especial (niños) o para quienes puede ser difícil rechazar un tratamiento (prisioneros).
 - Beneficio: Evitar tratamientos para los que habría buena razón de hacer daño. Esto se debe balancear con el riesgo de no conducir la investigación.
 - Justicia: Asignación de riesgos y beneficios debe ser justa (*fair*). Ej: Probar la efectividad de un remedio con prisioneros para luego ser vendido a familias ricas.
- Diferencias culturales
- Ponderar riesgos y beneficios

Experimentos Aleatorios Controlados

Si bien no podemos testear *ex-post* si una intervención fue efectivamente aleatorizada, podemos analizar el balance entre el grupo de control y tratamiento usando las variables observables que tenemos disponibles.

Un ejemplo concreto: Amaral et al., (2022)

POLICY RESEARCH WORKING PAPER 9999

Abstract

Researchers and policy makers face significant challenges in selecting a method to conduct remote surveys, especially when collecting sensitive information or during turbulent life stages of hard-to-reach groups. In the context of the COVID-19 lockdown, this study randomly selected about 600 adults in El Salvador to survey using two different tools: telephone interviews or a self-completion survey via WhatsApp. The findings show that phone-based surveys

increase the rate of survey completion by 42 percentage points. Even larger effects are documented for women and older adults. Although the direct costs of phone-based surveys are substantially higher—doubling implementation cost—the estimates imply that when adjusted for the probability of completion, the costs of conducting phone-based surveys can be 25 percent lower.

Experimentos Aleatorios Controlados

Table 1: Summary Statistics and Balance Tests of Sample Characteristics

Variable	(1)	(2)	(3)	(4)	(5)	(6)	(7)	(8)
	Obs.	Mean	St.Dev.	Min	Max	WhatsApp Mean	Phone Mean	P-val.Dif. (6) vs (7)
<i>Panel A: Characteristics of full sample</i>								
Age (years)	597	31.22	6.65	16	45	31.24	31.21	(0.960)
Female (%)	599	0.52	0.50	0	1	0.572	0.473	(0.016)**
Oldest child age (years)	599	4.56	2.70	0	13	4.602	4.517	(0.699)
Shares phone (%)	599	0.23	0.42	0	1	0.234	0.220	(0.681)
Has Tigo Money (%)	599	0.30	0.46	0	1	0.291	0.300	(0.809)
Completed baseline survey (%)	599	0.60	0.49	0	1	0.589	0.607	(0.653)
Completed endline survey (%)	599	0.44	0.50	0	1	0.431	0.453	(0.590)
Observations						299	300	
<i>Panel B: Characteristics of subsample</i>								
Education level								
Basic (1-9 grades, %)	358	0.21	0.41	0	1	0.239	0.176	(0.143)
High school (10-12 grades, %)	358	0.43	0.50	0	1	0.426	0.429	(0.963)
Bachelor or higher (%)	358	0.37	0.48	0	1	0.335	0.396	(0.237)
Employment status pre and post pandemic								
Always unemployed (%)	358	0.20	0.40	0	1	0.190	0.203	(0.746)
Always employed (%)	358	0.49	0.50	0	1	0.449	0.522	(0.165)
Lost job (%)	358	0.08	0.28	0	1	0.098	0.071	(0.370)
Found job (%)	358	0.23	0.42	0	1	0.264	0.203	(0.175)
Observations						176	182	

Notes: This table shows descriptive statistics of samples' characteristics in columns (1)-(5). Balance tests comparing mean characteristics of control and treatment groups and p-value for the difference in means are presented in columns (6)-(8). Panel A presents descriptive statistics using the full sample of the experiment and Panel B shows descriptive statistics only for the sub-sample of participants that completed baseline survey. Description of each variable is presented in table A10 in the Appendix. "WhatsApp" refers to the self-completion survey treatment and "CATI" to the phone-based survey. Robust standard errors are in parentheses. *** $p < 0.01$, ** $p < 0.05$, * $p < 0.1$.


Experimentos Aleatorios Controlados

Table 3: Differences in response rates by mode of data collection

	(1)	(2)	(3)	(4)
<i>Outcome: Survey completed</i>				
Phone survey	0.422*** (0.037)	0.425*** (0.037)	0.427*** (0.038)	0.417*** (0.038)
Mean of Dep.Var (WhatsApp)	0.298	0.299	0.299	0.299
R-squared	0.178	0.182	0.212	0.242
Observations	599	597	597	597
Controls (Age, Sex)	No	Yes	Yes	Yes
Controls (Education)	No	No	No	Yes
Municipality FE	No	No	Yes	Yes

Experimentos Aleatorios Controlados

Figure 2: Heterogeneous Effects by Age



Tratamientos mal (*poorly*) definidos

Pensemos en los siguientes casos (Holland, 1986):

- Obtuvo buena nota porque es mujer.
- Obtuvo buena nota porque estudió.
- Obtuvo buena nota porque su profesora le enseñó.

De ahí entonces "*No causation without manipulation*"

Una distinción clave: *El efecto de causas vs. las causas de un efecto*

Diseños de Investigación

Hemos visto la ventaja de los RCT para lidiar con sesgo selección en la variable de interés (tratamiento). Una pregunta relevante es bajo qué condiciones (si las hubiere) podemos usar una regresión lineal -u otros métodos similares- para identificar una relación causal entre x_i e y .

- x_i asignada **como si hubiera** sido aleatoria ("*as good as random*").
- Lalonde (1986) usó un RCT como benchmark para evaluar aquello
- Experimentos Naturales (Freedman, 1991): En vez de seguir haciendo regresiones sofisticadas, Freedman presenta la investigación de John Snow sobre el cólera en Londres durante el siglo XIX.
- **Situaciones donde el tratamiento fue asignado en forma *exógena*.**

The Prize in Economic Sciences 2021

The Royal Swedish Academy of Sciences has decided to award the Sveriges Riksbank Prize in Economic Sciences in Memory of Alfred Nobel 2021

with one half to

David Card

University of California, Berkeley, USA

*“for his empirical contributions
to labour economics”*

and the other half jointly to

Joshua D. Angrist

Massachusetts Institute of Technology,
Cambridge, USA

*“for their methodological contributions to the analysis
of causal relationships”*

Guido W. Imbens

Stanford University, USA

Natural experiments help answer important questions for society

Cólera en Londres, 1849

1849: Epidemia Cólera en Londres: 14,137 muertos

- Dos compañías de agua: Lambeth Waterworks Co y Southwark and Vauxhall Water Co.
- Ambas compañías se abastecían del río Thames
- Snow Ho: Cólera se transmite vía agua contaminada

1852: Lambeth Waterworks movió la extracción aguas arriba

- Gente sabía que "aguas abajo" del centro, el agua del Thames iba sucia.

1853: Nuevo brote de cólera en Londres

- Pregunta clave: Los clientes de Lambeth tendrán mayor tasa de contagio?

Cólera en Londres, 1849

Figure: London map by John Snow




Table: Death rate from cholera by source of water. London epidemic of 1854.

	No. Houses	Cholera Deaths	Rate per 10,000
Southwark and Vauxhall	40,046	1,263	315
Lambeth	26,107	98	37
Rest of London	256,423	1,422	59

Snow's table IX. Extraído de Freedman (2009, p.8)

Diseños de Investigación

Hemos visto la ventaja de los RCT para lidiar con sesgo selección en la variable de interés (tratamiento). Una pregunta relevante es bajo qué condiciones (si las hubiere) podemos usar una regresión lineal para identificar una relación causal entre x_i e y ?

Veremos dos tipos de diseños:

- Selección vía variables observables: Regresión lineal, Matching.
- Selección vía variables no observables: Datos de panel, efectos fijos, diferencias en diferencias, variables instrumentales, regresión discontinua, entre otros.

Selección en Observables

Existen situaciones donde la regla de asignación a tratamiento es perfectamente conocida (observable). Ahí, el problema de identificar el efecto del tratamiento consiste en incorporar todos aquellos factores en la estimación (*controlar* por aquello que define la asignación al tratamiento y que afecta el resultado de interés).

En otras palabras, puedes obtener estimadores insesgados si la regla de selección es función de variables observables -que puedes incorporar en la estimación.

Formalmente,

- Supuesto (*unconfoundedness*): $(Y_i(1), Y_i(0)) \perp D_i | X_i$
- ... o "supuesto de selección en observables" o "supuesto de independencia condicional".
- Combinado con supuesto de traslape (*overlap*: $0 < P(D_i = 1 | X_i) < 1$) se conoce como "asignación de tratamiento fuertemente ignorable" (*strongly ignorable treatment assignment*).

Selección en Observables

En el caso de una regresión lineal, podemos escribir.:

- $Y_i(0) = \alpha + \epsilon$
- $Y_i(1) = Y_i(0) + \beta + \beta_i$
- Bajo el supuesto de efecto constante, asumimos que $\beta_i = 0$ y tenemos que:
- $Y_i = \alpha + \beta D_i + \epsilon_i$
- Ahora, si $(Y_i(1), Y_i(0)) \perp D_i | X_i$:
- $Y_i = \alpha + \beta D_i + \delta h(X_i) + \epsilon_i$
- donde $h(X_i) = \mathbb{E}[D_i | X_i]$

Función Condicional Esperada (CEF)

Una forma alternativa de interpretar una regresión lineal.

- CEF de y_i viene dado por $\mathbb{E}[y_i|X_i] = h(X_i)$ y, como tal, es una función de X_i . Como X_i es variable aleatoria, CEF también lo es.
- Caso especial: $\mathbb{E}[y_i|D_i]$ con D_i una variable binaria.
- Residuos de CEF: $\epsilon_i = y_i - h(X_i)$
- Por definición: $\mathbb{E}[\epsilon_i|x_i] = 0$ por qué?

Función Condicional Esperada (CEF)

Teorema. Residuos CEF son media-independientes de los argumentos de $CEF(x_i)$. En otras palabras, son ortogonales a cualquier función de las variables condicionantes.

Teorema CEF es la *mejor* función de X que existe para predecir y .

- $\mathbb{E}[y_i|X_i] = \operatorname{argmin}_h \mathbb{E}[(y_i - h(X_i))^2]$.
- O sea, CEF minimiza el error cuadrado esperado.

Una pregunta adicional es sobre la conveniencia de usar una regresión *lineal*. Veamos tres razones:

Función Condicional Esperada (CEF)

Razón 1: **Teorema.** Regresión-CEF.

- Si CEF lineal, entonces la regresión de y_i sobre X_i estima la CEF.
- **Formalmente:** $\mathbb{E}[y_i|x_i] = x_i'\beta \rightarrow \beta = \mathbb{E}[x_i x_i']^{-1} \mathbb{E}[x_i y_i]$

Por supuesto, CEF no tiene por qué ser lineal. Pero puede haber dos condiciones suficientes para ello:

- Normalidad conjunta entre x_i e y_i
- Modelo *saturado* con regresores discretos (más común en la práctica).

Así y todo, en mayoría de casos, CEF no es lineal. Entonces?

Función Condicional Esperada (CEF)

Razón 2: **Teorema.** BLP (Best Linear Predictor)

- Si quieres predecir y_i y te restringes a funciones lineales de x_i , entonces
- $x_i'\beta = x_i'\mathbb{E}[x_ix_i']^{-1}\mathbb{E}[x_iy_i]$ es el mejor predictor lineal de y_i (en el sentido de producir el menor error cuadrático posible).
- **Formalmente:** $\beta = \mathbb{E}[x_ix_i']^{-1}\mathbb{E}[x_iy_i] = \operatorname{argmin}_b \mathbb{E}[(y_i - x_i'b)^2]$

Quizás esto no es sorprendente, pero es útil si te interesa predecir, aunque no muy relevante si quieres conocer la relación entre x_i e y_i .

Función Condicional Esperada (CEF)

Razón 3: **Teorema.** Aproximación de la regresión.

- La aproximación lineal MMSE de la CEF es: $\beta = \mathbb{E}[x_i x_i']^{-1} \mathbb{E}[x_i y_i]$.
- **Formalmente:** $\beta = \mathbb{E}[x_i x_i']^{-1} \mathbb{E}[x_i y_i] = \operatorname{argmin}_b \mathbb{E}[(\mathbb{E}[y_i | x_i] - x_i' b)^2]$

Regresión provee la *mejor* aproximación lineal de la CEF, incluso cuando la CEF no es lineal. Esto , siempre y cuando, no estés extrapolando muy lejos de la zona de soporte de x_i .

Función Condicional Esperada (CEF)

Tres razones para querer una regresión lineal (Angrist):

- Regresión resuelve el problema mínimos cuadrados *poblacional* y, por lo tanto, es el mejor predictor lineal de y_i dado X .
- Si la CEF es lineal, la regresión también lo es.
- Regresión entrega la mejor aproximación lineal de la CEF.


Función Condicional Esperada (CEF)

Anatomía de una regresión (Angrist)

- Si tienes un regresor x_i y la constante, $\hat{\beta}_1 = \frac{\text{Cov}(y_i, x_i)}{\text{Var}[x_i]}$, y el intercepto es $\hat{\alpha} = \mathbb{E}[y_i] - \hat{\beta}_1 \mathbb{E}[x_i]$
- Con más de un regresor: $\hat{\beta}_k = \frac{\text{Cov}(y_i, \tilde{x}_{ki})}{\text{Var}[\tilde{x}_{ki}]}$, donde $\tilde{x}_{ki}$ es el residuo de la regresión de x_{ki} sobre todos las demás covariables.
- También lo puedes escribir matricialmente como $\hat{\beta}_k = \mathbb{E}[XX']^{-1} \mathbb{E}[Xy]$

Función Condicional Esperada (CEF)

Figure: Raw data and the CEF of average log weekly wages given schooling




© Princeton University Press. All rights reserved. This content is excluded from our Creative Commons license. For more information, see <http://ocw.mit.edu/help/faq-fair-use/>.

Figure 3.1.1: Raw data and the CEF of average log weekly wages given schooling. The sample includes white men aged 40-49. The data are from the 1980 IPUMS5 percent sample.

Función Condicional Esperada (CEF)

Figure: Regression threads the CEF of average weekly wages given schooling



© Princeton University Press. All rights reserved. This content is excluded from our Creative Commons license. For more information, see <http://ocw.mit.edu/help/faq-fair-use/>.

Sample is limited to white men, age 40-49. Data is from Census IPUMS 1980, 5% sample.

Figure 3.1.2: Regression threads the CEF of average weekly wages given schooling

Función Condicional Esperada (CEF)

Figure: CEF: Regresiones a nivel individual vs. grupal

A - Individual-level data

```
. regress earnings school, robust
```

Source	SS	df	MS	Number of obs = 409435	
Model	22631.4793	1	22631.4793	F(1,409433) =	49118.25
Residual	188648.31	409433	.460755019	Prob > F =	0.0000
				R-squared =	0.1071
				Adj R-squared =	0.1071
Total	211279.789	409434	.51602893	Root MSE =	.67879

earnings	Coef.	Robust Std. Err.	t	Old Fashioned Std. Err.	t
school	.0674387	.0003447	195.63	.0003043	221.63
const.	5.835761	.0045507	1282.39	.0040043	1457.38

B - Means by years of schooling

```
. regress average_earnings school [aweight=count], robust
(sum of wgt is 4.0944e+05)
```

Source	SS	df	MS	Number of obs = 21	
Model	1.16077332	1	1.16077332	F(1, 19) =	540.31
Residual	.040818796	19	.002148358	Prob > F =	0.0000
				R-squared =	0.9660
				Adj R-squared =	0.9642
Total	1.20159212	20	.060079606	Root MSE =	.04635

average_earnings	Coef.	Robust Std. Err.	t	Old Fashioned Std. Err.	t
school	.0674387	.0040352	16.71	.0029013	23.24
const.	5.835761	.0399452	146.09	.0381792	152.85



EKONOMIPRISET 2023 THE PRIZE IN ECONOMIC SCIENCES 2023



KUNGL.
VETENSKAPS-
AKADEMIEN

THE ROYAL SWEDISH ACADEMY OF SCIENCES



Claudia Goldin
Harvard University, USA

*"för att ha förbättrat vår förståelse av kvinnors
arbetsmarknadsutfall"*

*"for having advanced our understanding of
women's labour market outcomes"*

Orchestrating Impartiality: The Impact of “Blind” Auditions on Female Musicians

By CLAUDIA GOLDIN AND CECILIA ROUSE*

A change in the audition procedures of symphony orchestras—adoption of “blind” auditions with a “screen” to conceal the candidate’s identity from the jury—provides a test for sex-biased hiring. Using data from actual auditions, in an individual fixed-effects framework, we find that the screen increases the probability a woman will be advanced and hired. Although some of our estimates have large standard errors and there is one persistent effect in the opposite direction, the weight of the evidence suggests that the blind audition procedure fostered impartiality in hiring and increased the proportion women in symphony orchestras. (JEL J7, J16)




FIGURE 1. PROPORTION FEMALE IN NINE ORCHESTRAS, 1940 TO 1990's
A: THE "BIG FIVE"; B: FOUR OTHERS

Orchestrating Auditions

- **Motivación:** Cómo identificar discriminación a un grupo? Difícil ya que diferencias en probabilidad de selección puede reflejar diferencias en la calidad de los postulantes (o mera tendencia a postular a lugares más exigentes por parte de un grupo. Recuerda caso de estudiantes en UC Berkeley).
- **Datos:** Records de las 8 principales orquestas (confidenciales) 1950-1995. Nombre de asistentes y quienes pasaron a c/ronda de selección, instrumento y posición (sección, principal o sustituto). Sexo inferido a partir del nombre. Muestra final: 7k individuos de 588 rondas de audición (14k rondas-personas).
- **Método:** $P_{ijtr} = \alpha + \beta F_i + \gamma B_{jtr} + \delta F_i \times B_{jtr} + X_{it}\theta_1 + Z_{jtr}\theta_2 + \epsilon_{ijtr}$
- **Resultados:** Controlando por la calidad de los postulantes, la implementación de audiencias ciegas mejoró la probabilidad de seleccionar a una mujer.

TABLE 4—AVERAGE SUCCESS AT AUDITIONS BY SEX, YEAR, AND ROUND OF AUDITION

Year	Relative female success		
	All auditions	Completely blind auditions	Not completely blind auditions
All	-0.001 (0.008)	-0.022 (0.012)	0.006 (0.010)
Pre-1970	0.053 (0.115)		0.053 (0.115)
1970-1979	0.001 (0.021)		0.001 (0.021)
1980-1989	-0.006 (0.009)	-0.039 (0.016)	0.010 (0.009)
1990+	-0.003 (0.010)	-0.001 (0.017)	-0.003 (0.013)
Round	All rounds	Blind rounds	Not-blind rounds
Preliminaries, without semifinals	-0.032 (0.019)	-0.048 (0.021)	0.012 (0.040)
Preliminaries, with semifinals	-0.048 (0.016)	-0.052 (0.016)	0.116 (0.228)
Semifinals	-0.030 (0.038)	-0.059 (0.044)	0.071 (0.080)
Finals	0.009 (0.036)	-0.028 (0.102)	0.016 (0.038)

Notes: For the top part of the table “success” is a “hire,” whereas for the bottom portion “success” is advancement from one stage of an audition to the next. The unit of observation for the top portion is the audition, whereas it is the round for the bottom portion (e.g., relative female success in the top portion of the table is averaged across the auditions). Standard errors are in parentheses. “Relative female success” is the proportion of women advanced (or hired) minus the proportion of men advanced (or hired). By hired, we mean those who were advanced from the final round out of the entire audition.

Source: Eight-orchestra audition sample. See text.

TABLE 5—AVERAGE SUCCESS AT AUDITIONS BY SEX AND STAGE OF AUDITION FOR THE SUBSET OF MUSICIANS WHO AUDITIONED BOTH BLIND AND NOT BLIND

	Blind		Not blind	
	Proportion advanced	Number of person-rounds	Proportion advanced	Number of person-rounds
Preliminaries without semifinals				
Women	0.286 (0.043)	112	0.193 (0.041)	93
Men	0.202 (0.026)	247	0.225 (0.031)	187
Preliminaries with semifinals				
Women	0.200 (0.092)	20	0.133 (0.091)	15
Men	0.083 (0.083)	12	0.000 (0.000)	8
Semifinals				
Women	0.385 (0.061)	65	0.568 (0.075)	44
Men	0.368 (0.059)	68	0.295 (0.069)	44
Finals				
Women	0.235 (0.106)	17	0.087 (0.060)	23
Men	0.000 (0.000)	12	0.133 (0.091)	15
"Hired"				
Women	0.027 (0.008)	445	0.017 (0.005)	599
Men	0.026 (0.005)	816	0.027 (0.005)	1102

Notes: The unit of observation is a person-round. Standard errors are in parentheses. For the round in question, only musicians who auditioned more than once and who auditioned at least once behind a screen and at least once without a screen are included. "Hired" means those who were advanced from the final round out of the entire audition. Blind in the "hired" category means for all rounds. Not blind in the "hired" category means that at least one round was not blind. This difference in the definition of what constitutes a "blind" round or audition is one reason why the number of observations in the first four panels is less than the number of observations in the "hired" panel. The number of observations also differ because we exclude auditions or rounds in which no individual is advanced or in which there are only women or no women. Finally, unlike in subsequent tables, we exclude a few candidates for whom we could not determine or impute their sex. Note that the binding constraint for the preliminaries is the not-blind category, for which we have only one orchestra. The binding constraint in the "hired" category are the blind auditions, for which we have (at most) three orchestras. Musicians can appear more than once in either the blind or not-blind categories.

Source: Eight-orchestra audition sample. See text.

TABLE 7—LINEAR PROBABILITY ESTIMATES OF THE LIKELIHOOD OF BEING ADVANCED: WITH INDIVIDUAL AND ORCHESTRA FIXED EFFECTS

	Include individual fixed effects		Exclude individual fixed effects
	(1)	(2)	(3)
Blind	0.404 (0.027)	0.399 (0.027)	0.103 (0.018)
Female × Blind	0.044 (0.039)	0.041 (0.039)	−0.069 (0.022)
Female			−0.005 (0.019)
p -value of H_0 : Blind + (Female × Blind) = 0	0.000	0.000	0.090
Individual fixed effects?	Yes	Yes	No
Orchestra fixed effects?	No	Yes	Yes
Year fixed effects?	Yes	Yes	Yes
Other covariates?	Yes	Yes	Yes
R^2	0.615	0.615	0.048
Number of observations	8,159	8,159	8,159

Notes: The unit of observation is a person-round. The dependent variable is 1 if the person is advanced to the next round and 0 if not. Standard errors are in parentheses. All specifications include an interaction for the sex being missing and a blind audition; “Other covariates” include automatic placement, years since last audition, number of auditions attended, size of the audition round, proportion female in audition round, whether a principal or substitute position, and a dummy indicating whether years since last audition is missing. These regressions include only the orchestras that changed their audition policy during our sample years and for which we observe individuals auditioning for the audition round both before and after the policy change. These regressions include 4,836 separate persons and are identified off of 1,776 person-rounds comprised of individuals who auditioned both before and after the policy change for a particular orchestra. *Source:* Eight-orchestra audition sample (three orchestras of which are used; see Notes). See text.

Pounds That Kill: The External Costs of Vehicle Weight

MICHAEL L. ANDERSON

University of California, Berkeley and NBER

and

MAXIMILIAN AUFFHAMMER

University of California, Berkeley and NBER

First version received January 2012; final version accepted May 2013 (Eds.)

Heavier vehicles are safer for their own occupants but more hazardous for other vehicles. Simple theory thus suggests that an unregulated vehicle fleet is inefficiently heavy. Using three separate identification strategies we show that, controlling for own-vehicle weight, being hit by a vehicle that is 1000 pounds heavier generates a 40–50% increase in fatality risk. These results imply a total accident-related externality that exceeds the estimated social cost of US carbon emissions and is equivalent to a gas tax of \$0.97 per gallon (\$136 billion annually). We consider two policies for internalizing this external cost, a weight-varying mileage tax and a gas tax, and find that they are similar for most vehicles. The findings suggest that European gas taxes may be much closer to optimal levels than the US gas tax.

Key words: Traffic accidents, Highway safety, Gasoline tax, Energy Policy, Arms race.

JEL Codes: H23, I18, Q48, Q58, R41

Pounds that kill: the external costs of vehicle weight

Descripción general del paper:

- Mensaje: Vehículos pesados son más seguros para sus ocupantes, pero más peligrosos para el resto de los vehículos.
- Resultado: Ser impactado por un vehículo 1,000 lb más pesado aumenta 40-50% el riesgo de muerte.
- Datos: reportes policiales de 8 estados: heridos, muertes, ubicación, condiciones del tiempo, equipamiento de seguridad y características del conductor y pasajeros. Además, al usar ID vehículo pudieron identificar el peso de cada uno. Dividieron accidentes en único, doble o triples. 4.8 m accidentes dobles.

Estrategia de identificación

We estimate the conditional expectation of a fatality in the struck vehicle as a function of striking vehicle weight, struck vehicle weight, and a rich set of covariates. We estimate the conditional expectation function (CEF) using either a linear probability model (LPM) or a probit. For robustness, we report estimates for both models.

We specify the linear probability model as follows:

$$\begin{aligned} E[\text{struck veh fatality}_i | \text{striking veh weight}_i, \text{struck veh weight}_i, X_{1i}, X_{2i}, W_i,] \\ = \beta_1 \text{striking veh weight}_i + \beta_2 \text{struck veh weight}_i + X_{1i}\delta_1 + X_{2i}\delta_2 + W_i\delta_3 \end{aligned} \quad (6)$$

- Condicional en haber chocado, lo que nos previene de comparar resultados generados por diferencias en tasa de choques entre conductores de autos pesados y livianos.
- Análisis centrado en choques dobles; cada vehículo aparece dos veces (*once as the struck and once as the striking vehicle*). Errores *clusterizados* al nivel de choque para tomar en cuenta la correlación serial entre observaciones.
- Controles incluyen: peso vehículo, indicadores camión liviano and efectos fijos de año, además de indicadores de autos que impactan (*striking*) e impactados (*struck*). Otras especificaciones incluyen: lluvia, oscuridad, día de la semana, autopista, término cuadrático del año del vehículo, y año, hora y efectos fijos de condado para contabilizar diferencias importantes en estas dimensiones.

Pounds that kill: the external costs of vehicle weight

Estrategia de identificación

"(...) nevertheless, driver selection could bias our results if drivers of heavy vehicles have a tendency towards severe accidents." (Anderson and Auffhammer, 2013 p.536).

Descartan esa posibilidad vía:

- Tests de falsification: resultados se sostienen incluso luego de controlar por tipo de vehículo y efectos fijos de modelos.
- Dos fuentes alternativas de identificación: (i) estiman efecto peso vehículo que impacta variando número de ocupantes y encuentran resultados similares, (ii) peso vehículo no predice muertes cuando dos vehículos de igual peso chocan.

Pounds that kill: the external costs of vehicle weight




FIGURE 1

Relationship between striking vehicle weight and struck vehicle fatalities

Pounds that kill: the external costs of vehicle weight

ANDERSON & AUFFHAMMER

POUNDS THAT KILL




FIGURE 2

Relationship between difference in vehicle weights and struck vehicle fatalities

Selección en Observables

Aplicación: El impacto de los computadores en ingresos laborales

- Krueger (1993): "Premio salarial" por usar computador en el trabajo
- Estima algo así: $\log(W_i) = X_i\beta + \alpha C_i + \epsilon_i$
- Agrega una serie de controles: educación, experiencia, raza, sexo, estado civil, ocupación, industria. Luego dice: "*A critical concern in interpreting the OLS regressions reported above is that workers who use computers on the job may be abler workers, and therefore may have earned higher wages even in the absence of computer technology* (pp.42-43)".
- Krueger analiza algunos datos adicionales. Resultados se sostienen al:
 - Controlar por uso de computador en casa
 - Agrega una encuesta con ofertas temporales más altas para quienes usen PCs
 - Usa otra fuente de datos y obtiene resultados similares
 - Muestra que ocupaciones que adoptaron PC más rápido mostraron crecimiento salarial más rápido

Selección en Observables

Aplicación: El impacto de los computadores en ingresos laborales

- DiNardo and Pischke (1997): "Premio salarial" por usar lápiz en el trabajo
- Estima algo similar: $\log(W_i) = X_i\beta + \alpha P_i + \epsilon_i$
- Encuentra en muchos casos (especificaciones) "retornos" similares a los encontrados por Krueger para computadores.
- Más que falsear el resultado de Krueger, muestran que su diseño no sería capaz de distinguir entre un efecto real y otro que se debe a mera selección.

Selección en Observables v.s Selección en no-observables

SOO SOU

- SOO: $(Y_i(1), Y_i(0)) \perp D_i | X_i$
- SOU: $(Y_i(1), Y_i(0)) \perp Z_i$ and $Cov(D_i | Z_i) \neq 0$

Recuerda que todo buen diseño debe basarse en *buena* variación de D ("*as good as randomly assigned*").

- SOO: Puedes identificar toda la variación mala y controlar por ella. ("*I know everything about everything*"). Ejemplos: Regresión lineal, matching (apareamiento), propensity score matching.
- SOU: Puedes identificar alguna parte de la variación buena y usarla en la estimación. ("*I know a little bit about a little bit*"). Ejemplos: Efectos fijos, diferencias en diferencias, regresión discontinua, variables instrumentales.

Econometría Aplicada

ICS 2563

Patricio Domínguez

Departamento de Ingeniería Industrial y de Sistemas
Universidad Católica de Chile

September 10, 2025