

Econometría Aplicada

ICS 2563

Patricio Domínguez

Departamento de Ingeniería Industrial y de Sistemas
Universidad Católica de Chile

October 22, 2025

Variables Instrumentales

- SOO: Puedes identificar toda la variación mala y controlar por ella. ("*I know everything about everything*"). Ejemplos: Regresión lineal, matching (apareamiento), propensity score matching.
- SOU: Puedes identificar alguna parte de la variación buena y usarla en la estimación. ("*I know a little bit about a little bit*"). Ejemplos: Efectos fijos, diferencias en diferencias, regresión discontinua, variables instrumentales.

Variables Instrumentales



Scientific Background on the Sveriges Riksbank Prize in Economic Sciences in Memory of Alfred Nobel 2021

ANSWERING CAUSAL QUESTIONS USING OBSERVATIONAL DATA

The Committee for the Prize in Economic Sciences in Memory of Alfred Nobel

Variables Instrumentales

IV es uno de los principales métodos para identificar causalidad.

- Diseño basado en no-observables.
- Originalmente ideado por Wright and Wright (1928) y continuado por Tinbergen y Haavelmo en los 1930s y 1940s, fue fuertemente desarrollado durante los 1990s y 2000s (revolución de credibilidad en economía).
- Revisaremos métodos con efectos homogéneos (constantes), y luego ampliaremos a métodos que consideran efectos heterogéneos.

Variables Instrumentales

IV es uno de los principales métodos para identificar causalidad.

- Phillip and Sewal Wright en los años 1920s: Estimar oferta y demanda con datos sobre equilibrio de precio/cantidad (ecuaciones simultáneas).
- Wald (1940): Estimar una regresión donde el regresor relevante está medido con error.
- Hoy: Método principal para eliminar sesgo de variable omitida u otro sesgo de endogeneidad.
 - O para analizar RCT con *imperfect compliance*.

Variables Instrumentales

Considere un simple modelo causal con efectos homogéneos del tipo:

$$Y_i(s) = \alpha + \rho s_i + \epsilon_i$$

- $Y_i(s)$ es el salario potencial si i completa s años de escolaridad.
- Efecto causal homogéneo: $\rightarrow Y_i(s) - Y_i(s - 1) = \rho \quad \forall (i, s)$
- Observamos escolaridad s_i y salarios $Y_i(s)$.

Variables Instrumentales

Considere un simple modelo causal con efectos homogéneos del tipo:

$$Y_i(s) = \alpha + \rho s_i + \epsilon_i$$

- Ecuación estructural: $Y_i(s) = \alpha + \rho s_i + \epsilon_i$
- Estamos seguros que condición $Cov(s_i, \epsilon_i) = 0$ se cumple?
- Supongamos que existe habilidad no observada: $\epsilon_i = \gamma A_i + v_i$
- Podría estar sesgada nuestra estimación del efecto de escolaridad sobre salarios?

Variables Instrumentales

Retomemos la discusión sobre sesgo de variable omitida

- Regresión larga: $Y_i(s) = \alpha + \rho s_i + \gamma A_i + v_i$
- Regresión corta: $Y_i(s) = \alpha_s + \rho_s s_i + v_{is}$
- OVB fórmula: $\rho_s = \rho + \gamma \frac{\text{Cov}(S_i, A_i)}{\text{Var}(S_i)}$

Una alternativa es usar una variable instrumental. Idea?

- Identificar parte de la variación de s_i (o más general, respecto de un tratamiento d_i), que llamaremos z_i , que no está correlacionada con ϵ_i . Si eso se cumple, podemos decir que es "tan buena como si hubiera sido aleatoria".
- Meta: encontrar un instrumento z_i (si existe por ahí) que cumpla con lo siguiente:

Variables Instrumentales: Tratamiento d_i

Meta: encontrar un instrumento z_i (si existe por ahí) que cumpla con lo siguiente:

1. $\text{Cov}(z_i, d_i) \neq 0 \dots$ que sea relevante (primera etapa).
2. $\text{Cov}(z_i, \epsilon_i) = 0 \dots$ que sea exógeno (restricción de exclusión).

Se puede dar en forma *natural* o manipulada adecuadamente por investigadores para identificar un efecto causal.

En el caso de una regresión, donde z, y, x son vectores $N \times 1$

$$\hat{\beta}_{IV} = (z'd)^{-1}(z'y) \quad (1)$$

$\hat{\beta}_{IV}$ es un estimador consistente de β .

Variables Instrumentales: Tratamiento s_i

Meta: encontrar un instrumento z_i (si existe por ahí) que cumpla con lo siguiente:

1. $\text{Cov}(z_i, s_i) \neq 0$... que sea relevante (primera etapa).
2. $\text{Cov}(z_i, \epsilon_i) = 0$... que sea exógeno (restricción de exclusión).

Se puede dar en forma *natural* o manipulada adecuadamente por investigadores para identificar un efecto causal.

En el caso de una regresión, donde z, y, x son vectores $N \times 1$

$$\hat{\beta}_{IV} = (z's)^{-1}(z'y) \quad (2)$$

$\hat{\beta}_{IV}$ es un estimador consistente de β .

Variables Instrumentales: Tratamiento S_i

Relevancia (1a etapa) se puede testear

Restricción de exclusión?

- $Cov(Y_i, Z_i) = Cov(\alpha + \rho S_i + \epsilon_i, Z_i)$
- $Cov(Y_i, Z_i) = \rho Cov(S_i, Z_i)$
- Es claro, que si $Cov(S_i, Z_i) > 0$, podemos identificar ρ

Variables Instrumentales: Tratamiento s_i

Cómo podemos estimar ρ en la práctica? Cuociente de dos regresiones.

- $Cov(Y_i, Z_i) = \rho Cov(S_i, Z_i)$ se puede describir como:
- $\frac{Cov(Y_i, Z_i)}{Var(Z_i)} = \rho \frac{Cov(S_i, Z_i)}{Var(Z_i)}$

$$Y_i = \lambda + \delta Z_i + u_i \quad (3)$$

$$S_i = \kappa + \pi Z_i + \eta_i \quad (4)$$

- δ se conoce como el coeficiente de forma reducida (instrumento sobre el *outcome*).
- π es el coeficiente de la primera etapa.

Pero, de dónde viene Z_i ?

THE
QUARTERLY JOURNAL
OF ECONOMICS

Vol. CVI

November 1991

Issue 4

DOES COMPULSORY SCHOOL ATTENDANCE AFFECT
SCHOOLING AND EARNINGS?*

JOSHUA D. ANGRIST AND ALAN B. KRUEGER

We establish that season of birth is related to educational attainment because of school start age policy and compulsory school attendance laws. Individuals born in the beginning of the year start school at an older age, and can therefore drop out after completing less schooling than individuals born near the end of the year. Roughly 25 percent of potential dropouts remain in school because of compulsory schooling laws. We estimate the impact of compulsory schooling on earnings by using quarter of birth as an instrument for education. The instrumental variables estimate of the return to education is close to the ordinary least squares estimate, suggesting that there is little bias in conventional estimates.

Variables Instrumentales: 1a Etapa




FIGURE I
Years of Education and Season of Birth
1980 Census
Note. Quarter of birth is listed below each observation.

Variables Instrumentales: Forma Reducida




FIGURE V
Mean Log Weekly Wage, by Quarter of Birth
All Men Born 1930-1949; 1980 Census

Angrist and Krueger (1991, QJE)

Una forma simple de analizar el tipo de variación que usa el instrumento para estimar el efecto de la escolaridad sobre los salarios es la siguiente:

Analicemos dos casos de personas que desertan a la edad mínima posible:

- Fecha de Nacimiento: 2 Enero, 1930:
 - Inicio edad escolar: 1 Septiembre, 1936
 - 1er día deserción: 2 Enero, 1946
 - Escolaridad al desertar: **9.5 años**
- Fecha de Nacimiento: 31 Diciembre, 1930:
 - Inicio edad escolar: 1 Septiembre, 1936
 - 1er día deserción: 31 Diciembre, 1946
 - Escolaridad al desertar: **10.5 años**

Estimador de Wald

El estimador IV más simple con un instrumento binario (dummy) y un regresor endógeno (sin covariables).


De nuevo, supongamos la regresión: $Y_i = \alpha + \rho s_i + \eta_i$. Usando el hecho que $\mathbb{E}[\eta_i|z_i] = 0$, podemos escribir:

$$\mathbb{E}[Y_i|z_i] = \alpha + \rho \mathbb{E}[s_i|z_i].$$

Luego, comparando los casos $z_i = 0$ y $z_i = 1$, podemos ver fácilmente que:

$$\rho = \frac{\mathbb{E}[Y_i|Z_i = 1] - \mathbb{E}[Y_i|Z_i = 0]}{\mathbb{E}[S_i|Z_i = 1] - \mathbb{E}[S_i|Z_i = 0]} \quad (5)$$

Estimador de Wald (1940)



Variables Instrumentales

Alternativamente, podemos encontrar ρ usando r.e: $Cov(Z_i, \epsilon_i) = 0$:

$$Cov(Y_i, Z_i) = Cov(\alpha + \rho S_i + \epsilon_i, Z_i) = \rho Cov(S_i, Z_i)$$

Luego, la covarianza de una variable binaria (invocando ley de esperanzas iteradas):

$$\begin{aligned} Cov(Y_i, Z_i) &= \mathbb{E}[Y_i Z_i] - \mathbb{E}[Y_i] \mathbb{E}[Z_i] \\ &= p \mathbb{E}[Y_i | Z_i = 1] - \underbrace{[p \mathbb{E}[Y_i | Z_i = 1] + (1 - p) \mathbb{E}[Y_i | Z_i = 0]]}_{\mathbb{E}[Y_i]} p \\ &= p(1 - p) [\mathbb{E}[Y_i | Z_i = 1] - \mathbb{E}[Y_i | Z_i = 0]] \end{aligned}$$

Lo mismo para: $Cov(S_i, Z_i) = [\mathbb{E}[S_i | Z_i = 1] - \mathbb{E}[S_i | Z_i = 0]] p(1 - p)$

Ergo,

$$\rho = \frac{Cov(Y_i, Z_i)}{Cov(S_i, Z_i)} = \frac{\mathbb{E}[Y_i | Z_i = 1] - \mathbb{E}[Y_i | Z_i = 0]}{\mathbb{E}[S_i | Z_i = 1] - \mathbb{E}[S_i | Z_i = 0]} \quad (6)$$

Variables Instrumentales

Angrist and Krueger (1991) implementan IV de distintas maneras:

- Estimador Wald = $\frac{\mathbb{E}[w|q_1] - \mathbb{E}[w|q_{2-4}]}{\mathbb{E}[s|q_1] - \mathbb{E}[s|q_{2-4}]}$, lo que resulta equivalente a estimar IV sin covariables en la regresión: $\beta_{IV} = 0.1$
- 2SLS: usando una docena de instrumentos: $\hat{\beta}_{2SLS} = 0.07$
- Qué críticas podría tener este instrumento?

Variables Instrumentales

Formalmente, dada la restricción de exclusión $Cov(v_i, z_i) = 0$, o que z_i no esté correlacionada con otros determinantes de la variable dependiente (A_i y v_i), tenemos:

$$\rho = \frac{Cov(Y_i, z_i)}{Cov(s_i, z_i)} = \frac{\frac{Cov(Y_i, z_i)}{Var(z_i)}}{\frac{Cov(s_i, z_i)}{Var(z_i)}} \quad (7)$$

- **Pregunta:** Qué pasa al incluir covariables? Interesante aplicación del teorema Frisch-Waugh-Lovell.

$$\rho = \frac{Cov(Y_i, \tilde{z}_i)}{Cov(s_i, \tilde{z}_i)} = \frac{\frac{Cov(Y_i, \tilde{z}_i)}{Var(\tilde{z}_i)}}{\frac{Cov(s_i, \tilde{z}_i)}{Var(\tilde{z}_i)}} \quad (8)$$

- También recuerda que la restricción de exclusión requiere que sea cierto que la única razón por la que el instrumento afecta al *outcome* es a través de la variable instrumentada. En modelos heterogéneos veremos que este supuesto tiene dos partes.

Variables Instrumentales

Por qué incluir controles?

- Ej: QOB puede estar correlacionado con la edad y a su vez afectar ingresos. Imagina que la regla de admisión a PK fue cambiando en el tiempo; entonces, necesitas agregar una función de la edad en la regresión.
- Controlar por covariantes es equivalente a residualizar.
- En este caso, X representa covariables exógenas.
- Los supuestos de 1a etapa y R.E ahora se deben cumplir para $\tilde{z}_i$ y no z_i .
- En la práctica, esto exige que Z debe "sobrevivir" a la adición de controles X .

Variables Instrumentales

En términos generales, el estimador IV se escribe:

$$\hat{\beta}_{IV} = (Z'D)^{-1}(Z'Y)$$

Cómo?

$$Y = D\beta + \epsilon$$

$$Z'y = Z'D\beta + Z'\epsilon$$

Luego, es fácil ver que: $\hat{\beta}_{IV} = (Z'D)^{-1}(Z'Y)$

Variables Instrumentales

En términos generales, el estimador IV se escribe:

$$\hat{\beta}_{IV} = (Z'D)^{-1}(Z'Y)$$

Z (matriz) puede incluir las covariables predeterminadas x_i que afectan y_i .

En el caso en que no hay covariables:

$$\hat{\beta}_{IV} = \frac{\text{Cov}(z_i, y_i)}{\text{Cov}(z_i, d_i)}$$

Es β_{IV} consistente?

$$\begin{aligned}\text{plim}(\hat{\beta}_{IV}) &= \text{plim}[(Z'D)^{-1}(Z'Y)] \\ &= \text{plim}[(Z'D)^{-1}(Z'D\beta + Z'\epsilon)] \\ &= \text{plim}[(Z'D)^{-1}(Z'D\beta)] + \text{plim}[(Z'D)^{-1}(Z'\epsilon)] \\ &= \beta\end{aligned}$$

Intuición IV

Si el instrumento es exógeno, por qué no entonces quedarnos con la forma reducida que denota el efecto de Z sobre Y ?

En muchos casos eso está bien. Pero más que la forma reducida, el instrumento z_i nos permite recuperar el efecto de d_i sobre y_i . Veamos el caso de un instrumento:

- $\hat{\beta}_{IV} = \frac{RF}{1E}$
- En otras palabras, la forma reducida re-escalada por la 1a etapa.
- Pero, por qué dividir por $1E$?
 - Escalar por la cantidad de observaciones que *cambiaron su comportamiento* debido al instrumento.

Intuición IV

Imaginemos un caso simple donde queremos estimar:

$$y_i = \alpha + \rho d_i + \epsilon_i$$

donde d_i es un tratamiento binario. Usando notación POF:

- $y = dy_1 + (1 - d)y_0$
- $y_0 = \alpha + \epsilon$
- $y_1 = y_0 + \rho$

Estimador ITT (*intention to treat*). Pero qué ocurre con *non-compliance*?

Una alternativa, es usar la asignación aleatoria como un instrumento –que aumenta la probabilidad de recibir el tratamiento.

Intuición IV

Imaginemos un caso simple donde queremos estimar:

$$y_i = \alpha + \rho d_i + \epsilon_i$$

Supuestos?

- Relevancia? $Cov(z_i, d_i) \neq 0$
- Exógeno? $Cov(z_i, \epsilon_i) = 0$

Cómo es que resuelve el problema de *non-compliance*?

- Supongamos que este problema ocurre sólo en el grupo asignado al tratamiento. (Ningún control recibe tratamiento)
- Primera etapa: $d_i = \gamma_1 z_i + u_i$; γ representa cómo cambia la probabilidad recibir el tratamiento por haber sido asignado al grupo tratado.
- Forma reducida: $y_i = \pi_1 z_i + v_i$

$\rho_{IV} = \frac{\pi_1}{\gamma_1}$, Qué pasaría si $\gamma = 1$? o $\gamma = 0.5$?

Múltiples instrumentos: 2SLS

En rigor, podrías definir un instrumento usando más de una variable. Qué hacer?

Def: Ecuación estructural: $Y_i = \alpha + \rho S_i + X_i' \theta + \epsilon_i$

Def: 1a etapa (relevancia): $S_i = \kappa + Z_i' \pi + X_i' \phi + \eta_i$

Sustituyendo la 1a etapa en la ecuación estructural:

$$\begin{aligned} Y_i &= \alpha + \rho(\kappa + Z_i' \pi + X_i' \phi + \eta_i) + X_i' \theta + \epsilon_i \\ &= \alpha + \rho(\kappa + Z_i' \pi + X_i' \phi) + X_i' \theta + (\epsilon_i + \rho \eta_i) \\ &= \alpha + \rho(\hat{S}_i) + X_i' \theta + \nu_i \end{aligned}$$

Donde $\hat{S}_i$ representa el valor predicho de una regresión de S_i en la primera etapa y ν_i es el nuevo residuo.

2SLS

IV es un caso especial del procedimiento "dos etapas de mínimos cuadrados" (2SLS). En qué consiste el 2SLS?

1. **Primera etapa:** Corremos una regresión del instrumento z_i sobre la variable a instrumentar d_i , incluyendo además todos los regresores que afectan nuestro resultado y_i .

$$d_i = \gamma_1 z_{1i} + \gamma_2 z_{2i} + x_i \gamma_3 + u_i$$

γ_1, γ_2 son escalares, x_i es un vector $1 \times (K + 1)$ (incluye la constante).

Antes de pasar a la segunda etapa, recoge los valores predichos de

$$\hat{d}_i = \gamma_1 z_{1i} + \gamma_2 z_{2i} + x_i \gamma_3.$$

Forma reducida y 2SLS

IV es un caso especial del procedimiento "dos etapas de mínimos cuadrados" (2SLS). En qué consiste el 2SLS?

2. **Segunda etapa:** Corremos la regresión que queríamos correr originalmente pero usando $\hat{d}_i$ en vez de d_i .

$$y_i = \beta_0 + \beta_1 \hat{d}_i + x_i \beta_2 + \epsilon_i$$

El coeficiente β_1 de esta última regresión es consistente

Fíjense que en ambas regresiones incluimos todas las variables explicativas predeterminadas x_i . Así, podemos escribir matricialmente nuestro estimador como:

$$\hat{\beta}_{2SLS} = (D'P_Z D)^{-1}(D'P_Z Y), \text{ donde } P_Z = Z'(Z'Z)^{-1}Z.$$

Angrist and Krueger (1991, QJE)

Table 4.1.1: 2SLS estimates of the economic returns to schooling

	OLS		2SLS					
	(1)	(2)	(3)	(4)	(5)	(6)	(7)	(8)
Years of education	0.075 (0.0004)	0.072 (0.0004)	0.103 (0.024)	0.112 (0.021)	0.106 (0.026)	0.108 (0.019)	0.089 (0.016)	0.061 (0.031)
<i>Covariates:</i>								
Age (in quarters)								✓
Age (in quarters) squared								✓
9 year of birth dummies		✓			✓	✓	✓	✓
50 state of birth dummies		✓			✓	✓	✓	✓
<i>Instruments:</i>								
			dummy for QOB=1	dummy for QOB=1 or QOB=2	dummy for QOB=1	full set of QOB dummies	full set of QOB dummies int. with year of birth dummies	full set of QOB dummies int. with year of birth dummies

Notes: The table reports OLS and 2SLS estimates of the returns to schooling using the the Angrist and Krueger (1991) 1980 Census sample. This sample includes native-born men, born 1930-1939, with positive earnings and non-allocated values for key variables. The sample size is 329,509. Robust standard errors are reported in parentheses.

Forma reducida y 2SLS

Veamos ahora qué entendemos por forma reducida.

- Regresión de la variable dependiente y_i sobre las variables exógenas (x_i y z_i).
- Mide el efecto causal del instrumento sobre el *outcome*.
- Tenemos entonces tres componentes:
 - 1a etapa: regresión de la variable endógena D sobre el instrumento Z (y todos los regresores exógenos, X)
 - 2a etapa: regresión Y sobre los valores predichos de la 1a etapa (y todos los regresores exógenos, X)
 - forma reducida: regresión Y sobre el instrumento Z (y todos los regresores exógenos, X)
- Muchas veces la forma reducida entrega la información valiosa. Qué variable mueve exógenamente nuestra variable de interés.
- Y no sufre de problemas como *instrumentos débiles*.

IV Reacción Causal

Instrumento $\rightarrow$ Variable de Interés $\rightarrow$ *Outcome*

El instrumento comienza la cadena de causalidad. IV nos permite descubrir el mecanismo por el cual es afectado el *outcome*.

Supuestos:

1. Primera etapa fuerte
2. Independencia: tan bueno como si fuera aleatoria
3. Instrumento afecta el *outcome* sólo a través de la variable de interés.

2SLS: Algunos errores clásicos

Veamos ahora qué entendemos por forma reducida.

1. Generalmente, no es buena idea correr 2SLS en forma manual, ya que encontrarás los errores estándares equivocados (exagerados).
2. Incluir distintas covariables en 1a y 2a etapa:
 - Puede introducir una correlación entre el error y aquellas covariables incluidas en la 2a.
 - "Si una covariable es buena para la 1a etapa, lo será para la segunda".

Estimador de Wald

Table: Wald estimates of the effects of family size on labor supply

Dependent variable	Mean	OLS	IV Estimates using			
			Twins		Sex Composition	
			1st St	Wald	1st St	Wald
	(1)	(2)	(3)	(4)	(5)	(6)
Employment	0.528	-0.167 (0.002)	0.625 (0.011)	-0.083 (0.017)	0.067 (0.002)	-0.135 (0.029)
Weeks worked	19.0	-8.05 (0.090)		-3.83 (0.760)		-6.23 (1.290)
Hours/Week	16.7	-6.02 (0.080)		-3.39 (0.640)		-5.54 (1.080)

Efectos homogéneos vs. Efectos heterogéneos

La primera generación de estudios IV asumía efectos homogéneos (constantes sobre la población). En este caso $ATE = TOT$. Pero si permitimos la existencia de efectos heterogéneos, qué representa el IV, ATE o TOT?

Angrist, Imbens and Rubin (1996, JASA): Ninguna de las anteriores.

- Con efectos heterogéneos, IV estima *LATE-for-compliers*
- Unidades para quienes el instrumento cambia la probabilidad de recibir el tratamiento.
- Relevante para definir tipo de validez de un análisis: externa v.s interna

Efectos homogéneos vs. Efectos heterogéneos

Imagine el siguiente caso: Ud evalúa el efecto de un remedio en la presión arterial.

- Diseña un RCT con grupos de control/tratamiento para asignar la entrega de una píldora
- Suponga que hay dos tipos de personas: aquellos que reaccionan a la píldora ($\beta < 0$) y aquellos a quienes no hace efecto ($\beta = 0$).
- Suponga, además, que la píldora la consumen finalmente quienes son sensibles a su efecto (de algún modo la consiguen).
- Qué pasa al comparar los grupos de control/tratamiento (ITT) en este RCT?
- $\beta_{IV} = LATE - for - compliers = 0$. Por qué?
- Piensa qué comparas al analizar grupo asignado a control v.s tratamiento si quienes son sensibles al tratamiento *se las arreglan* para recibirlo.
- Concluiría Ud. que β_{IV} es inconsistente?

Efectos homogéneos vs. Efectos heterogéneos

La primera generación de estudios IV asumía efectos homogéneos (constantes sobre la población). En este caso $ATE = TOT$. Pero si permitimos la existencia de efectos heterogéneos, qué representa el IV, ATE o TOT?

Esta pregunta también afecta la interpretación de nuestros coeficientes de un RCT. Por qué?

- *Imperfect compliance*: decisión de participar o no de un programa no está perfectamente *controlada* por el investigador.
- *Treatment heterogeneity*: efecto causal varía según la población bajo estudio

Imbens and Angrist (1994, JASA): Qué podemos (y no podemos) aprender de un RCT/exp.natural sin imponer restricciones adicionales en el comportamiento de los sujetos de estudio cuyo comportamiento no es directamente observable? (Nobel scientific background paper, 2021).


Efectos homogéneos vs. Efectos heterogéneos

Consideremos el siguiente esquema:

- Outcome: Y_i
- Tratamiento $D_i \in \{0, 1\}$
- Instrumento $Z_i \in \{0, 1\}$

Aplicación 1: Charter School


Gráfico n° 1. Brechas de puntajes SIMCE promedio por tipo de establecimiento. Año 2015



Fuente: Elaboración propia con base en datos de la Agencia de la Calidad de la Educación

Aplicación 1: Charter School

Gráfico n° 2. Distribución de establecimientos por puntaje promedio SIMCE, lectura segundo medio.



Aplicación 1: Charter School

Angrist et al., (2010, 2012): Decisión de asistir a un colegio *subvencionado* en EE.UU no es aleatoria. **Pregunta:** Podemos simplemente comparar el rendimiento de sus estudiantes para analizar la calidad del colegio?

Caso: Asignación aleatoria en Mass, EE.UU (KIPP schools).

- Clave fue que cupos eran limitados $\rightarrow$ oportunidad de aleatorizar y medir efecto causal entre quienes recibieron cupo y quienes no.
- Recuerda que al poder aleatorizar puedes asegurar balance entre grupo de control y tratamiento en todas las variables (observables y no-observables) y así poder comparar manzanas con manzanas.
- IV permite transformar variable $z = \text{ofrecer cupos} \rightarrow$ en efecto causal de *asistir al colegio KIPP*.
- Luego veremos que es el *efecto* de asistir entre quienes asistieron gracias al cupo ofrecido (*compliers*) –y no debido a otras razones.

Aplicación 1: Charter School

Al asignar en forma aleatoria podemos asegurarnos que los grupos de control y tratamiento son comparables. Una manera de chequear aquello es a través de una tabla de balance. **Pregunta:** Cómo seleccionar la muestra?

Muchas veces ofrece un resumen del problema/paper:

- Comparar atributos de ambos grupos (atributos observables de interés)
- Analizar el impacto de la *primera etapa*
- Analizar variables de interés *pre-tratamiento* (línea de base).
- Veamos la tabla que reportan Angrist et al. (2012):

Aplicación 1: Charter School

TABLE 1—DESCRIPTIVE STATISTICS AND COVARIATE BALANCE

	Means for 2005–2008			Balance regression
	Lynn 5th graders (1)	KIPP Lynn 5th graders (2)	KIPP Lynn applicants (3)	Winners vs. Losers (4)
Hispanic	0.418	0.565	0.538	–0.052 (0.053)
Black	0.173	0.235	0.254	0.027 (0.044)
Asian	0.108	0.021	0.022	0.026* (0.015)
Female	0.480	0.474	0.484	–0.010 (0.054)
Free/reduced price lunch	0.770	0.842	0.825	–0.030 (0.041)
Special education	0.185	0.189	0.197	–0.013 (0.042)
Limited English proficient	0.221	0.172	0.206	–0.075 (0.047)
Baseline (4th grade) math score	–0.307	–0.336	–0.390	0.097 (0.114)
Baseline (4th grade) ELA score	–0.356	–0.399	–0.438	0.054 (0.118)
Fourth grade applicant			0.768	0.056 (0.046)
<i>p</i> -value from joint <i>F</i> -test				0.671

Notes: Column (4) reports coefficients from regressions of the variable indicated in each row on an indicator variable equal to one if the student won an admissions lottery. Covariates include dummies for application year interacted with a contemporaneous sibling applicant dummy as well as application grade. The regression sample is restricted to randomized applicants with baseline demographics.

Aplicación: Charter School

Podemos, entonces, usar la asignación de cupo como instrumento para medir el efecto de los colegios KIPP en el rendimiento de los estudiantes.

Qué supuestos requerimos para ello?

- *Primera etapa*: El instrumento tiene un efecto causal sobre la variable de interés (aquella cuyo efecto intentamos medir).
- *Independencia*: El instrumento es exógeno (*as good as randomly assigned*).
- *Restricción de exclusión*: Hay un canal único por medio del cual el instrumento afecta al *outcome*. La diferencia en rendimiento entre ambos grupos es sólo atribuible a la diferencia en los cupos asignados a cada grupo.

Aplicación: Charter School

Efecto de asistir a un colegio KIPP.

$$0.48\sigma = \frac{RF}{1a \text{ Etapa}} = \frac{\bar{s}_{Ofrece} - \bar{s}_{No Ofrece}}{\bar{p}_{Ofrece} - \bar{p}_{No ofrece}} = \frac{-0.003 - -0.358}{0.787 - 0.046} \quad (9)$$

- Muestra total: Se ofreció cupo a 253 (T) individuos y se ofreció no-cupo a 118 (C)
- Este estimador también se conoce como LATE (*Local Average Treatment Effect*) y se puede expresar como una operación entre medias condicionales.

LATE

Local Average Treatment Effect:

$$\rho = \frac{\mathbb{E}[Y_i|Z_i = 1] - \mathbb{E}[Y_i|Z_i = 0]}{\mathbb{E}[D_i|Z_i = 1] - \mathbb{E}[D_i|Z_i = 0]} \quad (10)$$

- Pero qué significa el estimador LATE?
- Efecto para quienes el instrumento los hizo recibir el tratamiento.
- Pero en realidad, uno podría imaginar cuatro posibles tipos de individuos. Si hay efectos heterogéneos, a cuál de ellos representa el estimador LATE?

Table: Cuatro tipos de individuos *ex ante*

		Cupo No Ofrecido ($Z_i = 0$)	
		No Asiste a KIPP ($D_i = 0$)	Asiste a KIPP ($D_i = 1$)
Cupo Ofrecido ($Z_i = 1$)	No Asiste a KIPP ($D_i = 0$)	Never-Takers	Defiers
	Asiste a KIPP ($D_i = 1$)	Compliers	Always-takers

LATE: Intuición

Variación viene por quienes se ven afectados por el instrumento (*compliers*).

Aquellos que son insensibles al instrumento no aportan variación para estimar el efecto de interés. Si el efecto es distinto para estos grupos de individuos, entonces debemos interpretar con cuidado el coeficiente estimado ya que no es representativo de la población (ATE).

- Es entonces inconsistente? No, pero requiere interpretación adecuada sobre la población que representa.
- Ej: *compliers* en el caso del trimestre de nacimiento: aquellos que por nacer un determinado trimestre se sienten empujados a terminar un año de escolaridad –que en caso contrario no lo harían.
- Validez interna vs externa

LATE

Así, en rigor LATE estima lo siguiente:

$$\rho = \frac{\mathbb{E}[Y_i|Z_i = 1] - \mathbb{E}[Y_i|Z_i = 0]}{\mathbb{E}[D_i|Z_i = 1] - \mathbb{E}[D_i|Z_i = 0]} = \mathbb{E}[Y_{1i} - Y_{0i}|C_i = 1] \quad (11)$$

- La condición $C_i = 1$ también se puede escribir $D_1(1) > D_1(0)$
- Detalle en Paper-Nobel (2021, pp 27-31)
- Bajo efectos heterogéneos, instrumentos distintos pueden estimar *efectos* diferentes ya que representan grupos específicos de *compliers*.
- Validez interna vs externa

LATE: Teorema

Supón lo siguiente:

1. Independencia: $\{Y_i(D_{1i}, 1), Y_i(D_{0i}, 0), D_{1i}, D_{0i}\} \perp Z_i$
2. Exclusión: $Y_i(d, 0) = Y_i(d, 1) \equiv Y_{di}$ para $d = 0, 1$
3. Primera Etapa: $\mathbb{E}[D_{1i} - D_{0i}] \neq 0$
4. Monotonicidad: $D_{1i} - D_{0i} \geq 0 \forall i$ o viceversa

Entonces,

$$\rho_{LATE} = \frac{\mathbb{E}[Y_i|Z_i = 1] - \mathbb{E}[Y_i|Z_i = 0]}{\mathbb{E}[D_i|Z_i = 1] - \mathbb{E}[D_i|Z_i = 0]} = \mathbb{E}[Y_{1i} - Y_{0i} | D_{1i} > D_{0i}] \quad (12)$$

LATE: Teorema

Por qué LATE y TOT podrían ser distintos? Repasemos cada estimador:

- $ATE = \mathbb{E}[Y_{1i} - Y_{0i}]$
- $TOT = \mathbb{E}[Y_{1i} - Y_{0i} | D_i = 1]$
- $TONT = \mathbb{E}[Y_{1i} - Y_{0i} | D_i = 0]$
- $LATE = \mathbb{E}[Y_{1i} - Y_{0i} | D_{1i} > D_{0i}]$

Algunas cosas que se desprenden acá:

- Si previenes al grupo de control de recibir tratamiento: $LATE = TOT$ (*one-sided non-compliance*, Bloom, 1984)
- TOT es un promedio ponderado entre *always-takers* y *compliers*.
- TONT es un promedio ponderado entre *never-takers* y *compliers*.
- IV nos puede permitir identificar TOT en situaciones de cumplimiento no-aleatorio (*non-random compliance*). En este caso, nos interesa ITT (*intention to treat*).

Veamos un ejemplo donde los últimos *coinciden*: Violencia doméstica

Aplicación: Violencia Doméstica

Minneapolis Domestic Violence Experiment (MDVE) en 1980s.

Cuál es el efecto de arrestar a un acusado de VD/VIF?

Diseño MDVE consideraba tres tipos de tratamientos, para aquellos casos que cumplían las condiciones para ingresar al experimento:

- Arresto
- Separación temporal (8 horas)
- Consejo
- Casos de lesiones severas o amenazas de muerte fueron excluidos del análisis.

Outcome: Reincidencia en la misma dirección dentro de 6 meses de la asignación del experimento.

Aplicación: Violencia Doméstica

Qué podemos decir del experimento?

Flexibilidad en el protocolo:

- Policías se desviaban del protocolo muchas veces. Asignados a separación/consejo, decidían arrestar.
- Intensidad de desvío hace difícil creer que el tratamiento fue aleatorio.
- No arrestos → *Coddled*

Al analizar el protocolo asignado y los tratamiento realizados: experimento fallido?

Tratamiento asignado y realizado en experimento MDVE.

Table: Assigned and delivered treatments in the MDVE

Assigned Treatment	Delivered treatmet			Total
	Arrest	Coddled		
		Advise	Separate	
Arrest	98.9 (91)	0.0 (0)	1.1 (1)	29.3 (92)
Advise	17.6 (19)	77.8 (84)	4.6 (5)	34.4 (108)
Separate	22.8 (26)	4.4 (5)	72.8 (83)	36.3 (114)
Total	43.4 (136)	28.3 (89)	28.3 (89)	100.0 (314)

Aplicación: Violencia Doméstica

Casos asignados a *coddled* fueron *coddled* $177/222=0.797$ de las veces.

Pero casos no-asignados a *coddled* fueron no-*coddled* $1/92=0.011$ de las veces.

Experimento fallido?

IV, bajo algunos supuestos, puede recuperar algún parámetro de interés -a pesar de decisiones no aleatorias de los participantes que afectan individuos que finalmente reciben tratamiento (*non-random compliance*). Ej: TOT.

Clave: ITT (*intention to treat*). Veamos qué pasa:

- Primera etapa? $\mathbb{E}[D_i|Z_i = 1] - \mathbb{E}[D_i|Z_i = 0] = 0.797 - 0.011 = 0.786$
- $ITT = \mathbb{E}[Y_i|Z_i = 1] - \mathbb{E}[Y_i|Z_i = 0] = 0.211 - 0.097 = 0.114$
- Pero reincidencia general: 18 %

$$LATE = 0.114/0.786 = 0.145 = (TOT)$$

Cuál sería el sesgo si obviamos el cumplimiento no-aleatorio del experimento?

$$\mathbb{E}[Y_i|D_i = 1] - \mathbb{E}[Y_i|D_i = 0] = 0.216 - 0.129 = 0.087$$

Caracterizando *compliers*

Recuerda que cada variable instrumental identifica un efecto que es representativo de la subpoblación de *compliers* propia del instrumento utilizado.

Excepción importante: instrumentos que fuerzan *compliance* en un sentido (*one-sided compliance*).

Aunque 2SLS produce un promedio entre múltiples instrumentos, tal agregación no tiene sentido en un mundo donde permitimos efectos heterogéneos.

****** Hemos obviado toda la discusión sobre tests de sobreidentificación usando múltiples instrumentos, discusión que tiene sentido al analizar efectos homogéneos.

¿Qué podemos decir entonces sobre los *compliers*?

Caracterizando *compliers*

Pensemos algunas cosas razonables. Ej: Si subpoblaciones distintas de *compliers* entregan estimadores similares, hay una buena razón para creer que el efecto es homogéneo, no?

Tamaño del grupo *compliers*: Asumiendo monotonicidad,

$$\mathbb{P}[D_{1i} > D_{0i}] = \mathbb{E}[D_{1i} - D_{0i}] = \mathbb{E}[D_{1i}] - \mathbb{E}[D_{0i}] = \mathbb{E}[D_i | Z_1 = 1] - \mathbb{E}[D_i | Z_i = 0]$$

Proporción *compliers* del grupo tratamiento.

$$\begin{aligned}\mathbb{P}[D_{1i} > D_{0i} | D_{i=1}] &= \frac{\mathbb{P}[D_i = 1 | D_{1i} > D_{0i}] \mathbb{P}[D_{1i} > D_{0i}]}{\mathbb{P}[D_1 = 1]} \\ &= \frac{\mathbb{P}[z_i = 1] (\mathbb{E}[D_1 | z_i = 1] - \mathbb{E}[D_1 | z_i = 0])}{\mathbb{P}[D_i = 1]}\end{aligned}$$

No sabemos quién es *complier*, pero podemos describir al grupo? Clave es caracterizar aquellos que cumplen con $D_{1i} > D_{0i}$

Caracterizando *compliers*

Teorema Abadie-KAPPA:

Supóngase que los supuestos LATE se cumplen condicional en covariables X_i . Sea $g(Y_i, D_x, X_i)$ cualquier función de (Y_i, D_x, X_i) con valor esperado definido.

Tamaño del grupo *compliers*: Asumiendo monotonicidad,

Definamos:

$$\kappa_i = 1 - \frac{D_i(1 - z_i)}{1 - \mathbb{P}(z_i = 1|X_i)} - \frac{(1 - D_i)z_i}{\mathbb{P}(z_i = 1|X_i)}$$

Entonces:

$$\mathbb{E}[g(Y_i, D_i, X_i)|D_{1i} > D_{0i}] = \frac{\mathbb{E}[\kappa_i g(Y_i, D_i, X_i)]}{\mathbb{E}[\kappa_i]}$$

Algunos diseños populares

1. Loterías.
2. Efectos fijos de jueces. Sistema de turno en asignación de casos muchas veces ofrece un buen instrumento para medir impacto del sistema judicial en diversos outcomes.
3. Bartik: Medir el cambio en la demanda laboral de una región debido a cambios en la demanda nacional para productos de diferentes industrias.

Shifts v.s Shares

Algunos diseños populares: Loterías

Efecto de participar en la guerra de Vietnam usando el draft (Angrist, 1990).

Algunas preguntas importantes:

- Qué impacto sobre el mercado laboral tiene la experiencia de haber participado en una guerra?
- Cómo calcular la compensación que debiera recibir un veterano de guerra?

Algunos diseños populares: Loterías. (Angrist, 1990)

Algunas preguntas importantes?

- Por qué una regresión MCO podría producir un estimador sesgado?
 - El grupo de personas que participa es probable que sea una función de factores observables y no-observables que también inciden en los salarios.
- Relevancia del instrumento:
 - Angrist muestra que la probabilidad de participar en el ejército cae con el número de la lotería.
- Monotonicidad:
 - Requiere que alguien que habría participado en el ejército con un número k , lo habría hecho también con un número l ($l < k$). Es plausible? O sea, no *defiers*.
- Restricción de exclusión:
 - Requiere que ingresos potenciales (en presencia/ausencia de participar en el ejército) sean independientes del número de la lotería. (O, que el único canal por el cual la lotería afecta los ingresos sea el haber participado en el ejército.)

Judge Leniency o Efectos Fijos de Jueces

Originalmente propuesto por Kling (2006) para analizar el impacto de la extensión del encarcelamiento sobre indicadores del mercado laboral futuro (salario, empleo).

Algunas preguntas importantes?

- Por qué una regresión MCO podría producir un estimador sesgado?
 - Personas con penas efectivas más largas son esencialmente diferentes a quienes completan estadías más cortas en la cárcel. Aquello que los hace distintos en ese sentido puede afectar también sus ingresos potenciales o su vínculo con el mercado laboral.
- Definición del instrumento
 - Condicional en el día y ubicación del caso-tribunal, jueces son asignados aleatoriamente.
 - Importante, porque jueces suelen diferir en su nivel de severidad a la hora de asignar penas

Judge Leniency o Efectos Fijos de Jueces

Criminal Recidivism after Prison and Electronic Monitoring

Rafael Di Tella

Harvard University, Canadian Institute for Advanced Research, and National Bureau of Economic Research

Ernesto Schargrodsky

Universidad Torcuato Di Tella

We study criminal recidivism in Argentina by focusing on the rearrest rates of two groups: individuals released from prison and individuals released from electronic monitoring. Detainees are randomly assigned to judges, and ideological differences across judges translate into large differences in the allocation of electronic monitoring to an otherwise similar population. Using these peculiarities of the Argentine setting, we argue that there is a large, negative causal effect on criminal recidivism of treating individuals with electronic monitoring relative to prison.

Judge Leniency o Efectos Fijos de Jueces

Una aplicación: Di Tella and Schargrotsky (2013, JPE)

Cuál es la conveniencia de la pulsera/tobillera electrónica?

En teoría (*rational choice theory*), su efecto sobre la reincidencia criminal es incierto:

- Disuasión específica: señal que podría hacer menos costosa la comisión de un delito
- Encarcelamiento puede ser criminogénico, ergo la pulsera disminuir reincidencia. Además, puede ayudar en la reinserción laboral lo que puede disuadir criminales de cometer crímenes a futuro.

Di Tella and Schargrodsky (2013, JPE)

Por qué no podemos simplemente comparar condena en prisión v.s. pulsera/tobillera electrónica?

- Problema de selección
 - Un criterio para asignar el beneficio de la pulsera es el riesgo de reincidencia.
- Diferencial de riesgo en la población
 - Sólo observamos personas de bajo riesgo de reincidir.
 - No detectar un efecto negativo puede ser reflejo del bajo nivel de riesgo del grupo tratado.

Resultados: Fuerte efecto negativo en reincidencia.

Di Tella and Schargrodsky (2013, JPE)

Estrategia empírica:


$$R_i = a + bEM_i + \epsilon_i \quad (13)$$

- Controles: tipo de crimen, edad, edad al cuadrado, nacionalidad, número de estadías previas en la cárcel, e indicadores de distrito judicial y año.
- Instrumento: la "ideología" del juez — > Porcentaje de acusados enviados a EM, excluyendo al individuo en cuestión (*leave-out mean*)
- Dado que los jueces son asignados aleatoriamente, IV lo interpretan como el efecto causal de EM en reincidencia.

Judge Leniency o Efectos Fijos de Jueces

- Independencia del instrumento:
 - Podría estar afectado en casos donde el defendant conoce el juez de antemano y anticipa su leniency para solicitar cambio de juez. Uno puede chequear balance para lidiar con esto.
- Monotonicidad:
 - Jueces pueden diferir no sólo en *benevolencia*, pero también en sus preferencias.
 - Un juez puede ser *benevolente* si el acusado es de una raza/sexo particular.
 - Además, jueces pueden decidir multifactorialmente: en algunos casos ser *duros*, en otros *blandos*.
- Restricción de exclusión:
 - Si el acusado conoce al juez de antemano, puede anticipar el resultado y definir su umbral de decisión/cambiar de juez. En el fondo, cambiar su comportamiento en función del juez que observa.

Judge Leniency o Efectos Fijos de Jueces



Bartik o shift-share IV

Ejemplos aplicados en diversos temas:

- Inmigración: Altonji and Card (1991), Card (2001), Ajzenman et al (2021)
- Comercio: Autor, Dorn and Hanson (2013)
- Automatización: Acemoglu and Restrepo (2017)
- Elasticidad de la oferta laboral: Blanchard and Katz (1992), Bartik (1991)

Bartik o shift-share IV

Considera una regresión sobre un mercado laboral del tipo (Goldsmith-Pinkham et al., 2020 , AER):

$$y_i = \rho + \beta_0 x_i + \epsilon_i$$

- x_i crecimiento empleo entre dos períodos
- y_i crecimiento salarios entre dos períodos
- Queremos conocer: β_0 , elasticidad inversa oferta laboral

Bartik combina dos identidades:

1. $x_l = \sum_k z_{lk} g_{lk}$
2. $g_{lk} = g_k + \tilde{g}_{lk}$

z_{lk} share empleo en industria k en localidad l ; g_{lk} tasa crecimiento de industria k en localidad l ; $\tilde{g}_{lk}$ shock crecimiento idiosincrásico localidad-industria.

Instrumento de Bartik: $B_l = \sum_k z_{lk} g_k$

Bartik o shift-share IV

Considera una regresión sobre un mercado laboral del tipo (Cunningham, 2020):

$$y_{lt} = \alpha + \delta I_{lt} + \rho X_{lt} + \epsilon_{lt}$$

- y_{lt} salarios trabajadores nativos en localidad l , año t .
- I_{lt} migrantes que arriban a localidad l , año t .

Cómo estimar δ ?

- Bartik interactúa *shares* iniciales de regiones geográficas, previo al flujo migratorio con tasa nacional de crecimiento.
- Desviaciones del *crec.regional* se explican por desviaciones en la predicción de crecimiento del promedio nacional.
- Y desviaciones del promedio nacional en la predicción del crecimiento se deben a los *shares* porque el efecto del crecimiento nacional es el mismo para todas las regiones.

Bartik o shift-share IV

Considera una regresión sobre un mercado laboral del tipo (Cunningham, 2020):

$$y_{lt} = \alpha + \delta I_{lt} + \rho X_{lt} + \epsilon_{lt}$$

Define: $B_{lt} = \sum_k \underbrace{z_{lkt^0}}_{share} \underbrace{m_{kt}}_{shift}$, donde

- z_{lkt^0} es el *share* inicial de migrantes del país k en localidad l en t^0 .
(exogeneidad)
- m_{kt} es el cambio en inmigración del país k a nivel nacional (1a etapa)
- B_{lt} es la predicción de migrantes en destino l y corresponde a una suma ponderada del influjo nacional ponderada por la distribución inicial de los migrantes.

Intuición: *"measure of the supply-push component of recent immigrant inflows to a particular city that is arguably exogenous to local demand conditions"* (Card, 2001, JOLE)

Variables Instrumentales

Algunos temas pendientes"

- Propiedades asintóticas
- Sesgo de muestras finitas: IV/2SLS es consistente, pero no insesgado.
Importante para casos *many/weak instruments*. Ej: Angrist and Krueger QOB
x Year (LIML)
- Test de Hausman
- Test de sobre-identificación (más instrumentos que variables instrumentadas).
IV como un problema GMM.
- Abadie-Kappa formula para describir *compliers*.

Variables Instrumentales

Contenidos del módulo:

- Efectos homogéneos: IV, 2SLS
- Efectos heterogéneos: LATE
- Aplicaciones.

Para leer: Además de las referencias del programa: "*Answering Causal Questions Using Observational Data.*" The Committee for the Prize in Economic Sciences in Memory of Alfred Nobel.