



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE
DEPARTAMENTO DE INGENIERÍA INDUSTRIAL Y DE SISTEMAS
ICS2563 - ECONOMETRÍA APLICADA

Solución Guía POF

Fecha de publicación: 29/09/2025

2° semestre 2025 - Profesor: Patricio Domínguez

Ayudante: Pía Cereceda - piacereceda@uc.cl

Ejercicios

1. A continuación se presenta el código de lo pedido:

Código 1: Simulación pregunta 1

```
1 # Seteamos semilla:
2 set.seed(2005)
3
4 # Se determina el número de observaciones de la
5 # simulación (cada observación será un individuo).
6 Nobs = 1000
7
8 # Se crea indicador para las observaciones que serán tratadas,
9 # la mitad es tratada y la otra mitad serán controles.
10 t = as.integer(runif(Nobs) > 0.5)
11 data1 = data.frame(t) # Con bdd es más fácil la interacción
12
13 # Creamos nuestra variable de interés (el outcome),
14 # sin haberse realizado aún el tratamiento (imagine que es antes
15 # de que recibir el tratamiento).
16 data1$y = rnorm(Nobs, 6,3)
17
18 # Se revisa si existe alguna correlación entre el outcome y
19 # las observaciones designadas
20 # como tratamientos y controles:
21 summary(lm(y ~ t, data=data1))
22
23 # No es significativo el coeficiente (valor-p>>0.05).
```

```

24 # Como era de esperarse por tratarse de
25 # una asignación aleatoria del tratamiento.
26
27 # Se crea el efecto que tendrá el tratamiento (Notar
28 # que es de carácter determinístico)
29 treat = 3
30
31 # Se crea variable con el outcome de interés una vez que se hubiera
32 # realizado la intervención (note que los asignados reciben el
33 # tratamiento "treat" y que los controles tienen el outcome
34 # original).
35
36 data1$y_obs = ifelse(data1$t==0, data1$y, data1$y + treat)
37
38 # Creamos el contrafactual, este corresponde al outcome que tendrían
39 # los controles si se hubiesen tratado y al outcome que tendrían los
40 # tratados si no hubiesen recibido el tratamiento.
41
42 data1$y_contf = ifelse(data1$t==1, data1$y, data1$y + treat)

```

Con la información obtenida se responde lo siguiente:

- (a) Con las distintas variables asociadas a *outcomes* que tiene, genere una nueva que muestre el efecto del tratamiento para cada una de las observaciones independiente de si trate de un individuo tratado o control, utilice su contrafactual. Como se dará cuenta, debería obtener que el tratamiento es de 3 para cada individuo. Al crear la variable nueva, que resta las variables de resultado “y” observada con su respectivo contrafactual, se obtiene efectivamente que el efecto tratamiento es de 3, esto se encuentra tanto al usar los tratados como los controles.

Descriptive statistics by group														
group: 0														
	vars	n	mean	sd	median	trimmed	mad	min	max	range	skew	kurtosis	se	
x1	1	493	-3	0	-3	-3	0	-3	-3	0	0.18	4.33	0	

group: 1														
	vars	n	mean	sd	median	trimmed	mad	min	max	range	skew	kurtosis	se	
x1	1	507	3	0	3	3	0	3	3	0	-0.25	3.42	0	

Figure 1: Tabla resumen de los tratados y no tratados. group: 0 corresponde a los no tratados. group: 1 corresponde a los tratados.

- (b) Considerando solamente el *outcome* observado (*y_obs*), ejecute una expresión para el *Average Treatment Effect*, ¿es igual al valor del efecto del tratamiento? ¿Por qué?

Para la expresión del ATE basta con calcular la diferencia de promedios entre la variable de resultado para los tratados y los controles. Como se trata de una simulación es esperable que sus resultados difieran pero debieran ser cercanos a 3. Sin embargo, no necesariamente son iguales a 3 porque aún cuando la asignación al tratamiento es aleatoria, como el outcome, al ser una variable aleatoria a la que le sumamos el tratamiento, la diferencia entre el efecto medido y el efecto real no son exactamente cero sino que no son estadísticamente distintos de cero. Para este caso, en el que la semilla está seteada, el promedio corresponde a 2.902549.

- (c) Repita lo anterior pero solamente para el contrafactual, ¿Qué ocurre con el ATE? ¿es igual al valor del efecto del tratamiento? ¿por qué?

Usando el contrafactual el coeficiente no es exactamente el mismo que el del tratamiento ni que del ATE mostrado en el inciso anterior, sino que tiene la misma diferencia entre el ATE y el tratamiento. Al usar el contrafactual se toma el outcome que habrían tenido tratados y controles de no haber sido tratados ni controles, respectivamente. El valor pedido de acuerdo a la semilla dada corresponde a -3.097451 .

- (d) Ahora corra una regresión entre el outcome observado y la asignación del tratamiento, ¿qué valor tiene el coeficiente que acompaña a la variable del tratamiento? ¿A cuál de los dos calculados anteriormente es igual? ¿Es igual al ATE? Explique su respuesta.

El coeficiente tiene el mismo valor que el mostrado en el inciso 2. Corresponde al ATE y al mirar el p-value se ve que tiene significancia estadística al 10%, 5% y 1%.

```

Residuals:
    Min       1Q   Median       3Q      Max
-8.9285 -2.0297 -0.0485  1.9665  9.3933

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)    5.9402     0.1327   44.77  <2e-16 ***
t               2.9025     0.1863   15.58  <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.946 on 998 degrees of freedom
Multiple R-squared:  0.1956,    Adjusted R-squared:  0.1948
F-statistic: 242.7 on 1 and 998 DF,  p-value: < 2.2e-16

```

Figure 2: Tabla resumen de la regresión

- (e) Considerando lo anterior, ¿por qué aún cuando el efecto tratamiento es determinístico la estimación del ATE entrega un coeficiente distinto del efecto? En otras palabras, ¿de dónde viene la variación en la estimación?

Como se trata de una asignación aleatoria no hay sesgo, entonces tanto la diferencia de promedios como una regresión lineal por OLS entrega el ATE.

2. A continuación se presenta el código de lo pedido:

Código 2: Simulación pregunta 2

```
1 # Este será el vector que contendrá los datos del coeficiente:
2 coefs = rep(0, Nobs)
3 for (i in 1:Nobs){
4   # Para 1000 observaciones, asigne aleatoriamente cuales seran
      tratadas y cuales
5   # controles manteniendo la proporcion de 0,5 entre tratados y
      controles.
6   t = as.integer(runif(Nobs) > 0.5)
7
8   # Creamos una base de datos:
9   data2 = data.frame(t)
10
11  # Cree un efecto tratamiento deterministico de 5.
12  treat = 5
13
14  # Cree una variable outcome con distribucion normal de media 6 y
      desviacion
15  # estandar de 6 sin efecto tratamiento aun.
16  data2$y = rnorm(Nobs, 6, 6)
17
18  # Genere una variable de outcome observado para tratados y
      controles una vez que
19  # se realice el tratamiento.
20  data2$y_obs = ifelse(data2$t==0, data2$y, data2$y + treat)
21
22  # Corra una regresion entre el outcome observado y la asignación
      al tratamiento
23  reg = lm(y_obs ~ t, data=data2)
24
25  # Guarde en un vector el coeficiente que acompaña a la variable de
      tratamiento (el
26  # objetivo es que este vector incluya los coeficientes de las 1000
      estimaciones,
27  #luego cada observación del vector es el coeficiente de cada
      estimación).
28  coefs[i] = reg$coefficients[[2]]
29 }
30
```

```
31 # Graficamos el histograma:
32 hist(coefs, breaks=30)
```

El histograma pedido corresponde a:




Figure 3: Histograma de los coeficientes estimados

- (a) ¿Dónde se concentra la mayor cantidad de coeficientes estimados? ¿Por qué?
 La mayor cantidad de coeficientes estimados se concentra alrededor de 5. Tiene sentido por el hecho de que el tratamiento se define en 5 de manera determinística.
- (b) ¿Por qué razón cree usted que el gráfico adquiere esa forma?
 El gráfico adquiere dicha forma porque al repetir una gran cantidad de veces, de acuerdo al teorema del límite central, la estimación tendrá una distribución normal alrededor del valor real del coeficiente. Más aún, es sabido que una regresión lineal tiene una distribución normal de la forma $\mathcal{N}_n(\mathbf{X}\beta, \sigma^2\mathbf{I})$, es decir, una distribución normal n-dimensional.
- (c) ¿Cuál es la media de los coeficientes estimados? ¿Y la mediana? ¿Se parecen?

Si sus cálculos fueron bien hechos, tanto la media como la mediana de los coeficientes estimados debieran ser cercanas a 5. Para el caso de esta semilla, se tiene que la media corresponde a 4.986, y la mediana corresponde a 4.984.

Para la segunda parte, se utilizó este código:

Código 3: Simulación con tratamiento aleatorio en pregunta 2

```
1  coefs = rep(0, Nobs)
2  for (i in 1:Nobs){
3    # Para 1000 observaciones, asigne aleatoriamente cuales seran
      tratadas y cuales
4    # controles manteniendo la proporcion de 0,5 entre tratados y
      controles.
5    t = as.integer(runif(Nobs) > 0.5)
6
7    # Creamos una base de datos:
8    data2 = data.frame(t)
9
10   # Cree un efecto tratamiento N(5,1).
11   treat = rnorm(Nobs, 5, 1)
12
13   # Cree una variable outcome con distribucion normal de media 6 y
      desviacion
14   # estandar de 6 sin efecto tratamiento aun.
15   data2$y = rnorm(Nobs, 6, 6)
16
17   # Genere una variable de outcome observado para tratados y
      controles una vez que
18   # se realice el tratamiento.
19   data2$y_obs = ifelse(data2$t==0, data2$y, data2$y + treat)
20
21   # Corra una regresion entre el outcome observado y la asignacion
      al tratamiento
22   reg = lm(y_obs ~ t, data=data2)
23
24   # Guarde en un vector el coeficiente que acompaña a la variable
      de tratamiento (el
25   # objetivo es que este vector incluya los coeficientes de las 1000
      estimaciones,
26   # luego cada observacion del vector es el coeficiente de cada
      estimacion).
27   coefs[i] = reg$coefficients[[2]]
28 }
```

```
29
30 # Graficamos el histograma:
31 hist(coefs, breaks=30)
```

El histograma obtenido es el siguiente:




Figure 4: Histograma de los coeficientes estimados con tratamiento no determinístico

- (a) ¿Dónde se concentra la mayor cantidad de coeficientes estimados? ¿Por qué?

Al igual que antes, los coeficientes se concentran alrededor del 5, porque a un cuando el efecto es una variable aleatoria con distribución normal de media 5 y desviación estándar 1, al realizar las estimaciones una gran cantidad de veces el coeficiente tiende a acercarse a su valor real.

- (b) ¿Cuál es la media de los coeficientes estimados? ¿Y la mediana? ¿Se parecen?

Nuevamente media y mediana son similares y cercanas a 5. Para esta semilla la media corresponde a 5.006 y la mediana a 4.988

- (c) Compare su gráfico con el gráfico obtenido con el procedimiento anterior y explique las diferencias/similitudes.

En esta oportunidad el gráfico quedó más centrado en 5 que cuando el tratamiento es determinístico.

3. El código utilizado para esta pregunta es el siguiente:

Código 4: Simulación pregunta 3

```
1 # La siguiente variable contiene los errores estándar según la
  proporción:
2 coefs_err = rep(0, Nobs)
3 for (i in 1:Nobs){
4   # Para Nobs observaciones, se define un grupo de tratados/
     controles según
5   # el parámetro i/Nobs (que cambia en cada iteración)
6   k = i/Nobs
7   t = as.integer(runif(Nobs) > k)
8
9   # Creamos una base de datos:
10  data3 = data.frame(t)
11
12  # Cree un efecto tratamiento determinístico:
13  treat = 5
14
15  # Cree una variable outcome con distribución normal de media 6 y
     desviación
16  # estándar de 6 sin efecto tratamiento aun.
17  data3$y = rnorm(Nobs, 6, 6)
18
19  # Genere una variable de outcome observado para tratados y
     controles una vez que
20  # se realice el tratamiento.
21  data3$y_obs = ifelse(data3$t==0, data3$y, data3$y + treat)
22
23  # Corra una regresión entre el outcome observado y la asignación
     al tratamiento
24  reg = lm(data3$y_obs ~ data3$t)
25
26  if (is.na(reg$coefficients[[2]])){
27    break
28  }
29
30  # Se guardan los errores estándar en el vector:
31  coefs_err[i] = summary(reg)$coefficients[[2,2]]
32 }
```

```
33
34 # Graficamos el comportamiento de los errores:
35 plot(1:length(coefs_err), coefs_err, ylab="se", xlab="order")
```

De esta manera, el gráfico obtenido es el siguiente:




Figure 5: Error estándar en cambios de proporción para tratados/controles

Al graficar los errores estándar con una diferente proporción de tratados y controles se obtiene un gráfico en forma de “u”, que parece tener un mínimo cuando la proporción de tratados y controles es 0.5.

Considerando que el eje x corresponde a i , luego i/Nobs corresponde al valor de la proporción utilizada. Se puede ver que el error mínimo sucede cuando $\text{order}=i \in [400, 600]$, luego $[0.4, 0.6]$ corresponde a una buena proporción. Es importante destacar que en $[0.4, 0.6]$ se encuentra la proporción de 0.5, es decir, una asignación equitativa (no necesariamente aleatoria) minimiza el error estándar.

4. El código utilizado para esta pregunta es el siguiente:

Código 5: Simulación pregunta 4

```
1 # Las siguientes variables contienen los coeficientes de las
  regresiones calculadas:
2 coefs_y = rep(0, Nobs)
3 coefs_y_x = rep(0, Nobs)
4 coefs_y_z = rep(0, Nobs)
5 for (i in 1:Nobs){
6   # Para 1000 observaciones y un efecto tratamiento aleatorio que
     distribuye Normal
7   # (5,1), defina 3 regresores "x" que distribuyan Normal con alguna
     media y desviacion
8   # estandar a su eleccion, distintas entre si. Defina 3 regresores
     "z" de la misma
9   # forma que los "x" pero con distinta media y varianza.
10  treat = rnorm(Nobs, 5, 1) # efecto del tratamiento aleatorio.
11  data4 = data.frame(treat)
12  data4$x1 = rnorm(Nobs, 10, 3)
13  data4$x2 = rnorm(Nobs, 2, 1)
14  data4$x3 = rnorm(Nobs, 7, 3)
15
16  data4$z1 = rnorm(Nobs, 12, 5)
17  data4$z2 = rnorm(Nobs, 6, 2)
18  data4$z3 = rnorm(Nobs, 1, 0)
19
20  # Defina su outcome "y" previa al tratamiento como la suma de una
     Normal
21  # estandar y los tres regresores "x".
22  data4$y = rnorm(Nobs) + data4$x1 + data4$x2 + data4$x3
23
24  # Defina con una nueva variable a los tratados y controles de
     manera que
25  #aproximadamente la mitad sean tratados y la otra mitad controles.
26  data4$t = as.integer(runif(Nobs) > 0.5)
27
28  # Aplique el tratamiento a las observaciones correspondientes
     definiendo una nueva
29  # variable "y" observada.
30  data4$y_obs = ifelse(data4$t==0, data4$y, data4$y + treat)
31
32  # Haga tres regresiones distintas: "y" observado con la variable
     tratamiento, "y"
33  # observado con la variable tratamiento y los regresores "x", y
     por ultimo el outcome
```

```
34 # observado con los regresores "z". Guarde el coeficiente estimado
    de cada una en
35 # vectores distintos.
36 reg_y = lm(y_obs ~ t, data=data4)
37 reg_y_x = lm(y_obs ~ t + x1 + x2 + x3, data=data4)
38 reg_y_z = lm(y_obs ~ t + z1 + z2 + z3, data=data4)
39
40 coefs_y[i] = reg_y$coefficients[[2]]
41 coefs_y_x[i] = reg_y_x$coefficients[[2]]
42 coefs_y_z[i] = reg_y_z$coefficients[[2]]
43 }
```

Considerando lo visto en clases, la más precisa debiera ser la que incluye los regresores “x” por ser variables relevantes. La menos precisa debiera ser la que incluye los regresores “z” por ser variables irrelevantes que se incluyen.

El histograma pedido se muestra a continuación:




Figure 6: Histogramas

De esta manera, se puede notar que la regresión más precisa corresponde a la regresión de "y" sobre "x", en cambio, la menos precisa corresponde a la de regresores irrelevantes. Al pasar de regresión simple a múltiple se concentran más los valores en el valor esperado, además la desviación estándar disminuye. Al incorporar regresores irrelevantes la desviación aumenta respecto al modelo `reg_y_x` (el correcto). En caso que las regresiones "x" y "z" tengan la misma media y varianza, pero distintas observaciones entre sí, entonces deberían ser bien estimadas ambas regresiones de igual manera, ya que el modelo de regresión lineal corresponde a una predicción de la población en base a una muestra, y podemos pensar "x" e "y" como dos muestras de una población que se comporta como si fuese Normal (relacionado con un muestreo aleatorio y la eficiencia del estimador bajo dos muestras puntuales).

5. A continuación se presenta el código utilizado:

Código 6: Simulación pregunta 5

```

1 data5 = data.frame(data1) # Copia de data1
2
3 data5$old = as.integer(runif(Nobs) < 0.3)
4
5 # El tratamiento no tiene efecto en el grupo old:
6 data5$t_nuevo = ifelse(data5$old==0, data1$t, 0)
7 data5$y_obs_nuevo = ifelse(data5$old==1 & data5$t==1, data5$y_contf,
                             data5$y_obs)
8
9 # Calculamos el ATE según la regresión:
10 reg5 = lm(y_obs_nuevo ~ t, data=data5)
11 summary(reg5)
12
13 # Comparamos coeficientes con la 1:
14 reg1$coefficients[[2]]
15 reg5$coefficients[[2]]
16
17 # Con la nueva regresión se tiene que el coeficiente disminuye. Esto
    sucede porque
18 # ahora existe selección, es decir,
19 #  $E[y_i | T_i=1] = E[y_{\{1i\}} | T_i=1] - E[y_{\{0i\}} | T_i=1] + E[y_{\{0i\}} | T_i=1] -$ 
     $E[y_{\{1i\}} | T_i=0]$ 
20 # donde  $E[y_{\{0i\}} | T_i=1] - E[y_{\{1i\}} | T_i=0]$  no puede ser
    despreciado,
21 # luego el sesgo de selección debería ser:
22 #  $E[y_{\{0i\}} | T_i=1] - E[y_{\{0i\}} | T_i=0] =$ 
23  $mean(data5$y_obs_nuevo[data5$t == 1 \& data5$t_nuevo==0]) -$ 

```

```

25     mean(data5$y_obs_nuevo[data5$t == 0 & data5$t_nuevo==0])
26
27 # Incluyendo old en la regresión:
28 reg5_old = lm(y_obs_nuevo ~ t + old, data=data5)
29 summary(reg5_old)
30 # Sigue siendo sesgado. Para que no sea sesgado se debe aadir la
    regla de selección,
31 # es decir, que sea old y este tratado:
32
33 reg5_old_t = lm(y_obs_nuevo ~ t + old + t_nuevo, data=data5)
34 summary(reg5_old_t)

```

Al no considerar la heterogeneidad del impacto, la estimación resulta sesgada. La dirección del sesgo tiene que ver con la covarianza entre el tratamiento y el indicador de quienes reciben un impacto de manera heterogénea. La tabla que resume los resultados de la estimación es la siguiente:

```

Residuals:
    Min       1Q   Median       3Q      Max
-9.1428 -2.1426 -0.0073  1.9825  9.3933

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)    5.9402     0.1412  42.08  <2e-16 ***
t               2.0091     0.1983  10.13  <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 3.135 on 998 degrees of freedom
Multiple R-squared:  0.09329,    Adjusted R-squared:  0.09238
F-statistic: 102.7 on 1 and 998 DF,  p-value: < 2.2e-16

```

Figure 7: Tabla resumen de regresión sesgada inicial

Si se incorpora el indicador “old” aún la estimación del tratamiento está sesgada, pues no se ha modelado la heterogeneidad de manera correcta, sigue habiendo una variable omitida relevante. Para modelar la heterogeneidad correctamente se debe incluir como regresor la interacción entre el tratamiento y el indicador “old”. La estimación de este inciso sin incorporar la heterogeneidad es:

```

Residuals:
    Min       1Q   Median       3Q      Max
-9.0974 -2.0475 -0.0134  2.0597  8.8713

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)    6.4621     0.1555  41.562 < 2e-16 ***
t               1.9327     0.1937   9.980 < 2e-16 ***
old            -1.4960     0.2070  -7.226 9.89e-13 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 3.057 on 997 degrees of freedom
Multiple R-squared:  0.1384,    Adjusted R-squared:  0.1367
F-statistic: 80.08 on 2 and 997 DF,  p-value: < 2.2e-16

```

Figure 8: Tabla resumen de regresión sesgada sin heterogeneidad

La estimación con la heterogeneidad bien modelada es:

```

Residuals:
    Min       1Q   Median       3Q      Max
-8.9448 -2.0130 -0.0494  1.9789  9.4288

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  5.956486    0.160375  37.141 < 2e-16 ***
t            -0.002391    0.330296  -0.007  0.994
old          -0.051795    0.286019  -0.181  0.856
t_nuevo       2.860183    0.400201   7.147 1.71e-12 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.948 on 996 degrees of freedom
Multiple R-squared:  0.1779,    Adjusted R-squared:  0.1755
F-statistic: 71.86 on 3 and 996 DF,  p-value: < 2.2e-16

```

Figure 9: Tabla resumen de regresión bien estimada

Se puede ver que el efecto estimado es mucho más cercano al efecto real del impacto y que además el coeficiente que acompaña a la variable de interacción entre el impacto y el indicador “old” es significativa al 5%, mientras que “old” por sí sola no lo es.

Para el loop pedido el código es el siguiente:

Código 7: Loop pregunta 5

```

1  coefs = rep(0, 100)
2  for (i in 1:100){

```

```
3   # Para Nobs observaciones, se define un grupo de tratados/
    controles
4   # según el parámetro i/100 (que cambia en cada iteración)
5   k = i/100
6
7   data5 = data.frame(data1) # Copia de data1
8
9   data5$old = as.integer(runif(Nobs) < k)
10
11  # El tratamiento no tiene efecto en el grupo old:
12  data5$t_nuevo = ifelse(data5$old==0, data1$t, 0)
13  data5$y_obs_nuevo = ifelse(data5$old==1 & data5$t==1,
    data5$y_contf, data5$y_obs)
14
15  # Calculamos el ATE según la regresión:
16  reg5 = lm(y_obs_nuevo ~ t, data=data5)
17
18  if (is.na(reg5$coefficients[[2]])){
19    break
20  }
21
22  # Se guardan los errores estándar en el vector:
23  coefs[i] = reg5$coefficients[[2]]
24 }
25
26 # Se grafica el efecto del coeficiente según el porcentaje de old:
27 plot(1:100, rev(coefs), xlab="%", ylab="Coeficiente")
```

A medida que va disminuyendo la proporción de ancianos, el coeficiente estimado de una regresión que modela mal la heterogeneidad va en aumento desde cero hasta alcanzar su verdadero valor, cuando el 100% de la población no es vieja. El gráfico de la evolución del coeficiente a medida que disminuye la proporción de ancianos se ve de la siguiente forma:




Figure 10: Evolución del coeficiente a medida que disminuye la proporción de ancianos

6. En econometría generalmente se dice que dentro del *Potential Outcomes Framework*, los efectos solo pueden entenderse empíricamente en relación con las variables causales que han sido manipuladas de alguna manera. A esta afirmación se le conoce como *No causation without manipulation*. Responda a partir de ella y sus conocimientos en econometría y estadística las siguientes preguntas:

(a) Explique por qué esta noción de “manipulación” es tan importante.

La noción de “manipulación” es importante porque la posibilidad de exponerse a más de una condición (por ejemplo, tratamiento vs control) hace posible estimar un supuesto **efecto causal**. Según la notación de Gerber Green, la existencia de un resultado potencial (o *potential outcome*) $Y_i(1)$ y $Y_i(0)$ para alguna unidad i depende críticamente de si cada unidad i tuvo alguna probabilidad mayor (o igual) que 0 o menor (o igual) que 1 de estar en cualquiera de esas dos condiciones. Esta posibilidad de exposición hace a los resultados potenciales viables, y como tal, la manipulación “permitiría” en cierta medida la exposición. Estadísticamente, el hecho que cada unidad i pueda ser expuesta a tratamiento o control permite que sea posible calcular estimaciones del efecto del tratamiento T_i , usando $\mathbb{E}[Y_i(1) - Y_i(0)]$.

- (b) ¿Cuáles son los efectos de esto para la investigación de atributos relativamente estables de personas tales como fenotipo (color de piel) o género?

Los atributos estables de unidades experimentales que no pueden ser manipulados **no pueden ser analizados como causas o con el propósito de encontrar efectos causales bajo el marco de resultados potenciales estudiado hasta ahora**. Para cualquier unidad i , el atributo no podría tomar otro valor que el efectivamente observado, por lo tanto los *potential outcomes* bajo condiciones contrafactuales son poco plausibles de utilizar en estos tipos de atributos. (Para más detalles, recomiendo ver Statistics and Causal Inference, Holland, 1986).

7. Conteste las siguientes preguntas:

- (a) Demuestre formalmente que $ATE = p \cdot ATT + (1 - p) \cdot ATU$, donde p es la probabilidad de ser tratado.

Tomando ATE y dado que las esperanzas se pueden descomponer como la suma de las esperanzas condicionales, entonces: $ATE = E(Y_iT - Y_iNT) = E(Y_iT - Y_iNT|T = 1) \cdot Pr(T = 1) + E(Y_iT - Y_iNT|T = 0) \cdot Pr(T = 0)$, lo cual es idéntico a lo que se pide demostrar.

- (b) Imagine que se realizó un experimento en un país con bajo PIB per cápita, para ver como la nutrición afecta el desempeño escolar. Para esto, en un colegio se repartieron aleatoriamente (y de manera gratuita) vitaminas de sabores a los alumnos, las cuales también se venden en una farmacia cercana. Los investigadores tomaron como control un colegio que está frente al colegio de tratamiento, teniendo ambos *outcomes* similares previo al tratamiento. Mencione qué problema metodológico podría estar ocurriendo. Demuestre formalmente que aún cuando el tratamiento es aleatorio y los tratados y controles estaban balanceados previo al tratamiento, es posible que no se pueda estimar el ATE.

Aún cuando se hace un tratamiento aleatorio, es posible que los controles se vean afectados indirectamente por el tratamiento. Es por esto que se podría estar violando el supuesto de SUTVA, con lo cual $E(YNT)$ es distinto a $E(YNT(datos))$.

- (c) Usted quiere explicar las notas de sus compañeros en el primer curso de matemática de la carrera. Sea la variable dependiente 1 si el alumno aprueba el curso y 0 si lo reprueba. Usted tiene datos sobre los colegios de origen de cada alumno. En particular, tiene una medición de la mensualidad que se tiene que pagar para asistir a cada colegio, el tamaño del colegio y la fracción de los alumnos del colegio que provienen de los 2 primeros deciles de ingreso del país.

Se muestra el siguiente gráfico:

Variables independientes	Modelo 1	Modelo 2
Log(mensualidad)	11,30 (3,30)	7.75 (3,04)
Log(tamaño colegio)	0,022 (0,615)	-1,26 (0,58)
Log(fracción I, II)	-	-0,324 (0,036)
Intercepto	-69,24 (26,72)	-23,14 (24,99)
Observaciones	428	428
R^2	0,0297	0,1893

- i. Discute la relación anticipada entre cada variable y la probabilidad de aprobar el primer curso de matemática.

Proceder de un colegio donde la mensualidad es mayor debería estar positivamente correlacionado con una mayor probabilidad de aprobar el curso. Provenir de un colegio con más alumnos podría perjudicar a los alumnos si tienen más compañeros por curso pero si indica algo de popularidad del colegio, podría estar positivamente correlacionado. Finalmente, venir de un colegio donde hay una mayor fracción de alumnos vulnerables esta negativamente correlacionado con la probabilidad de aprobar si hay diferencias en la preparación que obtienen estos alumnos.

- ii. Alguien argumenta que no se debería interpretar el coeficiente de “log(matricula)” como el efecto causal de entregar a niños de la secundaria un *voucher* para asistir a un colegio más caro. En particular, argumenta que el hecho que pagar más mensualidad cambia la composición socio-económica del colegio. Explique si está de acuerdo con esta afirmación usando los resultados del modelo.

Es difícil argumentar que el efecto es causal porque corresponde a la suma del efecto causal ATT y el sesgo de selección. Es fácil de pensar que hay diferencias en características entre alumnos que egresan de colegios con mensualidad mayor y menor y entonces, no se puede interpretar el coeficiente como causal.

8. Supongamos que estamos interesados en determinar el efecto causal de un nuevo medicamento (tratamiento) en la reducción de la presión arterial en pacientes con hipertensión. Tenemos un grupo de pacientes y queremos estimar el efecto causal del medicamento en la presión arterial sistólica (PAS) en milímetros de mercurio (mmHg). Hacemos mediciones de la presión arterial en dos momentos diferentes: antes de administrar el medicamento (PAS(0)) y después de la administración del medicamento (PAS(1)). Cada paciente tiene dos posibles resultados de presión arterial, uno si no recibe el medicamento (Y(0)) y otro si recibe el medicamento (Y(1)).

A continuación se muestran los resultados observados para tres pacientes seleccionados al azar:

Paciente	PAS(0)	PAS(1)
1	150 mmHg	140 mmHg
2	160 mmHg	155 mmHg
3	145 mmHg	142 mmHg

Calcula el efecto causal promedio del medicamento en la presión arterial sistólica (PAS) y explica tus resultados.

Para calcular el efecto causal promedio del medicamento en la presión arterial sistólica (PAS), primero calcularemos la diferencia en los resultados potenciales para cada paciente y luego promediaremos estos efectos.

- Paciente 1: $Y(1) - Y(0) = 140 \text{ mmHg} - 150 \text{ mmHg} = -10 \text{ mmHg}$
- Paciente 2: $Y(1) - Y(0) = 155 \text{ mmHg} - 160 \text{ mmHg} = -5 \text{ mmHg}$
- Paciente 3: $Y(1) - Y(0) = 142 \text{ mmHg} - 145 \text{ mmHg} = -3 \text{ mmHg}$

Ahora, para calcular el efecto causal promedio en el grupo de pacientes, promediamos estos efectos:

Efecto causal promedio = (Efecto causal Paciente 1 + Efecto causal Paciente 2 + Efecto causal Paciente 3) / N

Donde N es el número de pacientes en el estudio:

Efecto causal promedio = $(-10 \text{ mmHg} - 5 \text{ mmHg} - 3 \text{ mmHg}) / 3 = -6 \text{ mmHg}$

Entonces, según el Potencial Outcome Framework, el efecto causal promedio del medicamento en la presión arterial sistólica (PAS) es una reducción de 6 mmHg. Esto significa que, en promedio, el medicamento reduce la presión arterial sistólica en 6 mmHg en pacientes con hipertensión.

9. A continuación se presenta el código utilizado:

Código 8: Simulación Pregunta 9

```
1 ## Pregunta 9 ##
2 # Seteamos la semilla
3 set.seed(123)
4
5 # Número de observaciones
6 Nobs <- 1000
```

```
7
8 # Generamos las variables explicativas
9 X1 <- rnorm(Nobs, 0, 1) # Nivel de educación
10 X2 <- rnorm(Nobs, 0, 1) # Ingreso
11 Z <- rnorm(Nobs, 0, 1) # Motivación
12
13 # Asignamos el tratamiento según la probabilidad
14 T <- as.integer(runif(Nobs) < pnorm(0.5 * X1 + 0.5 * X2 + 0.5 * Z))
15
16 # Generamos la variable de ruido
17 epsilon <- rnorm(Nobs, 0, 1)
18
19 # Generamos el outcome con efectos heterogéneos del tratamiento
20 Y <- 3 + (1.5 + 0.5 * Z) * T + 1.5 * X1 + 0.7 * X2 + 0.5 * Z +
    epsilon
21
22 # 1. Regresión para estimar el ATE omitiendo Z
23 modelo_ols <- lm(Y ~ T + X1 + X2)
24 summary(modelo_ols)
25
26 # El ATE estimado sin Z es 2.0959
27 # Los coeficientes de X1 y X2 son significativos con p-values
    menores a 2e-16
28 # R^2 ajustado = 0.7697, lo que indica un buen ajuste del modelo
29
30 # ATE verdadero (el valor del coeficiente que acompaa a T en la
    simulación)
31 verdadero_ATE <- 1.5 # Efecto promedio del tratamiento
32 estimado_ATE <- coef(modelo_ols)["T"]
33
34 # La diferencia entre el ATE estimado y el ATE verdadero es de
    aproximadamente 0.5959
35 sesgo <- estimado_ATE - verdadero_ATE
36 cat("Sesgo por omitir Z:", sesgo, "\n")
37 # El sesgo es de 0.5959 debido a la omisión de la variable Z, lo que
    causa un sobreestimado del efecto de T.
38
39 # 3. Modelo con interacción entre T y X1 (para capturar efectos
    heterogéneos)
40 modelo_interaccion <- lm(Y ~ T * X1 + X2)
41 summary(modelo_interaccion)
42
43 # El coeficiente de la interacción T:X1 es -0.1682 con p-value
    significativo de 0.042
```

```

44 # Esto indica que la relación entre el tratamiento y el outcome
45 varía en función del nivel de educación (X1)
46
47 # Comparación del coeficiente de interacción
48 coef_interaccion <- coef(modelo_interaccion)["T:X1"]
49 # El coeficiente de la interacción es -0.1682, lo que muestra que el
    impacto del tratamiento es menor para las personas con mayor X1

```

De esta forma, la omisión de la variable Z introduce un sesgo significativo en la estimación del ATE, en este caso resultando en una sobreestimación de 0.5959 unidades. Esto ocurre porque Z está correlacionada tanto con el tratamiento como con el outcome, lo que hace que el efecto del tratamiento parezca mayor cuando no se controla por esta variable.

Al incluir la interacción entre T y X_1 , el modelo captura parte de la heterogeneidad en los efectos del tratamiento, especialmente mostrando que el efecto del tratamiento es menor para individuos con mayores niveles de X_1 . Sin embargo, este ajuste no es suficiente para corregir el sesgo causado por la omisión de Z , destacando así la importancia de incluir todas las variables relevantes para obtener inferencias causales válidas.

10. Considere una intervención en la cual se quiere obtener el efecto promedio de tratamiento (ATE). Demuestre bajo qué condiciones, al agregar una covariable X_i a la especificación, esta producirá un estimador de ATE más eficiente. *Hint*: considere que el error estándar del estimador del ATE se puede expresar de la siguiente forma cuando no existen covariables:

$$SE(\widehat{ATE}) = \sqrt{\frac{\text{Var}(Y_i(0)) + \text{Var}(Y_i(1)) + 2 \cdot \text{Cov}(Y_i(0), Y_i(1))}{N - 1}}$$

Las siguientes igualdades y supuestos le pueden ser útiles:

- $\text{Var}(Y - X) = \text{Var}(Y) + \text{Var}(X) - 2 \cdot \text{Cov}(Y, X)$
- $\beta_1 = \frac{\text{Cov}(Y, X)}{\text{Var}(X)}$ cuando $Y_i = \beta_0 + \beta_1 X_i + u_i$

Primero, se debe notar que para agregar la covariable al modelo, se debe reemplazar $\text{Var}(Y_i(D_i))$ por $\text{Var}(Y_i(D_i) - X_i)$. Para ambos valores de D_i , la ecuación del error estándar se transforma en:

$$SE(\widehat{ATE}') = \sqrt{\frac{\text{Var}(Y_i(0) - X_i) + \text{Var}(Y_i(1) - X_i) + 2 \cdot \text{Cov}(Y_i(0) - X_i, Y_i(1) - X_i)}{N - 1}}$$

$$= \sqrt{\frac{\text{Var}(Y_i(0)) + \text{Var}(Y_i(1)) + 2 \cdot \text{Cov}(Y_i(0), Y_i(1)) + 4(\text{Var}(X_i) - \text{Cov}(Y_i(0), X_i) - \text{Cov}(Y_i(1), X_i))}{N-1}}$$

Al comparar ambos errores estándar, podemos notar que el término decisivo es:

$$4(\text{Var}(X_i) - \text{Cov}(Y_i(0), X_i) - \text{Cov}(Y_i(1), X_i)) < 0$$

Reordenando, se debe cumplir que:

$$\text{Cov}(Y_i(0), X_i) + \text{Cov}(Y_i(1), X_i) > \text{Var}(X_i)$$

O bien:

$$\frac{\text{Cov}(Y_i(0), X_i)}{\text{Var}(X_i)} + \frac{\text{Cov}(Y_i(1), X_i)}{\text{Var}(X_i)} > 1$$

En resumen, los coeficientes β_1 para la regresión de Y_i sobre X_i en ambos casos deben ser suficientemente fuertes para cumplir con la condición. Es decir, la covariable X_i debe ser un buen predictor para mejorar la eficiencia del estimador del ATE.

11. Suponga que le piden evaluar el impacto asistir a clases en el rendimiento académico. Como medida de interés, le piden que analice el efecto de asistir a clases sobre las notas obtenidas en una interrogación. Por suerte, se cuenta con la información sobre las notas que 4 estudiantes hubiesen tenido asistiendo y sin asistir a clase. Además la tabla posee una columna que indica si la persona asistió efectivamente a clases en la realidad.

Estudiante	Nota con asistencia	Nota sin asistencia	Asistió?
1	6.1	5.3	Sí
2	5.9	3.8	No
3	5.1	2.7	Sí
4	6.9	6.6	No

- Utilizando los datos entregados, calcule el efecto causal de asistir a clase en las notas de la interrogación.

Se tiene que el efecto de ir a la universidad es:

$$ATE = E[\tau_i] = E[Y_{1i} - Y_{0i}] = E[Y_{1i}] - E[Y_{0i}]$$

Y se tiene:

$$E[Y_{1i}] = \frac{6.1 + 5.9 + 5.1 + 6.9}{4} = 6$$
$$E[Y_{0i}] = \frac{5.3 + 3.8 + 2.7 + 6.6}{4} = 4.6$$

Entonces el efecto promedio del tratamiento o ATE sería igual a 1.4

- Asuma ahora que no se conocen los 2 escenarios de las notas de cada estudiantes, sino que solo la nota que efectivamente tuvo cada uno. Calcule el efecto causal de asistir a clase sólo con datos empíricos.

En este caso no se tiene el contrafactual perfecto de qué pasaría si la persona i hubiera asistido a clase y viceversa. Como sabemos:

$$\underbrace{\mathbb{E}[Y_{1i} | D_i = 1] - \mathbb{E}[Y_{0i} | D_i = 0]}_{\text{Diferencia observada}} = \underbrace{\mathbb{E}[Y_{1i} | D_i = 1] - \mathbb{E}[Y_{0i} | D_i = 1]}_{\text{ATT}} + \underbrace{\mathbb{E}[Y_{0i} | D_i = 1] - \mathbb{E}[Y_{0i} | D_i = 0]}_{\text{Sesgo de selección}}$$

En este caso tenemos:

$$E[Y_{1i} | D_i = 1] = \frac{6.1 + 5.1}{2} = 5.6$$

$$E[Y_{0i} | D_i = 0] = \frac{3.8 + 6.6}{2} = 5.2$$

Entonces la diferencia observada es de 0.4

- Calcule la diferencia entre los resultados obtenidos en (a) y (b) y comente al respecto.

En el punto (a) obtuvimos que el efecto promedio de asistir a clase en las notas de la interrogación es un aumento de 1.4, sin embargo, en el punto (b) observamos un aumento de 0.4. Esto se debe a que en la vida real la diferencia observada corresponde a el efecto sobre los tratados + un sesgo de selección. No todas las personas reaccionan de igual manera al tratamiento, por lo que al medir el efecto del tratamiento pueden estar afectando factores endógenos de las personas que sí afectan a la nota obtenida. Para eliminar este sesgo de selección se puede realizar un RCT, el cual si está hecho correctamente permite eliminar el sesgo y generar una buena estimación del efecto del tratamiento.

- Suponga que está intentando encontrar la relación causal entre la temperatura y la venta de helados. Defina el efecto de un aumento en la temperatura en la cantidad de helados vendidos en términos de resultados potenciales (también conocida como notación Neyman-Rubin, Potential Outcomes Framework, POF).

El resultado observado para un individuo i (Y_i) se puede escribir como:

$$Y_i = Y_{0i} + (Y_{1i} - Y_{0i})D_i$$

donde el efecto individual sería:

$$\tau_i = Y_{1i} - Y_{0i}, \quad \text{o bien, } Y_i(1) - Y_i(0).$$

Dado que no se pueden observar simultáneamente ambos casos, se define el efecto promedio en una población como:

$$E[\tau_i] = E[Y_i(1) - Y_i(0)] = E[Y_i(1)] - E[Y_i(0)].$$

13. Suponga que tiene los siguientes datos sobre temperatura y cantidad de ventas:

Día	Temperatura alta?	Ventas (baja temp.)	Ventas (alta temp.)
1	1	20	30
2	0	15	25
3	1	18	35
4	0	10	22
5	1	22	40
6	0	12	20
7	1	25	38
8	0	14	19

Calcule:

- El efecto promedio del tratamiento (ATE, Average Treatment Effect).

Como se mencionó en el punto anterior, $E[\tau_i] = E[Y_i(1) - Y_i(0)] = E[Y_i(1)] - E[Y_i(0)]$, por lo tanto:

$$E[\tau_i] = E[Y_i(1)] - E[Y_i(0)]$$

$$E[\tau_i] = E[30 + 25 + 35 + 22 + 40 + 20 + 38 + 19] - E[20 + 15 + 18 + 10 + 22 + 12 + 25 + 14]$$

$$E[\tau_i] = \frac{209}{8} - \frac{136}{8}$$

$$E[\tau_i] = \frac{73}{8}$$

$$E[\tau_i] = 9.125$$

- El efecto promedio del tratamiento que calcularía si sólo usa los delitos que ve en la realidad.

En el caso de ver solo la realidad, tenemos que: $E[Y_i | D_i = 1] = E[Y_i(1) | D_i = 1]$ y $E[Y_i | D_i = 0] = E[Y_i(0) | D_i = 0]$

$$E[\tau_i] = E[Y_i(1) | D_i = 1] - E[Y_i(0) | D_i = 0]$$

$$E[\tau_i] = E[30 + 35 + 40 + 38] - E[15 + 10 + 12 + 14]$$

$$E[\tau_i] = \frac{143}{4} - \frac{51}{4}$$

$$E[\tau_i] = \frac{92}{4}$$

$$E[\tau_i] = 23$$

- Explique por qué (o por qué no) ve una diferencia entre su respuesta entre sus dos estimaciones anteriores. Expréselo en términos de esperanza de resultados potenciales.

De acuerdo a lo visto en clases, podemos descomponer la diferencia observacional en dos partes identificadas como el efecto promedio en las unidades tratadas (ATT) y el sesgo de selección (diferencias estructurales entre las unidades que reciben tratamiento y quienes no):

$$\underbrace{\mathbb{E}[Y_{1i} | D_i = 1] - \mathbb{E}[Y_{0i} | D_i = 0]}_{\text{Diferencia observada}} = \underbrace{\mathbb{E}[Y_{1i} | D_i = 1] - \mathbb{E}[Y_{0i} | D_i = 1]}_{\text{ATT}} + \underbrace{\mathbb{E}[Y_{0i} | D_i = 1] - \mathbb{E}[Y_{0i} | D_i = 0]}_{\text{Sesgo de selección}}$$

A partir de esto, llegamos a:

$$\underbrace{E[y_i | d_i = 1] - E[Y_{1i} | D_i = 1]}_{\text{Diferencia observacional}} = 23 - 9.125$$

$$\underbrace{E[y_i | d_i = 1] - E[Y_{1i} | D_i = 1]}_{\text{Diferencia observacional}} = 13.875$$

$$13.875 = \text{TOT} + \text{BIAS}$$

Donde:

$$\text{TOT} = \frac{30 + 35 + 40 + 38}{4} - \frac{20 + 18 + 22 + 25}{4} = 11.25,$$

$$\text{BIAS} = \frac{20 + 18 + 22 + 25}{4} - \frac{15 + 10 + 12 + 14}{4} = 2.625.$$

14. Considere una empresa de 10 trabajadores de una consultora de innovación, para los cuales conocemos los puntajes potenciales de desempeño de un proyecto si hubiesen participado en un programa de inteligencia artificial, como también si es que no. A su vez, conocemos quienes efectivamente participaron en el programa ($D_i = 1$) y quienes no ($D_i = 0$).

Trabajador i	D_i	Puntaje con programa IA	Puntaje sin programa IA
1	1	85	80
2	0	78	75
3	1	90	82
4	1	88	83
5	0	70	68
6	0	76	74
7	1	92	85
8	0	72	65
9	1	75	69
10	0	69	62

A partir de lo anterior, responda las siguientes preguntas.

- a) Calcule el efecto causal individual del programa IA sobre el puntaje de desempeño para cada uno de los 10 trabajadores.

Trabajador i	Efecto causal individual sobre el desempeño
1	$85 - 80 = 5$
2	$78 - 75 = 3$
3	$90 - 82 = 12$
4	$88 - 83 = 5$
5	$70 - 68 = 2$
6	$76 - 74 = 2$
7	$92 - 85 = 7$
8	$72 - 65 = 7$
9	$75 - 69 = 6$
10	$69 - 62 = 7$

- b) Si todos los trabajadores hubieran sido parte del programa, ¿Cuál sería el efecto promedio esperado sobre sus puntajes en comparación con el escenario en que nadie hubiese participado?

$$ATE = \mathbb{E}[Y_i(1)] - \mathbb{E}[Y_i(0)] = \frac{5 + 3 + 12 + 5 + 2 + 2 + 7 + 7 + 6 + 7}{10} = \frac{56}{10} = 5.6 \quad (1)$$

- c) Compare el promedio de puntajes realmente observados entre quienes participaron en el programa y quienes no lo hicieron.

$$\mathbb{E}[Y_i(1)] = \frac{85 + 90 + 88 + 92 + 75}{5} = \frac{430}{5} = 86 \quad (2)$$

$$\mathbb{E}[Y_i(0)] = \frac{75 + 68 + 74 + 65 + 62}{5} = \frac{344}{5} = 68.8 \quad (3)$$

Por ende, la diferencia promedio corresponde a lo siguiente.

$$\mathbb{E}[Y_i(1)] - \mathbb{E}[Y_i(0)] = 86 - 68.8 = 17.2 \quad (4)$$

- d) Entre los trabajadores que si participaron del programa, ¿Cuál fue el impacto promedio del programa, considerando lo que hubieran obtenido en caso de no haber asistido?

$$TOT = \frac{5+8+5+7+6}{5} = \frac{31}{5} = 6.2$$

- e) Analice qué tan comparables eran los trabajadores respecto a los que asistieron al programa y los que no asistieron.

$$\begin{aligned}\mathbb{E}[Y_i(0)|D_i = 1] &= \frac{80 + 82 + 83 + 85 + 69}{5} = \frac{399}{5} = 79.8 \\ \mathbb{E}[Y_i(0)|D_i = 0] &= \frac{75 + 68 + 74 + 65 + 62}{5} = \frac{344}{5} = 68.8\end{aligned}$$

Por ende, el sesgo de selección corresponde al siguiente.

$$BIAS = \mathbb{E}[Y_i(0)|D_i = 1] - \mathbb{E}[Y_i(0)|D_i = 0] = 79.8 - 68.8 = 11$$

Existe sesgo de selección porque la participación del programa de inteligencia artificial no fue asignada de forma aleatoria, de forma que, aquellos trabajadores que participan del programa deciden ir, y entonces, ambos grupos no son comparables.

15. Suponga que una empresa prueba una actualización pagada de excel. Sea Y el outcome donde, $Y = 1$ el resultado si el trabajador logra terminar su tarea a tiempo y, análogamente, $Y = 0$ si es que no. Sea D la asignación de la implementación de la actualización (tratamiento) a su cuenta de excel, donde $D \in [0, 1]$. En este escenario, y dado al problema de la inferencia causal, solo se observa un solo resultado potencial dependiendo si se le asignó o no el tratamiento. Por ende, si $D = 1$, entonces solo se puede observar $Y(1)$ ya que se le actualizó excel, mientras que si $D = 0$, solo se puede observar $Y(0)$ dado que su excel no se actualizó.

Un mes después, se registran los siguientes datos a continuación.

- Proporción tratada: $P(D = 1) = p = 0.4$
- Proporción no tratada: $P(D = 0) = (1 - p) = 0.6$
- Tasa promedio en que los trabajadores con la actualización de excel completan su tarea a tiempo: $\mathbb{E}[Y|D = 1] = 0.6$.
- Tasa promedio en que los trabajadores sin la actualización de excel completan su tarea a tiempo: $\mathbb{E}[Y|D = 0] = 0.3$.

- a) Escriba $\mathbb{E}[Y(1)]$ como combinación de $\mathbb{E}[Y(1)|D = 1]$ y $\mathbb{E}[Y(1)|D = 0]$ utilizando la ley de esperanza total.

Mediante ley de esperanza total se cumple la siguiente relación a continuación.

$$\begin{aligned}\mathbb{E}[Y(1)] &= \mathbb{E}[Y(1)|D = 1] \cdot P(D = 1) + \mathbb{E}[Y(1)|D = 0] \cdot P(D = 0) \\ &= \mathbb{E}[Y(1)|D = 1] \cdot p + \mathbb{E}[Y(1)|D = 0] \cdot (1 - p)\end{aligned}$$

- b) Obtenga cotas para $\mathbb{E}[Y(1)]$

Con los datos entregados se sabe que lo siguiente.

$$\mathbb{E}[Y(1)|D = 1] = 0.6 \text{ y } \mathbb{E}[Y(1)|D = 0] \in [0, 1]$$

Reemplazando en (a), se obtiene lo siguiente.

$$\begin{aligned}\mathbb{E}[Y(1)] &= \mathbb{E}[Y(1)|D = 1] \cdot P(D = 1) + \mathbb{E}[Y(1)|D = 0] \cdot P(D = 0) \\ &= 0.6 \cdot 0.4 + \mathbb{E}[Y(1)|D = 0] \cdot 0.6 \\ &= 0.24 + \mathbb{E}[Y(1)|D = 0] \cdot 0.6\end{aligned}$$

Luego, como $\mathbb{E}[Y(1)|D = 0] \in [0, 1]$, el intervalo para $\mathbb{E}[Y(1)]$ es el siguiente.

$$0.24 + 0 \cdot 0.6 = 0.24 \leq \mathbb{E}[Y(1)] \leq 0.84 = 0.24 + 1 \cdot 0.6$$

- c) Escriba $\mathbb{E}[Y(0)]$ como combinación de $\mathbb{E}[Y(0)|D = 1]$ y $\mathbb{E}[Y(0)|D = 0]$ utilizando la ley de esperanza total.

Similarmente a a), escribimos la expresión asociada.

$$\mathbb{E}[Y(0)] = \mathbb{E}[Y(0)|D = 0] \cdot (1 - p) + \mathbb{E}[Y(0)|D = 1] \cdot p$$

- d) Obtenga cotas para $\mathbb{E}[Y(0)]$

Al igual que en b), se sabe que

$$\mathbb{E}[Y(0)|D = 0] = \mathbb{E}[Y|D = 0] = 0.3 \text{ y } \mathbb{E}[Y(0)|D = 1] \in [0, 1]$$

Reemplazando en (b) se obtiene lo siguiente.

$$\begin{aligned}\mathbb{E}[Y(0)] &= \mathbb{E}[Y(0)|D = 0] \cdot (1 - p) + \mathbb{E}[Y(0)|D = 1] \cdot p \\ &= 0.3 \cdot 0.6 + \mathbb{E}[Y(0)|D = 1] \cdot 0.4 \\ &= 0.18 + \mathbb{E}[Y(0)|D = 1] \cdot 0.4\end{aligned}$$

Luego, como $\mathbb{E}[Y(0)|D = 1] \in [0, 1]$, se obtiene el siguiente intervalo para $\mathbb{E}[Y(0)]$.

$$0.18 + 0 \cdot 0.4 = 0.18 \leq \mathbb{E}[Y(0)] \leq 0.58 = 0.18 + 1 \cdot 0.4 \quad (5)$$

- e) Encuentre las cotas para $ATE = \mathbb{E}[Y(1)] - \mathbb{E}[Y(0)]$

El valor mínimo que puede tomar ATE es tal que $\mathbb{E}[Y(1)]$ es mínimo y $\mathbb{E}[Y(0)]$ es máximo, por ende, reemplazando, se obtiene lo siguiente.

$$ATE_{minimo} = 0.24 - 0.58 = -0.34$$

Utilizando la misma lógica, el valor máximo que puede tomar ATE es tal que $\mathbb{E}[Y(1)]$ es máximo y $\mathbb{E}[Y(0)]$ es mínimo, por ende,

$$ATE_{m\acute{a}ximo} = 0.84 - 0.18 = 0.66$$

Es así como se tiene un intervalo para el *Average Treatment Effect*.

$$-0.34 \leq ATE \leq 0.66$$

- f) ¿Cómo cambiaría su respuesta si se pudiera asumir asignación aleatoria de la actualización de excel?

La asignación aleatoria de D_i implica independencia, donde los resultados potenciales no dependen de si el individuo fue o no fue tratado:

$$(Y_i(1), Y_i(0)) \perp D_i$$

Por ende,

$$ATE = \mathbb{E}[Y(1)|D = 1] - \mathbb{E}[Y(0)|D = 0] = \mathbb{E}[Y(1)] - \mathbb{E}[Y(0)] = 0.6 - 0.3 = 0.3$$

16. Un profesor le pide ayuda para evaluar el impacto de una vacunación contra la influenza en la escuela. Sea Y el outcome donde $Y_i = 1$ si el estudiante se enferma, y $Y_i = 0$ si es que no. Sea D_i la asignación de la vacuna a cada estudiante.

Explique por qué razón usted **no** podría ayudarlo con sus conocimientos de *Potential Outcomes Framework*

En este caso particular, no se cumple con el supuesto de no interferencia **SUTVA**, es decir, ocurre que si $D_i = D'_i$, no se cumple que $Y_i(D) = Y_i(D')$, debido a que el resultado potencial de un estudiante Y_i depende de la asignación de vacunas de los demás estudiantes a su alrededor, ya que, si gran parte de su entorno está vacunado, aunque el propio estudiante no se vacune, su probabilidad de contagio será más baja. Es así como, la probabilidad de que un estudiante se enferme no depende solo de si se le asigna o no tratamiento (la asignación de la vacuna), sino también de cuantos de sus compañeros están vacunados. En conclusión, no se puede utilizar *POF* ya que no se cumple el supuesto de no interferencia SUTVA.

Referencias

[Angrist and Pischke, 2008] Angrist, J. D. and Pischke, J.-S. (2008). *Mostly harmless econometrics*. Princeton university press.

[Cunningham, 2020] Cunningham, S. (2020). Causal inference. *The Mixtape*, 1.

[Montamat, G. (2020). *Causality and the potential outcomes model* [Presentación en PowerPoint]. Harvard University.https://scholar.harvard.edu/files/montamat/files/causality_and_the_potential_outcomes_model.pdf].

Agradecimiento especial a Lucas Contardo por proporcionar la base de los ejercicios.

Agradecimiento especial a Alonso Parada Frigerio, Felipe Valdés y Francisca Correa por sus contribuciones con nuevos ejercicios en los períodos 2023-2, 2024-1 y 2025-1.