



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE
DEPARTAMENTO DE INGENIERÍA INDUSTRIAL Y DE SISTEMAS
ICS2563 - ECONOMETRÍA APLICADA

Solución Guía de Repaso: Interrogación 1

Fecha de publicación: 28/08/2025

2° semestre 2025 - Profesor Patricio Domínguez y Gonzalo Gaete

Ayudante: Catalina Alegría - calegriak@uc.cl

Agradecimientos a Felipe Valdés por la base de este material.

Ejercicios

1. Para $i = 1, \dots, n$, justifique cuál de los siguientes modelos de regresión corresponden a modelos lineales.

(a) $y_i = \beta_0 + \beta_1 x_1 + \beta_2 x_1^2 + \varepsilon_i$

Si es un modelo lineal.

(b) $y_i = \beta_0 + \beta_1 \left(\frac{1}{x_i}\right) + \varepsilon_i$

Si es un modelo lineal.

(c) $y_i = \beta_0 \exp(\beta_1 x_i) + \varepsilon_i$

No es un modelo lineal. Notar que el exponente de β_0 y β_1 es distinto bajo cualquier transformación de la ecuación.

(d) $y_i = \beta_0 x_i^{\beta_1} + \varepsilon_i$

No es un modelo lineal. Notar que el exponente de β_0 y β_1 es distinto bajo cualquier transformación de la ecuación.

(e) $\text{Log}(y_i) = \beta_0 \text{Log}(x_1) + \beta_1 e^{x_2} + \varepsilon_i$

Si es un modelo lineal.

(f) $y_i = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_1 x_2 + \varepsilon_i$

Si es un modelo lineal.

(g) $\Gamma(y) = \alpha + \beta_1 \nabla x_1 + \beta_2 \Delta x_2 + \varepsilon$

Si es un modelo lineal.

(h) $y_i = (\alpha + \beta_0 + \beta_1)x_1 + \varepsilon_i$

Si es un modelo lineal. Notar que existe una única estimación MCO.

2. Como ya sabemos, existen diversos métodos de estimación para los parámetros de una regresión. Entre los métodos más utilizados se encuentra el Método de Máxima Verosimilitud (EMV), el Método de los Momentos (EMM), y el Método de Mínimos cuadrados ordinarios (MCO). Para la ecuación de regresión lineal, $y = X\beta + \epsilon$, con n observaciones y p características;

- (a) Derive el estimador MCO de β . ¿Es necesario el supuesto de normalidad en este caso? Especifique los supuestos utilizados.

Buscamos minimizar el cuadrado de la norma 2 del vector de errores, es decir, buscamos minimizar la siguiente función:

$$MCO(\beta) = \epsilon' \epsilon = (y - X\beta)'(y - X\beta) = \|y - X\beta\|_2^2$$

Podemos utilizar los conocimientos en álgebra matricial:

$$\begin{aligned} MCO(\beta) &= (y - X\beta)'(y - X\beta) \\ &= y'y - \beta'X'y - y'X\beta + \beta'X'X\beta \\ &= y'y - 2y'X\beta + \beta'X'X\beta \end{aligned}$$

Sabemos que podemos minimizar una función utilizando el gradiente e igualando a cero

$$\frac{\partial MCO(\beta)}{\partial \beta} = \nabla MCO(\beta) = -2X'y + 2X'X\beta \quad (1)$$

Podemos utilizar (1) para obtener un candidato a mínimo según

$$\begin{aligned} -2X'y + 2X'X\beta &= 0 \\ X'X\beta &= X'y \end{aligned} \quad (2)$$

De esta manera, las ecuaciones (2) se conocen como ecuaciones normales. Verificamos que tenemos un mínimo según el hessiano:

$$\frac{\partial^2 MCO(\beta)}{\partial \beta \partial \beta'} = 2X'X \quad (3)$$

Bajo el supuesto que las columnas de la matriz de diseño son independientes, es decir, que la matriz es de rango columna completo, tenemos que la matriz hessiana presentada en (3) es semi definida positiva, luego tratamos con un mínimo. Además, esto garantiza la existencia de la inversa de $X'X$, luego podemos resolver las ecuaciones normales en (2) para β :

$$\hat{\beta} = (X'X)^{-1}X'y$$

Luego se tiene el resultado que se buscaba.

- (b) Derive el EMV de β . Especifique los supuestos utilizados.

Bajo el supuesto de que los errores distribuyen normal, tienen media 0 y varianza constante, es decir, $\epsilon \sim \mathcal{N}_n(\mathbf{0}, \sigma^2 \mathbf{I}_n)$, se puede derivar la distribución muestral de $\mathbf{y}$, obteniendo $\mathbf{y} \sim \mathcal{N}_n(\mathbf{X}\beta, \sigma^2 \mathbf{I}_n)$.

El método de máxima verosimilitud intenta maximizar la función de verosimilitud, la cual se obtiene mediante una distribución. En nuestro caso, conociendo la función de densidad de probabilidad de una normal n – variada, tenemos la siguiente función de verosimilitud:

$$\mathcal{L}(\beta, \sigma^2) = \frac{1}{2\pi\sigma^2} \exp \left\{ -\frac{1}{2\sigma^2} (\mathbf{y} - \mathbf{X}\beta)' (\mathbf{y} - \mathbf{X}\beta) \right\} \quad (4)$$

Como la función de verosimilitud es monótona creciente, luego maximizar (4) es equivalente a maximizar el logaritmo de la función de verosimilitud, la log-verosimilitud:

$$l(\beta, \sigma^2) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} (\mathbf{y} - \mathbf{X}\beta)' (\mathbf{y} - \mathbf{X}\beta) \quad (5)$$

Notamos que maximizar la función de log-verosimilitud implica obtener el gradiente de (5), luego podemos descartar los valores constantes (aquellos que no dependen de β). Simplificando entonces, maximizar (5) es equivalente a maximizar la siguiente función:

$$MV(\beta) = -\frac{1}{2\sigma^2} (\mathbf{y} - \mathbf{X}\beta)' (\mathbf{y} - \mathbf{X}\beta) \quad (6)$$

Podemos notar que por dualidad, maximizar la función (6) es equivalente a minimizar la siguiente función:

$$MV_d(\beta) = (\mathbf{y} - \mathbf{X}\beta)' (\mathbf{y} - \mathbf{X}\beta) \quad (7)$$

Notamos así que MV_d es la función *MCO* definida en (a), luego minimizar la función en (7), bajo el supuesto de que la matriz de diseño tiene rango columna completo, es equivalente al método de mínimos cuadrados ordinarios. Obtuvimos así el mismo estimador, con las mismas propiedades, pero pidiéndole más a la regresión (que tenga más supuestos).

3. En la ciencia generalmente se considera como un error de predicción a la distancia entre el valor predicho y el valor real. La distancia, sin embargo, puede entenderse de diferentes maneras. Considere el modelo $y = X\beta + \epsilon$ y defina el vector $e = y - \hat{y} = y - X\hat{\beta}$, considerado como un vector de error de estimación. Los elementos del vector e se denominan residuos.

- (a) Demuestre que los residuos son ortogonales a la matriz de diseño X .

Podemos definir los residuos según:

$$\begin{aligned} \mathbf{e} &= \mathbf{y} - \hat{\mathbf{y}} \\ &= (\mathbf{I}_n - \mathbf{P})\mathbf{y} \end{aligned}$$

Donde $\mathbf{P} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$. Además, notamos que $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}$, luego

$$\mathbf{e} = (\mathbf{I}_n - \mathbf{P})\boldsymbol{\epsilon}$$

De esta manera, podemos notar lo siguiente:

$$\mathbf{X}'\mathbf{e} = \mathbf{X}'(\mathbf{I}_n - \mathbf{P})\boldsymbol{\epsilon} = (\mathbf{X}' - \mathbf{X}')\boldsymbol{\epsilon} = \mathbf{0}$$

Luego la matriz de diseño es ortogonal al vector de residuos.

- (b) Utilizando el resultado anterior, demuestre que los residuos son ortogonales al vector de predicción, $\hat{\mathbf{y}}$.

Similar al caso anterior, tenemos:

$$\mathbf{y}'\mathbf{e} = \mathbf{y}'(\mathbf{I}_n - \mathbf{P})\boldsymbol{\epsilon} = \mathbf{0}$$

Luego el vector de respuestas es ortogonal al vector de residuos.

- (c) Considere el modelo descrito anteriormente con intercepto. Pruebe $\sum_{i=1}^n e_i = 0$ para los residuos $\mathbf{e} = [e_1 \ e_2 \ \dots \ e_n]'$.

Podemos notar que un modelo con intercepto implica que la primera columna es una columna de unos. Denotemos $\mathbf{X}_1 = \mathbf{1}_n = [1 \ 1 \ \dots \ 1]'$ como el vector de 1's de dimensión n . Luego,

$$\mathbf{X}'_1\mathbf{e} = \mathbf{1}'_n\mathbf{e} = \sum_{i=1}^n e_i$$

Por el resultado en (a), tenemos que $\mathbf{X}'_1\mathbf{e} = 0$, luego $\sum_{i=1}^n e_i = 0$.

4. Suponga que la matriz de diseño, $\mathbf{X}$ de dimensión $(n \times p)$ tiene rango p . Se define la matriz de proyección como $\mathbf{P} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$, y la matriz de residuos como $\mathbf{M} = \mathbf{I}_n - \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}' = \mathbf{I}_n - \mathbf{P}$.

- (a) Pruebe que $\mathbf{P}$ y $\mathbf{M}$ son matrices simétricas e idempotentes.

Podemos utilizar las propiedades del álgebra:

$$\begin{aligned} \mathbf{M}^2 &= \mathbf{I}'_n\mathbf{I}_n - 2\mathbf{I}_n\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}' + \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}' \\ &= \mathbf{I}_n - 2\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}' + \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}' \\ &= \mathbf{I}_n - \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}' \end{aligned}$$

Luego $M^2 = M$, es decir, M es idempotente. Consideremos ahora lo siguiente:

$$\begin{aligned}
 M' &= (I_n - X(X'X)^{-1}X')' \\
 &= I_n' - (X(X'X)^{-1}X')' && \text{(Por } (A - B)' = A' - B') \\
 &= I_n - (X')'(X(X'X)^{-1})' && \text{(Por } (AB)' = B'A') \\
 &= I_n - X((X'X)^{-1})'X' && \text{(Por } (AB)' = B'A') \\
 &= I_n - X((X'X)')^{-1}X' && \text{(Por } ((A)^{-1})' = (A')^{-1}) \\
 &= I_n - X(X'X)^{-1}X' && \text{(Por } (AB)' = B'A')
 \end{aligned}$$

Luego se tiene que $M' = M$, es decir, M es simétrica. Para la matriz P el procedimiento es análogo.

- (b) Pruebe que $tr(M) = n - p$, con $tr(\cdot)$ la traza de una matriz.

Existen dos propiedades de la traza que nos interesan, en primer lugar, la traza es un operador lineal:

$$tr(M) = tr(I_n) - tr(P)$$

En segundo lugar, la traza es invariante ante permutaciones cíclicas:

$$tr(P) = tr(X(X'X)^{-1}X') = tr(X'X(X'X)^{-1}) = tr(I_p)$$

Luego, juntando ambas propiedades tenemos:

$$tr(M) = tr(I_n) - tr(I_p) = n - p$$

- (c) Pruebe que M es una matriz semi-definida positiva.

Sea $x \in \mathbb{R}^n$, $x \neq 0$. Notemos lo siguiente:

$$\begin{aligned}
 x'Mx &= x'M^2x \\
 &= x'M'Mx \\
 &= (Mx)'Mx
 \end{aligned}$$

Como $(Mx)'Mx \geq 0$ tenemos que M es una matriz semi-definida positiva (notar el producto interno que se produjo).

- (d) Pruebe que $PX = X$.

Simplemente multiplicando obtenemos lo pedido:

$$PX = X(X'X)^{-1}X'X = X$$

5. Sean a , b y c vectores constantes de dimensión $(n \times 1)$. Un estimador lineal $a'y$ de $c'\beta$ es el mejor estimador lineal insesgado (BLUE) de $c'\beta$ si $\mathbb{E}[a'y] = c'\beta$, y, para cualquier otro estimador lineal insesgado $b'y$ de $c'\beta$ se cumple que $\text{Var}[a'y] \leq \text{Var}[b'y]$. Sea $\hat{\beta}$ el estimador MCO del modelo de regresión lineal $y = X\beta + \epsilon$. A continuación demostraremos que $\hat{\beta}$ es el BLUE (teorema de Gauss-Markov):

- (a) Sea $c'y$ cualquier otro estimador lineal insesgado de $a'\beta$. Pruebe que $a' = c'X$.

Por insesgamiento,

$$\mathbb{E}[c'y] = a'\beta \quad (8)$$

También, podemos reescribir según la linealidad del operador esperanza:

$$\begin{aligned} \mathbb{E}[c'y] &= c'\mathbb{E}[y] \\ &= c'X\beta \end{aligned} \quad (9)$$

Igualando (8) con (9), obtenemos

$$a' = c'X$$

- (b) Considerando lo anterior, pruebe que $\text{Var}[c'y] = \sigma^2 c'c$.

$$\begin{aligned} \text{Var}[c'y] &= c'\text{Cov}[y]c \\ &= c'\sigma^2 I_n c \\ &= \sigma^2 c'c \end{aligned}$$

- (c) Pruebe que $\text{Var}[a'\hat{\beta}] = \sigma^2 c'Pc$.

$$\begin{aligned} \text{Var}[a'\hat{\beta}] &= a'\text{Cov}[\hat{\beta}]a \\ &= a'\sigma^2(X'X)^{-1}a \\ &= \sigma^2 c'X(X'X)^{-1}X'c \\ &= \sigma^2 c'Pc \end{aligned}$$

- (d) Concluya que $\text{Var}[c'y] - \text{Var}[a'\hat{\beta}] \geq 0$.

$$\begin{aligned} \text{Var}[c'y] - \text{Var}[a'\hat{\beta}] &= \sigma^2(c'c - \sigma^2 c'Pc) \\ &= \sigma^2 c'Mc \end{aligned}$$

Como M es semi-definida positiva, se tiene que $c'Mc \geq 0$, por lo tanto $\text{Var}[c'y] \geq \text{Var}[a'\hat{\beta}]$

6. Suponga que las variables explicativas de un modelo de regresión lineal $y = X\beta + \mu$ pueden dividirse en dos submatrices, X_1 y X_2 , con la propiedad de que ambas son ortogonales entre sí. Demuestre que los estimadores MCO para los sub-vectores β_1 y β_2 en los modelos parciales $y = X_1\beta_1 + \mu_1$, $y = X_2\beta_2 + \mu_2$ coinciden con los estimadores MCO para el modelo $y = X\beta + \mu$.

El estimador MCO del modelo $y = X_1\beta_1 + \mu_1$ es $\hat{\beta} = (X_1'X_1)^{-1}X_1'y$. Podemos escribir y como

$$y = Py + My = X_1\hat{\beta}_1 + X_2\hat{\beta}_2 + My$$

Donde P es la matriz que proyecta sobre el espacio columna de X , y M es la matriz que proyecta sobre el complemento ortogonal del espacio columna de X . Si se multiplica la ecuación anterior por X_1' se obtiene:

$$X_1'y = X_1'X_1\hat{\beta}_1 + X_1'X_2\hat{\beta}_2 + X_1'My$$

Al ser ortogonales las matrices, queda lo siguiente:

$$X_1'y = X_1'X_1\hat{\beta}_1$$

Luego multiplicando por la izquierda por la matriz $(X_1'X_1)^{-1}$ obtenemos

$$(X_1'X_1)^{-1}X_1'y = \hat{\beta}_1$$

Y para $\hat{\beta}_2$ el procedimiento es análogo.

7. Considere un modelo de regresión lineal simple normal con $\mu_i = \beta_0 + \beta_1 x_i$ para $i = 1, \dots, n$, y el siguiente estimador de la pendiente:

$$b = \frac{1}{n-1} \sum_{i=2}^n \frac{(y_i - y_{i-1})}{(x_i - x_{i-1})}$$

- (a) ¿Es b un estimador insesgado de β_1 ?

Podemos probar insesgamiento mediante definición. Asumiendo que x_i es no estocástico (en caso que lo sea, se puede condicionar la esperanza fijando en

$x_i = z_i$), podemos tener:

$$\begin{aligned}
 \mathbb{E}[b] &= \mathbb{E}\left[\frac{1}{n-1} \sum_{i=2}^n \frac{(y_i - y_{i-1})}{(x_i - x_{i-1})}\right] \\
 &= \frac{1}{n-1} \sum_{i=2}^n \frac{1}{(x_i - x_{i-1})} \mathbb{E}[y_i - y_{i-1}] \\
 &= \frac{1}{n-1} \sum_{i=2}^n \frac{1}{(x_i - x_{i-1})} (\mathbb{E}[y_i] - \mathbb{E}[y_{i-1}]) \\
 &= \frac{1}{n-1} \sum_{i=2}^n \frac{1}{(x_i - x_{i-1})} (\beta_1(x_i - x_{i-1})) \\
 &= \frac{1}{n-1} \sum_{i=2}^n \beta_1 \\
 &= \beta_1
 \end{aligned}$$

- (b) Calcule la varianza de b y compare con la varianza de $\hat{\beta}_1$. ¿Cuál estimador prefiere?
Igual que antes, podemos calcular la varianza según sus propiedades:

$$\text{Var}[b] = \frac{1}{(n-1)^2} \text{Var}\left[\sum_{i=2}^n \frac{(y_i - y_{i-1})}{(x_i - x_{i-1})}\right]$$

En este punto notamos que no conocemos independencia entre variables aleatorias y_i . Sin embargo, por los supuestos de regresión, podemos determinar que $\text{Cov}[y_i, y_j] = 0$ para todo $i \neq j \in [n]$. Luego,

$$\begin{aligned}
 \text{Var}[b] &= \frac{1}{(n-1)^2} \sum_{i=2}^n \frac{1}{(x_i - x_{i-1})^2} (\text{Var}[y_i] + \text{Var}[y_{i-1}]) \\
 &= \frac{2\sigma^2}{(n-1)^2} \sum_{i=2}^n \frac{1}{(x_i - x_{i-1})^2}
 \end{aligned}$$

Sin necesidad de calcular la varianza del estimador MCO, podemos decir con certeza que preferiríamos el estimador $\hat{\beta}_1$, por Gauss-Markov.

8. Considere las ecuaciones

$$\begin{aligned}
 y_1 &= \beta_1 + \varepsilon_1 \\
 y_2 &= 2\beta_1 - \beta_2 + \varepsilon_2 \\
 y_3 &= \beta_1 + 2\beta_2 + \varepsilon_3
 \end{aligned}$$

Suponga adicionalmente que para todo $i \in \{1, 2, 3\}$ se cumple $\mathbb{E}[\varepsilon_i] = 0$. Encuentre el estimador MCO de β . ¿Es necesario el supuesto de normalidad en los errores, ε_i ? Justifique.

Podemos escribir lo siguiente:

$$\mathbf{X} = \begin{bmatrix} 1 & 0 \\ 2 & -1 \\ 1 & 2 \end{bmatrix} \quad \mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \end{bmatrix}$$

Por lo tanto, utilizando la fórmula MCO obtenemos que

$$\hat{\beta} = \begin{bmatrix} 0.167y_1 + 0.33y_2 + 0.167y_3 \\ -0.2y_2 + 0.4y_3 \end{bmatrix}$$

Notamos que pudimos calcular el estimador sin necesitar el supuesto de normalidad. Esto ocurre generalmente, el supuesto de normalidad no es condición necesaria para utilizar la estimación MCO, por ello su uso es transversal y tan famoso en la literatura.

9. Considere el siguiente modelo lineal: $y_{ij} \sim \mathcal{N}(\beta_i x_j, \sigma^2)$, $i = 1, 2$, $j = 1, \dots, n$.
- (a) Especifique el vector de respuestas y , el vector de parámetros β y la matriz de diseño X .

Las matrices y vectores son los siguientes:

$$\mathbf{y} = \begin{bmatrix} y_{11} \\ y_{21} \\ y_{12} \\ y_{22} \\ \vdots \\ y_{1j} \\ y_{2j} \\ \vdots \\ y_{1n} \\ y_{2n} \end{bmatrix} \quad \mathbf{X} = \begin{bmatrix} x_1 & 0 \\ 0 & x_1 \\ x_2 & 0 \\ 0 & x_2 \\ \vdots & \vdots \\ x_n & 0 \\ 0 & x_n \end{bmatrix} \quad \beta = \begin{bmatrix} \beta_1 \\ \beta_2 \end{bmatrix}$$

- (b) Encuentre el estimador MCO de β y el estimador insesgado de σ^2 .

Utilizando la fórmula dada por MCO obtenemos:

$$\hat{\beta} = \begin{bmatrix} \frac{\sum_{j=1}^n y_{1j}x_j}{\sum_{j=1}^n x_j^2} \\ \frac{\sum_{j=1}^n y_{2j}x_j}{\sum_{j=1}^n x_j^2} \end{bmatrix}$$

Similarmente, notando que $S^2 = \frac{(\mathbf{y}-\mathbf{X}\hat{\beta})'(\mathbf{y}-\mathbf{X}\hat{\beta})}{n-p}$ para una matriz $\mathbf{X}$ de dimensión $(n \times p)$ es un estimador insesgado de σ^2 , tenemos:

$$S^2 = \frac{\sum_{j=1}^n \left(y_{1j} - \frac{x_j \sum_{k=1}^n y_{1k}x_k}{\sum_{k=1}^n x_k^2} \right)^2 + \left(y_{2j} - \frac{x_j \sum_{k=1}^n y_{2k}x_k}{\sum_{k=1}^n x_k^2} \right)^2}{2(n-1)}$$

10. Suponga que se tienen $n+1$ observaciones, $y_0, \dots, y_n$, las cuales siguen el modelo lineal simple, $y_i \sim \mathcal{N}(\beta_0 + \beta_1 i, \sigma^2)$, $\forall i = 0, \dots, n$.

- (a) Encuentre el estimador MCO de β_1 .

Utilizando la fórmula, obtenemos:

$$\hat{\beta}_1 = \frac{\sum_{i=0}^n i y_i - \frac{n+1}{2} \sum_{i=0}^n y_i}{\frac{n(n^2-1)}{12}}$$

- (b) Un amigo suyo que recientemente dio un curso de econometría le comenta que él posee un mejor estimador de β_1 que el de MCO estimado en (a). El estimador de su amigo en cuestión es $\tilde{\beta}_1 = (y_n - y_0)/n$. Lamentablemente su amigo no dio nunca un curso de estadística, por lo que le pide probar que $\tilde{\beta}_1$ es un estimador insesgado de β_1 , y encontrar su varianza.

Para probar que es insesgado, calculamos la esperanza del estimador:

$$\begin{aligned}\mathbb{E}\left[\frac{(y_n - y_0)}{n}\right] &= \frac{1}{n}\mathbb{E}[y_n] - \frac{1}{n}\mathbb{E}[y_0] \\ &= \frac{1}{n}(\beta_0 + \beta_1 n) - \frac{1}{n}\beta_0 \\ &= \frac{1}{n}\beta_0 + \beta_1 - \frac{1}{n}\beta_0 \\ &= \beta_1\end{aligned}$$

Por lo tanto, el estimador de β_1 propuesto por su amigo es insesgado. A continuación calcularemos su varianza. Notemos:

$$\text{Var}\left[\frac{y_n - y_0}{n}\right] = \frac{1}{n^2}\text{Var}[y_n] + \frac{1}{n^2}\text{Var}[y_0] - \frac{2}{n^2}\text{Cov}[y_n, y_0]$$

Podemos notar que como $\mathbf{y}$ proviene del modelo lineal propuesto en el enunciado, tenemos por propiedades de la distribución normal n – variada que $\mathbf{y} \sim \mathcal{N}_n(\mathbf{X}\boldsymbol{\beta}, \sigma^2 \mathbf{I}_n)$, luego la covarianza entre cada par de observaciones es cero. Finalmente tenemos:

$$\begin{aligned}\text{Var}\left[\frac{y_n - y_0}{n}\right] &= \frac{1}{n^2}\text{Var}[y_n] + \frac{1}{n^2}\text{Var}[y_0] \\ &= \frac{2\sigma^2}{n^2}\end{aligned}$$

- (c) Considerando el estimador encontrado en (a), y el estimador que le propone su amigo, ¿cuál de los dos estimadores usaría usted? Justifique.

Dado que ambos estimadores son insesgados, deberíamos comparar su varianza, bajo el criterio de mínimo error cuadrático medio en estadística. Así, el estimador con menor varianza es el que deberíamos escoger. Podemos notar que $\text{Rango}(\mathbf{X}) = 2$, $\mathbb{E}[\boldsymbol{\epsilon}] = \mathbf{0}$, $\text{Var}[\boldsymbol{\epsilon}] = \sigma^2 \mathbf{I}_n$. Luego por el teorema de Gauss-Markov, tenemos que el estimador MCO es el BLUE (mínima varianza entre estimadores lineales). Más aún, por la distribución normal, el estimador MCO es también el EIVUM (estimador insesgado de varianza uniforme mínima), luego el estimador que utilizaríamos sería el dado por MCO.

11. Considere el modelo lineal, $y \sim \mathcal{N}_5(X\beta, \sigma^2 I_5)$. Se observan para el modelo anterior los siguientes datos:

Observación	y	x
1	0	-2
2	0	-1
3	1	0
4	1	1
5	3	2

Table 1: Datos observados

- (a) Especifique el vector de respuestas y (también conocido como *outcome*), la matriz de diseño, X , y el vector de parámetros β .

Observando los datos podemos escribir:

$$\mathbf{y} = \begin{bmatrix} 0 \\ 0 \\ 1 \\ 1 \\ 3 \end{bmatrix} \quad \mathbf{X} = \begin{bmatrix} -2 \\ -1 \\ 0 \\ 1 \\ 2 \end{bmatrix} \quad \boldsymbol{\beta} = [\beta_1]$$

- (b) Estime por medio de MCO el vector de parámetros β y la matriz de covarianza de los errores, $\sigma^2 I_5$.

Utilizando la fórmula obtenemos:

$$\beta_1 = 0.7 \quad \sigma^2 I_5 = \begin{bmatrix} 1.525 & 0 & 0 & 0 & 0 \\ 0 & 1.525 & 0 & 0 & 0 \\ 0 & 0 & 1.525 & 0 & 0 \\ 0 & 0 & 0 & 1.525 & 0 \\ 0 & 0 & 0 & 0 & 1.525 \end{bmatrix}$$

- (c) Estime la matriz de covarianza de los estimadores $\hat{\beta}$. ¿Son independientes? Justifique.

Podemos notar que $(\mathbf{X}'\mathbf{X})^{-1} = 0.1$, luego $\text{Cov}[\hat{\beta}] = 0.1525$. Como es un solo estimador, la independencia no tiene sentido.

12. Considere el modelo lineal $y = X\beta + \epsilon$. Suponga que existen variables omitidas en el modelo guardadas en una matriz X_2 . Utilice regresiones particionadas para mostrar el sesgo en que se incurriría al omitir una o más variables identificadas por la matriz X_2 . Discuta las principales condiciones para que el sesgo incurrido sea distinto de cero.

Podemos escribir el modelo lineal según

$$\mathbf{y} = \mathbf{X}_1\boldsymbol{\beta}_1 + \mathbf{X}_2\boldsymbol{\beta}_2 + \boldsymbol{\epsilon} \quad (10)$$

Por conveniencia, se tomará el estimador de mínimos cuadrados ordinarios, $\hat{\beta} = (\mathbf{X}\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$. Como $(\mathbf{X}\mathbf{X})\hat{\beta} = \mathbf{X}'\mathbf{y}$, podemos formar dos ecuaciones:

$$\mathbf{X}'_1\mathbf{X}_1\hat{\beta}_1 + \mathbf{X}'_1\mathbf{X}_2\hat{\beta}_2 = \mathbf{X}'_1\mathbf{y} \quad (11)$$

$$\mathbf{X}'_2\mathbf{X}_1\hat{\beta}_1 + \mathbf{X}'_2\mathbf{X}_2\hat{\beta}_2 = \mathbf{X}'_2\mathbf{y} \quad (12)$$

Utilizando la ecuación (12) en la ecuación (11) obtenemos lo siguiente:

$$\hat{\beta}_1 = (\mathbf{X}'_1\mathbf{X}_1)^{-1}\mathbf{X}'_1(\mathbf{y} - \mathbf{X}_2\hat{\beta}_2)$$

Esta fórmula muestra que hay dos componentes de la solución MCO en caso multivariado. Una que es exacta la solución del modelo simple y la segunda que es un “factor de corrección” que incluye, además de la misma matriz inversa, un componente asociado a la correlación entre $\mathbf{X}_1$ y $\mathbf{X}_2$ y la relación entre $\mathbf{X}_2$ e $\mathbf{y}$ (coeficiente $\hat{\beta}_2$). Esta segunda parte es el sesgo de omitir variables relevantes en el modelo, ya que es el componente que se aleja de la solución MCO del modelo simple. Las condiciones para que el sesgo sea distinto de cero son dos:

- (a) Que haya correlación entre $\mathbf{X}_1$ y $\mathbf{X}_2$ (en otras palabras que la multiplicación de matrices $\mathbf{X}_1$ y $\mathbf{X}_2$ sea diferente de cero)
 - (b) Que $\mathbf{X}_2$ sea una variable relevante o que tenga un efecto sobre y distinto de cero ($\hat{\beta}_2 \neq 0$)
13. Considere el modelo lineal, $y_i \sim (\beta_0 + x_{i1}\beta_1 + x_{i2}\beta_2, \sigma^2)$, $i = 1, 2, 3, 4$. Los datos se encuentran en la siguiente tabla:

Observación	y	x ₁	x ₂
1	6	1	2
2	1	-1	2
3	11	0	-3
4	3	0	-1

Table 2: Datos observados

- (a) Especifique el vector de respuestas y , el vector de parámetros y la matriz de diseño X .

Las matrices y vectores son los siguientes:

$$\mathbf{y} = \begin{bmatrix} 6 \\ 1 \\ 11 \\ 3 \end{bmatrix} \quad \mathbf{X} = \begin{bmatrix} 1 & 1 & 2 \\ 1 & -1 & 2 \\ 1 & 0 & -3 \\ 1 & 0 & -1 \end{bmatrix} \quad \boldsymbol{\beta} = \begin{bmatrix} \beta_1 \\ \beta_2 \\ \beta_3 \end{bmatrix}$$

Donde β_i , $i = 1, 2, 3$ será especificado en el siguiente apartado.

- (b) Estime
- $\beta_0, \beta_1, \beta_2, \sigma^2$
- .

Utilizando el estimador MCO y la varianza insesgada del error, tenemos:

$$\hat{\beta} = \begin{bmatrix} 5.25 \\ 2.5 \\ -1.22 \end{bmatrix} \quad \hat{\sigma}^2 = S^2 = 17.36$$

- (c) Encuentre el valor del coeficiente de determinación
- R^2
- para los datos entregados. ¿Puede concluir únicamente con esta información que el modelo se encuentra bien ajustado? Justifique.

Utilizando la fórmula entregada, obtenemos $R^2 = 0.6941$. Sólo con esta información no es posible determinar que el modelo está bien ajustado, ya que pueden afectar otras variables en $\mathbf{y}$ que no están añadidas al modelo, y añadirlas aumentaría considerablemente el valor. Sin embargo, asumiendo que no hay problemas con los datos, se tiene que aproximadamente el 70% de la varianza de la respuesta explica la varianza total.

- (d) Especifique el estadístico de prueba para el test de hipótesis
- $H_0 : \beta_i = 0$
- v/s
- $H_a : \beta_i \neq 0, i = 1, 2, 3$
- .

Utilizando el estadístico $t_i, i = 1, 2, 3$, obtenemos:

$$\mathbf{t} = \begin{bmatrix} 2.52 \\ 0.85 \\ -1.24 \end{bmatrix}$$

- (e) Para el test de hipótesis anterior, arme un intervalo de confianza que permita concluir respecto a la hipótesis nula. ¿Existe evidencia estadística para decir que el coeficiente
- β_i
- es significativo? Justifique para
- $i = 1, 2, 3$
- .

Sea $\alpha = 0.05$, podemos especificar los siguientes intervalos de confianza para los tests de hipótesis anteriores:

$$IC_{100(1-\alpha)\%}(\beta_1) = [-21.22126; 31.72126]$$

$$IC_{100(1-\alpha)\%}(\beta_2) = [-34.93601; 39.93601]$$

$$IC_{100(1-\alpha)\%}(\beta_3) = [-13.70089; 11.25645]$$

Notemos que en todos los casos se tiene que, al 95% de confianza, el valor de $\beta_i, i = 1, 2, 3$ puede tener el valor 0. Por lo tanto, no podemos asegurar que las variables x_i tengan efecto real en la respuesta.

14. Considere el modelo lineal $y_j \sim \mathcal{N}(\beta_0 + \sum_{i=1}^4 \beta_i x_{ij}, \sigma^2), j = 1, \dots, n$. Los resultados de aplicar el modelo se encuentran en la siguiente tabla:

Variable	Coefficient	Standard Error	t-Statistic	p-value
Constant	6.54	1.91	-	0.0014
x_1	-15.54	1.64	-9.46	0.0000
x_2	-	0.013	-2.56	0.0141
x_3	0.002	0.003	0.546	-
x_4	-0.00085	-	-2.28	-

Table 3: Datos observados

- (a) Explique qué significan los valores de i, j en el modelo lineal.

Los valores de j corresponden a la cantidad de datos del modelo, en tanto, los valores de i corresponden a la cantidad de variables (sin incluir el intercepto) en el modelo.

- (b) Rellene la tabla con los valores que no se encuentran en cada columna. ¿Cómo interpretaría cada coeficiente?

A continuación se presenta la tabla completa:

Variable	Coefficient	Standard Error	t-Statistic	p-value
Constant	6.54	1.91	3.42	0.0014
x_1	-15.54	1.64	-9.46	0.0000
x_2	-0.033	0.013	-2.56	0.0141
x_3	0.002	0.003	0.546	0.5886
x_4	-0.00085	0.000379	-2.28	0.029

Se debe notar que no conocemos el valor de $n - p$. Su cálculo se deja al lector¹.
Hint: Puede proponer una aproximación numérica.

- (c) Realice un intervalo de confianza para el parámetro asociado a la variable x_3 . ¿Existe evidencia estadística para decir que la variable tiene incidencia en la predicción?

Utilizamos $\alpha = 0.1, 0.05, 0.01$, luego tenemos los siguientes intervalos de confianza:

$$IC_{90\%}(\beta_3) = [-0.00307; 0.00707]$$

$$IC_{95\%}(\beta_3) = [-0.004098; 0.008098]$$

$$IC_{99\%}(\beta_3) = [-0.00619; 0.01019]$$

- (d) Para $\alpha = 0.1, 0.05, 0.01$. Identifique si se rechazaría o no la hipótesis nula asociada al test que presenta la tabla 3.

¹Si llegase a ser necesario, puedo responder en el foro cómo se calcula, pero la idea es que puedan realizarlo por su cuenta, ya que poseen los valores reales de la tabla.

De acuerdo al ejercicio anterior, podemos notar que para ningún valor de α se tiene que β_3 es estadísticamente distinto de cero, luego en ningún caso se rechaza la hipótesis nula.

15. Suponga que usted quiere estimar un modelo de regresión lineal simple del tipo: $y_i = \alpha + \beta x_i + \mu_i$.

- (a) Muestre qué pasaría en su estimación del coeficiente asociado a la variable independiente si usted en vez de observar x_i , cuenta con datos que incorporan un error aleatorio del tipo $x'_i = x_i + v_i$. Asuma que $Cov(v_i, x_i) = 0$.

Estimamos erróneamente la regresión $y_{i-erroneo} = \tilde{\alpha} + \tilde{\beta}x'_i + \tilde{\mu}_i$. El coeficiente de interés en este caso corresponde a:

$$\begin{aligned}\tilde{\beta} &= \frac{Cov(x'_i, y_i)}{Var(x'_i)} \\ &= \frac{Cov(x_i + v_i, y_i = \alpha + \beta x_i + \mu_i)}{Var(x_i + v_i)} \\ &= \beta \frac{Var(x_i)}{Var(x_i) + Var(v_i)}\end{aligned}$$

- (b) Explique qué puede decir de su estimación sobre el coeficiente de x_i al utilizar datos ruidosos de esta variable. ¿Qué significa eso en la práctica si usted no encuentra un coeficiente significativo?

La estimación sería sesgada, en particular el coeficiente real se ve ponderado por el factor $\frac{Var(x_i)}{Var(x_i) + Var(v_i)}$. Las condiciones necesarias para que no exista sesgo sería desaparecer el factor anterior de la ecuación:

$$\begin{aligned}\tilde{\beta} &= \beta \frac{Var(x_i)}{Var(x_i) + Var(v_i)} \\ \tilde{\beta} &= \beta \iff \frac{Var(x_i)}{Var(x_i) + Var(v_i)} = 1 \\ \implies \frac{Var(x_i)}{Var(x_i) + Var(v_i)} &= 1 \iff Var(v_i) = 0\end{aligned}$$

Es decir, si y solo si la varianza del error es nula. Más aún, podemos apreciar que $0 \leq \frac{Var(x_i)}{Var(x_i) + Var(v_i)} \leq 1$, luego $|\tilde{\beta}| \leq |\beta|$

16. Para una muestra de 32 motos distintas que pueden adquirirse en Chile se obtuvo; la velocidad máxima (y), la potencia en CV (x_1), la cilindrada en CC (x_2) y el número de cilindros (x_3). Se ajustó un modelo lineal y se obtuvo:

Coficiente	Estima	De($\hat{\beta}_j$)	
β_0	88.2	-	$R^2 = 0.86$
β_1	1.280	0.32	
β_2	0.0184	0.02	
β_3	0.610	3.46	

- (a) Interprete el coeficiente de determinación

El coeficiente de determinación nos indica que el 86% de la variación en la velocidad máxima de las motos es explicada por los datos.

- (b) Construya un intervalo de confianza al 95% para el incremento medio en la velocidad máxima cuando la potencia aumenta en un CV, dejando fijo la cilindrada y el número de cilindros.

Fijamos $\alpha = 0.05$. Notemos que como se espera el intervalo de confianza para el incremento promedio en la velocidad máxima cuando la potencia aumenta en un CV, *ceteris paribus*, tenemos que nos piden el intervalo de confianza para la interpretación del coeficiente $\hat{\beta}_1$. Por lo tanto, el intervalo de confianza corresponde al de β_1 :

$$IC_{95\%}(\beta_1) = [\hat{\beta}_1 - t_{1-\alpha/2, n-p} De(\hat{\beta}_1); \hat{\beta}_1 + t_{1-\alpha/2, n-p} De(\hat{\beta}_1)]$$

Reemplazando con los valores de la tabla, obtenemos

$$IC_{95\%}(\beta_1) = [0.6245; 1.9354]$$

Es evidente que el coeficiente es significativo.

- (c) Pruebe la hipótesis $H_0 : \beta_2 = 0$. Comente el resultado

Notemos que hay intercepto, luego el estadístico

$$t = \frac{\hat{\beta}_2}{De(\hat{\beta}_2)} = 0.92$$

Como fijamos $\alpha = 0.05$, tenemos que el valor crítico es $t_{0.975, 28} = 2.048407$. Como $t < t_{0.975, 28}$ no rechazamos H_0 , es decir, el coeficiente no es significativo.

17. Considere un modelo lineal normal con $\mu_i = x_{i1}\beta_1 + x_{i2}\beta_2$ para $i = 1, \dots, 15$. Las ecuaciones normales son

$$\begin{bmatrix} 15.00 & 374.50 \\ 374.50 & 9482.75 \end{bmatrix} \begin{bmatrix} \beta_1 \\ \beta_2 \end{bmatrix} = \begin{bmatrix} 6.03 \\ 158.25 \end{bmatrix}$$

y $y'y = 3.03$:

- (a) Estime los parámetros del modelo.

Podemos notar que $|X'X| = 1991$. Luego,

$$(X'X)^{-1} = \begin{bmatrix} 4.7628 & -0.188 \\ -0.188 & 0.00753 \end{bmatrix}$$

Por lo tanto,

$$\hat{\beta} = \begin{bmatrix} -1.0465 \\ 0.0580 \end{bmatrix}$$

- (b) Obtenga un IC del 98% para
- β_2
- .

Con un 90% de confianza,

$$IC_{98\%}(\beta_2) = [\hat{\beta}_2 - t_{1-\alpha/2, n-p} De(\hat{\beta}_2); \hat{\beta}_2 + t_{1-\alpha/2, n-p} De(\hat{\beta}_2)]$$

Debemos estimar $De(\hat{\beta}_2) = S\sqrt{(X'X)^{-1}_{22}}$ donde $S^2 = SCE/(n-p)$. Notemos que:

$$\begin{aligned} SCE &= (y - X\beta)'(y - X\beta) \\ &= y'y - 2y'X\beta + \beta'X'X\beta \end{aligned}$$

Notemos que $(X'y)' = y'X = [6.03 \quad 158.25]$. Luego, podemos utilizar los datos que tenemos de tal manera que

$$SCE = 3.03 - 2(2.870861) + 2.870861 = 0.15914$$

Por lo tanto, $S^2 = 0.01224146$ y se tiene $S = 0.1106411$. Además, $(X'X)^{-1}_{22} = 0.007533903$. Por lo tanto,

$$De(\hat{\beta}_2) = 0.009603436$$

Finalmente, reemplazando los valores para el intervalo de confianza, con $t_{1-\alpha/2, n-p} = t_{0.99, 13}$, tenemos

$$IC_{98\%}(\beta_2) = [0.03256651; 0.08347065]$$

- (c) Pruebe la hipótesis
- $H_0 : \beta_1 = 0.5$

Probamos la hipótesis nula mediante el estadístico

$$t_0 = \frac{\hat{\beta}_1 - 0.5}{De(\hat{\beta}_1)}$$

Podemos utilizar el mismo procedimiento que antes, con $S = 0.1106411$, para obtener $De(\hat{\beta}_1 = 0.2414616$. de esta manera, $t_0 = -6.404873$. Aquí notamos que $|t_0|$ es un valor bastante grande. Particularmente, cuando $|t_0|$ es mayor a 3, se podría decir que a una significancia de al menos 0.05, se rechazaría la hipótesis nula. Esto es porque se aleja bastante del centro en la distribución test. Podemos comprobar lo anterior numéricamente, mediante el valor-p. notemos que

$$valor - p = 2\mathbb{P}(t > t_0) = 0.000023254$$

Podemos notar que el valor-p es prácticamente 0. Así, para un gran intervalo de niveles de confianza α se tiene que el coeficiente es significativo. Particularmente, el coeficiente no sería significativo para un $\alpha < 0.000023254$, que en la práctica es muy difícil de escoger.

18. Suponga que b es el vector de coeficientes MCO en una regresión entre $X \in \mathbb{R}^{n \times p}$ e $y \in \mathbb{R}^n$, y suponga que c es cualquier otro vector de dimensión $p \times 1$. Pruebe que

$$(y - Xc)'(y - Xc) - (y - Xb)'(y - Xb) = (c - b)'X'X(c - b) \geq 0$$

Escribamos c tal que $c = b + (c - b)$. De esta manera, si tomamos c como nuestro vector de coeficientes (en el sentido representativo) podemos calcular SCE_c según

$$\begin{aligned} SCE_c &= (y - Xc)'(y - Xc) \\ &= (y - X(b + (c - b)))'(y - X(b + (c - b))) \\ &= (y - Xb + X(c - b))'(y - Xb + X(c - b)) \\ &= (y - Xb)'(y - Xb) + (c - b)'X'X(c - b) + 2(c - b)'X'(y - Xb) \end{aligned}$$

Notemos que $(y - Xb) = e$, los residuos de una regresión, y en el ejercicio 3.(a) se probó que la matriz de diseño es ortogonal a los residuos, es decir $X'e = 0$, por lo tanto,

$$2(c - b)'X'(y - Xb) = 2(c - b)'X'e = 0$$

luego,

$$SCE_c = e'e + (c - b)'X'X(c - b)$$

Recordar que el enunciado nos pide

$$\begin{aligned} (y - Xc)'(y - Xc) - (y - Xb)'(y - Xb) &= SCE_c - e'e \\ &= e'e + (c - b)'X'X(c - b) - e'e \\ &= (c - b)'X'X(c - b) \end{aligned}$$

luego probamos lo que se nos pedía. Para probar que $(c - b)'X'X(c - b) \geq 0$, definamos $v = X(c - b)$. Como $(c - b)$ es vector y X una transformación, se tiene que v es vector, y, particularmente,

$$(c - b)'X'X(c - b) = v'v$$

notemos que $v'v$ corresponde al producto interno en el espacio euclideo (producto punto), que particularmente es semi-positivo en este espacio, luego es evidente que $v'v \geq 0$.

19. En una regresión de y sobre una constante y X , para calcular el vector de coeficientes MCO en X , podemos: En primer lugar, transformar y tal que $y_{transformado,i} = y_i - \bar{y} \quad \forall i$, e igualmente transformar tal que $X_{transformado,i} = X_i - \bar{X}_i \quad \forall i$ (notar que a cada elemento de una columna se le resta la media de la columna). En segundo lugar, regresionar y transformado entre X transformado, sin incluir la constante. Responda: Si definimos $1 = [1, 1, \dots, 1]'$ como un vector de unos, de tamaño n , podemos notar que tenemos $M^0 = I_n - 1(1'1)^{-1}1'$. Particularmente, M^0 es la matriz que transforma las observaciones en las desviaciones respecto a la media de las columnas (puede demostrarse). Por lo tanto, según la terminología del problema tenemos

$$\begin{aligned} X_{transformado} &= M^0 X \\ y_{transformado} &= M^0 y \end{aligned}$$

Por FWL, podemos notar que M^0 es idempotente y simétrica. De esta manera, el coeficiente $\hat{\beta}$ puede ser calculado por MCO según

$$\hat{\beta} = ((X'M^0')(M^0X))^{-1}(X'M^0')(M^0y) \quad (13)$$

lo que implica que la regresión entre M^0y y M^0X produce el vector de coeficientes sin intercepto.

- (a) ¿Obtenemos el mismo resultado si sólo transformamos y ?

Si sólo y está transformado, tenemos $\hat{\beta} = (X'X)^{-1}X'M^0y$, que bajo ninguna transformación de identidad puede ser igual a (13), por lo tanto, no se obtiene el mismo resultado.

- (b) ¿Obtenemos el mismo resultado si sólo transformamos X ?

Si sólo X está transformado, tenemos $\hat{\beta} = ((X'M^0')(M^0X))^{-1}(X'M^0')y$, que como M^0 es simétrica e idempotente, puede llevarse idénticamente a (13), por lo tanto se obtiene el mismo resultado.

20. Suponga que el modelo de regresión es $y_i = \alpha + \beta x_i + e_i$, donde e_i cumple con $f(e_i) = 1/\lambda e^{(-\lambda e_i)}$, $e_i \geq 0$. Lo interesante de este modelo es que todas las perturbaciones son semi-positivas. Note que $\mathbb{E}(e_i | x_i) = \lambda$ y $\text{Var}(e_i | x_i) = \lambda^2$.

Notemos primeramente que el modelo de regresión entregado por el enunciado no cumple con los supuestos de regresión, ya que $\mathbb{E}[e_i] \neq 0$. Sea $\lambda \neq 0$. Definamos el siguiente modelo de regresión:

$$y_i = \alpha + \lambda + \beta x_i + e_i - \lambda \quad (14)$$

Podemos definir $\gamma = \alpha + \lambda$ y $\mu_i = e_i - \lambda$. De esta forma, se tiene que el modelo (14) puede ser escrito según

$$y_i = \gamma + \beta x_i + \mu_i \quad (15)$$

- (a) Pruebe que $\hat{\beta}$ es insesgado.

Notemos que para el modelo (15),

$$\begin{aligned} \mathbb{E}[\mu_i | x_i] &= \mathbb{E}[e_i - \lambda | x_i] \\ &= \mathbb{E}[e_i | x_i] - \mathbb{E}[\lambda | x_i] \\ &= \lambda - \lambda = 0 \end{aligned}$$

Por lo tanto, el modelo (15) si cumple con los supuestos usuales de regresión. Por ello, sabemos que el estimador MCO de γ y β es insesgado, luego evidentemente $\hat{\beta}$ es insesgado.

- (b) Pruebe que $\hat{\alpha}$ es sesgado.

Dado que el modelo dado por enunciado es simple, se tiene que $\hat{\alpha} = \bar{y} - \hat{\beta}\bar{x}$. Así, su esperanza,

$$\begin{aligned} \mathbb{E}[\hat{\alpha}] &= \mathbb{E}[\bar{y} - \hat{\beta}\bar{x}] \\ &= \mathbb{E}[\bar{y}] - \beta\bar{x} \end{aligned}$$

donde hemos usado, por el inciso anterior, que $\hat{\beta}$ es un estimador insesgado. Por definición de la media muestral, podemos escribir

$$\begin{aligned} \mathbb{E}[\bar{y}] &= \mathbb{E}\left[\frac{1}{n} \sum_{i=1}^n y_i\right] \\ &= \frac{1}{n} \sum_{i=1}^n \mathbb{E}[y_i] \\ &= \frac{1}{n} \sum_{i=1}^n \mathbb{E}[\alpha + \beta x_i + e_i] \\ &= \frac{1}{n} \sum_{i=1}^n (\alpha + \beta x_i + \mathbb{E}[e_i]) \\ &= \alpha + \beta\bar{x} + \lambda \end{aligned}$$

Por lo tanto, la esperanza del estimador de α es

$$\begin{aligned} \mathbb{E}[\hat{\alpha}] &= \mathbb{E}[\bar{y}] - \beta\bar{x} \\ &= \alpha + \beta\bar{x} + \lambda - \beta\bar{x} \\ &= \alpha + \lambda \end{aligned}$$

Dado que $\lambda \neq 0$ se tiene que $\hat{\alpha}$ es sesgado con un sesgo igual a λ .

21. Considere el modelo de regresión múltiple de y sobre p variables contenidas en la matriz de diseño X . Suponga que existe una variable adicional en el modelo, z . Pruebe que bajo los supuestos de regresión lineal, la varianza del estimador MCO del intercepto en X es más grande cuando z está incluido en la regresión que cuando no lo está. Asuma que $z \neq 0$ y que X, z no son estocásticas.

Este es un caso de adición de una variable irrelevante. Supongamos que estimamos la regresión

$$y = X\beta + z\gamma + \mu \quad (16)$$

Y tenemos otra regresión, que no incluye a z , según

$$y = Xb_1 + e \quad (17)$$

Queremos probar que la varianza del intercepto (incluido en β) en la regresión (16) es mayor que la varianza del intercepto en la regresión (17). Para ello, notamos que la varianza del estimador MCO de b_1 en (17) es

$$\text{Var} [\hat{b}_1] = \sigma^2(X'X)^{-1}$$

Definamos $b_2 = [\beta \ \gamma]$ (es decir, el vector de coeficientes en la regresión (16)). Notemos que por regresiones particionadas (FWL), podemos obtener la estimación de b_2 por MCO según:

$$\hat{b}_2 = (X'M_zX)^{-1}X'M_zy$$

donde $M_z = I - z(z'z)^{-1}z'$. Luego, por idempotencia y simetría de M_z tenemos que la varianza de $\hat{b}_2$ puede representarse según

$$\begin{aligned} \text{Var} [\hat{b}_2] &= \sigma^2(X'M'_zM_zX)^{-1} \\ &= \sigma^2(X'M_zX)^{-1} \end{aligned}$$

Entonces, consideremos

$$\begin{aligned} \left(\text{Var} [\hat{b}_1]\right)^{-1} - \left(\text{Var} [\hat{b}_2]\right)^{-1} &= \sigma^{-2}(X'X) - \sigma^{-2}(X'M_zX) \\ &= \sigma^{-2}((X'X) - (X'M_zX)) \\ &= \sigma^{-2}(X'(X - M_zX)) \\ &= \sigma^{-2}(X'((I - M_z)X)) \\ &= \sigma^{-2}(X'z(z'z)^{-1}z'X) \end{aligned}$$

Ahora, sea $a \in \mathbb{R}^p$ un vector tal que $a \neq 0$, entonces,

$$a' \left(\left(\text{Var} [\hat{b}_1] \right)^{-1} - \left(\text{Var} [\hat{b}_2] \right)^{-1} \right) a = \sigma^{-2} (a' X' z (z' z)^{-1} z' X a)$$

Notemos que $a' X' z \in \mathbb{R}$, $(z' X a)' = a' X' z$ y $(z' z)^{-1} \in \mathbb{R}$. Definamos $c = z' X a$, luego $c' = c$ por lo anterior, y tenemos:

$$a' \left(\left(\text{Var} [\hat{b}_1] \right)^{-1} - \left(\text{Var} [\hat{b}_2] \right)^{-1} \right) a = \sigma^{-2} \left(\frac{c^2}{z' z} \right) \geq 0$$

Se concluye que la diferencia entre la inversa de las varianzas es semidefinida positiva, por lo tanto, la diferencia entre varianzas es semidefinida negativa. Por ello, se concluye que²

$$\begin{aligned} \text{Var} [\hat{b}_1] - \text{Var} [\hat{b}_2] &\preceq 0 \\ \text{Var} [\hat{b}_1] &\preceq \text{Var} [\hat{b}_2] \end{aligned}$$

Que en palabras, quiere decir que la varianza de $\hat{b}_2$ es mayor que la varianza de $\hat{b}_1$. Particularmente, la varianza de los interceptos cumple esta propiedad, luego se demostró lo pedido.

22. Considere el modelo de regresión lineal múltiple $y_i \sim \mathcal{N}_n(X\beta, \sigma^2 I_n)$, con los supuestos usuales de regresión vistos en el curso. Se define

$$b = \beta + (X'X)^{-1} X' \epsilon$$

Demuestre que

$$\mathbb{E}(b'b) = \beta' \beta + \sigma^2 \text{Tr}[(X'X)^{-1}]$$

Notemos que

$$b'b = \beta' \beta + \epsilon' X (X'X)^{-1} (X'X)^{-1} X' \epsilon + 2\beta' (X'X)^{-1} X' \epsilon$$

Luego, su esperanza,

$$\begin{aligned} \mathbb{E}[b'b] &= \mathbb{E}[\beta' \beta + \epsilon' X (X'X)^{-1} (X'X)^{-1} X' \epsilon + 2\beta' (X'X)^{-1} X' \epsilon] \\ &= \beta' \beta + \mathbb{E}[\epsilon' X (X'X)^{-1} (X'X)^{-1} X' \epsilon] + 2\beta' (X'X)^{-1} X' \mathbb{E}[\epsilon] \\ &= \beta' \beta + \mathbb{E}[\epsilon' X (X'X)^{-1} (X'X)^{-1} X' \epsilon] \end{aligned}$$

Nos mencionan n observaciones en el enunciado. Asumiendo p parámetros, con $p \geq 1$, se tiene que $\epsilon \in \mathbb{R}^n$, $\beta \in \mathbb{R}^p$ y $X \in \mathbb{R}^{n \times p}$. De esta manera, es evidente que

²Los símbolos $\succeq$ y $\preceq$ indican semipositividad y seminegatividad de matrices respectivamente

$\epsilon'X(X'X)^{-1}(X'X)^{-1}X'\epsilon \in \mathbb{R}$, es decir, es un escalar. Por lo tanto, su traza es equivalente a su valor, es decir,

$$\epsilon'X(X'X)^{-1}(X'X)^{-1}X'\epsilon = \text{tr}(\epsilon'X(X'X)^{-1}(X'X)^{-1}X'\epsilon)$$

Por lo tanto,

$$\begin{aligned}\mathbb{E}[b'b] &= \beta'\beta + \mathbb{E}[\text{tr}(\epsilon'X(X'X)^{-1}(X'X)^{-1}X'\epsilon)] \\ &= \beta'\beta + \mathbb{E}[\text{tr}((X'X)^{-1}X'\epsilon\epsilon'X(X'X)^{-1})]\end{aligned}$$

donde en la última línea utilizamos la propiedad de que la traza es invariante ante permutaciones cíclicas. Se puede demostrar (aunque es conocido) que la traza y el operador de valor esperado pueden permutar en igualdad, es decir,

$$\mathbb{E}[\text{tr}(\cdot)] = \text{tr}(\mathbb{E}[\cdot])$$

Utilizando esto último, tenemos

$$\begin{aligned}\mathbb{E}[b'b] &= \beta'\beta + \mathbb{E}[\text{tr}((X'X)^{-1}X'\epsilon\epsilon'X(X'X)^{-1})] \\ &= \beta'\beta + \text{tr}(\mathbb{E}[(X'X)^{-1}X'\epsilon\epsilon'X(X'X)^{-1}]) \\ &= \beta'\beta + \text{tr}((X'X)^{-1}X'\mathbb{E}[\epsilon\epsilon']X(X'X)^{-1}) \\ &= \beta'\beta + \text{tr}((X'X)^{-1}X'\mathbb{E}[\epsilon\epsilon']X(X'X)^{-1})\end{aligned}$$

Notemos que, por los supuestos de regresión usuales, tenemos

$$\text{Var}[\epsilon] = \mathbb{E}[\epsilon\epsilon'] - \mathbb{E}[\epsilon]^2 = \sigma^2 I_n$$

Por lo tanto, sabiendo que $\mathbb{E}[\epsilon] = 0$ (por supuestos también), se puede despejar $\mathbb{E}[\epsilon\epsilon'] = \sigma^2 I_n$, así,

$$\begin{aligned}\mathbb{E}[b'b] &= \beta'\beta + \text{tr}((X'X)^{-1}X'\mathbb{E}[\epsilon\epsilon']X(X'X)^{-1}) \\ &= \beta'\beta + \text{tr}((X'X)^{-1}X'\sigma^2 I_n X(X'X)^{-1}) \\ &= \beta'\beta + \sigma^2 \text{tr}((X'X)^{-1}X'X(X'X)^{-1}) \\ &= \beta'\beta + \sigma^2 \text{tr}((X'X)^{-1})\end{aligned}$$

que es lo que se pedía.

23. Considere la transformación lineal preservante de dimensión $T : \mathbb{R} \rightarrow \mathbb{R}$. En un modelo lineal simple sin intercepto. Pruebe que transformar la variable independiente según T resulta en el estimador MCO

$$\hat{\beta} = \frac{\sum_{i=1}^n T x_i y_i}{\sum_{i=1}^n (T x_i)^2}$$

Comente las principales implicancias de esta fórmula.

La transformación lineal permite definir una nueva matriz de diseño. Comencemos notando que el modelo no tiene intercepto, luego

$$X = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}$$

Aplicando la transformación T a la matriz de diseño, se obtiene,

$$TX = \begin{bmatrix} Tx_1 \\ Tx_2 \\ \vdots \\ Tx_n \end{bmatrix}$$

Por lo tanto, podemos utilizar la fórmula de MCO con TX , $(TX'TX)^{-1}TX'y$. Realizando el trabajo matricial se obtiene,

$$\hat{\beta} = \frac{\sum_{i=1}^n Tx_i y_i}{\sum_{i=1}^n (Tx_i)^2}$$

La gran conclusión de esto es que la transformación es cualquiera, por lo tanto, se puede enunciar la siguiente proposición:

Proposición (de las soluciones simples sin intercepto): *Para cualquier modelo lineal simple sin intercepto, el estimador $\hat{\beta}$ puede ser calculado según:*

$$\hat{\beta} = \frac{\sum_{i=1}^n x_i y_i}{\sum_{i=1}^n (x_i)^2}$$

Demostración: $Tx = x$ es una transformación lineal. Luego aplicar lo demostrado previamente. $\square$

24. Observe los resultados de una regresión lineal entre el logaritmo natural del ingreso, años de educación, educación de la madre y número de hijos.

	(1) log(<i>salario</i>)
Años de educación	0.118 (0.0156307)
Número de hijos	-0.04 (0.025)
Años de educación de la madre	-0.0203 (-)
Constante	- (0.1920918)
N	428

Errores estándar entre paréntesis
⁺ $p < 0.10$, ^{*} $p < 0.05$
 Valor crítico del t-test al 5% de significancia para esta regresión: 1.96

y considere que para la hipótesis

$$H_0 : \beta_{\text{constante}} = 0.5 \quad v/s \quad H_a : \beta_{\text{constante}} \neq 0.5$$

se obtuvo un estadístico $t_{\text{constante}} = -2.83875$. Por otra parte, el intervalo de confianza al 95% para los años de educación de la madre corresponde a $[-0.0413958; 0.000795872]$.

- (a) ¿Considera usted que los años de educación de la madre tienen un impacto real en el logaritmo natural del ingreso? Justifique.

Únicamente interpretando el coeficiente asociado a los años de educación de la madre, es evidente que existe una correlación negativa entre el logaritmo de los salarios y esta variable. Aún así, únicamente con los datos de la tabla es imposible deducir si existe o no un impacto significativo en el salario, esto es porque puede que existan variables que no estén consideradas en el modelo. Más aún, se puede ver que la variable no es significativa (por el intervalo de confianza).

- (b) Complete la tabla presentada en el enunciado. ¿Cómo interpretaría los años de educación de la madre?

Se puede completar la tabla primeramente utilizando la igualdad

$$t_{\text{constante}} = \frac{\hat{\beta}_{cte} - \gamma}{Sd(\beta_{cte})}$$

reemplazando y despejando, $\hat{\beta}_{cte} = -0.0453$. Por otra parte, para la desviación estándar del coeficiente asociado a la madre, se puede utilizar la igualdad

$$-0.0413958 = \hat{\beta}_{mama} + tSd(\beta_{mama})$$

Despejando la desviación estándar se tiene que $Sd(\beta_{mama}) = 0.01076$. Luego, la tabla completa es

	(1)
	Log(salario)
Años de educación	0.118 (0.0156307)
Número de hijos	-0.04 (0.025)
Años de educación de la madre	-0.0203 (0.01076)
Constante	-0.0453 (0.1920918)
N	428

Errores estándar entre paréntesis
⁺ $p < 0.10$, ^{*} $p < 0.05$
 Valor crítico del t-test al 5% de significancia para esta regresión: 1.96

- (c) Defina una hipótesis nula que permita testear la significancia del coeficiente de número de hijos y calcule el t -test de ese coeficiente.

El test de hipótesis para testear significancia del coeficiente puede definirse de la siguiente manera:

$$H_0 : \beta_{hijos} = 0 \quad v/s \quad H_a : \beta_{hijos} \neq 0$$

Con esta definición, el estadístico de prueba es el siguiente:

$$t_{hijos} = \frac{\hat{\beta}_{hijos}}{Sd(\beta_{hijos})} = -1.6$$

- (d) Según la información de la tabla, ¿qué concluiría usted de la influencia del número de hijos en el ingreso?

Podemos notar que el valor crítico para el t-test está dado por la tabla, equivalente a 1.96, luego como la hipótesis del t-test es de doble cola, tenemos que no rechazamos H_0 si $-1.96 < t < 1.96$ para el t definido en el ítem anterior. Para $\gamma = 0$, tenemos que $t = 1.6$, luego no rechazamos H_0 , es decir, no existe evidencia estadística suficiente para decir que el coeficiente asociado al número de hijos pueda ser distinto de 0. En conclusión, utilizando el modelo descrito no podemos concluir que el número de hijos tenga un efecto lineal en el logaritmo de los ingresos, luego el coeficiente no es significativo.

Lo anterior puede interpretarse en la siguiente imagen:




Figura 1: Interpretación gráfica del test de hipótesis.

En la Figura 1, se presenta la distribución aproximada del coeficiente β_{hijos} . El 95% de los datos se encuentra en la zona de color azul claro, y en esa zona **no se rechaza la hipótesis nula**. Por otra parte, en los extremos se encuentra el resto de los datos, y en esa zona **se rechaza la hipótesis nula**. Puede notarse que el estadístico de prueba $t = -1.6$ se encuentra en la zona donde no se rechaza la hipótesis, luego con un 95% de confianza (o 5% de significancia) se puede decir que el coeficiente no es significativo (no se rechaza H_0). Debe notarse que por la tabla se tiene el nivel de significancia en los valores críticos. Para otra significancia, se tendrían otros valores y por lo tanto otras áreas.

25. Considere el modelo lineal $y = X\beta + \varepsilon$ con los supuestos usuales de regresión, n observaciones y p parámetros. Usando la descomposición en valores singulares se puede obtener

$$y = X\beta + \varepsilon = U\Lambda V'\beta + \varepsilon = U\gamma + \varepsilon$$

donde $\gamma = \Lambda V'\beta$

Hint: Recuerde de álgebra lineal que la descomposición en valores singulares entrega a U y V como matrices ortonormales, y a Λ como una matriz diagonal.

- (a) Muestre que $\hat{\gamma} = U'y$ y demuestre que $\hat{\beta} = V(U\Lambda)^{-1}y$.

Notemos que nada nos impide usar MCO, por lo tanto,

$$\begin{aligned}\hat{\gamma} &= (U'U)^{-1}U'y \\ &= U'y\end{aligned}$$

donde en la última línea utilizamos que la matriz U es ortonormal, es decir $U'U = I$. Para demostrar la representación de $\hat{\beta}$, notemos:

$$\hat{\gamma} = \Lambda V' \hat{\beta}$$

porque los estimadores MCO son insesgados, luego,

$$\begin{aligned}\hat{\beta} &= (\Lambda V')^{-1} \hat{\gamma} \\ &= (V')^{-1} \Lambda^{-1} \hat{\gamma} \\ &= V \Lambda^{-1} U' y \\ &= V(U\Lambda)^{-1} y\end{aligned}$$

Donde utilizamos que como V es ortogonal, $V' = V^{-1}$ y como U también es ortogonal, $U' = U^{-1}$.

- (b) Demuestre que $\hat{\beta}$ es un estimador insesgado.

Por definición:

$$\begin{aligned}\mathbb{E} [\hat{\beta}] &= V(U\Lambda)^{-1} y \\ &= V(U\Lambda)^{-1} U \Lambda V' \beta \\ &= V' V \beta \\ &= \beta\end{aligned}$$

donde hemos usado que $V'V = I$

- (c) Demuestre que $\text{Var} [\hat{\gamma}] = \sigma^2$

Utilizando álgebra de MCO,

$$\text{Var} [\hat{\gamma}] = \sigma^2 (U'U)^{-1} = \sigma^2$$

- (d) Demuestre que, en este caso, $SCE = y'y - \sum_{i=1}^p \hat{\gamma}_i^2$.

Por definición,

$$\begin{aligned}\varepsilon' \varepsilon &= (y - U\hat{\gamma})'(y - U\hat{\gamma}) \\ &= y'y - 2\hat{\gamma}'U'y + \hat{\gamma}'U'U\hat{\gamma} \\ &= y'y - 2\hat{\gamma}'U'(U\hat{\gamma}) + \hat{\gamma}'U'U\hat{\gamma} \\ &= y'y - \hat{\gamma}'U'U\hat{\gamma} \\ &= y'y - \hat{\gamma}'\hat{\gamma}\end{aligned}$$

que demuestra lo pedido.

26. Dado el modelo $Y_t = \beta_1 + \beta_2 X_{2t} + \beta_3 X_{3t} + \beta_4 X_{4t} + u_t$, utilizando una muestra de 20 datos, se procedió a su estimación, obteniéndose:

$$Y_t = 8.34 + 0.7X_{2t} - 0.4X_{3t} + 0.1X_{4t}$$

Con:

- $R^2 = 0.96$
- $SE(\hat{\beta}_2) = 0.56$
- $SE(\hat{\beta}_3) = 0.7$
- $SE(\hat{\beta}_4) = 0.5$

- a) Analice un posible problema de multicolinealidad.

Se sabe que, para un nivel de confianza del 95% y un tamaño de muestra de 20, los grados de libertad son:

$$\text{Grados de libertad} = n - k - 1 = 20 - 3 - 1 = 16$$

El valor crítico de t por lo tanto es $t_{16}(0.975) = 2.12$

Luego, se calcula el valor t para cada coeficiente:

– Para β_2 :

$$t_2 = \frac{0.7}{0.56} \approx 1.25 < 2.12$$

– Para β_3 :

$$t_3 = \frac{-0.4}{0.7} \approx -0.57 < 2.12$$

– Para β_4 :

$$t_4 = \frac{0.1}{0.5} \approx 0.20 < 2.12$$

Puesto que todos los valores son menores al valor crítico, ningún coeficiente es significativo.

Esto sugiere que, a pesar de un alto R^2 , los coeficientes individuales no son estadísticamente significativos. Esto podría ser una señal de multicolinealidad en el modelo, donde las variables independientes están correlacionadas entre sí, inflando los errores estándar y reduciendo la significancia de los coeficientes.

- b) Si hay algún problema, indique la forma más adecuada de solucionarlo

Para abordar la posible multicolinealidad se deben eliminar las variables correlacionadas en el modelo, a través de un análisis de la matriz de correlación. Si alguna de las correlaciones es alta (por ejemplo, mayor a 0.8 o menor a -0.8), esto indica que las variables independientes están altamente correlacionadas. La alta correlación sugiere que una variable puede estar prediciendo información similar a la de otra, lo cual puede inflar los errores estándar de los coeficientes y reducir la significancia de los mismos.

27. En un estudio acerca de cómo utilizan las tarjetas de crédito los estudiantes no titulados, se reportó que este tipo de población tiene un saldo medio en su tarjeta de crédito de US\$3173 (Sallie Mae, abril de 2009). Tal cifra fue la más alta de todos los tiempos y tuvo un incremento de 44% sobre la de los cinco años previos. Suponga que se realiza un estudio actual para determinar si es posible concluir que el saldo medio en la tarjeta de crédito de estudiantes no titulados ha continuado en aumento comparado con el informe de abril de 2009. Con base en reportes previos, utilice una desviación estándar poblacional de $\sigma = US\$1.000,1$

a) Establezca las hipótesis nula y alternativa.

Queremos determinar si el saldo medio en la tarjeta de crédito ha aumentado comparado con el saldo medio reportado en abril de 2009.

– **Hipótesis nula** (H_0): $\mu \leq 3173$

– **Hipótesis alternativa** (H_a): $\mu > 3173$

Este es un test de una sola cola (cola superior).

b) ¿Cuál es el valor-p de una muestra de 180 estudiantes no titulados con un saldo medio muestral en su tarjeta de crédito de \$3325?

El estadístico de prueba Z se calcula como:

$$Z = \frac{\bar{X} - \mu_0}{\frac{\sigma}{\sqrt{n}}}$$

donde:

– $\bar{X} = 3325$

– $\mu_0 = 3173$

– $\sigma = 1000$

– $n = 180$

Sustituyendo estos valores se obtiene el estadístico Z :

$$Z = \frac{3325 - 3173}{\frac{1000}{\sqrt{180}}} = 2.04$$

– La función de distribución acumulativa $\Phi(Z)$ para $Z = 2.04 \approx 0.9793$.

– Por lo tanto, el valor-p es:

$$\text{Valor-p} = 1 - \Phi(Z) = 1 - 0.9793 = 0.0207$$

c) Usando un nivel de significancia de 0.05, ¿cuál es su conclusión?

Comparando el valor-p con el nivel de significancia $\alpha = 0.05$:

$$\text{Valor-p} = 0.0207$$

Dado que $0.0207 < 0.05$, rechazamos la hipótesis nula. Por lo tanto, podemos concluir que el saldo medio en la tarjeta de crédito de los estudiantes no titulados ha aumentado comparado con el saldo reportado en abril de 2009.

28. La superintendencia de Pensiones informa una serie de bases de datos públicas. Una de ellas corresponde al número total de cotizantes hombres por ingreso imponible en el sistema de AFP. Con los datos de esta base, actualizados a diciembre de 2017, se ha realizado una regresión simple (con Excel) entre el número de cotizantes varones y el ingreso imponible (en Miles de \$), dando como resultado:

Estadística	
Coeficiente de correlación múltiple	0.79702894
Coeficiente de determinación R^2	0.63525514
R^2 ajustado	0.62309697
Error típico	39.9394381
Número de observaciones	32

Coeficiente	Estimación	Error típico
Intercepto	185.05289	16.1535836
Ingreso Imponible	-0.00011055	1.5294E-05

- a) Determine la suma de cuadrados de los residuales

La suma de cuadrados de los residuales se calcula usando la varianza de la regresión, que es el cuadrado del error típico de la regresión, y el número de observaciones:

$$SCR = \sum \hat{u}^2 = \hat{\sigma}^2(n - 2)$$

$$SCR = 39.9394381^2 \times (32 - 2) = 47854.76$$

- b) Determine la suma de cuadrados totales

$$r^2 = 1 - \frac{SCR}{SCT} \rightarrow SCT = \frac{1 - r^2}{SCR}$$

En este caso, r^2 corresponde al Coeficiente de determinación R^2 . Reemplazando los valores, queda:

$$SCT = 131200.645$$

- c) ¿Qué tan precisa es la estimación de los coeficientes de la regresión?

La precisión de los coeficientes de la regresión se puede expresar en términos de porcentaje del error estándar sobre el valor del coeficiente estimado. Para el coeficiente de intercepto:

$$\text{Precisión del Intercepto} = \frac{16.1535836}{185.05289} \cdot 100 \approx 8.7\%$$

Para el coeficiente de pendiente:

$$\text{Precisión de la Pendiente} = \frac{1.5294 \cdot 10^{-5}}{0.00011055} \cdot 100 \approx 13.83\%$$

Un valor del 13.83% indica que el error estándar representa aproximadamente el 13.83% del valor estimado de la pendiente. La precisión relativamente baja sugiere que la estimación de la pendiente es menos confiable y podría no reflejar con exactitud el impacto del ingreso imponible en el número de cotizantes.

- d) ¿Qué puede decir del resultado de esta regresión en cuanto a su calidad para estimar los verdaderos parámetros de la regresión? Justifique clara y detalladamente. Los coeficientes, tanto de intercepción como de pendiente son poco precisos, dado que el de intercepción es cercano al 10% y el de pendiente, es casi un 14%. Lo anterior también se ve reflejado en que el coeficiente de determinación R^2 es bajo para ser una regresión simple. Según este valor, las variaciones de la variable explicativa Ingreso imponible, sólo explican el 63.5% de las variaciones en el número de cotizantes hombres del sistema de AFP chileno. Lo anterior significa que hay efectos importantes no considerados explícitamente en el modelo y que están incluidos en los u_i .
- e) ¿Qué variables explicativas incluiría usted en la regresión? Fundamente su respuesta

Pueden haber muchas variables, como por ejemplo:

- **La tasa de desempleo:** Mide el porcentaje de personas activamente buscando trabajo que no pueden encontrar empleo. Un aumento en esta tasa puede indicar una contracción económica, lo que podría llevar a una disminución en el número de cotizantes.
- **La proporción de trabajadores con contratos honorarios:** Representa la proporción de trabajadores que tienen contratos honorarios en lugar de contratos dependientes. Esta proporción puede indicar qué tan significativa es la categoría de trabajadores no cotizantes y cómo afecta el número total de cotizantes, pues los trabajadores a honorarios no tienen obligación de cotizar mensualmente.
- **El crecimiento del porcentaje de participación laboral femenina:** Mide el cambio en la participación de las mujeres en el mercado laboral. Un aumento podría afectar la composición del mercado laboral y, por ende, la cantidad de cotizantes masculinos.
- **La tasa de crecimiento del PIB trimestral (IMACEC):** Indica el crecimiento económico en términos trimestrales. Un crecimiento económico positivo suele estar asociado con un mayor empleo formal o con contrato dependiente, lo cual puede incrementar el número de cotizantes.

29. Los siguientes resultados corresponden a la estimación de un modelo econométrico simple que trata de explicar la relación entre la cantidad de suscripciones a revistas

económicas en USA el año 2000 (subs) a partir de la razón entre la variable precio y la variable número de citas de dichas revistas (Price/citations). Interprete y analice detalladamente dichos resultados, incluido el tipo de datos usados.


Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	4.7662	0.0559	85.2	<2e-16
log(price/citations)	-0.5331	0.0356	-15.0	<2e-16

Residual standard error: 0.75 on 178 degrees of freedom

Multiple R-squared: 0.557, Adjusted R-squared: 0.555

F-statistic: 224 on 1 and 178 DF, p-value: <2e-16



- Los datos corresponden a datos transversales, dado que se ha medido el número de suscripciones (variable subs), el precio (variable Price) y el número de citas (variable citations) para distintas revistas de Estados Unidos en el mismo tiempo (año 2000)
- Este es un modelo lineal simple, con forma funcional log-log, doble log o loglineal
- Dada la forma funcional de las variables, el coeficiente de pendiente proporciona la elasticidad (precio/citación) de la cantidad de suscripciones, de manera directa. Así, esta elasticidad es negativa y equivalente a -0.5331.
- La relación negativa entre el logaritmo de la variable dependiente y el logaritmo de la regresora se aprecia además en el gráfico reportado. El signo de esta elasticidad

es respaldado por la teoría económica, que señala que, para la mayoría de los bienes, la cantidad demandada decrece con el precio. Así, el aumento en un 1% de la relación precio a citas implicará una disminución de 0.53% en el número (o cantidad) de suscripciones.

- Los resultados del modelo son bastante buenos:
 - El coeficiente de determinación es superior a 0.5, es decir, la variación de la relación precio a citas explica al menos la mitad de la variación en la cantidad de suscripciones.
 - Los signos de los coeficientes son los esperados
 - Las estimaciones son bastante precisas. Para el intercepto, el error estándar corresponde a 1.1% del valor estimado, mientras que, para el coeficiente de pendiente, corresponde al 6.7%.
 - Los coeficientes son estadísticamente significativos de acuerdo al valor-p de los estadísticos t de cada estimador. (son prácticamente 0).
 - El valor del estadístico F y su correspondiente valor-p confirman la significancia estadística del coeficiente de pendiente, por lo que se rechaza la hipótesis nula que el valor de ese parámetro sea nulo.

30. Sea *niños* la cantidad de hijos que ha tenido una mujer, y *educ* los años de educación que tiene esta mujer. Un modelo sencillo para relacionar fertilidad con años de educación es:

$$niños = \alpha + \beta \cdot educ + \nu$$

donde ν es el error no observado.

- a) ¿Qué tipo de factores son los contenidos en ν ? ¿Es posible que estos factores estén correlacionados con el nivel de educación?

Tal y como se vio en clase, el error captura todos los factores no observables que afectan la cantidad de hijos que tiene una mujer pero que no están incluidos explícitamente en el modelo. Un ejemplo de esto podría ser el nivel de ingresos familiares.

- b) ¿Es posible que con un análisis de regresión simple se halle el efecto *ceteris paribus* de educación sobre fertilidad? Explique.

Al estimar una regresión simple, se obtiene la relación entre los años de educación y la cantidad de hijos que ha tenido la madre sin controlar por otros factores que podrían influir en la relación. Para que el coeficiente β represente el efecto *ceteris paribus* de la educación sobre la cantidad de hijos, se requiere que la variable independiente *educ* sea exógena.

En la realidad, es muy probable que haya variables omitidas (como ingreso) que afecten tanto la educación como la fertilidad, generando un sesgo en la estimación.

31. En la tabla siguiente se presentan las puntuaciones obtenidas en el examen de ingreso a la universidad en Estados Unidos, ACT (American College Test), y en el GPA (promedio escolar) por ocho estudiantes universitarios. El GPA está medido en una escala de cuatro puntos y se ha redondeado a un dígito después del punto decimal.

Estudiante	GPA	ACT
1	2.8	21
2	3.4	24
3	3.0	26
4	3.5	27
5	3.6	29
6	3.0	25
7	2.7	25
8	3.7	30

- a) Estime la relación entre GPA y ACT empleando MCO; es decir, obtenga las estimaciones para la pendiente y para el intercepto en la ecuación

$$\widehat{GPA} = \hat{\alpha} + \hat{\beta}ACT$$

Comente la dirección de la relación ¿tiene, en este caso, el intercepto una interpretación útil? Explique, ¿qué tanto más alto será el GPA predicho si ACT aumenta cinco puntos?

Ingresando los vectores de cada variable en R y estimando de forma matricial, se obtiene:

$$\hat{\beta} = 0.10220$$

$$\hat{\alpha} = 0.56813$$

Al observar el valor de β se puede ver que la relación entre el GPA y el ACT es positiva, ya que la pendiente es 0.10220, es decir, al aumentar el puntaje del ACT, también lo hace el GPA.

Por otro lado, al ver que el valor de α es igual a 0.56813, se puede decir que si el promedio escolar (GPA) fuese cero, se estima que la puntuación en los ACT sería igual a 0.56813.

Por último, sabemos que: $\delta(GPA) = \beta \cdot \delta(ACT)$ por ende, si el puntaje obtenidos en los ACT es 5 puntos más alto, el promedio escolar GPA sería 5 veces β , es decir, 0.511.

Estudiante	GPA	ACT	Valores Ajustados	Residuales
1	2.8	21	2.714286	0.08571429
2	3.4	24	3.020879	0.37912088
3	3.0	26	3.225275	-0.22527473
4	3.5	27	3.327473	0.17252747
5	3.6	29	3.531868	0.06813187
6	3.0	25	3.123077	-0.12307692
7	2.7	25	3.123077	-0.42307692
8	3.7	30	3.634066	0.06593407

- b) Calcule los valores ajustados y los residuales para cada observación y verifique que los residuales (aproximadamente) sumen cero. Se obtienen los residuos a partir de los valores estimados calculados con la regresión propuesta en el inciso anterior. Además, al sumar los residuos se obtiene un total $-4.163336 \cdot 10^{-17}$, lo que efectivamente, se aproxima a cero.
- c) ¿Cuál es el valor que se predice para el GPA si $ACT = 20$?
Utilizando la regresión entregada en el inciso a), se tiene:

$$\widehat{GPA} = 0.56813 + 0.10220 \cdot ACT$$

$$\widehat{GPA} = 0.56813 + 0.10220 \cdot 20$$

$$\widehat{GPA} = 0.56813 + 2.044$$

$$\widehat{GPA} = 2.61213$$

32. En la función lineal de consumo

$$\widehat{cons} = \hat{\alpha} + \hat{\beta} \cdot inc$$

la propensión marginal a consumir estimada (PMgC) del ingreso no es más que la pendiente, $\hat{\beta}$, mientras que la propensión media a consumir (PMeC) es $\widehat{cons}$. Usando las observaciones sobre ingreso anual y consumo de 100 familias (ambos medidos en dólares), se obtiene la ecuación siguiente:

$$\widehat{cons} = -124.84 + 0.853 \cdot inc$$

- a) Interprete el intercepto en esta ecuación y analice su signo y su magnitud.
Que el intercepto sea igual a -124,84 representa que el consumo estimado cuando el ingreso es igual a cero es de -124,84. En la realidad, uno no puede consumir valores negativos, por lo que el valor del intercepto nos da indicios de que la regresión es válida para un rango razonable de ingresos.
- b) ¿Cuál es el consumo que se predice si el ingreso familiar es de \$30,000 ?

Utilizando la regresión entregada en el enunciado, se tiene:

$$\widehat{\text{cons}} = -124.84 + 0.853 \cdot 30000$$

$$\widehat{\text{cons}} = -124.84 + 25590$$

$$\widehat{\text{cons}} = 25465.16$$

33. Derive el vector β de MCO utilizando álgebra de mínimos cuadrados. Muestre que la condición de primer orden y explique cómo podría asegurar que la solución encontrada es un mínimo y no un máximo de la función objetivo.

Queremos conocer los parámetros del modelo:

$$y = X\beta + \epsilon$$

Donde, X es de $n \times k$, ϵ, y son de $n \times 1$ y β es de $k \times 1$. Podemos escribir $e_i = y_i - x'_i b_0$ para cada observación i , para luego resolver el problema:

$$\min SSR(b_0) = \sum_{i=1}^n (y_i - x'_i b_0)^2 = \sum_{i=1}^n (y_i - x'_i b_0)(y_i - x'_i b_0)$$

Es fácil ver que $SSR(b_0) = y'y - 2y'Xb_0 + b'_0X'Xb_0$. Luego la condición de primer orden:

$$\frac{\partial SSR(b_0)}{\partial b_0} = -2X'y + 2X'Xb_0 = 0$$

Que se puede reescribir como: $X'Xb = X'y \Rightarrow b = (X'X)^{-1} X'y$

Para asegurarnos que el vector b_0 encontrado representa un punto mínimo de $SSR(b_0)$ utilizamos la condición de segundo orden:

$$\frac{\partial^2 SSR(b_0)}{\partial b_0^2} = X'X > 0$$

Necesitamos mostrar que $A = X'X$ es definida positiva, lo que se cumple si:

$$c'Ac \geq 0'X'Xc \geq 0 \forall c$$

Lo que se puede escribir como $q = v'v = \sum_{i=1}^n v_i^2$, donde $v = Xc$. A menos que todos los elementos de v sean cero, $q > 0$. (Lo que no tiene sentido dado que X tiene rango máximo).

34. Muestre que el método de momentos identifica la misma solución (β) que el mínimo de cuadrados ordinarios (MCO). Explique los principales supuestos utilizados.

Se tiene que $u_i = y_i - \beta_1 - \beta_2 X_i$ y sabemos que $E(u_i) = 0(1)$.

Luego de (1):

$$\frac{1}{n} \sum u_i = \frac{1}{n} \sum_{i=1}^n (y_i - \beta_1 - \beta_2 X_i) = 0$$

Estableciendo la siguiente condición: $E(u_i X_i) = 0$, y teniendo $\frac{1}{n} \sum_{i=1}^n (y_i - \beta_1 - \beta_2 X_i) = 0$ (2). Luego reescribiendo (1) y (2):

$$\begin{aligned} (1) \quad & \beta_1 + \left(\frac{1}{n} \sum_{i=1}^n X_i \right) \beta_2 = \frac{1}{n} \sum_{i=1}^n y_i \\ (2) \quad & \left(\frac{1}{n} \sum_{i=1}^n X_i \right) \beta_1 + \left(\frac{1}{n} \sum_{i=1}^n X_i^2 \right) \beta_2 = \frac{1}{n} \sum_{i=1}^n X_i y_i \end{aligned}$$

Multiplicando todo por n , se puede ver que corresponde a un caso similar al de regresiones particionadas usando $\mathbf{X} = [1, X]$ donde:

$$\mathbf{X}'\mathbf{X} = (1, X)'(1, X) = \begin{bmatrix} \sum 1 & \sum X_i \\ \sum X_i & \sum X_i^2 \end{bmatrix}$$

Y también:

$$X'y = (1, X)'y = \left(\sum y_i, \sum x_i y_i \right)'$$

De donde se ve que las ecuaciones (1) y (2) son:

$$(X'X) \beta = X'y \Rightarrow \hat{\beta} = (X'X)^{-1} X'y$$

Que es precisamente β_{MCO}

35. Muestre que el método de máxima verosimilitud identifica la misma solución (β) que el mínimo de cuadrados ordinarios (MCO). Explique los principales supuestos utilizados.

Para demostrar que $\hat{\beta}_{MLE} = \hat{\beta}_{MCO}$ solo se necesita asumir que $u \sim N(0, \sigma^2 I)$. El modelo de regresión lineal clásico es $y = X\beta + u$. Luego definimos la función de verosimilitud L . Para ello, debemos contar con un supuesto de y :

$$f(y, \beta, \sigma) = \frac{1}{\sigma \sqrt{2\pi}} \exp \left(-\frac{(y'X\beta)^2}{2\sigma^2} \right)$$

(La distribución normal)

En la práctica, queremos maximizar L lo que es equivalente a $\max \log(L)$, ya que $\log(\cdot)$ es una función monótonica. Definamos:

$$l = \log(L) = \frac{-1}{2} \log(2\pi) - \frac{1}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} (y - X\beta)^2$$

Asumiendo que las observaciones son independientes, l es simplemente la suma de las contribuciones residuales

$$l(y, \beta, \sigma) = \frac{-n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} (y - X\beta)'(y - X\beta) \quad (1)$$

Luego, derivando respecto a σ :

$$\frac{\partial l}{\partial \sigma} = \frac{-n}{\sigma} + \frac{1}{\sigma^3} (y - X\beta)'(y - X\beta) = 0$$

Recordemos que: $\hat{\sigma}^2(\beta) = \frac{1}{n} (y - X\beta)'(y - X\beta)$

Sustituyendo en (1), tenemos que:

$$l(y, \beta, \sigma) = \frac{-n}{2} (1 + \log(2\pi) - \log(n)) - \frac{n}{2} SSR(\hat{\beta})$$

Que resulta equivalente al problema MCO:

$$\max_{\hat{\beta}} l(y, \hat{\beta}, \hat{\sigma}) = \min_{b_0} SSR(b_0)$$

36. Conteste verdadero o falso y justifique la respuesta.

- (a) Las ecuaciones normales del modelo de regresión lineal múltiple indica que el vector de residuos del MCO es ortogonal al vector de valores estimados $\hat{y}$. Verdadero. Las ecuaciones normales del modelo de regresión lineal múltiple pueden escribirse como:

$$-2X'y + 2X'X\hat{\beta} = 0$$

$$X'y - X'X\hat{\beta} = 0$$

$$X'(y - X\hat{\beta}) = 0$$

Se puede observar que las ecuaciones normales implican que la matriz de información X sea ortogonal al vector de residuos $\hat{u}$, y esto implica que el vector de residuos sea ortogonal al vector de valores estimados $\hat{y}$.

$$(X\hat{\beta})'\hat{u} = 0$$

$$\hat{\beta}'X'\hat{u} = 0$$

Esto último se da porque se asume que el vector $\hat{\beta}$ no puede ser 0.

- (b) Si las variables que intervienen en un modelo de regresión lineal simple están en desviaciones con respecto de su propia media, entonces la línea de regresión estimada debe pasar a través del origen. Verdadero. El modelo de regresión simple con variables en desviaciones con respecto a su propia media puede ser escrito como:

$$\forall i : y_i^* = \alpha + \beta x_i^* + u_i$$

Donde y_i^* y x_i^* son las variables en desviaciones con respecto a su media. Teniendo en cuenta que la media muestral de x^* y y^* son 0. Los estimadores MCO del modelo son simplemente:

$$\hat{\beta} = \frac{\sum_i x_i^* y_i^*}{\sum_i x_i^{*2}} = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sum_i (x_i - \bar{x})^2}$$

$$\hat{\alpha} = \bar{y}^* - \bar{x}^* \hat{\beta} = 0 - 0 \hat{\beta} = 0$$

Como el término de intercepto estimado es 0, entonces la recta de regresión estimada debe pasar por el origen.

37. Considere la siguiente salida de una regresión lineal en STATA, donde log_ingresos es el logaritmo de ingresos totales medidos en \$ pesos chilenos; esc es una variable que mide años de escolaridad formal completados por el individuo i, exp representa la experiencia laboral medida en años trabajados y esfuerzo es una variable que mide la capacidad de esfuerzo que el individuo i reporta en su trabajo actual.

Source	55	dt	MS		er of obs	891
Model	545.295791	3	181.765264	Pro	¿ F	0.08e0
Residual	207.311965	887	. 233722621		uared	0. 7245
Total	752.607756	890	.845626692	Roo		. 48345
log_ingresos	Coef.	Std. Err.	t	$P > t $	[95* Con	Interval]
exp	. 0638733	. 0021202	30.13	e. 008	. 659712	. 0680346
esc	. 3118498	. 00666	46.82	e. 088	. 2987786	. 324921
esfuerzo	. 0161511	. 0158767	1.62	0. 309	-. 0149974	. 0472996
_cons	5.e29305	. 184976	47.91	0. 688	4.823275	5.235335

- (a) ¿Cómo interpreta el valor del coeficiente esc?
Representa el retorno en ingresos de un año adicional de educación. Por retornos, se entiende cuánto aumentan los ingresos de una observación al aumentar en 1 año los años de escolaridad.
- (b) ¿Cómo interpreta el valor del coeficiente exp?
Representa el cambio en ingresos (según esta base de datos particular) al aumentar en 1 año los años de experiencia.

- (c) ¿Cómo se obtiene el valor t asociado a cada coeficiente? Explique.
Es el cuociente entre $\beta / se(\beta)$, donde $se()$ es el error estándar.
- (d) A partir de los valores reportados en la tabla, encuentre el valor crítico t utilizado por STATA para construir los intervalos de confianza (95%) del coeficiente esc.
Lo puedes obtener de distintas maneras (ej: límite inferior/superior):

$$IC_i = \beta - t_c \cdot se(\beta)$$

$$IC_s = \beta + t_c \cdot se(\beta)$$

- (e) A partir de los valores reportados en la tabla, muestre que el coeficiente de determinación de la regresión lineal es 0.7245 . ¿Qué significa ese número?
Como se indica en la tabla, en la parte superior-derecha el valor de $R^2 = 0,7245$. Este número explica que tan bien ajustado está el modelo. En este caso está medianamente bien ajustado, por lo que se puede ver una cierta correlación entre las variables.
- (f) ¿Qué representa el valor-p?
Representa el nivel de significancia límite que debiera ser considerado para que el coeficiente deje de ser significativo (rechace la hipótesis nula).

38. Para estudiar la relación entre 2 variables se han estimado los siguientes modelos:

- (a) $y_i = \alpha + \beta x_1 + u_i$
El coeficiente $\hat{\beta}$ es el cambio que se produce en y cuando x aumenta en una unidad.
- (b) $\ln(y_i) = \alpha + \beta x_1 + u_i$
Si se multiplica el coeficiente $\hat{\beta}$ por 100 entonces $100\hat{\beta}$ representa el cambio porcentual en y ocasionado por un cambio absoluto en x
- (c) $y_i = \alpha + \beta \ln(x_1) + u_i$
Si se divide $\hat{\beta}$ por 100 , entonces $0,01\hat{\beta}$ representa el cambio absoluto en y debido a un cambio relativo en x .
- (d) $\ln(y_i) = \alpha + \beta \ln(x_1) + u_i$
El coeficiente $\hat{\beta}$ mide el cambio porcentual en y ante pequeños cambios porcentuales en x , es decir mide la elasticidad de y respecto a x .

Discuta la interpretación que tendría, en cada caso, el valor estimado para β

39. Muestre que al utilizar estimadores MCO puede obtener una predicción insesgada de la variable Y .

MCO permite estimar el modelo $y^* = \beta X + \epsilon$ y la predicción de y viene dada por:

$$\hat{y} = Py = X\beta$$

Entonces se tiene:

$$E(y - \hat{y}) = E(X\beta + \epsilon - X\beta) = E(\epsilon) = 0$$

40. Muestre que el estimador B_{MCO} tiene la varianza más pequeña dentro de la clase de estimadores lineales insesgados. Muestre claramente cada uno de los supuestos que hace uso (al menos 4).

De acuerdo al teorema de Gauss-Markov, si se cumple linealidad, rango completo, exogeneidad estricta y errores esféricos (4 supuestos), entonces el estimador MCO es el más eficiente respecto a los otros estimadores lineales insesgados. En otras palabras es el de menor varianza:

$$\text{Var}(\hat{\beta}) \geq \text{Var}(\beta)$$

En dicho caso se dice que el estimador es B.L.U.E. (En este caso B_{MCO} es equivalente a β)

41. Suponga el modelo de regresión $y_t = \alpha + \beta_1 x_{t1} + \beta_2 x_{t2} + u_t$ donde se tiene:

$$X'X = \begin{bmatrix} 33 & 0 & 0 \\ 0 & 40 & 20 \\ 0 & 20 & 60 \end{bmatrix} \quad X'y = \begin{bmatrix} 132 \\ 24 \\ 92 \end{bmatrix} \quad \hat{u}'\hat{u} = 150$$

Se pide:

- (a) El tamaño de la muestra, y la media aritmética de x_1, x_2 , e y .
El tamaño de la muestra es 33. Las medias aritméticas de x_1 y x_2 son iguales a 0, mientras que la media de y es igual a $132/33 = 4$.
- (b) Los estimadores de α, β_1, β_2
Usando la fórmula del estimador MCO se obtienen los resultados:

$$\hat{\beta} = (X'X)^{-1} X'y = (4, -0, 2, 1, 6)'$$

- (c) La varianza de β_2 , y plantee un estadístico de prueba para testear la hipótesis de que $\beta_2 = 0$

$$\begin{aligned} \text{Var}(\hat{\beta}) &= \sigma^2 (X'X)^{-1} = \frac{u'u}{n-3} (X'X)^{-1} \\ &= \frac{150}{30} \begin{bmatrix} 0,03030303 & 0 & 0 \\ 0 & 0,03 & -0,01 \\ 0 & -0,01 & 0,02 \end{bmatrix} \end{aligned}$$

Para realizar el test de hipótesis es necesario calcular el estadístico t :

$$t = \frac{\hat{\beta}_2}{\sqrt{\text{Var}(\hat{\beta}_2)}} = \frac{1,6}{0,1} = 16$$

42. Sea el modelo $y = X\beta + u$. Se estima β por MCO y se obtienen los residuos de la regresión $\hat{u} = y - X\hat{\beta}$. Considere ahora la regresión $y = X\gamma + \delta u + \nu$.

- (a) Derive los estimadores de MCO para γ, δ y ν

Dado que los regresores X y $\hat{u}$ son ortogonales, los estimadores de γ y δ serán los mismos de las regresiones:

$$\begin{aligned} y &= X\gamma + \nu_1 \\ y &= \delta\hat{u} + \nu_2 \end{aligned}$$

Por lo tanto:

$$\hat{\gamma} = (X'X)^{-1} X'y$$

y

$$\begin{aligned} \hat{\delta} &= (\hat{u}'\hat{u})^{-1} \hat{u}'y = (\hat{u}'\hat{u})^{-1} (My)'y \\ &= (\hat{u}'\hat{u})^{-1} y'My = (\hat{u}'\hat{u})^{-1} \hat{u}'u = 1 \end{aligned}$$

- (b) ¿Que valores tendrán los residuos $\hat{\nu}$?

Los residuos serán cero porque hemos incluido en los regresores la parte de y que no es explicada por X de la regresión original:

$$\hat{\nu} = y - X\hat{\gamma} - \hat{\delta}\hat{u} = y - X\hat{\beta} - \hat{u} = \hat{u} - \hat{u} = 0$$

- (c) Calcule el R^2 de la regresión.

Por obvias razones el R^2 será 1, debido a que el modelo se ajusta perfectamente, es decir la variabilidad de y está explicada completamente por la variabilidad de los regresores:

$$R^2 = 1 - \frac{\hat{\nu}'\hat{\nu}}{(y - \bar{y})'(y - \bar{y})} = 1 - 0 = 1$$

43. Considere la regresión por mínimos cuadrados de y sobre k variables X . Considere otro conjunto de regresores $Z = XA$, donde X es una matriz no singular. Entonces cada columna de Z es una combinación lineal de las columnas de X . Pruebe que el vector de residuos de la regresión de y sobre Z , y de y sobre X coinciden. ¿Que relevancia tiene esto al momento de cambiar las unidades de medida en las variables independientes.

Se sabe que la matriz de proyección al espacio columna de X es $P_X = X(X'X)^{-1}X'$. La matriz de proyección al espacio columna de Z es:

$$\begin{aligned} P_Z &= Z(Z'Z)^{-1}Z' = XA(A'X'XA)^{-1}A'X' \\ &= X(X'X)^{-1}X' = P_X \end{aligned}$$

Esto se debe a que el subespacio generado por las columnas de X es idéntico al subespacio generado por las columnas de Z . Esto resulta bastante obvio, ya que cada columna de Z es una combinación lineal de las columnas de X . Si $P_Z = P_X$ entonces $M_Z = M_X$, así que el vector de residuos $M_Z y$ será igual a $M_X y$. La importancia de esto es que al cambiar la unidad de medida de las variables explicativas no se altera la predicción ni los residuos, a pesar de que el estimador $\hat{\beta}$ si cambia.

44. Suponga que desea estudiar la relación entre y y x_1 . Para eso, se pueden incluir dos variables de control, x_2 y x_3 . Sea $\tilde{\beta}_1$ y $\hat{\beta}_1$ estimadores de dos regresiones tal que:

$$\begin{aligned} y &= \tilde{\alpha}_0 + \tilde{\alpha}_1 x_1 = X_1 \tilde{\beta}_1 \\ y &= \hat{\alpha}_0 + \hat{\alpha}_1 x_1 + \hat{\alpha}_2 x_2 + \hat{\alpha}_3 x_3 = \hat{\beta}_1 X_1 + X_2 \hat{\beta}_2 \end{aligned}$$

Con

$$X_1 = \begin{bmatrix} 1 & x_{11} \\ 1 & x_{21} \\ 1 & x_{31} \\ \vdots & \vdots \\ 1 & x_{n1} \end{bmatrix}, \quad X_2 = \begin{bmatrix} x_{12} & x_{13} \\ x_{22} & x_{23} \\ x_{32} & x_{33} \\ \vdots & \vdots \\ x_{n2} & x_{n3} \end{bmatrix}, \quad \tilde{\beta}_1 = \begin{bmatrix} \tilde{\alpha}_0 \\ \tilde{\alpha}_1 \end{bmatrix}, \quad \hat{\beta}_1 = \begin{bmatrix} \hat{\alpha}_0 \\ \hat{\alpha}_1 \end{bmatrix} \quad \text{y} \quad \hat{\beta}_2 = \begin{bmatrix} \hat{\alpha}_2 \\ \hat{\alpha}_3 \end{bmatrix}$$

Por FWL sabemos que

$$\hat{\beta}_1 = \tilde{\beta}_1 - (X_1' X_1)^{-1} X_1' X_2 \hat{\beta}_2 \quad (18)$$

- a) Demuestre que $\hat{\beta}_1$ se puede reescribir como

$$\hat{\beta}_1 = (X_1' M_2 X_1)^{-1} X_1' M_2 y$$

con $M_2 = I - X_2(X_2' X_2)^{-1} X_2'$

Solución:

Por FWL tenemos que $\hat{\beta}_2$ equivale a

$$\hat{\beta}_2 = (X_2' X_2)^{-1} (X_2 y - X_2' X_1 \hat{\beta}_1)$$

Reemplazando $\hat{\beta}_2$ en (18) resulta:

$$\hat{\beta}_1 = \tilde{\beta}_1 - (X_1'X_1)^{-1}X_1'X_2(X_2'X_2)^{-1}(X_2y - X_2'X_1\hat{\beta}_1)$$

Despejamos $\hat{\beta}_1$ y reemplazamos $\tilde{\beta}_1 = (X_1'X_1)^{-1}X_1'y$

$$[I - (X_1'X_1)^{-1}X_1'X_2(X_2'X_2)^{-1}X_2'X_1]\hat{\beta}_1 = (X_1'X_1)^{-1}X_1'y - (X_1'X_1)^{-1}X_1'X_2(X_2'X_2)^{-1}X_2y$$

Multipliquemos ambos lados por $(X_1'X_1)$ para poder cancelar algunos términos.

$$[(X_1'X_1) - X_1'X_2(X_2'X_2)^{-1}X_2'X_1]\hat{\beta}_1 = X_1'y - X_1'X_2(X_2'X_2)^{-1}X_2y$$

Notemos que en los dos lados podemos factorizar por $M_2 = I - X_2(X_2'X_2)^{-1}X_2'$.

$$[X_1'M_2X_1]\hat{\beta}_1 = X_1'M_2y$$

Ahora despejamos $\hat{\beta}_1$ y obtenemos:

$$\hat{\beta}_1 = (X_1'M_2X_1)^{-1}X_1'M_2y$$

b) Encuentre expresiones para $\text{Var} [\hat{\beta}_1]$ y $\text{Var} [\tilde{\beta}_1]$.

Solución:

Para $\text{Var} [\tilde{\beta}_1]$ tenemos que:

$$\tilde{\beta}_1 = (X_1'X_1)^{-1}X_1'y$$

Reemplazamos $y = X_1\beta_1 + \nu$

$$\tilde{\beta}_1 = (X_1'X_1)^{-1}X_1'(X_1\beta_1 + \nu)$$

$$\tilde{\beta}_1 = \beta_1 + (X_1'X_1)^{-1}X_1'\nu$$

Como $\mathbb{E} [\tilde{\beta}_1] = \beta_1$, se cumple que:

$$\text{Var} [\tilde{\beta}_1|X] = \text{Var} [(X_1'X_1)^{-1}X_1'\nu]$$

$$\text{Var} [\tilde{\beta}_1|X] = (X_1'X_1)^{-1}X_1'\text{Var} [\nu|X]X_1(X_1'X_1)^{-1}$$

$$\text{Var} [\tilde{\beta}_1|X] = (X_1'X_1)^{-1}X_1'\sigma^2IX_1(X_1'X_1)^{-1}$$

$$\text{Var} [\tilde{\beta}_1|X] = \sigma^2(X_1'X_1)^{-1}$$

Para $\text{Var} [\hat{\beta}_1]$ resolvemos un proceso análogo al anterior y obtenemos:

$$\text{Var} [\hat{\beta}_1|X] = \sigma^2(X_1'M_2X_1)^{-1}$$

c) Con ayuda de las expresiones obtenidas anteriormente responda:

- i) Si x_1 está altamente correlacionada con x_2 y x_3 , y x_2 y x_3 tienen efectos parciales grandes sobre y , ¿esperaría que $\tilde{\beta}_1$ y $\hat{\beta}_1$ sean similares o muy diferentes?

Solución:

Como x_1 está muy correlacionada con x_2 y x_3 , se espera que $X_1'X_2$ sea grande. Además, se espera que $\hat{\beta}_2$ sea alto, ya que x_2 y x_3 tiene efectos grandes sobre y (es significativo). Por lo tanto, por la expresión dada en el enunciado:

$$\hat{\beta}_1 = \tilde{\beta}_1 - (X_1'X_1)^{-1}X_1'X_2\hat{\beta}_2$$

Vemos que $(X_1'X_1)^{-1}X_1'X_2\hat{\beta}_2$ es distinto de 0 y por lo tanto $\tilde{\beta}_1$ y $\hat{\beta}_1$ serán diferentes.

- ii) Si x_1 casi no está correlacionada con x_2 y x_3 , pero x_2 y x_3 están fuertemente correlacionadas, ¿esperaría que $\tilde{\beta}_1$ y $\hat{\beta}_1$ sean similares o muy diferentes?

Solución:

Como x_1 casi no está correlacionada con x_2 y x_3 , se espera que $X_1'X_2$ sea pequeño o cercano a 0. En este caso, que x_2 y x_3 estén correlacionadas no aporta información para inferir nada respecto a β_1 . Por lo tanto, ocupando la misma expresión que en el enunciado:

$$\hat{\beta}_1 = \tilde{\beta}_1 - (X_1'X_1)^{-1}X_1'X_2\hat{\beta}_2$$

Vemos que $(X_1'X_1)^{-1}X_1'X_2\hat{\beta}_2$ será cercano a 0 y por lo tanto $\tilde{\beta}_1$ y $\hat{\beta}_1$ serán similares.

- iii) Si x_1 está altamente correlacionada con x_2 y x_3 , y x_2 y x_3 tienen efectos parciales pequeños sobre y , ¿esperaría que $\text{Var}[\tilde{\beta}_1]$ o $\text{Var}[\hat{\beta}_1]$ fuera pequeña?

Solución:

Como x_1 se correlaciona fuertemente con x_2 y x_3 , X_1 es cercano a X_2 . Por lo que la proyección de X_1 a la matriz de residuos de X_2 , es decir, M_2X_1 es pequeña. Por lo tanto, $(X_1'M_2X_1)^{-1}$ será grande. Por otro lado, al agregar la variable X_2 , σ^2 no se reduce significativamente, ya que tiene efectos pequeños sobre y . Observando la expresión que obtuvimos para las varianzas:

$$\text{Var}[\hat{\beta}_1|X] = \sigma^2(X_1'M_2X_1)^{-1}$$

$$\text{Var}[\tilde{\beta}_1|X] = \sigma^2(X_1'X_1)^{-1}$$

Podemos decir que $\text{Var}[\hat{\beta}_1]$ será mayor a $\text{Var}[\tilde{\beta}_1]$.

- iv) Si x_1 casi no está correlacionada con x_2 y x_3 , y x_2 y x_3 tienen efectos parciales grandes sobre y , ¿esperaría que $\text{Var}[\tilde{\beta}_1]$ o $\text{Var}[\hat{\beta}_1]$ fuera pequeña?

Solución:

Como X_1 y X_2 casi no están correlacionadas, $M_2 X_1$ será cercano a simplemente X_1 . Sin embargo, como X_2 tiene efectos grandes sobre y , σ^2 se reduce al incluir esta variable, por lo tanto, observando las expresiones de las varianzas:

$$\text{Var} [\hat{\beta}_1 | X] = \sigma^2 (X_1' M_2 X_1)^{-1}$$

$$\text{Var} [\tilde{\beta}_1 | X] = \sigma^2 (X_1' X_1)^{-1}$$

Podemos decir que $\text{Var} [\hat{\beta}_1]$ será menor a $\text{Var} [\tilde{\beta}_1]$.

45. a) Sean $\hat{\beta}_0$ y $\hat{\beta}_1$ el intercepto y la pendiente de y_i sobre x_i usando n observaciones. Sean c_1 y c_2 constantes, con $c_2 \neq 0$. Sean $\tilde{\beta}_0$ y $\tilde{\beta}_1$ el intercepto y la pendiente de $c_1 y_i$ sobre $c_2 x_i$. Muestre que $\tilde{\beta}_1 = (c_1/c_2)\hat{\beta}_1$ y $\tilde{\beta}_0 = c_1\hat{\beta}_0$.

Recordemos que para una regresión simple las expresiones para la pendiente y el intercepto son:

$$\hat{\beta}_1 = \frac{\text{Cov}(x, y)}{\text{Var}(x)}, \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

Entonces:

$$\tilde{\beta}_1 = \frac{\text{Cov}(c_2 x, c_1 y)}{\text{Var}(c_2 x)} = \frac{c_1 c_2 \text{Cov}(x, y)}{c_2^2 \text{Var}(x)} = (c_1/c_2)\hat{\beta}_1$$

Y para el intercepto:

$$\tilde{\beta}_0 = \overline{c_1 y} - \tilde{\beta}_1 \overline{c_2 x} = c_1 \bar{y} - (c_1/c_2)\hat{\beta}_1 c_2 \bar{x} = c_1 \bar{y} - c_1 \hat{\beta}_1 \bar{x} = c_1(\bar{y} - \hat{\beta}_1 \bar{x}) = c_1 \hat{\beta}_0$$

- b) Ahora, sean $\tilde{\beta}_0$ y $\tilde{\beta}_1$ la intersección con el eje Y y la pendiente en la regresión de $(c_1 + y_i)$ sobre $c_2 + x_i$. Muestre que $\tilde{\beta}_1 = \hat{\beta}_1$ y $\tilde{\beta}_0 = \hat{\beta}_0 + c_1 - c_2 \hat{\beta}_1$

$$\tilde{\beta}_1 = \frac{\text{Cov}(c_2 + x, c_1 + y)}{\text{Var}(c_2 + x)} = \hat{\beta}_1$$

Y para el intercepto:

$$\tilde{\beta}_0 = \overline{c_1 + y} - \tilde{\beta}_1 \overline{c_2 + x} = c_1 + \bar{y} - \hat{\beta}_1(c_2 + \bar{x}) = \bar{y} - \hat{\beta}_1 \bar{x} + c_1 - c_2 \hat{\beta}_1 = \hat{\beta}_0 + c_1 - c_2 \hat{\beta}_1$$

- c) Ahora, sean $\hat{\beta}_0$ y $\hat{\beta}_1$ los estimadores de MCO en la regresión de $\log(y_i)$ sobre x_i , donde hay que suponer que $y_i > 0$ para toda i . Para $c_1 > 0$, sean $\tilde{\beta}_0$ y $\tilde{\beta}_1$ el intercepto y la pendiente en la regresión de $\log(c_1 y_i)$ sobre x_i . Muestre que

$$\tilde{\beta}_1 = \hat{\beta}_1 \quad \text{y} \quad \tilde{\beta}_0 = \log(c_1) + \hat{\beta}_0.$$

Tenemos que los coeficientes de la regresión de $\log(y_i)$ sobre x_i son:

$$\hat{\beta}_1 = \frac{\text{Cov}(x, \log(y))}{\text{Var}(x)}, \quad \hat{\beta}_0 = \overline{\log(y)} - \hat{\beta}_1 \bar{x}$$

Entonces la pendiente de la regresión de $\log(c_1 y_i)$ sobre x_i es:

$$\tilde{\beta}_1 = \frac{\text{Cov}(x, \log(c_1 y))}{\text{Var}(x)} = \frac{\text{Cov}(x, \log(c_1) + \log(y))}{\text{Var}(x)} = \frac{\text{Cov}(x, \log(y))}{\text{Var}(x)} = \hat{\beta}_1$$

Y para el intercepto:

$$\tilde{\beta}_0 = \overline{\log(c_1 y)} - \tilde{\beta}_1 \bar{x} = \log(c_1) + \overline{\log(y)} - \hat{\beta}_1 \bar{x} = \log(c_1) + \hat{\beta}_0$$

- d) Ahora, suponiendo que $x_i > 0$ para toda i , sean $\tilde{\beta}_0$ y $\tilde{\beta}_1$ el intercepto y la pendiente de y_i sobre $\log(c_2 x_i)$. ¿Cuál es la relación de $\tilde{\beta}_0$ y $\tilde{\beta}_1$ con el intercepto y la pendiente de la regresión de y_i sobre $\log(x_i)$?

Tenemos que los coeficientes de la regresión de y_i sobre $\log(x_i)$ son:

$$\hat{\beta}_1 = \frac{\text{Cov}(\log(x), y)}{\text{Var}(\log(x))}, \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \overline{\log(x)}$$

Entonces la pendiente de la regresión de y_i sobre $\log(c_2 x_i)$ es:

$$\tilde{\beta}_1 = \frac{\text{Cov}(\log(c_2 x), y)}{\text{Var}(\log(x))} = \frac{\text{Cov}(\log(c_2) + \log(x), y)}{\text{Var}(\log(x))} = \frac{\text{Cov}(\log(x), y)}{\text{Var}(\log(x))} = \hat{\beta}_1$$

Y para el intercepto:

$$\tilde{\beta}_0 = \bar{y} - \tilde{\beta}_1 \overline{\log(c_2 x)} = \bar{y} - \hat{\beta}_1 (\log(c_2) + \bar{x}) = \hat{\beta}_0 - \log(c_2) \hat{\beta}_1$$