



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE

ESCUELA DE INGENIERÍA

DEPARTAMENTO DE INGENIERÍA INDUSTRIAL Y DE SISTEMAS

ICS2563 - ECONOMETRÍA APLICADA

Interrogación 2

Segundo Semestre de 2025 - Profesores: P.Domínguez & G.Gaete

Instrucciones

- Tiene un total de **2 horas** para realizar la prueba.
- El trabajo en esta prueba es **individual**. No se permite colaborar con persona alguna, de la forma que sea.
- Justifique adecuadamente todas sus respuestas en base a los contenidos vistos en clase.
- No está permitido el uso de material de apoyo ni calculadora para el desarrollo de la evaluación.
- Usted debe responder las **4 preguntas** y el puntaje máximo será de **60 puntos**.
- Responda cada pregunta en **planas separadas** (que no queden respuestas de incisos de preguntas distintas en una misma plana).

- Al final de la prueba deberán escanear sus respuestas y subirla a la plataforma de CANVAS al buzón “Interrogación 2” y deberán entregar la prueba física (NO se pueden llevar la prueba física, en caso que se la lleven tendrán nota mínima 1.0).
- En caso que terminen antes del final de la prueba (antes de las 2 horas), deberán levantar la mano para que un ayudante acuda a su puesto y con él vayan hacia el mesón de adelante y solo ahí podrán escanear la prueba.
- Hint 1: Recuerde que el teorema FWL establece que, para un modelo del tipo $y = X_1b_1 + X_2b_2 + e$, la solución MCO para b_2 se puede obtener como $b_2 = (X_2'M_1X_2)^{-1}X_2'M_1y$.
- Hint 2: Como corolario de la pista anterior, considere que $b_2'X_2'M_1y = b_2'X_2'M_1X_2b_2$.

Código de honor

Como miembro de la comunidad de la Pontificia Universidad Católica de Chile, me comprometo a respetar los principios y normativas que la rigen. Asimismo, me comprometo a actuar con rectitud y honestidad en las relaciones con los demás integrantes de la comunidad y en la realización de todo trabajo, particularmente en aquellas actividades vinculadas a la docencia, al aprendizaje y la creación, difusión y transferencia del conocimiento. Además, me comprometo a velar por la dignidad e integridad de las personas, evitando incurrir en y, rechazando, toda conducta abusiva de carácter físico o, verbal, psicológico y de violencia sexual. Del mismo modo, asumo el compromiso de cuidar los bienes de la Universidad.

Pregunta 1 (15 puntos)

La academia de tenis *Andre & Steffi* selecciona a jugadores escolares de elite a nivel global, previo a su inserción al deporte profesional. Sus seleccionadores son sofisticados y recolectan información útil para pronosticar una carrera exitosa en el exigente y competitivo mundo del tenis profesional. Dentro de la información que recolectan, está el rendimiento P en $t = 0$ y otros factores que les permiten estimar rigurosamente los resultados potenciales en caso de asistir o no a la academia para cada joven tenista (vectores $(Y_i(1), Y_i(0))$, utilizando una métrica que resume en una escala $(0, 1000)$ todo el futuro profesional de cada tenista). Para su análisis usted cuenta con toda esa información para una muestra representativa de 6 tenistas postulantes en la tabla 1.

Tabla 1: Datos para selección de tenistas

Competidor	$Y(1)$	$Y(0)$	Performance $t = 0$
1	900	500	350
2	300	250	300
3	750	450	300
4	250	300	250
5	900	600	250
6	350	350	300

Responda las siguientes preguntas:

- a) Calcule el impacto promedio causal del programa, si los seleccionadores escogen a los 3 tenistas que vislumbran se beneficiarían de mejor manera asistiendo a la academia. Justifique su cálculo y señale si podría considerar ese efecto válido para quienes no serían seleccionados en este caso.

Solución:

Examinando los vectores de resultados potenciales $(Y(1), Y(0))$, los 3 tenistas que presentan mayor beneficio si asistieran a la academia son los competidos 1, 3 y 5.¹

El estimador del efecto causal para los tenistas seleccionados se puede estimar calculando el promedio entre ellos tres:

$$E[Y_i(1) - Y_i(0)] = \frac{(900+750+900)-(500+450+600)}{3} = \frac{1000}{3}$$

¹Obviamente este es un caso ficticio y lo que señala el enunciado es que los seleccionadores son capaces de examinar es el valor de $\tau_i = Y_i(1) - Y_i(0)$ (e.g. el efecto causal *individual* del programa) que precisamente compara los dos estados del mundo que necesitamos para definir un efecto causal: el observado y su contrafactual.

Para el caso de los no seleccionados, no tiene sentido asumir que ese efecto promedio se extrapole para ellos también. En este caso particular (ficticio) donde conocemos el vector de resultados potenciales individuales es posible estimar el impacto promedio para los competidores 2, 4 y 6.

Similar al caso anterior, obtenemos lo siguiente:

$$E[Y_i(1) - Y_i(0)] = \frac{(300+250+350)-(250+300+350)}{3} = 0$$

Siendo claramente menor que el efecto estimado anterior, lo que resulta consistente con el hecho de que los seleccionadores podían anticipar *a priori* quiénes se pueden beneficiar más con la participación en la academia.

(1.5 puntos) Por mencionar correctamente que tenistas representan el mayor beneficio.

(1.5 puntos) Por calcular correctamente el efecto para los seleccionados.

(2 puntos) Por argumentar correctamente que no es posible considerar el efecto válido para los no seleccionados.

- b) Si el vector tratamiento tiene la forma $D'_i = (0, 0, 1, 1, 0, 1)$, identifique Y_i , el vector de resultados observados y encuentre una expresión para el coeficiente que obtendría al estimar τ a partir de la siguiente regresión lineal (MCO): $Y_i = \alpha + \tau D_i + \epsilon_i$, donde ϵ_i es el residuo de la estimación y α el intercepto. ¿Cree usted que τ identificaría el efecto causal? Discuta la eventual presencia de un sesgo y calcule su magnitud.

Solución:

En primer lugar, obtenemos el vector de resultados observado, Y_i :

$$Y_i = Y_i(0) + D_i(Y_i(1) - Y_i(0))$$

$$\text{Así, } Y_i = (500, 250, 750, 250, 600, 350).$$

Luego, sabemos al tener una regresión lineal simple, sabemos que τ absorbe simplemente la diferencia observacional de la siguiente forma:

$$\hat{\tau} = E[Y_i | D_i = 1] - E[Y_i | D_i = 0]$$

Reemplazando se obtiene:

$$\tau = \frac{750+250+350}{3} - \frac{500+250+600}{3} = 0$$

Existe una presencia de sesgo ya que el efecto del tratamiento de las medias observadas no necesariamente corresponde al efecto del tratamiento causal sobre toda la muestra.

Considerando esto, se utiliza la descomposición del sesgo observacional POF. Partimos por descomponer la diferencia observacional que representa la estimación de τ :

$$\hat{\tau} = E[Y_i|D_i = 1] - E[Y_i|D_i = 0] = E[Y_{1i}|D_i = 1] - E[Y_{0i}|D_i = 1] + E[Y_{0i}|D_i = 1] - E[Y_{0i}|D_i = 0]$$

de donde se observa que la primera diferencia corresponde al efecto causal promedio para las unidades tratadas y la segunda diferencia contiene el sesgo de selección:

$$\text{Sesgo de selección} = E[Y_{0i}(1)|D_i = 1] - E[Y_{1i}(0)|D_i = 0] \quad (1)$$

Reemplazando se obtiene:

$$\tau = \frac{450+300+350}{3} - \frac{500+250+600}{3} = 366,6 - 450 = -83,33$$

Es claro que el sesgo se obtiene porque las unidades tratadas y no tratadas difieren sustancialmente en el valor promedio del vector $E[Y_i(0)]$, esto es con su estado *en caso de no ser tratadas*.

En este caso, el sesgo es de una magnitud tal que la diferencia promedio observada en rendimiento entre tenistas que asistieron y quienes no a la academia es nula.

(1 punto) Por obtener correctamente el vector de resultados.

(1 punto) Por obtener correctamente el valor de τ .

(1 punto) Por discutir si τ identifica el efecto causal.

(1 punto) Por argumentar correctamente la presencia de un sesgo.

(1 punto) Por calcular correctamente la magnitud del sesgo.

- c) Imagine ahora que los estudiantes se escogen por medio de una lotería y que la información que contiene la tabla (1) corresponde a una muestra aleatoria de todos los postulantes. ¿Cuál sería su estimación para ATE y ATT (TOT) en este caso?

Solución:

Si D_i fue asignado de manera aleatoria, entonces D_i es independiente de $Y(0)$ e $Y(1)$ por lo que la distribución condicional de $Y_i(1)$ e $Y_i(0)$ dado D_i es igual a la distribución incondicional, por lo tanto:

$$E[Y_i(0)|D_i = 0] = E[Y_i(0)|D_i = 1] \text{ y } E[Y_i(1)|D_i = 1] = E[Y_i(0)|D_i = 0]$$

Usando la expresión de sesgo planteada en (1), se puede notar que es 0.

En este caso, habría balance entre tenistas seleccionados y no seleccionados tanto en variables observables como no observables. Así, el ATE y ATT serían equivalentes. De esta manera, podemos estimar el efecto como el promedio simple de τ_i para cada tenista que participa del proceso de selección. Así $\hat{\tau} = \sum_{i=1}^6 \tau_i = \frac{1000}{6}$

(1 punto) Por mencionar que si D_i es asignado de forma aleatoria, entonces D_i es igual a la distribución incondicional.

(2 puntos) Por mencionar que existe balance entre seleccionados y no seleccionados tanto en variables observables como no observables.

(1 punto) Por calcular correctamente el ATE.

(1 punto) Por mencionar que el ATE y ATT son equivalentes.

Pregunta 2 (15 puntos)

La Decana de la Facultad de Ingeniería está interesada en conocer el efecto de las **horas de estudio** sobre las **notas** que obtienen los estudiantes en Cálculo III. Para esto, durante el primer semestre del 2025 se realizó una encuesta a todos los estudiantes del curso, en la cual reportaron las horas que estudiaron para las dos interrogaciones.

La Decana, al tanto de sus conocimientos de econometría, le solicita ayuda para estimar el siguiente modelo:

$$\text{nota}_{it} = \alpha_i + \beta \text{horas}_{it} + u_{it},$$

donde:

- nota_{it} es la nota obtenida por el estudiante i en la interrogación t ,
- horas_{it} son las horas de estudio dedicadas por el estudiante i en la interrogación t ,
- u_{it} es el error idiosincrático.

a) ¿Qué supuesto impondría sobre la relación entre el término de error u_{it} y la variable horas_{it} para hacer sus estimaciones según el modelo propuesto? Fundamente.

Solución: Es razonable pensar que hay heterogeneidad no observada invariante en el tiempo que está correlacionada con la cantidad de horas (por ejemplo, el sexo de los estudiantes). Por lo tanto, se utiliza el supuesto de *exogeneidad estricta*:

Sea:

$$u_{it} = c_i + e_{it}$$

$$E[e_{it} \mid \text{horas}_{i1}, \text{horas}_{i2}, c_i] = 0. \quad (2)$$

Este supuesto implica que las horas de estudio son exógenas: no están correlacionadas con los shocks idiosincráticos e_{it} que afectan la nota. En otras palabras, los factores no observados que

influyen en la nota (motivación, salud, etc.) no están relacionados con la cantidad de horas de estudio una vez controlado por la heterogeneidad no observada c_i .

(1 punto) Por mencionar que hay heterogeneidad no observada.

(1 punto) Por utilizar el supuesto de exogeneidad estricta.

(1 punto) Por presentar la ecuación (2).

(2 punto) Por fundamentar correctamente el supuesto de exogeneidad estricta.

b) Adicionalmente, le dan la siguiente información de dos estudiantes:

Estudiante	Interrogación	Horas de estudio	Nota
1	1	5	2,8
1	2	25	5,2
2	1	20	4,4
2	2	30	5,6

Utilizando los datos anteriores y un modelo de efectos fijos individuales, realice una estimación *within* del parámetro de interés e interprete el resultado.

Solución: Primero, se calculan las medias individuales:

$$\bar{y}_1 = \frac{2,8 + 5,2}{2} = 4,0, \quad \bar{y}_2 = \frac{4,4 + 5,6}{2} = 5,0.$$

$$\bar{x}_1 = \frac{5 + 25}{2} = 15, \quad \bar{x}_2 = \frac{20 + 30}{2} = 25.$$

Las variables de-meaned son:

$$\tilde{y}_{11} = 2,8 - 4,0 = -1,2, \quad \tilde{y}_{12} = 5,2 - 4,0 = 1,2,$$

$$\tilde{y}_{21} = 4,4 - 5,0 = -0,6, \quad \tilde{y}_{22} = 5,6 - 5,0 = 0,6.$$

$$\tilde{x}_{11} = 5 - 15 = -10, \quad \tilde{x}_{12} = 25 - 15 = 10,$$

$$\tilde{x}_{21} = 20 - 25 = -5, \quad \tilde{x}_{22} = 30 - 25 = 5.$$

El estimador within es:

$$\hat{\beta}_W = \frac{\sum_i \sum_t \tilde{x}_{it} \tilde{y}_{it}}{\sum_i \sum_t \tilde{x}_{it}^2}.$$

Sustituyendo:

$$\sum_i \sum_t \tilde{x}_{it} \tilde{y}_{it} = (-10)(-1, 2) + (10)(1, 2) + (-5)(-0, 6) + (5)(0, 6) = 12 + 12 + 3 + 3 = 30,$$

$$\sum_i \sum_t \tilde{x}_{it}^2 = (-10)^2 + (10)^2 + (-5)^2 + (5)^2 = 100 + 100 + 25 + 25 = 250.$$

Por tanto:

$$\hat{\beta}_W = \frac{30}{250} = 0,12.$$

Interpretación: un aumento de una hora de estudio se asocia, en promedio, con un incremento de 0,12 puntos en la nota del estudiante, controlando por diferencias individuales fijas.

(1 punto) Por calcular las medias individuales.

(1 punto) Por calcular las variables de-meaned.

(1 punto) Por sustituir correctamente en la sumatoria.

(1 punto) Por obtener correctamente el valor de $\hat{\beta}_W$.

(1 punto) Por interpretar correctamente el resultado.

- c) Utilizando los datos anteriores, realice una estimación de primeras diferencias para el coeficiente de interés. Compare sus resultados con los obtenidos en el punto anterior.

Solución: Para cada estudiante:

$$\Delta y_1 = 5, 2 - 2, 8 = 2, 4, \quad \Delta x_1 = 25 - 5 = 20,$$

$$\Delta y_2 = 5, 6 - 4, 4 = 1, 2, \quad \Delta x_2 = 30 - 20 = 10.$$

El estimador de primeras diferencias es:

$$\hat{\beta}_{FD} = \frac{\sum_i \Delta x_i \Delta y_i}{\sum_i (\Delta x_i)^2} = \frac{(20)(2,4) + (10)(1,2)}{20^2 + 10^2} = \frac{48 + 12}{400 + 100} = \frac{60}{500} = 0,12.$$

Conclusión: los estimadores within y de primeras diferencias son idénticos para dos períodos:

$$\boxed{\hat{\beta}_W = \hat{\beta}_{FD} = 0,12.}$$

(0.5 puntos) Por calcular correctamente Δy_i .

(0.5 puntos) Por calcular correctamente Δx_i .

(1 punto) Por plantear correctamente la expresión para $\hat{\beta}_{FD}$.

(1 punto) Por calcular correctamente el estimador de primeras diferencias.

(2 puntos) Por concluir correctamente que los estimadores son idénticos para dos periodos.

Pregunta 3 (15 puntos)

En el 2011, el gobierno italiano implementó un programa para instalar parques industriales en varias ciudades a través del país. Usted cuenta con datos, a nivel de ciudad, del PIB per cápita para cada año entre 2006 y 2019 (ambos inclusive).

- a) Utilizando los datos disponibles, plantee un modelo que le permita identificar el impacto causal del programa sobre el PIB per cápita de la ciudad. Explique cada una de las variables e índices utilizados, e identifique explícitamente el coeficiente que captura el efecto de interés.

Solución:

Se plantea un modelo de **diff-in-diff**

$$Y_{it} = \alpha + \beta D_i + \eta Post_t + \delta(D_i \times Post_t) + \varepsilon_{it} \quad (3)$$

Donde:

- D_i : Es una binaria que indica si se instalaron parques industriales en la ciudad i .
- $Post_t$: Es una binaria que indica si la observación corresponde a después del 2011 (inclusive).

Notar que el coeficiente de interés es δ (captura el efecto del tratamiento).

(1 punto) Por plantear correctamente el modelo **diff-in-diff**.

(1 punto) Por definir correctamente D_i y $Post_t$.

(1 punto) Por mencionar que δ captura el efecto del tratamiento.

- b) En este contexto, ¿Qué supuestos deben cumplirse para que el modelo que propuso en el punto anterior identifique el asunto causal del programa? Con los datos que dispone, ¿Podría entregar evidencia que sustente los principales supuestos? De ser así, ¿Esta evidencia aseguraría el cumplimiento del (los) supuesto(s)?

Solución:

- En ausencia del programa de industrialización, el cambio esperado en el PIB per cápita desde el 2011 en adelante hubiese sido el mismo en las ciudades que se instalaron parques industriales en comparación con aquellas en donde no se instalaron.
- $Cov(D_i, \varepsilon_{it}) = 0$: No debe haber una relación sistemática entre haber recibido un parque industrial y algún factor no observado que afecte el PIB.
- $Cov(Post_t, \varepsilon_{it}) = 0$: El único cambio que afecta de manera distintas a las ciudades desde el 2011 en adelante es la instalación de parques industriales.

Con los datos disponibles, para dar sustento al primer supuesto señalado, analizaría la existencia de tendencias paralelas pre-tratamiento en la esperanza del PIB per cápita entre ambos grupos de ciudades (tratadas y controles). Sin embargo, esta evidencia no es suficiente para asegurar que la tendencia paralela se cumpla posterior a la implementación de los parques industriales, por lo que nunca deja de ser un supuesto. Por ejemplo, se podría haber implementado otra política de desarrollo industrial que haya afectado de manera diferencial e ambos tipos de ciudades, lo cual no es capturado por la evidencia post-tratamiento.

(1 punto) Por fundamentar el supuesto de tendencias paralelas.

(1 punto) Por fundamentar el supuesto de $Cov(D_i, \varepsilon_{it}) = 0$ (en palabras o con ecuación).

(1 punto) Por fundamentar el supuesto de $Cov(Post_t, \varepsilon_{it}) = 0$ (en palabras o con ecuación).

(1 punto) Por fundamentar que no hay evidencia suficiente para asegurar el cumplimiento de tendencias paralelas posterior al tratamiento.

- c) Un amigo suyo italiano, que es de Milán (norte de Italia), le comenta de las importantes diferencias culturales entre el norte y el sur del país, por lo que le sugiere estudiar la potencial heterogeneidad del efecto entre ambas regiones (tanto en el norte como en el sur hay ciudades que recibieron el programa y otras que no lo hicieron). Proponga un modelo que le permita estimar dicho efecto diferencial. Explique cada una de las variables utilizadas y subíndices, además de identificar explícitamente el efecto del programa en las ciudades del norte y en las ciudades del sur.

Solución: Se plantea un modelo DDD:

$$\begin{aligned}
Y_{it} = & \alpha + \beta_1 D_i + \beta_2 Post_t + \beta_3 Norte_i + \beta_4 (D_i \times Post_t) + \beta_5 (D_i \times Norte_i) \\
& + \beta_6 (Post_t \times Norte_i) + \beta_7 (D_i \times Post_t \times Norte_i) + \varepsilon_{it}
\end{aligned}
\tag{4}$$

Donde:

- D_i : Es una binaria que indica si se instalaron parques industriales en la ciudad i .
- $Post_t$: Es una binaria que indica si la observación corresponde a después del 2011 (inclusive).
- $Norte_i$: Es una binaria que indica si la ciudad i es del Norte de Italia.

El efecto diferencial del tratamiento entre norte y sur corresponde a β_7 . El efecto promedio del tratamiento para el norte es $\beta_4 + \beta_7$, mientras que para el sur es solo β_4 .

(1.5 puntos) Por plantear correctamente el modelo DDD.

(0.5 puntos) Por definir correctamente D_i , $Post_t$ y $Norte_i$.

(1 punto) Por mencionar que β_7 captura el efecto diferencial del tratamiento entre norte y sur.

(1 punto) Por mencionar que $\beta_4 + \beta_7$ captura el efecto promedio para el norte.

(1 punto) Por mencionar que β_4 captura el efecto promedio para el sur.

- d) Ahora suponga que la asignación de los parques industriales hecha en el 2011 fue aleatoria. Si dispone exactamente de la misma información (pero ahora con la asignación aleatoria del programa) y estima el modelo planteado en el punto (a), ¿Esperaría que alguno de los estimadores de los parámetros del modelo no fuese estadísticamente distinto de cero? Cuál/es? ¿Por qué?

Solución: Sí, esperamos que haya un parametro que no sea estadísticamente distinto de cero.

En promedio, al haber asignación aleatoria no debería haber diferencias pre-tratamiento entre

controles y tratados, por lo que el estimador del parámetro que acompaña la variable binaria de tratamiento debiese ser cero (equivalente a decir que es estadísticamente no significativo).

(1.5 puntos) Por mencionar que se espera que el parámetro que acompaña la variable binaria de tratamiento debiese ser cero.

(1.5 puntos) Por argumentar correctamente.

Pregunta 4 (15 puntos)

El Proyecto STAR (Student/Teacher Achievement Ratio) fue un experimento aleatorio implementado en Tennessee a mediados de los años 80, en el cual estudiantes de kindergarten fueron asignados aleatoriamente a clases de distinto tamaño: pequeñas (13–17 estudiantes) y regulares (22–25 estudiantes).

Usted está interesado en estudiar el efecto causal del tamaño de clase sobre diferentes resultados como el rendimiento académico y la salud mental. Para ello usted cuenta con la tabla 2 que contiene información de estudiantes asignados a cada tipo de sala (columnas A y B) en tres momentos del tiempo (cada panel de la tabla): previo a la asignación de salas ($t = 0$), un año después ($t = 1$) y dos años después ($t = 2$). Lamentablemente, por razones de anonimato de la información, usted no dispone de un identificador que le permita identificar a un mismo estudiantes en el tiempo. Además, abajo de cada panel se incluye una fila con cantidad de individuos para quienes logró obtener información en cada etapa y, por último, la columna C contiene el valor p de la diferencia de las columnas A y B de cada fila.

Tabla 2: STAR

	(A) 13-17	(B) 22-25	(C) p-value (A)-(B)
Pre Tratamiento (t=0)			
% Mujeres	52	51	0.521
Edad	4.22	4.2	0.386
Ingreso per Capita	2.351	2.122	0.188
Puntaje Lenguaje	102.21	104.21	0.211
Observaciones	450	980	
Post Tratamiento (t=1)			
Puntaje Lenguaje	110.21	160.22	0.020
Stress	10.21	10.33	0.387
Observaciones	449	978	
Post Tratamiento (t=2)			
Puntaje Lenguaje	111.21	165.22	0.021
Stress	12.21	10.37	0.389
Observaciones	445	721	

a) Plantee un modelo que le permita identificar el efecto causal de interés por medio de una

regresión MCO en $t = 1$. Explique qué supuesto(s) le permitiría(n) interpretar el coeficiente obtenido como causal.

Solución

Se plantea el siguiente modelo genérico:

$$Y_i = \alpha + \beta_1 treat_i + \epsilon_i \quad (5)$$

Donde $treat_i$ corresponde a una binaria que indica si el estudiante fue asignado a una sala pequeña (A) en $t = 1$ y Y_i el outcome de interés (puntaje en lenguaje o stress, ya sea en $t = 1$ como en $t = 2$).

Este modelo logra identificar el efecto promedio del tratamiento bajo los siguientes supuestos:

- Asignación aleatoria: Se requiere de este supuesto para eliminar el sesgo de selección, ya que la distribución condicional de $Y_i(0)$ dado D_i independiente es igual a la distribución incondicional. La asignación aleatoria asegura que los grupos sean en promedio iguales excepto por el hecho de que unos asistieron a una sala pequeña y otros a una sala grande.
- SUTVA (valor del tratamiento es estable): se requiere que no haya interferencia entre unidades tratadas y no tratadas (en este caso las salas) por lo que el outcome Y_i solo depende de la asignación al tratamiento. A su vez, esto implica que el valor del tratamiento sea estable. Una violación a este supuesto se produciría, por ejemplo, si el contraste entre asistir a una sala pequeña (vs una grande) es diferente si el en el establecimiento donde se aplica hay muchas o pocas salas tratadas.

(1 punto) Por plantear y definir correctamente el modelo.

(2 puntos) Por fundamentar el supuesto de asignación aleatoria.

(2 puntos) Por fundamentar el supuesto de SUTVA.

- b) Imagine que uno de los profesores le comenta que el programa muestra muy buenos resultados en $t = 1$ porque en salas pequeñas es más fácil cuidar un ambiente propicio de concentración. Para asegurar lo anterior, le comenta que, incluso en ocasiones, decidieron enviar a estudiantes

disruptivos a las salas grandes y así preservar el objetivo de calma y silencio que se esperaba cumplir en una sala pequeña. Discuta si esta información modificaría en algo su análisis anterior y qué sugeriría considerar a la hora de interpretar su respuesta anterior.

Solución

En este caso aparece sesgo de contaminación entre grupos tratados y no tratados, de manera que la diferencia entre estos ya no pueda ser simplemente atribuible al tamaño de la sala, sino a un factor adicional (e.g. el hecho de que los profesores deciden enviar algún tipo de estudiante de una sala a otra). Más fundamentalmente, se violaría la aleatoriedad que permite decir que, en promedio, los grupos son iguales tanto en sus atributos observables como no observables. Al asignar un perfil de estudiantes para ser enviados de un tipo de salas a otras, ya no podremos asumir que, por ejemplo, la proporción de estudiantes con potencial de disrumpir el ambiente de la sala de clases sea el mismo en ambos tipos de salas. Esta intervención es problemática para efectos de la estimación porque además la condición que hace enviar a estudiantes de un grupo al otro tiene un alto potencial de afectar el rendimiento de los estudiantes. Este aspecto, al no ser modelado correctamente en la estimación, induce una correlación con el término de error que obliga a estimar el parámetro de interés de manera sesgada (Sesgo de variable relevante omitida).

Esta medida es esperable que favorezca aún más a las salas pequeñas y perjudique a las grandes, uno debería esperar que el coeficiente estimado en (5) exagere (sesgo hacia arriba) los beneficios de las salas pequeñas.

(2 puntos) Por fundamentar y explicar correctamente que ocurre una violación del supuesto de aleatoriedad.

(2 puntos) Por fundamentar que ocasiona un problema en los efectos de estimación al no ser modelada correctamente.

(2 puntos) Por indicar correctamente la dirección del sesgo.

- c) Plantee un modelo que le permita identificar el efecto causal de interés por medio de una regresión MCO en $t = 2$. Explique qué supuesto(s) le permitiría(n) interpretar el coeficiente obtenido como causal.

Solución Se plantea el mismo modelo que en (5), ajustando el outcome a lo observado en $t = 2$. Notar que se siga requiriendo de los supuestos de asignación aleatoria y SUTVA.

Sumado a lo anterior, al examinar el total de observaciones disponibles se observa un desbalance importante en la proporción de estudiantes que se mantiene en la muestra en un grupo y otro. Esta atrición diferencial es una amenaza a la comparabilidad de los grupos y podría ser indicio de un sesgo de selección (ej: podría existir una razón por la cual algunos alumnos desertan el estudio). La única forma de asumir que los grupos sigan siendo comparables en $t = 2$ consiste en asumir que la atrición o muerte muestral haya sido aleatoria. ¿Te parece creíble que ello haya ocurrido?

(1 punto) Por plantear correctamente el modelo.

(2 puntos) Por mencionar el desbalance ocurrido en la proporción de estudiantes.

(1 punto) Por comentar respecto a la atrición aleatoria (muerte muestral).