



Pontificia Universidad Católica de Chile
Escuela de Ingeniería
Departamento de Ingeniería Industrial y de Sistemas

ICS2563 Econometría Aplicada

Tarea 2 - Grupo 77

Integrantes:

- Agustina Caneo Huerta
- Franco Nicolai Corvalán Mansourova

Fecha de entrega: 2 de septiembre de 2025

Índice de contenido

1 Problema 1	3
1.1 Ítem a.	3
1.1.1 Gráfico: mujeres en comparación a hombres	3
1.1.2 Gráfico: sector salud en comparación al resto de los sectores	5
1.1.3 Gráfico: estamento profesional en comparación al resto de los estamentos	7
1.1.4 Gráfico: trabajadores contratados en calidad jurídica de planta en comparación a trabajadores a contrata	9
1.2 Ítem b.	10
1.3 Ítem c.	11
1.4 Ítem d.	12
2 Problema 2	15
2.1 Ítem a.	15
2.2 Ítem b.	16
2.3 Ítem c.	16
2.4 Ítem d.	18
2.5 Ítem e.	19
3 Problema 3	20
3.1 Ítem a.	20
3.2 Ítem b.	20
3.3 Ítem c.	21
3.4 Ítem d.	21
4 Problema 4	22
4.1 Ítem a.	23
4.2 Ítem b.	30

4.3 Ítem c y d.	34
5 Anexos	35

1. Problema 1

1.1. Ítem a.

A continuación, se presentan los gráficos de la distribución del pago de horas extraordinarias para distintos conjuntos, con el objetivo de comparar su comportamiento.

Para este análisis, se han considerado los siguientes supuestos:

- Solo se incluirán los datos correspondiente al mes de Agosto.
- Solo se incluirán los datos de pago de horas extraordinarias que sean mayores a cero y menores a \$1.000.000 CLP. El objetivo de esta restricción es centrar el análisis en los tramos con mayor variedad de datos y evitar la influencia de valores atípicos (outliers) extremos.

Importante: Esta decisión (la de solo considerar valores mayores a cero) es debido a que buscamos analizar del pago en horas extraordinarias, o sea, si este monto es cero, no hubo pago y por lo tanto, podemos inferir que no se desarrollaron horas extraordinarias.

- Se agregó una variable *dummy* para el sexo de los individuos, donde 0 corresponde a masculino y 1 a femenino.

A continuación los gráficos obtenidos:

1.1.1. Gráfico: mujeres en comparación a hombres




Imagen 1

Gráfico densidad *pago_hrs_ext*: mujeres en comparación a hombres

El gráfico de densidad muestra que la curva para las mujeres (línea roja) tiene un pico más alto y se concentra en montos bajos, indicando que la mayoría de ellas recibe pagos de horas extras más bajos. En cambio, la curva para los hombres (línea azul) es más plana y dispersa, lo que demuestra una mayor variedad y una distribución más amplia de los pagos. Esta diferencia visual clara señala una brecha salarial de género.

Importante: Uno de los supuestos mencionados era que, solo se consideran los valores de pago de horas extraordinarias que sean mayores de cero, este es un supuesto valido, pero como respuesta complementaria ejecutaremos el anterior desarrollo con los datos sin dicho supuesto, obteniendo:




Imagen 2

Gráfico densidad pago_hrs_ext: mujeres en comparación a hombres


1.1.2. Gráfico: sector salud en comparación al resto de los sectores**Imagen 3**

Gráfico densidad pago_hrs_ext: sector salud en comparación al resto de los sectores

El gráfico de densidad compara el pago de horas extraordinarias del sector salud (línea azul) con el resto de los sectores (línea roja). El sector salud presenta una curva más plana y dispersa, mientras que el resto de los sectores tiene una curva con un pico alto y estrecho en valores bajos. Esto sugiere que los pagos en el sector salud son más bajos y uniformes en comparación con la alta concentración de pagos mínimos en los otros sectores.

Importante: Uno de los supuestos mencionados era que, solo se consideran los los valores de pago de horas extraordinarias que sean mayores de cero, este es un supuesto valido, pero como respuesta complementaria ejecutaremos el anterior desarrollo con los datos sin dicho supuesto, obteniendo:




Imagen 4

Gráfico densidad pago_hrs_ext: sector salud en comparación al resto de los sectores


1.1.3. Gráfico: estamento profesional en comparación al resto de los estamentos**Imagen 5**

Gráfico densidad pago_hrs_ext: estamento profesional en comparación al resto de los estamentos

El gráfico de densidad compara los pagos por horas extras entre profesionales y el resto de los estamentos. La curva para los profesionales (línea azul) es más alta y aguda, lo que indica que una mayor concentración de ellos recibe pagos en los tramos más bajos. Por el contrario, la curva del resto de los estamentos (línea roja) es más plana y dispersa, lo que sugiere una distribución más equitativa y variada de los montos. Esto podría interpretarse como una brecha de pago, donde los profesionales, a pesar de su cargo, tienden a recibir menos por horas extras en comparación con la distribución más amplia que se observa en los demás estamentos.

Importante: Uno de los supuestos mencionados era que, solo se consideran los los valores de pago de horas extraordinarias que sean mayores de cero, este es un supuesto valido, pero como respuesta complementaria ejecutaremos el anterior desarrollo con los datos sin dicho supuesto, obteniendo:




Imagen 6

Gráfico densidad pago_hrs_ext: estamento profesional en comparación al resto de los estamentos

1.1.4. Gráfico: trabajadores contratados en calidad jurídica de planta en comparación a trabajadores a contrata




Imagen 7

Gráfico densidad pago_hrs_ext: trabajadores contratados en calidad jurídica de planta en comparación a trabajadores a contratas

El gráfico de densidad compara las distribuciones de pagos de horas extras entre trabajadores de planta y a contrata. La curva de los trabajadores a contrata (línea roja) muestra un pico más alto y angosto, lo que indica una alta concentración de estos trabajadores en los tramos de pago más bajos. Por otro lado, la curva de los trabajadores de planta (línea azul) es más baja y se extiende de manera más amplia a lo largo del eje x, sugiriendo una distribución de pagos más dispersa y una mayor probabilidad de recibir montos más elevados. Esta diferencias podría reflejar la peor calidad laboral y la falta de estabilidad que afecta a los trabajadores a contrata en comparación con los de planta.

Importante: Uno de los supuestos mencionados era que, solo se consideran los los valores de pago de horas extraordinarias que sean mayores de cero, este es un supuesto valido, pero como respuesta complementaria ejecutaremos el anterior desarrollo con los datos sin dicho supuesto, obteniendo:




Imagen 8

Gráfico densidad pago_hrs_ext: trabajadores contratados en calidad jurídica de planta en comparación a trabajadores a contrata

1.2. Ítem b.

Plantemos un modelo (MCO) que nos permita calcular la brecha de género en el pago de horas extraordinarias entre los trabajadores del sector salud.

Para este análisis, se han considerado los siguientes supuestos:

- Solo se incluirán los datos correspondiente al mes de Agosto.
- Solo se incluirán los datos correspondiente al sector de la salud.
- Solo se incluirán los datos de pago de horas extraordinarias que sean mayores a cero. El objetivo de esta restricción es centrar el análisis en los tramos donde efectivamente se hicieron horas extraordinarias, y por lo tanto, el pago de horas extraordinarias.
- Se agregó una variable *dummy* para el sexo de los individuos, donde 0 corresponde a masculino y 1 a femenino.

Con base en lo anterior, utilizaremos la solución matricial de un modelo de Mínimos Cuadrados Ordinarios (MCO), obteniendo:

$$\text{pago_hrs_ext} = \beta_0 + \beta_1 \cdot \text{sexo} + \varepsilon$$

Con:

β_0 : Representa el pago promedio de horas extraordinarias para el grupo de referencia, que en este caso corresponde a los hombres (cuando la variable sexo es igual a 0).

β_1 : Este coeficiente representa la diferencia en el pago promedio de horas extraordinarias entre el grupo de mujeres y el grupo de referencia (hombres). En otras palabras, β_1 es la brecha de género.

ε : Es el término de error o residuo, que captura la variación no explicada por el modelo.

La cual su solución del anterior modelo es:

$$\hat{\beta} = (X^T X)^{-1} X^T y$$

Esta fórmula nos permite encontrar el vector de coeficientes $\hat{\beta}$ que minimiza la suma de los residuos al cuadrado en un modelo de regresión lineal. Desde una perspectiva computacional, la ecuación se traduce en las siguientes manera:

```

1  f_MCO = function(X, y){
2
3    X_con_intercepto <- cbind(1, X)
4    XtX <- t(X_con_intercepto) %*% X_con_intercepto
5    XtX_inv <- solve(XtX)
6    Xty <- t(X_con_intercepto) %*% y
7    beta <- XtX_inv %*% Xty
8
9    resultado <- paste("Valor b0:", beta[1], "y valor b1:", beta[2])
10   return(resultado)}

```

Es fundamental mencionar la línea 3, donde se agrega una columna de unos a la matriz de datos X . Esto se debe a que la solución de Mínimos Cuadrados Ordinarios (MCO), que se utiliza para encontrar los coeficientes de un modelo de regresión lineal, está formulada para incluir un término de intercepto o sesgo.

1.3. Ítem c.

Luego de procesar los datos en el modelo del ítem b, obtenemos los siguientes resultados para los coeficientes del modelo de MCO:

El vector de coeficientes $\hat{\beta}$ se representa de forma matricial como un vector columna.

$$\hat{\beta} = \begin{pmatrix} \beta_0 \\ \beta_1 \end{pmatrix} = \begin{pmatrix} 100480.29 \\ -19641.88 \end{pmatrix}$$

El valor de $\hat{\beta}_1$ es negativo, lo que indica que, en promedio, las mujeres ganan \$19.641,88 CLP menos que los hombres en horas extraordinarias. Este resultado es notablemente menor que la diferencia simple de las medias, que es \$33.869,48 CLP.

Importante: Uno de los supuestos mencionados era que, solo se consideran los valores de pago de horas extraordinarias que sean mayores de cero, este es un supuesto válido, pero como respuesta complementaria ejecutaremos el anterior desarrollo con los datos sin dicho supuesto, obteniendo:

$$\hat{\beta} = \begin{pmatrix} \beta_0 \\ \beta_1 \end{pmatrix} = \begin{pmatrix} 75137.16 \\ -13985.18 \end{pmatrix}$$

El valor de $\hat{\beta}_1$ es negativo, lo que indica que, en promedio, las mujeres ganan \$-13,985.18 CLP menos que los hombres en horas extraordinarias

1.4. Ítem d.

Agregaremos al modelo de regresión lineal simple una serie de variables dummy para cada institución pública. El objetivo es controlar por las características institucionales que puedan influir en el pago de horas extraordinarias. El nuevo modelo de Mínimos Cuadrados Ordinarios (MCO) incluye la variable *sexo_dummy* y las variables *padre_org*, que representan la institución a la que pertenece cada trabajador:

$$\text{pago_hrs_ext} = \beta_0 + \beta_1 \cdot \text{sexo} + \beta_2 \cdot \text{inst}_2 + \cdots + \beta_k \cdot \text{inst}_k + \varepsilon$$

Después de procesar los datos con este modelo expandido, se obtienen los siguientes coeficientes:

$$\hat{\beta} = \begin{pmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \\ \hat{\beta}_{\text{Bienes Nacionales}} \\ \hat{\beta}_{\text{Ciencia Tecnología e Innovación}} \\ \hat{\beta}_{\text{Consejo Defensa del Estado}} \\ \hat{\beta}_{\text{Culturas y las Artes}} \\ \hat{\beta}_{\text{Defensa Nacional}} \\ \hat{\beta}_{\text{Deporte}} \\ \hat{\beta}_{\text{Desarrollo Social}} \\ \hat{\beta}_{\text{Economía Fomento y Turismo}} \\ \hat{\beta}_{\text{Educación}} \\ \hat{\beta}_{\text{Energía}} \\ \hat{\beta}_{\text{Hacienda}} \\ \hat{\beta}_{\text{Instituto Nacional de Hidráulica (INH)}} \\ \hat{\beta}_{\text{Interior y Seguridad Pública}} \\ \hat{\beta}_{\text{Justicia}} \\ \hat{\beta}_{\text{La Mujer y Equidad de Género}} \\ \hat{\beta}_{\text{Medio Ambiente}} \\ \hat{\beta}_{\text{Minería}} \\ \hat{\beta}_{\text{Obras Públicas}} \\ \hat{\beta}_{\text{Presidencia de la República}} \\ \hat{\beta}_{\text{Relaciones Exteriores}} \\ \hat{\beta}_{\text{Salud}} \\ \hat{\beta}_{\text{Secretaría General de Gobierno}} \\ \hat{\beta}_{\text{Secretaría General de la Presidencia}} \\ \hat{\beta}_{\text{Servicio Electoral}} \\ \hat{\beta}_{\text{Trabajo y Previsión Social}} \\ \hat{\beta}_{\text{Transportes y Telecomunicaciones}} \\ \hat{\beta}_{\text{Vivienda y Urbanismo}} \end{pmatrix} = \begin{pmatrix} 87380.33 \\ -22494.79 \\ -58498.56 \\ -60875.95 \\ -78087.39 \\ -61908.11 \\ 59384.25 \\ -67333.27 \\ -70653.00 \\ -67540.48 \\ -66786.70 \\ -64633.05 \\ 91777.75 \\ -15631.95 \\ -55965.44 \\ 57389.16 \\ -49500.81 \\ -66367.07 \\ -74546.35 \\ -52318.66 \\ 48644.40 \\ -75288.49 \\ 15069.53 \\ -20156.50 \\ -18858.46 \\ 62794.49 \\ -61608.09 \\ -67499.96 \\ -42700.60 \end{pmatrix}$$

El valor de $\hat{\beta}_{\text{sexo}}$ es negativo, lo que indica que, en promedio, las mujeres ganan \$22.494,78 CLP menos que los hombres en horas extraordinarias. Este valor es distinto al obtenido en el ítem c ($-\$19.641,88$ CLP). La discrepancia se puede explicar debido al teorema de Frisch-Waugh-Lovell, en cual es la base de la interpretación de las betas obtenidos. El nuevo modelo, al incluir las variables dummy para las organizaciones, aísla el efecto del género. Esto significa que la diferencia de \$22.494,78 representa una brecha de género más precisa, ya que se ha controlado por las particularidades salariales de cada institución. En otras palabras, la diferencia en el pago ya no es atribuible a factores institucionales.

Importante: Uno de los supuestos mencionados era que, solo se consideran los los valores de pago de horas extraordinarias que sean mayores de cero, este es un supuesto valido, pero como respuesta complementaria ejecutaremos el anterior desarrollo con los datos sin dicho supuesto, obteniendo:

$$\hat{\beta} = \begin{pmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \\ \hat{\beta}_{\text{Bienes Nacionales}} \\ \hat{\beta}_{\text{Ciencia Tecnología e Innovación}} \\ \hat{\beta}_{\text{Consejo Defensa del Estado}} \\ \hat{\beta}_{\text{Culturas y las Artes}} \\ \hat{\beta}_{\text{Defensa Nacional}} \\ \hat{\beta}_{\text{Deporte}} \\ \hat{\beta}_{\text{Desarrollo Social}} \\ \hat{\beta}_{\text{Economía Fomento y Turismo}} \\ \hat{\beta}_{\text{Educación}} \\ \hat{\beta}_{\text{Energía}} \\ \hat{\beta}_{\text{Hacienda}} \\ \hat{\beta}_{\text{Instituto Nacional de Hidráulica (INH)}} \\ \hat{\beta}_{\text{Interior y Seguridad Pública}} \\ \hat{\beta}_{\text{Justicia}} \\ \hat{\beta}_{\text{La Mujer y Equidad de Género}} \\ \hat{\beta}_{\text{Medio Ambiente}} \\ \hat{\beta}_{\text{Minería}} \\ \hat{\beta}_{\text{Obras Públicas}} \\ \hat{\beta}_{\text{Presidencia de la República}} \\ \hat{\beta}_{\text{Relaciones Exteriores}} \\ \hat{\beta}_{\text{Salud}} \\ \hat{\beta}_{\text{Secretaría General de Gobierno}} \\ \hat{\beta}_{\text{Secretaría General de la Presidencia}} \\ \hat{\beta}_{\text{Servicio Electoral}} \\ \hat{\beta}_{\text{Trabajo y Previsión Social}} \\ \hat{\beta}_{\text{Transportes y Telecomunicaciones}} \\ \hat{\beta}_{\text{Vivienda y Urbanismo}} \end{pmatrix} = \begin{pmatrix} 93307.76 \\ -20636.63 \\ -66895.14 \\ -69911.73 \\ -83208.52 \\ -68191.53 \\ 45402.88 \\ -73561.70 \\ -76572.97 \\ -74270.07 \\ -73770.61 \\ -72719.20 \\ 79138.56 \\ -17393.51 \\ -59714.33 \\ 55486.70 \\ -62023.56 \\ -65512.87 \\ -81842.74 \\ -60837.17 \\ 83410.59 \\ -80626.56 \\ 10245.91 \\ -29963.64 \\ -35618.28 \\ 97732.07 \\ -66361.00 \\ -69294.93 \\ -49467.64 \end{pmatrix}$$

Interpretación similar a la mencionada anteriormente pero con otros valores.

2. Problema 2

A continuación, se presentan el desarrollo del análisis de que el pago de horas extraordinarias de los trabajadores del sector público se encuentra relacionado con su remuneración bruta mensualizada. Para este análisis, se han considerado los siguientes supuestos:

- Solo se incluirán los datos correspondiente al mes de Agosto.
- Se agregó una variable *dummy* para el sexo de los individuos, donde 0 corresponde a masculino y 1 a femenino.

2.1. Ítem a.

Para estimar los coeficientes de un modelo bivariado, utilizaremos el método de Mínimos Cuadrados Ordinarios (MCO) en su forma manual-matricial. El objetivo es determinar la relación entre el pago mensual de horas extraordinarias (y) y la remuneración bruta mensualizada (x). El modelo de regresión que se busca estimar es:

$$y = \beta_0 + \beta_1 x + u$$

El vector de coeficientes estimados, $\hat{\beta}$, se obtiene mediante la fórmula:

$$\hat{\beta} = (X'X)^{-1}X'y$$

Aplicando esta fórmula a los datos, se obtienen los siguientes coeficientes:

$$\hat{\beta} = \begin{pmatrix} \beta_0 \\ \beta_1 \end{pmatrix} = \begin{pmatrix} 48215.4 \\ -0.002090202 \end{pmatrix}$$

La interpretación de los coeficientes estimados es:

- $\hat{\beta}_0 = 48215.4$: Este es el valor estimado del intercepto. Representa el pago mensual promedio de horas extraordinarias (en pesos) cuando la remuneración bruta mensualizada es cero. En este contexto, este valor carece de una interpretación económica directa, ya que una remuneración nula no es realista.
- $\hat{\beta}_1 = -0.002090202$: Este es el valor estimado de la pendiente. Indica que, por cada peso de aumento en la remuneración bruta mensualizada, el pago promedio de horas extraordinarias disminuye aproximadamente en 0.002 pesos. La relación entre las dos variables es negativa, lo que sugiere que a mayor remuneración bruta, menor es el pago de horas extra, en promedio.

2.2. Ítem b.

En este caso, se plantea un modelo de regresión lineal simple sin un intercepto, lo que significa que la recta de regresión está obligada a pasar por el origen (0,0). El modelo a estimar es el siguiente:

$$y = \beta_1 x + u$$

donde y es el pago mensual de horas extraordinarias y x es la remuneración bruta mensualizada.

El estimador de MCO para el coeficiente β_1 se obtiene mediante la expresión matricial simplificada:

$$\hat{\beta}_1 = (X'X)^{-1}X'y$$

Al aplicar esta fórmula con los datos proporcionados, se obtiene el siguiente coeficiente estimado:

$$\hat{\beta}_1 = 0.01316271$$

El coeficiente estimado de la pendiente, 0.01316271, indica que, por cada peso de aumento en la remuneración bruta mensualizada, el pago promedio de horas extra aumenta en aproximadamente 0.013 pesos. Esto sugiere una relación positiva entre ambas variables.

La principal diferencia con el modelo que incluye un intercepto es el signo y la magnitud del coeficiente de la pendiente. El modelo anterior mostraba una relación ligeramente negativa, mientras que este modelo muestra una relación positiva y más significativa. Esta discrepancia se debe a la restricción que impone el modelo sin intercepto, al forzar la recta de regresión a pasar por el origen. Dado que en la muestra la remuneración y el pago de horas extra no están centrados en el origen, esta restricción podría no ser una representación adecuada de la relación real entre las variables. Por lo tanto, el modelo con intercepto podría ser una mejor representación de los datos.

2.3. Ítem c.

Para analizar si la relación entre el pago de horas extraordinarias y la remuneración bruta mensualizada varía por sexo, es necesario plantear un modelo de regresión con un ****término de interacción****. Este tipo de modelo nos permite estimar no solo el efecto de cada variable independiente por separado, sino también cómo el efecto de una variable (remuneración) cambia según los niveles de otra variable (sexo).

El modelo propuesto para este análisis es una regresión lineal múltiple con un término de interacción. Las variables utilizadas son:

- y : Pago mensual de horas extraordinarias.
- x : Remuneración bruta mensualizada.

- D : Variable ficticia (dummy) para el sexo, donde $D = 1$ para mujeres y $D = 0$ para hombres.
- $x * D$: Término de interacción, que es el producto de la remuneración y la variable dummy.

El modelo se expresa de la siguiente manera:

$$y = \beta_0 + \beta_1 x + \beta_2 D + \beta_3 (x * D) + \varepsilon$$

Donde los coeficientes estimados tienen las siguientes interpretaciones:

- β_0 : Pago de horas extraordinarias esperado para un hombre con remuneración de cero.
- β_1 : Efecto marginal de la remuneración sobre el pago de horas extra para los hombres.
- β_2 : Diferencia en el pago de horas extra entre mujeres y hombres cuando la remuneración es cero.
- β_3 : Diferencia en el efecto marginal de la remuneración sobre el pago de horas extra entre mujeres y hombres.

A partir de la estimación del modelo, podemos calcular los efectos marginales de la remuneración sobre el pago de horas extraordinarias para cada sexo.

Los coeficientes estimados son:

$$\hat{\beta} = \begin{pmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \\ \hat{\beta}_2 \\ \hat{\beta}_3 \end{pmatrix} = \begin{pmatrix} 65563.71 \\ -0.005455916 \\ -25508.98 \\ 0.004975111 \end{pmatrix}$$

Para los hombres, el modelo se simplifica a:

$$y = \beta_0 + \beta_1 x + \beta_2(0) + \beta_3(x * 0) = \beta_0 + \beta_1 x$$

El efecto marginal de la remuneración es simplemente el coeficiente β_1 . Por lo tanto, el efecto marginal de la renta bruta mensualizada sobre el pago de horas extra en el caso de los hombres es: -0.005455916 . Esto indica que, por cada peso adicional en su remuneración bruta mensualizada, los hombres ven, en promedio, una disminución de 0.0055 pesos en el pago de sus horas extraordinarias.

Para las mujeres, el modelo se convierte en:

$$y = \beta_0 + \beta_1 x + \beta_2(1) + \beta_3(x * 1) = (\beta_0 + \beta_2) + (\beta_1 + \beta_3)x$$

El efecto marginal de la remuneración para las mujeres es la suma de los coeficientes β_1 y β_3 . Calculando esta suma:

$$\hat{\beta}_1 + \hat{\beta}_3 = -0.005455916 + 0.004975111 = -0.0004808053$$

Por lo tanto, el efecto marginal de la renta bruta mensualizada sobre el pago de horas extra en el caso de las mujeres es: -0.0004808053 . Esto significa que, por cada peso adicional en su remuneración bruta mensualizada, las mujeres ven, en promedio, una disminución mucho menor de 0.00048 pesos en el pago de sus horas extraordinarias.

En resumen, aunque el efecto marginal de la remuneración es negativo para ambos sexos, la disminución en el pago de horas extra es significativamente menor para las mujeres que para los hombres. El término de interacción ($\hat{\beta}_3$) captura precisamente esta diferencia en la pendiente.

2.4. Ítem d.

Para el análisis, se extendió el modelo de regresión anterior incorporando nuevas variables de control de forma acumulativa: sector de la economía (salud vs. el resto), estamento profesional, calidad jurídica de planta y variables binarias por institución pública. El objetivo es observar cómo la inclusión de estas variables afecta los coeficientes originales, especialmente el de la remuneración.

La siguiente tabla resume los coeficientes principales obtenidos de la estimación:

Variable	Coefficiente Estimado
(Intercepto)	3.497×10^{-9}
rem_mes_inf	1.234×10^{-2}
sexo	5.902×10^{-10}
rem_mes_inf:sexo	1.635×10^{-3}
estamento_dummy	1.632×10^{-9}
planta_dummy	8.833×10^{-10}

Tabla 1

Comparación de Coeficientes de Regresión obtenidos al ampliar modelo ítem c

La inclusión de las variables de control en el modelo d) generó cambios significativos en los coeficientes.

- Efecto de la remuneración (rem_mes_inf): En el modelo original, el coeficiente de la remuneración era negativo (-0.00546). Sin embargo, en el modelo d), este coeficiente se vuelve positivo (0.0123). Este cambio sugiere que la relación negativa observada inicialmente era en realidad una confusión causada por variables omitidas. Al controlar por factores como el estamento, la calidad jurídica y la institución, la verdadera relación entre remuneración y pago de horas extra emerge como positiva, lo cual es más intuitivo (a mayor salario, es probable que la tarifa por hora extra también sea mayor).

- Término de interacción (rem_mes_inf:sexo): El valor del término de interacción cambia de 0.00498 a 0.0016. Aunque sigue siendo positivo, su magnitud se reduce significativamente. Esto indica que la diferencia en la relación entre remuneración y pago de horas extra por sexo es menos pronunciada una vez que se controlan los demás factores. El efecto de la remuneración es ligeramente mayor para las mujeres ($0.0123 + 0.0016 = 0.0139$) que para los hombres (0.0123), lo que indica una diferencia de aproximadamente 13 % en la pendiente entre ambos grupos.
- Variables de control: Los coeficientes para *estamento_dummy* y *planta_dummy* son extremadamente cercanos a cero. Esto es un indicio de colinealidad o dependencia lineal entre las variables explicativas. La inclusión de numerosas variables ficticias para las instituciones públicas puede haber absorbido la variabilidad que estas variables intentan explicar.

2.5. Ítem e.

La variabilidad explicada en un modelo de regresión se refiere a qué tan bien las variables independientes explican la variabilidad de la variable dependiente. Esta se mide por el coeficiente de determinación (R^2).

Como regla general, el R^2 siempre aumenta o se mantiene igual al añadir una nueva variable a un modelo de regresión. En el caso de pasar de un modelo simple al modelo completo con más de 300 variables ficticias (dummies), es de esperar que el R^2 aumente significativamente. Esto se debe a que las variables dummies de *padre_org* y *organismo* capturan una gran cantidad de la variabilidad del pago de horas extras que está relacionada con la institución específica de cada individuo.

A pesar del aumento en el R^2 , el modelo no es robusto. La evidencia de esto es la colinealidad perfecta que resultó en coeficientes de cero para las variables *estamento_dummy* y el término de interacción *rem_mes_inf sexo*. Este hallazgo muestra que la relación entre las variables de interés se ve comprometida al añadir las variables ficticias, lo que hace que los resultados sean inestables e imposibles de interpretar de forma aislada.

En conclusión, mientras que el aumento del R^2 indica que el modelo se ajusta mejor a los datos, la aparición de la colinealidad perfecta y la consecuente pérdida de interpretabilidad de los coeficientes de variables importantes demuestran que el modelo de la pregunta 2d no es robusto.

3. Problema 3

En esta sección se estudia cómo ciertas condiciones administrativas de la relación laboral (estamento y calidad jurídica) se relacionan con el pago de horas extraordinarias, controlando por características individuales. Para ello se utilizan los datos del mes de agosto y se estiman modelos por Mínimos Cuadrados Ordinarios (MCO), tanto de manera directa como mediante el teorema de Frisch-Waugh-Lovell (FWL).

3.1. Ítem a.

Se plantea el siguiente modelo lineal:

$$pago_hrs_i = \beta_0 + \beta_1 rem_mes_i + \beta_2 sexo_i + \beta_3 profesional_i + \beta_4 planta_i + \beta_5 salud_i + u_i$$

La variable dependiente es el pago de horas extraordinarias. Las variables explicativas son: remuneración bruta mensual (*rem_mes_inf*), sexo (dummy que vale 1 si es mujer), una dummy para estamento profesional, una dummy para contrato planta y una dummy para pertenencia al sector salud.

Los coeficientes estimados fueron:

$$\hat{\beta} = (34,905.51, -0.002835, -17,402.11, 9,212.00, 4,405.16, 37,835.18)$$

Con:

- El coeficiente de **profesional** indica que los trabajadores de este estamento reciben, en promedio, \$9,212 adicionales en horas extra en comparación con otros estamentos, controlando por las demás variables.
- El coeficiente de **planta** muestra que los contratos en calidad jurídica de planta tienen en promedio \$4,405 más en pago de horas extra respecto a los a contrata.
- Pertenecer al **sector salud** está asociado a un pago promedio \$37,835 mayor en horas extra, reflejando la alta concentración de este gasto en dicho sector.

3.2. Ítem b.

Se reestimó el efecto de las variables **profesional** y **planta** mediante el teorema de Frisch-Waugh-Lovell (FWL). Esto implica:

1. Regresar Y (variable dependiente) sobre las variables de control (*rem_mes*, sexo y salud) y guardar los residuos.

2. Regresar las dummies de interés (profesional y planta) sobre las mismas variables de control y guardar los residuos.
3. Estimar el modelo de los residuos de Y contra los residuos de las variables de interés.

Los coeficientes obtenidos fueron:

$$\hat{\beta}_{profesional} = 9,212.00, \quad \hat{\beta}_{planta} = 4,405.16$$

Estos valores coinciden (hasta la precisión numérica) con los coeficientes de la regresión múltiple directa. Esto confirma empíricamente la equivalencia entre la estimación por FWL y la estimación MCO completa.

Interpretación intuitiva: Los residuos al regresar $Y(u_1)$ representan la parte de (Y) que no es explicada por los controles. Los residuos al regresar las dummies de interés (u_2) representan la parte de las dummies que no está correlacionada con los controles. Al regredir (u_1) sobre (u_2) se estima el efecto (libre de la correlación con los controles) de las dummies sobre (Y) . Por teoría, se obtienen coeficientes idénticos al que arroja la regresión múltiple completa.

3.3. Ítem c.

Definición:

Si $\hat{Y} = X\hat{\beta}$ son las predicciones del modelo y $e = Y - \hat{Y}$ los residuos, la suma de residuos cuadrados se define como:

$$SSR = \sum_{i=1}^n e_i^2 = e'e.$$

Obteniendo:

$$SSR_{MCO} = SSR_{FWL} = 3.88771039448710 \times 10^{14}$$

La diferencia calculada dio un valor próximo a -0.3125, que es de orden mucho menor que la magnitud del SSR: esta diferencia es debida únicamente a errores de precisión numérica (redondeo en operaciones de punto flotante) y no indica una discrepancia estadística o de implementación.

Conclusión: La igualdad de los SSR confirma que la estimación particionada y la estimación MCO completa producen el mismo ajuste del modelo. Además, el resultado empírico (igualdad dentro del error de máquina) es una verificación adicional de la correcta implementación del procedimiento FWL. La diferencia entre ambas es nula (salvo por error numérico de redondeo). Esto confirma que ambos métodos producen el mismo ajuste global del modelo.

3.4. Ítem d.

Se reestimó el modelo excluyendo las variables **profesional** y **planta**:

$$\text{pago_hrs}_i = \beta_0 + \beta_1 \text{rem_mes}_i + \beta_2 \text{sexo}_i + \beta_3 \text{salud}_i + u_i$$

El coeficiente de determinación R^2 se calculó a partir de la fórmula:

$$R^2 = 1 - \frac{SSR}{SST},$$

donde $SSR = \sum (y_i - \hat{y}_i)^2$ corresponde a la suma de los residuos cuadrados del modelo, y $SST = \sum (y_i - \bar{y})^2$ corresponde a la suma total de cuadrados de la variable dependiente respecto a su media. Los resultados obtenidos fueron:

$$R_a^2 \approx 0.03108, \quad R_b^2 \approx 0.03108, \quad R_{reducido}^2 \approx 0.02966.$$

Comentario: El coeficiente de determinación del modelo reducido es menor que el de los modelos completo y particionado. La diferencia de aproximadamente 0.0014 refleja la contribución de las variables **profesional** y **planta** a la capacidad explicativa del modelo. Aunque el efecto es pequeño, su inclusión mejora el ajuste global.

Conclusión: Los resultados muestran que el estamento, la calidad jurídica y la pertenencia al sector salud tienen un efecto positivo sobre el pago de horas extraordinarias. Además, se comprobó que el uso del teorema de Frisch-Waugh-Lovell permite obtener los mismos resultados que la regresión múltiple directa, y que excluir variables relevantes reduce la capacidad explicativa del modelo.

4. Problema 4

Plantemos un modelo (MCO) vía el procedimiento conocido como Bootstrap, que nos permita extraer conclusiones sobre la muestra general. Para este análisis, se han considerado los siguientes supuestos:

- Solo se incluirán los datos correspondiente al mes de Agosto para el desarrollo del ítem a. Para el ítem b se usara el completitud de los registros existentes, o sea, todos los meses.
- Solo se incluirán los datos de pago de horas extraordinarias que sean mayores a cero. El objetivo de esta restricción es centrar el análisis en los tramos donde efectivamente se hicieron horas extraordinarias, y por lo tanto, el pago de horas extraordinarias.

Importante: Esta decisión es fundamental, ya que excluye muestra, por lo que los valores obtenidos daran distintos a los obtenidos si se considera todos los valores de pago de horas extraordinarias, pero a pesar de eso, es coherente la decisión tomada.

Importante: Esta decisión (la de solo considerar valores mayores a cero) es debido a que buscamos analizar del pago en horas extraordinarias, o sea, si este monto es cero, no hubo pago y por lo tanto, podemos inferir que no se desarrollaron horas extraordinarias.

- Se agregó una variable *dummy* para el sexo de los individuos, donde 0 corresponde a masculino y 1 a femenino.
- Se agregó una variable *dummy* para el estamento, donde 1 corresponde a profesional y 0 al resto.
- Se agregó una variable *dummy* para la calidad jurídica, donde 1 corresponde a planta y 0 al resto.
- Se agregó una variable *dummy* para padre_org, donde 1 corresponde a salud y 0 al resto.
- Solo se incluirán los datos correspondiente a las siguientes columnas: rem_mes_inf, pago_hrs_ext, sexo_dummy, profesional_dummy, planta_dummy y salud_dummy.

Con base en lo anterior, realizaremos un algoritmo de Bootstrap que se encontrara el archivo adjunto a la presente entrega, que rescatara los valores de, el coeficiente asociado a la remuneración y el coeficiente de determinación (R^2) asociado al modelo.

4.1. Ítem a.

Para analizar cómo la variación en el tamaño de la muestra y el número de iteraciones afecta el valor de los estimadores, ejecutamos el algoritmo previamente definido con distintos valores de iteraciones, en este caso 50, 100 y 300, obteniendo así en particular los valores de coeficiente asociado a la remuneración y el coeficiente de determinación (R^2). Antes de continuar sera indispensable explicar que corresponden estos coeficientes:

- Coeficiente asociado a la remuneración (beta): En términos sencillos, el valor del coeficiente te dice cuánto cambia el pago promedio de horas extra por cada unidad de cambio en la variable independiente, manteniendo las otras variables del modelo constantes.
- Coeficiente de determinación (R^2): El R^2 es una medida de la bondad de ajuste del modelo. Es un valor que oscila entre 0 y 1 y indica qué proporción de la variabilidad de la variable dependiente (el pago de horas extra) puede ser explicada por las variables independientes. Un valor de (R^2) cercano a 1 significa que el modelo explica casi toda la variabilidad de los datos, mientras que un valor cercano a 0 indica que el modelo no tiene mucho poder explicativo. Es una forma de saber qué tan bien el modelo se ajusta a los datos observados.

Una vez explicado lo anterior, presentamos los resultados obtenidos de forma gráfica a continuación:

Importante: En los siguientes gráficos, solo se muestran los resultados correspondientes a las iteraciones 50 y 300. Esta selección tiene como objetivo ilustrar de forma clara las diferencias en los resultados en los casos bordes mencionados. Cabe destacar que el procesamiento completo del algoritmo requiere un tiempo considerable, con una duración mínima de 45 minutos, por eso tomamos esta decisión.




Imagen 9

Gráfico de evolución de coeficiente de remuneración respecto a N, con 50 iteraciones


**Imagen 10**

Gráfico de evolución R^2 respecto a N, con 50 iteraciones


**Imagen 11**

Gráfico de evolución de coeficiente de remuneración respecto a N, con 300 iteraciones


**Imagen 12**

Gráfico de evolución de R^2 respecto a N, con 300 iteraciones


**Imagen 13**

Gráfico estabilidad del coeficiente de remuneración por tamaño de iteración


**Imagen 14**

Gráfico estabilidad del coeficiente de determinación R^2 por tamaño iteración

Según las imágenes 5 a 8 que contrastan los coeficientes con la variación del tamaño de la muestra, se observa que cuanto mayor es el conjunto de datos (N), más eficientes y estables son los valores de los coeficientes buscados. A pesar de que existe cierto ruido en los datos, se puede notar que a medida que N aumenta, los estimadores convergen hacia un valor constante. Este fenómeno se fundamenta en la Ley de los Grandes Números, que establece que a medida que el tamaño de la muestra crece, el promedio de los resultados (en este caso, el valor de los coeficientes) se aproxima al valor real esperado. En su caso, se puede observar que a partir de $N = 10.000$ se alcanza una estabilidad tanto en el coeficiente de remuneración como en el R^2 . Esta estabilidad es crucial para la inferencia, ya que nos indica que el modelo se ha ajustado a la variabilidad general de los datos y no a las particularidades de una muestra pequeña.

Las imágenes 9 y 10, que analizan el valor de los estimadores con la cantidad de iteraciones, muestran la convergencia del algoritmo. Los puntos estables en los que los estimadores se asientan coinciden con las observaciones realizadas al variar el tamaño de la muestra. En las primeras iteraciones, los estimadores cambian drásticamente, pero a medida que el algoritmo avanza, se acercan a su valor óptimo, donde el error del modelo es mínimo. Con el suficiente número de iteraciones, los estimadores convergen a una solución estable. Si bien el gráfico puede mostrar algunos valores atípicos al inicio, el proceso de iteración asegura que el modelo se ajuste de manera progresiva, garantizando que la solución final sea la más robusta posible para el conjunto de datos proporcionado.

Importante: Uno de los supuestos mencionados era que, solo se consideran los los valores de pago de horas extraordinarias que sean mayores de cero, este es un supuesto valido, pero como respuesta complementaria ejecutaremos el anterior desarrollo con los datos sin dicho supuesto, obteniendo:




Imagen 15

Gráfico de evolución de coeficiente de remuneración respecto a N, con 50 iteraciones




Imagen 16

Gráfico de evolución R^2 respecto a N, con 50 iteraciones

Importante: Uno de los supuestos mencionados era que, solo se consideran los los valores de pago de horas extraordinarias que sean mayores de cero, este es un supuesto valido, pero como respuesta complementaria ejecutaremos el anterior desarrollo con los datos sin dicho supuesto, obteniendo:




Imagen 17

Gráfico de evolución de coeficiente de remuneración respecto a N, con 300 iteraciones




Imagen 18

Gráfico de evolución de R^2 respecto a N, con 300 iteraciones

Importante: Uno de los supuestos mencionados era que, solo se consideran los los valores de pago de horas extraordinarias que sean mayores de cero, este es un supuesto valido, pero como respuesta complementaria ejecutaremos el anterior desarrollo con los datos sin dicho supuesto, obteniendo:




Imagen 19

Gráfico estabilidad del coeficiente de remuneración por tamaño de iteración




Imagen 20

Gráfico estabilidad del coeficiente de determinación R^2 por tamaño iteración

4.2. Ítem b.

A continuación, se presenta la comparación de los resultados obtenidos al ejecutar el mismo algoritmo de MCO. Se contrastan los coeficientes estimados y el R^2 del modelo que utiliza únicamente los

datos de agosto con los resultados obtenidos al procesar los datos de todos los meses del año.

- **Importante:** En los siguientes gráficos, solo se muestran los resultados correspondientes a la estabilidad de los coeficientes respecto a tamaño de iteración. Esto es debido a que consideramos que corresponde a la gráfica más relevante para sacar conclusiones sobre la eficacia de los valores obtenidos.
- **Importante:** En los siguientes gráficos, solo se muestran los resultados correspondientes a 300 iteraciones.




Imagen 21

Gráfico estabilidad del coeficiente de remuneración por tamaño de muestra

Los valores obtenidos de la estabilidad del coeficiente de remuneración por tamaño de muestra, son:

- Media obtenida en datos de mes de agosto: -0.002314095
- Media obtenida en datos todos los meses: -0.002233881
- Diferencia absoluta entre medias: 8.021409×10^{-5}

Podemos observar que los valores obtenidos son valores bastante similares, aunque con una diferencia no menor dado los valores del coeficiente de remuneración. De hecho el valor anteriormente estimado, el de agosto, corresponde a un 4 % mayor al valor estimado en todos los meses.

Al comparar el gráfico de densidad del mes de agosto con el de todos los demás meses, podemos observar una diferencia en la distribución de los pagos por horas extraordinarias. Agosto: La curva de densidad de agosto muestra un pico más pronunciado en un intervalo específico. Esto sugiere

que los pagos por horas extras durante este mes están más concentrados en un rango particular de valores, indicando que fue un período con una tendencia más uniforme en los registros de pago. Otros meses: En contraste, la curva de densidad para el resto de los meses es más dispersa y se asemeja a una distribución de probabilidad más amplia, similar a la de una distribución t-Student con alta variabilidad. Esto puede interpretarse como una falta de focalización en los montos de pago, lo que se refleja en la menor densidad en un intervalo determinado y una mayor dispersión.




Imagen 22

Gráfico estabilidad del coeficiente de determinación R^2 por tamaño de muestra

Los valores obtenidos de la estabilidad del coeficiente de determinación R^2 por tamaño de muestra, son:

- Media obtenida en datos de mes de agosto: 0.03872832
- Media obtenida en datos todos los meses: 0.03707897
- Diferencia absoluta entre medias: 0.001649348

Podemos observar que los valores obtenidos son valores bastante similares, aunque con una diferencia no menor dado los valores de R^2 . De hecho el valor anteriormente estimado, el de agosto, corresponde a un 5.3% mayor al valor estimado en todos los meses.

De esto podemos inferir que, si bien los datos son muy representativos, existe una dependencia de los registros de los meses obtenidos. Es posible que el mes de agosto haya tenido un número de registros significativamente mayor en comparación con el resto de los meses.

Sin embargo, desde una perspectiva objetiva, la diferencia es tan ínfima que, considerando la complejidad y la gran cantidad de datos que implica procesar la información de todos los meses, resulta altamente conveniente analizar solo una muestra, como la de agosto.

Importante: Uno de los supuestos mencionados era que, solo se consideran los los valores de pago de horas extraordinarias que sean mayores de cero, este es un supuesto valido, pero como respuesta complementaria ejecutaremos el anterior desarrollo con los datos sin dicho supuesto, obteniendo:




Imagen 23

Gráfico estabilidad del coeficiente de remuneración por tamaño de iteración




Imagen 24

Gráfico estabilidad del coeficiente de determinación R^2 por tamaño de muestra

4.3. Ítem c y d.

El análisis desarrollado nos permite concluir que el método Bootstrap es una herramienta válida que puede ser eficaz para el desarrollo de inferencias en ciertos escenarios. En este caso particular, se obtuvo un resultado demasiado similar al análisis de agosto en comparación con el de los otros meses, lo cual sugiere que es una buena herramienta para obtener conclusiones a partir de una muestra de datos. Sin embargo, considero que la implementación de este método agrega una considerable complejidad a nivel de manejo de datos, programación y análisis de resultados. En mi opinión, sería mucho más eficiente realizar un análisis con una simple regresión lineal multivariada.

Como respuesta a mi compañero, le diría que como todo método estadístico tiene sus pros y contras, pero en ambos casos sale conveniente levantar este método.

5. Anexos




Imagen 25
Conversación con Google Gemini




Imagen 26
Conversación con Google Gemini



Imagen 27
Conversación con Google Gemini



Imagen 28
Conversación con Google Gemini