



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE
DEPARTAMENTO DE INGENIERÍA INDUSTRIAL Y DE SISTEMAS
ICS2563 - ECONOMETRÍA APLICADA 2025'2

Tarea 2

19 de agosto del 2025

Profesores: Patricio Domínguez
Gonzalo Gaete

Ayudantes: Mauricio Correa (mauricio.correa@uc.cl)
Alonso Parada (alonso.parada@uc.cl)

Aspectos generales

1. La tarea puede ser desarrollada en forma individual o en parejas (2 estudiantes) de una misma sección. **Debe inscribirse con su pareja en un grupo habilitado en Canvas para esta tarea. Aún cuando realice su tarea de manera individual, debe inscribirse en un grupo sin miembros.**
2. La fecha de entrega de la tarea es el **01 de septiembre a las 23:00 hrs** en el portal del curso en Canvas.
3. La entrega debe incluir el script de R (o el dofile de STATA) y un informe de análisis en formato pdf.
4. La entrega debe realizarse subiendo cada archivo por separado en Canvas. **No se aceptarán archivos en formato .zip.**
5. Para el análisis de contenidos específicos del curso, no podrá hacer uso de paquetes disponibles en R o STATA como los comandos `lm` o `reg`, respectivamente. Ud deberá realizar las estimaciones usando las derivaciones de fórmulas enseñadas en el curso. Cualquier uso de paquetes o comando pre-elaborados deberá ser justificado y podría ser penalizado. En caso de ambigüedades, consulte por el foro correspondiente si se puede utilizar algún paquete en específico.
6. Sobre el **informe**:
 - a) Se requiere que el informe debe incorporar las respuestas a todas las preguntas, incorporando las figuras y/o tablas que estime conveniente.
 - b) Es **obligatorio** el uso del compilador de texto L^AT_EX. Se facilitará una plantilla TeX en CANVAS para redactar sus respuestas. **No debe copiar el enunciado**

de las preguntas en su informe.

7. Sobre el **código**:

- a) Cada entrega debe incluir el script de R (o el dofile de **STATA**) desde donde se corre todo el análisis.
- b) Cada análisis debe ser desarrollado por ustedes mismos utilizando vectores y matrices; el uso de paquetes estadísticos será penalizado. Se indicará en las preguntas cuando deben realizar cálculos “a mano”, es decir, utilizando fórmulas vistas en clases, vectores y matrices.
- c) Es importante que el código esté adecuadamente comentado para facilitar su corrección. Por ejemplo, indicar qué parte del informe/preguntas se desarrollan en cada sección del código.
- d) **Reproducibilidad:** El código debiera estar escrito de manera tal que cualquier persona lo pueda correr, y reproducir los resultados desde su computador. En el caso de crear datos aleatorios recomendamos fijar una semilla que permita reproducir los resultados tal cual queden especificados en el informe de reporte.

- 8. Parte de la tarea es que se vean enfrentados a tomar decisiones. Si deben aplicar criterio, háganlo y justifiquen sus elecciones.
- 9. Ante dudas o preguntas, se recomienda fuertemente la utilización del foro de preguntas del curso en CANVAS. Las respuestas pueden servir a otros compañeros, que se enfrentan a las mismas dudas. **No se permite publicar respuestas.**
- 10. Para la tarea, a menos que se especifique lo contrario, la función real log es el logaritmo natural.
- 11. Para el desarrollo de la tarea se permite el uso de herramientas de Inteligencia Artificial (IA), como por ejemplo ChatGPT, siempre y cuando **no se copie de forma textual lo generado por la IA**. En caso de utilizar alguna herramienta de este estilo, se debe proporcionar todo lo que se entregue y obtenga de ella como captura de pantalla en el anexo del informe (es decir, incluyendo tanto las preguntas realizadas como las respuestas que entrega la IA). Si se detecta el uso de alguna herramienta de IA sin la citación requerida se considerará la tarea como plagio, y se tomarán las acciones pertinentes en tales casos.¹
- 12. La tarea tiene un total de **24 puntos**, en donde la presentación del informe tiene 1.5 puntos (el informe debe incorporar las respuestas a todas las preguntas, y las figuras y/o tablas que estime necesarias además debe estar ordenado para obtener el puntaje), y la presentación de un *script* ordenado que facilite la corrección tiene 0.5 puntos. En caso que el informe no se realice en formato L^AT_EX, no se obtendrá puntaje por presentación

¹En los anexos del documento se presenta un ejemplo de cómo citar correctamente el uso de una herramienta de IA.

del informe. En caso de no entregar script sus respuestas no tendrán puntaje debido a que es necesario mostrar el desarrollo de como se obtienen los resultados.

13. La tarea puede contener algunas preguntas interrelacionadas. Quienes no hayan podido completar la pregunta que esté vinculada, se les sugiere asumir un valor o distribución de valores (según corresponda) por su cuenta y desarrollar el análisis de cada pregunta en forma independiente.

Descripción de la tarea y pasos previos:

El objetivo de esta tarea es aplicar conocimientos sobre regresiones lineales multivariados. En particular, la tarea demanda la estimación e interpretación de modelos de regresión, comprender la relación entre la distribución de las variables y los estimadores, y el conocimiento de propiedades algebraicas que permiten cuantificar la asociación entre variables. Para ello, se analiza el mercado laboral en el Sector Público, utilizando datos reales de funcionarios durante el 2024, archivo disponible en Canvas llamado `salarios_transparencia.dta`.

Esta tarea se concentrará en el estudio del pago en horas extraordinarias al personal de planta y contrata de organismos del Gobierno Central. En términos agregados, durante el 2023 se destinaron \$176.384 millones de pesos al pago de horas extraordinarias, mientras que el 2024, \$200.605 millones de pesos.² En particular, este monto corresponde al 13,2 % del total de la remuneración bruta percibida por los trabajadores que realizaron horas extraordinarias.

La tarea contiene algunas preguntas interrelacionadas. Quienes no hayan podido completar la pregunta que esté vinculada, se les sugiere asumir un valor o distribución de valores (según corresponda) por su cuenta y desarrollar el análisis de cada pregunta en forma independiente.

Para esta tarea se recomienda crear algunas funciones que serán utilizadas a lo largo de todas las preguntas, como una que calcule los coeficientes MCO de una regresión lineal múltiple, facilitando así el trabajo.

Luego de las preguntas sigue un diccionario con el nombre de las variables a utilizar en la tarea, junto con sus definiciones (Ver Tabla 1).

²Estimaciones propias utilizando la información de Transparencia Activa compilada por el Portal de Transparencia.

Pregunta 1 (5 puntos)

En el sector público, existe una marcada dispersión en el pago de horas extraordinarias. Para esto, se le solicita analizar dicha dispersión en función tanto de características individuales de los trabajadores como institucionales. Utilizando la base de datos provista y considerando únicamente los registros del mes de agosto, realice lo siguiente:

- a) Para cada uno de los siguientes puntos, presente, en un solo gráfico, la distribución del pago de horas extraordinarias que compare³:
- I) Mujeres en comparación a hombres.
 - II) Trabajadores del sector salud en comparación al resto de los sectores.
 - III) Trabajadores que pertenecen al estamento profesional en comparación al resto de los estamentos.
 - IV) Trabajadores contratados en calidad jurídica de planta en comparación a trabajadores a contrata.

Comente respecto a las diferencias observadas.

(1 punto)

Solución: A continuación, se presentan los gráficos solicitados.




Figura 1: Histograma de comparando entre hombres y mujeres.

³Nota: Solo debe incluir a las observaciones con pago de horas extras menor a 1.000.000




Figura 2: Histograma de Trabajadores del sector salud en comparación al resto de los sectores.




Figura 3: Histograma de Trabajadores que pertenecen al estamento profesional en comparación al resto de los estamentos.




Figura 4: Histograma de trabajadores contratados en calidad jurídica de planta en comparación a trabajadores a contrata.

Los hombres presentan, en promedio, un mayor pago por horas extraordinarias. Además, la dispersión también es mayor en la distribución de los hombres. El pago de horas extraordinarias entre las mujeres se encuentra concentrado en montos bajos, lo que podría deberse tanto a diferencias en cargos como a restricciones no laborales que afectan su disponibilidad de tiempo.

En el sector salud se observan montos más altos de pago de horas extraordinarias en comparación con otros sectores, además de una mayor dispersión. Una potencial explicación responde a la naturaleza del trabajo, donde el sistema de turnos y emergencias implican un mayor trabajo por sobre la jornada ordinaria.

Los profesionales muestran una mayor dispersión, con una distribución más uniforme en comparación a la del resto de los funcionarios. En particular, una mayor proporción de los profesionales, en comparación a los no profesionales, presentan pagos por horas extraordinarias en la parte alta de la distribución. Esto puede explicarse porque el pago de horas extraordinarias es función de la remuneración, la cual tiende a ser mayor en los profesionales.

Los funcionarios con contratos en calidad jurídica de planta presentan una mayor dispersión en el pago de horas extraordinarias, con una distribución más uniforme en comparación a los funcionarios en calidad jurídica de contrata. Al igual que en el caso de los trabajadores profesionales, esto puede en parte explicarse porque el pago de horas extraordinarias es función de la remuneración, y los trabajadores en calidad de planta suelen tener remuneraciones mayores.

(0.5 puntos cada una) De los cuales 0.3 corresponde a mencionar diferencias correctamente

y 0.2 por el gráfico.

Nota: Podía ser tanto un gráfico de densidad como histograma.

- b) Plantee un modelo (MCO) que, usando sus parámetros luego de ser estimado, le permita calcular la brecha de género en el pago de horas extraordinarias entre los trabajadores del sector salud. Estime dichos parámetros en forma manual-matricial (**2 puntos**).

Solución: El modelo de regresión que permite calcular la brecha de género en el pago de horas extraordinarias entre los trabajadores del sector salud es el siguiente:

$$pago_hrs_ext_tot_inf_i = \beta_0 + \beta_1 salud_i \cdot mujer_i + \beta_2 salud_i + \beta_3 mujer_i + \epsilon_i$$

A continuación, se presenta en una tabla los valores de los coeficientes:

Coeficientes	β_0	β_1	β_2	β_3
Valor	43488	16304	30217	-29677

Tabla 1: Tabla de coeficientes del modelo con binaria mujer

También, se podría haber planteado el modelo usando la binaria **hombre**. En ese caso, el modelo sería el siguiente:

$$pago_hrs_ext_tot_inf_i = \beta_0 + \beta_1 salud_i \cdot hombre_i + \beta_2 salud_i + \beta_3 hombre_i + \epsilon_i$$

Obteniendo los siguientes coeficientes:

Coeficientes	β_0	β_1	β_2	β_3
Valor	13812	-16304	46521	29677

Tabla 2: Tabla de coeficientes del modelo con binaria mujer

(1 punto): Por plantear correctamente el modelo.

(1 punto): Por estimar correctamente los coeficientes del modelo.

- c) ¿Cuál es la diferencia del pago promedio de horas extraordinarias entre los hombres que trabajan en el sector salud con los que trabajan en otros sectores? (**1 punto**).

Solución:

Para calcular la diferencia no es necesario estimar los valores promedios por sexo. En el caso del modelo con la binaria **mujer**, notar que la diferencia promedio entre los

trabajadores hombres del sector salud y los trabajadores hombres de los otros sectores se ve capturada por el coeficiente $\beta_2 = 30,217$. Usando el modelo con la binaria **hombre**, la diferencia promedio entre hombres del sector salud con el resto de los hombres es $\beta_1 + \beta_2 = 30,217$, obteniendo el mismo valor que en el otro modelo.

(0.5 puntos): Por señalar correctamente que la diferencia está dada por β_2 en el caso del modelo con **mujeres** y por $\beta_1 + \beta_2$ en el caso de **hombres**.

(0.5 puntos): Por obtener correctamente el valor.

- d) Agregue a su modelo especificado en (b) una *dummy* por cada institución pública, con el fin de controlar por características institucionales, y vuelva a contestar la pregunta del punto (c) con su nuevo modelo. Compare y justifique la diferencia/similitud en el valor obtenido **(1 punto)**.

Solución: Se generó *dummies* para controlar por características institucionales, se eliminó "Vivienda y Urbanismo" para dejarla como categoría base, y así evitar colinealidad perfecta. Además, se eliminó "Salud" de esta lista, ya que está previamente contenida en el modelo. A continuación, se presenta la tabla con los coeficientes estimados:

Coeficientes	β_0	β_1	β_2	β_3
Valor	30173.57	5217.45	43531	-18590.07

Tabla 3: Tabla de coeficientes del modelo mujer en d)

Recordar que el coeficiente que captura la variación para el modelo **mujer** es β_2 . Al comparar con los resultados anteriores, se observa que la inclusión de *dummies* por institución pública permite capturar endogeneidad no observada asociada a las características institucionales. Lo anterior, implica un cambio cuantitativo importante en los coeficientes (magnitud), aunque cualitativamente se mantienen (signo). En particular, la diferencia promedio del pago de horas extraordinarias entre los hombres del sector salud y el resto de hombres es aun mayor.

(0.25 puntos): Por eliminar alguna columna para evitar colinealidad perfecta.

(0.25 puntos): Por calcular correctamente el valor.

(0.5 puntos): Por comparar y justificar las diferencias observadas.

Pregunta 2 (8 puntos)

Se le sugiere que el pago de horas extraordinarias de los trabajadores del sector público se encuentra relacionado con su remuneración bruta mensualizada. Para estudiar dicha relación, utilizando la base de datos provista y considerando únicamente los registros del mes de agosto, se le solicita que realice el siguiente procedimiento:

- a) Mediante una regresión por MCO, estime en forma manual-matricial los coeficientes de un modelo bivariado en el cual el pago mensual de horas extraordinarias es explicado por la remuneración bruta mensualizada. Interprete el estimador del parámetro de esta última variable **(1 punto)**.

Solución: Se debe estimar la siguiente regresión:

$$pago_hrs_ext_tot_inf_i = \beta_0 + \beta_1 rem_mes_inf_i + \epsilon_i$$

El coeficiente estimado $\hat{\beta}_1 = 0,00145183$ indica que, en promedio, por cada peso adicional en la remuneración bruta mensualizada, el pago mensual de horas extraordinarias aumenta en aproximadamente 0.00145 pesos. Este resultado refleja una relación positiva entre la remuneración bruta mensual y el pago de horas extraordinarias, sugiriendo que a mayor nivel de ingresos base, también tiende a ser mayor el monto percibido por concepto de horas extras. El intercepto estimado $\hat{\beta}_0 = 44,801$ representa el valor esperado del pago mensual por horas extraordinarias cuando la remuneración bruta mensualizada es igual a cero.

(0.5 puntos): Por plantear correctamente el modelo.

(0.5 puntos): Por interpretar correctamente el coeficiente de interés.

- b) Plantee y estime el el modelo del inciso anterior esta vez sin un intercepto. Comente respecto a la diferencia en sus valores. ¿Que modelo cree que representa mejor a la muestra? **(1 punto)**.

Solución: La regresión sin el intercepto queda como:

$$pago_hrs_ext_tot_inf_i = \beta_1 rem_mes_inf_i + \epsilon_i$$

El coeficiente es $\hat{\beta}_1 = 0,0156$, indica que por cada peso adicional de remuneración bruta mensualizada, el pago mensual de horas extraordinarias aumenta en promedio 0.0156 pesos. Al comparar con el modelo anterior, se observa que el valor de $\hat{\beta}_1$ es mayor en este caso, ya que el intercepto fue eliminado y el modelo intenta compensar dicha omisión cargando mayor peso sobre la pendiente. La diferencia central está en que el modelo sin intercepto fuerza a que cuando la remuneración bruta sea cero, el pago de horas extraordinarias también sea cero, lo cual podría no reflejar la realidad empírica.

El modelo con intercepto es más flexible y permite capturar un valor base en el pago de horas extraordinarias independiente de la remuneración bruta.

(0.5 puntos): Por plantear correctamente el modelo.

(0.5 puntos): Por justificar correctamente que modelo representa mejor a la muestra.

- c) Se sospecha que la relación entre el pago de horas extraordinarias y la remuneración bruta mensualizada también puede variar por sexo. Por lo tanto, plantee un modelo que, usando sus parámetros luego de ser estimado, le permita calcular el diferencial por sexo de la relación entre la remuneración bruta mensualizada y el pago de horas extraordinarias ¿Cuál es el efecto marginal de la renta bruta mensualizada sobre el pago de horas extraordinarias en el caso de las mujeres? ¿Y en el caso de los hombres? **(2 puntos).**

Solución: El modelo a estimar es el siguiente:

$$\text{pago_hrs_ext_tot_inf}_i = \beta_0 + \beta_1 \text{rem_mes_inf}_i + \beta_2 \text{mujer}_i + \beta_3 \text{rem_mes_inf}_i \cdot \text{mujer}_i + \epsilon_i$$

A continuación, se presentan los coeficientes estimados.

Coeficientes	$\hat{\beta}_0$	$\hat{\beta}_1$	$\hat{\beta}_2$	$\hat{\beta}_3$
Valor	62250	-0.0013	-24730	0.0033

Tabla 4: Tabla de coeficientes del modelo

El efecto marginal de la remuneración bruta mensualizada sobre el pago de horas extraordinarias depende del sexo. Para los hombres, el efecto marginal es $\hat{\beta}_1 = -0,0013$, lo que indica que por cada peso adicional en la remuneración bruta mensualizada, el pago de horas extraordinarias aumenta en promedio \$0.0013. Para las mujeres, el efecto marginal es $\hat{\beta}_1 + \hat{\beta}_3 = -0,0013 + 0,0033 = 0,002$, lo que significa que por cada peso adicional en la remuneración bruta mensualizada, el pago de horas extraordinarias aumenta en promedio \$0.002. En este modelo, $\hat{\beta}_3 = 0,0033$ representa la diferencia en la pendiente de la relación entre remuneración y pago de horas extraordinarias entre mujeres y hombres.

(0.5 puntos): Por plantear correctamente el modelo.

(0.75 puntos): Por identificar y calcular correctamente los coeficientes que capturan el efecto marginal de las horas extras en el caso de las mujeres.

(0.75 puntos): Por identificar y calcular correctamente los coeficientes que capturan el efecto marginal de las horas extras en el caso de las mujeres.

- d) A su modelo anterior, agregue de forma acumulativa las siguientes variables: variable binaria que toma el valor 1 si la persona pertenece al estamento administrativo profesional; *planta* variable binaria que toma el valor 1 si el contrato es en calidad jurídica de planta y *dummies* por institución pública. Tabule sus resultados de los coeficientes y comente

respecto a la diferencias observadas en su valor. *Nota: Tiene permitido el uso del comando $lm()$ para este item. (2 puntos)*

Solución: A continuación se mostrará los modelos que se tienen que estimar sus coeficientes:

Modelo 1

$$\text{pago_hrs_ext_tot_inf}_i = \beta_0 + \beta_1 \text{rem_mes_inf}_i + \beta_2 \text{mujer}_i + \beta_3 \text{rem_mes_inf}_i \cdot \text{mujer}_i + \beta_4 \text{profesional} + \epsilon_i$$

Modelo 2

$$\text{pago_hrs_ext_tot_inf}_i = \beta_0 + \beta_1 \text{rem_mes_inf}_i + \beta_2 \text{mujer}_i + \beta_3 \text{rem_mes_inf}_i \cdot \text{mujer}_i + \beta_4 \text{profesional} + \beta_5 \text{planta} + \epsilon_i$$

Modelo 3

$$\text{pago_hrs_ext_tot_inf}_i = \beta_0 + \beta_1 \text{rem_mes_inf}_i + \beta_2 \text{mujer}_i + \beta_3 \text{rem_mes_inf}_i \cdot \text{mujer}_i + \beta_4 \text{profesional}_i + \beta_5 \text{planta}_i + \gamma' D_i + \epsilon_i$$

Donde D_i es el vector de *dummies* de institución pública y, γ' representa el conjunto de coeficientes asociados a esas dummies.

A continuación se muestran los coeficientes de los 3 modelos:

Modelo	$\hat{\beta}_0$	$\hat{\beta}_1$	$\hat{\beta}_2$	$\hat{\beta}_3$	$\hat{\beta}_4$	$\hat{\beta}_5$	R^2
1	61230	-0.0015	-24180	0.003	3693		0.0044
2	60230	-0.0016	-24310	0.003	4456	4546	0.0046
3	63650	-0.0026	-23260	0.0032	10990	4809	0.0609

Al comparar los modelos, se observa que la inclusión progresiva de variables adicionales no modifica sustancialmente los coeficientes de las variables originales $\hat{\beta}_0$ a $\hat{\beta}_3$ del modelo estimado en el punto c) anterior. En el Modelo 1, el efecto de ser profesional sobre el pago de HE corresponde a 3.693 (*ceteris paribus*). Al agregar la variable planta (Modelo 2), el estimador puntual asociado a la dummy fr profesional aumenta (4.456), mientras que los coeficientes de género y remuneración se ajustan ligeramente. Finalmente, en el Modelo 3, al incluir las dummies de institución pública, el efecto marginal de

ser profesional (*ceteris paribus*) aumenta sustancialmente (más del doble), mientras que el de planta aumenta levemente (4.809). Esto indica que parte de las diferencias inicialmente atribuidas a género o remuneración se explican por estamento, tipo de contrato y pertenencia institucional, destacando la importancia de controlar por estas variables.

(1 punto): Por tabular y calcular correctamente los valores de los coeficientes.

(1 punto): Por señalar correctamente las diferencias observadas y la posible causa de estas.

Pregunta Bonus: Se dará un premio de 3 décimos a aquellos que expliquen y justifiquen el motivo por el cual, incluso luego de no considerar las variables especificadas en el punto 1 anterior (i.e., sector de la economía (salud vs. el resto) y dummies por organismo), se obtiene error al realizar la estimación de forma manual-matricial, pero no al utilizar el comando `lm()`.

Respuesta: R utiliza aproximaciones para invertir las matrices lo que es numéricamente inestable en algunas situaciones. Esto lleva a que aún cuando en el papel las matrices sean LI, si están altamente correlacionadas al intentar invertirlas aparece el error de matriz no invertible al ser una aproximación computacional (comportandose como LD). `lm` no enfrenta ese problema ya que utiliza la descomposición QR para estimar sus coeficientes.

- e) ¿Cómo varía la variabilidad explicada con la adición de nuevas variables? ¿Cree usted que esto es un indicador de la robustez del modelo? Justifique **(2 puntos)**

Solución: Al añadir nuevas variables a los modelos, la variabilidad explicada aumenta, lo que se refleja en un incremento del R^2 . Esto ocurre porque cada nueva variable proporciona información adicional que ayuda a explicar parte de la variación de la variable dependiente. Sin embargo, un R^2 mayor no necesariamente indica que el modelo sea más adecuado, ya que no considera problemas como sesgo de variable omitida (endogeneidad de las variables) o errores de medición. Como nota adicional, es importante considerar que la inclusión indiscriminada de variables puede provocar overfitting, es decir, que el modelo se ajuste demasiado a la muestra utilizada y pierda capacidad predictiva fuera de ella.

(1 punto): Por señalar que a mayor cantidad de variables hay un aumento del valor del R^2 .

(1 punto): Por justificar correctamente que el R^2 no es una señal de robustez del modelo.

Pregunta 3 (4 puntos)

Ahora, se le pide estudiar como ciertas condiciones administrativas de la relación laboral, como el estamento y la calidad jurídica, se relacionan con el pago de horas extraordinarias, controlando por otras características individuales. Utilizando la base de datos provista y considerando únicamente los registros del mes de agosto:

- a) Proponga un modelo lineal en el cual el pago de horas extraordinarias se encuentre explicado por la remuneración bruta mensual, sexo, por las *dummies* profesional, planta y salud. Estime el modelo mediante MCO e interprete los coeficientes obtenidos para estas dos últimas variables **(1 punto)**.

Solución: El modelo lineal es el siguiente:

$$pago_hrs_ext_tot_inf_i = \beta_0 + \beta_1 rem_mes_inf_i + \beta_2 mujer_i + \beta_3 planta_i + \beta_4 profesional_i + \beta_5 salud_i + \epsilon_i$$

A continuación se muestra una tabla con los coeficientes:

Coeficientes	$\hat{\beta}_0$	$\hat{\beta}_1$	$\hat{\beta}_2$	$\hat{\beta}_3$	$\hat{\beta}_4$	$\hat{\beta}_5$
Valor	32150	0.0007	-20230	1697	8321	41410

Tabla 5: Tabla de coeficientes del modelo

El coeficiente estimado para la variable planta es de 1697. Esto significa que, manteniendo constantes la remuneración bruta mensual, el sexo, la condición profesional y el sector salud, los trabajadores contratados en calidad de planta reciben en promedio 1697 pesos adicionales por concepto de horas extraordinarias respecto de aquellos que no pertenecen a la planta. El efecto es positivo, aunque de menor magnitud comparado con otras condiciones.

El coeficiente estimado para la variable salud es de 41410. Esto indica que, controlando por las demás características, los trabajadores que se desempeñan en el sector salud perciben en promedio 41410 pesos adicionales por pago de horas extraordinarias respecto de quienes trabajan en otros organismos. El impacto es considerablemente mayor, lo que sugiere que el sector salud tiene un régimen más intensivo en horas extraordinarias.

(0.5 puntos): Por calcular correctamente los valores de los coeficientes.

(0.5 puntos): Por interpretar correctamente los valores de los coeficientes.

- b) Mediante regresiones particionadas, reporte y calcule manualmente los coeficientes de las variables *profesional* y *planta*. Compare los resultados con los obtenidos en la sección anterior **(1 punto)**.

Solución: Generamos un modelo restringido, modelo para la variables profesional, planta y utilizamos FWL, de la siguiente manera:

Modelo Restringido

$$pago_hrs_ext_tot_inf_i = \beta_0 + \beta_1 rem_mes_inf_i + \beta_2 mujer_i + \beta_3 salud_i + \epsilon_i$$

Luego de correr la regresión recuperamos los residuos de la regresión, donde X_{rest} es la matriz de variables del modelo resntrigido y β_{rest} son los coeficientes estimados:

$$e_{rest_i} = pago_hrs_ext_tot_inf_i - X_{rest}\beta_{rest}$$

Modelo Profesional

$$profesional_i = \beta_0 + \beta_1 rem_mes_inf_i + \beta_2 mujer_i + \beta_3 salud_i + \epsilon_i$$

Luego de correr la regresión recuperamos los residuos de la regresión, donde X_{prof} es la matriz de variables del modelo profesional y β_{prof} son los coeficientes estimados:

$$e_{prof_i} = profesional_i - X_{prof}\beta_{prof}$$

Modelo Planta

$$planta_i = \beta_0 + \beta_1 rem_mes_inf_i + \beta_2 mujer_i + \beta_3 salud_i + \epsilon_i$$

Luego de correr la regresión recuperamos los residuos de la regresión, donde X_{planta} es la matriz de variables del modelo planta y β_{planta} son los coeficientes estimados:

$$e_{planta_i} = planta_i - X_{planta}\beta_{planta}$$

Modelo FWL

Finalmente, con los residuos ya recuperados, estimamos la siguiente regresión para hallar los coeficientes de profesional y planta.

$$e_{rest_i} = \beta_0 + \beta_1 e_{prof_i} + \beta_2 e_{planta_i} + \epsilon_i$$

Los coeficientes recuperados son los siguientes:

$$\beta_0 = 2,7e - 11$$

$$\beta_1 = 8321 \quad [\text{corresponde a coeficiente profesional}]$$

$$\beta_2 = 1697 \quad [\text{corresponde a coeficiente planta}]$$

Como podemos observar, los coeficientes calculados recientemente, son los mismos que los que se calculó para el inciso anterior (coeficientes de interés), por lo que se pudo recuperar ambos coeficientes de la regresión completa.

(0.25 puntos): Por calcular y obtener correctamente el modelo restringido.

(0.25 puntos): Por calcular y obtener correctamente el modelo profesional.

(0.25 puntos): Por calcular y obtener correctamente el modelo planta.

(0.25 puntos): Por calcular y obtener correctamente el modelo FWL.

- c) Obtenga y compare la suma de los residuos cuadrados del modelo propuesto en la letra (a) con la estimación mediante regresiones particionadas. Comente **(1 punto)**.

Solución: A continuación se presenta los residuos al cuadrado de la regresión completa, es decir, la original:

$$R^2 = 0,0265$$

Ahora calculamos el R^2 particionado, para ello, se calcula primero para el modelo restringido y después para el FWL, luego se suman:

$$R^2_{rest} = 0,0257$$

$$R^2_{FWL} = 0,0008$$

$$R^2_{particionado} = 0,0265$$

La suma de los residuos cuadrados del modelo completo coincide exactamente con la suma obtenida mediante regresiones particionadas, por lo que no hay pérdida de información al descomponer la regresión en pasos. Sin embargo, el incremento en al agregar las variables adicionales es muy pequeño (0.0008), lo que indica que estas variables casi no contribuyen a explicar la variabilidad de la variable dependiente.

(0.25 puntos): Por calcular correctamente el R^2 .

(0.25 puntos): Por comparar correctamente los valores.

- d) Estime nuevamente el modelo propuesto en la letra (a), pero excluyendo las variables *profesional* y *planta*. Compare el coeficiente de determinación de este nuevo modelo con los obtenidos en el modelo propuesto en la letra (a) y la regresión particionada. Comente **(1 punto)**.

Solución: Al excluir las variables profesional y planta, el modelo reducido tiene un coeficiente de determinación $R^2_{rest} = 0,0257$, que es ligeramente menor que el R^2 del modelo completo calculado en el inciso anterior y coincide con la parte del R^2 atribuible al modelo restringido en la regresión particionada. Esto indica que la mayor parte de la variabilidad explicada por el modelo original ya se captura sin estas dos variables, y la contribución de las variables excluidas es muy pequeña (0.0008). En términos prácticos, el ajuste del modelo prácticamente no se ve afectado al eliminar profesional y planta, lo que sugiere que su inclusión aporta muy poca información adicional para explicar la variable dependiente. **(1 punto)**: Por concluir justificadamente que prácticamente no hay efecto sobre el valor del R^2 .

Pregunta 4 (5 puntos)

Un colega suyo está interesado en saber si es posible extraer conclusiones sobre la muestra general a partir de su análisis realizado con la información del mes de agosto. Para ello, su colega plantea realizar el siguiente procedimiento conocido como *Bootstrap*, utilizando sólo la información de agosto:

- i) Defina una malla de tamaños de muestra N , comenzando en $N = 200$ y aumentando de 200 en 200 hasta alcanzar el total de observaciones disponibles en su base de datos.
- ii) Para cada tamaño de muestra N en su malla definida en i), realice $n = 50$ veces el siguiente procedimiento:
 - 1) Obtenga una muestra aleatoria sin reemplazo de tamaño N su base de datos original.
 - 2) Estime de forma manual el coeficiente asociado a la remuneración del modelo planteado en la letra (a) de la pregunta anterior.
 - 3) Estime de forma manual el coeficiente de determinación (R^2) asociado al modelo.
- iii) Una vez terminadas las $n = 50$ iteraciones, para cada tamaño de muestra N en su malla definida en i) calcule y guarde la media de los coeficientes y la media de R^2 .
- iv) Repita los pasos ii) y iii) pero considerando $n = 100$ y $n = 300$ iteraciones.

Una vez realizado esto, conteste:

- a) ¿Cómo cambia el valor de los estimadores con la variación del tamaño de muestra? ¿Y con la cantidad de iteraciones? Explique y justifique **(1 punto)**.

Solución:

Para resolver esta pregunta, se requiere graficar el valor promedio de los coeficientes y R^2 a lo largo de los distintos tamaños de muestra considerando cada una de la cantidad de iteraciones solicitadas.




Figura 5: Beta media 50 iteraciones



Figura 6: R cuadrado media 50 iteraciones




Figura 7: Beta media 100 iteraciones



Figura 8: R cuadrado media 100 iteraciones




Figura 9: Beta media 300 iteraciones



Figura 10: R cuadrado media 300 iteraciones

A medida que aumenta el tamaño de la muestra (N), los valores promedio del coeficiente de remuneración tienden a estabilizarse y muestran menos volatilidad. Para muestras pequeñas, las estimaciones fluctúan más, mientras que al acercarse al tamaño total de la base, las medias se aproximan a un valor más cercano al parámetro poblacional real. Esto refleja la relación directa entre tamaño de muestra y precisión de los estimadores: muestras más grandes reducen la varianza y generan resultados más confiables.

En cuanto a la cantidad de iteraciones (n), incrementar el número de réplicas (de 50 a 100 o 300) suaviza las medias bootstrap de los coeficientes y del R^2 . Con más iteraciones, la variabilidad de las medias disminuye, proporcionando una mejor aproximación al valor esperado del estimador. Esto demuestra que un mayor número de iteraciones hace que los promedios sean más robustos frente a la aleatoriedad de la muestra.

En conjunto, los resultados muestran que para obtener estimaciones más estables y cercanas al verdadero valor poblacional, conviene trabajar con tamaños de muestra suficientemente grandes y un número adecuado de réplicas. Para tamaños pequeños o pocas iteraciones, la incertidumbre es mayor y las medias pueden fluctuar considerablemente, lo que resalta la importancia de considerar ambos factores al realizar inferencias sobre la población a partir de la muestra.

(0.5 puntos): Por realizar graficos que le permitan visualizar el comportamiento.

(0.5 puntos): Por comentar respecto a la variación relacionada al tamaño de la muestra y la cantidad de iteraciones.

- b) Ahora, utilice la base de datos completa (es decir, con todos los meses y años) y realice el procedimiento descrito por su colega. Comente respecto a las diferencias observadas **(2 puntos)**.

Solución: Para responder a esta figura, es fundamental graficar los resultados obtenidos:




Figura 11: Comparación 50 iteraciones




Figura 12: Comparación 100 iteraciones




Figura 13: Comparación 300 iteraciones

Primero, los estimadores de los coeficientes muestran una menor variabilidad a medida que se incrementa el tamaño de la muestra, lo cual es consistente con la ley de los grandes números. Al tener más observaciones de distintos meses y años, la media de los coeficientes se estabiliza y refleja mejor el efecto promedio de la remuneración sobre las horas extra, disminuyendo la influencia de fluctuaciones mensuales particulares.

Segundo, al graficar comparando con los coeficientes obtenidos de la submuestra, se puede observar claramente una diferencia en valor del coeficiente, aun cuando en ambos casos disminuye la variabilidad con el aumento del tamaño muestral. Esto indica que la muestra de agosto no es representativa de la población completa.

Tercero, el R^2 tiende a tener menor variación y, en general, ligeramente más alto que en las muestras mensuales individuales. Esto indica que la inclusión de más datos mejora la explicación del modelo sobre la variabilidad observada en la base completa, aunque las relaciones no cambian significativamente.

Finalmente, al comparar los resultados de 50, 100 o 300 iteraciones, se observa que el número de repeticiones afecta principalmente la estabilidad de la estimación de la

media: con más iteraciones, la media del coeficiente y del R^2 se estabiliza y se reduce la variación asociada al muestreo aleatorio. Esto refuerza la importancia de utilizar tanto un tamaño de muestra representativo como un número suficiente de réplicas en procedimientos de tipo bootstrap para obtener inferencias confiables.

(1 puntos): Por realizar graficos que le permitan visualizar el comportamiento.

(0.5 puntos): Por comentar respecto a la diferencia observada en el valor del coeficiente.

(0.5 puntos): Por comentar respecto al efecto en el número de iteraciones sobre la variabilidad del coeficiente.

- c) ¿Cree usted que el *Bootstrap* es un buen procedimiento para responder a la inquietud de su colega? **(1 punto).**

Solución: El Bootstrap no es un buen procedimiento para responder a la inquietud, ya que permite evaluar la estabilidad de los estimadores sin necesidad de hacer supuestos estrictos sobre la distribución de los errores o sobre la población. Al generar múltiples muestras aleatorias a partir de los mismos datos, se obtiene una distribución empírica de los coeficientes y del R^2 , lo que permite medir su variabilidad y consistencia. Esto brinda una herramienta flexible y práctica para verificar la robustez de los resultados frente a cambios en el tamaño muestral y en la aleatoriedad del muestreo. Sin embargo, utilizar información sólo correspondiente a agosto no permite extraer conclusiones de la muestra general. Como en este caso en particular, donde existe una diferencia en el valor del coeficiente (aun cuando tengan el mismo signo). En ciertas ocasiones, uno se puede ver enfrentado a la paradoja de simpson.

(0.5 puntos): Por comentar que *Bootstrap* permite analizar la robustez y variabilidad de la muestra.

(0.5 puntos): Por concluir que no es un buen procedimiento para extraer conclusiones sobre la muestra general.

- d) ¿Que le respondería a su colega?**(1 punto).**

Solución: Le respondería que los resultados muestran que, al aumentar el tamaño de la muestra, las estimaciones tienden a estabilizarse y reflejar mejor la relación entre las variables, mientras que al aumentar el número de iteraciones se reduce la variabilidad en los promedios obtenidos. Como bien se respondió en la pregunta anterior, su inquietud es válida y en este caso resulta ser verdadera, ya que el coeficiente de la submuestra difiere sustancialmente de la muestra completa.

(1 puntos): Por argumentar que la inquietud del colega es válida.

Anexos


Códigos de la base de datos

Variable	Descripción
year	Año de registro de la remuneración.
mes	Mes de registro (1 a 12).
padre_org	Dependencia principal a la que pertenece el funcionario.
organismo	Nombre del organismo o institución.
sexo	Sexo del funcionario (masculino o femenino).
rem_mes_inf	Remuneración mensual imponible informada (en CLP).
n_hrs_ext_tot	Número total de horas extra solicitadas en el mes.
pago_hrs_ext_tot_inf	Pago total por horas extra informadas (en CLP).
cargo	Denominación del cargo del funcionario.
salud	Pertenencia a un instituo de salud
region	Región donde trabaja dicha persona.
calidad jurídica	calificación legal de la relación entre el empleado y empleador.


Tabla 6: Descripción de las variables utilizadas en el análisis de la tarea a partir de la base `salarios-transparencia.dta`.

Ejemplo de citación de IA

Si el/la estudiante utiliza alguna herramienta de IA para apoyarse en su informe o desarrollo de código, debe citar en un apartado de anexos del informe un pantallazo que incluya tanto el *prompt* proporcionado como la respuesta que dio la IA. Por ejemplo, si quisiera calcular una regresión particular en R, y le pregunto a ChatGPT cómo hacerlo, debo citarlo:



A su vez, se debe citar cualquier uso de la herramienta, por ejemplo, para incluir las figuras se utilizó también ChatGPT, por lo que se debe citar:



Note que el tamaño de las imágenes puede ser pequeño o grande, con tal de que se pueda distinguir perfectamente tanto el *prompt* como la respuesta de la IA.