



Pontificia Universidad Católica de Chile
Escuela de Ingeniería
Departamento de Ingeniería Industrial y de Sistemas

ICS2563 Econometría Aplicada

Tarea 3 - Grupo 21

Integrantes:

- Agustina Caneo Huerta
- Franco Nicolai Corvalán Mansourova

Fecha de entrega: 30 de septiembre de 2025

Índice de contenido

1 Problema 1	2
1.0.1 Preámbulo	2
1.0.2 Resultados	2
2 Problema 2	4
2.0.1 Preámbulo	4
2.0.2 Resultados	4
3 Problema 3	6
3.0.1 Preámbulo	6
3.0.2 Resultados	6
4 Problema 4	8
4.0.1 Preámbulo	8
4.0.2 Resultados	9
5 Anexos	11

1. Problema 1

1.0.1. Preámbulo

Realizaremos un análisis empírico del sesgo en las estimaciones de Mínimos Cuadrados Ordinarios (MCO) de los coeficientes de un modelo de regresión lineal. Nuestro objetivo es ilustrar cómo la omisión de una variable relevante del modelo puede llevar a estimadores sesgados e inconsistentes. Para ello, nos basaremos en un modelo de Generación de Datos (DGP).

A partir de eso, la variable de interés, salario_i , se genera a partir de la relación:

$$\text{salario}_i = \gamma_1 IA_{a,i} + \gamma_2 \text{hrs}_{a,i} + \varepsilon_i$$

donde $IA_{a,i}$ representa las horas dedicadas a un programa de inteligencia artificial, $\text{hrs}_{a,i}$ son las horas extras trabajadas, y ε_i es un término de error aleatorio con una distribución $N(0, 10^5)$. Los valores verdaderos de los parámetros son $\gamma_1 = 20,000$ y $\gamma_2 = 100$. Con esto mencionado, se simularán dos modelos de regresión en una submuestra aleatoria de tamaño $n = 1000$:

$$\text{salario}_i = \beta_0 + \beta_1 IA_{a,i} + u_i$$

$$\text{salario}_i = \alpha_0 + \alpha_1 IA_{a,i} + \alpha_2 \text{hrs}_{a,i} + v_i$$

Al comparar las estimaciones de $\hat{\beta}_1$ y $\hat{\alpha}_1$ buscaremos evidenciar el impacto de la omisión de una variable en el sesgo de la estimación.

1.0.2. Resultados

Importante: Los resultados varían enormemente según la semilla utilizada. Por favor, asegúrese de contrastar empleando la misma semilla para garantizar la comparabilidad.


**Imagen 1**

Gráfico distribución empírica de los estimadores $\hat{\beta}_1$ y $\hat{\alpha}_1$.

Además se puede obtener:

$$\hat{\beta}_{media} = \begin{pmatrix} \hat{\beta}_{1_media} \\ \hat{\alpha}_{1_media} \end{pmatrix} = \begin{pmatrix} 20061.97 \\ 20000.02 \end{pmatrix}$$

A partir del gráfico, se observan dos diferencias principales entre las distribuciones de los estimadores $\hat{\beta}_1$ y $\hat{\alpha}_1$:

- **Fundamento empírico:** La distribución de $\hat{\alpha}_1$ está centrada casi perfectamente en el valor verdadero del parámetro, que es $\gamma_1 = 20,000$. Por otro lado, la distribución de $\hat{\beta}_1$ está claramente desplazada o sesgada hacia la izquierda, con su media ubicada alrededor de 20,060 respecto a su valor verdadero que es $\beta_1 = 20,000$. Esta diferencia es el resultado del sesgo por omisión de variable relevante.
- **Fundamento teórico:** Esta diferencia es el resultado del sesgo por omisión de variable relevante. El modelo de $\hat{\alpha}_1$ incluye ambas variables, por lo que el estimador es insesgado y se aproxima al valor verdadero del parámetro. En cambio, el modelo de $\hat{\beta}_1$ omite la variable hrsta. Dado que las horas extras (hrsta) y las horas dedicadas a la IA (IAa) están positivamente correlacionadas en la base de datos, el estimador $\hat{\beta}_1$ de la regresión simple atribuye incorrectamente parte del efecto de hrsta a IAa, lo que resulta en una sobreestimación del coeficiente de IAa, lo que hace que tome otro valor. Por lo tanto, el estimador es sesgado.

2. Problema 2

2.0.1. Preámbulo

Examinaremos cómo la incorporación de una nueva variable explicativa, específicamente los años de servicio del individuo (x_{3i}), influye en la estimación de los coeficientes de las demás variables.

A partir de eso, el análisis se centrará en dos modelos de regresión:

$$salario_i = \beta_0 + \beta_1 IA_{a,i} + \beta_2 hrs_{a,i} + u_i$$

$$salario_i = \alpha_0 + \alpha_1 IA_{a,i} + \alpha_2 hrs_{a,i} + \alpha_3 x_{3i} + v_i$$

a partir del cual obtendremos la estimación $\hat{\alpha}_1$ y $\hat{\beta}_1$.

2.0.2. Resultados

Importante: Los resultados varían enormemente según la semilla utilizada. Por favor, asegúrese de contrastar empleando la misma semilla para garantizar la comparabilidad.




Imagen 2

Gráfico distribución empírica de los estimadores $\hat{\beta}_1$ y $\hat{\alpha}_1$.

Además se puede obtener:

$$\hat{\beta}_{media} = \begin{pmatrix} \hat{\beta}_{0_media} \\ \hat{\alpha}_{1_media} \end{pmatrix} = \begin{pmatrix} 19999.95 \\ 19999.95 \end{pmatrix}$$

A partir del gráfico, se observan dos diferencias principales entre las distribuciones de los estimadores $\hat{\beta}_1$ y $\hat{\alpha}_1$:

- **Fundamento empírico:** La distribución del estimador $\hat{\beta}_1$ está centrada casi perfectamente en el valor verdadero del parámetro, que es $\gamma_1 = 20,000$. La distribución del estimador $\hat{\alpha}_1$ también está centrada en 20,000. Esto demuestra que ninguno de los estimadores está sesgado. Además, la distribución de $\hat{\alpha}_1$ es idéntica a la de $\hat{\beta}_1$.
- **Fundamento teórico:** La inclusión de una variable irrelevante, como años_servicio, no introduce sesgo en los estimadores de los coeficientes de las otras variables (IAa y hrsa). Esto se debe a que años_servicio no forma parte del DGP del salario, por lo que no está correlacionada con el término de error. Teóricamente, se puede comprender como que si una variable extra no está correlacionada con el término de error del modelo verdadero, su inclusión no sesgará los estimadores de las demás variables. Esto significa que, en promedio, el estimador seguirá recuperando el valor real del parámetro.

3. Problema 3

3.0.1. Preámbulo

Examinaremos cómo la adición de 15 variables, $Z_{1i}, Z_{2i}, \dots, Z_{15i}$, influye en la estimación de los coeficientes de las demás variables.

Cada una de las variables se construye de la siguiente manera:

$$z_{ji} = 0.3IA_{a,i}^{scale} + 0.3hrs_{a,i}^{scale} + \varepsilon_{ji}, \quad ji \sim \mathcal{N}(0, 1)$$

Las z_{ji} resultan débilmente correlacionadas con las covariables relevantes, $IA_{a,i}$ y $hrs_{a,i}$, pero no entregan información adicional al modelo.

A partir de eso, el análisis se centrará en dos modelos de regresión:

$$salario_i = \beta_0 + \beta_1 IA_{a,i} + \beta_2 hrs_{a,i} + u_i$$

$$salario_i = \alpha_0 + \alpha_1 IA_{a,i} + \alpha_2 hrs_{a,i} + \sum_{j=1}^{15} \delta_j z_{ji} + v_i$$

a partir del cual obtendremos las estimaciones de $\hat{\alpha}_1$ y $\hat{\beta}_1$.

3.0.2. Resultados




Imagen 3

Gráfico distribución empírica de los estimadores $\hat{\beta}_1$ y $\hat{\alpha}_1$.

Obtenemos que:

$$\hat{\beta}_{media} = \begin{pmatrix} \hat{\beta}_{0_media} \\ \hat{\alpha}_{1_media} \end{pmatrix} = \begin{pmatrix} 19999.761 \\ 19999.764 \end{pmatrix}$$

A partir del gráfico, se observan dos diferencias principales entre las distribuciones de los estimadores $\hat{\beta}_1$ y $\hat{\alpha}_1$:

- **Fundamento empírico:** Es posible decir que ambos estimadores son insesgados. Esto se demuestra porque las medias de ambas distribuciones son prácticamente idénticas y están centradas sobre el valor verdadero del parámetro, $\gamma_1 = 20,000$, como podemos confirmar con el gráfico. Esto nos dice que añadir variables irrelevantes no desvió sistemáticamente la estimación del parámetro de interés. También, podemos analizar del gráfico que la distribución del modelo base (curva roja) es más alta y estrecha. Esto indica que las estimaciones de $\hat{\beta}_1$ están muy concentradas alrededor de la media, por lo que, es un estimador preciso. Mientras que, la distribución del modelo con las 15 variables (curva celeste) es más baja y ancha. Esto significa que las estimaciones de $\hat{\alpha}_1$ tienen una mayor dispersión. Esto muestra que añadir 15 variables irrelevantes y correlacionadas no sesgó el estimador de IA_a , pero sí redujo su eficiencia, haciéndolo menos preciso.
- **Fundamento teórico:** La teoría de Mínimos Cuadrados Ordinarios (MCO) establece que incluir variables en una regresión que son irrelevantes **no introduce sesgo** en las estimaciones de los coeficientes de las otras variables. El estimador sigue siendo insesgado, lo que significa que $E[\hat{\beta}_1] = E[\hat{\alpha}_1] = 20,000$. Considerando que, el valor medio estimado de $\hat{\alpha}_1$ es el que presenta el resultado más lejano, aunque por muy poco, al valor real. Esta pérdida de eficiencia se puede deber a la multicolinealidad, ya que las variables z están correlacionadas con IA_a . Esto hace que la incertidumbre sobre la estimación de IA_a aumenta, lo que se traduce en errores estándar más grandes y, por lo tanto, una mayor varianza del estimador.

4. Problema 4

4.0.1. Preámbulo

En esta pregunta, se construye un experimento simulado para analizar la distribución del estimador MCO, $\hat{\beta}_1$, en un escenario donde el efecto de un tratamiento varía sistemáticamente según el sexo de los individuos. El objetivo es evaluar cómo la composición de la muestra influye en la estimación de un modelo de regresión simple. El Proceso Generador de Datos (DGP) se define de la siguiente manera: El tratamiento D_i se asigna de forma aleatoria, siguiendo una distribución Bernoulli con probabilidad 0.5. Se define un ingreso extra, S , cuyo efecto sobre el salario depende de la interacción entre el tratamiento y el sexo. Esta relación se formaliza en la función $F(\text{male}_i, D_i)$:

$$F(\text{male}_i, D_i) = \begin{cases} +S \cdot D_i, & \text{si } \text{male}_i = 1 \text{ (hombre)} \\ -S \cdot D_i, & \text{si } \text{male}_i = 0 \text{ (mujer)} \end{cases}$$

El *outcome* final, $\text{salario}'_i$, se obtiene sumando este efecto al salario base definido en la Pregunta 1:

$$\text{salario}'_i = \text{salario}_i + F(\text{male}_i, D_i)$$

A partir de este diseño, la simulación se centrará en estimar repetidamente el siguiente modelo de regresión simple:

$$\text{salario}'_i = \beta_0 + \beta_1 D_i + u_i$$

4.0.2. Resultados




Imagen 4

Gráfico del valor promedio de $\hat{\beta}_1$ en función de la proporción de hombres p .

En el Gráfico, la línea negra punteada representa el valor teórico esperado del estimador, dado por la fórmula $E[\hat{\beta}_1 | p] = (2p - 1)S$. La similitud entre los valores empíricos y la curva teórica es notable. Los puntos rojos de la simulación se ajustan muy bien a la línea teórica, con algunas desviaciones, lo que confirma que el estimador MCO se comporta como la teoría predice en este escenario. El estimador $\hat{\beta}_1$ de la regresión simple está estimando una media ponderada de los efectos heterogéneos para hombres ($+S$) y mujeres ($-S$). Las ponderaciones de esta media están determinadas directamente por la composición de la muestra, es decir, por la proporción p .

Casos extremos e intermedio

La fórmula teórica nos permite analizar cómo varía el valor esperado de $\hat{\beta}_1$ en tres escenarios clave:

- Caso $p = 0$: En este caso la muestra es sólo mujeres, y la fórmula predice $E[\hat{\beta}_1] = (2 \cdot 0 - 1)S = -S$. Sabemos que para la muestra compuesta únicamente por mujeres, el efecto del tratamiento es una reducción en el salario de 50,000. Por lo que, la regresión estima correctamente el efecto del tratamiento para este grupo específico.
- Caso $p = 1$: En este caso, la fórmula predice $E[\hat{\beta}_1] = (2 \cdot 1 - 1)S = S$. De la misma manera que antes, con la muestra de sólo hombres. La regresión estima sin sesgo el efecto para ellos, un aumento en el salario de 50,000.

- Caso $p = 0.5$: La fórmula es $E[\hat{\beta}_1] = (2 \cdot 0.5 - 1)S = 0$. En este caso, la muestra está balanceada por sexo y los efectos opuestos se cancelan mutuamente. Por lo que, la regresión simple concluiría erróneamente que el tratamiento no tiene ningún efecto en promedio, ocultando los dos efectos reales $(+S - S)$ que hay.

Interpretación Resultados

Los resultados de esta simulación son consistentes con la teoría de Mínimos Cuadrados Ordinarios (MCO). El problema fundamental es que el modelo de regresión simple, $\text{salario}'_i = \beta_0 + \beta_1 D_i + u_i$, "asume" que el efecto del tratamiento (D) es el mismo para todos los individuos de la muestra. Sin embargo, el DGP que se diseñó define un efecto heterogéneo, ya que depende del sexo del individuo. Este escenario puede ser interpretado como un caso de sesgo por variable omitida. Ya que, el tratamiento D_i es asignado aleatoriamente y no depende del género, pero en el modelo el salario depende de la proporción de cada grupo en la muestra. Es decir, el resultado de $\hat{\beta}_1$ depende completamente de la proporción p de hombres y mujeres en la muestra.

En conclusión, la simulación es consistente con la teoría de MCO en un contexto de efecto heterogéneo. Aunque nos demuestra que cuando los efectos de un tratamiento varían sistemáticamente entre grupos de la población, un modelo de regresión simple puede producir estimaciones engañosas, ya que el coeficiente no converge a un único parámetro poblacional de interés, sino a un valor que depende de la composición particular de la muestra. Lo que subraya la importancia de considerar la posible heterogeneidad de efectos en el diseño de un análisis econométrico.

5. Anexos




Imagen 5
Conversación con Google Gemini






Imagen 6
Conversación con Google Gemini

**Imagen 7**

Conversación con Google Gemini dado el archivo de la tarea para mejor contexto

**Imagen 8**

Conversación con Google Gemini dado el archivo de la tarea para mejor contexto