



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE  
DEPARTAMENTO DE INGENIERÍA INDUSTRIAL Y DE SISTEMAS  
ICS2563 - ECONOMETRÍA APLICADA 2025'2

## Tarea 3

12 de septiembre del 2025

Profesores: Patricio Domínguez  
Gonzalo Gaete

Ayudantes: Gonzalo Aguilar (gonzalo.aguilar@uc.cl)  
Pía Cereceda (piacereceda@uc.cl)

---

### Aspectos generales

1. La tarea puede ser desarrollada en forma individual o en parejas (2 estudiantes) de una misma sección. **Debe inscribirse con su pareja en un grupo habilitado en Canvas para esta tarea. Aún cuando realice su tarea de manera individual, debe inscribirse en un grupo sin miembros.**
2. La fecha de entrega de la tarea es el **19 de agosto a las 23:00 hrs** en el portal del curso en Canvas.
3. La entrega debe incluir el script de R (o el dofile de STATA) y un informe de análisis en formato pdf.
4. La entrega debe realizarse subiendo cada archivo por separado en Canvas. **No se aceptarán archivos en formato .zip.**
5. Sobre el **informe**:
  - a) Se requiere que el informe debe incorporar las respuestas a todas las preguntas, incorporando las figuras y/o tablas que estime conveniente.
  - b) Es **obligatorio** el uso del compilador de texto L<sup>A</sup>T<sub>E</sub>X. Se facilitará una plantilla TeX en CANVAS para redactar sus respuestas. **No debe copiar el enunciado de las preguntas en su informe.**
6. Sobre el **código**:
  - a) Cada entrega debe incluir el script de R (o el dofile de STATA) desde donde se corre todo el análisis.

- b) Cada análisis debe ser desarrollado por ustedes mismos utilizando vectores y matrices; el uso de paquetes estadísticos será penalizado. Se indicará en las preguntas cuando deben realizar cálculos “a mano”, es decir, utilizando fórmulas vistas en clases, vectores y matrices.
  - c) Es importante que el código esté adecuadamente comentado para facilitar su corrección. Por ejemplo, indicar qué parte del informe/preguntas se desarrollan en cada sección del código.
  - d) **Reproducibilidad:** El código debiera estar escrito de manera tal que cualquier persona lo pueda correr, y reproducir los resultados desde su computador. En el caso de crear datos aleatorios recomendamos fijar una semilla que permita reproducir los resultados tal cual queden especificados en el informe de reporte.
7. Parte de la tarea es que se vean enfrentados a tomar decisiones. Si deben aplicar criterio, háganlo y justifiquen sus elecciones.
  8. Ante dudas o preguntas, se recomienda fuertemente la utilización del foro de preguntas del curso en CANVAS. Las respuestas pueden servir a otros compañeros, que se enfrentan a las mismas dudas. **No se permite publicar respuestas.**
  9. Para la tarea, a menos que se especifique lo contrario, la función real log es el logaritmo natural.
  10. Para el desarrollo de la tarea se permite el uso de herramientas de Inteligencia Artificial (IA), como por ejemplo ChatGPT, siempre y cuando **no se copie de forma textual lo generado por la IA**. En caso de utilizar alguna herramienta de este estilo, se debe proporcionar todo lo que se entregue y obtenga de ella como captura de pantalla en el anexo del informe (es decir, incluyendo tanto las preguntas realizadas como las respuestas que entrega la IA). Si se detecta el uso de alguna herramienta de IA sin la citación requerida se considerará la tarea como plagio, y se tomarán las acciones pertinentes en tales casos.<sup>1</sup>
  11. La tarea tiene un total de **20 puntos**, en donde la presentación del informe tiene 1.5 puntos (el informe debe incorporar las respuestas a todas las preguntas, y las figuras y/o tablas que estime necesarias además debe estar ordenado para obtener el puntaje), y la presentación de un *script* ordenado que facilite la corrección tiene 0.5 puntos. En caso que el informe no se realice en formato L<sup>A</sup>T<sub>E</sub>X, no se obtendrá puntaje por presentación del informe. En caso de no entregar script sus respuestas no tendrán puntaje debido a que es necesario mostrar el desarrollo de como se obtienen los resultados.
  12. La tarea puede contener algunas preguntas interrelacionadas. Quienes no hayan podido completar la pregunta que esté vinculada, se les sugiere asumir un valor o distribución

---

<sup>1</sup>En los anexos del documento se presenta un ejemplo de cómo citar correctamente el uso de una herramienta de IA.

de valores (según corresponda) por su cuenta y desarrollar el análisis de cada pregunta en forma independiente.

## Descripción de la tarea y pasos previos:

El objetivo de esta tarea es profundizar en el uso de simulaciones como herramienta para comprender las propiedades de los estimadores de Mínimos Cuadrados Ordinarios (MCO), así como para analizar cómo la inclusión u omisión de variables afecta la estimación de parámetros. En esta ocasión se trabajará directamente con una base extendida, denominada `salarios_transparencia_v2.0`, que ya contiene las principales variables de interés para el análisis.

Antes de comenzar con las preguntas, asegúrese de fijar una *semilla* para garantizar la replicabilidad de los resultados (por ejemplo, `set.seed(2563)`). De esta manera es más sencillo trabajar en las preguntas posteriores. Luego de las preguntas sigue un diccionario con el nombre de las variables a utilizar en la tarea, junto con sus definiciones (Ver Tabla 1).

### Pregunta 1 (4 puntos)

Considere como variable dependiente  $salario_i$ , que representa el ingreso adicional del individuo  $i$  proveniente de dos actividades: (i) las horas dedicadas a un programa de inteligencia artificial en abril ( $IA_i$ ), y (ii) el número de horas extras trabajadas en el mismo mes ( $hrs_{a,i}$ ). La relación entre estas variables (DGP) está dada por:

$$salario_i = \gamma_1 IA_{a,i} + \gamma_2 hrs_{a,i} + \varepsilon_i, \quad (1)$$

donde  $\varepsilon_i \sim N(0, 10^5)$  es un término de error que recoge perturbaciones aleatorias, y los parámetros verdaderos  $\gamma_1 = 20,000$  y  $\gamma_2 = 100$  reflejan el incremento esperado en los ingresos: por cada hora dedicada al programa de IA se agregan aproximadamente 20 mil pesos, mientras que cada hora extra aporta en promedio 100 pesos. Cree esta nueva variable. Con el objetivo de evaluar empíricamente sesgo, realice el siguiente procedimiento de simulación:

- (i) Para una submuestra aleatoria sin reemplazo de tamaño  $n = 1000$ , estime los coeficientes MCO de las siguientes regresiones:

$$\begin{aligned} salario_i &= \beta_0 + \beta_1 IA_{a,i} + u_i \\ salario_i &= \alpha_0 + \alpha_1 IA_{a,i} + \alpha_2 hrs_{a,i} + v_i \end{aligned}$$

y conserve las estimaciones de  $\hat{\beta}_1$  y  $\hat{\alpha}_1$  asociadas a la variable  $IA_{a,i}$ .

- (ii) Repita el paso (i) un total de  $N = 1000$  veces<sup>2</sup>, y en cada iteración conserve los valores de  $\hat{\beta}_1$  y  $\hat{\alpha}_1$ .
- (iii) Con las  $N$  repeticiones realizadas, construya las distribuciones empíricas de  $\hat{\beta}_1$  y  $\hat{\alpha}_1$ , y representelas mediante funciones de densidad de kernel en un mismo gráfico. Incluya líneas verticales que indiquen la media de cada distribución.

---

<sup>2</sup>Note que en cada iteración se obtiene una muestra “distinta” a la anterior

Responda:

- a) Presente el gráfico solicitado, asegurándose de incluir ambas distribuciones y sus medias. **(2 puntos)**
- b) Compare los resultados de sus simulaciones: ¿qué diferencia observa entre las distribuciones de  $\hat{\beta}_1$  y  $\hat{\alpha}_1$ ? Fundamente empírica y teóricamente su respuesta. **(2 puntos)**

## Pregunta 2 (4 puntos)

Considere nuevamente la especificación planteada en (1) y suponga que además se incorpora una nueva variable explicativa, los años de servicio del individuo  $i$ , denotados por  $x_{3i}$ . Con el objetivo de evaluar el efecto de incluir esta nueva covariable en la estimación del modelo, realice el siguiente procedimiento:

- (i) Para una submuestra aleatoria sin reemplazo de tamaño  $n = 1000$ , estime los coeficientes MCO de las siguientes regresiones:

$$\begin{aligned} \text{salario}_i &= \beta_0 + \beta_1 IA_{a,i} + \beta_2 hrs_{a,i} + u_i \\ \text{salario}_i &= \alpha_0 + \alpha_1 IA_{a,i} + \alpha_2 hrs_{a,i} + \alpha_3 x_{3i} + v_i \end{aligned}$$

y conserve las estimaciones de  $\hat{\beta}_1$  y  $\hat{\alpha}_1$  asociadas a la variable  $IA_{a,i}$ .

- (ii) Repita el paso (i) un total de  $N = 1000$  veces<sup>3</sup>, y en cada iteración almacene los valores de  $\hat{\beta}_1$  y  $\hat{\alpha}_1$ .
- (iii) Con las  $N$  repeticiones realizadas, construya las distribuciones empíricas de  $\hat{\beta}_1$  y  $\hat{\alpha}_1$ , y represéntelas mediante funciones de densidad de kernel en un mismo gráfico. Incluya líneas verticales que indiquen la media de cada distribución.

Responda:

- a) Presente el gráfico solicitado, asegurándose de incluir ambas distribuciones y sus medias. **(2 puntos)**
- b) Compare los resultados de sus simulaciones: ¿qué diferencia observa entre las distribuciones de  $\hat{\beta}_1$  y  $\hat{\alpha}_1$ ? Fundamente empírica y teóricamente su respuesta. **(2 puntos)**

## Pregunta 3 (4 puntos)

Considere nuevamente la especificación planteada en (1). Suponga ahora que, además de las variables relevantes  $IA_{a,i}$  y  $hrs_{a,i}$ , se quieren añadir 15 variables  $z_{1i}, z_{2i}, \dots, z_{15i}$ . Cada

---

<sup>3</sup>Note que en cada iteración se obtiene una muestra distinta a la anterior

una de estas variables irrelevantes se genera como una combinación lineal de las covariables relevantes más un término de ruido normal, es decir,

$$z_{ji} = 0,3 IA_{a,i}^{std} + 0,3 hrs_{a,i}^{std} + \varepsilon_{ji}, \quad \varepsilon_{ji} \sim \mathcal{N}(0, 1),$$

y posteriormente se estandarizan para que tengan media cero y varianza uno. De esta manera, las  $z_{ji}$  están débilmente correlacionadas con las covariables relevantes, pero no aportan información adicional al modelo.

- (i) Para una submuestra aleatoria sin reemplazo de tamaño  $n = 1000$ , estime los coeficientes MCO de las siguientes regresiones:

$$\begin{aligned} \text{salario}_i &= \beta_0 + \beta_1 IA_{a,i} + \beta_2 hrs_{a,i} + u_i \\ \text{salario}_i &= \alpha_0 + \alpha_1 IA_{a,i} + \alpha_2 hrs_{a,i} + \sum_{j=1}^{15} \delta_j z_{ji} + v_i \end{aligned}$$

y conserve en cada caso la estimación asociada a  $IA_{a,i}$ , es decir,  $\hat{\beta}_1$  y  $\hat{\alpha}_1$ .

- (ii) Repita el paso (i) un total de  $N = 500$  veces, y en cada iteración almacene los valores de  $\hat{\beta}_1$  y  $\hat{\alpha}_1$ .
- (iii) Con las  $N$  repeticiones realizadas, construya las distribuciones empíricas de  $\hat{\beta}_1$  y  $\hat{\alpha}_1$  y representélas mediante funciones de densidad de kernel en un mismo gráfico. Incluya líneas verticales que indiquen la media de cada distribución.

Responda:

- a) Presente el gráfico solicitado, asegurándose de incluir ambas distribuciones y sus medias. **(2 puntos)**
- b) Compare los resultados de sus simulaciones: ¿qué diferencia observa entre las distribuciones de  $\hat{\beta}_1$  y  $\hat{\alpha}_1$ ? Fundamente empírica y teóricamente su respuesta. **(2 puntos)**

## Pregunta 4 (6 puntos)

En esta pregunta se construirá un experimento simulado para analizar la distribución del estimador  $\hat{\beta}$ . A diferencia de las preguntas anteriores, aquí deberá generar explícitamente las variables de tratamiento y de resultado (*outcomes*).

Sea  $S$  un ingreso extra que afecta de forma opuesta según el sexo: a los hombres se les adiciona  $\text{salario}' = \text{salario} + S$  en caso de estar tratados, mientras que a las mujeres se les descuenta  $\text{salario}' = \text{salario} - S$ .  $S$  puede ser un número positivo o negativo, cuyo valor numérico usted debe definir, tal que  $30.000 < |S| < 80.000$ . Así, el proceso generador de datos se define como:

- El tratamiento  $D_i \sim \text{Bernoulli}(0,5)$  se asigna aleatoriamente con probabilidad 0,5.

$$\blacksquare F(\text{male}_i, D_i) = \begin{cases} +S \cdot D_i, & \text{si } \text{male}_i = 1 \text{ (hombre)}, \\ -S \cdot D_i, & \text{si } \text{male}_i = 0 \text{ (mujer)}. \end{cases}$$

- El DGP resulta:

$$\text{salario}'_i = \text{salario}_i + F(\text{male}_i, D_i).$$

Con este diseño, realice el siguiente procedimiento:

- (i) Defina una grilla de proporciones de hombres  $p \in \{0, 0,05, 0,10, \dots, 1\}$  y fije un tamaño de submuestra  $n = 1000$ . Para cada  $p$ , genere submuestras con  $n_h = p \cdot n$  hombres y  $n_m = (1 - p) \cdot n$  mujeres.

- (ii) Estime el modelo

$$y_i'' = \beta_0 + \beta_1 D_i + u_i,$$

y conserve el valor estimado de  $\hat{\beta}_1$ .

- (iii) Repita los pasos anteriores  $N = 200$  veces para cada proporción  $p$  y calcule la media de las estimaciones de  $\hat{\beta}_1$ .

Responda:

- a) Grafique el valor promedio de  $\hat{\beta}_1$  en función de la proporción de hombres  $p$  en la muestra. **(2.5 puntos)**
- b) Considere ahora el valor teórico esperado del estimador:

$$\mathbb{E}[\hat{\beta}_1 | p] = (2p - 1) \cdot S,$$

el cual depende linealmente de la proporción de hombres  $p$ . Añada esta curva teórica al gráfico obtenido en a) y compare con los valores empíricos. Interprete las similitudes y posibles diferencias entre ambos. **(1 punto)**

- c) Explique cómo varía el valor esperado de  $\hat{\beta}_1$  en los casos extremos y en el caso intermedio  $p = 0,5$ . **(1 punto)**
- d) Interprete los resultados en relación con la definición de  $S$  y discuta su consistencia con la teoría de MCO y con el diseño del DGP planteado. **(1.5 punto)**

## Anexos


### Códigos de la base de datos

| Variable      | Descripción                                               |
|---------------|-----------------------------------------------------------|
| rem_mes_inf   | Remuneración mensual imponible informada (en CLP).        |
| n_hrs_ext_tot | Número total de horas extra solicitadas en el mes.        |
| male          | Indicador de sexo: 1 si es hombre, 0 si es mujer.         |
| id_ind        | Identificador único del funcionario en la base.           |
| mes           | Mes de registro de la remuneración (1 a 12).              |
| IA            | Horas dedicadas a un programa de inteligencia artificial. |
| años_servicio | Años de servicio acumulados del funcionario.              |


Tabla 1: Descripción de las variables contenidas en la base `salarios_transparencia_v2.0.dta`.

## Ejemplo de citación de IA

Si el/la estudiante utiliza alguna herramienta de IA para apoyarse en su informe o desarrollo de código, debe citar en un apartado de anexos del informe un pantallazo que incluya tanto el *prompt* proporcionado como la respuesta que dio la IA. Por ejemplo, si quisiera calcular una regresión particular en R, y le pregunto a ChatGPT cómo hacerlo, debo citarlo:



A su vez, se debe citar cualquier uso de la herramienta, por ejemplo, para incluir las figuras se utilizó también ChatGPT, por lo que se debe citar:



Note que el tamaño de las imágenes puede ser pequeño o grande, con tal de que se pueda distinguir perfectamente tanto el *prompt* como la respuesta de la IA.