



Pontificia Universidad Católica de Chile
Escuela de Ingeniería
Departamento de Ingeniería Industrial y de Sistemas

ICS2563 Econometría Aplicada

Tarea 4 - Grupo 21

Integrantes:

- Agustina Caneo Huerta
- Franco Nicolai Corvalán Mansourova

Fecha de entrega: 28 de octubre de 2025

Índice de contenido

1 Problema 1	2
1.1 Ítem a.	2
1.2 Ítem b.	3
1.3 Ítem c.	4
2 Problema 2	6
2.1 Ítem a.	6
2.2 Ítem b.	6
2.3 Ítem c.	7
3 Problema 3	9
3.1 Ítem a.	9
3.2 Ítem b.	10
3.3 Ítem c.	10
3.4 Ítem d.	11
4 Problema 4	13
4.1 Ítem a.	13
4.2 Ítem b.	14
5 Problema 5	16
5.1 Ítem a.	16
5.2 Ítem b.	17
5.3 Ítem c.	17
6 Anexos	20

1. Problema 1

1.1. Ítem a.

Para analizar la relación entre el nivel de interrupción en la sala y la cantidad de estudiantes disruptivos, se puede plantear el siguiente modelo de regresión lineal:

$$disrupcion_i = \beta_0 + \beta_1 \cdot n_disrup_i + \varepsilon_i$$

Donde:

- $disrupcion_i$ es el índice de interrupción en la sala de clases del colegio i .
- n_disrup_i es el número de estudiantes disruptivos en la sala del colegio i .
- β_1 es el coeficiente que mide el cambio en el nivel de interrupción por cada estudiante disruptivo adicional.
- ε_i es el término de error.

Dado el desarrollo del modelo de regresión lineal simple propuesto con los datos proporcionados resultó en la siguiente tabla ANOVA y de coeficientes:

```
Call:
lm(formula = disrupcion ~ n_disrup, data = linea_base)

Residuals:
    Min       1Q   Median       3Q      Max
-2.16837 -0.57781 -0.00221  0.59709  2.14273

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) -1.18972    0.27798  -4.280 3.62e-05 ***
n_disrup      0.26214    0.05226   5.016 1.71e-06 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.9048 on 129 degrees of freedom
Multiple R-squared:  0.1632,    Adjusted R-squared:  0.1567
F-statistic: 25.16 on 1 and 129 DF,  p-value: 1.711e-06
```

Imagen 1

Tabla ANOVA obtenida de la regresión lineal desarrollada.

El modelo de regresión lineal simple desarrollado arroja un coeficiente $\hat{\beta}_1$ de 0.26214, lo que significa que por cada estudiante disruptivo adicional en una sala de clases, el índice de interrupción promedio aumenta en 0.26214 unidades. Este hallazgo es estadísticamente muy significativo, dado que el p -valor de 1.71×10^{-6} es extremadamente bajo, permitiendo rechazar la hipótesis nula de que no existe relación. Sin embargo, el R^2 múltiple es bajo (0.1632), indicando que solo una pequeña fracción

de la variabilidad del índice de interrupción es explicada por el número de estudiantes disruptivos, lo cual, junto con la naturaleza observacional del estudio, subraya que no se puede inferir causalidad; la relación es meramente de correlación, y es probable que el estimador esté sesgado debido a la omisión de variables clave (como la calidad del profesor o la disciplina del colegio) que afectan tanto la asignación de estudiantes como el nivel de interrupción general.

1.2. Ítem b.

Para analizar la relación entre el nivel de interrupción en la sala y la cantidad de estudiantes disruptivos agregaremos variables de control tales como el tamaño del curso y el sexo del profesor, se puede plantear el siguiente modelo de regresión lineal:

$$disrupcion_i = \beta_0 + \beta_1 \cdot n_disrup_i + \beta_2 \cdot n_curso_i + \beta_3 \cdot prof_mujer_i + \varepsilon_i$$

Dado el desarrollo del modelo de regresión lineal simple propuesto con los datos proporcionados resultó en la siguiente tabla ANOVA y de coeficientes:

```
Call:
lm(formula = disrupcion ~ n_disrup + n_curso + prof_mujer, data = linea_base)

Residuals:
    Min       1Q   Median       3Q      Max
-2.13948 -0.55021  0.00377  0.60434  2.09656

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) -1.73994    1.88950  -0.921   0.359
n_disrup      0.26204    0.05350   4.898 2.89e-06 ***
n_curso       0.01866    0.06013   0.310   0.757
prof_mujer    -0.09550    0.16140  -0.592   0.555
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.9105 on 127 degrees of freedom
Multiple R-squared:  0.1658,    Adjusted R-squared:  0.1461
F-statistic: 8.416 on 3 and 127 DF,  p-value: 3.817e-05
```

Imagen 2

Tabla ANOVA obtenida de la regresión lineal desarrollada.

El modelo de regresión lineal múltiple desarrollado muestra que el coeficiente asociado al número de estudiantes disruptivos, $\hat{\beta}_1$, es de 0.26204. La interpretación es que, controlando por (manteniendo constantes) el tamaño total del curso y el sexo del profesor, el índice de interrupción promedio de la sala aumenta en 0.26204 unidades por cada estudiante disruptivo adicional. La principal conclusión estadística se centra en el p -valor de $\hat{\beta}_1$, que es de 2.89×10^{-6} . Este valor, siendo extremadamente pequeño (mucho menor que el umbral $\alpha = 0.05$), indica que la relación entre la cantidad de estudiantes disruptivos y el índice de interrupción es altamente significativa desde el punto de vista estadístico. El hecho de que este p -valor sea el más bajo sugiere que n_disrup es la variable con la evidencia más fuerte de relación lineal con la interrupción, en comparación con las variables de control. ¿Es una Relación Causal Ahora? No, aún no es posible asegurar que la relación sea causal. La adición del tamaño del curso y el sexo del profesor hace que el modelo sea más robusto al mitigar el sesgo

de las variables omitidas observables, pero persiste el potencial sesgo por variables omitidas no observables. Factores como la calidad pedagógica o la metodología de enseñanza del profesor, el liderazgo escolar, o el compromiso de los padres, no están incluidos.

1.3. Ítem c.

Para realizar un análisis exploratorio de las diferencias en las variables de resultado, la muestra de colegios fue clasificada en dos grupos en función de su nivel de estudiantes disruptivos. La métrica utilizada para la clasificación fue la mediana de la cantidad de estudiantes disruptivos de la muestra total. Los colegios se segmentaron de la siguiente manera:

- **Alta proporción de estudiantes disruptivos:** Colegios cuya cantidad de estudiantes disruptivos se encuentra por encima de la mediana.
- **Baja proporción de estudiantes disruptivos:** Colegios cuya cantidad de estudiantes disruptivos se encuentra por debajo de la mediana.

A continuación, se calcularon los valores promedio del índice de disrupción agregada y del tiempo de demora para comenzar la clase para cada uno de estos grupos, cuyos resultados se presentan a continuación:

Tabla 1

Estadísticas Descriptivas por Grupo de Estudiantes Disruptivos

Grupo	N_Colegios	Disrupción_Promedio	Atraso_Promedio_Minutos
Alta proporción de estudiantes disruptivos	50	0.5931034	9.21100
Baja proporción de estudiantes disruptivos	81	-0.1284130	10.23025

Los resultados de la tabla muestran una clara asociación entre la proporción de estudiantes disruptivos y las variables de resultado. Analizamos cada punto por separado:

- **Nivel de Disrupción:** Como era de esperar, los colegios con una alta proporción de estudiantes disruptivos presentan, en promedio, un índice de disrupción mayor (0.59) en comparación con los colegios de baja proporción (-0.13).
- **Tiempo de Demora:** La relación es inversa para el tiempo de demora. Las salas con alta proporción de alumnos disruptivos tardan, en promedio, un minuto menos en comenzar la clase (9.21 vs 10.23 minutos). Puede deberse a un pseudo entrenamiento a volver a tomar la atención o posible habito de pausa activa dada por la distracción que ya es un hbito.

Con lo anterior, no es posible establecer una relación causal a partir de esta diferencia de promedios. El marco de resultados potenciales exige que la asignación al grupo de "tratamiento" sea aleatoria. Claramente, esta condición no se cumple, ya que los colegios no son asignados al azar a tener más o menos alumnos disruptivos. Aunque las estadísticas descriptivas muestran una correlación, no

podemos afirmar que una mayor cantidad de alumnos disruptivos cause un mayor nivel de disrupción (aunque sea plausible) y definitivamente no podemos concluir que cause una disminución en el tiempo de inicio de la clase.

2. Problema 2

2.1. Ítem a.

Se utilizó la base *linea_base* para evaluar el balance de covariables entre los colegios tratados y de control.

Las variables disponibles permiten realizar comparaciones en características pretratamiento como:

- *n_disrup*: número de estudiantes clasificados como potencialmente disruptivos.
- *n_curso*: número total de estudiantes del curso.
- *disrupcion*: índice promedio de disrupción en aula (normalizado a media 0 y desviación estándar 1).
- *prof_mujer*: sexo del profesor jefe (1= mujer, 0= hombre).
- *atraso*: Tiempo promedio (en minutos) que demora en comenzar la clase, medido por el profesor.

Ahora, para entregar evidencia sobre la aleatorización del experimento, se comparan las medias de las variables antes descritas en $t=0$ entre tratamiento=0 y tratamiento=1, y si la aleatorización fue exitosa no deberían existir diferencias sistemáticas o significativas entre grupos.

En caso de que lo anterior falle, significa que hay **sesgo de selección**, y el grupo de control no es un **contrafactual** válido, por lo que la interpretación causal directa falla.

2.2. Ítem b.

Para contextualizar, los datos de corte transversal son un tipo de datos que se recopilan de múltiples sujetos u objetos al mismo tiempo en un solo punto o período de tiempo, para este caso se utiliza observaciones de múltiples colegios en un solo momento del tiempo.

Por lo tanto, se propone el siguiente modelo sobre la línea de salida (datos post-tratamiento):

$$disrupcion_i = \beta_0 + \beta_1 tratamiento_i + \varepsilon_i$$

El coeficiente de interés es β_1 , el cual mide el efecto promedio del programa sobre la disrupción.

Supuesto: Lo más importante es asumir que la asignación del tratamiento fue aleatoria y exitosa, la aleatorización hace que la variable de tratamiento sea independiente de otros factores (como ε_i) que afectan la variable de disrupción.

De esta manera, se supone que $E[\varepsilon_i | tratamiento_i] = 0$. Bajo estas condiciones, podemos interpretar al coeficiente β_1 como el efecto promedio del tratamiento (ATE), por lo que, los grupos tratado y control son comparables en ausencia del programa, de modo que los no tratados constituyen un contrafactual válido para los tratados. Cuando este supuesto se cumple, la simple diferencia de

medias entre tratados y controles puede interpretarse como una estimación causal válida del efecto promedio sobre los tratados. Por lo que se puede interpretar a β_1 como **efecto causal promedio del tratamiento**.

2.3. Ítem c.

Si agregamos otras variables de control al modelo anterior, ahora se ve de la siguiente manera:

$$disrupcion_i = \beta_0 + \beta_1 tratamiento_i + \beta_2 n_curso_base_i + \beta_3 prof_mujer_base_i + \beta_4 disrupcion_base_i + \beta_5 n_disrupcion_base_i$$

En la estimación del modelo del inciso b, se evalúa el efecto del programa sobre la disrupción sin incluir controles adicionales:

```
Call:
lm(formula = disrupcion ~ tratamiento, data = cruzar_datos)

Residuals:
    Min       1Q   Median       3Q      Max
-2.0199 -0.5599  0.0241  0.6081  2.9441

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)   0.1934     0.1209   1.600  0.11194
tratamiento  -0.4667     0.1678  -2.782  0.00622 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.9593 on 129 degrees of freedom
Multiple R-squared:  0.05659,    Adjusted R-squared:  0.04928
F-statistic: 7.738 on 1 and 129 DF,  p-value: 0.006217
```

Imagen 3

Tabla ANOVA obtenida de la regresión lineal desarrollada en inciso b.

En el modelo para este inciso, se incorporan covariables pretratamiento para controlar diferencias residuales entre los grupos:

```

Call:
lm(formula = disrupcion_t1 ~ tratamiento + disrupcion_t0 + n_disrup_t0 +
    n_curso_t0 + prof_mujer_t0, data = cruzar_datos_t0)

Residuals:
    Min       1Q   Median       3Q      Max
-1.9737 -0.6505 -0.0777  0.6921  3.2640

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  -2.11059    1.95644  -1.079  0.28276
tratamiento   -0.43970    0.16344  -2.690  0.00812 **
disrupcion_t0  0.06953    0.09054   0.768  0.44397
n_disrup_t0    0.14874    0.05950   2.500  0.01373 *
n_curso_t0     0.05083    0.06169   0.824  0.41154
prof_mujer_t0 -0.21651    0.16488  -1.313  0.19155
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.9285 on 125 degrees of freedom
Multiple R-squared:  0.1437,    Adjusted R-squared:  0.1095
F-statistic: 4.196 on 5 and 125 DF,  p-value: 0.00147

```

Imagen 4

Tabla ANOVA obtenida de la regresión lineal desarrollada en inciso c.

Análisis: Al comparar los resultados, podemos ver que el coeficiente del tratamiento pasa de -0.474 a -0.439 aproximadamente, manteniendo magnitud y significancia casi idénticas. Esto muestra que el efecto del programa es robusto frente a la inclusión de covariables. Y dado que la asignación fue aleatoria, era de esperar que los controles no alteraran el efecto estimado, lo cual se confirma empíricamente.

Conclusión: Los resultados muestran que el programa de mentorías reduce significativamente el nivel de disrupción en el aula, tanto en el modelo simple como en el modelo con controles pretratamiento. La inclusión de controles pretratamiento mejora la capacidad explicativa del modelo sin alterar el coeficiente del tratamiento, por lo cual se considera conveniente mantenerlos en el análisis final.

3. Problema 3

3.1. Ítem a.

Para medir el efecto promedio del programa sobre el tiempo de retraso de inicio de clases, se puede plantear el siguiente modelo de regresión lineal:

$$atraso_{it} = \beta_0 + \beta_1 \cdot tratamiento_i + \beta_2 \cdot periodo_t + \delta \cdot (tratamiento_i \cdot periodo_t) + \varepsilon_{it}$$

Donde:

- $atraso_{it}$ es el tiempo de demora del colegio i en el periodo t .
- $tratamiento_i$ es una variable binaria que toma el valor 1 si el colegio pertenece al grupo de tratamiento y 0 si pertenece al grupo de control.
- $periodo_t$ es una variable binaria que vale 1 para el periodo post-intervención (junio de 2025) y 0 para el periodo base (marzo de 2024).
- El término de interacción $(tratamiento_i \cdot periodo_t)$ es la variable que captura el efecto promedio del tratamiento sobre los tratados (ATT).

Dado el desarrollo del modelo de regresión lineal simple propuesto con los datos proporcionados resultó en la siguiente tabla ANOVA y de coeficientes:

```
Call:
lm(formula = atraso ~ tratamiento * periodo, data = panel_data)

Residuals:
    Min       1Q   Median       3Q      Max
-10.921  -4.921  -1.034   0.853  43.853

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)    9.88889    1.02987   9.602  <2e-16 ***
tratamiento   -0.09183    1.42943  -0.064   0.9488
periodo        1.03175    1.45645   0.708   0.4793
tratamiento:periodo -4.53469    2.02152  -2.243   0.0257 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 8.174 on 258 degrees of freedom
Multiple R-squared:  0.04513,    Adjusted R-squared:  0.03403
F-statistic: 4.064 on 3 and 258 DF,  p-value: 0.007602
```

Imagen 5

Tabla ANOVA obtenida de la regresión lineal desarrollada.

El modelo de regresión lineal simple desarrollado arroja un coeficiente $\hat{\delta}$ de -4.53469 , lo que es menor a cero, lo que su interpretación es que implicaría que el programa fue efectivo en reducir el tiempo promedio de inicio de clases en los colegios tratados, en comparación con la tendencia que seguían los colegios de control.

3.2. Ítem b.

Para que el coeficiente DiD (δ) se interprete como un efecto causal válido (ATT), el supuesto fundamental es el de Tendencias Paralelas (PTA), el cual requiere que, sin el programa, las trayectorias temporales del tiempo de demora habrían sido idénticas para los grupos de tratamiento y control. El cumplimiento de este supuesto resulta muy plausible aquí porque el diseño incluye la aleatorización de los 131 colegios a los grupos; esta asignación aleatoria es una fortaleza crítica, ya que garantiza la equivalencia promedio de los grupos en las tendencias iniciales, incluyendo factores no observables. Además, se cumple el requisito de estabilidad de los grupos puesto que se confirmó que se siguió a los mismos colegios y que la composición de los estudiantes y profesores no cambió, evitando sesgos por migración. Finalmente, el supuesto SUTVA también parece razonable, ya que la intervención se realiza a nivel de colegio y es improbable que su implementación en un centro afecte el tiempo de demora en un colegio de control distinto, asegurando la independencia de los efectos.

3.3. Ítem c.

Para evaluar si el efecto del programa varía según el sexo del profesor, se puede plantear el siguiente modelo de regresión lineal

$$atraso_{it} = \beta_0 + \dots + \delta_1 \cdot (tratamiento_i \cdot periodo_t) + \gamma \cdot (tratamiento_i \cdot periodo_t \cdot prof_mujer_i) + \dots + \varepsilon_{it}$$

Dado el desarrollo del modelo de regresión lineal simple propuesto con los datos proporcionados resultó en la siguiente tabla ANOVA y de coeficientes:

```
Call:
lm(formula = atraso ~ tratamiento * periodo * prof_mujer, data = panel_data)

Residuals:
    Min       1Q   Median       3Q      Max
-13.067  -4.576  -1.018   1.257  43.424

Coefficients:
                Estimate Std. Error t value Pr(>|t|)
(Intercept)      9.36364    1.42076   6.591 2.51e-10 ***
tratamiento       0.02922    1.98035   0.015   0.988
periodo          -0.39394    2.00926  -0.196   0.845
prof_mujer        1.10303    2.05888   0.536   0.593
tratamiento:periodo -2.11320    2.80063  -0.755   0.451
tratamiento:prof_mujer -0.27013    2.85670  -0.095   0.925
periodo:prof_mujer  2.99394    2.91169   1.028   0.305
tratamiento:periodo:prof_mujer -5.04589    4.03999  -1.249   0.213
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 8.162 on 254 degrees of freedom
Multiple R-squared:  0.06285,    Adjusted R-squared:  0.03702
F-statistic: 2.433 on 7 and 254 DF,  p-value: 0.01981
```

Imagen 6

Tabla ANOVA obtenida de la regresión lineal desarrollada.

El modelo de Diferencias en Diferencias (DiD) arroja un coeficiente de interacción, $\hat{\delta}$, de -5.04589 ,

lo que significa que el programa implementado generó una reducción en el tiempo de demora de 5.04589 minutos en el grupo de tratamiento, lo que se interpreta que dicho tratamiento o programa fue más efectivo en clases de profesoras que profesores.

3.4. Ítem d.

Ahora desarrollaremos el mismo análisis diferenciado por el sexo del profesor, se puede plantear los siguiente modelo de regresión lineal:

$$atraso_{it} = \alpha_0 + \alpha_1 \cdot tratamiento_i + \alpha_2 \cdot periodo_t + \delta_{hombres} \cdot (tratamiento_i \cdot periodo_t) + u_{it}$$

$$atraso_{it} = \theta_0 + \theta_1 \cdot tratamiento_i + \theta_2 \cdot periodo_t + \delta_{mujeres} \cdot (tratamiento_i \cdot periodo_t) + v_{it}$$

Dado el desarrollo del modelo de regresión lineal simple propuesto con los datos proporcionados resultó en la siguiente tabla ANOVA y de coeficientes:

```
Call:
lm(formula = atraso ~ tratamiento * periodo, data = data_mujeres)

Residuals:
    Min       1Q   Median       3Q      Max
-13.067  -5.576  -2.821   1.783   43.424

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)    10.4667     1.7500   5.981 2.28e-08 ***
tratamiento     -0.2409     2.4180  -0.100  0.9208
periodo         2.6000     2.4749   1.051  0.2955
tratamiento:periodo -7.1591     3.4195  -2.094  0.0384 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 9.585 on 122 degrees of freedom
Multiple R-squared:  0.07456,    Adjusted R-squared:  0.05181
F-statistic: 3.277 on 3 and 122 DF,  p-value: 0.02342
```

Imagen 7

Tabla ANOVA obtenida de la regresión lineal desarrollada con datos mujer.

```

Call:
lm(formula = atraso ~ tratamiento * periodo, data = data_hombres)

Residuals:
    Min       1Q   Median       3Q      Max
-10.886  -3.886  -0.886   1.150   34.114

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)    9.36364    1.14500   8.178 2.1e-13 ***
tratamiento     0.02922    1.59598   0.018  0.985
periodo        -0.39394    1.61928  -0.243  0.808
tratamiento:periodo -2.11320    2.25705  -0.936  0.351
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 6.578 on 132 degrees of freedom
Multiple R-squared:  0.02533, Adjusted R-squared:  0.003179
F-statistic: 1.144 on 3 and 132 DF, p-value: 0.334

```

Imagen 8

Tabla ANOVA obtenida de la regresión lineal desarrollada con datos hombre.

Este método está directamente relacionado con el modelo de la parte c). A continuación ilustramos las relaciones:

- El coeficiente de la interacción tratamiento en el modelo completo captura directamente el efecto del programa para el grupo de referencia, en este caso, los profesores hombres, arrojando un valor de -2.11, idéntico al obtenido en su respectivo modelo individual.
- Para calcular el efecto del programa en las profesoras mujeres desde el modelo completo, simplemente se suma el efecto base al coeficiente de la triple interacción ($-2.11320 + -5.04589$), lo que resulta en -7.1591, coincidiendo perfectamente con el resultado del modelo estimado solo para la submuestra de mujeres.

4. Problema 4

4.1. Ítem a.

Los coeficientes estimados para n_disrup y n_curso representan el efecto promedio de un cambio dentro de una misma escuela a lo largo del tiempo (de $t=0$ a $t=1$) sobre la variable *disrupcion*. Estos estimadores controlan por todas las características fijas no observadas de cada colegio.

En resumen, el modelo con efectos fijos permite capturar heterogeneidad no observada constante en el tiempo:

$$disrupcion_{it} = \alpha_i + \beta n_disrup_{it} + \gamma_1 n_curso_{it} + \gamma_2 prof_mujer + u_{it}$$

Los resultados son los siguientes:

```
Call:
plm(formula = disrupcion ~ n_disrup + n_curso + prof_mujer, data = data_4a,
     model = "within", index = c("rbd_curso", "periodo"))

Balanced Panel: n = 131, T = 2, N = 262

Residuals:
    Min.   1st Qu.   Median   3rd Qu.    Max.
-2.01941 -0.48104  0.00000  0.48104  2.01941

Coefficients:
              Estimate Std. Error t-value Pr(>|t|)
n_disrup    0.247491    0.102636  2.4113  0.0173 *
n_curso    -0.065583    0.090784 -0.7224  0.4714
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Total Sum of Squares:    107.62
Residual Sum of Squares: 102.59
R-Squared:               0.046678
Adj. R-Squared:          -0.92881
F-statistic: 3.15812 on 2 and 129 DF, p-value: 0.045811
```

Imagen 9

Tabla ANOVA obtenida del modelo realizado utilizando desviaciones de la media.

Análisis: Podemos ver que el coeficiente para el efecto del número de alumnos disruptivos (β) es 0.247 y estadísticamente significativo. Es decir, dentro de un mismo curso a lo largo del tiempo, un aumento de un estudiante disruptivo promedio está asociado con un incremento de aproximadamente 0.25 desviaciones estándar en el nivel de disrupción. Mientras que, el coeficiente para el efecto del tamaño del curso (γ_1) no es significativo, lo que sugiere que las variaciones internas en el número de alumnos por curso no tienen un efecto sobre la disrupción promedio, una vez controlados los efectos fijos. Finalmente, aunque incluimos a la variable *prof_mujer* en la fórmula, no se encuentra en los resultados. Esto se debe a que el estimador *within* elimina automáticamente toda variable que no varía en el tiempo dentro del curso, y cómo se mencionó los alumnos mantienen el mismo

profesor, por lo que la variable se absorbe dentro de los efectos fijos. Esto significa que las diferencias estructurales entre profesores hombres y mujeres no sesgan los coeficientes estimados, aunque no se obtenga un valor para γ_2 .

4.2. Ítem b.

Ahora se estima el modelo planteado anteriormente utilizando primeras diferencias:

$$\Delta \text{disrupcion}_{it} = \beta_0 + \beta_1 \Delta n_disrup_{it} + \beta_2 \Delta n_curso_{it} + \beta_3 \text{prof_mujer}_{it} + \Delta u_{it}$$

Donde $\Delta Y_{it} = Y_{it} - Y_{i0}$

Los resultados fueron los siguientes:

```
Oneway (individual) effect First-Difference Model

Call:
plm(formula = disrupcion ~ n_disrup + n_curso + prof_mujer, data = data_4a,
     model = "fd", index = c("rbd_curso", "periodo"))

Balanced Panel: n = 131, T = 2, N = 262
Observations used in estimation: 131

Residuals:
    Min.    1st Qu.    Median    3rd Qu.    Max.
-3.136395 -0.972974 -0.093585  0.872046  4.183980

Coefficients:
              Estimate Std. Error t-value Pr(>|t|)
(Intercept)  -0.130013   0.114393  -1.1365  0.25785
n_disrup      0.215584   0.106295   2.0282  0.04462 *
n_curso      -0.058007   0.090927  -0.6380  0.52464
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Total Sum of Squares:    210.22
Residual Sum of Squares: 203.14
R-Squared:               0.03366
Adj. R-Squared:          0.018561
F-statistic: 2.22928 on 2 and 128 DF, p-value: 0.11177
```

Imagen 10

Tabla ANOVA obtenida del modelo realizado utilizando primeras diferencias.

Análisis: Al comparar los modelos de efectos fijos y primeras diferencias, se observa consistencia en los resultados: en ambos casos, el número de alumnos disruptivos tiene un efecto positivo y significativo sobre el nivel de disrupción en la sala de clases, mientras que el tamaño del curso no muestra influencia estadísticamente relevante. Aunque, podemos notar que El coeficiente de n_disrup es ligeramente menor en magnitud en el modelo de primeras diferencias (0.215 vs. 0.247). Y la significancia global del modelo (F-test) cae en el de primeras diferencias ($p = 0.111 > 0.05$), lo que sugiere menor precisión estadística. Esto se puede deber a que el modelo de primeras diferencias se basa en las diferencias de las variables, mientras que el modelo *within* directamente controla

la varianza interna a cada individuo. Por lo que, primeras diferencias genera estimaciones menos eficientes y más ruidosas. Finalmente, en ambos modelos la variable *prof_mujer* no se estima explícitamente, ya que es constante en el tiempo. Por lo tanto, el efecto del sexo del profesor se controla implícitamente, y las diferencias estructurales entre profesores hombres y mujeres no sesgan los resultados.

5. Problema 5

5.1. Ítem a.

Para estimar el efecto causal de la cantidad de estudiantes disruptivos sobre el nivel de disrupción en la sala de clases, usaría un modelo similar al de la pregunta 4, considerando que se buscaba la relación entre la cantidad de estudiantes disruptivos y el nivel de disrupción y este modelo controla los factores de posibles variables omitidas, que influyen en la variable dependiente y explicativas (por ejemplo: el nivel socioeconómico promedio de los alumnos del curso, que podría afectar el número de alumnos disruptivos y también la disrupción en la clase).

Estimaremos el siguiente modelo de efectos fijos y temporales:

$$disrupcion_{it} = \beta_1 n_disrup_{it} + \beta_2 n_curso_{it} + \alpha_i + \lambda_t + \varepsilon_{it}$$

Tener en cuenta que:

- i representa el colegio.
- t representa el periodo de tiempo.
- $disrupcion_{it}$ es el índice de disrupción del colegio i en el período t .
- n_disrup_{it} es el número de estudiantes disruptivos.
- n_curso_{it} es el número total de estudiantes.
- α_i es el efecto fijo específico del colegio (captura características no observadas constantes en el tiempo).
- λ_t es el efecto fijo específico del período (captura tendencias comunes a todos los cole en un período dado).
- β_1 y β_2 son los coeficientes que miden el efecto de n_disrup y n_curso sobre $disrupcion$, controlando por los efectos fijos α_i y λ_t .
- ε_i es el término de error.

Las ventajas de este modelo son que elimina el sesgo por variable omitida proveniente de factores fijos de cada colegio, que no cambian entre los periodos. También al incluir efectos fijos de tiempo, controla por factores que afectan a todos las colegios por igual en un año específico.

Resultados obtenidos:

5.2. Ítem b.

Es necesario mencionar, que aunque el modelo de efectos fijos es correcto para intentar estimar el efecto causal de la cantidad de estudiantes disruptivos sobre el nivel de disrupción en la sala de clases. No necesariamente garantiza por sí solo una identificación causal de β_1 , ya que no corrige por endogeneidad proveniente de variables omitidas que cambian en el tiempo ni por simultaneidad entre n_disrup y $disrupcion$.

Supuestos necesarios:

1. **Exogeneidad estricta:** Para este caso la fórmula es $E[\varepsilon_{it} | n_disrup_{i1}, n_disrup_{i2}, \dots, \alpha_i] = 0$. Este supuesto implica que las variaciones en el número de estudiantes disruptivos dentro de un curso a lo largo del tiempo son exógenas respecto a las perturbaciones no observadas en la disrupción. es decir, los cambios en n_disrup_{it} no deben estar correlacionados con cambios en factores no medidos que también afecten $disrupcion_{it}$. Por ejemplo, si se cambiaran las políticas de disciplina en el colegio entre el periodo 0 y 1, y esto afecta la manera que se clasifican a los alumnos disruptivos (aumenta n_disrup_{it}) y también el nivel general de disrupción, entonces no se cumple el supuesto. Empíricamente si calculáramos los estimadores del modelo de efectos fijos y primeras diferencias, y estos fueran muy distintos podría significar que el supuesto no se cumple
2. **Ausencia de endogeneidad dinámica o simultaneidad:** En conjunto con lo anterior, para reforzar, si un aumento temporal en la disrupción ($\Delta\varepsilon_{it} > 0$) lleva a que los profesores clasifiquen a más alumnos como disruptivos ($\Delta n_disrup_{it} > 0$), entonces se rompe la exogeneidad estricta y el estimador de efectos fijos estaría sesgado.
3. **Ausencia de variables omitidas que varían en el tiempo:** Si existen factores no observados que cambian dentro de la escuela entre 2024 y 2025 (por ejemplo, la llegada o salida de un profesor clave, cambios en la composición socioeconómica del alumnado, o eventos institucionales particulares) y que afectan tanto a n_disrup como a $disrupcion$, el coeficiente β_1 también estaría sesgado.

5.3. Ítem c.

Resultados obtenidos:

```

Oneway (individual) effect Within Model

Call:
plm(formula = disrupcion ~ n_disrup + n_curso + factor(periodo),
     data = data_4a, model = "within", index = c("rbd_curso",
        "periodo"))

Balanced Panel: n = 131, T = 2, N = 262

Residuals:
    Min.   1st Qu.   Median   3rd Qu.    Max.
-2.09199 -0.46495  0.00000  0.46495  2.09199

Coefficients:
              Estimate Std. Error t-value Pr(>|t|)
n_disrup         0.215584   0.106295   2.0282  0.04462 *
n_curso          -0.058007   0.090927  -0.6380  0.52464
factor(periodo)1 -0.130013   0.114393  -1.1365  0.25785
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Total Sum of Squares:    107.62
Residual Sum of Squares: 101.57
R-Squared:               0.056202
Adj. R-Squared:          -0.92446
F-statistic: 2.54075 on 3 and 128 DF, p-value: 0.059315

```

Imagen 11

Tabla ANOVA obtenida del modelo realizado utilizando efectos fijos.

Los coeficientes obtenidos fueron:

$$\hat{\beta}_1 \approx 0.2156 \quad \text{y} \quad \hat{\beta}_2 \approx -0.0580$$

El coeficiente de interés, $\hat{\beta}_1$, representa el efecto promedio del número de estudiantes disruptivos sobre el nivel de disrupción en la sala de clases, controlando por el tamaño del curso, los efectos fijos específicos de cada colegio (α_i) y las tendencias comunes a todos los colegios en cada periodo (λ_t). El valor de $\hat{\beta}_1 = 0.2156$ indica que, manteniendo constante el tamaño total del curso y las características invariables del colegio, un aumento de un estudiante clasificado como disruptivo se asocia, en promedio, con un incremento de aproximadamente 0.22 desviaciones estándar en el índice de disrupción de la sala de clases.

En términos prácticos, esto implica que incluso pequeños aumentos en la cantidad de estudiantes disruptivos generan un efecto medible y sustancial en la dinámica general del aula, afectando potencialmente el ambiente de aprendizaje, la atención del profesor y la participación de los demás alumnos.

Por su parte, el coeficiente $\hat{\beta}_2 = -0.0580$ no resulta estadísticamente significativo, aunque su signo negativo podría interpretarse como una evidencia de que, para un número dado de alumnos disruptivos, clases más grandes disminuyen ligeramente el impacto relativo de cada alumno sobre la disrupción

total.

Análisis: El resultado causal estimado subraya la importancia de abordar de forma temprana y focalizada el problema de la disrupción escolar. Dado que cada estudiante disruptivo adicional aumenta el nivel general de disrupción en el aula, se podría recomendar políticas educativas como:

- **Intervenciones tempranas y personalizadas:** Implementar programas de especiales como mentorías para alumnos con conductas disruptivas, puede contribuir a reducir la incidencia de estos comportamientos.
- **Capacitación para profesores:** Fortalecer la formación continua de los profesores en estrategias de gestión del comportamiento y resolución de conflictos. Equipar a los docentes con herramientas pedagógicas efectivas para mitigar el impacto negativo de la disrupción en el aprendizaje.
- **Distribución de salas:** La concentración excesiva de alumnos con conductas problemáticas en una misma sala puede generar externalidades negativas sobre el resto de los estudiantes. Así que, distribuir de forma más equilibrada los cursos, podría mejorar el clima en cada sala.

Conclusión: El coeficiente estimado evidencia que el comportamiento disruptivo de los alumnos tiene efectos cuantificables y relevantes sobre el ambiente de aprendizaje. Y reducir la incidencia de conductas disruptivas mediante diferentes políticas es clave para mejorar la convivencia escolar y los resultados educativos en el largo plazo.

6. Anexos




Imagen 12

Conversación con Google Gemini.





Imagen 13

Conversación con Google Gemini.

**Imagen 14**

Conversación con Google Gemini.