



ESCUELA DE INGENIERÍA

FACULTAD DE INGENIERÍA



ESCUELA DE INGENIERÍA
FACULTAD DE INGENIERÍA

"Predictores de Malnutrición en el Seguimiento de Prematuros: Análisis de Datos de la Red Neocosur (2015-2024)"

Integrantes: Sebastián Jiménez, Franco Nicolai, Paula Soto, Isa Wilhelmy

I. Objetivos

Objetivo General


- Analizar variables asociadas a malnutrición en el seguimiento de prematuros de la Red Neocosur.

Objetivos específicos:

- Identificar variables asociadas a malnutrición en la red.
- Categorizar perfiles de los niños en seguimiento.
- Predecir el estado nutricional de los niños en los diferentes controles durante el seguimiento.

II. Graphical Abstract

Predictores de Malnutrición en Prematuros: Análisis de la Red Neocosur (2015-2024)



III. Resultados Previos y Preprocesamiento

Reducción de Dimensionalidad:

- **Qué se hizo:** Se introdujeron cuatro variables sintéticas orientadas a capturar el contexto temporal y socioeconómico del paciente. Se aplicó codificación *one-hot* y escalado `MinMaxScaler` para estandarizar las magnitudes paramétricas. Se eliminaron 66 registros (2.0%) y 8 columnas carentes de utilidad analítica.
- **Qué se obtuvo:** Mediante Análisis de Componentes Principales (PCA), se redujo la dimensionalidad del espacio de características, reteniendo 19 componentes que explican el 90% de la varianza.

Modelado Base y Clustering:

- **Qué se hizo:** Se estableció un modelo K-Nearest Neighbors (KNN) como línea base predictiva. Para la categorización no supervisada, se implementó Clustering Jerárquico (HAC) acoplado a Modelos de Mezcla Gaussiana (GMM), evaluando la cohesión mediante el coeficiente de Silhouette y el Criterio de Información de Akaike (AIC).
- **Qué decisiones se tomaron:** Se descartó el uso planificado de Isolation Forest y HDBSCAN para el análisis de perfiles.

IV. a. Reglas de Asociación y Red Bayesiana

Flujo de Trabajo

Se ejecutó la binarización y discretización de las variables clínicas continuas para adecuarlas a modelos probabilísticos discretos.

El objetivo fue transicionar desde una búsqueda exploratoria amplia de co-ocurrencias hacia un modelo jerárquico que explique las dependencias probabilísticas entre morbilidades/intervenciones tempranas y la malnutrición posterior.

IV. a. Reglas de Asociación y Red Bayesiana

Reglas de Asociación (mlxtend - Apriori)

- **Qué se hizo:** Se aplicó el algoritmo Apriori para explorar el espacio de datos discretizados sin asumir causalidad previa, basando el análisis en métricas de soporte y confianza.
- **Qué decisiones se tomaron:**
 - Se optó por Apriori frente a otros algoritmos exhaustivos debido a su eficiencia computacional.
 - Por otro lado, Notamos que las variables de seguimiento dependen del sexo del bebe, por lo que no se utilizaran.

```
cols_apriori = [  
    "Fenton al nacer",  
    "Multiple",  
    "Corticoides prenatales",  
    "Sulfato de magnesio",  
    "Malformación congénita mayor",  
    "Tipo de parto",  
    "Hemorragia Intraventricular (HIV)",  
    "Leucomalacia",  
    "Hidrocefalia",  
    "ECN",  
    "Recibe Surfactante",  
    "O2 36 semanas",  
    "Severidad DBP",  
    "Destino",  
    "O2 domiciliario al alta",  
    "Parálisis cerebral 24 Meses",  
    "cat_socioeducativa",  
    "Estado_Seguimiento",  
    "Tuvo_sepsis"  
]
```

IV. a. Reglas de Asociación y Red Bayesiana

Reglas de Asociación (mlxtend - Apriori)

Qué se obtuvo:

Reglas encontradas por Confianza (≥ 0.35): 257055

	antecedents	consequents	support	confidence	lift
170116	(Cat_Estadia_Estancia Corta, Cat_VM_Sin VM, Fe...	(Cat_EG_Nacer_Moderado/Tardío (≥ 32), Severida...	0.105801	0.583748	4.760121
170109	(Cat_EG_Nacer_Moderado/Tardío (≥ 32), Severida...	(Cat_Estadia_Estancia Corta, Cat_VM_Sin VM, Fe...	0.105801	0.862745	4.760121
170098	(Cat_Estadia_Estancia Corta, Severidad DBP_NA,...	(Cat_EG_Nacer_Moderado/Tardío (≥ 32), Cat_Oxig...	0.105801	0.583748	4.748483
86166	(Cat_Estadia_Estancia Corta, Cat_VM_Sin VM, Fe...	(Cat_EG_Nacer_Moderado/Tardío (≥ 32), Cat_Oxig...	0.105801	0.583748	4.748483
86173	(Cat_EG_Nacer_Moderado/Tardío (≥ 32), Cat_Oxig...	(Cat_Estadia_Estancia Corta, Cat_VM_Sin VM, Fe...	0.105801	0.860636	4.748483
170127	(Cat_EG_Nacer_Moderado/Tardío (≥ 32), Cat_Oxig...	(Cat_Estadia_Estancia Corta, Severidad DBP_NA,...	0.105801	0.860636	4.748483
170118	(Cat_Estadia_Estancia Corta, Cat_Oxigeno_Sin O...	(Cat_EG_Nacer_Moderado/Tardío (≥ 32), Severida...	0.105801	0.770241	4.659256
170107	(Cat_EG_Nacer_Moderado/Tardío (≥ 32), Severida...	(Cat_Estadia_Estancia Corta, Cat_Oxigeno_Sin O...	0.105801	0.640000	4.659256
170125	(Cat_EG_Nacer_Moderado/Tardío (≥ 32), Cat_VM_S...	(Cat_Estadia_Estancia Corta, Severidad DBP_NA,...	0.105801	0.637681	4.652555
170100	(Cat_Estadia_Estancia Corta, Severidad DBP_NA,...	(Cat_EG_Nacer_Moderado/Tardío (≥ 32), Cat_VM_S...	0.105801	0.771930	4.652555

Reglas de Asociación y Red Bayesiana

Red Bayesiana (pgmpy):


- **Qué se hizo:** Se construyó un grafo acíclico dirigido (DAG) a partir de las asociaciones extraídas para modelar dependencias condicionales. Se utilizó el método de Eliminación de Variables para realizar la inferencia probabilística.
- **Qué decisiones se tomaron:** Se transicionó del modelo de asociación puro a una red bayesiana para estructurar explícitamente las dependencias direccionales e indirectas, lo que habilita la formulación de consultas de probabilidad condicional frente a distintos escenarios clínicos.

IV. a. Reglas de Asociación y Red Bayesiana

Resultados

- **Qué se obtuvo:** Un modelo jerárquico que cuantifica la probabilidad marginal de malnutrición ante la inyección de evidencia dura en los nodos (por ejemplo, el incremento del riesgo al condicionar por la presencia simultánea de sepsis y bajo peso).

Estructura de la Red Bayesiana (Jerarquía Causal)



IV. a. Reglas de Asociación y Red Bayesiana

Conclusiones

- El modelo aprendió correctamente que las semanas de gestación es el padre directo del peso al nacer.

Cat_EG_Nacer —> Cat_Peso_Nacer —> Fenton al nacer

- Existe una gran correlación entre el tiempo de estadía y el peso al nacer.

Cat_Estadia —> Cat_Peso_Nacer

- El peso al nacer queda separado las de las enfermedades. Se infiere que las enfermedades están más relacionadas a una causa común: las semanas de gestación

IV. b. Análisis Causal y Estimación del ATE


Flujo de Trabajo

Se estructuró un análisis para aislar el efecto directo de intervenciones neonatales críticas sobre la malnutrición a los 6 meses, mitigando el sesgo por variables confusoras. Se definió el modelo causal, se estimó el impacto paramétrico y se sometió la arquitectura a pruebas de falsación rigurosas.

IV. b. Análisis Causal y Estimación del ATE

Analisis de coorrelación


En general, los gráficos confirman relaciones esperadas entre las variables generadas, siendo la Malnutricion 6m el resultado de interés que parece estar influenciado por ECN, Dias de VM, indice vulnerabilidad, y EG al nacer.



IV. b. Análisis Causal y Estimación del ATE

Estimación del Efecto Causal (Back-door e IPW):

- **Qué se hizo:** Se calculó el Efecto Causal Promedio (ATE) para tratamientos clave (Días de VM, índice vulnerabilidad, Fenton al nacer) empleando el criterio back-door y estimadores de Probabilidad Inversa de Ponderación (IPW) y Doubly Robust.
- **Qué se obtuvo:** Una estimación del impacto del tratamiento sobre la variable objetivo, fijando un ATE inicial de 0.0273.



IV. b. Análisis Causal y Estimación del ATE

Pruebas de Refutación (Data Subset Refuter):

- **Qué se hizo:** Se ejecutó una prueba de refutación mediante la retención aleatoria del 40% del dataset, reestimando el efecto causal en el 60% restante de los datos.
- **Qué se obtuvo:** Un nuevo efecto reestimado de 0.0476 asociado a un valor p de 0.60.
- **Qué decisiones se tomaron:** Se implementó esta prueba de falsación específica para garantizar que el ATE no constituyera un artefacto estadístico derivado del sobreajuste a la distribución particular de los datos recolectados.

IV. b. Análisis Causal y Estimación del ATE

Conclusiones

A través de la prueba de refutación obtuvimos un valor alto de p-value, lo que sugiere una estimación causal es robusta, es decir, no cambia drásticamente cuando se analiza una porción diferente de los datos. Esto aumenta la confianza en la validez de la estimación original.

Pero a pesar de todo, el efecto causal es bajo, acerca del 0.027.

IV. c. Optimización del Modelo Supervisado

Flujo de Trabajo

El proceso partió del descarte de un modelo baseline deficiente (K-Nearest Neighbors). El esfuerzo se concentró en la optimización de algoritmos mediante la manipulación de funciones de pérdida y la reconfiguración de umbrales asimétricos de probabilidad para contrarrestar el desbalance de clases.

IV. c. Optimización del Modelo Supervisado

Limitaciones del Baseline Supervisado (KNN)

- El modelo KNN base (**k=5**) obtiene una *accuracy* de **0,731**, resultado prácticamente idéntico al de un clasificador trivial (0,737). Este valor se sostiene de manera artificial al predecir constantemente la clase mayoritaria (74% de los casos normales).

	weights	k	recall_malnut	accuracy
0	uniform	5	0.238	0.731
1	uniform	11	0.148	0.741
2	uniform	15	0.098	0.726
3	uniform	21	0.074	0.739
4	uniform	31	0.066	0.746
5	distance	5	0.246	0.685
6	distance	11	0.205	0.711
7	distance	15	0.156	0.703
8	distance	21	0.131	0.716
9	distance	31	0.082	0.716

IV. c. Optimización del Modelo Supervisado


Limitaciones del Baseline Supervisado (KNN)

- El modelo presenta un *recall* crítico de **0,24** para la clase minoritaria. Falla en identificar a la mayoría de los pacientes afectados, detectando apenas **29 de 122** niños con riesgo de malnutrición (1 de cada 4).
 - La iteración sobre el número de vecinos (**k**) y la métrica de distancia (**weights**) no soluciona la incapacidad del algoritmo.
 - Incrementar **k** reduce aún más el *recall*, forzando al modelo a apoyarse en la clase dominante.
 - La configuración óptima (**k=5**, **weights=distance**) no supera el *recall* inicial.
- El algoritmo KNN resulta deficiente frente al desbalance estructural de los dato. Superar este límite requiere abandonar este baseline en favor de técnicas de reponderación de clases, ajuste de umbrales de decisión o modelos robustos ante clases desbalanceadas.

IV. c. Optimización del Modelo Supervisado

Clustering y Perfiles de Riesgo Intrahospitalario

- Mediante PCA (95% de varianza, 16 componentes) y clustering jerárquico aglomerativo (HAC, *linkage ward*), se aislaron grupos basados estrictamente en datos de hospitalización. La evaluación métrica (Silhouette de **0,23** y curva AIC mediante GMM) justificó una partición óptima de **k=2**.



IV. c. Optimización del Modelo Supervisado

Clustering y Perfiles de Riesgo Intrahospitalario

- **Estructura de perfiles clínicos:**
 - **Perfil 0 (Menor severidad, n=2.817):** Prematurez moderada (29,8 semanas), mayor peso al nacer (1.200 g), bajo soporte respiratorio (2,8 días de ventilación) y estadía corta (58,5 días).
 - **Perfil 1 (Mayor severidad, n=510):** Prematurez extrema (27,3 semanas), bajo peso (939 g), dependencia respiratoria severa (21,7 días de ventilación, 78,6 días de oxígeno) y hospitalización prolongada (110,1 días).
- El clustering captura una señal clínica altamente significativa. El Perfil 1 (mayor severidad) presenta una tasa de malnutrición a los 6 meses del **41,6%**, casi duplicando el riesgo del Perfil 0 (**23,6%**). Las variables al alta hospitalaria anticipan de forma efectiva el deterioro nutricional a mediano plazo.

IV. c. Optimización del Modelo Supervisado

Conclusiones

La reestructuración del modelo supervisado demostró que es viable predecir eventos adversos raros al ajustar las funciones de pérdida. El cambio de paradigma algorítmico, transitando desde la maximización de la asertividad global hacia la minimización estricta del error tipo II (falsos negativos), resulta un requerimiento intransable para el despliegue de soluciones de machine learning en entornos clínicos reales.

V. Resultados generales y conclusión

El análisis aplicado validó el cumplimiento de los objetivos:

- **Identificar variables asociadas a malnutrición en la red:** Logrado mediante las tareas asociativas y causales. Se demostró estadísticamente que factores como la ventilación mecánica, fenton, índice vulnerabilidad, tienen un efecto directo sobre el déficit nutricional.
- **Categorizar perfiles de los niños en seguimiento:** Cumplido mediante la Red Bayesiana.
- **Controles durante el seguimiento:** Alcanzado a través de la reestructuración de herramientas supervisada. Se superó la falla técnica del modelo KNN original empleando Random Forest y regresiones penalizadas con pesos de clase asimétricos y umbrales algorítmicos (< 0.5). Esto garantizó la detección del paciente en riesgo a los 6 meses, priorizando la sensibilidad clínica.



Want to make a presentation like this one?

Start with a fully customizable template, create a beautiful deck in minutes, then easily share it with anyone.

Create a presentation (It's free)