

Econometría I*

Notas, apuntes y ejercicios de preparación

Vicente Breguel Gallaher
vabreguel@uc.cl

Pontificia Universidad Católica de Chile

Introducción

Durante los dos cursos de estadística que ya hemos tenido a lo largo de la carrera hemos podido conocer muchos fundamentos de la estadística; las distribuciones, sus parámetros y los comportamientos que tienen dependiendo del contexto en el cuál se sitúen.

- Por un lado, en **probabilidad y estadística** -por ejemplo- hicimos importantes distinciones sobre la naturaleza de las variables aleatorias (continuas y discretas), las funciones de probabilidad (o densidad) asociadas a estas mismas y los parámetros que la acompañan. Posteriormente, introdujimos el concepto de distribuciones, las cuales nos muestran el comportamiento de determinadas variables aleatorias según el modelamiento lo permite, conociendo algunas importantes como la distribución *Poisson*, de parámetro λ y discreta, o también la distribución *Normal* (con parámetros μ y σ^2) y su versión *estandarizada* (con parámetros $\mu = 0$ y $\sigma^2 = 1$). **Todo esto en un contexto de parámetros conocidos.**
- Por otro, en **inferencia estadística**, introdujimos el concepto de **parámetros desconocidos** y, por lo tanto, necesarios de estimar. En ese sentido, introdujimos formas «naturales» de estimar los parámetros que acompañan a todas las distribuciones (por ejemplo, $\hat{\mu} = \bar{Y}$ y $\hat{\sigma}^2 = S^2$) y, también, algunas alternativas, como lo son la estimación por momentos (*EMM*) o la estimación máximo verosímil (*EMV*). Luego, además, conocimos distintos metodos para realizar inferencia sobre los parámetros (**inferencia paramétrica**) de la distribución, como lo fueron los intervalos de confianza, test de hipótesis, valor p , entre otros., como también metodos para realizar inferencia sobre los datos de una muestra (**inferencia no paramétrica**), como lo fueron los test de bondad de ajuste y/o test de independencia (o homogeneidad).

En el contexto de la econometría, la intención es la de poder predecir un valor o el comportamiento de una cierta variable Y (**variable dependiente**) en función de otras variables X que lo «explican» (**variables independientes o explicativas**) y ciertos parámetros β (**regresores**) que «ponderan» esta explicación. De ese modo, durante todo el curso estudiaremos distintas maneras de predecir y estimar en función de los contextos particulares en los cuales vivamos. *Profundizaremos en esto durante todo este apunte.*

*Apuntes hechos rescatando la información de los ppt's del curso Econometría I con el profesor Tomás Rau Binder. Cualquier error en la explicación o en alguna teoría es de mi completa responsabilidad. Los ejercicios, sacados algunos de evaluaciones del profesor Rau, se complementan con algunas ayudantías y evaluaciones de otros profesores de la FACEA UC.

Índice

1. Modelo de regresión lineal simple.	4
1.1. Mínimos cuadrados ordinarios (MCO)	5
1.2. Supuestos detrás de MCO	8
2. Modelo de regresión lineal múltiple.	10
2.1. Estimación a través de MCO	11
2.2. Propiedades del estimador MCO.	13
2.2.1. Esperanza del estimador.	14
2.2.2. Varianza del estimador.	14
2.2.3. Estimador MELI (o BLUE) y Gauss-Markov	15
2.3. Bondad de ajuste	16
2.3.1. Características del coeficiente de determinación.	17
2.4. Estimación en programación	19
3. Inferencia sobre los parámetros.	19
3.1. Test de hipótesis	20
3.2. Estadísticos de prueba.	22
3.2.1. Variantes del Test Conjunto F (caso 5 y caso 6)	23
4. Predicción	23
4.1. Esperanza y Varianza del error de predicción	24
4.2. Test de normalidad de los errores	24
4.3. Distribución del error de predicción	25
5. Estimación Máximo Verosímil	26
5.1. Estimación en el Modelo Lineal Clásico	26
5.2. Propiedades de la estimación por máximo verosímil	27
5.3. Matriz de Información	28
6. Tests en la estimación MV	29
6.1. Test de Wald (W)	29
6.2. Test de Razón de Verosimilitud (LR)	29
6.3. Test de Multiplicador de Lagrange (LM)	30
6.3.1. Test LM más simple...	30
6.4. Consideraciones en torno a los Test's	31
7. Forma funcional y especificación	31
7.1. Regresores estocásticos	31
7.2. No Linealidades	33
7.2.1. Modelo Logarítmico	33
7.2.2. Modelo Semi-Logarítmico	33
7.2.3. Modelo Cuadrático	33
7.2.4. Test de Ramsey para no linealidades	33
7.3. Variables Dummies o cualitativas	34

7.4. Selección de Modelos	35
7.4.1. Criterio de Akaike (AIC)	35
7.4.2. Criterio de información Bayesiano o Schwarz (BIC)	35
7.5. Omisión de variable relevante e inclusión de variables irrelevantes.	35
7.5.1. Omisión de Variables Relevantes.	36
7.5.2. Inclusión de Variables Irrelevantes.	37
7.6. Errores de medida	38
8. Multicolinealidad	38
8.1. Formas de «detectar» la multicolinealidad	39
9. Variables Instrumentales	39
9.1. Sobreidentificación: Two Stage Least Squares (2SLS ó MC2E)	40
9.2. Test de Endogeneidad - Caso exactamente identificado (Hausman)	41
9.2.1. Generalización a más de 1 variable endógena	41
9.3. Test de Exogeneidad (Sargan)	42
10. Heterocedasticidad	42
10.1. Tests de Heterocedasticidad	43
11. Autocorrelación de errores	45
11.1. Efectos de AR(1)	46
11.2. Causas de la autocorrelación	47
11.3. Test de autocorrelación	47
11.4. Solución a la autocorrelación	48
12. Ejercicios: Prueba 1	50
13. Ejercicios: Prueba 2	52
13.1. Predicción	52
13.2. Hipótesis múltiple	52
13.3. Aplicaciones cortas	53
13.4. Sobre estimación, hipótesis múltiple e intervalos de predicción.	53
13.5. Trabajando con variables <i>dummy</i>	54
13.6. Comentarios	54
14. Ejercicios: Examen	55
14.1. Comentarios	55
14.2. Ejercicio 1	55
14.3. Ejercicio 2	56
14.4. Ejercicio 3	57

1. Modelo de regresión lineal **simple**.

El primer modelo que introducimos en el curso de Econometría I es aquel que estudia la dependencia entre una variable dependiente Y y una (o más) variables explicativas X , ponderadas por coeficientes de regresión β_0 y β_1 (el objetivo es estimarlos). En ese sentido, el modelamiento de una regresión lineal simple es como se muestra a continuación:

$$Y_i = \beta_0 + \beta_1 X_i + u_i$$

donde X es determinística/no estocástica/no aleatoria y u_i es un término de error, que resume todos los otros factores que pueden afectar a Y_i . A diferencia de las variables explicativas, el término de error es aleatorio y, por tanto, tendrá distribución (lo veremos más adelante).

Es importante destacar que cuando estemos intentando hacer predicción, lo estaremos haciendo en términos **esperados**, ya que estaremos condicionando el valor que tomará Y sujeto a distintos valores que puede tomar la variable explicativa X . De ese modo, la esperanza condicional de los valores de la dependiente se puede reescribir del siguiente modo:

$$\mathbb{E}(Y|X = x) = \beta_0 + \beta_1 X_1$$

$$\mathbb{E}(Y_i|X = X_i) = \beta_0 + \beta_1 X_i = f(X_i)$$

donde la $\mathbb{E}$ de X es el mismo número ya que la estoy condicionando a un valor específico, y β_0 y β_1 son el mismo número ya que son constantes. Además, es importante notar que asumimos $\mathbb{E}(u_i|X_i) = 0$, es decir, que -en promedio- los errores muestrales (condicionados en valores de X_i) son 0. Este es un supuesto que mantendremos vivo a lo largo de gran parte del curso, y profundizaremos sobre él más adelante. Finalmente, la expresión mostrada ($\mathbb{E}(Y|X = x) = \beta_0 + \beta_1 X_i$) la denominaremos como **recta (función) de regresión poblacional**, y no será más que simplemente el lugar geométrico de las medias condicionales de la variable dependiente para valores fijos de la(s) variable(s) explicativa(s).

No es difícil entonces notar que la diferencia entre la observación (Y_i) y la recta de regresión poblacional (RRP) es el error (u_i), que puede ser positivo (+) ó negativo (-), y que explica lo que las X_i no pudieron hacer o capturar. Luego, toda la aleatoriedad de Y_i viene dada por el factor u_i , que es una variable aleatoria y que, por tanto, NO es observable.

Por otro lado, la **función de regresión muestral (FRM)** es aquella que me permite **estimar** el valor de mi dependiente sujeto a los estimadores muestrales de los parámetros que debemos estimar β_0 y β_1 , por lo que la podremos representar del siguiente modo:

$$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$$

donde $\hat{Y}_i$ es el estimador de $\mathbb{E}(Y_i|X_i)$ y los otros los estimadores que se pudieron extraer de la muestra obtenida. Luego, una representación estocástica que se le puede dar a la ecuación muestral es la siguiente:

$$Y_i = \hat{\beta}_0 + \hat{\beta}_1 X_i + \hat{u}_i$$

por lo que el objetivo del **análisis de regresión** es estimar la función de regresión poblacional $\mathbb{E}(Y_i|X_i) = \beta_0 + \beta_1 X_i$ con base en la función de regresión muestral $\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$.

Cuáles son las propiedades de los estimadores que nos permitirán evaluar nuestra estimación?

1. **Sesgo:** Definido como la diferencia entre el valor esperado del estimador y su verdadero valor:

$$\text{Sesgo} = \mathbb{E}(\hat{\beta}) - \beta$$

y cuando el estimador sea insesgado, se cumplirá que el Sesgo=0, es decir $\mathbb{E}(\hat{\beta}) = \beta$.

2. **Eficiencia o Mínima Varianza:** Un estimador es **EIMV** si es que no hay otro estimador insesgado que tenga una varianza menor a $\widehat{\beta}$. En general, se tratará de utilizar estimadores con varianza pequeña, pues de este modo la estimación es más precisa. Recordar que cuando hacemos inferencia sobre un parámetro de una distribución, lo hacemos con un estadístico t definido como:

$$\frac{\widehat{\beta} - \beta}{\sqrt{\text{Var}(\widehat{\beta})}} \sim t_{n-k}$$

por lo que mayores varianzas (errores estándar) generan que sea más difícil rechazar hipótesis nulas, ya que el estadístico se hace más pequeño cuando calculo el t_{obs} y, por tanto, es más difícil cumplir las reglas de rechazo.

3. **Consistencia:** Un estimador será consistente si converge en probabilidad (en el límite) al verdadero valor del parámetro ($\widehat{\beta} \xrightarrow{p} \beta$), esto es:

$$\forall \varepsilon > 0 : \lim_{n \rightarrow \infty} P \left[|\widehat{\beta} - \beta| < \varepsilon \right] \approx 1$$

lo que se denota como

$$\text{plim} \widehat{\beta} = \beta$$

y que, de forma más intuitiva, lo que nos quiere decir es que para todo número muy pequeño ($\varepsilon > 0$) la probabilidad, cuando el tamaño muestra sea muy grande ($n \rightarrow \infty$), de que la diferencia entre el valor del estimador y el parámetro verdadero sea -en valor absoluto- muy (muy) pequeña ($< \varepsilon$) es cercana a 1. **Esto es una generalización del concepto «asintóticamente insesgado».**

4. **Error cuadrático medio (ECM):** Es una característica de los estimadores que mezcla conceptos de eficiencia e insesgamiento, y que se define como:

$$\begin{aligned} ECM(\widehat{\beta}) &= \mathbb{E} \left[(\widehat{\beta} - \beta)^2 \right] \\ &= \mathbb{V}(\widehat{\beta}) + \text{sesgo}^2 \end{aligned}$$

lo que por supuesto nos muestra que uno quisiera estar en presencia de estimadores que tengan el menor error cuadrático medio. Sin embargo, también nos dice que uno si puede estar dispuesto a sacrificar un poco de sesgo en caso de que eso involucre disminuir un poco la varianza, ya que entre un estimador insesgado y otro sesgado en donde se cumpla que $ECM_{sesgado} < ECM_{insesgado}$ puede que no siempre escoga al que cumple con $\text{sesgo} = 0$, por lo que esta propiedad será clave en la elección entre uno u otro estimador de los parámetros.

1.1. Mínimos cuadrados ordinarios (MCO)

Nuestro interés entonces es estimar la función de regresión poblacional (**FRP**) $E(Y|X) = \beta_0 + \beta_1 X$ y sabemos que el estimador de ella es la función de regresión muestral (**FRM**) para una muestra $i = 1, 2, 3, \dots, n$: $\widehat{Y} = \widehat{\beta}_0 + \widehat{\beta}_1 X_i$, que en términos de la **FRM**, la Y_i puede expresarse como:

$$Y_i = \widehat{Y}_i + \widehat{u}_i$$

lo que permite reescribir el **error muestral** del siguiente modo:

$$\begin{aligned} \widehat{u}_i &= Y_i - \widehat{Y}_i \\ &= Y_i - \widehat{\beta}_0 - \widehat{\beta}_1 X_i \end{aligned}$$

concluyendo que los residuos muestrales son la mera diferencia entre los valores veraderos y estimados de Y para distintas observaciones i . Luego, el método de mínimos cuadrados ordinarios (**MCO**) escoge $\widehat{\beta}_0$ y $\widehat{\beta}_1$ de

forma tal que para una muestra dada **la suma de los errores $\hat{u}_i$ al cuadrado $\hat{u}_i^2$ (para netear el efecto de diferencias + ó -) sea lo más pequeña posible**. Finalmente, sea Q :

$$Q = \sum_{i=1}^n \hat{u}_i^2 = \left(Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i \right)^2$$

la forma de minizar esa expresión será obteniendo **CPO's** para cada uno de los parámetros:

1. Con respecto a $\hat{\beta}_0$:

$$\frac{\delta Q}{\delta \hat{\beta}_0} = 0 \rightarrow \sum_{i=1}^n 2 \left(Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i \right) (-1) = 0 \rightarrow \sum_{i=1}^n \left(Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i \right) = 0$$

Luego, desarrollando la expresión:

$$\sum_{i=1}^n Y_i - n\hat{\beta}_0 - \hat{\beta}_1 \sum_{i=1}^n X_i = 0$$

y despejando $\hat{\beta}_0$ obtenemos su estimación según **MCO**:

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X} \longleftrightarrow E(Y) - \beta_1 E(X)$$

2. Con respecto a $\hat{\beta}_1$:

$$\frac{\delta Q}{\delta \hat{\beta}_1} = 0 \rightarrow \sum_{i=1}^n 2 \left(Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i \right) (-X_i) = 0 \rightarrow \sum_{i=1}^n \left(Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i \right) (X_i) = 0$$

Luego, desarrollando la expresión:

$$\sum_{i=1}^n Y_i X_i - \hat{\beta}_0 \sum_{i=1}^n X_i - \hat{\beta}_1 \sum_{i=1}^n X_i^2 = 0$$

reemplazando $\hat{\beta}_0$ en la expresión anterior:

$$\sum_{i=1}^n Y_i X_i - \left(\frac{\sum_{i=1}^n Y_i}{n} - \hat{\beta}_1 \frac{\sum_{i=1}^n X_i}{n} \right) \sum_{i=1}^n X_i - \hat{\beta}_1 \sum_{i=1}^n X_i^2 = 0$$

lo que me permite (reagrupando términos semejantes y desarrollando la expresión) obtener la estimación mediante **MCO** del parámetro β_1 (el que acompaña a la variable explicativa en el modelo de regresión lineal simple):

$$\hat{\beta}_1 = \frac{n \sum Y_i X_i - \sum Y_i \sum X_i}{n \sum X_i^2 - (\sum X_i)^2} \longleftrightarrow \frac{Cov(X, Y)}{V(X)}$$

Sin embargo, el estimador del regresor que acompaña a las variables explicativas $\hat{\beta}_1$ puede ser reescrito según un **modelo con desvíos respecto a la media**, quedando su expresión reducida a la que se detalla a continuación:

$$\hat{\beta}_1 = \frac{\sum x_i y_i}{\sum x_i^2}$$

en donde $x_i = X_i - \bar{X}$ e $y_i = Y_i - \bar{Y}$, siendo equivalente a la derivada del problema de minimización de la suma de los errores muestrales al cuadrado.

Por último, es importante rescatar que de las **CPO's** anteriores obtuvimos 2 condiciones que son muy relevantes para la teoría para la teoría y poca visibilización clara tuvieron en nuestra derivación. Estas son:

- a) La suma (y el promedio) de los errores muestrales estimados en una muestra $i = 1, 2, 3, \dots, n$ es 0. Esto es,

$$\sum_{i=1}^n \hat{u}_i = 0 \xrightarrow{\text{Lo que implica}} \frac{\sum_{i=1}^n \hat{u}_i}{n} = \bar{\hat{u}} = 0$$

- b) Las variables explicativas y los residuos son ortogonales, lo que quiere decir que **no comparten información** (el error $\hat{u}_i$ no puede capturar una información que ya esté siendo capturada por la variable explicativa X_i , ya que si es que lo hiciera, estaríamos **sobreexagerando** la estimación de Y_i). Lo anterior, se corrobora según:

$$\sum_{i=1}^n \hat{u}_i X_i = 0$$

- c) Por último, no es difícil comprobar que ambos estimados extraídos del proceso por **MCO** son insesgados. Veamos el caso a caso:
- $\hat{\beta}_1$: Para ver el insesgamiento del parámetro que acompaña a la explicativa, primero operemos la **FRP** con desvíos respecto a la media. Sabemos que:

$$Y_i = \beta_0 + \beta_1 X_i + u_i \text{ (poblacional)}$$

ahora, sumamos $\sum_{i=1}^n$ y multiplicamos por $\frac{1}{n}$:

$$\bar{Y} = \beta_0 + \beta_1 \bar{X} + \bar{u}$$

de modo que restando ambas, obtenemos:

$$(Y_i - \bar{Y}) = \beta_1 (X_i - \bar{X}) + (u_i - \bar{u})$$

$$y_i = \beta_1 x_i + \tilde{u}$$

Ahora, si escribimos con desvíos con respecto a la media, obtendríamos:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n y_i x_i}{\sum_{i=1}^n x_i^2} = \frac{\sum_{i=1}^n (\beta_1 x_i + \tilde{u}_i) x_i}{\sum_{i=1}^n x_i^2} = \beta_1 \frac{\sum_{i=1}^n x_i^2}{\sum_{i=1}^n x_i^2} + \frac{\sum_{i=1}^n \tilde{u}_i x_i}{\sum_{i=1}^n x_i^2}$$

Por último, aplicando Esperanza:

$$\mathbb{E}(\hat{\beta}_1) = \beta_1 + \frac{x_i}{\sum_{i=1}^n x_i^2} \mathbb{E} \left(\sum_{i=1}^n \tilde{u}_i \right) \rightarrow \mathbb{E}(\hat{\beta}_1) = \beta_1 + \frac{x_i}{\sum_{i=1}^n x_i^2} \mathbb{E} \left(\sum_{i=1}^n (u_i - \bar{u}) \right)$$

$$\mathbb{E}(\hat{\beta}_1) = \beta_1 + \frac{x_i}{\sum_{i=1}^n x_i^2} \sum_{i=1}^n \left\{ \cancel{\mathbb{E}(u_i)} - \frac{\sum_{i=1}^n \cancel{\mathbb{E}(u_i)}}{n} \right\}$$

$$\mathbb{E}(\hat{\beta}_1) = \beta_1 \rightarrow \text{Inssegado}$$

- $\hat{\beta}_0$: Para ver el insesgamiento del parámetro intercepto de la regresión lineal, su operación es más sencilla que la anterior. Dado que el estimador se escribe como sigue:

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X} \longleftrightarrow \frac{1}{n} \sum (\beta_0 + \beta_1 X_i + u_i) - \beta_1 \bar{X}$$

$$\hat{\beta}_0 = \beta_0 + \beta_1 \bar{X} + \bar{u} - \beta_1 \bar{X}$$

Luego, aplicando Esperanza:

$$\mathbb{E}(\hat{\beta}_0) = \beta_0 + \cancel{\mathbb{E}(\bar{u} = 0)} \rightarrow \text{Inssegado}$$

3. Por último, es importante entender la **interpretación de los parámetros**, con el objetivo de clarificar el por qué de su utilización. El parámetro β_1 representa el **cambio esperado** del valor de Y cuando X aumenta en una unidad, es decir, es la **pendiente** del modelo de regresión. Por otro lado, el parámetro β_0 representa el valor medio de Y cuando $X = 0$, es decir, $E(Y|X = 0)$. También, es conocido como el **intercepto** del modelo de regresión.
4. Por último, se puede demostrar que bajo el cumplimiento de ciertos criterios (ver **1.2**) las varianzas de los parámetros de la regresión son:

$$V(\hat{\beta}_1|X) = \frac{\sigma^2}{s_x^2}$$

$$V(\hat{\beta}_0|X) = \frac{(\sigma^2) \cdot \sum_{i=1}^n x_i^2}{ns_x^2}$$

con $s_x^2 = \sum_{i=1}^n (x_i - \bar{x})^2$. De ese modo, tenemos forma de medición de la dispersión de los estimadores con respecto a sus valores poblacionales.

1.2. Supuestos detrás de MCO

Para entender el desarrollo del curso, debemos entender que para que se cumpla la forma de estimación mediante mínimos cuadrados ordinarios (**MCO**) se deben cumplir ciertos supuestos que poco a poco iremos relajando a lo largo del curso. Estos son nueve (**9**) los cuales se detallan a continuación:

1. **Modelo de regresión es lineal en los parámetros:** Para que se cumpla la estimación mediante MCO se debe corroborar que la especificación del modelo de regresión es lineal en sus parámetros: $Y_i = \beta_0 + \beta_1 X_i + u_i$ ó $Y_i = \beta_0 + \beta_1 X_i^2 + u_i$, por ejemplo. No se cumplirá el supuesto N°1, por ejemplo, cuando tengamos modelos del tipo $Y_i = AL^\alpha K^\beta e^{u_i}$, ya que en este caso particular vemos que Y_i no depende linealmente de sus parámetros. Luego, para este tipo de casos, deberemos aplicar un concepto denominado *log-linealización*, el cual consiste básicamente en aplicar $\ln$ a ambos lados de la ecuación, de manera de lograr una dependencia lineal en parámetros: $\ln(Y_i) = \ln(A) + \alpha \ln(L) + \beta \ln(K) + u_i$.
2. **Valores de X fijos (no estocásticos):** Lo anterior genera (y permite) que el análisis de regresión sea un análisis condicional a los valores dados de la variable independiente X para cada observación i .
3. **El valor medio del error u_i condicional en X_i es igual a 0:** Lo anterior nos dice que dado un valor específico de X , el valor esperado del término de error es 0.

$$E(u_i|X_i) = E(u_i) = 0$$

4. **Homocedasticidad (o igual varianza) de u_i :** Dado el valor de X_i , la varianza de u_i es la misma para todas las observaciones de mi muestra (cuando hay dispersiones desiguales entre observaciones se conoce como **Heterocedasticidad**). Es decir,

a) **Homocedasticidad:**

$$\begin{aligned} \mathbb{V}(u_i|X_i) &= \mathbb{E}[(u_i - \mathbb{E}(u_i|X_i))^2|X_i] \\ &= \mathbb{E}[u_i^2|X_i] \\ &= \mathbb{E}[u_i^2] = \sigma^2 \end{aligned}$$

es decir, para cualquier " i ", todas las $\mathbb{V}(u_i|X_i)$ van a ser iguales.

b) **Heterocedasticidad:**

$$\mathbb{V}(u_i|X_i) = \sigma_i^2 \text{ es decir, dependientes de cada observación.}$$

5. **No existe autocorrelación entre los errores:** Dado los valores de las observaciones de X , imaginemos dos distintas: X_i y X_j con $i \neq j$. En ese sentido, este supuesto establece que la correlación entre los errores de la observación con X_i y los de la observación con X_j es cero (**0**). Lo anterior se ve expresado en lo siguiente:

$$\begin{aligned}\text{Cov}(u_i, u_j | X_i, X_j) &= \mathbb{E} \{ [u_i - \mathbb{E}(u_i | X_i)] [u_j - \mathbb{E}(u_j | X_j)] | X_i, X_j \} \\ &= \mathbb{E} [u_i u_j | X_i X_j] = 0\end{aligned}$$

es decir, no existe covarianza cuando los errores son distintos (por distintas observaciones). Si es que así no fuese, Y no sólo dependería de cada X , si no que de sus errores u también.

6. **La covarianza entre los errores y las observaciones es 0, es decir,** $\mathbb{E}(u_i X_i) = 0$: Lo anterior nos dice que X y u no están correlacionados, ya que si lo estuvieran no sería posible determinar efectos individuales sobre Y . Este supuesto se cumple automáticamente si es que X es no estocástica (**supuesto(2)**) y la esperanza de los errores es 0 (**supuesto(3)**).

$$\begin{aligned}\text{Cov}(u_i, X_i) &= \mathbb{E} \{ [u_i - \mathbb{E}(u_i)] [X_i - \mathbb{E}(X_i)] \} \\ &= \mathbb{E}(u_i) * [X_i - \mathbb{E}(X_i)] \\ &= \mathbb{E}(u_i X_i) - \underbrace{\mathbb{E}(u_i) \mathbb{E}(X_i)}_{\text{Sup. (3)}} \\ &= \mathbb{E}(u_i X_i) \xrightarrow{\text{Sup. (2)}} X_i * \mathbb{E}(u_i) = 0\end{aligned}$$

7. **El número de observaciones n debe ser mayor que el número de parámetros por estimar:** En el caso del modelo de regresión lineal simple, el número de parámetros a estimar son sólo 2 β_0 y β_1 , por lo que habría que tener un $n > 2$. Imaginemos solo tenemos 1 sola observación:

$$Y_1 = \beta_0 + \beta_1 X_1 + u_1$$

sabemos, por desvíos con respecto a la media, que el parámetro β_1 puede ser estimado a través de **MCO** según la siguiente expresión:

$$\widehat{\beta}_1 = \frac{\sum_{i=1}^n x_i y_i}{\sum_{i=1}^n x_i^2}$$

pero como tenemos una sola muestra, en este caso ocurriría que $X_i = \bar{X}$, y como sabemos que cuando usamos desvíos definimos $x_i = X_i - \bar{X}$ e $y_i = Y_i - \bar{Y}$, en este caso se nos indefinen nuestro estimador (de β_1 y β_0) y, por tanto, no podemos tener **MCO**.

8. **Variabilidad en los valores de X .** El argumento de este supuesto es parecido al anterior: No todos los valores de X en una muestra deben ser iguales, ya que la varianza de X debe ser un número positivo (y finito). En caso contrario, si las X_i son iguales para cada muestra i , ocurre que $X_i = \bar{X}$ y nuevamente se nos indefinen nuestras estimaciones.
9. **El modelo de regresión está correctamente especificado.** Este último supuesto es muy (muy) importante, ya que la omisión (inclusión) de variables importantes (irrelevantes) pueden cuestionar la validez de la regresión estimada. En definitiva, este supuesto busca establecer un mínimo para que mi modelo de regresión sea “bueno”.

- **(Extra) Normalidad de los errores.** Para hacer que las distribuciones muestrales de los estimadores sean manejables, asumiremos que el error no observable se distribuye de manera Normal en la población, es decir, $u_i \sim N(0, \sigma^2)$. Luego, la normalidad se traduce en distribuciones normales de los estimadores:

$$\widehat{\beta}_i | X \sim N(\beta_i, \text{Var}(\widehat{\beta}_i))$$

de modo que los test de hipótesis serán tal como lo hacíamos en inferencia estadística:

$$H_0 : \beta_1 = \beta_{1,0} \text{ vs } H_1 : \beta_1 \neq \beta_{1,0}$$

y el estadístico queda cómo se muestra a continuación:

$$t = \frac{\hat{\beta}_1 - \beta_{1,0}}{\sqrt{\text{var}(\hat{\beta}_1)}} \sim t_{n-k}$$

Ahora, antes de cualquier cosa, debemos notar que hemos impuesto que los errores tienen una varianza igual a σ^2 (notar que consideramos homocedasticidad, por lo que la varianza del error muestral es la misma para cada una de las observaciones). Sin embargo, **esa varianza no necesariamente la conoceremos, por lo que en un contexto de MCO deberemos estimarla**. Se puede mostrar fácilmente que el estimador de la varianza general será:

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^n \hat{u}_i^2}{n-k}$$

con k el número de variables de mi modelo que están siendo estimadas. Lo anterior nos señala directamente entonces que, en el caso de la regresión lineal simple (**2 variables**) en donde estimamos a β_0 y β_1 , el estimador de la varianza será ajustado por un $k = 2$.

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^n \hat{u}_i^2}{n-2}$$

2. Modelo de regresión lineal múltiple.

Por su parte, el modelo de regresión lineal múltiple (ya no son sólo 2 variables, sino que k) es la **representación matricial del simple**, y considera que, en la representación usual del modelo, nosotros podemos incluir múltiples variables en el lado derecho de la ecuación:

$$Y_i = \beta_1 + \beta_2 X_{2i} + \dots + \beta_k X_{ki} + u$$

donde cada i representa el número de la observación en una muestra de tamaño n , es decir, $i = 1, \dots, n$. En ese sentido, el modelo con k variables puede expresarse con notaciones matriciales, considerando que cada variable explicativa X_j con $j = 1, \dots, k$ (para notar las k variables) es un vector **columna** $[n \times 1]$ con elementos provenientes de cada una de las observaciones, al igual que la variable dependiente Y_i y el término de error:

$$\underbrace{\begin{bmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{bmatrix}}_{\mathbf{Y}} = \underbrace{\begin{bmatrix} 1(X_{11}) \\ 1(X_{12}) \\ \vdots \\ 1(X_{1n}) \end{bmatrix}}_{\mathbf{X}_1} \beta_1 + \underbrace{\begin{bmatrix} X_{21} \\ X_{22} \\ \vdots \\ X_{2n} \end{bmatrix}}_{\mathbf{X}_2} \beta_2 + \dots + \underbrace{\begin{bmatrix} X_{k1} \\ X_{k2} \\ \vdots \\ X_{kn} \end{bmatrix}}_{\mathbf{X}_k} \beta_k + \underbrace{\begin{bmatrix} u_1 \\ u_2 \\ \vdots \\ u_n \end{bmatrix}}_{\mathbf{u}}$$

con k parámetros a estimar y, por tanto, k vectores con X' s.

$$\beta_{\text{vector}} = \begin{bmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_k \end{bmatrix}_{k \times 1} ; X_{\text{matriz}} = \begin{bmatrix} 1 & X_{21} & \dots & X_{k1} \\ 1 & X_{22} & & X_{k2} \\ & \vdots & & \vdots \\ 1 & X_{2n} & \dots & X_{kn} \end{bmatrix}_{n \times k}$$

de modo que el lado derecho del modelo de regresión lineal múltiple se puede representar como un producto entre la matriz $\mathbf{X}$ y el vector β , resultando de ese modo un vector de $n \times 1$.

$$\underbrace{\mathbf{X}}_{(n \times k)} \cdot \underbrace{\beta}_{(k \times 1)} = \begin{bmatrix} \beta_1 + \beta_2 X_{21} + \dots + \beta_k X_{k1} \\ \beta_1 + \beta_2 X_{22} + \dots + \beta_k X_{k2} \\ \vdots \\ \beta_1 + \beta_2 X_{2n} + \dots + \beta_k X_{kn} \end{bmatrix}_{n \times 1}$$

siendo posible, por último, que la representación matricial del modelo se logre del siguiente modo:

$$\mathbf{Y} = \mathbf{X}\beta + \mathbf{u}$$

en donde, al igual que para el caso simple, cada β_j con $j = 1, \dots, k$ representa el cambio en Y debido a un cambio en la explicativa que acompaña X_j , en un contexto de *ceteris paribus* (todo lo demás constante).

Una cosa importante sobre la matriz $\mathbf{X}$ es que existe colinealidad imperfecta, lo que quiere decir que ninguna variable independiente es combinación lineal **exacta** de otras. Eso, permite que las independientes correlacionen entre sí, sólo que no pueden hacerlo en forma perfecta. Luego, $\mathbf{X}$ es de “rango completo”.

Nota: Si bien no representa mayor dificultad, algo que debemos notar es que en el modelo explicitado en este apunte los parámetros a estimarse β comienzan desde el 1 hasta el k ($\beta_1, \dots, \beta_k$), siendo **efectivamente** k parámetros a estimarse. **Sin embargo**, hay algunos que especifican el modelo desde el 0 hasta el k ($\beta_0, \dots, \beta_k$), por lo que efectivamente hay $(k + 1)$ parámetros a estimarse. En ese sentido, debemos hacer el ajuste a nuestras estimaciones de parámetros que dependen del número de β que estemos estimando, por ejemplo:

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^n \hat{u}_i^2}{n - k} \xrightarrow{\text{se transforma}} \hat{\sigma}^2 = \frac{\sum_{i=1}^n \hat{u}_i^2}{n - (k + 1)} \leftrightarrow \hat{\sigma}^2 = \frac{\sum_{i=1}^n \hat{u}_i^2}{n - k - 1}$$

y las matriz $\mathbf{X}$, por ejemplo, ya no es de $(n \times k)$, sino que de $(n \times (k + 1))$.

2.1. Estimación a través de MCO

Veremos a continuación como estimar los parámetros en el modelo caracterizado matricialmente, como también el cómo se comportan los supuestos de **MCO** detallados en el modelo de regresión lineal **simple** ahora en el caso múltiple.

(1) Sobre los errores:

Esperanza.

Se sigue cumpliendo el supuesto de que el valor esperado de los errores es 0, esto es, $\mathbb{E}(u_i) = 0$, sin embargo, ahora aplicamos el operador $\mathbb{E}$ al vector $\mathbf{u}$ detallado más arriba y según la propiedad de que la esperanza de un vector no es más que la esperanza de cada uno de sus componentes:

$$\mathbb{E}(u) = \begin{bmatrix} \mathbb{E}(u_1) \\ \mathbb{E}(u_2) \\ \vdots \\ \mathbb{E}(u_n) \end{bmatrix} = \mathbf{0}$$

donde $\mathbf{0}$ no es un escalar, sino que un vector de $\mathbf{0}'s$ de tamaño $n \times 1$.

Varianza.

La varianza de un vector ν se define como:

$$\mathbb{V}(\nu) = \mathbb{E} \left[(\nu - \mathbb{E}(\nu))(\nu - \mathbb{E}(\nu))' \right]$$

de modo que si lo queremos hacer para nuestro vector de errores, lo hacemos como sigue a continuación:

$$\mathbb{V}(u) = \mathbb{E} \left[(u - \mathbb{E}(u))(u - \mathbb{E}(u))' \right] \xrightarrow{\mathbb{E}(u)=0} \mathbb{E}[u \cdot u']$$

siendo $u \cdot u'$ el producto entre dos vectores de $(n \times 1)$ y de $(1 \times n)$ (por estar transpuesto $\rightarrow$ cambiar filas por columnas), respectivamente, lo que es **conformable** y resulta una matriz de $n \times n$.

$$\mathbb{E}[u \cdot u'] = \mathbb{E} \left[\begin{pmatrix} u_1 \\ u_2 \\ \vdots \\ u_n \end{pmatrix}_{n \times 1} \cdot \begin{pmatrix} u_1 & u_2 & \cdots & u_n \end{pmatrix}_{1 \times n} \right]$$

$$\mathbb{E}[u \cdot u'] = \mathbb{E} \begin{bmatrix} u_1^2 & u_1 u_2 & u_1 u_3 & \cdots & u_1 u_n \\ u_2 u_1 & u_2^2 & \cdots & u_2 u_{n-1} & u_2 u_n \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ u_{n-1} u_1 & \vdots & \cdots & u_{n-1}^2 & \vdots \\ u_n u_1 & \cdots & \cdots & u_n u_{n-1} & u_n^2 \end{bmatrix}$$

como partimos asumiendo que se cumple **homocedasticidad**, sabemos que $\mathbb{E}[u_i^2] = \sigma^2$ y, además, por supuesto **5** sabemos que las covarianzas entre errores son nulas, esto es: $\mathbb{E}[u_i u_j] = 0$. De esa forma, lo que habrá en la diagonal de la matriz anterior (la cual llamaremos **matriz de varianzas y covarianzas**) serán las varianzas y fuera de ella las covarianzas, es decir, solamente 0 's.

$$\mathbb{E}[u \cdot u'] = \mathbb{E} \begin{bmatrix} \sigma^2 & 0 & 0 & \cdots & 0 \\ 0 & \sigma^2 & \cdots & 0 & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & \vdots & \cdots & \sigma^2 & \vdots \\ 0 & \cdots & \cdots & 0 & \sigma^2 \end{bmatrix} = \sigma^2 \cdot \mathbf{I}_{n \times n} = \mathbb{V}(u)$$

con $\mathbf{I}_{n \times n}$ una matriz identidad (sólo 1's en su diagonal y 0's fuera de ella). De ese modo, tendremos que nuestro vector de errores tendrá cierta distribución (que detallaremos más adelante) con los siguientes parámetros definidos:

$$u \sim (\mathbf{0}_{n \times 1}, \sigma^2 \cdot \mathbf{I}_{n \times n})$$

(2) Sobre la estimación:

Recordemos que el método de mínimos cuadrados ordinarios (**MCO**) plantea que los parámetros del modelo pueden ser estimados minimizando la suma de los errores al cuadrado, en términos matriciales lo representaremos del siguiente modo:

$$Q = \sum_{i=1}^n \widehat{u}_i^2 = \widehat{u}' \widehat{u} = (\mathbf{Y} - \mathbf{X}\widehat{\beta})' (\mathbf{Y} - \mathbf{X}\widehat{\beta})$$

donde $\widehat{u} = (\mathbf{Y} - \mathbf{X}\widehat{\beta})$

$$\widehat{u} = \begin{bmatrix} \widehat{u}_1 \\ \widehat{u}_2 \\ \vdots \\ \widehat{u}_n \end{bmatrix}_{n \times 1} \rightarrow \widehat{u}' \widehat{u} = \begin{bmatrix} \widehat{u}_1 & \widehat{u}_2 & \cdots & \widehat{u}_n \end{bmatrix} \cdot \begin{bmatrix} \widehat{u}_1 \\ \widehat{u}_2 \\ \vdots \\ \widehat{u}_n \end{bmatrix} = \widehat{u}_1^2 + \widehat{u}_2^2 + \widehat{u}_3^2 + \cdots + \widehat{u}_n^2 = \sum_{i=1}^n \widehat{u}_i^2$$

Antes de realizar la minimización, recordaremos algunas propiedades que serán muy importantes para este comienzo del curso:

Propiedades matriciales útiles

$(\mathbf{AB})' = \mathbf{B}' \mathbf{A}'$	si $\mathbf{a}$ es escalar $\mathbf{a} = \mathbf{a}'$	si $\mathbf{A}$ es simétrica $\mathbf{A} = \mathbf{A}'$	$(\mathbf{A} + \mathbf{B})'$ $\downarrow$ $\mathbf{A}' + \mathbf{B}'$	$(\mathbf{A} + \mathbf{B})(\mathbf{C} + \mathbf{D})$ $\downarrow$ $(\mathbf{AC} + \mathbf{AD} + \mathbf{BC} + \mathbf{BD})$	$(\mathbf{ABC})'$ $\downarrow$ $(\mathbf{C}' \mathbf{B}' \mathbf{A}')$	$\mathbf{A}'' = \mathbf{A}$
--	--	--	---	---	--	-----------------------------

Luego, la suma la operamos del siguiente modo:

$$\begin{aligned} Q &= (\mathbf{Y} - \mathbf{X}\hat{\beta})' (\mathbf{Y} - \mathbf{X}\hat{\beta}) = (\mathbf{Y}' - (\mathbf{X}\hat{\beta})') (\mathbf{Y} - \mathbf{X}\hat{\beta}) \\ &= (\mathbf{Y}' - \hat{\beta}' \mathbf{X}') (\mathbf{Y} - \mathbf{X}\hat{\beta}) \\ &= \mathbf{Y}' \mathbf{Y} - \mathbf{Y}' \mathbf{X} \hat{\beta} - \hat{\beta}' \mathbf{X}' \mathbf{Y} + \hat{\beta}' \mathbf{X}' \mathbf{X} \hat{\beta} \end{aligned}$$

luego, como sabemos que $\hat{u}' \hat{u}$ es un **escalar**, todos los términos de su desarrollo también deben serlos. Además, podemos notar que $\hat{\beta}' \mathbf{X}' \mathbf{Y}$ es la transpuesta de $\mathbf{Y}' \mathbf{X} \hat{\beta}$, y como ambos son escalares, según las propiedades mostradas anteriormente podemos deducir que son iguales. De ese modo la suma de los errores muestrales al cuadrado se puede reducir a lo siguiente:

$$Q = \mathbf{Y}' \mathbf{Y} - 2\hat{\beta}' \mathbf{X}' \mathbf{Y} + \hat{\beta}' \mathbf{X}' \mathbf{X} \hat{\beta}$$

Ahora, como sabemos que la minimización de la expresión anterior implica derivación, necesitamos antes conocer ciertas propiedades que nos ayudarán a conseguir la expresión de la estimación de β según el proceso de mínimos cuadrados ordinarios.

Propiedades de derivación matricial útiles

$$\frac{\delta \mathbf{A} \mathbf{x}}{\delta \mathbf{x}} = \mathbf{A}' \quad \frac{\delta \mathbf{A} \mathbf{x}}{\delta \mathbf{x}'} = \mathbf{A} \quad \frac{\delta \mathbf{x}' \mathbf{A} \mathbf{x}}{\delta \mathbf{x}} = (\mathbf{A}' + \mathbf{A}) \mathbf{x} = 2\mathbf{A} \mathbf{x} \text{ si } \mathbf{A} \text{ es simétrica.}$$

Finalmente podemos hacer la minimización pertinente según lo que establece el método de mínimos cuadrados ordinarios:

$$\begin{aligned} \min_{\{\beta\}} Q &= \mathbf{Y}' \mathbf{Y} - 2\hat{\beta}' \mathbf{X}' \mathbf{Y} + \hat{\beta}' \mathbf{X}' \mathbf{X} \hat{\beta} \\ \frac{\delta Q}{\delta \hat{\beta}} &= 0 \rightarrow -2\mathbf{X}' \mathbf{Y} + \left((\mathbf{X}' \mathbf{X}) + (\mathbf{X}' \mathbf{X}) \right) \hat{\beta} = 0 \end{aligned}$$

asumiendo $\mathbf{X}' \mathbf{X}$ simétrica:

$$-2\mathbf{X}' \mathbf{Y} + 2(\mathbf{X}' \mathbf{X}) \hat{\beta} = 0 \leftrightarrow \mathbf{X}' \mathbf{X} \hat{\beta} = \mathbf{X}' \mathbf{Y}$$

y asumiendo que $(\mathbf{X}' \mathbf{X})$ tiene inversa (ya que es cuadrada y con $\det \neq 0$), podemos multiplicar por $(\mathbf{X}' \mathbf{X})^{-1}$ de **izquierda a derecha**:

$$\hat{\beta} = (\mathbf{X}' \mathbf{X})^{-1} \mathbf{X}' \mathbf{Y}$$

Y para que esta solución sea efectivamente un mínimo, es necesario que se cumpla que:

$$\left(\frac{\delta Q}{\delta \beta \delta \beta'} \right) = 2(\mathbf{X}' \mathbf{X})$$

sea definida **positiva**. Luego, si $\mathbf{X}$ es de rango completo, entonces esta solución es única, se cumpla la definición positiva del término anterior y efectivamente se minimiza la suma de los cuadrados de los residuos.

Es importante recordar que el estimador **MCO** está definido solo cuando la matriz $\mathbf{X}' \mathbf{X}$ es invertible, lo que ocurre siempre y cuando se cumplan las siguientes **dos** condiciones:

1. Las k columnas de la matriz $\mathbf{X}$ sean L.I (*linealmente independientes*).
2. Se disponga al menos de tantas observaciones como variables explicativas, es decir, $n \geq k$ (supuesto 7).

2.2. Propiedades del estimador MCO.

Para ver las propiedades del estimador anteriormente expuesto, veremos como se comporta tanto su esperanza como también su varianza, de modo de posteriormente poder comenzar a evaluar la inferencia sobre este mismo vector de parámetros estimados.

2.2.1. Esperanza del estimador.

Para evaluar el valor esperado del estimador debemos nada más que aplicar el operador $\mathbb{E}$ y ver qué ocurre. Sabemos que el estimador se puede escribir como $\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}$, y reemplazando nuestro modelo $\mathbf{Y} = \mathbf{X}\beta + \mathbf{u}$ en dicha estimación, nos quedaría una expresión como la que sigue:

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'(\mathbf{X}\beta + \mathbf{u}) \rightarrow (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X}\beta + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{u}$$

y como sabemos que $(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X} = \mathbf{I}$, la expresión resultante se transforma en:

$$\hat{\beta} = \beta + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{u}$$

y podemos extraer dos conclusiones importantes:

1. Si quisiéramos medir el **error de estimación**, lo deberíamos hacer viendo la diferencia entre el estimador ($\hat{\beta}$) y el verdadero valor del parámetro (β), lo que evidentemente se traduciría en la siguiente expresión

$$\text{Error de estimación} \rightarrow \hat{\beta} - \beta = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{u}$$

2. Si quisiéramos evaluar la **esperanza del estimador**, debemos aplicar $\mathbb{E}$ a la primera expresión mostrada:

$$\mathbb{E}(\hat{\beta}) = \mathbb{E}(\beta + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{u})$$

y como lo **único de carácter aleatorio es el error** (y naturalmente todo lo demás algo no estocástico), la expresión anterior se reduce a lo siguiente:

$$\mathbb{E}(\hat{\beta}) = \beta + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbb{E}(\mathbf{u})$$

y por supuesto **1** sabemos que $\mathbb{E}(u) = 0$, vemos que el estimador a través de **MCO** es **insesgado**, lo que es:

$$\mathbb{E}(\hat{\beta}) = \beta$$

2.2.2. Varianza del estimador.

Antes de la obtención de la varianza del estimador $\hat{\beta}$ recordemos de inferencia estadística que cuando yo quiero obtener la varianza de una variable aleatoria z , lo debo hacer del siguiente modo:

$$\mathbb{V}(z) = \mathbb{E}(z - \mathbb{E}(z))^2$$

luego, si $\hat{\beta}$ es un vector de $k \times 1$, su varianza será una matriz de $k \times k$, en donde en la diagonal estarán las varianzas de cada uno de los parámetros estimados $\beta_1, \dots, \beta_k$ y, fuera de ella, las covarianzas entre estos mismos. Veamos que se obtiene:

$$\begin{aligned} \mathbb{V}(\hat{\beta}) &= \mathbb{E} \left[\left(\hat{\beta} - \mathbb{E}(\hat{\beta}) \right) \left(\hat{\beta} - \mathbb{E}(\hat{\beta}) \right)' \right] \\ &= \mathbb{E} \left[\left(\hat{\beta} - \beta \right) \left(\hat{\beta} - \beta \right)' \right] \\ &= \mathbb{E} \left[\left((\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{u} \right) \left((\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{u} \right)' \right] \\ &= \mathbb{E} \left[(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{u}\mathbf{u}'\mathbf{X}''(\mathbf{X}'\mathbf{X})^{-1} \right] \end{aligned}$$

ahora entonces notamos que de la expresión anterior lo único de carácter estocástico son los errores, por lo que aplicando la esperanza resulta:

$$\mathbb{V}(\hat{\beta}) = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbb{E}(\mathbf{u}\mathbf{u}')\mathbf{X}''(\mathbf{X}'\mathbf{X})^{-1}$$

y cómo sabemos que $\mathbb{E}(\mathbf{u}\mathbf{u}') = \sigma^2\mathbf{I}$, la expresión anterior (logrando las matrices identidad correspondientes y resolviendo) resulta ser:

$$\mathbb{V}(\hat{\beta}) = \sigma^2(\mathbf{X}'\mathbf{X})^{-1}$$

y en caso de que no tengamos el valor poblacional de σ^2 debemos estimarlo recordando que:

$$\hat{\sigma}^2 = \frac{\hat{\mathbf{u}}'\hat{\mathbf{u}}}{n-k}$$

ya que es una estimación insesgada (*que no requiere mayor demostración*).

2.2.3. Estimador MELI (o BLUE) y Gauss-Markov

Diremos que $\hat{\beta}$ es el **mejor estimador linealmente insesgado (MELI)** (*o BLUE en sus siglas en inglés*) si cumple con las siguientes propiedades:

1. **Es lineal en Y** , es decir, (algo no estocástico) $\ast Y$. Lo anterior vemos que el estimador **MCO** si lo cumple, ya que como sabemos que $(\mathbf{X}'\mathbf{X})$ es algo no estocástico, $(\mathbf{X}'\mathbf{X})^{-1}$ también lo será. En ese sentido $\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}$ si cumple con la linealidad en torno a la variable dependiente.
2. **Es insesgado**. También podemos ver que $\hat{\beta}$ según **MCO** cumple con esta propiedad, ya que como demostramos anteriormente sí se cumple que $\mathbb{E}(\hat{\beta}) = \beta$.
3. **Tiene varianza mínima**. Esto es: dentro de la clase de todos los estimadores linealmente insesgados, un estimador insesgado con varianza mínima es conocido como un **estimador eficiente**.

Finalmente, lo que nos dice **Gauss – Markov** es que (*bajo el cumplimiento de los supuestos 1 a 5*) el estimador **MCO** es el estimador lineal insesgado óptimo, ya que cualquier otro estimador que también cumpla con la característica de ser lineal e insesgado tiene una matriz de varianzas y covarianzas **mayor** que la del estimador según el método de mínimos cuadrados ordinarios.

El estimador **MCO** es MELI (*BLUE*)

Antes de pasar al siguiente tópico, es importante que se entienda perfecto el concepto de matriz de varianzas y covarianzas, ya que muchas veces será de mucha utilidad para la inferencia sobre los parámetros de mi modelo. Veamos el siguiente ejemplo:

Imaginemos que tenemos un modelo con parámetros estimados tales que mi vector de parámetros estimados se puede representar del siguiente modo:

$$\hat{\beta} = \begin{pmatrix} \hat{\beta}_1 \\ \hat{\beta}_2 \end{pmatrix}$$

ahora, cuando obtengamos la matriz de varianzas y covarianzas, debemos notar inmediatamente que será una matriz de 2×2 (si mi vector -de manera general- es de $k \times 1$, mi matriz de varianzas y covarianzas será de $k \times k$). De ese modo, se representará como sigue a continuación:

$$\mathbb{V}(\hat{\beta}) = \begin{pmatrix} \mathbb{V}(\hat{\beta}_1) & \text{Cov}(\hat{\beta}_1, \hat{\beta}_2) \\ \text{Cov}(\hat{\beta}_2, \hat{\beta}_1) & \mathbb{V}(\hat{\beta}_2) \end{pmatrix}$$

*y como sabemos que $\text{Cov}(\hat{\beta}_1, \hat{\beta}_2) = \text{Cov}(\hat{\beta}_2, \hat{\beta}_1)$, será fácil notar que la **matriz de varianzas y covarianzas de $\hat{\beta}$ es simétrica** ($\mathbf{A} = \mathbf{A}'$).*

2.3. Bondad de ajuste

Muchas veces vamos a querer ver qué tan bueno es el ajuste de mi modelo en función de qué tan bien seleccionadas están las variables explicativas o independientes **X** del modelo para explicar a la variable dependiente **Y**. La bondad anterior se logra a través del cálculo del **coeficiente de determinación del modelo** (*de ahora en adelante R^2*), lo que se logra a través del análisis de la variabilidad de distintos términos posibles de obtener según los datos que tenga y las estimaciones que haga sobre ellos.

Estas variabilidades se conocen como **sumas de cuadrados** del modelo, y el cálculo de cada una de ellas se detalla a continuación.

1. La variabilidad existente en la variable dependiente Y se puede definir como la suma de sus diferencias con respecto al promedio muestral, es decir:

$$\sum_{i=1}^n (y_i - \bar{y})^2$$

La expresión anterior la denominaremos de ahora en adelante como la **Suma de Cuadrados Totales (SCT)**

2. La variabilidad restante me la entregaran las diferencias entre lo estimado de la variable dependiente y el promedio muestral de esta misma, es decir:

$$\sum_{i=1}^n (\hat{y}_i - \bar{y})^2$$

y de ahora en adelante la denominaremos como la **Suma de Cuadrados Explicados (SCE)**

3. La variabilidad del error también ya la definimos anteriormente y se ve del siguiente modo:

$$\sum_{i=1}^n (y_i - \hat{y}_i)^2$$

y de ahora en adelante la denominaremos como la **Suma de Cuadrados No explicados (SCR)**

Luego, se cumplirá la siguiente identidad:

$$SCT = SCE + SCR$$

y de ella obtendremos el coeficiente de determinación R^2 , que se definirá del siguiente modo:

$$R^2 = \frac{SCE}{SCT} = 1 - \frac{SCR}{SCT}$$

y que corresponde a la proporción de la varianza muestral de Y que es realmente explicada por la regresión según **MCO**. Este coeficiente también puede ser extraído de las salidas de STATA cuando se realiza alguna regresión, encontrándolo en la esquina superior izquierda, tal como se señala en la imagen a continuación:

Extrayendo coeficiente de determinación desde STATA

```
. reg testscr str
```

Source	SS	df	MS
(SCE) Model	7794.11004	1	7794.11004
(SCR) Residual	144315.484	418	345.252353
(SCT) Total	152109.594	419	363.030056

```
Number of obs = 420
F( 1, 418) = 22.58
Prob > F = 0.0000
R-squared = 0.0512
Adj R-squared = 0.0490
Root MSE = 18.581
```

testscr	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]
str	-2.279808	.4798256	-4.75	0.000	-3.22298 -1.336637
_cons	698.933	9.467491	73.82	0.000	680.3231 717.5428

¿Cómo obtenemos el R^2 en un contexto **matricial**?

1. SCR :

$$SCR = \sum_{i=1}^n \hat{u}_i^2 = \hat{u}' \hat{u}$$

y, además, sabemos que $\hat{u} = \mathbf{Y} - \mathbf{X}\hat{\beta}$. Por lo que, en términos matriciales,

$$SCR = (\mathbf{Y} - \mathbf{X}\hat{\beta})' (\mathbf{Y} - \mathbf{X}\hat{\beta})$$

2. SCT :

$$SCT = \sum_{i=1}^n (y_i - \bar{y})^2$$

para obtener esta expresión en términos matriciales, definiremos los siguientes vectores que nos ayudarán en su cálculo:

a) Definamos un vector de $\mathbf{1}$'s (L) de tamaño $n \times 1$, es decir,

$$L = \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix}_{n \times 1}$$

b) De mis datos de la muestra, obtengamos el promedio muestral $\bar{y}$, lo que será indiscutiblemente un número (**escalar**). Luego, multipliquemóslor por el vector L anteriormente descrito para así formar un vector de tamaño $n \times 1$ en donde todos sus componentes sean $\bar{y}$. Esto es:

$$\bar{y} \cdot L = \begin{pmatrix} \bar{y} \\ \vdots \\ \bar{y} \end{pmatrix}_{n \times 1}$$

Luego, la SCT se logrará en términos matriciales solamente restando el vector de y original al vector “creado” recientemente:

$$SCT = (\mathbf{Y} - \bar{\mathbf{Y}} \cdot L)' (\mathbf{Y} - \bar{\mathbf{Y}} \cdot L)$$

3. Finalmente, en términos matriciales, el R^2 se puede representar del siguiente modo:

$$R^2 = 1 - \frac{(\mathbf{Y} - \mathbf{X}\hat{\beta})' (\mathbf{Y} - \mathbf{X}\hat{\beta})}{(\mathbf{Y} - \bar{\mathbf{Y}} \cdot L)' (\mathbf{Y} - \bar{\mathbf{Y}} \cdot L)}$$

2.3.1. Características del coeficiente de determinación.

Algunas propiedades que debemos tener claras en el tratamiento del R^2 se detallan a continuación:

1. Como $0 \leq SCE \leq SCT$, entonces $0 \leq R^2 \leq 1$.

2. El análisis de varianza anterior fue derivado bajo el supuesto de que el modelo incluía una constante (β_1 en nuestra modelación). En ese sentido, nos aseguramos que $R^2 \geq 0$.

3. Si existe independencia entre X e Y , entonces el R^2 será igual a 0. Sin embargo, si el $R^2 = 0$ **no necesariamente** implica independencia entre ambas variables. Esto nos dice entonces que ha medida que el R^2 sea más grande, mejor especificación tiene mi modelo.

Además de lo anterior, es importante mencionar que a medida que agreguemos más variables al modelo (incluso si es que estas variables son *malas*) el R^2 se mantendrá constante o aumentará (nunca decrecerá). En ese sentido, existe un incentivo “perverso” a agregar variables a mi modelo y así “pensar” que será mejor.

Sin embargo, frente a esta problemática, se crea el **coeficiente de determinación ajustado** ($\tilde{R}^2$) y que corrige el R^2 original por grados de libertad del numerador y del denominador.

- **Numerador:** Como sabemos que la suma de los cuadrados proviene del modelo, debemos ajustar por la cantidad de parámetros estimados dentro de este mismo (k). Es decir, los grados de libertad del numerador son $(n - k)$.
- **Denominador:** Como la suma de los cuadrados totales solo realiza una estimación ($\bar{y}$), se debe ajustar por solo 1 parámetro estimado. Esto significa que el ajuste se hace por $(n - 1)$ grados de libertad.

Finalmente entonces, el R^2 **ajustado** se puede representar del siguiente modo:

$$\tilde{R}^2 = 1 - \frac{\frac{(\mathbf{Y} - \mathbf{X}\hat{\beta})'(\mathbf{Y} - \mathbf{X}\hat{\beta})}{(n-k)}}{\frac{(\mathbf{Y} - \bar{\mathbf{Y}} \cdot \mathbf{L})'(\mathbf{Y} - \bar{\mathbf{Y}} \cdot \mathbf{L})}{(n-1)}} \quad \longleftrightarrow \quad \tilde{R}^2 = 1 - (1 - R^2) \frac{(n-1)}{(n-k)}$$

equivalente

2.4. Estimación en programación

Cuando desarrollamos un modelo según datos de X y obtenemos la estimación de los parámetros lo podemos hacer numéricamente o bien programando la regresión en STATA. Luego, será de mucha utilidad saber donde identificar las estimaciones en una salida usal de stata;

Diferencias: De un modelo simple a uno múltiple.

```
. reg testscr str
```

Source	SS	df	MS	
Model	7794.11004	1	7794.11004	
Residual	144315.484	418	345.252353	
Total	152109.594	419	363.030056	

testscr	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]
str	-2.279808	.4798256	-4.75	0.000	-3.22298 -1.336637
_cons	698.933	9.467491	73.82	0.000	680.3231 717.5428


```
. reg testscr str el_pct
```

Source	SS	df	MS	
Model	64864.3011	2	32432.1506	
Residual	87245.2925	417	209.221325	
Total	152109.594	419	363.030056	

testscr	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]
str	-1.101296	.3802783	-2.90	0.004	-1.848797 -.3537945
el_pct	-.6497768	.0393425	-16.52	0.000	-.7271112 -.5724423
_cons	686.0322	7.411312	92.57	0.000	671.4641 700.6004

Luego, podemos notar 3 cosas a simple vista (en este ejemplo):

- Lo primero es notar que al incluir una variable cambió tanto el R^2 como también el coeficiente de determinación **ajustado**, es decir, aumentó la capacidad de predicción de nuestro modelo, tanto en su versión general como en su versión ajustada por la inclusión de regresores.
- Podemos extraer los valores tanto de β_1 y de β_2 en la imagen 1 y de β_1 , β_2 y β_3 en la imagen 2, en la columna “coef”. Luego, además, tenemos los errores estándar de cada uno de los estimadores, de manera que resulta fácil hacer test de hipótesis, mucho más aún considerando que el valor del t_{obs} y el intervalo de confianza al 95 % para cada estimador también está entregado explícitamente.
- En **STATA** el modelo considera el intercepto `_cons` como β_0 , de modo que siempre todos los cálculos se hacen ajustando por $n - k - 1$.

3. Inferencia sobre los parámetros.

Antes de comenzar a realizar inferencia debemos imponer un supuesto clave dentro de la estimación a través de **MCO**, que es que las perturbaciones $\mathbf{u}$ son independientes de las variables X' s (supuesto 6) y, además, que la distribución que tendrá el término aleatorio del error será normal. Este supuesto se denomina **normalidad de los errores**.

$$\mathbf{u} \sim N(0, \sigma^2)$$

con media = 0 (por supuesto **3**) y varianza = σ^2 (mostrado en la sección 2.1 del presente apunte). Lo anterior es muy importante, ya que como $\hat{\beta}$ es una función de $\mathbf{u}$ (recordar que $\hat{\beta} = \beta + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{u}$) y $\mathbf{u}$ distribuye $N(0, \sigma^2)$, $\hat{\beta}$ también lo hará, con sus parámetros bien definidos. De ese modo:

$$\hat{\beta} \sim N(\beta, \sigma^2(\mathbf{X}'\mathbf{X})^{-1})$$

y nuevamente recordamos que si no tenemos el valor poblacional de σ^2 , debemos estimarlo con el estimador recurrentemente mostrado en este apunte y descrito como:

$$\hat{\sigma}^2 = \frac{\hat{\mathbf{u}}'\hat{\mathbf{u}}}{n - k}$$

3.1. Test de hipótesis

Luego de manejar la información previa, podremos hacer inferencia sobre los parámetros de nuestro modelo, de modo que las hipótesis a las cuales nos podremos encontrar se resumen a continuación:

1. Innumerables veces queremos testear si un regresor (o variable independiente) particular X_i tiene o no influencia alguna sobre la variable dependiente Y . Luego, para estos casos, solamente debemos plantear la hipótesis H_0 cómo la que establece que el valor del parámetro que acompaña a esa X_i particular β_i es igual o distinto de 0. **Este test se llama test de significancia.**

$$H_0 : \beta_i = 0$$

2. Podremos querer testear si un regresor particular X_i tiene una influencia **determinada** sobre la variable dependiente Y . Esto es, si el parámetro que acompaña a ese regresor β_i toma un valor particular. Luego, la hipótesis planteada en estos casos será del tipo:

$$H_0 : \beta_i = (\beta_i)_0$$

3. También, podremos querer testear **si dos regresores distintos X_i y X_j tienen el mismo impacto sobre la variable dependiente Y** . De ese modo, deberemos testear si los valores de cada uno de los parámetros que los acompaña son iguales, con una hipótesis del tipo:

$$H_0 : \beta_i = \beta_j$$

4. Si queremos testear, por ejemplo, que **dos regresores distintos X_i y X_j tienen conjuntamente un impacto conjunto “unitario” sobre la variable dependiente Y_i** deberemos hacerlo testeando una hipótesis del tipo:

$$H_0 : \beta_i + \beta_j = 1$$

5. Si quisieramos hacer un test de significancia más **global**, podríamos querer ver si todos los regresores (excepto la constante) tienen un impacto nulo sobre la variable dependiente, teniendo que testear una hipótesis conjunta del tipo:

$$H_0 : \beta_i = 0 \text{ con } i = 2, \dots, k.$$

6. Por último, podemos querer testear si un **subconjunto** de las pendientes del modelo son 0 (*no significativos*), esto es, si particionamos en dos el vector de parámetros β en β_I y β_P , cada uno de dimensiones $k_I \times 1$ y $k_P \times 1$, respectivamente, con $k_I + k_P = k$, para hacer este test deberemos plantear una hipótesis del tipo:

$$H_0 : \beta_P = 0$$

Y, desde ahora en adelante, comenzaremos a plantear las hipótesis anteriores del siguiente modo:

$$\mathbf{R}\beta = \mathbf{r}$$

donde $\mathbf{R}$ es una matriz de constantes que acompañan a cada uno de los parámetros a testearse de $q \times k$, donde q es el número de hipótesis lineales a testear y k el número de parámetros del modelo, q es el número de hipótesis lineales en el problema y $\mathbf{r}$ es un vector de tamaño $q \times 1$ que contiene todos los valores de las hipótesis nulas a testearse.

Veamos el siguiente ejemplo para que quede más claro:

Si tengo un modelo de regresión lineal múltiple del tipo:

$$Y = \beta_1 + \beta_2 X_2 + \beta_3 X_3 + u$$

lo primero que debemos notar es que el vector de estimaciones $\mathbf{MCO}$ será de tamaño 3×1 (ya que son sólo 3 los parámetros a estimarse $\beta_1, \beta_2, \beta_3$). Además, si quisiéramos, por ej, evaluar si las variables X_2 y X_3 tienen el mismo impacto sobre mi variable dependiente Y , deberíamos hacerlo con un test del tipo:

$$H_0 : \beta_2 = \beta_3$$

que es equivalente a escribirla del siguiente modo:

$$H_0 : \beta_2 - \beta_3 = 0$$

Luego, la escribimos de manera matricial:

$$\mathbf{R} = [0 \ 1 \ -1]$$

ya que en la hipótesis no hay nada que acompañe a β_1 , una constante $\mathbf{1}$ que acompaña a β_2 y el $-\mathbf{1}$ que acompaña a β_3 . Además, es de tamaño 1×3 porque hay sólo una hipótesis lineal testandose.

Ahora, el vector β es igual que siempre, de tamaño $k \times 1$ (en este caso 3×1), y visualmente es cómo se muestra a continuación:

$$\beta = \begin{pmatrix} \beta_1 \\ \beta_2 \\ \beta_3 \end{pmatrix}$$

Además, el vector $\mathbf{r}$ será un escalar igual a 0, ya que como hay una sola hipótesis a testear su tamaño será de 1×1 .

$$\mathbf{r} = 0$$

Por último, podemos ver que si hacemos la operación matricial, llegaremos a la misma hipótesis planteada originalmente:

$$\underbrace{[0 \ 1 \ -1]}_{\mathbf{R}} \cdot \underbrace{\begin{pmatrix} \beta_1 \\ \beta_2 \\ \beta_3 \end{pmatrix}}_{\beta} = \underbrace{0}_{\mathbf{r}} \longleftrightarrow H_0 : \beta_2 - \beta_3 = 0$$

Entonces, nuestras hipótesis serán:

$$\mathbf{R}\beta = \mathbf{r} \text{ vs } \mathbf{R}\beta \neq \mathbf{r}$$

de modo que solamente nos queda derivar el test que nos permitirá tomar decisiones entorno a estas hipótesis. Recordando que $\mathbb{E}(\hat{\beta}) = \beta$, $\mathbb{V}(\hat{\beta}) = \sigma^2(\mathbf{X}'\mathbf{X})^{-1}$ y $\hat{\beta} \sim N(\beta, \sigma^2(\mathbf{X}'\mathbf{X})^{-1})$, podemos notar fácilmente que si quisiéramos operar $\mathbf{R}\hat{\beta}$, los parámetros y distribución de esta función de $\hat{\beta}$ serían los siguientes:

1. Esperanza:

$$\mathbb{E}(\mathbf{R}\hat{\beta}) = \mathbf{R}\beta$$

al ser $\mathbf{R}$ no aleatorio y $\hat{\beta}$ insesgado.

2. Varianza:

$$\begin{aligned}
 \mathbb{V}(\mathbf{R}\hat{\beta}) &= \mathbb{E} \left[\left(\mathbf{R}\hat{\beta} - \mathbb{E}(\mathbf{R}\hat{\beta}) \right) \left(\mathbf{R}\hat{\beta} - \mathbb{E}(\mathbf{R}\hat{\beta}) \right)' \right] \\
 &= \mathbb{E} \left[\left(\mathbf{R}\hat{\beta} - \mathbf{R}\beta \right) \left(\mathbf{R}\hat{\beta} - \mathbf{R}\beta \right)' \right] \\
 &= \mathbb{E} \left[\mathbf{R} \left(\hat{\beta} - \beta \right) \left(\hat{\beta} - \beta \right)' \mathbf{R}' \right] \\
 &= \mathbf{R} \mathbb{E} \left[\left(\hat{\beta} - \beta \right) \left(\hat{\beta} - \beta \right)' \right] \mathbf{R}'
 \end{aligned}$$

de modo que la varianza termina siendo:

$$\mathbb{V}(\mathbf{R}\hat{\beta}) = \sigma^2 \mathbf{R}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{R}'$$

3. Distribución:

Como $\hat{\beta}$ ya tiene una distribución normal, esta transformación la seguirá teniendo con los parámetros revisados en la enumeración 1 y 2, de modo que:

$$\mathbf{R}\hat{\beta} \sim N(\mathbf{R}\beta, \sigma^2 \mathbf{R}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{R}')$$

3.2. Estadísticos de prueba.

Como siempre trabajamos los test de hipótesis suponiendo *a priori* que la hipótesis nula es cierta (para posteriormente corroborar o no ese supuesto), este caso no será la excepción. Ahora, si H_0 es cierta, tendremos que:

$$\underbrace{\mathbf{R}\hat{\beta} - \mathbf{r}}_{\text{discrepancia}} \sim N(0, \sigma^2 \mathbf{R}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{R}')$$

ya que la media de $\mathbf{R}\hat{\beta}$ es $\mathbf{R}\beta$ y la nula establece que $\mathbf{R}\beta = \mathbf{r}$, y la varianza desplazada por una constante $\mathbf{r}$ es la misma que sin desplazar. Luego, se puede demostrar que:

$$\left(\mathbf{R}\hat{\beta} - \mathbf{r} \right)' \left[\sigma^2 \mathbf{R}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{R}' \right]^{-1} \left(\mathbf{R}\hat{\beta} - \mathbf{r} \right) \sim \chi^2_{(q)}$$

y si σ^2 es desconocido, entonces:

$$\frac{\left(\mathbf{R}\hat{\beta} - \mathbf{r} \right)' \left[s^2 \mathbf{R}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{R}' \right]^{-1} \left(\mathbf{R}\hat{\beta} - \mathbf{r} \right)}{q} \sim F_{(q, n-k)}^{1-\alpha}$$

que es conocido como el “test F” y aplica para realizar estos tipos de contrastes de hipótesis.

Ahora, si $q = 1$ notaremos que $\left(\mathbf{R}\hat{\beta} - \mathbf{r} \right)$ es un escalar (1×1) , de modo que el test $\mathbf{F}$ es tratado como un simple test $\mathbf{T}$, de modo que:

$$\frac{\left(\hat{\beta} - \beta \right)}{\sqrt{V(\hat{\beta})}} \sim F_{(1, n-k)} \longleftrightarrow t_{n-k}$$

y rechazaremos para valores mayores al crítico de una $F(q, n - k)$ para un valor de significancia α .

3.2.1. Variantes del Test Conjunto F (caso 5 y caso 6)

■ **Caso 5:** “Todas las pendientes del modelo son 0”

En estos casos se puede demostrar que el test F (ver más abajo explicación del mismo) puede expresarse cómo:

$$F = \frac{ESS/(k-1)}{RSS/(n-k)} \sim F_{(k-1, n-k)}$$

o, alternativamente y usando la definición de R^2 ;

$$F = \frac{R^2/(k-1)}{(1-R^2)/(n-k)} \sim F_{(k-1, n-k)}$$

■ **Caso 6:** “Un subconjunto de las pendientes del modelo son 0”.

En estos casos se puede demostrar que el test F puede expresarse cómo:

$$F = \frac{(\hat{u}'_*\hat{u}_* - \hat{u}'\hat{u})/k_2}{\hat{u}'\hat{u}/(n-k)} \sim F_{(k_2, n-k)}$$

donde $\hat{u}'_*$ son los residuos del modelo estimado por **MCO** pero **restringido** (donde k_2 representa el número de regresores que han sido restringidos a 0), mientras que $\hat{u}$ representan los residuos del modelo **MCO** original.

4. Predicción

Recurrentemente en nuestra carrera nos interesará mucho predecir el valor de una variable, lo que sin duda es una tarea difícil. En ese sentido, el modelo de regresión lineal nos permite hacer este ejercicio, sobre la base de una serie de ciertos supuestos. Estas predicciones tendrán **error**, por lo que deberemos calcularlos y, posteriormente, obtener intervalos de confianza.

Supongamos que queremos predecir el valor individual de Y , y^0 , asociado a un vector de regresores x_i^0 con $i = 1, \dots, k$ de dimensión $1 \times k$. De acuerdo con el modelo econométrico ya presentado, lo que se tiene es:

$$y^0 = \beta_1 + x_2^0\beta_2 + \dots + x_k^0\beta_k + u^0$$

Luego, para predecir el valor de y^0 podemos (y debemos!) utilizar la estimación **MCO** del modelo, es decir:

$$\hat{y}^0 = x^0\hat{\beta}$$

siendo x^0 un supuesto o escenario (“supongamos que el próximo año se proyecta x^0 , es decir, tomará **ese** valor). Luego, con esa “muestra”, estimamos los parámetros $\hat{\beta}$. Luego, **el error de predicción** se definirá cómo:

$$\hat{e}^0 = y^0 - \hat{y}^0 = x^0(\beta - \hat{\beta}) + u^0$$

que intuitivamente es “la verdad” – “la estimación”. Luego, en la expresión anterior se distinguen **2** fuentes del error de predicción:

- El error en la estimación del vector β ($\beta - \hat{\beta}$)
- El error estocástico inherente al modelo, es decir, u^0 .

4.1. Esperanza y Varianza del error de predicción

1. Notamos que el **valor esperado** del error de predicción es:

$$\begin{aligned}\mathbb{E}(\hat{e}^0) &= \mathbb{E}(y^0) - \mathbb{E}(\hat{y}^0) \\ &= x^0\beta - x^{0'}\mathbb{E}(\hat{\beta})\end{aligned}$$

si $\hat{\beta}$ es insesgado (**deseable**) vemos que:

$$\begin{aligned}&= x^0\beta - x^0\beta \\ &= \mathbf{0}.\end{aligned}$$

2. Notamos que para obtener la **varianza** debemos expresarla del siguiente modo:

$$\begin{aligned}V(\hat{e}^0) &= \mathbb{E}(\hat{e}\hat{e}') \\ &= \mathbb{E}\left[x^0(\beta - \hat{\beta})(\beta - \hat{\beta})'x^{0'} + 2x^0(\beta - \hat{\beta})u^0 + u^0u^{0'}\right]\end{aligned}$$

que nace del desarrollo de:

$$\mathbb{E}\left[\underbrace{(x^0(\beta - \hat{\beta}) + u^0)}_{\hat{e}}\underbrace{(x^0(\beta - \hat{\beta}) + u^0)'}_{\hat{e}'}\right]$$

luego,

$$V(\hat{e}^0) = \sigma_u^2 + \sigma_u^2 x^0 (x'x)^{-1} x^{0'}$$

Logicamente, el error estándar no es más que la raíz de la expresión anterior, es decir,

$$S.E(\hat{e}^0) = \sqrt{\sigma_u^2 + \sigma_u^2 x^0 (x'x)^{-1} x^{0'}}$$

y como muchas veces desconoceremos σ^2 , deberemos estimarlo a través del estimador usual:

$$\hat{\sigma}^2 = \frac{\hat{\mathbf{u}}'\hat{\mathbf{u}}}{n-k}$$

Ahora, para que el **error de predicción** tenga una distribución normal, se hace excesivamente necesario que los errores tengan efectivamente una distribución normal. De ese modo, lo que viene a continuación es el **test de normalidad de los errores**.

4.2. Test de normalidad de los errores

Jarque y Bera (1987), propusieron el siguiente estadígrafo basado en la hipótesis nula de **normalidad**:

$$JB = n \left[\frac{\hat{s}^2}{6} + \frac{(\hat{k} - 3)^2}{24} \right] \sim \chi^2_{(2)}$$

con

$$\hat{s}^2 = \frac{\mathbb{E}(u^3)}{(\sigma^2)^{3/2}} \text{ coeficiente de simetría}$$

$$\hat{k} = \frac{\mathbb{E}(u^4)}{(\sigma^2)^2} \text{ kurtosis}$$

Donde los estimadores **muestrales** del coeficiente de simetría y kurtosis se obtienen al considerar que un estimador natural de

$$u_r = \mathbb{E}(\hat{u}^r)$$

corresponde a:

$$m_r = \frac{1}{n} \sum \hat{u}_i^r$$

4.3. Distribución del error de predicción

Ahora, **bajo el supuesto de normalidad del término error**, el error de predicción es una combinación lineal de 2 variables normales, por lo tanto también tiene una distribución normal $N(0, \sigma_e^2)$. Por lo tanto, se tiene que:

$$\frac{y^0 - \hat{y}^0}{\sqrt{\sigma_u^2 (1 + x^0 (x'x)^{-1} x^{0'})}} \sim N(0, 1)$$

y si σ_u^2 es desconocido:

$$\frac{y^0 - \hat{y}^0}{\sqrt{\hat{\sigma}_u^2 (1 + x^0 (x'x)^{-1} x^{0'})}} \sim t_{n-k}$$

Por lo tanto, dada una predicción puntual $\hat{y}^0$ y una estimación de la desviación estándar del error de predicción podemos construir un intervalo de confianza para el valor de y^0 (despejando desde el pivote anterior) :

$$\begin{aligned} Pr \left[\hat{y}^0 - t_{1-\frac{\alpha}{2}}^{n-k} \sqrt{\text{var}(\hat{e}^0)} \leq y^0 \leq \hat{y}^0 + t_{1-\frac{\alpha}{2}}^{n-k} \sqrt{\text{var}(\hat{e}^0)} \right] \\ \iff \\ \left[x^0 \hat{\beta} \pm t_{1-\frac{\alpha}{2}}^{n-k} \sqrt{\hat{\sigma}_u^2 (1 + x^0 (x'x)^{-1} x^{0'})} \right] \end{aligned}$$

además, recordar que a pesar de que σ_u^2 sea desconocido y debemos estimarlo, si $n - k$ es mayor o igual a 30, por **tlc** se puede aproximar a una distribución normal.

Otro caso es si es que uno no está interesado en predecir el valor de la variable y^0 , si no tan solo su valor esperado, es decir, $\mathbb{E}(y^0) = x^0 \beta$. Luego, la predicción será igualmente $x^0 \hat{\beta}$ pero el **error de predicción será distinto**, definido como:

$$\hat{e}^0 = \mathbb{E}(y^0) - x^0 \hat{\beta} = x^0 \beta - x^0 \hat{\beta} = x^0 (\beta - \hat{\beta})$$

Ahora, si calculamos la varianza de este nuevo error de predicción podremos construir un intervalo pero ahora para el valor $\mathbb{E}(y^0)$ de la misma manera que antes:

$$\begin{aligned} V(\hat{e}^0) &= \mathbb{E} \left[\left(x^0 (\beta - \hat{\beta}) \right) \left(x^0 (\beta - \hat{\beta}) \right)' \right] \\ &= \sigma_u^2 x^0 (x'x)^{-1} x^{0'} \end{aligned}$$

luego,

$$\frac{\mathbb{E}(y^0) - \hat{y}^0}{\sqrt{\sigma_u^2 x^0 (x'x)^{-1} x^{0'}}} \sim N(0, 1)$$

nuevamente, si σ_u^2 es desconocido, debo estimarlo y aproximar a distribución t_{n-k} .

5. Estimación Máximo Verosímil

A diferencia de la estimación por **MCO**, la estimación máximo verosímil (**EMV**) descansa en un determinado supuesto respecto de la distribución del término de error teniendo por objetivo -cómo se verá más adelante- determinar los parámetros que **maximicen la probabilidad de ocurrencia de todos los elementos de la muestra observada** (por eso multiplicamos todos los eventos).

De ese modo, sea $Y' = [y_1, \dots, y_n]$ un vector de $n \times 1$ de valores muestrales para la variable dependiente, los cuales dependen de un vector de $k \times 1$ parámetros $\theta' = [\theta_1, \theta_2, \dots, \theta_k]$. Luego, sea $f(y; \theta)$ la función densidad conjunta asociada. A dicha probabilidad conjunta se le llama **función de verosimilitud** y se denota por $L(\cdot)$:

$$L(\theta; y) = \prod_{i=1}^n f(y_i; \theta)$$

luego, debemos asumir que las observaciones de Y son independientes, entonces la función de verosimilitud es:

$$l(\theta; Y) = \ln \left(\prod_{i=1}^n L_i(\theta; y_i) \right) = \sum_{i=1}^n l_i(\theta; y_i)$$

y en máxima verosimilitud lo que se hace es **maximizar esa función**. Luego, la primera derivada de L es generalmente conocida como **Score**, y nosotros obtenemos $\hat{\theta}_{mv}$ cuando igualamos el score a 0 y despejamos el parámetro de interés.

5.1. Estimación en el Modelo Lineal Clásico

Según el clásico modelo poblacional:

$$Y = x\beta + u$$

donde las matrices poseen los tamaños usuales y $u \stackrel{iid}{\sim} N(0, \sigma^2 \mathbf{I})$, entonces sabemos que: -dado **iid**-:

$$f(u_1, u_2, \dots, u_n; \sigma^2 \mathbf{I}) = f(u_1) * f(u_2) * \dots * f(u_n) = \prod_{i=1}^n f(u_i)$$

y asumiendo una distribución normal para los errores (como es usual) tenemos que la función de verosimilitud corresponde a:

$$f(\mathbf{u}; \sigma^2 \mathbf{I}) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{u_i^2}{2\sigma^2}}$$

lo cual puede resolverse («**simplificarse**») y quedar del siguiente modo:

$$f(\mathbf{u}; \sigma^2 \mathbf{I}) = \frac{1}{(2\pi\sigma^2)^{\frac{n}{2}}} e^{-\frac{\mathbf{u}'\mathbf{u}}{2\sigma^2}}$$

de ese modo, dado nuestro modelo poblacional, tenemos que nuestra función de verosimilitud es:

$$L = f(y_1, y_2, \dots, y_n; X, \sigma^2, \beta) = \frac{1}{(2\pi\sigma^2)^{\frac{n}{2}}} e^{-\frac{(Y - X\beta)'(Y - X\beta)}{2\sigma^2}}$$

luego, como notamos que nuestra función de verosimilitud depende de **2** parámetros (β y σ^2) tendremos que nuestro vector de estimadores máximo verosímil(es) será:

$$\hat{\theta}_{mv} = \begin{bmatrix} \hat{\beta}_{mv} & \hat{\sigma}_{mv}^2 \end{bmatrix}'$$

luego debemos **maximizar**:

$$\begin{aligned} \max_{\beta, \sigma^2} \ln(L) &= \max_{\beta, \sigma^2} \ln \left(\frac{1}{(2\pi\sigma^2)^{\frac{n}{2}}} e^{-\frac{(y-x\beta)'(y-x\beta)}{2\sigma^2}} \right) \\ &= \max_{\beta, \sigma^2} \left(-\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln(\sigma^2) - \frac{(y-x\beta)'(y-x\beta)}{2\sigma^2} \right) \end{aligned}$$

luego, las condiciones de primer orden (**CPOs**) son:

$$[\beta] = 0 \rightarrow \frac{1}{\sigma^2} X' (y - x\beta) = \frac{1}{\sigma^2} X' u$$

y cómo estamos igualando a **0** tenemos que poner los «sombreros» sobre los parámetros, para notar que están resultando de un proceso de maximización y, por tanto, son estimadores. Luego,

$$\frac{1}{\hat{\sigma}^2} X' (Y - X\hat{\beta}) = 0 \rightarrow \hat{\beta}_{mv} = (X'X)^{-1} X'Y$$

Notamos que la estimación por **MV** es igual a la estimación por **MCO**. Ahora, para la varianza σ^2 :

$$\begin{aligned} [\sigma^2] = 0 &\rightarrow -\frac{n}{2\hat{\sigma}^2} + \frac{1}{2\hat{\sigma}^4} (Y - x\hat{\beta})' (Y - x\hat{\beta}) = 0 \\ \hat{\sigma}_{mv}^2 &= \frac{(Y - x\hat{\beta}_{mv})' (Y - x\hat{\beta}_{mv})}{n} \end{aligned}$$

5.2. Propiedades de la estimación por máximo verosímil

Como toda estimación, tiene propiedades bien definidas. En la presente subsección se detallan cuáles son:

1. **Consistencia:** Asintóticamente, el parámetro estimado corresponde al parámetro poblacional (asintóticamente insesgado). Esta propiedad se traduce a:

$$\text{plim}(\hat{\theta}_{mv}) = \theta$$

2. **Eficiencia Asintótica:** La varianza del estimador **MV** alcanza la llamada «Cota Inferior de Cramer Rao», es decir, $I(\theta)^{-1}$ (ya hablaremos sobre esto en la propiedad 4). Esta propiedad asintótica es la principal virtud de los estimadores máximo verosímil. La **CCR** corresponde al inverso de la matriz de información, la cual corresponde a la **mínima varianza** que posee un estimador insesgado.
3. **Normalidad Asintótica:** El estimador máximo verosímil (al ser consistente y alcanzando la **CCR**) tendrá una distribución asintóticamente normal, con parámetros $\mu = \theta$ y $\sigma^2 = I(\sigma)^{-1}$. De ese modo:

$$\hat{\theta}_{mv} \overset{a}{\sim} N(0, I(\theta)^{-1})$$

donde la matriz de información corresponde a la «información de Fisher» (que se veía en inferencia estadística), solo que ahora es una matriz de segundas derivadas de orden $k \times k$, es decir,

$$I(\theta) = E \left[\frac{\partial l}{\partial \theta} \frac{\partial l'}{\partial \theta} \right] = -E \left[\frac{\partial^2 l}{\partial \theta \partial \theta'} \right]$$

4. **Invarianza:** Si $\hat{\theta}_{mv}$ es el estimador máximo verosímil de θ y $g(\theta)$ es una función **continua** de θ , entonces aplicando **invarianza** tenemos que $g(\hat{\theta}_{mv})$ será la estimación **MV** de esa función $g(\theta)$.

5.3. Matriz de Información

Es la matriz de **varianzas y covarianzas de los estimadores MV**, y corresponde al inverso de la matriz de información ($I(\theta)$) donde $\theta = (\beta, \sigma^2)$. Además, por facilidad de cálculo, generalmente se utiliza la segunda definición de $I(\theta)$, es decir, **el negativo de la esperanza del hessiano** (segundas derivadas respecto de la función de verosimilitud. Entonces, comencemos:

1. Derivando $[\beta]$ nuevamente con respecto a β debemos hacerlo con respecto a β' (por reglas de derivación matricial). Luego,

$$\frac{\partial^2 l}{\partial \beta \partial \beta'} = -\frac{X'X}{\sigma^2}$$

luego, multiplicando por **-1** y tomando esperanza, tenemos que:

$$-E\left(\frac{\partial^2 l}{\partial \beta \partial \beta'}\right) = \frac{X'X}{\sigma^2}$$

en donde se asume que X es **determinístico** (no estocástico - no variable).

2. Luego, derivando cruzado:

$$\frac{\partial^2 l}{\partial \beta \partial \sigma^2} = -\frac{X'u}{\sigma^4}$$

luego, multiplicando por **-1** y tomando esperanza, tenemos que:

$$-E\left(\frac{\partial^2 l}{\partial \beta \partial \sigma^2}\right) = \frac{X'E(u)}{\sigma^4}$$

y como se sigue cumpliendo el supuesto de identificación ($E(u) = 0$) tenemos que:

$$-E\left(\frac{\partial^2 l}{\partial \beta \partial \sigma^2}\right) = -E\left(\frac{\partial^2 l}{\partial \sigma^2 \partial \beta}\right) = 0$$

es decir, los elementos **fuera de la diagonal de la matriz** (covarianzas) será **0**.

3. Por último derivando $[\sigma^2]$ nuevamente con respecto a σ^2 (como es un número **no debemos transponer**) tenemos:

$$\frac{\partial^2 l}{\partial (\sigma^2)^2} = \frac{n}{2\sigma^4} - \frac{u'u}{\sigma^6}$$

luego, multiplicando por **-1** y tomando esperanza, tenemos que:

$$-E\left(\frac{\partial^2 l}{\partial (\sigma^2)^2}\right) = \frac{n}{2\sigma^4}$$

donde esta última esperanza se deriva del hecho que $E(u'u) = n\sigma^2$. Entonces, la **matriz de información** de todos los parámetros (β, σ^2) corresponde a:

$$I(\beta, \sigma^2) = \begin{pmatrix} \frac{X'X}{\sigma^2} & \mathbf{0} \\ \mathbf{0} & \frac{n}{2\sigma^4} \end{pmatrix}$$

mientras que su inversa es:

$$I(\beta, \sigma^2)^{-1} = \begin{pmatrix} (X'X)^{-1} \sigma^2 & \mathbf{0} \\ \mathbf{0} & \frac{2\sigma^4}{n} \end{pmatrix}$$

donde el primer elemento de la diagonal es la varianza de $\hat{\beta}_{mv}$, el segundo elemento es la varianza de $\hat{\sigma}^2$ y los elementos fuera de ella son las covarianzas entre ambos estimadores, es decir, $cov(\hat{\beta}, \hat{\sigma}^2) = cov(\hat{\sigma}^2, \hat{\beta}) = \mathbf{0}$.

6. Tests en la estimación MV

Hay **3** tests que se relacionan directamente con la estimación máximo verosímil de un modelo como el planteado al inicio de la sección N°5. El detalle de cada uno se procede a desarrollar en la presente sección.

6.1. Test de Wald (W)

Se basa en evaluar la hipótesis nula en los coeficientes estimados y evaluar cuán cercano es el resultado comparado a lo propuesto por la nula. Una de las ventajas del test de Wald es que **sólo necesita de la estimación no restringida**.

Siguiendo la misma lógica de la demostración del test $\mathbf{F}$, si tenemos que:

$$\hat{\beta} \stackrel{a}{\sim} (\beta, I(\beta)^{-1})$$

donde $I(\beta)^{-1}$ corresponde al primer elemento de la diagonal de la matriz de información (varianza de $\hat{\beta}$), entonces, bajo la certidumbre de la **hipótesis nula** tendremos que:

$$(R\hat{\beta} - r) \stackrel{a}{\sim} (0, R(I(\beta))^{-1} R')$$

entonces, se puede demostrar fácilmente que:

$$(R\hat{\beta} - r)' [R(I(\beta))^{-1} R']^{-1} (R\hat{\beta} - r) \stackrel{a}{\sim} \chi_{(q)}^2$$

donde q corresponde al número de filas de R y, por lo tanto, es el **número de restricciones lineales que estamos testeando**.

Luego, como ya hemos demostrado que los estimadores **MV** distribuyen asintóticamente normal, entonces la matriz de información expuesta es válida en **muestras grandes**. Luego, tenemos que el «estadístico de Wald» se define como:

$$W = \frac{(R\hat{\beta} - r)' [R(X'X)^{-1} R']^{-1} (R\hat{\beta} - r)}{\hat{\sigma}^2} \stackrel{a}{\sim} \chi_{(q)}^2$$

Nota: Debemos saber que este es válido asintóticamente, donde hemos utilizado el hecho de que en una $\mathbf{F}$, cuando los grados de libertad del denominador son grandes, converge a una χ^2 : «actúa **como si** σ^2 fuese conocido».

6.2. Test de Razón de Verosimilitud (LR)

Notemos que el valor de la función de verosimilitud luego de estimados los parámetros, es decir, $L(\hat{\beta}, \hat{\sigma}^2)$, corresponde al valor **irrestringido**, es decir, **sin imponer ninguna restricción sobre los parámetros del modelo**.

Luego, dado que nuestro interés se centra en una serie de restricciones lineales del tipo $R\beta = r$, entonces el modelo original es estimable en su versión restringida, al maximizar la función de verosimilitud en su versión **restringida**, es decir, sujeta a que $R\beta = r$, cuyo resultado son los estimadores $\tilde{\beta}$ y $\tilde{\sigma}^2$. Luego, $L(\tilde{\beta}, \tilde{\sigma}^2)$ corresponde al valor de la verosimilitud **restringida**.

Después de eso, debemos saber que el valor de la verosimilitud restringida **no puede ser superior** al

de la verosimilitud no restringida, sin embargo, podría esperarse que si la restricciones impuestas **son correctas**, el valor de la primera esté cerca de la segunda. Entonces, definimos **la razón de verosimilitud** (λ) como:

$$\lambda = \frac{L(\tilde{\beta}, \tilde{\sigma}^2)}{L(\hat{\beta}, \hat{\sigma}^2)}$$

luego, el test **LR** se define entonces como:

$$LR = -2 \ln(\lambda) = 2 \left[\ln L(\hat{\beta}, \hat{\sigma}^2) - \ln L(\tilde{\beta}, \tilde{\sigma}^2) \right] \sim \chi_{(q)}^2$$

donde q nuevamente corresponde al número de restricciones impuestas, es decir, el número de filas de R .

6.3. Test de Multiplicador de Lagrange (LM)

Un tercer test corresponde al test **LM**, el cual también es conocido como el «test del Score». Recordemos que el Score corresponde a la matriz de primeras derivadas de la función de Verosimilitud:

$$\begin{aligned} s_{score}(\theta) &= \frac{\partial \ln L}{\partial \theta} \\ &= \frac{\partial l}{\partial \theta} \end{aligned}$$

luego, como vimos en la sección 5, sabemos que el score evaluado en el estimador máximo verosimil es **0**, es decir, $s(\hat{\theta}) = 0$, por lo cual, al evaluar el score en el estimador restringido bajo la nula $R\beta - r = 0$ ($\tilde{\beta}$), generalmente obtendremos un **vector diferente de 0**, sin embargo, si la nula no se puede rechazar, esperaríamos obtener un vector cercano a 0.

Se puede demostrar que el score posee media 0 y varianza igual a la matriz de información. Por lo tanto, tenemos que la siguiente forma cuadrática tiene distribución:

$$s'(\theta) I(\theta)^{-1} s(\theta) \sim \chi^2$$

con lo cual, al evaluar en el vector de parámetros restringido tenemos que, bajo la hipótesis nula, el test **LM** se define y distribuye como:

$$LM = s'(\tilde{\theta}) I(\tilde{\theta})^{-1} s(\tilde{\theta}) \stackrel{a}{\sim} \chi_q^2$$

note que, en contraposición al test de Wald (**W**), sólo necesitamos calcular el estimador restringido. De hecho, la popularidad de este test radica en que muchas veces es más fácil calcular el estimador restringido que aquel que está irrestricto.

6.3.1. Test LM más simple...

Dada la normalidad asintótica de los estimadores **MV**, podemos reducir el estadígrafo a una forma mucho más simple. Para ver lo anterior, considere una notación **matricial** del score:

$$s(\theta) = \begin{bmatrix} \frac{\partial l}{\partial \beta} \\ \frac{\partial l}{\partial \sigma^2} \end{bmatrix} = \begin{bmatrix} \frac{1}{\sigma^2} X' u \\ -\frac{n}{2\sigma^2} + \frac{u' u}{2\sigma^4} \end{bmatrix}$$

entonces, para evaluar el score en la estimación **restringida**, utilizaremos por tanto los **residuos restringidos**, los cuales denotaremos por:

$$\tilde{u} = Y - x\tilde{\beta}$$

y, por lo tanto,

$$\tilde{\sigma}^2 = \frac{\tilde{u}' \tilde{u}}{n}$$

con lo cual,

$$s(\tilde{\theta}) = \begin{bmatrix} \frac{1}{\tilde{\sigma}^2} X' \tilde{u} \\ 0 \end{bmatrix}$$

entonces, tomando en cuenta la definición de $I(\theta)^{-1}$ dada en la sección anterior, y evaluándola en el estimador restringido, tenemos que nuestro test queda como:

$$\begin{aligned} LM &= \begin{bmatrix} \frac{1}{\tilde{\sigma}^2} X' \tilde{u} & 0 \end{bmatrix} \begin{pmatrix} (X'X)^{-1} \tilde{\sigma}^2 & \mathbf{0} \\ \mathbf{0} & \frac{2\tilde{\sigma}^4}{n} \end{pmatrix} \begin{bmatrix} \frac{1}{\tilde{\sigma}^2} X' \tilde{u} \\ 0 \end{bmatrix} \\ &= \frac{\tilde{u}X(X'X)^{-1}X'\tilde{u}}{\tilde{\sigma}^2} \\ &= n \frac{\tilde{u}X(X'X)^{-1}X'\tilde{u}}{\tilde{u}'\tilde{u}} \\ &= nR^2 \stackrel{a}{\sim} \chi_{(q)}^2 \end{aligned}$$

donde el R^2 corresponde a la **bonda de ajuste** de la regresión auxiliar (restringida). Luego, en resumen, este test se implementa en «3 etapas»:

1. Estimar el modelo restringido y obtener sus errores estimados, es decir, $\tilde{u}$.
2. Con ellos, correr una regresión contra X . Luego, obtener el R^2 de esa regresión.
3. Construir el estadístico nR^2 y comparar con el valor crítico de una $\chi_{(q)}^2$

6.4. Consideraciones en torno a los Test's

1. Una ventaja de la estimación por **MV** es que sus propiedades asintóticas se mantienen independientemente de la distribución utilizada (la que se asuma en el error)
2. Otra ventaja corresponde a la posibilidad de utilizar modelos no lineales. **MCO** (tal y como se ha estudiado hasta ahora) sólo permite estimar modelos lineales en parámetros, mientras que **MV** permite **no linealidades** (aunque ello implique la imposibilidad de obtener formas funcionales cerradas para nuestros estimadores, lo cual implica necesariamente utilizar métodos numéricos para optimizar la función objetivo).
3. Otra ventaja reside en la inferencia. Toda la inferencia vista en **MCO** poseía distribución exacta bajo el supuesto de normalidad. Los test asintóticos vistos en la inferencia en **MV** son válidos bajo cualquier distribución supuesta (aunque asintóticamente).
4. Es posible demostrar que $W \geq LR \geq LM$ al ser aplicados a un modelo lineal. Los tres son **asintóticamente equivalentes**, sin embargo, en muestras finitas arrojarán resultados diferentes.

7. Forma funcional y especificación

Ahora veremos distintas formas funcionales que puede adoptar el modelo de regresión lineal y cómo haremos para especificar la estimación de los parámetros en cada uno de los casos.

7.1. Regresores estocásticos

En el desarrollo del modelo de regresión lineal realizado en secciones anteriores hemos asumido que nuestras variables explicativas siempre han sido **determinísticas** (fijas - números). En esta sección, se procederá a eliminar ese supuesto para ver cuales son las consecuencias de asumir regresores que son **estocásticos** en las estimaciones del modelo de regresión lineal. Asumiremos que X es obtenida **aleatoriamente** a partir de

alguna distribución de probabilidad.

Sabemos que desde el modelo de regresión lineal ya tratado, si estimamos β a través de **MCO** obtendremos la siguiente forma funcional:

$$\hat{\beta} = (X'X)^{-1}X'Y \rightarrow \hat{\beta} = \beta + (X'X)^{-1}X'u$$

luego, como todos los otros supuestos de **MCO** se mantienen, tenemos que $E(u|X) = E(u) = 0$ y $Var(u|X) = Var(u) = \sigma^2$, y por tanto podemos evaluar sesgo y varianza del estimador ahora que los X son aleatorios. Veamos cada punto por separado:

1. Esperanza:

a) Esperanza condicional:

$$\begin{aligned} E[\hat{\beta}|X] &= \beta + (X'X)^{-1}X'E(u|X) \rightarrow 0 \\ &= \beta \end{aligned}$$

es decir, sigue siendo **insesgado** cuando **condicionamos en X** .

b) Esperanza incondicional: Si quisieramos obtener la esperanza incondicional solo bastaría con aplicar nuevamente esperanza en **todo el espacio posible de los regresores** (esto es, aplicar LEI - Ley de Esperanzas Iteradas):

$$\begin{aligned} E(\hat{\beta}) &= E_x[E[\hat{\beta}|X]] \\ &= \beta + E_x[(X'X)^{-1}X'E(u|X)] = \beta \end{aligned}$$

por lo tanto, $\hat{\beta}$ es también insesgado cuando **no condicionamos** en las X . Luego, vemos que el insesgamiento de los parámetros **MCO** es **robusto** a los supuestos de la matriz X (estocástica o no estocástica).

2. Varianza:

a) Varianza condicional: Sabemos que la varianza condicional es la siguiente:

$$V[\hat{\beta}|X] = \sigma^2 (X'X)^{-1}$$

b) Varianza incondicional: Para obtenerla, deberemos aplicar la Ley de Varianzas Iteradas, la cual aplica del siguiente modo:

$$\begin{aligned} V[\hat{\beta}] &= E_x[V[\hat{\beta}|X]] + V_x[E[\hat{\beta}|X]] \\ &= E_x[V[\hat{\beta}|X]] + V_x[\beta] \end{aligned}$$

De ese modo, tenemos que:

$$V[\hat{\beta}] = E_x[\sigma^2 (X'X)^{-1}] = \sigma^2 E[(X'X)^{-1}]$$

3. Conclusiones:

- $\hat{\beta}$ es condicional e incondicionalmente insesgado.
- La matriz de varianzas y covarianzas incondicional es $\sigma^2 E[(X'X)^{-1}]$.
- Aunque X sea estocástica, si $E[u|X] = 0$ se cumplirá el **Teorema de Gauss Markov**.
- Bajo normalidad del error, los test estadísticos tienen la misma distribución que en el caso en que X sea no estocástica.

7.2. No Linealidades

Hasta ahora solo hemos considerado relaciones que son lineales entre la variable dependiente (Y) y las variables explicativas/independientes (X), sin embargo, existen **muchas aplicaciones en las que las relaciones dejan de ser del tipo lineal**. Luego, para incorporar estas no linealidades deberemos redefinir algunas variables. Veamos los casos a los cuales nos podemos enfrentar.

7.2.1. Modelo Logarítmico

Supongamos que queremos estimar una función de producción para determinar la productividad de los trabajadores (esto se puede modelar con una Cobb-Douglas clásicamente). Esto sería:

$$Y = AK^{\beta_1}L^{\beta_2}$$

Para poder **estimar** esta función, debemos aplicar logaritmo para linealizarla y posteriormente añadir el término de error para especificarla como una regresión:

$$\ln(Y) = \ln(A) + \beta_1 \ln(K) + \beta_2 \ln(L) + u$$

luego, este modelo puede ser estimado de manera clásica a través de **MCO**, con la única salvedad de que la interpretación de los parámetros estimados será visto como una **elasticidad** (i.e «si K aumenta en 1 %, Y aumenta en β_1 %»).

7.2.2. Modelo Semi-Logarítmico

Supongamos un **modelo original** no lineal de la siguiente forma: $Y_i = \beta_1 e^{\beta_2 X_i} u_i$. Luego, si aplicamos logaritmo nos quedará un **modelo transformado** de la siguiente forma:

$$\ln(Y_i) = \ln(\beta_1) + \beta_2 X_i + \ln(u_i)$$

en donde $\beta_2 = \frac{\partial Y}{\partial X} \cdot \frac{1}{Y}$ corresponde a la **semi elasticidad** X de Y .

Una utilización común de la formulación semilogarítmica se da en los casos de crecimiento exponencial: Si X es el tiempo t , entonces $\frac{\partial \ln(Y)}{\partial t} = \beta_2 =$ tasa de crecimiento de Y .

Otra utilización común es la ecuación de salarios de la forma $\ln(\text{salario}_i) = \beta_1 + \beta_2 \text{escolaridad}_i + u_i$, que nos indica el efecto porcentual en el salario que tiene un año más de escolaridad, es decir, si *escolaridad* aumenta en 1, *salario* aumenta en $(\beta_2 \times 100)$.

7.2.3. Modelo Cuadrático

En este caso, algún regresor tiene forma cuadrática de modo que la función a estimar pueda capturar efectos crecientes o decrecientes. Imaginemos una regresión del tipo:

$$\text{ventas}_i = \beta_1 + \beta_2 (\text{días publicidad})_i + \beta_3 (\text{días publicidad})_i^2 + u_i$$

luego, esperaríamos que los días de publicidad aumentaran las ventas, sin embargo, a tasas decrecientes. Ese será un resultado propio de la estimación, es decir, que $\beta_2 > 0$, $\beta_3 < 0$ y que $\beta_2 > -2\beta_3$, para que efectivamente se de **crecimiento a tasas decrecientes** (evaluar midiendo efectos marginales).

7.2.4. Test de Ramsey para no linealidades

Si no conocemos a priori la forma funcional de mi modelo de regresión, existen algunos métodos que podrían identificar la existencia de alguna no linealidad. Una pregunta interesante de plantearse es si nuestro modelo **ha omitido no linealidades** en ciertos regresores. Ramsey (1969) introdujo el siguiente test:

Bajo la nula, el modelo **poblacional** corresponde a:

$$Y = X\beta + u$$

luego, sabemos que $\hat{Y} = X\hat{\beta}$. Ramsey propuso estimar el siguiente modelo auxiliar a través de **MCO**:

$$Y = X\hat{\beta}_1 + Z\hat{\beta}_2 + \hat{u}$$

donde $Z = [\hat{Y}^2 \ \hat{Y}^3 \ \dots \ \hat{Y}^m]$ son **potencias** de la predicción. Luego, la hipótesis nula es H_0 : No existen linealidades omitidas, es decir, $\beta_2 = 0$.

Esta hipótesis puede ser testeada utilizando un **test de Wald o F** sobre β_2 . Es posible demostrar que bajo la nula $W \sim \chi^2_{m-1}$. Por lo tanto, la nula se rechaza al $\alpha\%$ de significancia si el estadígrafo es mayor al valor crítico correspondiente.

Para implementar el test, m (es decir, el número de potencias de Y a incluir en la regresión auxiliar) debe ser seleccionado previamente. Típicamente, valores pequeños como 2, 3 o 4 parecen funcionar mejor.

7.3. Variables Dummies o cualitativas

En análisis de regresión, la variable dependiente está influida frecuentemente no solo por variables **continuas** como lo son el ingreso, producción, precios, costos, estatura, temperatura, etc..., sino también por **variables que son especialmente cualitativas**, estos son **regresores binarios**, es decir, variables que sólo toman el valor **0** ó **1**.

Dichas variables son llamadas **variables dummies**, **variables dicotómicas** o **variables ficticias**. Muchas veces el regresor es binario porque así fue recogido en la encuesta. Sin embargo, en otros casos el regresor binario ha sido construido a partir de otras variables de los datos.

Algunos ejemplos de variables dummies son: **género, raza, religión, nacionalidad, región geográfica**, etc. *Con respecto a las dos primeras variables mencionadas, por ejemplo, se ha encontrado que manteniendo todos los demás factores constantes, las trabajadoras mujeres ganan menos que sus colegas hombres, y que las personas de color ganan menos que las blancas.*

Por ejemplo, consideremos la siguiente variable dummy para género (mujer/hombre) del individuo. Entonces la variable dummy consistirá en un vector $(n \times 1)$ con elementos 0 ó 1 según corresponda. Es decir,

$$d_{1i} = \begin{cases} 1 & \text{hombre} \\ 0 & \text{mujer} \end{cases}$$

A modo de ejemplo, pensemos en una ecuación simple de salarios $E(W_{\text{salario}}|\text{Género})$, la cual implica el siguiente modelo:

$$W_i = \beta_0 + \beta_1 d_{1i} + u_i$$

luego, agreguemos escolaridad, es decir, $E(W_{\text{salario}}|\text{Escolaridad}(\text{esc}), \text{Género})$:

$$W_i = \beta_0 + \beta_1 d_{1i} + \beta_2 \text{esc}_i + u_i$$

dicho modelo presenta un **efecto intercepto** para el género, es decir, hombres y mujeres poseen diferente intercepto, pero igual pendiente β_2 en educación (**retorno a la educación**). Note que si bien hay dos géneros, hemos agregado solo una **variable dummy**.

Ahora, si quisiéramos especificar un modelo en que además las pendientes varíen con el género (retornos a la educación diferenciados), tendríamos el siguiente modelo:

$$W_i = \beta_0 + \beta_1 d_{1i} + \beta_2 \text{esc}_i + \beta_3 d_{1i} \text{esc}_i + u_i$$

donde:

$$\begin{aligned} E(W|esc, Hombre) &= \beta_0 + \beta_1 + \beta_2 esc + \beta_3 esc \\ E(W|esc, Mujer) &= \beta_0 + \beta_2 esc \end{aligned}$$

luego, vemos que el efecto **cambio** de salario respecto a la educación es, para hombres y mujeres, respectivamente, el siguiente:

$$\begin{aligned} \frac{\partial E(W|esc, Hombre)}{\partial esc} &= \beta_2 + \beta_3 \\ \frac{\partial E(W|esc, Mujer)}{\partial esc} &= \beta_2 \end{aligned}$$

7.4. Selección de Modelos

Una pregunta clásica es: ¿Cómo seleccionamos un modelo frente a otros alternativos? En general, tratamos que el modelo cumpla con lo siguiente:

- Elegir el modelo más **parsimonioso** (lo más pequeño posible).
- Que posea un **buen ajuste**.
- Que sea **consistente** con los datos observados.

Ya hemos visto dos criterios que permiten una buena percepción de que tan bueno es un modelo con respecto a otro: R^2 y $R_{ajustado}^2$. Sin embargo, hay **criterios de información** que me permiten seleccionar cual especificación de un modelo es mejor con respecto a otra.

7.4.1. Criterio de Akaike (AIC)

Se define como:

$$AIC = -2\ln(L) + 2k$$

que depende del negativo de la función de verosimilitud (log) evaluada en los estimadores. Luego, mientras **mayor verosimilitud** menor será el AIC. Además, mientras mayores sean los grados de libertad, mayor será el AIC.

7.4.2. Criterio de información Bayesiano o Schwarz (BIC)

Se define como:

$$BIC = -2\ln(L) + k\ln(n)$$

que ahora le agrega dependencia en torno al tamaño de la muestra. Luego, ambos criterios **penalizan** por agregar malos regresores, es decir, **menores números de AIC y BIC** son preferidos a la hora de evaluar la especificación de un modelo u otro.

7.5. Omisión de variable relevante e inclusión de variables irrelevantes.

Ahora hablaremos de que es lo que sucede sobre el insesgamiento y sobre la varianza de la estimación cuando:

- 1) Omitimos del modelo una variable que es **relevante** dentro de la especificación y
- 2) Incluimos al modelo una variable que es **irrelevante** en su especificación.

7.5.1. Omisión de Variables Relevantes.

Sea el siguiente modelo poblacional $Y = X_1\beta_1 + X_2\beta_2 + u$. Suponga ahora que el investigador se equivoca (o no tiene X_2) y estima el siguiente modelo: $Y = X_1\beta_1 + \tilde{u}$. Luego, el estimador **MCO** de β_1 en el **modelo incompleto** es, en general, **sesgado**:

$$\begin{aligned} E(\hat{\beta}_1) &= E\left[\left(X_1'X_1\right)^{-1}X_1'Y\right] \\ &= \beta_1 + E\left[\left(X_1'X_1\right)^{-1}X_1'X_2\right]\beta_2 \\ &= \beta_1 + \mathbf{Z}\beta_2 \end{aligned}$$

donde $\mathbf{Z} = E\left[\left(X_1'X_1\right)^{-1}X_1'X_2\right]$. Además, este estimador también es **inconsistente**. Ahora, debemos notar que en dos ocasiones **no habrá** sesgo:

- Si $X_1'X_2 = 0$, es decir, cuando X_1 es **ortogonal** a X_2 .
- Cuando $\beta_2 = 0$, es decir, cuando X_2 es una variable **irrelevante** que no pertenece al modelo.

Para el caso de **consistencia**, se puede demostrar que cuando X_1 y X_2 son escalares:

$$\text{plim}(\hat{\beta}_1) = \beta_1 + \frac{\text{Cov}(X_1, X_2)}{V(X_1)}\beta_2$$

y de lo anterior se desprende que la **dirección del sesgo** depende de:

1. Como covarien las variables incluidas con respecto a las excluidas.
2. Signo del parámetro omitido (β_2).

Con respecto al **impacto sobre la varianza**, sabemos que -en el modelo **incompleto**- el estimador de la varianza será:

$$V[\hat{\beta}_1|X_1] = \sigma^2 \left(X_1'X_1\right)^{-1}$$

mientras que si hubieramos estimado el modelo correcto, se puede demostrar que la varianza del estimador insesgado de β_1 ($\hat{\beta}_1^*$) correspondería a:

$$V(\hat{\beta}_1^*|X_1, X_2) = \sigma^2 \left(X_1'M_2X_1\right)^{-1}$$

donde $M_2 = I - X_2(X_2'X_2)^{-1}X_2'$. Además, se puede demostrar que:

$$V(\hat{\beta}_1|X_1) \leq V(\hat{\beta}_1^*|X_1, X_2)$$

por lo tanto, **el omitir variables relevantes implica que los parámetros estimados serán sesgados y que sus varianzas serán menores**. También, es posible demostrar que el estimador de la varianza de los errores ($\hat{\sigma}^2$) será sesgada **hacia arriba**.

Conclusiones;

- La omisión de variables relevantes produce **sesgo** e **inconsistencia**.
- Produce varianzas **menores** que las correctas.
- Gauss-Markov no se cumple, por cuanto se ha violado el supuesto **3** en el modelo corto.
- Es un promedio serio y debemos tener precaución en incorporar las variables relevantes del modelo.

7.5.2. Inclusión de Variables Irrelevantes.

Consideremos ahora el siguiente modelo poblacional:

$$Y = X_1\beta_1 + u$$

Suponga ahora que el investigador se equivoca y estima el siguiente modelo:

$$Y = X_1\beta_1 + X_2\beta_2 + u$$

luego, estimando el modelo «**incorrecto**» o «**largo**» obtendremos:

$$\hat{\beta} = (X'X)^{-1} X'Y$$

con $X = [X_1, X_2]$ y se puede extraer $\hat{\beta}_1$, obteniéndose:

$$\begin{aligned}\hat{\beta}_1 &= (X_1' M_2 X_1)^{-1} X_1' M_2 Y \\ &= \beta_1 + (X_1' M_2 X_1)^{-1} X_1' M_2 u\end{aligned}$$

donde M_2 se define igual que en la subsección anterior. Entonces, se puede demostrar que:

$$E(\hat{\beta}_1) = \beta_1$$

y, también, se puede demostrar que $E(\tilde{\sigma}^2) = \sigma^2$. De ese modo, algunas conclusiones con respecto a la inclusión de variables **irrelevantes** en el modelo:

- La inclusión **no causa sesgo** en los parámetros estimados, ni en la varianza de los errores estimados.
- Bajo dichos resultados, pareciera que es mejor poner muchos regresores en nuestro modelo. Sin embargo, nos falta estudiar que sucede con la varianza de los parámetros estimados.

Recordemos que en el modelo largo (**incorrecto**) tenemos que:

$$\hat{\beta}_1 = \beta_1 + (X_1' M_2 X_1)^{-1} X_1' M_2 u$$

luego, la varianza estimada será:

$$V(\hat{\beta}_1 | X_1, X_2) = \sigma^2 (X_1' M_2 X_1)^{-1}$$

mientras que la varianza verdadera es:

$$V(\hat{\beta}_1^* | X_1) = \sigma^2 (X_1' X_1)^{-1}$$

Entonces como discutimos antes, la **varianza del modelo corto** (verdadera en este caso) es **menor** a la varianza estimada. Ello implica que el incluir regresores adicionales, aumenta la varianza de nuestros parámetros estimados, lo cual se traduce en **parámetros menos eficientes**.

	Situación	
	Omisión de VR	Inclusión de VI
Sesgo	depende de Cov y signo β_2	No
Varianza	menor	mayor

7.6. Errores de medida

Los errores de medición aparecen porque en la realidad **no podemos observar con exactitud los valores de las variables que nos interesan** (i.e. los datos del salario provienen de encuestas donde las personas autorreportan sus ingresos, es decir, podrían tener incentivos para sobre ó sub reportarlos). Ahora, estudiaremos entonces cuál es el efecto de tener estos errores de medición.

Comencemos suponiendo que el modelo verdadero es:

$$Y = X\beta + u$$

Sin embargo, en los datos observamos $\tilde{X} = X + \mu_X$ e $\tilde{Y} = Y + \mu_Y$. Luego, en el error de medición clásico tenemos que:

$$\begin{aligned} Y &= X\beta + u \\ &= (\tilde{X} - \mu_X)\beta + u \\ &= \tilde{X}\beta + (u - \mu_X\beta) \\ &= \tilde{X}\beta + \tilde{u} \end{aligned}$$

donde $\text{corr}(\tilde{X}, \tilde{u}) \neq 0$ por lo tanto **hay sesgo de estimación**.

8. Multicolinealidad

La **multicolinealidad** aparece cuando las variables explicativas (X) en un modelo econométrico están muy correlacionadas entre sí. Esto tiene efectos negativos para la inferencia sobre los parámetros del modelo por **MCO**. Existen diversas fuentes de la multicolinealidad, como lo puede ser el **método de recolección de información, restricción en el modelo o en la población objetivo de la muestra**, etc.

Consideremos el siguiente modelo:

$$y_i = \beta_1 + \beta_2 x_{2i} + \dots + \beta_k x_{ki} + u_i$$

luego, si $(X'X)$ posee inversa, entonces sabemos que podemos encontrar:

$$\begin{aligned} \hat{\beta}_{MCO} &= (X'X)^{-1} X'Y \\ \text{Var}(\hat{\beta}_{MCO}) &= \sigma^2 (X'X)^{-1} \end{aligned}$$

Ahora bien, si suponemos que se tiene la siguiente relación entre los regresores:

$$x_{ji} = \delta_1 + \delta_2 x_{2i} + \dots + \delta_{j-1} x_{j-1,i} + v_i$$

veremos que la variable x_{ji} puede escribirse aproximadamente como una **combinación lineal** de un grupo de otras variables del modelo. Esto, significa que la variable está muy correlacionada con otras del modelo, y tiene como consecuencia directa que $(X'X)$ será **aproximadamente** singular, es decir, **det = 0**. Luego, al ser la matriz $(X'X)$ **casi** singular, es **muy** pequeña. Como consecuencia, la matriz de varianzas y covarianzas de $\hat{\beta}$ es muy grande, por lo tanto el estimador **MCO** es **poco preciso** en este caso.

De ese modo, debemos distinguir en 2 casos particulares:

- Multicolinealidad **exacta** (perfecta): $(X'X)$ singular con determinante igual a **0**, es decir, no podemos identificar ni las estimaciones ni las varianzas.

- Multicolinealidad **no exacta**: sucede cuando dos variables no son **exactamente** una función de la otra, pero se aproximan a ello. Luego, el $\det(X'X) \neq 0$ pero $\rightarrow 0$, por lo tanto, podemos calcular $\det(X'X)$ pero $(X'X)^{-1}$ va a tomar valores **muy grandes**. Luego, veamos los efectos:

- **Sesgo**:

$$\begin{aligned} E[\hat{\beta}] &= E\left[(X'X)^{-1} X'Y\right] \\ &= E\left[(X'X)^{-1} X'(X\beta + u)\right] \\ &= E\left[\beta + (X'X)^{-1} X'u\right] \\ &= \beta \end{aligned}$$

luego, **no hay efecto en sesgo**.

- **Varianza**: No es difícil mostrar que la varianza **ya no será mínima** (Gauss-Markov), pues $(X'X)^{-1}$ va a tomar valores muy grandes y, por tanto, $V(\hat{\beta}|X) = \sigma^2 (X'X)^{-1}$ será muy grande.

8.1. Formas de «detectar» la multicolinealidad

A menudo, en programaciones (STATA) automáticamente no se detectará la presencia de multicolinealidad, de modo que se deberá «intuir» su presencia en determinados contextos. De este modo, fuentes de detección son:

1. **Buen coeficiente de determinación con pocas variables significativas individualmente**

Esto ocurre cuando vemos que nuestro modelo tiene un R^2 considerablemente alto, pero las variables de ajuste de mi modelo ($\mathbf{x}'s$) **no** son significativas cuando hacemos los ttest individuales para cada uno de sus parámetros (es decir, **no se rechazan las nulas** $H_0 : \beta_i = 0$).

2. **Valor del determinante de la matriz $(X'X)$**

Cuando tenemos determinantes muy chicos (o tendientes a **0**) podemos detectar la presencia de multicolinealidad en nuestro modelo. El argumento recurre a la misma explicación de antes, en el caso en que nos encontramos frente a multicolinealidad **no exacta**.

9. Variables Instrumentales

Como ya sabemos, a esta altura del curso hemos estado constantemente asumiendo que se cumple el supuesto de que en promedio los errores, condicionados en las observables, son 0. Esto es $E(u|\mathbf{X}) = 0$ ó, alternativamente, $E(\mathbf{x}'u) = 0$, es decir, que los errores **no se relacionan** con las $\mathbf{x}'s$. Cuando este supuesto se viola, la estimación a través de **MCO** es inconsistente y, además, es sesgada.

Cuando ocurre la violación de ese supuesto, un método de estimación que nos permite obtener **de manera consistente** el β es el **variables instrumentales (IV)**. Este enfoque, intuitivamente, explota la **existencia de alguna variable** (o instrumento) **exógeno, que afecta al regresor endógeno** (alguna variable z no incluida en el modelo pero que afecta a las $\mathbf{x}'s$) y que **no tiene relación** con los no observables, es decir, los errores u . En ese sentido, este instrumento -para que sea bueno- debe cumplir con 2 propiedades muy importantes:

$$\begin{aligned} E(\mathbf{z}'u) &= 0 \quad (\text{instrumento limpio}) \\ E(\mathbf{z}'x) &\neq 0 \quad (\text{instrumento exógeno}) \end{aligned}$$

De ese modo, si consideramos el siguiente modelo lineal simple:

$$y_i = x_i\beta + u_i$$

y estamos en presencia de endogeneidad (es decir $E(x'_i u_i) \neq 0$) no podemos encontrar una expresión del parámetro poblacional β en función de los momentos poblacionales de las variables observables del modelo. Si ignoramos este problema, lo único que podremos conseguir es una **estimación sesgada de β** .

Luego, supongamos que contamos con otra(s) variable(s) $\mathbf{z}_i$ **excluidas de la ecuación principal** y de igual dimensión que x_i que cumpla con las condiciones señaladas más arriba. Luego, si tenemos:

$$y_i = x_i\beta + u_i$$

y multiplicamos de izquierda a derecha por z'_i tendremos:

$$z'_i y_i = z'_i x_i \beta + z'_i u_i$$

de modo que aplicando valor esperado tenemos la identificación de mi parámetro poblacional (explotando el hecho de que $E(z'_i u) = 0$) :

$$\beta = E(z'_i x_i)^{-1} E(z'_i y_i)$$

luego aplicando el «principio de la analogía» y posteriormente mostrando el estimador en su contexto matricial tenemos que **el estimador de variables instrumentales** es:

$$\hat{\beta}_{\mathbf{VI}} = \left(\frac{1}{n} \sum \mathbf{z}'_i x_i \right)^{-1} \left(\frac{1}{n} \sum \mathbf{z}'_i y_i \right) \equiv (\mathbf{Z}' \mathbf{X})^{-1} \mathbf{Z}' \mathbf{Y}$$

Este caso se denomina «exactamente identificado», ya que en él tenemos igual número de instrumentos que de variables endógenas ($\mathbf{x}$'s). Por esa misma razón, cuando desarrollamos el método, especificamos que estas variables capturadas en $\mathbf{z}$ eran de la **misma dimensión que los $\mathbf{x}$'s**.

9.1. Sobreidentificación: Two Stage Least Squares (2SLS ó MC2E)

En algunos casos dispondremos de más de un instrumento para cada variable endógena de mi modelo, es decir, distintas variables no incluídas en la regresión pero que explican a mix $\mathbf{x}$'s de manera exógena. En este escenario, lógicamente es mejor utilizar múltiples instrumentos ya que se mejoraría la estimación del parámetro que acompaña a la variable endógena. Sin embargo, **el problema** se encuentra en el hecho de que no podemos premultiplicar el modelo por $\mathbf{z}_i$ (como lo hicimos antes) para identificar los β .

Dada la existencia de ese «problema», el método de mínimos cuadrados en 2 etapas (**2SLS**) consiste en resolver 2 regresiones en 2 etapas distintas.

1. **Primera etapa:** Se determina la relación entre los instrumentos $\mathbf{z}_i$ y la variable endógena $\mathbf{x}_i$. Es decir, corre una regresión de x contra z y estima el parámetro que me permite magnificar la afectación que realiza $\mathbf{z}$ sobre $\mathbf{x}$. La estimación consiste en la siguiente regresión:

$$x_i = \mathbf{z}_i \Pi + \varepsilon_i$$

de la que nace $\hat{\Pi}$ y permite obtener $\hat{x}$. Este regresión se denomina «**forma reducida**».

2. **Segunda etapa:** Luego de determinada la relación entre los instrumentos y mi variable endógena, procedemos a correr la regresión de $\mathbf{y}$ en $\mathbf{x}$ para obtener $\hat{\beta}_{\mathbf{2SLS}}$. De ese modo, la regresión corrida es:

$$y_i = \hat{x}_i \beta_i + u_i$$

obteniéndose con ello:

$$\hat{\beta}_{\mathbf{2SLS}} = (\hat{\mathbf{x}}' \hat{\mathbf{x}})^{-1} \hat{\mathbf{x}}' \mathbf{y}$$

9.2. Test de Endogeneidad - Caso exactamente identificado (Hausman)

Si tenemos un modelo del tipo:

$$Y_i = \beta_0 + \beta_1 X_i + u_i$$

Cuando la teoría no nos indica explícitamente si alguna de las variables explicativas es de carácter endógeno, debemos hacer un test de endogeneidad denominado **test de Hausman**. Este test lo que hace es ver si mi variable $\mathbf{X}$ es endógena y presupone que tenemos un instrumento $\mathbf{z}$ en caso de que efectivamente lo sea. De ese modo, las hipótesis a testearse son

$$\begin{aligned} H_0 : \text{cov}(\mathbf{X}_i, u_i) &= 0 \text{ (exógeno)} \\ H_a : \text{cov}(\mathbf{X}_i, u_i) &\neq 0 \text{ (endógeno)} \end{aligned}$$

Además, cuando contamos con un instrumento válido, en la primera etapa tenemos la **forma reducida** del tipo:

$$X_i = \Pi_0 + \Pi_1 Z_i + v_i$$

por lo tanto $\text{cov}(\mathbf{X}_i, u_i) = \text{cov}(\Pi_0 + \Pi_1 Z_i + v_i, u_i) = \text{cov}(v_i, u_i)$. Luego, si la hipótesis nula es verdadera, es decir, si el instrumento es exógeno, deberá cumplirse necesariamente también que $\text{cov}(v_i, u_i) = \mathbf{0}$. Luego, podemos plantear una relación entre los errores de la ecuación estructural y la forma reducida como la que se muestra a continuación:

$$u_i = \alpha v_i + \varepsilon_i$$

Luego, si H_0 es verdadera ocurre que $\alpha = 0$. De ese modo, para hacer el test de endogeneidad, nos focalizaremos en testear:

$$\begin{aligned} H_0 : \alpha &= 0 \\ H_a : \alpha &\neq 0 \end{aligned}$$

Luego, haciendo ambas etapas el test se hará del siguiente modo:

1. Estimamos por **MCO** la primera etapa. Luego obtenemos el vector de estimadores $\hat{\Pi}$. Con ello, por diferencia, obtenemos los errores estimados de la forma reducida:

$$\hat{v}_i = X_i - \left\{ \hat{\Pi}_0 + \hat{\Pi}_1 Z_i \right\}$$

2. Con ello, reemplazamos en la segunda etapa y testeamos:

$$Y_i = \beta_0 + \beta_1 X_i + \alpha \hat{v}_i + \varepsilon_i$$

Estimamos por **MCO** y luego testamos significancia para α . Si rechazamos $H_0 : \alpha = 0$ entonces estamos frente al caso de que la variable explicativa $\mathbf{X}_i$ es endógena y por tanto se requiere la utilización de variables instrumentales.

9.2.1. Generalización a más de 1 variable endógena

Cuando tengo más de un « $\mathbf{x}$ » que sea endógeno, extendiendo el test de hausman a r variables endógenas. Luego, debemos testear r ecuaciones de forma reducida para cada una de las variables endógenas de mi ecuación estructural. De ese modo, obtendremos, para cada una de las formas reducidas, los residuos estimados:

$$\hat{v}_i = X_i - \left\{ \hat{\Pi}_0 + \hat{\Pi}_1 Z_i \right\} \quad ; \forall r$$

Luego, incluimos todos los errores estimados en el modelo según la misma lógica que en el caso de sólo 1 variable endógena, y hacemos un test de significancia conjunta para todos los « α » agregados. El estadístico es:

$$W^0 = n \times \left\{ \frac{SRR - SRC}{SRC} \right\} \sim \chi_r^2$$

que se compara con el tabulado al $(1 - \alpha)$. Si W^0 es mayor, se rechaza la nula de que $H_0 : \alpha_i = 0 \forall i$, de modo que hay endogeneidad en cada una de las r variables de mi modelo.

9.3. Test de Exogeneidad (Sargan)

En la sección 9.2 pudimos ver como realizar un test para detectar si alguna de mis variables del modelo es endógena y, por tanto, si hace falta o no estimar aplicando el método de variables instrumentales. Una cosa que también nos interesará será testear la exogeneidad de mis instrumentos $\mathbf{z}_i$, es decir, si efectivamente cumplen con $E(\mathbf{z}'x) \neq 0$. **Este test sólo aplica cuando estamos en el caso de sobre identificación, es decir, cuando tenemos más instrumentos que variables endógenas en mi modelo.** Los pasos son:

1. Estimamos la forma reducida y obtenemos los residuos estimados:

$$\hat{v}_i = X_i - \left\{ \hat{\Pi}_0 + \hat{\Pi}_1 Z_i \right\}$$

2. Se estima la regresión de los residuos sobre todas las variables exógenas y todos los instrumentos. Obtendremos el R^2 de dicha regresión, el cual llamaremos R_u^2 .
3. Bajo la hipótesis nula de exogeneidad de los instrumentos, el estadístico será el siguiente:

$$nR_u^2 \sim \chi_{(q-r)}^2$$

donde q es el número de instrumentos y r el número de variables endógenas.

4. Finalmente, se compara el estadístico de prueba con una $\chi_{(q-r);(1-\alpha)}^2$. Si el estadístico es mayor, se rechaza la hipótesis nula y, por tanto, los instrumentos **no son exógenos**. Si no se rechaza, los instrumentos **sí lo son**.

10. Heterocedasticidad

Durante muchos pasajes de este apunte hemos estado asumiendo implícitamente el hecho de que hay **homocedasticidad**, es decir, misma varianza de los errores y ausencia de autocorrelación entre ellos. En definitiva, lo que tenemos es que $E(uu') = \sigma^2 \mathbf{I}_N$, lo que en términos matriciales se ve del siguiente modo:

$$E(uu') = \sigma^2 \begin{bmatrix} 1 & 0 & \cdots & \cdots & 0 \\ & 1 & & & \vdots \\ \vdots & & \ddots & & 0 \\ & & & 1 & \vdots \\ 0 & 0 & \cdots & \cdots & 1 \end{bmatrix}$$

La **heterocedasticidad** surge cuando, a pesar de que $Cov(u_i u_j) = 0$ para $i \neq j$, las varianzas para **cada observación** son distintas, es decir, $\mathbf{V}(u_j) = \sigma_j^2$ para $j = 1, \dots, n$. En estos casos, la matriz anterior se observa del siguiente modo:

$$E(uu') = \sigma^2 \mathbf{\Omega} = \begin{bmatrix} \sigma_1^2 & \cdots & 0 \\ & \sigma_2^2 & \vdots \\ \vdots & & \sigma_3^2 & \vdots \\ & & & \sigma_4^2 & \vdots \\ 0 & & & & \sigma_n^2 \end{bmatrix} = \sigma^2 \underbrace{\begin{bmatrix} \omega_1 & \cdots & 0 \\ & \omega_2 & \vdots \\ \vdots & & \omega_3 & \vdots \\ & & & \omega_4 & \vdots \\ 0 & & & & \omega_5 \end{bmatrix}}_{\mathbf{\Omega}}$$

Veremos que la presencia de heterocedasticidad es un problema bastante recurrente, y las explicaciones más comunes sobre su presencia se relacionan a los siguientes ejemplos:

1. En los **modelos de aprendizaje sobre errores**, a medida que las personas aprenden, sus «errores de comportamiento» son menores, por lo que a medida que aumentan las horas de práctica, la varianza de los errores se reduce.
2. A medida que **aumentan los ingresos**, la gente tiene más posibilidades de disponer de parte de ese ingreso de la forma que desee. Así, en una regresión de ahorro contra ingreso, es posible que σ_i^2 aumente en la medida que el ingreso aumenta.
3. Al **omitir variables relevantes**, aparte del sesgo que se genera se produce heterocedasticidad, ya que esta variable estará en el término de error y por lo tanto la varianza dependerá de ella.

10.1. Tests de Heterocedasticidad

Cuando estamos en presencia de heterocedasticidad, el estimador **MCO seguirá siendo insesgado**, sin embargo, **no será de mínima varianza**, por lo tanto la fórmula que aplicábamos anteriormente ya no es válida. En ese sentido, será muy relevante tener mecanismos de detección de este problema que sean fáciles de aplicar. Algunas maneras de detectar son:

1. Patrón gráfico

La forma más «sencilla» de evaluar la presencia de heterocedasticidad consiste en obtener los errores estimados de una regresión ($\hat{\epsilon}_i = Y_i - \mathbf{X}_i\hat{\beta}$) y graficarlos contra las observaciones del modelo ($\mathbf{X}$). Luego, si los puntos se separan mucho del eje horizontal (cuando $\mathbf{X}$ está en **ese eje**), estamos en presencia de heterocedasticidad.

2. Test de Goldfeld-Quandt

Cuando en mis datos puedo distinguir fácilmente entre 2 subgrupos de la muestra, puedo separarla en 2 y correr regresiones para cada uno de los grupos. Luego, para ver si estamos en presencia de heterocedasticidad se puede hacer un test de igualdad de varianzas con un estadístico **F** simple:

$$H_0 : \sigma_{\text{grupo1}}^2 = \sigma_{\text{grupo2}}^2 \text{ (homocedasticidad)}$$

$$H_a : \sigma_{\text{grupo1}}^2 \neq \sigma_{\text{grupo2}}^2 \text{ (heterocedasticidad)}$$

Luego, si tengo una muestra de tamaño n y dividido en dos grupos de tamaño n_1 y n_2 ($n_1 + n_2 = n$) y quiero llevar a cabo el test de **Goldfeld-Quandt** debo realizar los siguientes pasos:

- a) Obtener la varianza muestral de cada una de las muestras, es decir, S_1^2 y S_2^2 (a veces se denominan como $\hat{\sigma}_i^2$).
- b) Construir el estadístico $\mathbf{F}_{obs}$ y calcularlo:

$$\mathbf{F}_c = \frac{\frac{S_1^2}{\sigma_1^2}}{\frac{S_2^2}{\sigma_2^2}} \underset{H_0}{\sim} \frac{\mathbf{SRC}_1 / (n_1 - k)}{\mathbf{SRC}_2 / (n_2 - k)} \equiv \frac{\hat{\sigma}_1^2}{\hat{\sigma}_2^2}$$

- c) Compare con el crítico $\mathbf{F}_{(n_1-k, n_2-k)}^{(1-\alpha)}$ y vea si rechaza o no H_0 . Si se rechaza, hay presencia de **heterocedasticidad**, y si no, hay **homocedasticidad**.

3. Test de Breusch & Pagan

Supongamos que la varianza del término de error de cada observación depende de un vector de variables z_i de dimensión p , es decir, se cumple la siguiente dinámica para la varianza del error del modelo de regresión:

$$\sigma_i^2 = z_i' \alpha = \alpha_0 + \alpha_1 z_{1i} + \alpha_2 z_{2i} + \dots + \alpha_p z_{pi}$$

Luego, no es difícil notar que en un contexto en donde $\alpha_1 = \alpha_2 = \dots = \alpha_p = 0$ tenemos una situación de **homocedasticidad**. De ese modo, el test de Breusch & Pagan lo que hace es testear si esa situación existe o no en la muestra y plantean la siguiente hipótesis nula:

$$H_0 = \alpha_1 = \alpha_2 = \dots = \alpha_p = 0$$

y el test debe aplicarse según los siguientes pasos:

- a) Estima mediante **MCO** el modelo original y obtenga los residuos correspondientes. Esto es:

$$\hat{u} = y - \mathbf{x}\hat{\beta}$$

- b) Obtenemos la serie de residuos normalizados al cuadrado. Esto es, para **cada observación** $i = 1, \dots, n$ tenemos:

$$\hat{\epsilon}_i^2 = \frac{\hat{u}_i^2}{\hat{\sigma}_{\mathbf{u}}^2}$$

$$\text{donde } \hat{\sigma}_{\mathbf{u}}^2 = \frac{\sum_{i=1}^n \hat{u}_i^2}{n}.$$

- c) Se estima una regresión de $\hat{\epsilon}_i^2$ sobre una constante y las variables $z_{1i}, z_{2i}, \dots, z_{pi}$ y se obtiene la suma explicada (**ESS**) de dicha regresión.
- d) Luego, bajo la hipótesis nula de Homocedasticidad y dado el supuesto de normalidad del término de error, la razón $\frac{\text{ESS}}{2}$ se distribuye χ_p^2 , con p número de regresores menos la constante de la regresión corrida en el punto (c). Luego, si $\frac{\text{ESS}}{2} > \chi_{(p), 1-\alpha}^2$ se rechaza H_0 de **homocedasticidad** en favor de **heterocedasticidad**.

4. Test de White

En presencia de heterocedasticidad, White (1980) ha propuesto una aproximación a la matriz de covarianzas del estimador **MCO**:

$$\mathbf{V}[\hat{\beta}|\mathbf{x}] = (\mathbf{x}'\mathbf{x})^{-1} (\mathbf{x}'\sigma^2\Omega\mathbf{x}) (\mathbf{x}'\mathbf{x})^{-1}$$

donde $\sigma^2\Omega$ representa la matriz de varianzas y covarianzas en el caso heterocedástico (note que si $\sigma^2\Omega = \sigma^2\mathbf{I}$ estamos en el caso de homocedasticidad y si reemplazamos esa expresión en la varianza del estimador **MCO** tenemos $\mathbf{V}[\hat{\beta}|\mathbf{x}] = \sigma^2 (\mathbf{x}'\mathbf{x})^{-1}$ que es la varianza ya conocida cuando no hay heterocedasticidad). Luego, se define:

$$\begin{aligned}\Sigma &= \sigma^2 \mathbf{x}'\Omega\mathbf{x} \\ &= \sum_{i=1}^n \sigma_i^2 \mathbf{x}_i \mathbf{x}_i'\end{aligned}$$

estimándose de la siguiente manera:

$$\hat{\Sigma} = \sum_{i=1}^n \hat{u}_i^2 \mathbf{x}_i \mathbf{x}_i'$$

y, además, White demuestra que esta es una estimación consistente, es decir, $\hat{\Sigma} \xrightarrow{P} \Sigma$ (insesgada en el límite). Luego, una estimación consistente de la matriz de varianzas y covarianzas en el caso de heterocedasticidad es:

$$\mathbf{V}[\hat{\beta}|\mathbf{x}] = (\mathbf{x}'\mathbf{x})^{-1} \hat{\Sigma} (\mathbf{x}'\mathbf{x})^{-1}$$

y su comparación con $\sigma^2 (\mathbf{x}'\mathbf{x})^{-1}$ nos entregará el **grado de heterocedasticidad** que hay en mi modelo de regresión. Esta estimación de White es un resultado muy útil, ya que **no se necesita saber la naturaleza de la Heterocedasticidad** (como por ejemplo si ocurre en el caso del **Test de Breusch & Pagan**). Los pasos para resolver el test son los siguientes, considerando un modelo del tipo:

$$y_i = \beta_0 + \beta_1 x_i + \beta_2 z_i + u_i$$

- Obtenga las estimaciones $\hat{\beta}$ y los residuos de la estimación del modelo anterior por **MCO**. Esto es: $\{\hat{u}_i\}_{i=1}^n$.
- Corra una regresión de $\hat{u}_i^2$ sobre **una constante**, x_i , z_i , x_i^2 , z_i^2 y $x_i z_i$, es decir, sobre todas las combinaciones que se puedan extraer del modelo anterior.
- Compute el nR^2 de la regresión anterior (este será nuestro estadístico).
- Para un nivel de significancia escogido, compare el estadístico anterior con el valor crítico de una chi cuadrado con $J - 1$ grados de libertad, donde J es el número de regresores de la regresión auxiliar (punto (b)), es decir, en este caso $J = 6$ por lo tanto los grados de libertad de la chi deben ser **5**.
- Finalmente, si $nR^2 > \chi_{J-1; (1-\alpha)}^2$ se rechaza la hipótesis nula de homocedasticidad en favor de la de heterocedasticidad. Esto sugeriría llevar a cabo la **corrección de White**, es decir, considerar que la matriz de varianzas y covarianzas de la estimación por **MCO** es:

$$\mathbf{V}[\hat{\beta}|\mathbf{x}] = (\mathbf{x}'\mathbf{x})^{-1} \hat{\Sigma} (\mathbf{x}'\mathbf{x})^{-1}$$

para solucionar el problema de la heterocedasticidad en la inferencia sobre los parámetros. Otra forma de solucionar es **mínimos cuadrados ponderados**, sin embargo, es muy difícil encontrar la forma exacta de la heterocedasticidad, por lo que no es una corrección muy plausible. En la práctica, la corrección de White (que no necesita saber esa forma exacta) es la más utilizada.

11. Autocorrelación de errores

La autocorrelación de errores ocurre cuando no se cumple que la covarianza entre los errores de mi modelo de regresión es **0**, es decir, rompemos el supuesto **5**, es decir:

$$\text{cov}(u_i u_j) \neq 0$$

Este fenómeno ocurre mucho en series de tiempo, y tiene una implicancia directa en la matriz de varianzas y covarianzas de los errores. Asumiendo $\mathbf{v}(u_i) = \sigma^2 \forall_i$, lo que tendremos al obtener la matriz de varianzas y covarianzas **no será una matriz diagonal** (como lo era en el caso de homo y heterocedasticidad), sino una que dependa del grado de correlación entre los errores. Esto es:

$$E(uu') = \begin{bmatrix} \sigma^2 & \sigma_{12} & \sigma_{13} & \dots & \sigma_{1T} \\ \sigma_{21} & \sigma^2 & & & \\ \sigma_{31} & & \sigma^2 & & \vdots \\ \vdots & & & \sigma^2 & \\ \sigma_{T1} & \sigma_{T2} & \dots & \dots & \sigma^2 \end{bmatrix}$$

donde $\sigma_{T,Q}$ es $\text{cov}(u_T, u_Q)$. En estos casos, si bien la estimación **MCO** continuará siendo insesgada, ya no tendrá la matriz de varianzas y covarianzas mínima. Luego, el estimador ya no será **MELI** (Gauss-Markov).

La autocorrelación de errores puede tomar distintas formas funcionales, dependiendo del proceso **AR** que siga (proceso auto regresivo), que puede ser de **distintos ordenes**:

$$\mathbf{AR}(1) \rightarrow u_t = \rho u_{t-1} + \varepsilon_t$$

$$\mathbf{AR}(2) \rightarrow u_t = \rho_1 u_{t-1} + \rho_2 u_{t-2} + \varepsilon_t$$

$$\vdots$$

$$\mathbf{AR}(n) \rightarrow u_t = \sum_{i=1}^n \rho_i u_{t-i} + \varepsilon_t$$

donde ε_t es un **nuevo error** que distribuye **iid** $(0, \sigma_\varepsilon^2)$.¹

¹En este curso nos focalizamos en **AR(1)**.

11.1. Efectos de AR(1)

La autocorrelación de orden 1 establece que el componente de error de mi regresión covaría según un proceso auto regresivo de un sólo período hacia atrás, es decir:

$$u_t = \rho u_{t-1} + \varepsilon_t$$

Luego, suponiendo que la autocorrelación cumple con $|p| < 1$, $E(\varepsilon_t) = 0$, $\mathbf{v}(\varepsilon_t) = \sigma_\varepsilon^2$ y $\mathbf{cov}(\varepsilon_t, \varepsilon_{t-1}) = 0$ tendremos implicancias del tipo:

$$\begin{aligned} u_t &= \rho u_{t-1} + \varepsilon_t \\ u_{t-1} &= \rho u_{t-2} + \varepsilon_{t-1} \\ u_{t-1} &= \rho u_{t-3} + \varepsilon_{t-2} \end{aligned}$$

y resolviendo iterativamente tenemos una expresión general para u_t que será:

$$u_t = \sum_{i=0}^{\infty} \rho^i \varepsilon_{t-i}$$

Luego, veamos la parametrización de este nuevo error:

1. **Esperanza:**

$$\mathbf{E}(u_t) = \mathbf{E}\left\{\sum_{i=0}^{\infty} \rho^i \varepsilon_{t-i}\right\} \rightarrow \sum_{i=0}^{\infty} \rho^i \mathbf{E}[\varepsilon_{t-i}] = 0$$

2. **Varianza:**

$$\mathbf{V}[u_t] = E[u_t - \mathbf{E}(u_t)]^2 = E[u_t]^2$$

dado que como vimos en el punto (1) se sigue cumpliendo que $\mathbf{E}(u_t) = 0$. Luego, tenemos:

$$\mathbf{V}[u_t] = \mathbf{E}\left[\sum_{i=0}^{\infty} \rho^i \varepsilon_{t-i} \sum_{i=0}^{\infty} \rho^i \varepsilon_{t-i}\right] \xrightarrow{[\dots]} \frac{\sigma_\varepsilon^2}{1 + \rho^2} = \sigma_u^2$$

que es homocedástico, es decir, a pesar de que hay autocorrelación, los errores tienen la misma varianza $\sigma_u^2 = \frac{\sigma_\varepsilon^2}{1+\rho^2}$.

3. **Covarianzas:**

$$\begin{aligned} \mathbf{cov}(u_t, u_{t-1}) &= E[(u_t - E[u_t])(u_{t-1} - E[u_{t-1}])] \\ &= E[u_t u_{t-1}] \\ &= E\left[\sum_{i=0}^{\infty} \rho^i \varepsilon_{t-i} \cdot \sum_{i=0}^{\infty} \rho^i \varepsilon_{t-1-i}\right] \\ &= \rho \sigma_u^2 \\ \mathbf{cov}(u_{t-1}, u_{t-2}) &= \rho^2 \sigma_u^2 \\ \mathbf{cov}(u_t, u_{t-k}) &= \rho^k \sigma_u^2 \end{aligned}$$

De ese modo, tenemos que la nueva matriz de varianzas y covarianzas de los errores se puede representar del siguiente modo:

$$E[uu'] = \sigma_u^2 \begin{bmatrix} 1 & \rho & \rho^2 & \dots & \rho^{T-1} \\ \rho & 1 & & & \\ \rho^2 & & 1 & & \vdots \\ \vdots & & & 1 & \\ \rho^{T-1} & \dots & & & 1 \end{bmatrix} = \sigma_u^2 \Omega$$

siendo $\mathbf{T}$ el último período en evaluación.

11.2. Causas de la autocorrelación

La autocorrelación en el término de error puede ser producida por varios factores:

1. **Inercia por existencia de ciclos y tendencias:** Si la autocorrelación es positiva (es decir, $\rho > 0$), un valor alto de u_t que genera un valor de y_t por sobre su media condicional, tendrá una probabilidad elevada de ir seguido por un valor alto de u_{t+1} , y por ello un valor alto de y_{t+1} por encima del promedio. Lo contrario ocurre cuando tenemos $\rho < 0$, con valores de y_t bajo su media condicional.
2. **Variables omitidas:** Omisión de variables relevantes y de relaciones dinámicas serán incorporadas en el término de error, causando posible autocorrelación. En vistas de eso, un comentario importante a tener siempre en cuenta es que si estamos encontrando autocorrelación en nuestros residuos, es lógico que debamos revisar el modelo, ya que el error puede estar captando información relevante que estamos omitiendo.

11.3. Test de autocorrelación

Test de Durbin-Watson

Un test muy popular para detectar la autocorrelación de los residuos en su forma **AR(1)** es el test de Durbin-Watson (**d**), donde dado **AR(1)** estaremos testeando si estamos frente a un error cuya dinámica es del tipo $u_t = \rho u_{t-1} + \varepsilon_t$ o no, donde ε es un ruido blanco con media 0 y varianza constante.

En este tipo de test la hipótesis nula corresponde a **no autocorrelación** y la alternativa a **autocorrelación**, es decir,

$$H_0 : \rho = 0$$

$$H_1 : \rho \neq 0$$


y el estadístico se define como:

$$\begin{aligned} \mathbf{d} &= \frac{\sum_{t=2}^n (\hat{u}_t - \hat{u}_{t-1})^2}{\sum_{t=1}^n \hat{u}_t^2} \\ &= \frac{\sum_{t=2}^n \hat{u}_t^2 + \sum_{t=2}^n \hat{u}_{t-1}^2 - 2 \sum_{t=2}^n \hat{u}_t \hat{u}_{t-1}}{\sum_{t=1}^n \hat{u}_t^2} \\ &\approx 2 - 2 \frac{\sum_{t=2}^n \hat{u}_t \hat{u}_{t-1}}{\sum_{t=1}^n \hat{u}_t^2} \equiv 2 - 2\hat{\rho} = 2(1 - \hat{\rho}) \end{aligned}$$

donde $\hat{\rho} = \frac{\sum_{t=2}^n \hat{u}_t \hat{u}_{t-1}}{\sum_{t=1}^n \hat{u}_t^2}$. Luego, las reglas son las siguientes:

1. Si $\rho = 0 \rightarrow \mathbf{d} = 2$: No hay autocorrelación.
2. Si $\rho = -1 \rightarrow \mathbf{d} = 4$: Autocorrelación negativa.
3. Si $\rho = 1 \rightarrow \mathbf{d} = 0$: Autocorrelación positiva.

Luego, el estadístico **d** es intuitivo pero tiene un problema estadístico, ya que su distribución no es estándar y los valores críticos depende de la base de datos que se use. Sin embargo, Durbin & Watson resuelven este problema encontrando **cotas para las zonas de rechazo**. Sin embargo, existen **zonas de indefinición**, en donde no podemos rechazar o no rechazar.



Luego:

- Si $d > 4 - dl$ se rechaza la nula en favor de autocorrelación negativa.
- Si $d < dl$ se rechaza la nula a favor de autocorrelación positiva.
- Si $d_u < d < 4 - d_u$ no se rechaza la nula.
- Si $d_l < d < d_u$ ó $4 - d_u < d < 4 - d_l$ es inconclusivo el test.

Los valores de la zona crítica (d_u y d_l) se obtienen de la tabla de Durbin-Watson, y dependen del tamaño muestral, el número de regresores y el nivel de significancia.

Test de Breusch-Godfrey

Este test sirve para testear autocorrelaciones de orden mayor a **AR(1)**, donde se supone conocido el orden n de la autocorrelación. Para efectos prácticos de mostrar este test, supondremos **T** como el tamaño de la muestra. En estos casos tenemos:

$$u_t = \rho_1 u_{t-1} + \rho_2 u_{t-2} + \dots + \rho_n u_{t-n} + \epsilon_t$$

Luego, el test **BG** evalúa la significancia conjunta, es decir:

$$H_o : \rho_1 = \rho_2 = \dots = \rho_n$$

Los pasos para realizar este test son:

1. Estimar el modelo por **MCO** y obtener los residuos $\hat{u}_t$. El modelo, además, puede incluir rezagos de la variable dependiente, por ej. $\mathbf{X}_{t-1}$, etc.
2. Estimar una **regresión auxiliar** de $\hat{u}_t$ sobre todos los rezagos, incluyendo las variables exógenas del modelo original.
3. Obtener el R^2 de esa regresión, al cual llamaremos R_u^2 .
4. Finalmente, estadístico de prueba es $(T - n) R_u^2 \sim \chi_{(n)}^2$ y comparamos según las mismas reglas señaladas anteriormente para este tipo de tests. Recordar que la nula es la de **no-autocorrelación**, de modo que si rechazamos H_o (crítico > tabulado) estamos en presencia de **AR(n)**.

11.4. Solución a la autocorrelación

El método de **Cochrane-Orcutt** pertenece a la clase de estimadores de mínimos cuadrados generalizados (factibles) cuando el error es **AR(1)**. Este estimador es **MELI** si se cumplen los supuestos respecto de la estructura del error. Además, su implementación es simple y muy intuitiva.

Supongamos tenemos el siguiente modelo de regresión lineal y la siguiente estructura de los errores:

$$\begin{aligned}y_t &= x_t\beta + u_t \\ u_t &= \rho u_{t-1} + \epsilon_t\end{aligned}$$

Luego, si rezagamos la ecuación principal y le restamos a esta misma el modelo transformado es de la siguiente forma:

$$\underbrace{y_t - \rho y_{t-1}}_{y_t^*} = \underbrace{(x_t - \rho x_{t-1})}_{x_t^*} \beta + \underbrace{u_t - \rho u_{t-1}}_{\varepsilon_t}$$

luego:

$$y_t^* = x_t^* \beta + \varepsilon_t$$

donde $t = 2, \dots, T$. **Note que en esta ecuación transformada hemos «eliminado» la primera observación.** Luego, el método de **C-O** es un método «iterativo» para obtener la estimación de β y ρ , y los pasos son los siguientes:

1. Estimar por mínimos cuadrados ordinarios la regresión de interés, ignorando la presencia (conocida) de autocorrelación de primer orden en el término de error.
2. Utilizar los residuos **MCO** para estimar el parámetro $\rho \rightarrow \hat{\rho}$. Esto puede hacerse mediante una regresión de $\hat{u}_t$ contra $\hat{u}_{t-1}$.
3. Utilizar este parámetro $\hat{\rho}$ para transformar las variables y obtener y_t^* y x_t^* (perdiendo una observación).
4. Estimar por **MCO** un modelo con las variables transformadas, para obtener un **nuevo** vector de coeficientes β .
5. Utilizar esta nueva estimación para computar otro vector de residuos, y utilizar estos residuos para obtener una **nueva** estimación de ρ .
6. Repetir este procedimiento hasta que los β converjan entre sí, lo que sucede cuando la diferencia entre el vector de parámetros β difiere infinitesimalmente del β obtenido en la vuelta anterior.

12. Ejercicios: Prueba 1

Ejercicio 1

Suponga que existe un modelo poblacional que cumple con todos los supuestos exigidos por **MCO**, el cual adopta la siguiente forma funcional:

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + u_i$$

A partir de los siguientes antecedentes:

$$X'X = \begin{pmatrix} 14 & 7 & 14 \\ 7 & 4,5 & 7 \\ 14 & 7 & 15 \end{pmatrix}$$

$$X'Y = \begin{pmatrix} 10 \\ 6 \\ 12 \end{pmatrix}$$

$$Y'Y = 14$$

$$(X'X)^{-1} = \begin{pmatrix} 1,3214 & -0,5 & -1 \\ -0,5 & 1 & 0 \\ -1 & 0 & 1 \end{pmatrix}$$

Se pide:

1. Estimar los coeficientes del modelo por **MCO**, y calcule el coeficiente de determinación o R^2
2. Calcule $Var(\hat{\beta}|\mathbf{X})$
3. Evalúe formalmente la hipótesis nula de que $\beta_1 = 1,5$. Considere un nivel de significancia del 5 %.
4. Construya un intervalo de confianza bilateral para β_2 al 95 % confianza.

Ejercicio 2

Suponga que existe un modelo poblacional que cumple con todos los supuestos exigidos por **MCO**, el cual adopta la siguiente forma funcional:

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + u_i$$

A partir de los siguientes antecedentes:

$$\begin{aligned} \sum X_{1i} &= 100 ; \sum X_{2i} = 24 ; \sum Y_i = 5 \\ \sum X_{1i}Y_i &= -255 ; \sum X_{2i}Y_i = 146 ; \sum X_{1i}X_{2i} = 100 \\ \sum X_{1i}^2 &= 680 ; \sum X_{2i}^2 = 48,8 ; \sum (Y_i - \bar{Y})^2 = 1200 \end{aligned}$$

Además, se sabe que $n = 20$. Luego, compruebe que:

$$1. X'X = \begin{pmatrix} 20 & 100 & 24 \\ 100 & 680 & 100 \\ 24 & 100 & 48,8 \end{pmatrix} \text{ y } (X'Y) = \begin{pmatrix} 5 \\ -255 \\ 146 \end{pmatrix}.$$

$$2. \text{ Sabiendo que } (X'X)^{-1} = \begin{pmatrix} 0,36225 & -0,03875 & -0,09875 \\ -0,03875 & 0,00625 & 0,00625 \\ -0,09875 & 0,00625 & 0,05625 \end{pmatrix} \text{ demuestre que la estimación por}$$

$$\text{MCO de los parámetros es } \hat{\beta} = \begin{bmatrix} -2,725 \\ -0,875 \\ 6,125 \end{bmatrix}$$

3. Finalmente, demuestre que $SCR = 97,5$ y, por tanto, que el $R^2 = 0,91875$.

Ejercicio 3

Sea $\hat{\beta}$ el estimador **MCO** de la regresión de y sobre X , y sea $\mathbf{A}$ una matriz no singular de dimensión $(k+1) \times (k+1)$. Defina entonces a la matriz $\mathbf{Z}$ de dimensión $n \times (k+1)$ tal que $\mathbf{Z} = \mathbf{XA}$.

1. Entregue una expresión para estimador **MCO** de la regresión de y sobre $\mathbf{Z}$ (llámelo $\tilde{\beta}$), y muestre la relación que existe entre éste y $\hat{\beta}$.
2. ¿Cómo se comparan los residuos de la regresión original con los residuos de la regresión de y sobre $\mathbf{Z}$? Justifique su respuesta.
3. Ahora resuelta para $\mathbb{E}(\tilde{\beta}|X)$ y luego para $V(\tilde{\beta}|X)$ en términos de $\mathbf{A}$, $\mathbf{X}$, y cualquier otro parámetro relevante.

Ayuda: Recuerde que $\mathbb{E}(\hat{\beta}|X) = \beta$ y que $V(\hat{\beta}|X) = \sigma^2(X'X)^{-1}$.

Ejercicio 4

Considere el siguiente modelo de regresión lineal:

$$cog_i = \beta_1 + \beta_2 exposure_i + \beta_3 child - age_i + \beta_4 educ - high_i + u_i$$

donde cog_i es una medida de habilidades cognitivas del niño i , $exposure_i$ una variable que mide las semanas de exposición del niño i a un tratamiento de estimulación temprana, $child - age_i$ mide la edad del niño i en semanas y $educ - high_i$ es una variable que toma el valor **1** si la madre tiene alta educación y **0** si no. Se dispone de una muestra de 3.387 niños. En el cuadro N°1 se presentan los resultados de la estimación por **MCO** de los parámetros del modelo recién descrito.

. reg cog exposure child_age educ_high						
Source	SS	df	MS	Number of obs	=	3,387
Model	72.2146286	3	24.0715429	F(3, 3383)	=	31.21
Residual	2608.88231	3,383	.771174198	Prob > F	=	0.0000
				R-squared	=	0.0269
				Adj R-squared	=	0.0261
Total	2681.09694	3,386	.791818352	Root MSE	=	.87817

cog	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]
exposure	.0169471	.0065843	2.57	0.010	.0040375 .0298567
child_age	.0063511	.0010603	5.99	0.000	.0042722 .0084301
educ_high	.2409622	.0320614	7.52	0.000	.1781005 .3038239
_cons	-.2725565	.0540646	-5.04	0.000	-.378559 -.166554

1. Interprete cada parámetro del modelo recién planteado. Refiérase al signo (esperado y efectivo) y significancia de cada uno de ellos. ¿Tiene efectividad el tratamiento de estimulación temprana?
2. Testee la siguiente hipótesis nula $H_0 : \beta_2 = 0,03$ a dos colas con nivel de significancia $\alpha = 5\%$.
3. Una amiga le indice que los niños mayores tienen más habilidades cognitivas y que el efecto de una semana adicional de “tratamiento” equivale al efecto de tres semanas más de vida, en términos de aumentos en habilidades cognitivas. ¿A qué se refiere su amiga? Testee estadísticamente la hipótesis planteada por su amiga con $\alpha = 5\%$. Ayuda: suponga que la covarianza entre $exposure$ y $child - age$ es igual a 0.

13. Ejercicios: Prueba 2

13.1. Predicción

Suponga un modelo de regresión lineal $y = \beta_1 + \beta_2 x_2 + \beta_3 x_3 + u$ donde y corresponde al puntaje SIMCE del estudiante, $x_1 = 1$, x_2 al ingreso familiar per cápita y x_3 al ratio alumno profesor. Suponga que u satisface los teoremas de Gauss-Markov. Ud está interesado en predecir los efectos de una reforma educacional que reducirá el número de alumnos por profesor.

1. Explique en detalle cómo predecir el valor puntual del SIMCE si x_2 toma el valor x_2^0 y x_3 toma el valor x_3^0 una vez implementada la reforma. ¿Bajo qué condiciones el error de predicción tiene valor esperado igual a 0?
2. Encuentre una expresión para la varianza del error de predicción. ¿Qué ocurre con dicha varianza en la medida que los valores x_1^0 y x_2^0 son muy grandes?
3. Suponga que $\hat{\beta}_1 = 240$, $\hat{\beta}_2 = 0,1$ y $\hat{\beta}_3 = -1$. Haga una predicción para y^0 si $x_2^0 = 500$ y $x_3^0 = 30$, calcule la varianza del error de predicción y construya un intervalo de confianza al 95 %. Suponga que $\hat{\sigma}_u^2 = 0,5$ y que:

$$(X'X) = \begin{bmatrix} 10 & 0 & 0 \\ 0 & 10000 & 0 \\ 0 & 0 & 500 \end{bmatrix}$$

Note que la información sobre el tamaño muestral está contenida en la matriz y use $t_{0,975}^7 = 2,37$, $t_{0,975}^8 = 2,31$, $t_{0,975}^9 = 2,26$, $t_{0,975}^{10} = 2,2$

4. ¿Qué ocurre con el valor de su predicción en la letra c) si la reforma logra reducir el ratio profesor alumno a 20 y el ingreso familiar per cápita promedio se mantiene constante en 500?

13.2. Hipótesis múltiple

Se tiene la siguiente ecuación sobre el consumo de acero en Chile, estimada con datos que van desde 1970 a 2003:

$$\ln(C_t) = -2,3 + 3,1\ln(PIB_t) - 2,6\ln(PIB_{t-1}) + 0,6\ln(C_{t-1})$$

donde C_i representa el consumo de acero en el periodo i y PIB_i representa el producto agregado de la economía en pesos del año 1995 en el año i .

La matriz **estimada** de varianzas y covarianzas de los estimadores es la siguiente:

$$\begin{bmatrix} 0,77 & 0,06 & -0,18 & 0,07 \\ 0,06 & 0,14 & -0,15 & 0,006 \\ -0,18 & -0,15 & 1,69 & -0,02 \\ 0,07 & 0,006 & -0,02 & 0,01 \end{bmatrix}$$

Por otro lado, se sabe que $u'u = 0,4$ (suma de cuadrados residuales). En vistas de la anterior información, se le pide que conteste lo siguiente:

1. Examine la hipótesis de que el efecto del PIB del año t y el del año $t - 1$ son ambos iguales a 0.
2. Examine la hipótesis de que la suma de los coeficientes, excluyendo la constante, es igual a 1.

13.3. Aplicaciones cortas

1. Con el objetivo de determinar si existen o no diferencias en las calificaciones obtenidas por hombres y mujeres en el curso de Econometría I en la Pontificia Universidad Católica de Chile, a partir de 20 observaciones se estimó el siguiente modelo:

$$nota_t = \beta_0 + \beta_1 NotamediaECON_t + \beta_2 Género_t + u_t$$

donde la variable *género* toma el valor 1 si se trata de una mujer y 0 si se trata de un hombre (es una *dummie*). Los resultados de la estimación fueron los siguientes:

$$\widehat{nota}_t = \underset{(4,5)}{25} + \underset{(7,1)}{0,75} NotamediaECON_t + \underset{(2,3)}{20,5} Género_t + u_t$$

donde los paréntesis bajo las estimaciones muestran la desviación estándar de cada una de estas. En vistas de lo anteriormente expuesto, ¿Puede decirse que los resultados entre hombres y mujeres son distintos?

2. En el modelo de regresión lineal múltiple $Y_t = \beta_1 + \beta_2 X_{2t} + \beta_3 X_{3t} + \beta_4 X_{4t} + u_t$ se verifica que $X_{2t} = 3X_{4t}$. Indique qué parámetros son estimables:
 - a) Cuando no se dispone de información a priori sobre los coeficientes que acompañan a las explicativas.
 - b) Cuando se sabe que $\beta_4 = 2$.
3. Para estimar el modelo $Y_t = \beta_1 + \beta_2 X_{2t} + \beta_3 X_{3t} + u_t$ se ha obtenido una muestra de la cual ha resultado lo siguiente:

$$X'X = \begin{pmatrix} 14 & 7 & 14 \\ 7 & 4,5 & 7 \\ 14 & 7 & 15 \end{pmatrix} \rightarrow (X'X)^{-1} = \begin{pmatrix} 1,3214 & -0,5 & -1 \\ -0,5 & 1 & 0 \\ -1 & 0 & 1 \end{pmatrix}$$

$$X'Y = \begin{pmatrix} 10 \\ 6 \\ 12 \end{pmatrix}$$

- a) Estime los coeficientes del modelo por MCO
- b) Estudie la significación del modelo con un test F.

Hint: Recuerde que en estos casos se puede corroborar que el test queda del siguiente modo: $F = \frac{ESS/(k-1)}{RSS/(n-k)} \sim F_{(k-1, n-k)}$ o, alternativamente -utilizando el R^2 :- $F = \frac{R^2/(k-1)}{(1-R^2)/(n-k)} \sim F_{(k-1, n-k)}$

- c) Contraste la hipótesis $\beta_2 - \beta_3 = -1$
- d) Calcular el intervalo de predicción al 95 % para Y sabiendo que $X_2 = 5$ y $X_3 = 7$.

13.4. Sobre estimación, hipótesis múltiple e intervalos de predicción.

A través de un muestreo de tamaño $n = 12$ se ha querido estimar el siguiente modelo $Y_t = \beta_1 + \beta_2 v_t + \beta_3 w_t + u_t$. Luego de estimado, se tienen los siguientes datos:

$$(X'X)^{-1} = \begin{pmatrix} 0,6477 & -0,041 & -0,0639 \\ -0,041 & 0,0071 & -0,0011 \\ -0,0639 & -0,0011 & 0,0152 \end{pmatrix}$$

$$X'Y = \begin{pmatrix} 91 \\ 699 \\ 448 \end{pmatrix}$$

$$TSS = 104,9167$$

Utilizando lo entregado, se le pide lo siguiente:

1. Estime el modelo por el método MCO y calcule el coeficiente de determinación del modelo R^2 . Recuerde que la suma explicada por el modelo (ESS) se puede obtener a través de una fórmula alternativa:

$$ESS = \hat{\beta}' \cdot X'Y - n\bar{Y}^2$$

lo que se puede demostrar desarrollando su versión tradicional vista en clases.

2. Realice un contraste de significación para $\beta_2 + \beta_3 = 1$.
3. Intervalo de predicción para $E(Y)$ sabiendo que $v_0 = 2,5$ y $w_0 = -0,3$

13.5. Trabajando con variables *dummy*

Existe presunción en nuestra Facultad de que los alumnos egresados de la mención de Administración en la carrera de Ingeniería Comercial tienen un mayor salario que aquellos que deciden irse por la mención de Economía.

1. Plantee un modelo que permita testear esa hipótesis. Explique de la manera más explícita posible como la testearía.
2. Plantee un modelo que además permita testear que dicha diferencia entre menciones no es igual entre universidades (Considere sólo las dos universidades más importantes del país: Universidad Católica y Universidad de Chile). Explique detalladamente como lo haría.

13.6. Comentes

1. En una prueba de hipótesis cualquiera, la zona de rechazo nunca cambia al cambiar la hipótesis nula. Comente
2. El método de mínimos cuadrados descansa fuertemente en el supuesto de normalidad del término de error. Luego, el estimador MCO, $\hat{\beta} = (X'X)^{-1}X'Y$ se obtiene solamente bajo errores normales.
3. La omisión de una variable relevante siempre subestima el verdadero valor del β y su varianza. Comente.

14. Ejercicios: Examen

14.1. Comentes

1. Sin duda alguna, el error de medida aumenta la probabilidad de cometer error tipo II.
2. En cambio, la multicolinealidad aumentará la probabilidad de cometer error tipo I.
3. El método de Cochrane-Orcutt sirve para obtener un estimador eficiente cuando estamos en presencia de autocorrelación.
4. La heterocedasticidad es un fenómeno menor, dado que no produce inconsistencia en los parámetros.
5. Breusch y Godfrey proponen un test similar al de Durbin y Watson, luego no hay mucha ganancia en elegir uno en lugar de otro.
6. El test de Breusch y Pagan es idéntico al de White, luego uno esperaría que arrojará las mismas conclusiones en términos de rechazo o no rechazo de la hipótesis nula de ausencia de autocorrelación.
7. La utilización de la matriz de White permite corregir el problema de heterocedasticidad sin saber a priori la especificación de esta.

14.2. Ejercicio 1

Sir Francis Galton (1822-1911), un antropólogo y primo de Charles Darwin, creó el término *Regresión a la mediocridad en estatura hereditaria*, Galton comparó la altura de los hijos con la de sus padres, usando una muestra de 930 hijos y 205 parejas. En esencia, el encontró que padres altos (bajos) tienen hijos altos (bajos), pero que los niños no serán tan altos (bajos) como sus padres, en promedio. Luego, habría lo que conocemos como **regresión a la media**, o como Galton se refirió, regresión a la mediocridad. Este resultado es una falacia si se intenta inferir este comportamiento a lo largo del tiempo. Si fuera verdad, la varianza de la altura en humanos hubiese disminuido de generación en generación y ese no es el caso.

1. Para investigar acerca de este resultado, Ud. junta datos de estudiantes universitarios y sus padres y estima la siguiente relación:

$$A_e = 0,5 + 0,7 \times A_p, \quad R^2 = 0,45, \quad n = 1000$$

(0,7) (0,32)

donde A_e es la altura del estudiante medida en centímetros y A_p es la altura del padre del estudiante. Los valores entre paréntesis son los errores estándar corregidos por heterocedasticidad. Haga un gráfico con esta línea de regresión junto con una línea de 45 grados y explique por qué el resultado encontrado arriba sugiere **regresión a la media**.

2. Investigando la literatura médica Ud. encuentre que la altura depende, en una proporción importantísima, de un gen llamado «phog» y de factores ambientales. Suponga la altura del hijo(a) está determinada por el padre y que padre e hijo(a) tienen exactamente el mismo gen el cual no cambia en el tiempo y que la altura es medida con error de la siguiente manera:

$$X_{i,h} = f(X_i) + \nu_{i,h} \quad \wedge \quad X_{i,p} = f(X_i) + u_{i,p}$$

donde $X_{i,h}$ es la medida de la altura del hijo h que tiene un gen X_i y los factores ambientales están dados por $\nu_{i,j}$ para el hijo y $u_{i,p}$ para el padre. La estatura medida del padre está dada por $X_{i,p}$. Considere que los factores medioambientales son independientes el uno del otro y además son independientes del gen. Combinando las dos ecuaciones, encuentre una función de regresión poblacional (que relacione altura del hijo y la del padre) y discuta su relación con la «falacia de Galton».

3. ¿Cómo testearía las dos restricciones implícitas en la función de regresión poblacional encontrada en 2)? ¿A la luz de lo que encontró en sus estimaciones en 1), como testearía si estas restricciones se cumplen o no?

14.3. Ejercicio 2

Suponga que Ud. trabaja en una empresa del sector financiero y está interesada en estimar el impacto de una campaña de tasas de interés reducidas en el *gross dollar volume* (**GDV**) de las tarjetas de créditos emitidas. Suponga que cuenta con variables de los **tarjetahabientes** como ingresos y una variable dummy d_i , que indica si el o la tarjetahabiente i recibió la promoción o no. Por ahora Ud. desconoce los criterios de asignación de la promoción. Una colega le plantea estimar el siguiente modelo lineal:

$$\ln(\mathbf{GDV}_i) = \beta_0 + \beta_1 \text{ingresos}_i + \beta_2 d_i + u_i$$

donde *ingresos* son los ingresos y u_i es el término de error.

1. Interprete económicamente los parámetros del modelo, específicamente interprete económicamente β_2 , y refiérase a los signos esperados. ¿Bajo que supuesto respecto del término de error sus estimadores son consistentes?
2. Se tiene una muestra aleatoria simple de 1200 tarjetahabientes para un período posterior a la campaña. En el cuadro se presentan los resultados del modelo de regresión lineal planteado en el enunciado usando dicha muestra. Complete la información faltante e interprete los resultados. ¿Tiene algún efecto la campaña?

```
. reg lgdv ingresos d
```

Source	SS	df	MS	Number of obs	=	1,200
Model	13.0279129	2	6.51395646	F(2, 1197)	=	80.09
Residual	97.3496192	1,197	.081328003	Prob > F	=	0.0000
Total	110.377532	1,199	.092057992	R-squared	=	
				Adj R-squared	=	0.1166
				Root MSE	=	.28518

lgdv	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]
ingresos		.005615	0.000	.0504285	.0724611
d	.1000559	.0164708	0.000	.0677411	.1323707
_cons	7.480301	.017989	415.83	0.000	7.445008 7.515594

3. Una colega le plantea que la especificación sería incorrecta por cuanto la relación entre el log del **GDV** y los ingresos sería no lineal. Plantee un modelo alternativo que capture dicha no linealidad y explique cómo seleccionaría entre el modelo planteado en el enunciado y el modelo propuesto.
4. Su asistente le entrega los resultados de un test estadístico acerca de la especificación del modelo en el cuadro a continuación. Interprete los resultados indicando la hipótesis nula y alternativa y si rechaza o no dicha hipótesis nula.

```
. estat ovtest
```

Ramsey RESET test using powers of the fitted values of lgdv

Ho:

F(3, 1194) = 1.29

Prob > F = 0.2758

5. Su asistente le entrega también los resultados de un test estadístico respecto a la varianza del término de error en el siguiente cuadro, donde *ingresos_2* es el ingreso al cuadrado. Interprete los resultados indicando la hipótesis nula y alternativa y si rechaza o no dicha hipótesis nula.

Breusch-Pagan / Cook-Weisberg test for heteroskedasticity

Ho:

Variables: ingresos_2

chi2(1) = 0.25

Prob > chi2 = 0.6198

6. Un analista de riesgo le dice que la promoción de tasas rebajadas habría sido asignada a personas de alto patrimonio. Discuta las implicancias de dicha asignación sobre la consistencia de los resultados obtenidos en el modelo estimado en 2).

7. Ahora suponga que por un error del sistema, la asignación de la promoción fue mucho más frecuente en las tarjetas terminadas en los dígitos 9 y 0 y que los números de las tarjetas son asignados de manera aleatoria. ¿Cómo podría usar esta información para estimar consistentemente los parámetros del modelo lineal planteado? Plantee una expresión para dicho estimador consistente y los supuestos necesarios.

14.4. Ejercicio 3

Usando una muestra de corte transversal de 100 firmas de la industria manufacturera, un investigador desea estimar mediante MCO la función de producción de esta industria, de acuerdo a la siguiente tecnología:

$$Y_i = e^{\beta_0} K_i^{\beta_1} L_i^{\beta_2} e^{u_i}$$

donde Y es el producto, L es empleo, K es capital y u un shock aleatorio (residuo) que satisface los supuestos del teorema de Gauss-Markov.

1. Encuentre una expresión lineal en los parámetros mediante una transformación logarítmica que permita estimar los parámetros mediante MCO. Interprete económicamente los parámetros β_1 y β_2 . ¿Cómo testaría la hipótesis nula de retornos constantes a escala?
2. Suponga que una amiga de su única hermana estima el modelo, luego de aplicarle una transformación logarítmica y obtiene los siguientes resultados:

```
. reg log_y log_L log_K
```

Source	SS	df	MS	
Model	29.0595225	2	14.5297613	
Residual	29.0599775	97	.299587397	
Total	58.1195	99	.587065657	

Number of obs =	100
F(2, 97) =	48.50
Prob > F =	0.0000
R-squared =	0.5000
Adj R-squared =	0.4897
Root MSE =	.54735

log_y	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]
log_L	.4618692	.0600741	7.69	0.000	.3426388 .5810996
log_K	.4470785	.0686171	6.52	0.000	.3108926 .5832644
_cons	.3679555	.5114096	0.72	0.474	-.6470509 1.382962

Analice los resultados. Refiérase al signo y magnitud de los parámetros, su significancia y la bondad de ajuste.

3. Suponga que Ud. estima el modelo anterior previa transformación logarítmica al modelo y hace un test F para la hipótesis nula $\beta_1 + \beta_2 = 1$ y obtiene el siguiente resultado:

```
. test log_L+ log_K=1
( 1) log_L + log_K = 1
F( 1, 97) = 0.95
Prob > F = 0.3317
```

Donde $F(1, 97) = 0,95$ es el valor del estadístico que sigue una distribución F de Fischer con 1 grado de libertad en el numerador y 97 en el denominador y **Prob > F** es el p-value. ¿Qué puede concluir? Puede usar el p-value u obtener el crítico de una t de student usando la relación entre la F y la t de student cuando el grado de libertad en el numerador es igual a 1. En caso de rechazar, ¿cuál es la hipótesis alternativa de dicho test F ?

4. Suponga que ud. desea realizar el test anterior pero contra la alternativa de retornos decrecientes (a una cola). Ud. sabe que $Cov(\widehat{\beta}_1, \widehat{\beta}_2) = 0,0001969$. Realice dicho test escribiendo la hipótesis nula, la alternativa, el valor del estadístico y concluya si rechaza o no la nula.

5. Ahora Ud. está preocupado de la existencia de heterocedasticidad. Luego Ud. realiza el test de Breusch y Pagan incluyendo como variables de la regresión auxiliar $\log(L)$ y $\log(K)$ y obtiene los siguientes resultados:

```
Breusch-Pagan / Cook-Weisberg test for heteroskedasticity
Ho: Constant variance
Variables: log_L log_K

chi2(2)      =      7.79
Prob > chi2   =    0.0204
```

donde **chi2(2)** es el valor del estadístico que sigue una χ^2 con 2 grados de libertad y **prob>chi2** es el p-value. ¿Qué puede concluir con esta información? Sugiera un test alternativo al de Breusch y Pagan para detectar heterocedasticidad.

Ayuda: algunos críticos de la χ^2 con 2 grados de libertad son, para distintos grados de significancia: 9.21 (al 1 %), 5.99 (al 5 %) y 4.61 (al 10 %).

Pautas

Ejercicios Prueba 1

Ejercicio 1

1. Sabemos que en un contexto matricial la estimación de β por MCO nace del modelo $y = x\beta + u$ y termina siendo:

$$\hat{\beta} = (x'x)^{-1}x'y$$

de ese modo, obtener la estimación no será tarea difícil, ya que tenemos los datos en el enunciado:

$$\hat{\beta} = \underbrace{\begin{pmatrix} 1,3214 & -0,5 & -1 \\ -0,5 & 1 & 0 \\ -1 & 0 & 1 \end{pmatrix}}_{(X'X)^{-1}} \cdot \underbrace{\begin{pmatrix} 10 \\ 6 \\ 12 \end{pmatrix}}_{X'Y}$$

operando matricialmente,

$$\hat{\beta}_{3 \times 1} = \begin{pmatrix} -1,7857 \\ 1 \\ 2 \end{pmatrix} = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{pmatrix}$$

Además, sabemos que $R^2 = \frac{SCE}{SCT}$, luego:

$$a) SCE = \sum (\hat{y} - \bar{y}_i)^2 = \sum \hat{y}^2 - n\bar{y}^2$$

$$b) SCT = \sum (y - \bar{y})^2 = \sum y^2 - n\bar{y}^2$$

Cómo tenemos que $Y'Y = \sum y^2 = 14$, debemos obtener ahora la $\sum \hat{y}^2$. Luego, sabemos que eso se podrá representar en términos matriciales cómo $\hat{y}'\hat{y}$ y, además, que $\hat{y} = x\hat{\beta}$. De ese modo,

$$\hat{y}'\hat{y} = \hat{\beta}'x'x\hat{\beta}$$

reemplazando en $\hat{\beta} = (x'x)^{-1}x'y$:

$$\hat{y}'\hat{y} = \hat{\beta}'x'x \underbrace{(x'x)^{-1}x'y}_{\mathbf{I}}$$

$$\hat{y}'\hat{y} = \hat{\beta}'(x'y)$$

finalmente entonces,

$$SCE = \hat{\beta}'(x'y) - n\bar{y}^2$$

$$SCT = \sum y_i^2 - n\bar{y}^2$$

Luego, cómo sabemos que la primera columna de la matriz $\mathbf{X}$ es de $\mathbf{1}$'s (ya que el intercepto no va acompañado de coeficiente), también sabremos cuál es la suma de las y 's si multiplicamos $X'Y$ y nos fijamos en el **primer elemento del vector**. De ese modo;

$$X'Y = \begin{pmatrix} 10 \\ 6 \\ 12 \end{pmatrix}$$

por tanto 10 es la suma $\sum y_i$. Luego, como $n = 14$ (eso lo entrega el primer elemento de la matriz $X'X$) sabemos que $\frac{\sum y_i}{n} = \bar{y} = \frac{10}{14}$. Finalmente, como el término que nos interesa es $n\bar{y}^2$ lo guardamos para calcular después:

$$n\bar{y}^2 = 14 \cdot \left(\frac{10}{14}\right)^2$$

Ahora, retomando el cálculo del coeficiente de determinación, obtenemos SCE y SCT ;

- *SCE*;

$$\widehat{\beta}'(x'y) = \underbrace{\begin{pmatrix} -1,7857 & 12 \end{pmatrix}}_{\widehat{\beta}'} \cdot \underbrace{\begin{pmatrix} 10 \\ 6 \\ 12 \end{pmatrix}}_{(x'y)} = 12,1429_{\text{[escalar]}}$$

$$SCE = 12,1429 - (14 * 0,7143) = 4,9998$$

- *SCT*;

$$\begin{aligned} SCT &= y'y - n\bar{y}^2 \\ &= 14 - 14 * \left(\frac{10}{14}\right)^2 = 6,8569 \end{aligned}$$

Luego,

$$R^2 = 0,7292 = \frac{SCE}{SCT}$$

2. Sabemos que $V(\widehat{\beta}|\mathbf{x}) = \widehat{\sigma}^2(x'x)^{-1}$. Sin embargo, no tenemos la estimación de la varianza. Luego:

$$\widehat{\sigma}^2 = \frac{SCR}{n-k}$$

$$SCR = SCT - SCE = 1,8751$$

como $n = 14$ y $k = 3$:

$$\widehat{\sigma}^2 = \frac{1,8751}{11} = 0,1688$$

Luego,

$$V(\widehat{\beta}|\mathbf{x}) = \widehat{\sigma}^2(x'x)^{-1} \rightarrow 0,1688 \cdot \begin{pmatrix} 1,3214 & -0,5 & -1 \\ -0,5 & 1 & 0 \\ -1 & 0 & 1 \end{pmatrix} = \begin{pmatrix} 0,223 & -0,084 & -0,169 \\ -0,084 & 0,169 & 0 \\ -0,169 & 0 & 0,169 \end{pmatrix}$$

siendo en la **diagonal las varianzas** de cada $\widehat{\beta}_i$ y **fuera de la diagonal las covarianzas** entre ellos.

3. $H_0 : \beta_1 = 1,5$ vs $H_1 : \beta_1 \neq 1,5$. Luego esto no es más que un simple test T, y ya tenemos la estimación de $\widehat{\beta}_1$ y, también, de su varianza $V(\beta_1|\mathbf{x})$. Luego,

$$t = \frac{1 - 1,5}{\sqrt{0,169}} = -1,21$$

y cómo $t_{11}^{0,975} = 2,201$, la regla de rechazo para este tipo de alternativas es $|t_{obs}| \geq t_{tab}$. Luego, **no hay evidencia para rechazar H_0 a un 95 % de confianza**.

4. Para construir un **bilateral** planteamos el pivote

$$\varphi = \frac{\widehat{\beta}_2 - \beta_2}{\sqrt{V(\beta_2|\mathbf{x})}} \sim t_{n-k=11}$$

luego, el intervalo de confianza **bilateral** considera los percentiles $(1 - \frac{\alpha}{2})$, por lo que pivoteando llegamos a que el resultado es:

$$\left[2 - \sqrt{0,169} * t_{11}^{0,975} \leq \beta_2 \leq 2 + \sqrt{0,169} * t_{11}^{0,975} \right]$$

Ejercicio 2

1. La intuición matricial nos indica lo siguiente:

$$X'X = \begin{bmatrix} 1 & \dots & 1 \\ x_{11} & \dots & x_{1n} \\ x_{21} & \dots & x_{2n} \end{bmatrix} \cdot \begin{bmatrix} 1 & x_{11} & x_{21} \\ \vdots & \vdots & \vdots \\ 1 & x_{1n} & x_{2n} \end{bmatrix} = \begin{bmatrix} n & \sum x_{1i} & \sum x_{2i} \\ \sum x_{1i} & \sum x_{1i}^2 & \sum x_{1i}x_{2i} \\ \sum x_{2i} & \sum x_{1i}x_{2i} & \sum x_{2i}^2 \end{bmatrix}$$

luego, tenemos la matriz $X'X = \begin{pmatrix} 20 & 100 & 24 \\ 100 & 680 & 100 \\ 24 & 100 & 48,8 \end{pmatrix}$. Además,

$$X'Y = \begin{bmatrix} 1 & \dots & 1 \\ x_{11} & \dots & x_{1n} \\ x_{21} & \dots & x_{2n} \end{bmatrix} \cdot \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} \sum y_i \\ \sum x_{1i}y_i \\ \sum x_{2i}y_i \end{bmatrix} = \begin{pmatrix} 5 \\ -255 \\ 146 \end{pmatrix}$$

2. La estimación $\hat{\beta}$ a través de **MCO** se puede representar como $\hat{\beta} = (x'x)^{-1}x'y$. Luego, sabiendo que:

$$(X'X)^{-1} = \begin{pmatrix} 0,36225 & -0,03875 & -0,09875 \\ -0,03875 & 0,00625 & 0,00625 \\ -0,09875 & 0,00625 & 0,05625 \end{pmatrix}$$

$$\hat{\beta}_{\text{MCO}} = \begin{pmatrix} 0,36225 & -0,03875 & -0,09875 \\ -0,03875 & 0,00625 & 0,00625 \\ -0,09875 & 0,00625 & 0,05625 \end{pmatrix} \cdot \begin{pmatrix} 5 \\ -255 \\ 146 \end{pmatrix} = \begin{pmatrix} -2,725 \\ -0,875 \\ 6,125 \end{pmatrix}$$

3. Sabemos que $R^2 = \frac{SCE}{SCT}$. Luego,

$$SCE = \sum (\hat{y} - \bar{y})^2 \rightarrow \sum \hat{y}^2 - n\bar{y}^2$$

$$SCE = \hat{\beta}'(x'y) - n\bar{y}^2$$

$$\hat{\beta}'(x'y) = \begin{pmatrix} -2,725 & -0,875 & 6,125 \end{pmatrix} \cdot \begin{pmatrix} 5 \\ -255 \\ 146 \end{pmatrix} = 1103,75$$

luego como $n = 20$ y $\sum y_i = 5$, sabemos que $\bar{y} = 0,25 \rightarrow \bar{y}^2 = \frac{1}{16} \rightarrow n\bar{y}^2 = \frac{20}{16}$. De ese modo,

$$SCE = 1103,75 - \frac{20}{16} = 1102,5$$

$$SCT = \sum (y_i - \bar{y})^2 = 1200$$

$$R^2 = \frac{1102,5}{1200} = 0,91875$$

además, como $SCR = SCT - SCE \rightarrow 1200 - 1102,5 = 97,5$.

Ejercicio 3

1. Sabemos que si hacemos una regresión de y en x el estimador $\hat{\beta}$ a través de **MCO** es $\hat{\beta} = (x'x)^{-1}x'y$. Luego, si hacemos una regresión de y sobre $\mathbf{Z}$, tendremos que el estimador será $\tilde{\beta} = (z'z)^{-1}z'y$, lógica-

mente sujeto a que $\mathbf{z} = \mathbf{XA}$. De ese modo:

$$\begin{aligned}\tilde{\beta} &= [(\mathbf{XA})' (\mathbf{XA})]^{-1} (\mathbf{XA})' y \\ &= [\mathbf{A}' \mathbf{X}' \mathbf{XA}]^{-1} (\mathbf{A}' \mathbf{X}') y \\ &= [\mathbf{A}^{-1} (\mathbf{A}' \mathbf{X}' \mathbf{X})^{-1} \mathbf{A}' \mathbf{X}' y] \\ &= \left[\mathbf{A}^{-1} (\mathbf{X}' \mathbf{X})^{-1} \underbrace{(\mathbf{A}')^{-1}}_{\mathbf{I}} \mathbf{A}' \mathbf{X}' y \right] \\ &= \mathbf{A}^{-1} (\mathbf{X}' \mathbf{X})^{-1} \mathbf{X}' \mathbf{Y}\end{aligned}$$

luego, no es difícil notar que la relación entre este estimador y el extraído de la regresión de y en X es:

$$\tilde{\beta} = \mathbf{A}^{-1} \hat{\beta}$$

2. Sabemos que $\tilde{u} = y - z\tilde{\beta}$ y cómo sabemos que $z = \mathbf{XA}$ y $\tilde{\beta} = \mathbf{A}^{-1}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}$ reemplazamos:

$$\begin{aligned}\tilde{u} &= y - \mathbf{XA}\mathbf{A}^{-1}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y} \\ &= y - \mathbf{X}\hat{\beta}\end{aligned}$$

por tanto, los residuos de ambas regresiones **son iguales**.

3. Calculando;

$$\begin{aligned}\mathbb{E}(\tilde{\beta}|\mathbf{x}) &= \mathbb{E}(\mathbf{A}^{-1}\hat{\beta}|\mathbf{x}) \\ &= \mathbf{A}^{-1}\mathbb{E}(\hat{\beta}|\mathbf{x})\end{aligned}$$

como sabemos que $\hat{\beta}$ es insesgado, luego:

$$\mathbb{E}(\tilde{\beta}|\mathbf{x}) = \mathbf{A}^{-1}\beta$$

Ahora,

$$\begin{aligned}V(\tilde{\beta}|\mathbf{x}) &= \sigma^2 [\mathbf{z}'\mathbf{z}]^{-1} \\ &= \sigma^2 [(\mathbf{XA})' (\mathbf{XA})]^{-1} \\ &= \sigma^2 [\mathbf{A}' \mathbf{X}' \mathbf{XA}]^{-1} \\ &= \sigma^2 \mathbf{A}^{-1} (\mathbf{X}' \mathbf{X})^{-1} (\mathbf{A}^{-1})'\end{aligned}$$

Ejercicio 4

1. Se esperaría que el signo de la variable $exposure_i$ sea positivo (si el tratamiento es bueno) y, también, es esperable que la edad del niño y la educación de la madre esté relacionada positivamente con las habilidades cognitivas del niño. En la estimación, lo que vemos es eso, todos significativos al 1 %. **Luego, el tratamiento es efectivo por cuanto afecta positivamente las habilidades cognitivas de los niños.**

2. Debemos construir el estadístico t y comparar con el crítico $t_{3383=3387-4}^{0,975} = 1,96$. Luego,

$$t = \frac{\hat{\beta}_2 - \beta_{2(0)}}{\sqrt{V(\hat{\beta}_2)}} = \frac{0,0169 - 0,03}{0,0065} = -2,02$$

Luego, la regla de rechazo ante este tipo de hipótesis alternativa es:

$$|t| \geq t_{tab} \rightarrow 2,02 \geq 1,96 \checkmark$$

De ese modo, rechazamos la hipótesis nula a un 95 % de confianza.

3. La amiga se refiere a la siguiente hipótesis $H_0 : \beta_2 = 3\beta_3$. Dado que las covarianzas podemos asumirlas como cero (hay independencia implícita), podemos hacer un test t usual:

$$t = \frac{(\hat{\beta}_2 - 3\hat{\beta}_3) - (\beta_2 - 3\beta_3)_0}{\sqrt{V(\hat{\beta}_2 - 3\hat{\beta}_3)}} = \frac{\hat{\beta}_2 - 3\hat{\beta}_3}{\sqrt{V(\hat{\beta}_2) + 9V(\hat{\beta}_3)}} = \frac{0,0169 - 3 \cdot 0,0063}{\sqrt{0,0065^2 + 9 \cdot 0,0011^2}} = -0,31$$

Luego, la regla de rechazo es igual a la de **2**, de ese modo:

$$t_{3383}^{0,975} = 1,96$$

$$|t| = 0,31$$

Finalmente, **no se cumple** que $|t| \geq t_{tab}$, por lo que **no hay evidencia para rechazar la hipótesis nula**, por lo que se cumple lo que predice la amiga.

Ejercicios Prueba 2

Ejercicio 1

1. La forma de predecir el valor puntual de una variable dependiente en función de distintos escenarios es mediante la forma:

$$Y^0 = X^0\beta + u^0$$

pero como no conocemos los parámetros a nivel poblacional, debemos hacer una estimación de la predicción, del siguiente modo:

$$\hat{Y}^0 = X^0\hat{\beta}$$

Ahora, aplicando al ejercicio, tenemos que la predicción estimada tendrá la siguiente forma:

$$\hat{Y}^0 = \hat{\beta}_1 + \hat{\beta}_2 X_2^0 + \hat{\beta}_3 X_3^0$$

Por lo tanto, el error de predicción será:

$$\begin{aligned} \hat{e}^0 &= \underbrace{X^0\beta}_{real} - \underbrace{X^0\hat{\beta}}_{estimado} \\ \hat{e}^0 &= X^0(\beta - \hat{\beta}) + u_0 \end{aligned}$$

y será 0 mientras el estimador de los regresores sea insesgado (lo cual se cumple en Gauss-Markov) y la esperanza de los errores sea 0.

2. La varianza del error de predicción la obtendremos del modo usual:

$$\begin{aligned} V(\hat{e}^0) &= E(\hat{e}\hat{e}') \\ &= E\left[(X^0(\beta - \hat{\beta}) + u_0)(X^0(\beta - \hat{\beta}) + u_0)'\right] \\ &= E\left[X^0(\beta - \hat{\beta})(\beta - \hat{\beta})'X^{0'} + X^0(\beta - \hat{\beta})u^{0'} + u^0(\beta - \hat{\beta})'X^{0'} + u^0u^{0'}\right] \\ &= E\left[X^0(\beta - \hat{\beta})(\beta - \hat{\beta})'X^{0'} + 2X^0(\beta - \hat{\beta})u^{0'} + u^0u^{0'}\right] \end{aligned}$$

Resolviendo, obtenemos:

$$\begin{aligned} V(\hat{e}^0) &= \left[X^0\sigma_u^2(X'X)^{-1}X^{0'} + \sigma_u^2\right] \\ &= \sigma_u^2 \left[1 + X^0(X'X)^{-1}X^{0'}\right] \end{aligned}$$

3. La predicción sería $\hat{Y}^0 = 240 + 0,1 * 500 + -1 * 30 = 260$.

Ahora, la varianza del error de estimación la obtenemos de modo matricial:

$$V(\hat{e}^0) = \sigma_u^2 \left\{ 1 + \begin{bmatrix} 1 & 500 & 30 \end{bmatrix} \begin{bmatrix} 1/10 & 0 & 0 \\ 0 & 1/10000 & 0 \\ 0 & 0 & 1/500 \end{bmatrix} \begin{bmatrix} 1 \\ 500 \\ 30 \end{bmatrix} \right\} = \alpha$$

Ahora, el intervalo de confianza:

$$\frac{\hat{Y}^0 - Y^0}{\sqrt{V(\hat{e}^0)}} \sim t_{n-k} \rightarrow \left[260 \pm t_{0,975}^{(10-3)} \sqrt{\alpha} \right]$$

4. Por último, la nueva predicción sería:

$$\begin{aligned} \hat{Y}^0 &= 240 + 0,1 * 500 - 1 * 20 \\ &= 270 \end{aligned}$$

es decir, el valor de la predicción aumenta en la misma proporción de la disminución de la variable explicativa.

Ejercicio 2

1. En este caso:

$$H_0 : \begin{aligned} \beta_2 &= 0 \\ \beta_3 &= 0 \end{aligned}$$

y se debe definir un vector R para realizar el test-F. En este caso, ese vector es el siguiente:

$$R = \begin{pmatrix} 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \end{pmatrix}$$

con $r = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$ y $q = 2$. De este modo, desarrollamos el estadístico F, dado por la siguiente fórmula:

$$F_{obs} = \frac{(R\hat{\beta} - r)' [R(X'X)^{-1}R']^{-1} (R\hat{\beta} - r)}{q\hat{\sigma}^2} > F_{(q, n-k)}^{\{1-\alpha\}}$$

y, en ese caso, rechazaríamos H_0 . Cómo sabemos la matriz de varianzas y covarianzas, podemos buscar aquella 2x2 que representas las varianzas y covarianzas de los parámetros testeados, quedando la siguiente matriz:

$$\begin{bmatrix} 0,77 & 0,06 & -0,18 & 0,07 \\ 0,06 & \mathbf{0,14} & \mathbf{-0,15} & 0,006 \\ -0,18 & \mathbf{-0,15} & \mathbf{1,69} & -0,02 \\ 0,07 & 0,006 & -0,02 & 0,01 \end{bmatrix}$$

Por lo que si desarrollamos el estadístico, obtenemos lo siguiente:

$$F_{obs} = \frac{\left[\begin{pmatrix} 3,1 \\ -2,6 \end{pmatrix} - \begin{pmatrix} 0 \\ 0 \end{pmatrix} \right]' \begin{pmatrix} 0,14 & -0,15 \\ -0,15 & 1,69 \end{pmatrix}^{-1} \left[\begin{pmatrix} 3,1 \\ -2,6 \end{pmatrix} - \begin{pmatrix} 0 \\ 0 \end{pmatrix} \right]}{2} \sim F_{(2, 34-4)}^{\{0,95\}}$$

Desarrollando, obtenemos que:

$$F_{obs} = 30,07 > 3,32 = F_{2,30}^{\{0,95\}}$$

Por lo tanto, se rechaza H_0 . Ojo que es muy importante destacar que desde el enunciado se puede extraer que la muestra es de tamaño $n = 34$ (por los 34 años entre 1970 y 2003) y $k = 4$, por todos los regresores inclusive la constante.

2. En este caso se podría usar el test-F, sin embargo, el test-T es más directo:

$$H_0 : \beta_2 + \beta_3 + \beta_4 = 1$$

$$t_{obs} = \frac{\beta_2 + \beta_3 + \beta_4 - 1}{\sqrt{V(\beta_2 + \beta_3 + \beta_4)}} = \frac{3,1 - 2,6 + 0,6 - 1}{\sqrt{1,512}} = \frac{0,1}{1,229}$$

con

$$V(\beta_2 + \beta_3 + \beta_4) = V(\beta_2) + V(\beta_3) + V(\beta_4) + 2Cov_{\beta_2, \beta_3} + 2Cov_{\beta_2, \beta_4} + 2Cov_{\beta_3, \beta_4}$$

Además, sabemos que

$$t_{30}^{0,975} = 2,042$$

Por lo tanto, **no** se rechaza la hipótesis nula.

Ejercicio 3: Aplicaciones cortas

Ejercicio 1

Teniendo en cuenta que la nota esperada para un hombre y una mujer son, respectivamente:

$$E(\text{nota}_t / \text{género}_t = 0) = \beta_0 + \beta_1 \text{NotamediaECON}_t$$

$$E(\text{nota}_t / \text{género}_t = 1) = \beta_0 + \beta_1 \text{NotamediaECON}_t + \beta_2$$

entonces, se tiene que para una misma nota media en ECON, la diferencia esperada entre la nota de una mujer y un hombre viene determinada por:

$$E(\text{nota}_t / \text{género}_t = 1) - E(\text{nota}_t / \text{género}_t = 0) = \beta_2$$

Por lo tanto, para ver si se puede decir que los resultados entre unos y otros es efectivamente distinto, debemos hacer un test de hipótesis asociado a la significación del parámetro, lo cual se logra a través del tradicional test-t ($H_0 : \beta_2 = 0$):

$$t_{obs} = \frac{20,5}{2,3} = 8,913 > 2,1098 = t_{17}^{\{0,975\}}$$

y concluimos que se rechaza la hipótesis nula. De este modo, el parámetro es distinto de cero y eso permite afirmar que los resultados entre hombres y mujeres SI son distintos.

Ejercicio 2

1. Sustituyendo $X_{2t} = 3X_{4t}$ en la ecuación del modelo, se obtiene lo siguiente:

$$\begin{aligned} Y_t &= \beta_1 + \beta_2 X_{2t} + \beta_3 X_{3t} + \beta_4 X_{4t} + u_t \\ &= \beta_1 + 3\beta_2 X_{4t} + \beta_3 X_{3t} + \beta_4 X_{4t} + u_t \\ &= \beta_1 + \beta_3 X_{3t} + (\beta_4 + 3\beta_2) X_{4t} + u_t \end{aligned}$$

Por tanto, son estimables los parámetros β_1 , β_3 y la combinación lineal $3\beta_2 + \beta_4$. De ese modo, a no ser que existe información a priori sobre los parámetros, no será posible obtener las estimaciones de β_2 y β_4 .

2. Si se sabe que $\beta_4 = 2$, entonces la ecuación del modelo quedaría del siguiente modo:

$$Y_t = \beta_1 + \beta_3 X_{3t} + (2 + 3\beta_2) X_{4t} + u_t$$

por lo que se podrían estimar todos los parámetros restantes β_1 , β_2 y β_3 .

Ejercicio 3

1. Para estimar el modelo a través de MCO ocupamos la fórmula típica:

$$\hat{\beta}_{mco} = (X'X)^{-1} X'Y = \begin{pmatrix} 1,3214 & -0,5 & -1 \\ -0,5 & 1 & 0 \\ -1 & 0 & 1 \end{pmatrix} \cdot \begin{pmatrix} 10 \\ 6 \\ 12 \end{pmatrix} = \begin{pmatrix} -1,7857 \\ 1 \\ 2 \end{pmatrix}$$

Por tanto, el modelo estimado queda del siguiente modo:

$$\hat{Y}_t = -1,7857 + X_{2t} + 2X_{3t}$$

2. Para estudiar la significancia del modelo, nos estamos refiriendo al siguiente testeo:

$$H_0 : \beta_i = 0 \quad \forall i$$

$$H_0 : \beta_i \neq 0 \quad \forall i$$

y, en estos casos, el test F tiene su forma particular:

$$F_{obs} = \frac{ESS/(k-1)}{RSS/(n-k)}$$

y si calculamos a través de la forma:

$$ESS = \hat{\beta}' \cdot X'Y - n\bar{Y}^2$$

$$TSS = Y'Y - n\bar{Y}^2$$

$$TSS = ESS + RSS \rightarrow RSS = TSS - ESS$$

tendremos lo siguiente:

$$a) ESS = \hat{\beta}' \cdot X'Y - n\bar{Y}^2 = 12,1429 - 14 * 0,7143^2 \simeq 5$$

$$b) TSS = Y'Y - n\bar{Y}^2 = 14 - 14 * 0,7143^2 \simeq 6,86$$

$$c) RSS = TSS - ESS = 1,86,$$

Por lo tanto,

$$F_{obs} = \frac{5/2}{1,86/11} = 14,8074 > 3,98 = F_{(2,1)}^{(1-\alpha)}$$

se rechaza la nula con una confianza del 95 % y, entonces, el modelo es significativo.

3. Para contrastar la hipótesis $H_0 : \beta_2 - \beta_3 = -1$, ocupamos el clásico test F:

$$F_{obs} = \frac{(R\hat{\beta} - r)' [R(X'X)^{-1}R']^{-1} (R\hat{\beta} - r)}{q\hat{\sigma}^2} > F_{(q,n-k)}^{\{1-\alpha\}}$$

con $R = \begin{pmatrix} 0 & 1 & -1 \end{pmatrix}$, $r = -1$ y $q = 1$. Por lo tanto, desarrollando:

$$R\hat{\beta} - r = \begin{pmatrix} 0 & 1 & -1 \end{pmatrix} \cdot \begin{pmatrix} -1,7857 \\ 1 \\ 2 \end{pmatrix} + 1 = 0$$

lo que conduce a que

$$F_{obs} = 0 < 4,84 = F_{(1,11)}^{\{0,95\}}$$

Por lo tanto, no se rechaza la hipótesis nula.

4. El intervalo de confianza de predicción es el siguiente:

$$x'_0\hat{\beta} \pm t_{(n-k)}^{1-\frac{\alpha}{2}} \hat{\sigma} \sqrt{x'_0(x'x)^{-1}x_0}$$

y, con los datos entregados, tenemos lo siguiente:

$$a) x_0\hat{\beta} = \begin{pmatrix} 1 & 5 & 7 \end{pmatrix} \cdot \begin{pmatrix} -1,7857 \\ 1 \\ 2 \end{pmatrix} = 17,2143$$

$$b) \hat{\sigma}^2 = \frac{RSS}{n-k} = \frac{1,86}{11} = 0,1688$$

$$c) x_0(x'x)^{-1}x'_0 = \begin{pmatrix} 1 & 5 & 7 \end{pmatrix} \cdot \begin{pmatrix} 1,3214 & -0,5 & -1 \\ -0,5 & 1 & 0 \\ -1 & 0 & 1 \end{pmatrix} \cdot \begin{pmatrix} 1 \\ 5 \\ 7 \end{pmatrix} = 56,3214$$

Y, por lo tanto, el intervalo de confianza al 95 % es el siguiente:

$$[10,3671 \leq E(Y) \leq 26,0615]$$

Ejercicio 4

1. La estimación MCO la obtenemos según la forma usual:

$$\hat{\beta}_{mco} = (X'X)^{-1}X'Y \rightarrow \begin{pmatrix} 0,6477 & -0,041 & -0,0639 \\ -0,041 & 0,0071 & -0,0011 \\ -0,0639 & -0,0011 & 0,0152 \end{pmatrix} \cdot \begin{pmatrix} 91 \\ 699 \\ 448 \end{pmatrix} = \begin{pmatrix} 1,6545 \\ 0,7391 \\ 0,2258 \end{pmatrix}$$

Para calcular el coeficiente de determinación R^2 , primero debemos obtener la suma explicada por el modelo, representada a través de la ESS, que la podemos obtener como el hint indicaba:

$$ESS = \hat{\beta}' \cdot X'Y - n\bar{Y}^2 = 768,35 - 690 \simeq 78,35$$

ya que

$$\hat{\beta}' \cdot X'Y = \begin{pmatrix} 1,6545 & 0,7391 & 0,2258 \end{pmatrix} \begin{pmatrix} 91 \\ 699 \\ 448 \end{pmatrix} \simeq 768,35$$

e

$$\sum Y_t = 91 \rightarrow \bar{Y} = \frac{91}{12} = 7,583 \rightarrow \bar{Y}^2 \simeq 57,51$$

Ahora, sabiendo que tenemos la suma total y la explicada solamente por el modelo, podemos obtener de manera sencilla el coeficiente de determinación:

$$R^2 = \frac{ESS}{TSS} = \frac{78,35}{104,9167} \simeq 75\%$$

es decir, el ajuste realizado a través de la estimación MCO explica aproximadamente un 75 % de la variabilidad de Y.

2. Para hacer el test de hipótesis solicitado, debemos notar que se rechazará la nula cuando:

$$F_{obs} = \frac{(R\hat{\beta} - r)' [R(X'X)^{-1}R']^{-1} (R\hat{\beta} - r)}{q\hat{\sigma}^2} > F_{(q,n-k)}^{\{1-\alpha\}}$$

De la restricción entregada $\beta_2 + \beta_3 = 1$ se obtiene que $R = \begin{pmatrix} 0 & 1 & 1 \end{pmatrix}$, $r = 1$ y $q = 1$, por lo que operando:

$$(R\hat{\beta} - r) = \begin{pmatrix} 0 & 1 & 1 \end{pmatrix} \cdot \begin{pmatrix} 1,6545 \\ 0,7391 \\ 0,2258 \end{pmatrix} - 1 = -0,0351$$

$$R(X'X)^{-1}R' = \begin{pmatrix} 0 & 1 & 1 \end{pmatrix} \cdot \begin{pmatrix} 0,6477 & -0,041 & -0,0639 \\ -0,041 & 0,0071 & -0,0011 \\ -0,0639 & -0,0011 & 0,0152 \end{pmatrix} \cdot \begin{pmatrix} 0 \\ 1 \\ 1 \end{pmatrix} = 0,0201$$

y ahora, estimando $\hat{\sigma}^2$ como $\hat{u}'\hat{u}/(n-k)$, obtenemos lo último que necesitamos para realizar el test F

$$\hat{\sigma}^2 = \frac{104,9167 - 78,35}{12 - 3} = \frac{26,6512}{9} = 2,962$$

y se tiene entonces que:

$$F_{obs} = \frac{0,0351^2}{2,962 * 0,0201} = \frac{0,0012}{0,0595} = 0,0207 < 5,117 = F_{(1,9)}^{\{0,95\}}$$

Por lo tanto, NO se rechaza la hipótesis nula.

3. Finalmente, para obtener el intervalo de confianza para $E(Y)$ seguimos su forma típica:

$$x'_0 \hat{\beta} \pm t_{(n-k)}^{1-\frac{\alpha}{2}} \hat{\sigma} \sqrt{x'_0 (x'x)^{-1} x_0}$$

Resolviendo:

$$x'_0 \hat{\beta} = 1,6445 + 0,7391 * 2,5 + 0,2258 * (-0,3) = 3,43451$$

$$x'_0 (x'x)^{-1} x_0 = \begin{pmatrix} 1 & 2,5 & -0,3 \end{pmatrix} * \begin{pmatrix} 0,6477 & -0,041 & -0,0639 \\ -0,041 & 0,0071 & -0,0011 \\ -0,0639 & -0,0011 & 0,0152 \end{pmatrix} * \begin{pmatrix} 1 \\ 2,5 \\ -0,3 \end{pmatrix} = 0,5384$$

Por lo tanto, el intervalo de confianza para $E(Y)$ es el siguiente:

$$[0,60451 \leq E(Y) \leq 6,26451]$$

Ejercicio 5

1. Suponiendo que disponemos con los datos de los alumnos egresados de la carrera, se podría estimar el siguiente modelo:

$$W_i = \beta_0 + \beta_1 D_{1i} + u_i$$

donde W_i es el logaritmo natural del salario y D_{1i} es una variable *dummy* que toma el valor 1 si la persona i egresó de administración y 0 si egreso de economía (*no hay ningún problema en caso de que la dummy se defina al révez, ya que luego para ver significancia estadística, será coherente con el parámetro*). De ese modo, obteniendo expresiones en términos esperados:

$$E[W_i / D_{1(i=administración)} = 1] = \hat{\beta}_0 + \hat{\beta}_1$$

$$E[W_i / D_{1(i=economía)} = 0] = \hat{\beta}_0$$

Para comprobar entonces la hipótesis solicitada se requiere un parámetro $\hat{\beta}_1$ positivo y estadísticamente significativo, por lo tanto -de manera explícita- se debe testear a través de un test-t la siguiente hipótesis $H_0 : \hat{\beta}_1 = 0$:

$$t = \frac{\hat{\beta}_1}{\sqrt{V(\hat{\beta}_1)}} \sim t_{n-k}$$

2. Para testear esta nueva condición, debemos incorporar una variable *dummy* que llamaremos D_3 , que tome el valor 1 si la persona egresó de la Universidad de Chile y 0 si egresó de la Universidad Católica, de modo que el modelo que nos permitiría testear lo solicitado debe ser del siguiente modo:

$$W_i = \beta_0 + \beta_1 D_{1i} + \beta_2 D_{3i} + \beta_3 D_{3i} \cdot D_{1i} + u_i$$

De este modo, nuevamente obteniendo expresiones en términos esperados:

$$E[W_i / Administración en U de Chile] = \hat{\beta}_0 + \hat{\beta}_1 + \hat{\beta}_2 + \hat{\beta}_3$$

$$E[W_i / Economía en U de Chile] = \hat{\beta}_0 + \hat{\beta}_2$$

$$E[W_i / Administración en U Católica] = \hat{\beta}_0 + \hat{\beta}_1$$

$$E[W_i / Economía en U Católica] = \hat{\beta}_0$$

Para testear la significancia solicitada, debemos hacer un test F para una hipótesis conjunta:

$$H_0 : \hat{\beta}_1 = 0$$

$$\hat{\beta}_2 = 0$$

$$\hat{\beta}_3 = 0$$

donde $R = [0_{3 \times 1} I_3]$ y $r = 0_{3 \times 1}$. De este modo, utilizamos el común test F, definido del modo:

$$\frac{(R\hat{\beta} - r)' [R(X'X)^{-1}R']^{-1} (R\hat{\beta} - r)}{q\hat{\sigma}^2} \sim F_{(q, n-k)}$$

Ejercicio 6 (Comentes)

1. **R.** Falso. Cuando hacemos un test de hipótesis de la forma $H_0 : R\hat{\beta} = r$ para ver si rechazamos o no la hipótesis nula, debemos comparar el valor calculado del estadístico con el valor de tabla de una distribución F con q grados de libertad en el numerador y $n - k$ grados de libertad en el denominador. Si bien el valor de tabla de la distribución F no cambia con r (los valores que testeamos bajo la hipótesis nula) si cambia con el número de hipótesis que estemos testeando (q).
2. **R.** Falso. El supuesto de normalidad lo necesitamos para conocer la distribución de los estimadores y de esta forma poder derivar los test t y F. Por otra parte, la fórmula $\hat{\beta} = (X'X)^{-1}X'Y$ resulta simplemente de plantear el problema de optimización de mínimos cuadrados, lo que no depende en lo absoluto de la normalidad de los errores.
3. **R.** Falso, la omisión de una variable relevante siempre produce sesgo en los parámetros a menos que la correlación entre la variable omitida y las explicativas incluidas sea cero, sin embargo, la dirección del sesgo no es siempre negativa, de hecho el signo del sesgo depende de dos cosas: la correlación entre la omitida y las explicativas incluidas y el valor del parámetro que tendría asociado la variable omitida (valor poblacional). Para un modelo sencillo, con una variable explicativa (x_1) y una variable omitida (x_2) se mostrará en clases que el sesgo es: $\frac{cov(x_1, x_2)}{v(x_1)}\beta_2$. Por otra parte, siempre al omitir una variable relevante, la varianza de los parámetros estimada a partir del modelo incorrecto es menor que la del modelo que incluye la variable omitida.


Ejercicios Examen

Comentes

1. **Incierto.** El error de medida en la variable dependiente producirá errores estándar más grandes y estadísticos t (para hipótesis lineales) menores con lo cual efectivamente se producirá error de tipo II con mayor probabilidad. Pero el error de medida en las variables independientes producirá sesgo de atenuación y el efecto en los test- t no es claro, dependerá de la hipótesis nula a testear.
2. **Falso,** aumenta la probabilidad de cometer error de tipo II. Si existe multicolinealidad (no exacta, si la multicolinealidad es exacta el estimador MCO no existe) los errores estándar serán muy elevados, con lo cual, los estadísticos serán pequeños (por ejemplo el estadístico t o F) y tenderemos a no rechazar la hipótesis nula, aun cuando esta sea falsa. Por definición, el error tipo II es el que se comete cuando uno no rechaza la hipótesis nula cuando ella es falsa, luego estaremos más expuestos a este tipo de error.
3. **Incierto,** es verdadero si la autocorrelación es de primer orden, es decir, el proceso de error sigue un proceso **AR(1)**. Es falso o incierto si la autocorrelación es de mayor orden.
4. **Falso.** No es un fenómeno menor. Si bien es cierto que no produce inconsistencia en los estimadores MCO de los parámetros del modelo lineal, si produce ineficiencia que puede producir que nuestra inferencia sea completamente equivocada, lo cual no es menor.
5. **Falso.** No son necesariamente similares. El test de **BG** es un test de tipo Lagrange Multiplier para detectar la presencia de autocorrelación de **cualquier orden** en cambio el test de **DB** sirve para testear la presencia de autocorrelación de orden 1 solamente. Luego las hipótesis nulas pueden ser distintas. Además, el test de **DB** tiene zonas de indeterminación y es inconclusivo. Eso no ocurre con el de **BG**.
6. **Falso.** El test es parecido pero un poco más general que el de White porque permite agregar otras variables a la regresión auxiliar, que pueden estar incluso fuera del modelo. Además, estos tests son para heterocedasticidad y no para autocorrelación.
7. **Falso,** la estimación de White no "corrige" la heterocedasticidad, sino que permite obtener un estimador consistente de la matriz de varianzas y covarianzas con heterocedasticidad, y de esta forma, poder realizar la inferencia. Efectivamente, esto se puede hacer sin conocer el patrón de heterocedasticidad, sin embargo, **no** se corrige esta última.

Ejercicio 1

1. La recta graficada queda del siguiente modo:



El resultado sugiere regresión a la media puesto que los hijos de padres bajos serán bajos, pero más altos que sus padres y los hijos de padres altos serán altos, pero más bajos que sus padres. Si esto sucede de generación en generación, tendremos que la altura de las personas convergerá a un valor medio.

2. Restando las dos ecuaciones tenemos la siguiente función de regresión poblacional:

$$X_{i,h} = X_{i,p} + (v_{i,h} - u_{i,p})$$

Claramente esta función no se condice con la «falacia de Galton» puesto que el intercepto es igual a 0 y la pendiente igual a 1, por lo tanto según esta especificación **no habría regresión a la media**.

3. Las restricciones son que el intercepto sea igual a 0 y la pendiente igual a 1. Para testear las dos restricciones habría que hacer un test conjunto como el test de Wald o un test **F**. Con lo encontrado en 1) y sólo con la información que tenemos de 1), la única manera de testear estas hipótesis es separadamente mediante test-t. Los valores del test-t son para el intercepto $t = 0,71$ y para la pendiente $t = -0,93$, luego **no se rechaza ninguna de las dos hipótesis**. Esto no nos ayuda mucho, puesto que como se dijo anteriormente la única manera de testear este modelo correctamente es haciéndolo con un test de hipótesis conjunta.

Ejercicio 2

- El parámetro β_1 corresponde a una semi-elasticidad entre **GDV** e ingresos. El parámetro β_2 es también una semi-elasticidad y tiene la siguiente interpretación en este caso: $100 \times \beta_2$ es el cambio porcentual del **GDV** entre la situación con campaña vs sin campaña (cambio de la dummy d de 0 a 1). El signo esperado de ambos parámetros es positivo. El supuesto es que el término de error no está correlacionado con las variables explicativas (ingresos y d).
- Para calcular $\hat{\beta}_1$ podemos usar uno de los límites del intervalo de confianza:

$$\hat{\beta}_1 + 1,96 \times 0,0056 = 0,072$$

Dado la gran cantidad de grados de libertad, es correcto usar 1.96 porque la t-student converge a una normal como lo indica el cuadro. $\hat{\beta}_1 = 0,061$ y $t = \hat{\beta}_1 / SE(\hat{\beta}_1) = 10,9$. El $R^2 = ESS/TSS = 13,02/110,37 = 0,118$. Y el estadístico t para $\hat{\beta}_2$ es simplemente $t = 0,10/0,0165 = 6,1$. Según los resultados, quienes recibieron la campaña de tasas reducidas aumentan un 10 % el **GDV** en relación a quienes no reciben dicha campaña. Este efecto es significativo al 1 %.

3. Un modelo alternativo que incorpora no-linealidades es simple de elaborar. Un ejemplo es:

$$\ln(\text{GDV}) = \beta_0 + \beta_1 \text{ingresos}_i + \beta_2 \text{ingresos}_i^2 + \beta_3 d_i + u_i$$

Para seleccionar entre este modelo y el modelo planteado en el enunciado debemos usar un criterio de información, considerando que los **modelos son anidados**. Claramente el modelo planteado anida al modelo del enunciado. Podemos usar el criterio de Akaike (**AIC**) ó el de Schwartz (**BIC**).

- El test en cuestión es el test RESET o test de Ramsey. De acuerdo a la definición y lo indicado en el cuadro, el test agrega potencias de los valores estimados de la variable dependiente $\ln(\widehat{\text{GDV}})$ con el modelo original para detectar presencia de no-linealidades omitidas en el modelo. Luego, la hipótesis nula es que los parámetros que acompañan a las potencias son conjuntamente iguales a 0 versus la alternativa de que son conjuntamente distintos de cero. En este caso, notamos que el p -value es mayor que 0.05, con lo cual no se rechaza la hipótesis nula y la especificación (log) lineal tiene sustento estadístico.
- El test es el de Breusch y Pagan para la hipótesis nula de homocedasticidad. Hace una regresión entre el error estimado (por **MCO**) al cuadrado (normalizado) e ingresos_2 en este caso. Testea que la **ESS/2** del modelo es pequeña, menor al crítico de la χ^2_1 , en este caso los grados de libertad son solamente 1, porque hay una variable (sin contar el intercepto). No se rechaza la nula de homocedasticidad por cuanto el p -value es mucho mayor que 0,05.

6. Dada la información del analista, podemos pensar que habría una violación del supuesto clave de **MCO** sobre la ausencia de correlación entre u y los regresores del modelo (se puede escribir de varias formas, una de ellas es $E(u|\text{ingresos}, d) = 0$). En este caso, si patrimonio y los ingresos están correlacionados, habrá correlación entre u y ambas variables del modelo. Así, el estimador **MCO** será sesgado e inconsistente.
7. Se podría usar una estrategia de variables instrumentales usando un instrumento binario $z = 1$ si el dígito fue 0 ó 9 y $z = 0$ de otra forma. Así, z está correlacionado con d_i pero no debería estarlo con u , por cuanto los números de las tarjetas son aleatorios. En notación matricial el estimador sería:

$$\beta_{\text{IV}} = (Z'X)^{-1} Z'Y$$

Ejercicio 3

1. **R:** Aplicando $\ln$ en la tecnología de la industria:

$$\ln(Y_i) = \beta_0 + \beta_1 \ln(K_i) + \beta_2 \ln(L_i) + u_i$$

los parámetros representan elasticidad producto de los factores (L y K). La hipótesis de retornos constantes a escala se testea simplemente planteando la siguiente nula:

$$H_0 : \beta_1 + \beta_2 = 1$$

contra alguna de las dos alternativas de retornos crecientes o decrecientes:

$$H_1 : \beta_1 + \beta_2 > 1 \text{ ó } H_1 : \beta_1 + \beta_2 < 1$$

2. **R:** Los signos son positivos, lo cual es esperable y ambos parámetros (elasticidades) son significativas al 1%. La bondad de ajuste (R^2) es cercana a 0.5 (ajustado y no ajustado) lo cual nos dice que aproximadamente la mitad de la variación en la variable independiente es explicada por el modelo.
3. **R:** Vemos que es claro que no rechazamos la hipótesis nula de retornos constantes a escala. El p -value es mayor a 0.01 (significancia 1%, se rechaza a todos los niveles). Dado que los tests que usan una F de Fischer se construyen haciendo formas cuadráticas y obteniendo distribuciones asimétricas, la nula es a 2 colas. **No existen tests F a una cola.** Es decir, la alternativa es inespecífica en relación a los retornos y en ese caso no muy informativa $\beta_1 + \beta_2 \neq 1$.
4. **R:**
 - a) La hipótesis nula sería $H_0 : \beta_1 + \beta_2 = 1$
 - b) La hipótesis alternativa sería $H_0 : \beta_1 + \beta_2 < 1$
 - c) Construimos un test-t

$$t = \frac{(\hat{\beta}_1 + \hat{\beta}_2) - 1}{\sqrt{v(\hat{\beta}_1 + \hat{\beta}_2) = v(\hat{\beta}_1) + v(\hat{\beta}_2) + 2Cov(\hat{\beta}_1, \hat{\beta}_2)}}$$

- d) No rechazamos la hipótesis nula.

5. **R:** Se puede concluir que a un 5% y a un 10% de significancia se rechaza la nula de homocedasticidad pero no al 1%. **Un test alternativo sería el test de White.**